

Numerical

Paolo Bettelini

Contents

1	Numerical	1
1.1	Eliminazione di Gauss	9
1.2	Matrici elementari unitarie	10
2	Metodi iterativi stazionari	14
3	Strumenti di localizzazione spettrale	22
3.1	Esempi matrici Gauss-Seidel e Jacobi	28
3.2	Gauss-Seidel è il doppio più veloce di Jacobi in certi casi	30
4	Sistemi lineari	33
4.1	Errore inerenti nei processi di soluzione di sistemi lineari	33
4.1.1	Contesto più generale	33
4.2	Metodi diretti: fattorizzazione	36
4.3	Verso la fattorizzazione di Cholesky	39
4.4	Matrici semi-elementari (generalizzazione)	43
4.5	Sherman-Morrison-Woodbury	44
5	Norme matriciali	46
5.1	Norme matriciali indotte dalla norma 1 e 2	48
6	Decomposizione ai valori singolari	50
7	Teoria dell'approssimazione	53
8	Esercizi	63

1 Numerical

Teorema Determinante matrice di Vandermonde

Sia V una matrice di Vandermonde. Allora

$$\det V = \prod_{1 \leq i < j \leq n} (A_j - A_i)$$

Quindi è invertibile se e solo se $i \neq j \implies A_i \neq A_j$.

Proof Determinante matrice di Vandermonde

We proceed by induction.

1. *Base case:* if $n = 1$, then $\det V = \det[1] = 1$.
2. *Induction:* suppose that the thesis holds for $n - 1$. Then, we can compute the determinant

using the Laplace's expansion

$$V = \left(\begin{array}{cccc|c} 1 & z_1 & \dots & z_1^{n-2} & z_1^{n-1} \\ 1 & z_2 & \dots & z_2^{n-2} & z_2^{n-1} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 1 & z_{n-1} & \dots & z_{n-1}^{n-2} & z_{n-1}^{n-1} \\ \hline 1 & z_n & \dots & z_n^{n-2} & z_n^{n-1} \end{array} \right)$$

Abbiamo

$$\det V_n = \sum_{k=0}^{n-1} (-1)^{n+(k+1)} z_n^k M_k = \sum_{k=0}^{n-1} A_k z_n^k$$

dove M_k è il minor ottenuto togliendo l'ultima riga e la colonna $k+1$ e quindi $A_k = (-1)^{n+(k+1)} M_k$. Quindi il determinante è un polinomio $P(z)$ di grado $n-1$ la cui potenza massima z_n^{n-1} corrisponde alla colonna n , cioè $M_{n-1} = \det V_{n-1}$. Otteniamo quindi l'espansione

$$\det V_n = z_n^{n-1} \det V_{n-1} + \sum_{k=0}^{n-2} V_k z_n^k$$

Per ipotesi induttiva,

$$\det V_{n-1} = \prod_{1 \leq i < j \leq n-1} (z_j - z_i)$$

che è il coefficiente del grado massimo z_n^{n-1} . Notiamo ora che se avessimo $z_n = z_k$ per qualche $k < n$, allora due righe della matrice coincidono e quindi $\det V_n = 0$, ciò implica che $P(z_k) = 0$, e quindi P ha le radici $z_1, \dots, z_{n-1}$. Allora, il polinomio ha esattamente la forma

$$P(z_n) = C \prod_{i=1}^{n-1} (z_n - z_i)$$

per qualche costante C . Ma noi sappiamo che questo coefficiente principale C è precisamente A , e quindi sostituendo otteniamo

$$\det V_n = \left(\prod_{1 \leq i < j \leq n-1} (z_j - z_i) \right) \left(\prod_{i=1}^{n-1} (z_n - z_i) \right) = \prod_{i \leq j \leq n} (z_j - z_i)$$

Teorema Forma normale di Schur

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. Esiste una matrice unitaria Q , cioè $Q^*Q = 1$, tale che

$$Q^*AQ = T$$

dove T è triangolare superiore.

Proof Forma normale di Schur

Procediamo per induzione su n .

1. *Base case:* we have $A = (a_{11}) = (e^{i\theta})(a_{11})(e^{-i\theta})$ for any $\theta \in \mathbb{R}$.
2. *Induction case:* let λ be an eigenvalue of A and let x an associated eigenvector. Sia $v_1 = x/\|x\|_2$ e quindi $Av_1 = \lambda v_1$ siccome $Ax = \lambda x$. Quindi, v_1 è un autovettore associato a λ con norma 1. Completiamo v_1 ad una base ortonormale di $\mathbb{C}^n$ usando il processo di Gram-Schmidt $\{v_1, \dots, v_n\}$. Costruiamo quindi la matrice unitaria $U_1 = [v_1, \dots, v_n]$.

Consideriamo quindi

$$U_1^* A U_1 = \begin{pmatrix} \lambda_1 & * \\ 0 & A_1 \end{pmatrix}$$

dove A_1 è una matrice $(n-1) \times (n-1)$ complessa. Per ipotesi induttiva esiste matrice unitaria U_2 tale che $U_2^* A_1 U_2 = T$ con T triangolare superiore. Allora costruiamo

$$U = U_1 \begin{pmatrix} 1 & 0 \\ 0 & U_2 \end{pmatrix}$$

Allora

$$U^* A U = \begin{pmatrix} \lambda_1 & * \\ 0 & T_1 \end{pmatrix} = T$$

è trinagolare superiore, con diagonale formata dagli autovalori di A .

Proposition

Somma diretta di matrici unitarie A, B è unitaria

Proof

$$\begin{aligned} (A \oplus B)^t (A \oplus B) &= \begin{pmatrix} A^t & 0 \\ 0 & B^t \end{pmatrix} \begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} \\ &= \begin{pmatrix} A^t A & 0 \\ 0 & B^t B \end{pmatrix} = \begin{pmatrix} I_m & 0 \\ 0 & I_n \end{pmatrix} = I_{m+n} \end{aligned}$$

Definizione Forma normale di Jordan

Sia $A \in \text{Mat}_{n \times n}$ una matrice quadrata. Una *matrice di Jordan* J associata ad A è una matrice a blocchi diagonali del tipo

$$J = \begin{pmatrix} J_1 & 0 & \cdots & 0 \\ 0 & J_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & J_k \end{pmatrix}$$

dove ogni blocco ha forma

$$J_i = \begin{pmatrix} \lambda_i & 1 & 0 & \cdots & 0 \\ 0 & \lambda_i & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_i & 1 \\ 0 & 0 & \cdots & 0 & \lambda_i \end{pmatrix}$$

con λ_i autovalori di A .

Teorema Teorema della forma normale di Jordan

Ogni matrice quadrata complessa A è simile a una e una sola matrice di Jordan J , a meno dell'ordine dei blocchi $A = PJP^{-1}$.

Siano $x, y \in \mathbb{C}^n$, allora $\|x\|_2^2 = x^* x$ e $(xy)^* = y^* x^*$. Inoltre,

$$\|A\|_2 = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|} = \rho(A^* A)$$

Se A è unitaria $\|A\|_2 = \rho(I) = 1$, ma si può dire anche che $Ax = \lambda x$.

Teorema

Sia λ autovalore di A unitaria, allora $|\lambda| = 1$.

Proof

Abbiamo che $\|Ax\|_2 = \|x\|_2$ ma ciò è uguale a $\|\lambda x\|_2 = |\lambda| \cdot \|x\|_2$, dividiamo per $\|x\|_2$ che non è nullo e troviamo la tesi.

Teorema

Sia $P \in \text{Mat}_{n \times n}(\mathbb{R})$, P matrice di permutazione, cioè $P = P^t$. Allora, λ autovalori di P sono in $\{+1, -1\}$.

Teorema

Consideriamo $\|\cdot\|$ su $\text{Mat}_{n \times n}(\mathbb{C})$ è unitariamente invariante, cioè $\forall A \in \text{Mat}_{n \times n}(\mathbb{C}), \forall P, Q$ unitarie su $\text{Mat}_{n \times n}(\mathbb{C})$, vale $\|PA\|_2 = \|AQ\|_2 = \|A\|_2$.

Proof

Abbiamo

$$\|PA\|_2 = \sup_{x \neq 0} \frac{\|PAx\|_2}{\|x\|_2} = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \|A\|_2$$

Inoltre

$$\|AQ\|_2 = \sup_{x \neq 0} \frac{\|AQx\|_2}{\|x\|_2} = \sup_{y \neq 0} \frac{\|Ay\|_2}{\|y\|_2} = \|A\|_2$$

dove $y = Qx$ e poiché Q è unitario $\|y\|_2 = \|x\|_2$.

Teorema

$GL_n(\mathbb{C})$ è denso rispetto a $\text{Mat}_n(\mathbb{C})$.

Proof

Sia $X \in \text{Mat}_{n \times n}(\mathbb{C})$. Mostriamo che $\exists \{X_s\}$ tale che $\{X_s\} \rightarrow X$, con $X_s \in GL_n(\mathbb{C})$. Se X è invertibile allora $\forall s, X_s = X$ e abbiamo finito. Altrimenti consideriamo la forma normale di Schur $X = QTQ^*$, costruiamo $X_s = QT_sQ^*$ con T_s dato da

$$(T_s)_{j,k} = \begin{cases} (T)_{j,k} & j \neq k \\ (T)_{j,k} & k = j \wedge T_{j,j} \neq 0 \\ \frac{1}{s} & k = j \wedge T_{j,j} = 0 \end{cases}$$

Quindi per costruzione T_s è invertibile per tutte le $s > 0$ ed è triangolare superiore. Abbiamo allora

$$\begin{aligned} \|X - X_s\|_2 &= \|QTQ^* - QT_sQ^*\|_2 = \|Q(T - T_s)Q^*\|_2 = \|T - T_s\|_2 \\ &= \left\| \text{diag}(\alpha_{j,s}) \right\|_2 = \frac{1}{s} \rightarrow 0 \end{aligned}$$

Con $\alpha_{j,s} = 0$ se $1 \leq j \leq n$ e $T_{j,j} \neq 0$, e $\alpha_{j,s} = -1/s$ se $1 \leq j \leq n$ e $T_{j,j} = 0$.

Definizione Quoziente di Rayleigh

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$ e $r_A: \mathbb{C}^n \setminus \{0\} \rightarrow \mathbb{C}$ data da

$$r_A(x) \triangleq \frac{x^* A x}{x^* x}$$

è il *Quoziente di Rayleigh* di A .

Definizione Matrice definita positiva

X è *definita positiva* se e solo se X è Hermitiana e $r_X(v) > 0$ per tutti i v , e tutti gli analoghi.

Questa è la definizione.

Definizione Matrice normale

Una matrice $X \in \text{Mat}_{n \times n}(\mathbb{C})$ è *normale* se $XX^* = X^*X$.

Proposition

Una matrice X normale è semidefinita positiva

Proof

Sia $B = XX^*$ e allora $B^* = X^{**}X^* = XX^* = B$. Il quoziente di Rayleigh è dato da

$$r_X(v) = \frac{v^* X X^* v}{v^* v}$$

chiamando $W = X^*v$ un vettore, allora $w^* = v^*X$, quindi

$$r_X(v) = \frac{w w^*}{v^* v}$$

che è la norma 2 e quindi il termine è non-negativo.

Per analizzare le varie classi di matrici usiamo il teorema di Shur.

Teorema

A è una matrice Hermitiana se e solo se $A = QDQ^*$, Q unitaria, e D diagonale reale.

Cioè il teorema spettrale. Sulla matrice diagonale ci sono gli autovalori e stiamo dicendo che sono reali. Cioè una matrice è Hermitiana se e solo se tutti gli autovalori sono normali e gli autovettori formano una base ortonormale.

Proof

Scomponiamo $A = QTQ^*$ per il teorema di Shur. Vogliamo quindi mostrare che T è diagonale reale. Siccome A è Hermitiana, abbiamo

$$QTQ^* = A^* = (QTQ^*)^* = Q^*T^*Q$$

Ma siccome Q è unitaria, moltiplicando a sinistra per Q^* e a destra per Q otteniamo che pure T è Hermitiana. L'unico modo per una matrice triangolare di essere Hermitiana è se i valori sopra la diagonale sono nulli. Inoltre, i valori sulla diagonale devono essere reali in quanto corrispondono al loro coniugato.

Teorema

A è una matrice normale se e solo se $A = QDQ^*$, D diagonale.

Questa è un'estensione del teorema spettrale: tutte e sole le matrici normali ammettono base ortonormale.

Proof

Scomponiamo $A = QTQ^*$ per il teorema di Schur. Siccome A è normale, $A^*A = A^*A$, e applicando nuovamente il teorema di Schur,

$$\begin{aligned} AA^* &= A^*A = (QTQ^*)^*QTQ^* = QTQ^*QT^*Q^* \\ &= QTT^*Q^* = QT^*TQ^* \end{aligned}$$

Moltiplicando a sinistra per Q^* e a destra per Q otteniamo che pure T è normale. Siccome $T^*T = T^*T$ abbiamo un pattern della matrice

$$\begin{pmatrix} * & * \\ 0 & * \end{pmatrix} \begin{pmatrix} * & 0 \\ * & * \end{pmatrix} = \begin{pmatrix} * & 0 \\ * & * \end{pmatrix} \begin{pmatrix} * & * \\ 0 & * \end{pmatrix}$$

Se consideriamo la prima riga e la prima colonna, abbiamo da una parte un numero solo e dall'altro un prodotto "intero"

$$\sum_{k=1}^n |T_{1,k}|^2 = (T^*T)_{1,1} = |T_{1,1}|^2$$

Ciò succede se e solo se $T_{1,k} = 0$, per k che va da 2 a n . Analogamente guardiamo la seconda riga: sappiamo che uno dei termini è nullo dal passo precedente, quindi $(T^*T)_{2,2} = (TT^*)_{2,2} = |T_{2,2}|^2$. Quindi $T_{2,k} = 0$ per ogni k da 3 a n . Proseguendo il procedimento troviamo quindi che la matrice è diagonale.

Teorema

Se A è una matrice unitaria se e solo se $A = QDQ^*$, D diagonale unitaria con $|D_{i,i}| = 1$.

Proof

Scomponiamo $A = QTQ^*$ per il teorema di Schur. Siccome A è identitaria, $A^*A = I = AA^*$ e quindi è anche normale, allora $A = QDQ^*$ con D diagonale. Abbiamo quindi

$$QD^*DQ = I$$

moltiplicando a sinistra per Q^* e a destra per Q otteniamo che $D^*D = I$ quindi è unitaria.

La Q sarà pure unitaria e consiste negli autovettori.

Teorema

A è definita positiva se e solo se $A = QDQ^*$ con D diagonale e $D_{j,j} > 0$. E analoghi gli altri.

Proof

A è definita positiva mediante quoziente di Rayleigh se $v^*Av > 0$ per ogni $v \neq 0$, e chiaramente deve essere Hermitiana. Abbiamo quindi la scomposizione $A = QDQ^*$ con D diagonale. Siccome Q ha come colonne una base ortonormale $\{q_1, \dots, q_n\}$, e allora il prodotto scalare con la matrice diagonale è il trasposto coniugato del vettore della base $q_j^*Q = e_j^t$. Abbiamo quindi $0 < q_j^*Aq_j =$

$e_j^t D e_j = D_{j,j}$. Quindi al variare di j , i valori sulla diagonale sono strettamente positivi.

Teorema

Se A è una matrice normale, l'immagine di r_A è il segmento fra il minimo autovalore e quello più grande.

Proof

Abbiamo

$$\begin{aligned} r_A(v) &= \frac{v^* A v}{v^* v} = \frac{v^* Q D Q^* v}{v^* v} \\ &= \frac{w^* D w}{\|w\|_2^2} \end{aligned}$$

usando $w = Q^* v$, quindi $\|w\|_2^2 = v^* v = \|v\|_2^2$. Definiamo

$$\hat{w} = \frac{w}{\|w\|_2}$$

e abbiamo quindi

$$r_A(v) = \hat{w}^* D \hat{w} = \sum_{j=1}^n |\hat{w}_j|^2 \lambda_j(A)$$

dove $\lambda_j(A)$ sono gli autovalori di A . I coefficienti complessi non sono non-negativi e sommano uno, quindi abbiamo una combinazione convessa. Tutte queste combinazioni disegnano l'involucro convesso (minimo oggetto convesso che contiene il tutto), cioè un poliedro complesso in cui i vertici sono autovalori. Siccome A è Hermitiana, tutti gli autovalori sono reali, quindi il poliedro è in realtà il segmento fra l'autovalore meno alto e il raggio spettrale.

Definizione

Sia $X \in \text{Mat}_{n \times n}(\mathbb{C})$, diciamo che X è ω -Hermitiana se $X^* = \omega X$.

Una matrice è Hermitiana se e solo se è 1-Hermitiana, e i suoi autovalori sono reali. Una matrice è anti-Hermitiana se e solo se è -1 -Hermitiana. Moltiplicare per i trasforma una matrice anti-Hermitiana in una matrice Hermitiana. Le matrici ω -Hermitiane sono uno spazio vettoriale reale ma non complesso.

In generale, siccome $X^{**} = X$ è un'involuzione sulle matrici ω -Hermitiane otteniamo

$$(\omega X)^* = \bar{\omega} X^* = |\omega|^2 X$$

Quindi ci serve per forza che ω sia un versore, altrimenti lo spazio vettoriale è degenere e contiene solo il vettore nullo (matrice nulla). Vogliamo quindi $\omega = e^{i\theta}$. Notiamo che per $\theta = 0$, gli autovalori sono reali. Per $\theta = \pi$, gli autovalori sono puramente immaginari, e più in generale gli autovalori stanno sulla retta

di angolo $\theta/2$. Partendo da $Ax = \lambda x$ abbiamo

$$\begin{aligned}x^*Ax &= \lambda \|x\|_2^2 \\(x^*Ax)^* &= (\lambda \|x\|_2^2)^* \\x^*A^*x &= \bar{\lambda} \|x\|_2^2 \\x\omega Ax &= \bar{\lambda} \|x\|_2^2 \\e^{i\theta} x^*Ax &= e^{i\theta} \lambda \|x\|_2^2 \\&= \bar{\lambda} \|x\|_2^2 \\e^{i\theta} \lambda &= \bar{\lambda}\end{aligned}$$

Definizione Diadi

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. A si dice *diade* se $\exists x, y \in \mathbb{C}^n$ tale che $A = xy^*$.

Definizione Matrice elementare

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. A si dice *elementare* se $A = I_n + F$ con F diade.

Matrici elementari nel senso dell'eliminazione gaussiana.

Proposition

Sia A diade non banale. Allora, i suoi autovalori sono

1. 0 con molteplicità geometrica $n - 1$, e y^*x come autovalore non banale.
2. se $y^*x = 0$ allora 0 ha molteplicità algebrica n e geometrica $n - 1$, e tutti gli autovettori sono gli z tali che $y^*z = 0$, che è un sottospazio di dimensione $n - 1$, cioè quelli ortogonali a y . Se $y^*x \neq 0$ le molteplicità coincidono ed è diagonalizzabile, l'autovalore rimanente è precisamente x , cioè l'autospazio relativo a $\lambda = y^*x$ è generato da x .

Proof

Siano x, y vettori complessi non banale, quindi xy^* ha rango 1 in quanto ogni riga è un multiplo di y^* . Quindi $n - 1$ autovalori sono nulli. Dunque per tutti gli z ortogonali a y ovvero $y^*z = 0$, vale che $Az = xy^*z = x \cdot 0 = 0$. Studiamo ora i vari casi. Se $xy^* = 0$ la traccia è nulla, quindi l'autovalore rimanente è zero. La molteplicità algebrica sale a n mentre quella geometrica rimane $n - 1$. Se invece $y^*x \neq 0$, cioè non è ortogonale, allora $Ax = (y^*x) \cdot x$.

Teorema

Sia $A = I_n + yx^*$ con $x, y \neq 0$. Allora, A è invertibile se e solo se $y^*x \neq -1$. In tal caso,

$$A^{-1} = I + \frac{1}{1 + y^*x} xy^*$$

Proof

Lo spettro di A è della forma $1 + \lambda(xy^*)$. Dalla caratterizzazione degli autovalori di una tale matrice, abbiamo

$$1 + \lambda(xy^*) = \begin{cases} 1 & \mu_g = n - 1 \\ 1 + y^*x & \end{cases}$$

quindi nel secondo caso vogliamo assicurarsi che $y^*x \neq -1$. Se la matrice è invertibile,

$$A^{-1} = I + \alpha xy^*$$

Per trovare α abbiamo

$$\begin{aligned}(I + \alpha xy^*)(I + xy^*) &= I + \alpha xy^* + xy^* + (\alpha y^* x)xy^* \\ &= I + [\alpha(1 + y^*x) + 1]xy^* \\ \alpha &= \frac{1}{1 + y^*x}\end{aligned}$$

Dato un sistema lineare $Bv = C$ con $B = A + xy^*$, dove $x, y \neq 0$, supponiamo di voler ricondurre alla soluzione del sistema $Av = C$ (cioè abbiamo perturbato il sistema con una matrice di rango 1) perché supponiamo di avere un algoritmo ottimale per risolvere un sistema associato ad A . Abbiamo che

$$B = A(I + A^{-1}xy^*)$$

e quindi il sistema si risolve come

$$\begin{aligned}Bv &= c \\ v &= B^{-1}c = (I + r_1 y^*)^{-1} A^{-1}c\end{aligned}$$

dove r_1 lo sappiamo risolvere da $Ar_1 = x$. Pure l'inversa A^{-1} può essere calcolata risolvendo $A\hat{c} = c$. Quindi alla fine dobbiamo applicare l'algoritmo iniziale due volte. Quindi otteniamo

$$B^{-1} = \left(I - \frac{A^{-1}xy^*}{1 + y^*A^{-1}x} \right) A^{-1} = A^{-1} - \frac{A^{-1}xy^*A^{-1}}{1 + y^*A^{-1}x}$$

In generale se perturbo una matrice grande con, per esempio, una matrice di norma 5, in generale è grande ma se il rango è 1 allora si risolve semplicemente il problema. Quindi in astratto la distanza fra matrici in un certo senso non è solo la norma ma anche il rango.

1.1 Eliminazione di Gauss

Per una matrice elementare abbiamo

$$E_{x,y}^{-1} = 1 - \frac{1}{1 + y^*x} xy^*$$

purché $y^*x \neq -1$. Sia $a \in \mathbb{C}^n$, $a_1 \neq 0$. Allora

$$E = I - \begin{pmatrix} 0 \\ a_1/a_1 \\ \vdots \\ a_n/a_1 \end{pmatrix} e_1^t$$

e quindi

$$Ea = a_1 \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

Nel nostro caso il termine

$$y^*x = e_1^t \begin{pmatrix} 0 \\ -\frac{a_2}{a_1} \\ \dots \\ -\frac{a_n}{a_1} \end{pmatrix}$$

e

$$E^{-1} = I + \begin{pmatrix} 0 \\ \frac{a_2}{a_1} \\ \dots \\ \frac{a_n}{a_1} \end{pmatrix} e_1^t$$

Quando una matrice è fortemente non-singolare allora l'algoritmo di eliminazione di gauss senza pivoting non ha breakdown (se e solo se). Sia $\hat{A}_1 = A_1 = A$ la matrice di innesco. Vogliamo trasformare questa matrice in U triangolare superiore, mantenendo l'equivalenza del sistema lineare. Sia $\hat{a}_j$ la prima colonna della matrice quadrata di ordine $n + 1 - j$, cioè al primo passo annullo tutto sotto al pivot, quindi vado avanti con matrici di quell'ordine. Allora

$$E_1 = I - \begin{pmatrix} 0 \\ 1 \end{pmatrix} e_1^t, E_2 = \left(\begin{array}{c|cccc} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & 0 \\ 0 & 0 & \dots & 0 & 1 \end{array} \right) = I - \begin{pmatrix} 0 \\ 0 \\ \vdots \\ v_2 \end{pmatrix}$$

E in generale

$$E_{n-1} = I - \begin{pmatrix} 0 \\ 0 \\ \vdots \\ v_{n-1} \end{pmatrix} e_{n-1}^t$$

e la matrice diventa

$$A_j = \left(\begin{array}{cc|ccc} * & * & * & \dots & * \\ 0 & * & * & \dots & * \\ \hline 0 & 0 & & & \\ \vdots & \vdots & & \hat{A}_j & \\ 0 & 0 & & & \end{array} \right)$$

e $A_{j+1} = E_j A_j$. Infine troviamo

$$A_n = U$$

Quindi abbiamo $U = A_n = E_{n-1} \dots E_2 E_1 A$. Per trovare A bisogna moltiplicare a sinistra per l'inversa, quindi

$$A = E_1^{-1} E_2^{-1} \dots E_{n-1}^{-1} U = \left(I + \begin{pmatrix} 0 \\ v_1 \end{pmatrix} e_1^t \right) \left(I + \begin{pmatrix} 0 \\ v_2 \end{pmatrix} e_2^t \right) \dots \left(I + \begin{pmatrix} 0 \\ \vdots \\ v_{n-1} \end{pmatrix} e_{n-1}^t \right) U$$

Dalla struttura sappiamo che questo termine che moltiplica U è triangolare inferiore. Consideriamo i primi due termini del prodotto,

$$\left(I + \begin{pmatrix} 0 \\ v_1 \end{pmatrix} e_1^t \right) \left(I + \begin{pmatrix} 0 \\ v_2 \end{pmatrix} e_2^t \right) = I + \begin{pmatrix} 0 \\ v_1 \end{pmatrix} e_1^t + \begin{pmatrix} 0 \\ 0 \\ v_2 \end{pmatrix} e_2^t + 0$$

quindi i prodotti misti delle diadi si annullano. Questo per induzione si estende a tutti i prodotti e quindi abbiamo una bella semplificazione. Notiamo che nella struttura della moltiplicazione $A = LU$, per come si svolge il prodotto, possiamo considerare la matrice a blocchi mettendo in evidenza il minore A_k , e da questa osservazione sul prodotto di matrici a blocchi, notiamo il se e solo se con la forte non-singularità. Vale $A_k = U_k L_k$ e l'ipotesi di invertibilità è equivalente a dire che i pivot non sono nulli.

1.2 Matrici elementari unitarie

Definiamo una generalizzazione per considerare anche la fattorizzazione QR , cioè unitaria per triangolare superiore.

Definizione Matrice elementare di Householder

Sia $v \in \mathbb{C}^n$ con $v \neq 0$. La *matrice elementare di Householder* è definita come

$$H_v = I - \frac{2}{\|v\|_2^2} vv^*$$

e definiamo $H_0 = I_0$.

È una correzione di rango 1 dell'identità.

Proposition

Per ogni $v \in \mathbb{C}$, la matrice H_v

1. è Hermitiana;
2. è unitaria;
3. $H_{\alpha v} = H_v$ per ogni $\alpha \neq 0$;

Proof

1. L'identità è Hermitiana, quindi H_0 è Hermitiana. Negli altri casi abbiamo

$$\begin{aligned} H_v^* &= \left(I - \frac{2}{\|v\|_2^2} vv^* \right)^* \\ &= I^* - \frac{2}{\|v\|_2^2} (vv^*)^* \\ &= I - \frac{2}{\|v\|_2^2} vv^* \end{aligned}$$

2. L'identità è unitaria, quindi H_0 è unitaria. Negli altri casi abbiamo

$$H_v^* H_v = H_v^2 = I - \frac{4}{\|v\|_2^2} vv^* + \frac{4}{\|v\|_2^4} vv^* vv^* = I$$

siccome $vv^* = \|v\|_2^2$.

3. Se $v = 0$ allora la proposizione è banale. Sia $v \neq 0$. Abbiamo

$$\begin{aligned} H_{\alpha v} &= I - \frac{2}{\|\alpha v\|_2^2} (\alpha v)(\alpha v)^* \\ &= I - \frac{2\alpha\bar{\alpha}}{|\alpha|^2 \|v\|_2^2} vv^* = H_v \end{aligned}$$

Siccome è una matrice Hermitiana e unitaria, quindi ha autovalori reali di modulo 1. Inoltre è elementare quindi ha 1 con molteplicità $n - 1$ e -1 con molteplicità 1. È diagonalizzabile quindi non distinguo il tipo di molteplicità. D'altro canto,

$$(H_v)v = v - \frac{2}{\|v\|_2^2} vv^*v = -v$$

quindi $H_v w = w$ per $w \in v^\perp$. Consideriamo $x \in \mathbb{C}^n$, possiamo decomporre lo spazio nella direzione dello v e nella sua componente ortogonale. Abbiamo quindi

$$\text{span}(v) \oplus v^\perp = \mathbb{C}^n$$

e quindi scriviamo $x = \alpha v + w$. Quindi l'applicazione è

$$H_v x = H_v(\alpha v + w) = \alpha H_v v + H_v w = w - \alpha v$$

Quindi applicare H_v ad x è come coniugare x nel piano $-v^\perp, v$.

Teorema

Per ogni $x \in \mathbb{C}^n$, esistono $v \in \mathbb{C}^n$ e $\alpha \in \mathbb{C}$ tale che $H_v x = \alpha e_1$.

Proof

Se $x = \beta e_1$ allora $H_v = I$ e $\alpha = \beta$ con $v = 0$, che è il caso banale. Altrimenti (in particolare $x \neq 0$), osserviamo che $\|x\|_2 = |\alpha|$ in quanto le matrici unitarie conservano la norma (se la dimostrazione va a buon fine). Allora possiamo scrivere $\alpha = |\alpha|e^{i\psi} = \|x\|_2^2 e^{i\psi}$. Dobbiamo trovare l'angolo. Siccome $H_v x = \alpha e_1$, dobbiamo usare proprio quella x . Siccome H_v è Hermitiana e $y^* H y \in \mathbb{R}$ per tutte le $y \in \mathbb{C}^n$, allora $x^* H_v x = x^* \alpha e_1 = \alpha \bar{x}_1$. Quindi, se scriviamo $x_1 = |x_1|e^{i\theta}$, allora

$$\alpha \bar{x}_1 = \|x\|_2 \|x\|_2 e^{i(\psi-\theta)}$$

Dunque $\psi = \theta$ oppure $\psi = \theta + \pi$. Abbiamo quindi due possibili soluzioni $\alpha = \pm \|x\|_2 e^{i\theta}$. Avendo informazioni su α , imponiamo $H_v x = \alpha e_1$. Usando la definizione

$$\begin{aligned} H_v x &= \alpha e_1 \\ \left(I - \frac{2}{\|x\|_2^2} v v^* \right) x &= \alpha e_1 x - \frac{2v^* x}{\|x\|_2^2} v = \alpha e_1 \\ \frac{2v^* x}{\|x\|_2^2} v &= x - \alpha e_1 \\ v &= x - \alpha e_1 \end{aligned}$$

dove abbiamo usato il fatto che $H_{xv} = H_v$, che funziona a patto che $v^* x \neq 0$. La condizione ci impone che

$$\begin{aligned} x^* v &= x^* (x - \alpha e_1) \\ &= \|x\|_2^2 - \alpha \bar{x}_1 \\ &= \|x\|_2^2 - (\pm \|x\|_2^2 e^{i\theta} |x_1|_2 e^{-i\theta}) \\ &= \|x\|_2^2 \mp \|x\|_2 |x_1| \end{aligned}$$

abbiamo scritto $x^* v$ al posto di $v^* x$ ma tanto è non-nullo. Scegliendo la versione con il $+$ siamo sicuri che non si annulli (in realtà anche l'altra funziona, ma la prima garantisce più stabilità numerica). Quindi scegliamo $\alpha = -\|x\|_2 e^{i\theta}$.

Esercizio

Costruire base ortonormale partendo da k vettori linearmente indipendenti. Che serve per la forma normale di Schur. Cioè che contenga lo span di quei primi k vettori e che sia ortonormale.

Teorema Fattorizzazione QR

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. Allora $\exists Q$ matrice unitaria e $\exists R$ matrice triangolare superiore tale che

$$A = QR$$

Proof Fattorizzazione QR

Partiamo dal primo passo considerando H_v tale che $H_v a^{(1)} = \alpha^{(1)} e_1$ dove e_1 è la prima colonna

di A . Data quindi $A^{(1)} = A$ possiamo costruire

$$A^{(2)} = H_v^{(1)} A^{(1)} = \left(\begin{array}{c|ccc} \alpha^{(1)} & * & \dots & * \\ 0 & & & \\ \vdots & & \hat{A}^{(2)} & \\ 0 & & & \end{array} \right)$$

Il secondo passo è quindi quello di definire

$$A^{(3)} = \left(\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ 0 & & & \\ \vdots & & H_v^{(2)} & \\ 0 & & & \end{array} \right) A^{(2)}$$

e cotinuando in generale otteniamo

$$A^{(k)} = \underbrace{\left(\begin{array}{c|ccc} I_{k-2} & 0 & & \\ 0 & & H_v^{(k-2)} & \end{array} \right)}_{\hat{H}^{(k-1)}} A^{(k-1)}$$

Continuiamo fino all'iterazione $k = n$, ottenendo quindi $A^{(n)} = R$ che è nella forma triangolare superiore

$$R = A^{(n)} = \hat{H}^{(n-1)} \hat{H}^{(n-2)} \dots \hat{H}^{(1)} A$$

In generale

$$\hat{H}^{(j)} = I_{j-1} \oplus H^{(j)}$$

Il primo blocco è quindi la matrice unitarie e il secodno una matrice di Householder. Essendo l'insieme delle matrici unitarie un gruppo moltiplicativo, R è anch'essa unitaria. Quindi $R = PA$ con

$$P = \hat{H}^{(n-1)} \hat{H}^{(n-2)} \dots \hat{H}^{(1)}$$

che è unitaria in quanto prodotto di unitarie. Infine, possiamo scrivere $A = QR$ con $Q = P^*$, che è unitaria.

Proposition

La complessità dell'algoritmo di fattorizzazione QR è $O\left(\frac{4}{3}n^3\right)$.

Proof

La matrice $H_v = I + xy^*$ viene scritta come diade dove

$$x = -\frac{2}{\|v\|_2^2}v, \quad y = v$$

Al primo passaggio abbiamo $\hat{H}^{(1)} = H^{(1)}$ e per passare da $A^{(1)}$ ad $A^{(2)}$ abbiamo una matrice la cui prima colonna ha in cima $\alpha^{(1)}$ e sotto zeri, il resto delle colonne sono i vettori s_j

$$\left(\begin{array}{c|c|c|c} \alpha^{(1)} & & & \\ 0 & s_2 & \cdots & s_n \\ \vdots & & & \\ 0 & & & \end{array} \right)$$

quindi la colonna è data da

$$s_j = H^{(1)} \text{col}_j(A^{(1)})$$

per $j \in \{2, \dots, n\}$. Il costo da iterare è quindi quello di una moltiplicazione di un vettore per una matrice di Householder, cioè il costo di $(I + xy^*)c$ per $c \in \mathbb{C}^n$. Sia $\gamma = y^*c$, che è un prodotto scalare, quindi m moltiplicazioni ed $n - 1$ somme (parallelizzabile). Dopodiché $\hat{x} = \gamma x$ costa n moltiplicazioni. Infine $I + \hat{x}$ sono n somme. Abbiamo quindi un costo complessivo di $(n-1)(4n-1)$ operazioni. Considerando tutti i passaggi abbiamo una somma

$$\begin{aligned} \sum_{\tau=n}^2 (n-1)(4n-1) &= \sum_{\tau=2}^n (n-1)(4n-1) = \sum_{\tau=2}^n (4\tau^2 - 5\tau + 1) \\ &= \sum_{\tau=2}^n 4\tau^2 + \mathcal{O}(n^2) = \frac{4}{3}n^3 + \mathcal{O}(n^2) \end{aligned}$$

2 Metodi iterativi stazionari

Consideriamo $A \in \text{Mat}_{n \times n}(\mathbb{C})$ invertibile. Abbiamo lo *splitting regolare* (M, N) se $A = M - N$ tale che M è invertibile. Consideriamo quindi il sistema lineare $Ax = b$ con $b \in \mathbb{C}^n$ con un suo splitting regolare. Il sistema è quindi equivalente a $(M - N)x = b$, oppure $Mx = b + Nx$. Siccome M è invertibile, $x = Px + c$ dove $P = M^{-1}N$ e $c = M^{-1}b$. Siccome $x = Px + c$, allora la soluzione è punto fisso di una trasformazione lineare $T: \mathbb{C}^n \rightarrow \mathbb{C}^n$ tale che $T(y) = Py + c$. Vogliamo quindi trovare il punto fisso di T . Il metodo iterativo collegato è $x^{(k+1)} = Px^{(k)} + c$ dato un punto iniziale $x^{(0)}$. Quindi, definito $e^{(j)} = x^{(j)} - x$, abbiamo che $e^{(k+1)} = Pe^{(k)}$, e quindi $e^k = P^k e^{(0)}$. Abbiamo quindi convergenza se e solo se

$$\lim_{k \rightarrow \infty} P^k = 0$$

Ci serve che il raggio spettrale sia minore di 1.

Definizione Modulo di una matrice

Sia $X \in \text{Mat}_{n \times n}(\mathbb{C})$. Definiamo

$$|X| = (|X_{j,k}|)_{j,k}^n$$

Teorema Matrix power convergence

Sia $P \in \text{Mat}_{n \times n}(\mathbb{C})$ e $k \in \mathbb{N}$. Allora,

$$\lim_k P^k = 0$$

se e solo se $\rho(P) < 1$.

Proof

($\Rightarrow$) Sappiamo che

$$\lim_k P^k = 0$$

e consideriamo λ autovalore di P con autovettore associato $x \neq 0$.

1. Da un lato sappiamo che $P^k x = \lambda^k x$;
2. Dall'altro sappiamo che

$$\lim_k (P^k y) = \left(\lim_k P^k \right) y = 0, \quad \forall y \in \mathbb{C}^n$$

Ciò implica che

$$\lim_k \lambda^k x = 0$$

che necessita $|\lambda| < 1$.

($\Leftarrow$) Distinguiamo i due casi:

1. *Caso diagonalizzabile*: Abbiamo $P = TDT^{-1}$ dove D è la matrice diagonale degli autovalori λ_i . Elevando alla k abbiamo quindi

$$P^k = (TDT^{-1})^k = TD^k T^{-1}$$

Quindi, per continuità del prodotto matriciale, abbiamo

$$\lim_k P^k = T \left(\lim_k D^k \right) T^{-1}$$

Ma dalla forma di D , il limite tende a 0 se e solo se $|\lambda_i| < 1$. Ma siccome il raggio spettrale è minore di 1 allora vale.

2. *Caso non diagonalizzabile*: Utilizzando la scomposizione di Schur otteniamo $P = QTQ^*$ con Q unitaria e T triangolare superiore. Abbiamo

$$\lim_k P^k = 0$$

se e soltanto se

$$\lim_k T^k = 0$$

in quanto $P^k = QT^k Q^*$. Notiamo che

$$0_{\text{Mat}_{n \times n}(\mathbb{C})} \leq |T| = \begin{pmatrix} |\lambda_1| & & & * \\ & |\lambda_2| & & \\ & & \ddots & \\ 0 & & & |\lambda_n| \end{pmatrix} \leq \begin{pmatrix} \gamma_1 & & & * \\ & \gamma_2 & & \\ & & \ddots & \\ 0 & & & \gamma_n \end{pmatrix} = \hat{T}$$

Stiamo usando l'ordinamento parziale indotto sulle matrici. Nella forma di Schur, possiamo permutare gli elementi della diagonale come vogliamo, quindi scegliamo di ordinarli in modo crescente:

$$|\lambda_1| \leq |\lambda_2| \leq \dots \leq |\lambda_n|$$

L'idea è la seguente: affinché $\hat{T}$ sia sicuramente diagonalizzabile, vogliamo che i suoi elementi diagonali γ_i siano a due a due distinti. Ogni qualvolta troviamo dei termini in $|T|$ che coincidono, aggiungiamo un valore ad uno tale da non fargli superare il successivo nella catena. Ad esempio, se abbiamo un blocco di autovalori con lo stesso modulo:

$$|\lambda_j| = |\lambda_{j+1}| = \dots = |\lambda_q| < |\lambda_{q+1}|$$

poniamo $\varepsilon = |\lambda_{q+1}| - |\lambda_j|$ e definiamo i nuovi valori aggiungendo incrementi successivi di $\frac{\varepsilon}{N}$ (con N opportunamente grande):

$$\gamma_j = |\lambda_j|, \quad \gamma_{j+1} = |\lambda_j| + \frac{\varepsilon}{N}, \quad \gamma_{j+2} = |\lambda_j| + \frac{2\varepsilon}{N}, \dots$$

facendo attenzione a restare strettamente minori del valore distinto successivo. Imponiamo infine che l'ultimo termine $\gamma_n < 1$ (il che è possibile poiché $\rho(P) < 1$), in maniera tale da avere tutti numeri non negativi, a due a due distinti, e tutti minori di 1.

Notiamo che $|T^k| \leq |T|^k$ per espansione del prodotto e applicando la disuguaglianza triangolare. Passando all'esponente per k , abbiamo la seguente catena:

$$0_{\text{Mat}_{n \times n}(\mathbb{C})} \leq |T^k| \leq |T|^k \leq \hat{T}^k$$

Ma siccome $\hat{T}$ ha autovalori tutti distinti è diagonalizzabile, e avendo $\rho(\hat{T}) < 1$, per il caso precedente il suo limite tende a zero. Per il teorema del confronto, il limite della catena collassa a 0, implicando $\lim_k |T^k| = 0$, e dunque $\lim_k P^k = 0$.

Negli spazi finiti dimensionali, tutte le metriche sono equivalenti e quindi il risultato non dipende dalla norma. Invece, in uno spazio infinito dimensionale va specificato, in quanto qualcosa può contrarsi rispetto ad una metrica ma non rispetto ad un'altra.

Teorema Teorema di equivalenza delle norme in $\mathbb{C}^n$

todo

Il raggio spettrale è un invariante che ha a che fare con le norme.

Teorema

Sia $\mathcal{N}$ l'insieme delle norme su $\text{Mat}_{n \times n}(\mathbb{C})$ indotte. Allora, $\forall P \in \text{Mat}_{n \times n}(\mathbb{C})$, vale

$$\rho(P) = \inf_{\|\cdot\| \in \mathcal{N}} \|P\|$$

Utilizziamo quindi questo per il teorema della contrazioni di Banach.

Definizione Metodo iterativo stabile

Metodo iterativo matriciale si dice *stabile* se $\rho(P) < 1$.

Definizione Metodo iterativo consistente

Metodo iterativo matriciale si dice *consistente* se è un punto fisso della mappa $\mathbb{C}^n \rightarrow \mathbb{C}^n$ data da $y \rightarrow Py + q$.

Questo ci dà in parte l'arbitrarietà del punto iniziale.

Teorema

Un metodo iterativo è convergente se e solo se è stabile e consistente.

Dato un sistema $Ax = b$, possiamo scrivere $A = M - N$ dove M è non singolare. Allora,

$$\begin{aligned}(M - N)x &= b \\ Mx - Nx &= b \\ Mx &= Nx + b \\ x &= \underbrace{M^{-1}N}_p x + \underbrace{M^{-1}b}_q\end{aligned}$$

L'altra decomposizione classica è $A = D - B - C$ dove $D = \text{diag}(A)$, B è triangolare inferiore con diagonale nulla e C è triangolare superiore con diagonale nulla.

Definizione Metodo di Jacobi

Sia $M = D$ e $N = B + C$ nella composizione a tre fattori. La matrice di iterazione è definita come

$$J = D^{-1}(B + C)$$

quindi

$$x^{(k+1)} = Jx^{(k)} + \underbrace{D^{-1}b}_q$$

Nel metodo di Jacobi $\det M \neq 0$ se e solo se tutti gli elementi principali di A sono non-nulli.

Il metodo di Jacobi è sia consistente che stabile. È costruire usando la definizione di consistenza, quindi quello è ovvio. Inoltre, il metodo è stabile in quanto la matrice ha ragione spettrale minore di 1. In forma

$$x_i^{(k+1)} = \frac{1}{a_{i,i}} \left[b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{i,j} x_j^{(k)} \right]$$

Teorema

Sia $A = D - B - C$ la decomposizione a tre fattori di A . Se almeno una delle seguenti ipotesi:

1. A è a predominanza diagonale forte (sia righe che colonne);
2. A è a predominanza diagonale debole e A è irriducibile;
3. A è a predominanza diagonale forte per colonne;
4. A è a predominanza diagonale debole per colonne e A è irriducibile;

Allora, $\rho(P) < 1$ e quindi il metodo di Jacobi è convergente.

Proof

Dimostriamo la (3). A è invertibile per i teoremi di Gershgorin e gli elementi diagonali sono non-nulli, altrimenti non sarebbe né invertibile né a predominanza diagonale. La consistenza è data dalla definizione. Dobbiamo solamente mostrare che $\rho(J) < 1$. Mostriamo infatti che per ogni autovalore $\lambda \in \sigma(J)$ abbiamo $|\lambda| < 1$. Supponiamo per assurdo che esista $\exists \nu$ tale che $|\nu| \geq 1$. Allora deve soddisfare il polinomio caratteristico

$$\begin{aligned}
 0 &= \det(J - \nu I_n) \\
 &= \det(D^{-1}(B + C) - \nu I_n) \\
 &= \det(D^{-1}(B + C) - \nu D^{-1}D) \\
 &= \underbrace{\det(D^{-1})}_{\neq 0} \cdot \det(B + C - \nu D) \quad \left. \vphantom{\det(D^{-1})} \right\} \text{Teorema di Binet} \\
 \implies 0 &= \det(\underbrace{B + C - \nu D}_H)
 \end{aligned}$$

Di questa matrice H possiamo dire che

$$|h_{i,j}| = \begin{cases} |\mu a_{i,i}| & i = j \\ |a_{i,j}| & i \neq j \end{cases}$$

Poiché $|\mu| \geq 1$ e H è a predominanza diagonale per colonne e irriducibile, quindi è anche invertibile. Ma questo è assurdo.

Proof Alternativa

Partiamo da

$$J = D^{-1}(B + C) = - \begin{bmatrix} \frac{1}{a_{11}} & 0 & \cdots & 0 \\ 0 & \frac{1}{a_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{a_{nn}} \end{bmatrix} \cdot \begin{bmatrix} 0 & * & \cdots & * \\ * & 0 & \cdots & * \\ \vdots & \vdots & \ddots & \vdots \\ * & * & \cdots & 0 \end{bmatrix} = - \begin{bmatrix} 0 & \frac{*}{a_{11}} & \cdots & \frac{*}{a_{11}} \\ \frac{*}{a_{22}} & 0 & \cdots & \frac{*}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{*}{a_{nn}} & \frac{*}{a_{nn}} & \cdots & 0 \end{bmatrix}$$

I cerchi di Gershgorin sono centrati nell'origine e sono concentrici con raggi

$$r_i = \frac{\sum_{j=1, j \neq i}^n |a_{i,j}|}{|a_{i,i}|} < 1$$

per il terzo teorema di Gershgorin, siccome A è a predominanza diagonale stretta oppure A è a predominanza diagonale debole ed è irriducibile.

È un altamente paralelizzabile.

Definizione Metodo di Gauss-Seidel

Sia $M = D - B$ e C nella composizione a tre fattori. La matrice di iterazione è definita come

$$G = (D - B)^{-1}C$$

quindi

$$x^{(k+1)} = Gx^{(k)} + (D - B)^{-1}b$$

L'iterazione ha forma

$$\begin{aligned} x^{(k+1)} &= Gx^{(k)} + (D - B)^{-1}b \\ Dx^{(n+1)} - Bx^{(k+1)} &= Cx^{(k)} + b \\ x^{(k+1)} &= D^{-1}Bx^{(k+1)} + D^{-1}Cx^{(k)} + D^{-1}b \\ x_i^{(k+1)} &= \frac{1}{a_{i,i}} \left[b_i - \sum_{j=1}^{i-1} a_{i,j}x_j^{(k+1)} - \sum_{j=i+1}^n a_{i,j}x_j^{(k)} \right] \end{aligned}$$

Jacobi è chiamato il metodo degli elementi simultanei, mentre Gauss-Seidel il metodo degli elementi successivi.

Teorema

Sia $A = D - B - C$ la decomposizione di A per tre fattori. Se vale una delle seguenti ipotesi:

1. A è a predominanza diagonale forte (sia righe che colonne);
2. A è a predominanza diagonale debole e A è irriducibile;
3. A è a predominanza diagonale forte per colonne;
4. A è a predominanza diagonale debole per colonne e A è irriducibile;

Allora, $\rho(P) < 1$ e quindi il metodo di Gauss-Seidel è convergente.

Proof

A è invertibile per i teoremi di Gershgorin e gli elementi diagonali sono non-nulli, altrimenti non sarebbe né invertibile né a predominanza diagonale. La consistenza è data dalla definizione. Dobbiamo solamente mostrare che $\rho(J) < 1$. Supponiamo per assurdo che esista $\exists \nu$ tale che $|\nu| \geq 1$. Allora deve soddisfare il polinomio caratteristico

$$\begin{aligned} 0 &= \det(G - \nu I_n) \\ &= \det((D - B)^{-1}C - \nu I_n) \\ &= \det((D - B)^{-1}C - \nu(D - B)^{-1}(D - B)) \\ &= \underbrace{\det((D - B)^{-1})}_{\neq 0} \cdot \det(C - \nu(D - B)) \quad \left. \vphantom{\det((D - B)^{-1})} \right\} \text{Teorema di Binet} \\ \implies 0 &= \det(\underbrace{C - \nu(D - B)}_H) \\ |h_{i,j}| &= \begin{cases} |\mu a_{i,i}| & i \geq j \\ |a_{i,j}| & i < j \end{cases} \end{aligned}$$

Poiché $|\mu| \geq 1$ e H è a predominanza diagonale per colonne e irriducibile (come A), allora

$$\begin{aligned} |h_{i,j}| &= |\nu| \sum_{\substack{j=1 \\ j \neq i}}^n |a_{i,j}| = |\nu| \sum_{j>1}^n |a_{i,j}| + |\nu| \sum_{j<i} |a_{i,j}| \\ &= \sum_{j<1}^n |h_{i,j}| + |\nu| \sum_{j>1}^n |a_{i,j}| \stackrel{(*)}{\geq} \sum_{j<i} |h_{i,j}| + \sum_{j>i} |a_{i,j}| = \sum_{j \neq i}^n |h_{i,j}| \end{aligned}$$

Sempre per il fatto che A è a predominanza diagonale per colonne, $\exists i_0 \in \{1, \dots, n\}$ tale che

$$|a_{i_0, i_0}| > \sum_{\substack{j=1 \\ j \neq i_0}}^n |a_{j, i_0}|$$

e per questo indice la maggiorazione in $(*)$ vale in senso stretto. Ma quindi la matrice H è invertibile, che è assurdo.

Esempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} 3 & 0 & 4 \\ 7 & 4 & 2 \\ -1 & -1 & -2 \end{pmatrix}, \quad (7 \quad 13 \quad -4)$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & 0 & -\frac{4}{3} \\ -\frac{7}{4} & 0 & -\frac{1}{2} \\ -\frac{1}{2} & -\frac{1}{2} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & 0 & -\frac{4}{3} \\ 0 & 0 & \frac{11}{6} \\ 0 & 0 & -\frac{1}{4} \end{pmatrix}$$

Il raggio spettrale di J è circa $1,337 > 1$ quindi il metodo non converge, mentre $\rho(G) = \frac{1}{4} < 1$ quindi è convergente.

Esempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} -3 & 3 & -6 \\ -4 & 7 & -8 \\ 5 & 7 & -9 \end{pmatrix}, \quad (-6 \quad -5 \quad 3)$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & 1 & -2 \\ \frac{4}{7} & 0 & \frac{8}{7} \\ \frac{5}{9} & \frac{7}{9} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & 1 & -2 \\ 0 & \frac{4}{7} & 0 \\ 0 & 1 & -\frac{10}{9} \end{pmatrix}$$

Abbiamo i raggi spettrali $\rho(J) = 0.81 < 1$ e $\rho(G) = 1.11 > 1$, quindi quello di Jacobi converge mentre quello di Gauss-Seidel no.

Esempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} 4 & 1 & 1 \\ 2 & -9 & 0 \\ 0 & -8 & -6 \end{pmatrix}, \quad (6 \quad -7 \quad -14)$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & -\frac{1}{4} & -\frac{1}{4} \\ \frac{2}{9} & 0 & 0 \\ 0 & -\frac{4}{3} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & -\frac{1}{4} & -\frac{1}{4} \\ 0 & -\frac{1}{18} & -\frac{1}{18} \\ 0 & \frac{2}{27} & \frac{2}{27} \end{pmatrix}$$

Abbiamo i raggi spettrali $\rho(J) = 0.44 < 1$ e $\rho(G) = 0.018 < 1$, quindi entrambi convergono ma quello di Gauss-Seidel è più veloce.

Per le matrici a predominanza diagonale stretta, vale in generale che sulla matrice di Gauss-Seidel e Jacobi

$$\|G\|_{\infty} \leq \|J\|_{\infty} < 1$$

Tuttavia, anche se $\rho(G) \leq \|G\|_{\infty}$ e $\rho(J) \leq \|J\|_{\infty}$, non sempre ne consegue che $\rho(G) \leq \rho(J)$, cioè non sempre il metodo di Gauss-Seidel è asintoticamente più veloce rispetto a quello di Jacobi.

Esempio Controesempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} 11 & -5 & -5 \\ 5 & -12 & 6 \\ 6 & -4 & 11 \end{pmatrix}, \quad (1 \quad 23 \quad 13)$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & \frac{5}{11} & \frac{5}{11} \\ -\frac{5}{12} & 0 & -\frac{5}{2} \\ -\frac{6}{11} & \frac{4}{11} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & \frac{5}{11} & \frac{5}{11} \\ 0 & -\frac{25}{132} & -\frac{91}{132} \\ 0 & -\frac{115}{363} & -\frac{131}{363} \end{pmatrix}$$

Abbiamo i raggi spettrali $\rho(J) = 0.79$ e $\rho(G) = 0.83$, e norme $\|J\|_{\infty} = 0.916$ e $\|G\|_{\infty} = 0.909$.

3 Strumenti di localizzazione spettrale

Definizione Cerchi di Gershgorin

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$, allora i cerchi di Gershgorin sono i cerchi complessi

$$C_j = \{z \in \mathbb{C} \mid |z - A_{j,j}| \leq r_j\}, \quad r_j = \sum_{\substack{k=1 \\ k \neq j}}^n |A_{j,k}|$$

Teorema Teorema di Gershgorin I

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$, λ autovalore di A . Allora,

$$\lambda \in \bigcup_{j=1}^n C_j$$

Teorema Teorema di Gershgorin II

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$ e siano $s_1, \dots, s_t, I_i$ insiemi di indici dove

$$s_i \triangleq \bigcup_{u \in I_i} C_u$$

tali che

1. $s_l \cap s_m = \emptyset$ per $l, m \in \{1, \dots, t\}$ con $l \neq m$;
2. $\bigcup_i I_i = \{1, \dots, n\}$ e $I_l \cap I_m = \emptyset$ per $l \neq m$.

Chiamiamo $k_l = |I_l|$. Allora, s_i contiene esattamente k_i autovalori.

Proof Teorema di Gershgorin I

Consideriamo la relazione

$$\sum_{k=1}^n A_{j,k} x_k = \lambda x_j$$

dove scegliamo j come indice p tale che $|x_p| = \|x\|_\infty > 0$, cioè vogliamo massimizzare la parte destra. Riscriviamo questa relazione per l'indice p ma isolando questo termine,

$$\begin{aligned} \lambda x_p - A_{p,p} x_p &= \sum_{\substack{k=1 \\ k \neq p}}^n A_{p,k} x_k \\ |(\lambda - A_{p,p}) x_p| &= \left| \sum_{\substack{k=1 \\ k \neq p}}^n A_{p,k} x_k \right| \\ |\lambda - A_{p,p}| \cdot |x_p| &\leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| \\ |\lambda - A_{p,p}| &\leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \frac{|x_k|}{|x_p|} \leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \end{aligned}$$

$|x_k| \leq |x_p|$

Quindi, l'autovalore sta nell'unione di tutti i cerchi, in quanto non so in quale cerchio sta

$$\lambda \in \bigcup_{j=1}^n C_j$$

Proof Teorema di Gershgorin II

Scriviamo $A_n = D + R$ dove D è la diagonale di A e R il resto. Sia $t \in [0, 1]$ e $A_n(t): [0, 1] \rightarrow M_n(\mathbb{C})$ definita da

$$A_n(t) = D + tR$$

Abbiamo quindi che $A_n(0) = D$ e $A_n(1) = A_n$. Definiamo i cerchi

$$C_j(t) = \{z \in \mathbb{C} \mid |A_{j,j} - z| \leq tr_j\}$$

Per il polinomio caratteristico, ogni coefficiente del polinomio è una funzione continua in t siccome le entrate lo sono. Quindi gli autovalori dipendono continuamente dai coefficienti. Quindi siccome $A_{j,k}(t)$ è una funzione lineare affine in t , allora

$$\det(A_n(t) - \lambda I) = (-1)^n \lambda^n + \alpha_{n-1}(t) \lambda^{n-1} + \dots + \alpha_1(t) \lambda + \alpha_0$$

Se abbiamo dei cerchi di Gershgorin separati, allora tutti gli autovalori sono separati. Ma se per esempio la matrice evolve in maniera continua, e due cerchi si toccano, allora entrambi gli autovalori di quei due cerchi possono spostarsi interamente in uno dei cerchi ma non nell'altro.



Esempio Teorema di Gershgorin I

Consideriamo la matrice

$$\begin{pmatrix} 10 & 1 & 3 & 3 \\ -1 & 4 & 0 & 1 \\ i & i & 4 & i \\ i+1 & 0 & 0 & 3i \end{pmatrix}$$

Abbiamo i seguenti cerchi di Gershgorin


$$C_1 = \{z \in \mathbb{C} \mid |z - 10| \leq 7\}$$

$$C_2 = \{z \in \mathbb{C} \mid |z - 4| \leq 2\}$$

$$C_3 = \{z \in \mathbb{C} \mid |z - 4| \leq 3\}$$

$$C_4 = \{z \in \mathbb{C} \mid |z - 3i| \leq \sqrt{2}\}$$

Possiamo notare che sicuramente il determinante della matrice non è nullo.



Definizione Grafo fortemente connesso

todo


Definizione Matrice irriducibile

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. Si dice che A è *irriducibile* se G_A è fortemente connesso dove G_A è il grafo (N, E) con $N = \{1, \dots, n\}$ dove $(J, K) \in E$ se e solo se $A_{j,k} \neq 0$.

**Esempio Teorema di Gershgorin II e III**

Consideriamo la matrice

$$A = \begin{pmatrix} -10 & 1 & & & & \\ 1 & -10 & 1 & & & 0 \\ & 1 & -10 & 1 & & \\ & & 1 & -10 & 1 & \\ 0 & & & 1 & -10 & 1 \\ & & & & -1 & 77 \end{pmatrix}$$




Mostrare che esiste un autovalore λ di questa matrice tale che $\lambda = \rho(A)$.

Abbiamo i cerchi

$$\begin{aligned} C_1 &= \{z \in \mathbb{C} \mid |z + 10| \leq 1\} \\ C_2 = C_3 = C_4 = C_5 &= \{z \in \mathbb{C} \mid |z + 10| \leq 2\} \\ C_6 &= \{z \in \mathbb{C} \mid |z - 77| \leq 1\} \end{aligned}$$

C'è quindi un singolo autovalore in C_6 , ma quest'ultimo non può essere propriamente complesso in quanto ci sarebbe un'altro autovalore coniugato nello stesso cerchio. Quindi quell'autovalore è reale e coincide con il raggio spettrale, data la sua distanza dall'origine. Il suo grafo associato è fortemente connesso:

**Teorema Teorema di Gershgorin III**

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$, A irriducibile e tale l'autovalore λ sta sul bordo dell'unione dei cerchi

$$\lambda \in \partial \left(\bigcup_{j=1}^n C_j \right)$$

Allora λ sta sul bordo di tutti i cerchi $\lambda \in \partial C_j, \forall j \in \{1, \dots, n\}$.

Non si verifica quasi mai l'ipotesi, quindi conviene usare la contronominale.

Proof Teorema di Gershgorin III

Sia λ un autovalore e sia x un suo autovettore. Consideriamo la relazione

$$\sum_{k=1}^n A_{j,k} x_k = \lambda x_j$$

dove scegliamo j come indice p tale che $|x_p| = \|x\|_\infty > 0$, cioè vogliamo massimizzare la parte destra.

$$\begin{aligned} \lambda x_p - A_{p,p} x_p &\leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| \leq |x_p| \cdot r_p \\ \lambda x_p - A_{p,p} x_p &= \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| = |x_p| \cdot r_p \end{aligned}$$

Ma per l'ipotesi l'autovalore sta sul bordo, quindi r_p è precisamente il raggio del cerchio. Scelgo $u = p$ e guardiamo con attenzione alla relazione

$$\sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| = \left(\sum_{\substack{u=1 \\ u \neq p}}^n |A_{p,u}| \right) |x_p|$$

Visto che è irriducibile, almeno un termine $i_2 \neq p$ esiste tale che $A_{p,i_2} \neq 0$. Abbiamo quindi necessariamente che $|x_{i_2}| = |x_p|$. Ma allora, tornando a Gershgorin I, avremmo potuto seguire la medesima dimostrazione su $i_2 \neq p$ al posto di p . Quindi, $\lambda \in C_{i_2}$, e per ipotesi λ sta quindi in ∂C_{i_2} . Iterando questo argomento $n - 1$, esaurendo l'insieme dei nodi, otteniamo la tesi.

Esempio Teorema di Gershgorin III

Consideriamo la matrice

$$A = \begin{pmatrix} 0 & 1 & & & 0 \\ & 0 & 1 & & 0 \\ & & \ddots & \ddots & \\ & & & \ddots & \ddots \\ 0 & & & & 0 & 1 \\ 1 & & & & 0 & 0 \end{pmatrix}$$


Ha autovalori pari a

$$\lambda_j = e^{i \frac{2\pi j}{n}}$$

e autovettori relativi

$$v^{(j)} = \left(\frac{1}{\sqrt{n}} e^{i \frac{2\pi j}{n} k} \right)_{k=1}^n$$

Il suo grafo associato è fortemente connesso:



Esempio Teorema di Gershgorin III

Consideriamo la matrice

$$A = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & 0 \\ & \ddots & \ddots & \ddots & \\ & & \ddots & \ddots & \ddots \\ 0 & & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix}$$

che discretizza l'equazione differenziale

$$\begin{cases} -u''(x) = f(x), & x \in (0, 1) \\ u(0) = \alpha \\ u(1) = \beta \end{cases}$$

con $A_n u = v$. Cominciamo notando che A_n è simmetrica, reale quindi Hermitiana, allora i suoi autovalori sono reali. Abbiamo i cerchi


$$C_1 = C_n = \{z \in \mathbb{C} \mid |z - 2| \leq 1\}$$

$$C_2 = C_3 = \dots = C_{n-1} = \{z \in \mathbb{C} \mid |z - 2| \leq 2\}$$

Dai teoremi di Gershgorin, siccome gli autovalori sono reali, sappiamo quindi che

$\lambda \in [0, 4]$. La matrice associata è irriducibile in quanto tridiagonale. Tuttavia, $0, 4 \notin \partial C_1$, mentre

$$0, 4 \in \partial \left(\bigcup_{j=2}^n C_j \right)$$



dunque $\lambda \in (0, 4)$. Sappiamo che se $B = A^*$, allora

$$\lambda_{\min}(B) = \min_{\substack{x \in \mathbb{C}^n \\ x \neq 0}} \frac{x^* B x}{x^* x}$$

Ci aspettiamo che r_n sia piccolo con e il vettore di 1

$$A_n e = \begin{pmatrix} 1 & 0 & \dots & 0 & 1 \end{pmatrix}$$

e il raggio $r_n = 2/n \rightarrow 0$ per $n \rightarrow \infty$. Se scegliessimo il vettore con elementi che si alternano $1, -1$, abbiamo più sovrapposizione possibili. I coefficienti oscillano, il vettore oscilla e quindi risuoniamo il più possibile. In tal caso otteniamo un valore appena inferiore al 4.

Supponiamo che $A \in \text{Mat}_n(\mathbb{C})$ con n grande. Come facciamo a verificare in maniera algoritmica se la matrice è fortemente connessa? Sia G_A il suo grafo associato. Consideriamo X la matrice di adiacenza di G_A . Consideriamo $Y = X^2$, cioè

$$(Y)_{j,k} = \sum_{l=1}^n x_{j,l} x_{l,k}$$

Cioè visto che i termini sono booleani, allora fa 1 se posso muovermi da j a e e da e a k , quindi muoversi fra j a k in due passi. Quindi il termine $(Y)_{j,k}$ è il numero di modi di traversare i due nodi in 2 passi. Possiamo semplificare usando una or iterata

$$(Y)_{j,k} = \bigvee_{l=1}^n x_{j,e} \cdot x_{e,k}$$

In generale, $(X^n)_{j,k}$ ci mostra il numero di cammini per connettere i nodi j, k . Sia

$$\tilde{X} = I_n \vee \bigvee_{k=1}^{n-1} X^k$$

Se tale matrice è tutta piena di 1, significa che X è fortemente connessa. L'identità serve per assicurarci che abbiamo uni sulla diagonale, cioè ogni elemento ha un percorso verso sè stesso, cioè il percorso nullo.

Tuttavia, l'algoritmo più ottimale è quello di fare un attraversamento DFS sul grafo, controllare, e poi un attraversamento DFS sul grafo invertito (che è associato alla matrice trasposta).

Teorema

Sia A Hermitiana con elementi principali reali positivi, cioè $a_{i,i} > 0$. Allora, l'iterazione di Gauss-Seidel è convergente se e solo se A è definita positiva.

Proof

Decomponiamo la matrice come $A = D - B - C = D - B - B^H$ siccome è Hermitiana. Allora la matrice di iterazione è

$$\begin{aligned} G &= (D - B)^{-1}C = (D - B)^{-1}B^H \\ &= (D - B)^{-1}(B^H + D - B - D + D) = I - (D - B)^{-1}A \end{aligned}$$

Prima di dimostrare l'uguaglianza, mostriamo che la matrice $Z \triangleq A - G^H AG$ è definita positiva. Poniamo $F \triangleq (D - B)^{-1}A$. Data l'uguaglianza precedente $G = I - F$. In particolare,

$$\begin{aligned} Z &= A - G^H AG = A - (I - F)^H A(I - F) \\ &= \cancel{A} - \cancel{A} + F^H A + AF - FAF = F^H (A + F^{-H} AF - AF) \\ &= F^H (AF^{-1} + F^{-H} A - A) F \\ &= F^H (\cancel{AA^{-1}}(D - B) + (D - B)^H \cancel{A^{-H}A} - A) F \\ &= F^H (D - B + D - B^H - A) F = F^H (D + A - A) F = F^H DF \end{aligned}$$

F è non singolare perché $(D - B)^{-1}$ e A non lo sono nemmeno. Inoltre, siccome A ha elementi principali positivi, D a sua volta ha elementi reali positivi, quindi $\forall x \in \mathbb{C}^n \setminus \{0\}$

$$\begin{aligned} x^H Z x &= x^H (A - G^H AG) x = x^H F^H DF x \\ &= y^H D y = \sum_{i=1}^n A_{i,i} \underbrace{|y_i|^2}_{\geq 0} > 0 \end{aligned} \quad \left. \vphantom{\sum_{i=1}^n} \right\} y = Fx$$

Concludiamo ora il teorema:

($\Leftarrow$) Supponiamo che A sia definita positiva. Consideriamo un autovalore $\lambda \in \sigma(G)$ e x autovettore corrispondente, quindi $Gx = \lambda x$. Siccome A è definita positiva,

$$\begin{aligned} x^H Z x &= x^H (A - G^H AG) x = x^H Ax - x^H G^H AG x \\ &= x^H Ax - \bar{\lambda} x^H A \lambda x = x^H Ax - |\lambda|^2 x^H Ax \\ &= (1 - |\lambda|^2) x^H Ax \end{aligned}$$

Siccome Z è definito positivo, questo termine è positivo se e solo se $1 - |\lambda|^2$, cioè $1 > |\lambda|$. In altre parole se e solo se $\rho(G) < 1$.

($\Rightarrow$) Supponiamo che il metodo sia convergente e mostriamo che A è definita positiva. Consideriamo l'errore

$$e^{(k)} = x^* - x^{(k)}$$

dove x^* è la soluzione del sistema. Questa successione tende a zero per ipotesi. Poiché $e^{(k)} = Pe^{(k-1)}, \forall k \geq 1$, abbiamo $e^{(k)} = Ge^{(k-1)}$. Allora, considerando la matrice Z dello scorso punto,

$$x^H Z x = (e^{(0)})^H A e^{(0)} - \frac{(e^{(0)})^H G^H A \overbrace{G e^{(0)}}^{(e^{(1)})}}{(e^{(1)})^H} = (e^{(0)})^H A e^{(0)} - (e^{(1)})^H A (e^{(1)})$$

O più in generale

$$0 < (e^{(k)})^H Z e^{(k)} = \underbrace{(e^{(k)})^H A e^{(k)}}_{\alpha_n} - \underbrace{(e^{(k+1)})^H A e^{(k+1)}}_{\alpha_{n+1}} \iff \alpha_n > \alpha_{n+1}$$

cioè se la successione tende a zero dal basso. Supponiamo per assurdo che A non sia definita positiva, allora esisterebbe un certo vettore $e_0 \neq 0$ (cioè un errore iniziale particolare) per cui

$$(e^{(0)})^H A e^{(0)} \leq 0$$

e quindi la successione non tende a zero dall'alto, il che è assurdo perché per ipotesi il metodo converge.

Metodo di rilassamento: se lo spettro della matrice è troppo vicino ad uno, esiste una modifica che sposta lo spettro più in basso per accelerare la convergenza. Al posto di risolvere $Ax = b$ risolviamo $\omega Ax = \omega b$. Una volta effettuata la decomposizione $\omega A = M - N$ vale $M = D - \omega B$ e $N = (1 - \omega)D + \omega C$. Se il determinante di N è non nullo,

$$x^{(k)} = \underbrace{(D - \omega B)^{-1} [(1 - \omega)D + \omega C]}_{P_\omega} x^{(k-1)} + \omega (D - \omega B)^{-1} b$$

A questo punto abbiamo due classi di rilassamento, quelli $\omega > 1$ (sovrarilassamenti) e $\omega < 1$ (sottorilassamenti). Abbiamo $\rho(P_\omega) > |\omega - 1|$, quindi se $|\omega - 1| \geq 1$ non convergerà.

3.1 Esempi matrici Gauss-Seidel e Jacobi

Esempio

Consideriamo la matrice

$$A = \begin{pmatrix} -4 & -1 & 1 & 1 \\ 0 & -4 & -1 & 1 \\ -1 & -1 & 4 & 1 \\ 1 & -1 & 0 & 4 \end{pmatrix}$$

ha predominanza diagonale forte. Abbiamo le matrici di Jacobi e Gauss-Seidel

$$J = \frac{1}{4} \begin{pmatrix} 0 & -1 & 1 & 1 \\ 0 & 0 & -1 & 1 \\ 1 & 1 & 0 & -1 \\ -1 & 1 & 0 & 0 \end{pmatrix}, \quad G = \frac{1}{16} \begin{pmatrix} 0 & -4 & 4 & 4 \\ 0 & 0 & -4 & 4 \\ 0 & -1 & 0 & -2 \\ 0 & 1 & -2 & 0 \end{pmatrix}$$

Il polinomio caratteristiche della matrice di Gauss-Seidel è

$$\rho_G(\lambda) = -\lambda^4 - \frac{3}{64}\lambda^2 - \frac{\lambda}{256} = \lambda \left(\lambda - \frac{1}{4} \right) \left(\lambda + \frac{1}{8} \right)^2$$

Abbiamo quindi autovalore $\lambda = 0, \frac{1}{4}, -\frac{1}{8}, -\frac{1}{8}$ e il raggio spettrale è minore di 1, quindi converge.

Lo spettro della matrice di Jacobi è

$$\lambda_1 = \lambda_2 = \frac{1}{4}, \quad \lambda_3 = \frac{-1 + i\sqrt{2}}{4}, \quad \lambda_4 = \frac{-1 - i\sqrt{2}}{4}$$

il raggio spettrale è $\sqrt{3}/4 < 1$, quindi il metodo è convergente.

Esempio

Consideriamo la matrice

$$A = \begin{pmatrix} -4 & -1 & 1 & 1 \\ 0 & -4 & -1 & -3 \\ -1 & -1 & 4 & 1 \\ 1 & 3 & 0 & 4 \end{pmatrix}$$

ha predominanza diagonale debole ed è irriducibile. Abbiamo le matrici di Jacobi e Gauss-Seidel

$$J = \frac{1}{4} \begin{pmatrix} 0 & -1 & 1 & 1 \\ 0 & 0 & -1 & -3 \\ 1 & 1 & 0 & -1 \\ -1 & -3 & 0 & 0 \end{pmatrix}, \quad G = \frac{1}{16} \begin{pmatrix} 0 & -4 & 4 & 4 \\ 0 & 0 & -4 & -12 \\ 0 & -1 & 0 & -6 \\ 0 & 1 & 2 & 8 \end{pmatrix}$$

Gli spettri sono

$$\sigma_J = \left\{ \frac{1}{4}, -\frac{3}{4}, \frac{1+\sqrt{2}}{4}, \frac{1-\sqrt{2}}{4} \right\}, \quad \sigma_G = \left\{ 0, \frac{1}{4}, \frac{1}{8} \right\}$$

Abbiamo ancora quindi la convergenza in ambo i metodi.

Esempio

Consideriamo la matrice

$$A = \begin{pmatrix} -4 & -1 & 1 & 1 \\ 0 & -4 & 0 & -4 \\ 1 & 1 & 4 & 1 \\ 0 & -4 & 0 & 4 \end{pmatrix}$$

ha predominanza diagonale debole ma non è irriducibile. Abbiamo le matrici di Jacobi e Gauss-Seidel

$$J = \frac{1}{4} \begin{pmatrix} 0 & -1 & 1 & 1 \\ 0 & 0 & 0 & -4 \\ -1 & -1 & 0 & -1 \\ 0 & 4 & 0 & 0 \end{pmatrix}, \quad G = \frac{1}{16} \begin{pmatrix} 0 & -4 & 4 & 4 \\ 0 & 0 & 0 & -16 \\ 0 & -1 & -1 & -1 \\ 0 & 0 & 0 & 16 \end{pmatrix}$$

Il polinomio caratteristico della matrice J è

$$\rho_J(\lambda) = \lambda^4 + \frac{17}{16}\lambda^2 + \frac{1}{16} = (\lambda^2 + 1)(\lambda^2 + 16)$$

quindi abbiamo autovalori $\lambda_1 = i, \lambda_2 = -i, \lambda_3 = \frac{i}{4}, \lambda_4 = -\frac{i}{4}$. Abbiamo quindi un raggio spettrale di esattamente 1, e quindi nessuna convergenza. Il polinomio caratteristiche per Gauss-Seidel abbiamo

$$\rho_J(\lambda) = \lambda^4 + \frac{17}{16}\lambda^3 + \frac{\lambda^2}{16} = \lambda^2(\lambda + 1)\left(\lambda + \frac{1}{16}\right)$$

abbiamo quindi autovalori $\lambda_1 = \lambda_2 = 0, \lambda_3 = -1, \lambda_4 = -\frac{1}{16}$, quindi ancora una volta abbiamo il raggio spettrale pari a 1.

3.2 Gauss-Seidel è il doppio più veloce di Jacobi in certi casi

Definizione Consistentemente ordinata

Siano $A \in \text{Mat}_n(\mathbb{C})$ e $\det A \neq 0$ con $A = D - B - C$ e $\det D \neq 0$. Scriviamo $P_J = D^{-1}(D + B)$ e $P_{GS} = (D - B)^{-1}C$. Per semplicità indichiamo $P_J = L + U$ con $L = D^{-1}B$ e $U = D^{-1}C$, e analogamente

$$P_{GS} = (D(I - D^{-1}B))^{-1}C = (I - D^{-1}B)^{-1}D^{-1}C = (I - L)U$$

Si dice che A è *consistentemente ordinata* se $\forall \alpha \neq 0$ vale P_J è simile

$$P_J(\alpha) \triangleq \alpha L + \frac{1}{\alpha}U$$

Le matrici tridiagonali che soddisfano le ipotesi della definizione sono consistentemente ordinate. Sia infatti $A \in \text{Mat}_n(\mathbb{C})$ tridiagonale, allora B è nulla tranne la sottodiagonale, e C è nulla tranne la sopradiagonale. Siccome la riscalatura non cambia il pattern della matrice, pure L hanno queste forme rispettivamente.

$$L = \begin{pmatrix} 0 & & & & \\ l_{2,1} & \ddots & & & \\ & l_{3,2} & \ddots & & \\ & & \ddots & \ddots & \\ & & & l_{n,n-1} & 0 \end{pmatrix}, \quad U = \begin{pmatrix} 0 & u_{1,2} & & & \\ & \ddots & u_{2,3} & & \\ & & \ddots & \ddots & \\ & & & \ddots & 0 \\ & & & & u_{n-1,n} \end{pmatrix}$$

Consideriamo la matrice $\Delta = \text{diag}(1, \alpha, \alpha^2, \dots, \alpha^{n-1})$ da cui $\Delta P_J = \Delta^{-1} = P_J(\alpha)$. Questa matrice applicata ad ogni matrice della forma $X = J + U$ produce la forma $\alpha L + \frac{1}{\alpha}U$. Quindi, questa classe include le tridiagonali ed è abbastanza ampia da chiedersi cosa fanno i metodi iterativi.

Teorema

Siano $A \in \text{Mat}_n(\mathbb{C})$ e $\det A \neq 0$ con $A = D - B - C$ e $\det D \neq 0$. Scriviamo $P_J = D^{-1}(D + B)$ e $P_{GS} = (D - B)^{-1}C$. Per semplicità indichiamo $P_J = L + U$ con $L = D^{-1}B$ e $U = D^{-1}C$, e analogamente

$$P_{GS} = (D(I - D^{-1}B))^{-1}C = (I - D^{-1}B)^{-1}D^{-1}C = (I - L)U$$

Sia A consistentemente ordinata. Allora,

$$\rho(P_{GS}) = \rho^2(P_J)$$

Quindi, o divergono assieme o convergono assieme, e quando convergono Gauss-Seidel è il doppio più veloce.

Proof

Valutiamo il polinomio caratteristico

$$\begin{aligned} \det(P_{GS} - \lambda I) &= \det((I - L)^{-1}U - \lambda I) = \det(\cancel{(I - L)^{-1}}^1) \det(U - \lambda(I - L)) \\ &= \det(U + \lambda L - \lambda I) \\ &= \det\left(\sqrt{\lambda}\left(\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U - \sqrt{\lambda}I\right)\right) \\ &= (\sqrt{\lambda})^n \det\left(\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U - \sqrt{\lambda}I\right) = g(\lambda) \end{aligned} \quad \lambda \neq 0$$

Possiamo eliminare il caso $\lambda \neq 0$ in quanto la radice nulla non contribuisce verso il raggio spettrale. Facciamo diventare questa funzione a due variabili, cioè $g(\lambda) = f(\lambda, \sqrt{\lambda})$

$$\begin{aligned} f(\lambda, \mu) &= (\sqrt{\lambda})^n \det \left(\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U - \mu I \right) \\ &= (\sqrt{\lambda})^n \text{pol. char} \underbrace{\left(\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U \right)}_{P_J(\sqrt{\lambda}) \sim P_J}(\mu)(\mu) = (\sqrt{\lambda})^n \det(P_J - \mu I) \end{aligned}$$

Quindi, purché λ sia autovalore nullo, che non mi interessa, allora per λ che annulla il polinomio caratteristico di Gauss-Seidel, quello che annulla il polinomio caratteristico di Jacobi è $\sqrt{\lambda}$. Ciò vale per tutti gli autovalori grandi e quindi vale per il raggio spettrale. Quindi abbiamo inoltre dimostrato che per ogni autovalore non-nullo di Gauss-Seidel ne corrisponde uno, la radice, per la matrice di Jacobi.

Questa condizione/problematica dell'autovalore nullo è in realtà inevitabile. Consideriamo

$$A = \begin{pmatrix} 1 & \alpha \\ \alpha & 1 \end{pmatrix} \in \text{Mat}_2(\mathbb{C})$$

con $|\alpha| < 1$. I metodi convergono e la matrice è tridiagonale (come tutte le matrici 2×2). Abbiamo quindi

$$P_J = D^{-1}(B + C) = \begin{pmatrix} 0 & -\alpha & \alpha & 0 \end{pmatrix}$$

Se consideriamo il vettore di tutti 1, troviamo che un autovalore è per esempio α . Siccome la traccia è nulla l'altro autovalore è $-\alpha$. D'altra parte abbiamo

$$P_{GS} = (D - B)^{-1}C = \begin{pmatrix} 1 & 0 \\ \alpha & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 & -\alpha \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ -\alpha & 1 \end{pmatrix} \begin{pmatrix} 0 & -\alpha \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -\alpha \\ 0 & \alpha^2 \end{pmatrix}$$

Quindi a zero non corrisponde la radice di zero cioè zero come autovalore. La matrice di Jacobi ha sempre un autovalore nullo, mentre quella di Gauss-Seidel non necessariamente. Esistono matrici per cui J e GS sono ben definite tali che $\rho(P_J) < 1$ e $\rho(P_{GS}) > 1$. Esistono matrici per cui J e GS sono ben definite tale che $\rho(P_{GS}) < 1$ e $\rho(P_J) > 1$.

Esercizio Per $M > 1$ esistono matrici per cui J e GS sono ben definite tali che $\rho(P_{GS}) < 1$ e $\rho(P_J) > M$.

In questo modo, abbiamo sempre la convergenza di Gauss-Seidel in quanto la matrice è definita positiva, ma sufficientemente poco a predominanza diagonale da non fare convergere Jacobi. Vogliamo costruire un caso limite di una matrice definita positiva ma non troppo a predominanza diagonale. Consideriamo la matrice con tutti elementi uguali a 1 e aggiungiamo εI , con $\varepsilon > 0$:

$$A_{n,\varepsilon} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{pmatrix} + \varepsilon I.$$

Indichiamo con E la matrice con tutti elementi uguali a 1. Allora

$$A_{n,\varepsilon} = E + \varepsilon I.$$

Questa matrice è definita positiva, infatti gli autovalori di E sono

$$\lambda(E) = \begin{cases} 0 & \text{con molteplicità } n-1, \\ n & \text{con molteplicità } 1, \end{cases}$$

quindi gli autovalori di $A_{n,\varepsilon}$ sono

$$\lambda(A_{n,\varepsilon}) = \begin{cases} \varepsilon & \text{con molteplicità } n-1, \\ n+\varepsilon & \text{con molteplicità } 1. \end{cases}$$

Dunque $A_{n,\varepsilon}$ è definita positiva per ogni $\varepsilon > 0$. Per il teorema di convergenza di Gauss-Seidel per matrici hermitiane definite positive, abbiamo quindi

$$\rho(P_{GS}) < 1.$$

Calcoliamo ora il raggio spettrale della matrice di iterazione di Jacobi. Poiché

$$D = (1 + \varepsilon)I,$$

si ha

$$P_J = -D^{-1}(L + U).$$

Siccome $L + U = E - I$, otteniamo

$$P_J = -\frac{1}{1+\varepsilon}(E - I) = \frac{1}{1+\varepsilon}(I - E).$$

Quindi

$$\rho(P_J) = \frac{1}{1+\varepsilon}\rho(I - E).$$

Gli autovalori di $I - E$ sono

$$\lambda(I - E) = \begin{cases} 1 & \text{con molteplicità } n-1, \\ 1-n & \text{con molteplicità } 1. \end{cases}$$

Pertanto, per $n \geq 2$,

$$\rho(I - E) = n-1,$$

e quindi

$$\rho(P_J) = \frac{n-1}{1+\varepsilon}.$$

Fissato $M > 1$, scegliamo ad esempio $\varepsilon > 0$ e poi n tale che

$$\frac{n-1}{1+\varepsilon} > M,$$

cioè

$$n > M(1+\varepsilon) + 1.$$

Allora

$$\rho(P_{GS}) < 1 \quad \text{e} \quad \rho(P_J) > M,$$

come volevamo.

Esercizio Altro caso
todo

4 Sistemi lineari

4.1 Errore inerenti nei processi di soluzione di sistemi lineari

Definizione Errori perturbazione

Dato un sistema $Ax = b$, consideriamo spesso dei sistemi perturbati $(A + \delta A)(x + \delta x) = (b + \delta b)$. I termini $\delta A, \delta b$ sono detti perturbazioni autogenerate (dai dati iniziali), mentre δx è la perturbazione indotta. Gli errori sono definiti come

$$\varepsilon_A = \frac{\|\delta A\|}{\|A\|}, \quad \varepsilon_b = \frac{\|\delta b\|}{\|b\|}, \quad \varepsilon_x = \frac{\|\delta x\|}{\|x\|}$$

Vogliamo che gli errori tendano a zero. Possiamo eseguire il prodotto e usando il fatto che $Ax = b$

$$\begin{aligned} \delta b &= A\delta x + \delta A(x + \delta x) \\ \delta x &= (A + \delta A)^{-1}(\delta b - \delta Ax) \\ &= [A(I + A^{-1}\delta A)]^{-1}[\delta b - \delta Ax] \\ &= (I + A^{-1}\delta A)^{-1}A^{-1}(\delta b - \delta Ax) \end{aligned}$$

Passando alle norme troviamo

$$\begin{aligned} \|\delta x\| &\leq \|(I + A^{-1}\delta A)^{-1}A^{-1}\| \cdot \|\delta b - \delta Ax\| \\ &\leq \|(I + A^{-1}\delta A)^{-1}\| \cdot \|A^{-1}\| \cdot \|\delta b - \delta Ax\| \\ &\leq \|(I + A^{-1}\delta A)^{-1}\| \cdot \|A^{-1}\| \left(\|\delta b\| + \|A\| \cdot \frac{\|\delta A\|}{\|A\|} \cdot \|x\| \right) \\ &= \|(I + A^{-1}\delta A)^{-1}\| \left(\|A^{-1}\| \cdot \|\delta b\| + \underbrace{\|A^{-1}\| \cdot \|A\|}_{\mu(A)} \varepsilon_A \cdot \|x\| \right) \\ &\leq \|(I + A^{-1}\delta A)^{-1}\| \left\| \underbrace{\frac{\|A^{-1}\| \cdot \|\delta b\|}{\|x\|}}_{\varepsilon_b} + \mu(A) \varepsilon_A \right\| \end{aligned}$$

siccome la norma dell'inverso di una matrice è il reciproco della norma della matrice, se A è invertibile. Abbiamo usato anche il fatto che $\|A\| \cdot \|x\| \leq \|b\|$. Il termine $\mu(A)$ è detto numero di condizionamento. Inoltre notiamo che il numero di condizionamento è sempre maggiore di 1 in quanto

$$1 = \|I\| = \|A^{-1}A\| \leq \|A\| \cdot \|A^{-1}\| = \mu(A)$$

Per le matrici normali, il numero di condizionamento è il rapporto fra l'autovalore massimo e quello minimo (esercizio).

4.1.1 Contesto più generale

Mettiamo il tutto in un contesto un pochettino più ampio.

Abbiamo una norma $\|\cdot\|_c$ su $\text{Mat}_{n \times n}(\mathbb{C})$ e $\|\cdot\|_b$ su $\mathbb{C}^n$.

Definizione Norma submoltiplicativa

Si dice norma submoltiplicativa se $\forall A, B \in \text{Mat}_{n \times n}(\mathbb{C})$ vale

$$\|AB\| \leq \|A\| \cdot \|B\|$$

Definizione Norme compatibili

Due norme sono compatibili se $\forall A \in \text{Mat}_{n \times n}(\mathbb{C}), \forall y \in \mathbb{C}^n$ vale

$$\|Ay\|_b \leq \|A\|_a \cdot \|y\|_b$$

Proposition

Sia data

$$\|A\|_a = \sup_{x \neq 0} \frac{\|Ax\|_b}{\|x\|}$$

allora le due norme sono compatibili e la norma $\|\cdot\|_a$ è submoltiplicativa.

Proof

Cominciamo con la compatibilità. Sia $y = 0$. Si ha

$$\|Ay\|_b = 0 = \|A\|_a \cdot \|y\|_b = 0$$

Se invece $y \neq 0$ abbiamo

$$\begin{aligned} \|Ay\|_b &= \frac{\|Ay\|_b}{\|y\|_b} \cdot \|y\|_b \\ &\leq \left(\sup_{x \neq 0} \frac{\|Ax\|_b}{\|x\|} \right) \cdot \|y\|_b = \|A\|_a \cdot \|y\|_b \end{aligned}$$

Successivamente studiamo la submoltiplicatività

$$\begin{aligned} \|AB\|_a &= \sup_{y \neq 0} \frac{\|AB y\|_b}{\|y\|_b} \leq \sup_{y \neq 0} \|A\|_a \cdot \frac{\|B y\|_b}{\|y\|_b} \\ &= \|A\|_a \cdot \|B\|_a = \|A\|_a \cdot \|y\|_b \end{aligned}$$

Supponiamo di avere $A \in \text{Mat}_{n \times n}(\mathbb{C})$ invertibile e consideriamo il sistema $Ax = b$. Consideriamo il sistema perturbato $(A + \delta A)(x + \delta x) = b + \delta$. Quantomeno la matrice $A + \delta A$ deve rimanere invertibile. Scegliamo una $\|\cdot\|$ norma vettoriale data con $\|\cdot\|$ su $\text{Mat}_{n \times n}(\mathbb{C})$ matriciale indotta, quindi compatibilità e submoltiplicatività valgono.

Teorema

Con le notazioni e le ipotesi precedenti e supponendo inoltre che $\varepsilon_A \cdot \mu(A) < 1$ e che $b \neq 0$, vale che

$$\varepsilon_x = \frac{\|\delta x\|}{\|x\|} \leq \frac{\mu(A)(\varepsilon_A + \varepsilon_b)}{1 - \varepsilon_A \cdot \mu(A)}$$

Proof

Abbiamo

$$\begin{aligned}
Ax &= b \\
(A + \delta A)(x + \delta x) &= b + \delta b \\
Ax + A\delta x + \delta A(x + \delta x) &= b + \delta b \\
(A + \delta A)\delta x + \delta Ax &= \delta B \quad \left. \begin{array}{l} \text{Sottrazione} \\ \text{della (1) dalla (2)} \end{array} \right\} \\
(A + \delta A)\delta x &= \delta b - \delta Ax \\
A(I + A^{-1}\delta A)\delta x &= \delta B - \delta Ax \\
(I + A^{-1}\delta A)^{-1}A^{-1}(\delta b + \delta Ax) &= \delta x
\end{aligned}$$

Passando alle norme e usando la compatibilità e la submoltiplicatività,

$$\|\delta x\| \leq \|(I + A^{-1}\delta A)^{-1}\| \cdot \|A^{-1}\|(\|\delta b\| + \|\delta A\| \cdot \|x\|)$$

Estraiamo il numero di condizionamento

$$\|A^{-1}\delta A\| = \|A^{-1}\| \cdot \|\delta A\| = \underbrace{\|A^{-1}\| \cdot \|A\|}_{\mu(A)} \cdot \underbrace{\frac{\|\delta A\|}{\|A\|}}_{<1}$$

Chiamando $V = A^{-1}\delta A$ abbiamo $V^j \rightarrow 0$ per $j \rightarrow \infty$. Quindi l'inversa di una tale perturbazione è

$$(I + V)^{-1} = \sum_{j=0}^{\infty} (-1)^j V^j$$

Quindi, usando la disuguaglianza triangolare e le submoltiplicatività iterata

$$\|(I + V)^{-1}\| \leq \sum_{j=0}^{\infty} \|V^j\| \leq \sum_{j=0}^{\infty} \|V\|^j$$

in quanto $\|V^j\| \leq \|V^{j-1}\| \cdot \|V\| \leq \|V\|^j$. Abbiamo quindi una serie geometria e

$$\|(I + V)^{-1}\| \leq \frac{1}{1 - \|V\|}$$

Mettendo tutti assieme

$$\begin{aligned}
\|\delta x\| &\leq \frac{\|A\| \cdot \|A^{-1}\|}{1 - \varepsilon_A \mu(A)} \left(\frac{\|\delta b\|}{\|A\|} + \frac{\|\delta A\|}{\|A\|} \cdot \|x\| \right) \\
&= \frac{\mu(A)}{1 - \varepsilon_A \mu(A)} \left(\frac{\|\delta b\|}{\|b\|} + \varepsilon_A \right) \\
\frac{\|\delta x\|}{\|x\|} &= \varepsilon_x \leq \frac{\mu(A)}{1 - \varepsilon_A \mu(A)} (\varepsilon_b + \varepsilon_A)
\end{aligned}$$

Vale sempre $\rho(A) \leq \|A\|$ per tutte le norme matriciali indotte e inoltre il raggio spettrale è il l'inf di tutte le norme matriciali indotte.

Proposition Il raggio spettrale non è una norma

1. *assoluta omogeneità*:

$$\rho(\alpha A) = |\alpha| \rho(A)$$

vale.

2. *Disuguaglianza triangolare*: Consideriamo A triangolare superiore con zeri sulla diagonale e

$B = A^t$, allora

$$\rho(A + B) > \rho(A) = \rho(B) = \rho(A) + \rho(B) = 0$$

quindi non è valida.

Allora il raggio spettrale non è una norma.

4.2 Metodi diretti: fattorizzazione

Esistono principalmente tre tipi di fattorizzazione: la fattorizzazione LU , la fattorizzazione QR e la fattorizzazione LL^H dove L è triangolare inferiore con elementi principali > 0 .

Per la fattorizzazione LL^H abbiamo il metodo di Cholesky, mentre per la QR il metodo di Householder.

Teorema Esistenza e unicità della fattorizzazione LU

Sia $A \in \text{Mat}_n(\mathbb{C})$ fortemente non singolare. Allora, esistono e sono uniche $L \in \text{Mat}_n(\mathbb{C})$ triangolare inferiore con $L_{i,i} = 1$ per $i \in \{1, \dots, n\}$ e $U \in \text{Mat}_n(\mathbb{C})$ triangolare superiore tale che $A = LU$.

Proof Esistenza e unicità della fattorizzazione LU

Procediamo per induzione. Il caso di base è $n = 1$ dove $A = (a_{1,1})$ e quindi abbiamo $L = (1)$ e $U = (a_{1,1})$. Sia $n = k > 1$ e supponiamo che la tesi sia vera per $k = n - 1$. Scriviamo

$$A = \left[\begin{array}{c|c} A_{n-1} & b \\ \hline c^H & \alpha \end{array} \right]$$

con $b, c \in \mathbb{C}^{n-1}$ e $\alpha \in \mathbb{C}$ dove A_{n-1} è il minore principale di testa di A di ordine $n - 1$, quindi $A_{n-1} = L_{n-1}U_{n-1}$. Abbiamo quindi il prodotto

$$A = \left[\begin{array}{c|c} L_{n-1}U_{n-1} & b \\ \hline c^H & \alpha \end{array} \right] = \left[\begin{array}{c|c} L_{n-1} & 0 \\ \hline M^H & 1 \end{array} \right] \left[\begin{array}{c|c} U_{n-1} & V \\ \hline 0^H & B \end{array} \right]$$

Analizziamo i blocchi:

1. $L_{n-1}U_{n-1} + 0 \cdot 0^H = A_{n-1}$;
2. $L_{n-1}U_{n-1} + 1 \cdot 0^H = b$ poiché L_{n-1} è invertibile esiste un'unica V tale che $L_{n-1}V = b$;
3. $M^H U_{n-1} + 1 \cdot 0^H = c^H$ e quindi $U_{n-1}^H M = c$, quindi esiste un'unica M tale che $U_{n-1}^H M = c$;
4. $M^H V + 1 \cdot B = \alpha$ e quindi $B = \alpha - M^H V$.

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$ invertibile. Allora, esistono L triangolare inferiore con $L_{i,i} = 1$ per $i \in \{1, \dots, n\}$, U triangolare superiore e Π matrice di permutazione $\Pi A = LU$.

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$. Allora, esiste L triangolare inferiore e U triangolare superiore e due matrici di permutazione Π_1, Π_2 tali che $\Pi_1 A \Pi_2 = LU$.

Proof

Procediamo per induzione. Il caso di base è $n = 1$ dove $A = (a_{1,1})$ e quindi abbiamo $L = (1)$, $U =$

$(a_{1,1})$ e $\Pi = (1) = I_1$. Sia $n = k > 1$ e supponiamo che la tesi sia vera per $k = n - 1$. Scriviamo

$$A = \left[\begin{array}{c|c} c_1^H & S_1 \\ \vdots & \vdots \\ c_n^H & S_n \end{array} \right]$$

Vogliamo che tra i vettori $C_i \in \mathbb{C}^{n-1}$ ci siano i generatori di $\mathbb{C}^{n-1}$. Siccome A è invertibile, il determinante è non nullo e applicando l'espansione di Laplace dall'ultimo termine

$$0 \neq \det A = \sum_{i=1}^n (-1)^{n-i} S_i \det(A \setminus \{C_i^H, \vec{S}\})$$

Troviamo che $\exists \vec{j}$ tale che $A \setminus \{C_{\vec{j}}^H, \vec{S}\}$ è una matrice invertibile in $\text{Mat}_{n-1}(\mathbb{C})$. Definiamo Π come la matrice di permutazione che scambia n con $\vec{j}$,

$$\Pi A = \left[\begin{array}{c|c} \hat{A}_{n-1} & b \\ \hline c^H & \alpha \end{array} \right], \quad \det(\hat{A}_{n-1}) \neq 0$$

Per ipotesi induttiva esistono Π_{n-1}, L_{n-1} tali che $\Pi_{n-1} \hat{A}_{n-1} = L_{n-1} U_{n-1}$

$$\left[\begin{array}{c|c} \Pi_{n-1} & 0 \\ \hline 0 & 1 \end{array} \right] \Pi A = \left[\begin{array}{c|c} L_{n-1} U_{n-1} & \hat{b} \\ \hline c^H & \alpha \end{array} \right]$$

dove $\hat{b} = \Pi_{n-1} b$.

Esempio

$$A = \begin{pmatrix} 1 & 2 & 1 \\ -1 & -1 & 2 \\ 1 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 2 & -1 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{pmatrix}$$

Studiamo ora l'algoritmo LU . Osserviamo che la forte non singolarità di A implica l'eliminazione di Gauss per ottenere LU senza usare permutazioni.

Passo 1: siccome A è fortemente non singolare, $a_{1,1} \neq 0$ quindi la prima matrice elementare di Gauss è ben definita

$$E_j = \begin{bmatrix} 1 & & 0 \\ & \ddots & \\ * & & 1 \end{bmatrix}$$

dove $*$ sono elementi della forma $-a_{i,j}/a_{j,j}$ e quindi

$$E_1 = \begin{bmatrix} 1 & & & & \\ -\frac{a_{2,1}}{a_{1,1}} & 1 & & & 0 \\ \vdots & & \ddots & & \\ & & & 1 & \\ -\frac{a_{n,1}}{a_{1,1}} & & & & 1 \end{bmatrix}, \quad \vec{a} = \left(-\frac{a_{2,1}}{a_{1,1}}, -\frac{a_{3,1}}{a_{1,1}}, \dots, -\frac{a_{n,1}}{a_{1,1}} \right)^T$$

Possiamo quindi eseguire il prodotto

$$E_1 A = \left(\begin{array}{c|ccc} a_{1,1} & * & \cdots & * \\ 0 & a_{2,2}^{(2)} & & * \\ \vdots & & \ddots & \\ 0 & * & & * \end{array} \right)$$

dove $a_{2,2}^{(2)}$ è il nuovo elemento diagonale.

Passo 2: supponiamo la tesi sia vera per $k-1$, mostriamo che possiamo applicare il passo k . La tesi è che $a_{k,k}^{(k)} \neq 0$. Abbiamo applicato l'eliminazione gaussiana $k-1$ volte

$$E_{k-1} E_{k-2} \cdots E_2 E_1 A = A^{(k)} = \left(\begin{array}{ccc|c} a_{11} & & & * \\ & \ddots & & \\ & & a_{k-1,k-1}^{(k-1)} & * \\ \hline & & & a_{kk}^{(k)} \\ 0 & & & * \end{array} \right)$$

Mostriamo $a_{k,k}^{(k)} \neq 0$. Ribaltando abbiamo

$$A = \underbrace{E_1^{-1} E_2^{-1} \cdots E_{k-1}^{-1}}_{\text{triangolare inferiore}} A^{(k)}$$

Osserviamo che il prodotto di matrici triangolare inferiore è a sua volta triangolare inferiore. Inoltre, siccome tutte le E_i hanno 1 come diagonale, allora pure il prodotto $E_{k-1} \cdots E_1$ ha 1 come diagonale. Ora se $E_j = I + m_j e_j^T$ dove $m_j \in \text{span}\{e_{j+1}, \dots, e_n\}$, calcoliamo $E_j^{-1} = I - m_j e_j^T$ e pertanto $E_1^{-1} E_2^{-1} \cdots E_{k-1}^{-1}$ è triangolare inferiore con 1 sulla diagonale. Abbiamo quindi

$$A = \underbrace{E_1^{-1} \cdots E_{k-1}^{-1}}_{\xi^{(k)}} A^{(k)} = \begin{bmatrix} 1 & & & 0 \\ & \ddots & & \\ * & & 1 & \\ * & \cdots & * & 1 \end{bmatrix} \begin{bmatrix} a_{1,1} & * & \cdots & * & \cdots & * \\ 0 & a_{2,2}^{(2)} & \ddots & \vdots & & \vdots \\ \vdots & \ddots & \ddots & * & & \vdots \\ 0 & \cdots & 0 & a_{k,k}^{(k)} & \cdots & * \\ \hline 0 & \cdots & 0 & 0 & & \Theta \\ \vdots & & \vdots & \vdots & \Theta & \\ 0 & \cdots & 0 & 0 & & \end{bmatrix}$$

Quindi Θ va moltiplicato con la parte nulla della sopradagonale di $E_1^{-1} \cdots E_{k-1}^{-1}$. Prendiamo una generica matrice $B \in \text{Mat}_n(\mathbb{C})$, B_{k-1} è il suo minore principale di testa di ordine $k-1$. Dunque,

$$A_{k-1} = \left(\xi^{(k)} A^{(k)} \right)_{k-1} = \xi_{k-1}^{(k)} A_{k-1}^{(k)}$$

Poiché A è fortemente non singolare, $\det(A_{k-1}) \neq 0$ allora

$$0 \neq \det(A_{k-1}) = \det(A_{k-1}^{(k)}) = a_{1,1} \cdot a_{2,2}^{(2)} \cdots a_{k,k}^{(k)}$$

e per il teorema di Binet $a_{k,k}^{(k)} \neq 0$. Quindi possiamo trovare esattamente chi sono l'unica L e l'unica U di LU . Abbiamo $L = E_1^{-1} \cdots E_{n-1}^{-1}$ e $U = A^{(n)}$. Per quanto detto prima, $E_j^{-1} = I - m_j e_j^T$ e quindi

$$\begin{aligned} L &= E_1^{-1} \cdots E_{n-1}^{-1} \\ &= (I - m_1 e_1^T) \cdots (I - m_n e_n^T) \\ &= (I - m_1 e_1^T - m_2 e_2^T) \cdots (I - m_{n-1} e_{n-1}^T) \quad \left. \begin{array}{l} -m_j e_j^T - m_k e_k^T = 0 \\ \text{perché sono ortogonali} \end{array} \right\} \\ &= \cdots = I - \sum_{j=1}^{n-1} m_j e_j^T \end{aligned}$$

e quindi

$$L = \begin{pmatrix} 1 & & & & \\ m_1 & & & & \\ & m_2 & & & \\ & & \ddots & & \\ & & & m_{n-2} & \\ & & & & m_{n-1} & 1 \end{pmatrix}$$

4.3 Verso la fattorizzazione di Cholesky

Teorema Fattorizzazione di Cholesky

$A = A^*$ definita positiva se e solo se esiste unica V triangolare inferiore con $V_{j,j} > 0$ tale che $A = VV^*$.

Proof Fattorizzazione di Cholesky

($\Rightarrow$) $A = A^*$ definita positiva se e solo se ogni minore principale è definita positiva. In particolare, lo sono i minori principali di testa, che quindi sono invertibili ovvero A è fortemente non singolare. Esiste un'unica L triangolare inferiore con $L_{j,j} = 1$ ed un'unica U triangolare superiore tale che $A = LU$. Scriviamo

$$A = LU = L \operatorname{diag}_j(U_{j,j}) \tilde{U}$$

dove $\tilde{U}$ è U ma con tutti gli elementi sopra la diagonale divisi per $U_{j,j}$, così possiede 1 sulla diagonale. Allora $A = A^* = \tilde{U}^* \operatorname{diag}_j(U_{j,j}) L^*$. Ma quindi $\tilde{U}^*$ è una triangolare inferiore con 1 sulla diagonale. L'altro termine prodotto è una triangolare superiore. La forte singolarità implica pure l'unicità della fattorizzazione, quindi deve essere

$$L = \tilde{U}^*, \quad U = \operatorname{diag}_j(\tilde{U}_{j,j}) L^*$$

Abbiamo quindi trovato che

$$A = L \cdot \operatorname{diag}_j(U_{j,j}) L^*$$

Gli $U_{j,j}$ sono reali perché coniugano, ma sono anche in $\mathbb{R}^{>0}$ in quanto A è definita positiva. Siccome L ha uno sulla diagonale ed è triangolare inferiore è invertibile. Scegliamo quindi $v^{(j)} = (L^*)^{-1} e_j$. Con questa scelta,

$$0 < v_{(j)}^* A v_{(j)} = e_j^T \operatorname{diag}_j(U_{j,j}) e_j$$

Abbiamo quindi che

$$A = L \operatorname{diag}_j(U_{j,j}) L^* = \underbrace{L \operatorname{diag}_j(\sqrt{U_{j,j}})}_V \underbrace{L \operatorname{diag}_j(\sqrt{U_{j,j}}) L^*}_{V^*}$$

($\Leftarrow$) Sappiamo che $A = VV^*$ con $V_{j,j} > 0$ e V triangolare inferiore, quindi è sicuramente invertibile. Abbiamo che $A^* = (VV^*)^* = V^{**} V^* = VV^* = A$, quindi è Hermitiana. Inoltre, $\forall x \neq 0$ abbiamo

$$\begin{aligned} x^* A x &= x^* V V^* x \\ &= y^* y = \|y\|_2^2 > 0 \end{aligned} \quad \left. \vphantom{\begin{aligned} x^* A x &= x^* V V^* x \\ &= y^* y = \|y\|_2^2 > 0 \end{aligned}} \right\} y = V^* x$$

siccome V è invertibile $y \neq 0$.

L'algoritmo è anche un criterio per testare la definita positività di una matrice. Data una Hermitiana, proviamo l'algoritmo: se funzione è definita positiva, altrimenti non lo è. L'algoritmo è un algoritmo compatto. Prendiamo $A \in \text{Mat}_n(\mathbb{C})$ come input ed imponiamo che $VV^* = A$, e si risolve l'equazione rispetto alle incognite, cioè alle entrate di V . Abbiamo quindi una matrice

$$\left(\begin{array}{c|c|c|c} \mathbf{V}_{1,1} & \mathbf{V}_{2,2} & & 0 \\ & & & \\ V_1 & V_2 & \ddots & \\ & & & \mathbf{V}_{n,n} \end{array} \right) \left(\begin{array}{c|c|c|c} \mathbf{V}_{1,1} & V_1^* & & \\ \hline & \mathbf{V}_{2,2} & V_2^* & \\ \hline & & \ddots & \\ \hline 0 & & & \mathbf{V}_{n,n} \end{array} \right) = \left(\begin{array}{c|c|c|c} \mathbf{A}_{1,1} & \mathbf{A}_{2,2} & & * \\ & & & \\ A_1 & A_2 & \ddots & \\ & & & \mathbf{A}_{n,n} \end{array} \right)$$

dove A_i, V_i sono le sotto-colonne relativamente all'elemento della diagonale delle rispettive matrici. L'itera è quella di iterativamente isolare ogni $A_{i,i}$ e risolvere per $V_{i,i}$, e le sottocolonne rispettive.

Passo 1: per la prima colonna, imponiamo $V_{1,1}^2 = A_{1,1}$ e quindi $V_{1,1} = \sqrt{A_{1,1}}$. Otteniamo quindi $V_{1,1} \cdot V_1$ da cui $V_1 = \frac{A_1}{V_{1,1}}$. Abbiamo eseguire $n - 1$ operazioni (1 operazione per ogni elemento).

Passo 2: per la colonna due, abbiamo

$$|V_{2,1}|^2 + V_{2,2}^2 \rightarrow V_{2,2} = \sqrt{A_{2,2} - |V_{2,1}|^2}$$

Abbiamo eseguire 3 operazioni. Denotiamo con $\tilde{V}_i$ la coda di V_i . Abbiamo ora la colonna di dimensione $n - 2$ data da $\bar{V}_{2,1}\tilde{V}_1 + V_{2,2}V_2 = A_2$. Precedentemente non abbiamo usato il coniugato su $V_{1,1}$ in quanto sapevamo che fosse positivo. Otteniamo quindi che

$$V_2 = \frac{A_2 - \bar{V}_{2,1}\tilde{V}_1}{V_{2,2}}$$

Abbiamo ora eseguito $3(n - 2)$ operazioni (3 operazioni per ogni elemento).

Passo 3: continuando otteniamo

$$|V_{3,1}|^2 + |V_{3,2}|^2 + V_{3,3}^2 = A_{3,3}$$

e qua abbiamo $5(n - 3)$ operazioni (5 operazioni per ogni elemento). In generale la dimensione dei vettori scende mentre il numero di operazione sale.

In totale abbiamo (senza contare quello diagonale che è di ordine inferiore)

$$\sum_{k=1}^{n-1} (2k - 1)(n - k) = 2n \sum_{k=1}^{n-1} k - \sum_{k=1}^{n-1} k^2 = \frac{1}{3}n^3 + \mathcal{O}(n^2)$$

che è esattamente la metà della complessità dell'algoritmo di Gauss. Tuttavia, l'algoritmo di Gauss applicato ad una matrice Hermitiana ha la stessa complessità.

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$ una matrice definita positiva ed Hermitiana. Allora, A è fortemente non singolare.

Proof

Consideriamo $\mathcal{I}, \mathcal{J} \subseteq \{1, \dots, n\}$, ossia $\mathcal{I} = \{i_1, \dots, i_p\}$ e $\mathcal{J} = \{j_1, \dots, j_q\}$ con

$$1 \leq i_1 < i_2 < \dots < i_p < n$$

$$1 \leq j_1 < j_2 < \dots < j_q < n$$

Denotiamo con $A_{\mathcal{I}, \mathcal{J}} \in \mathbb{C}^{p \times q}$ un generico minore di dimensione $p \times q$ che contiene gli elementi di indici $\mathcal{I}$ incrociati con $\mathcal{J}$. Abbiamo allora l'elemento

$$(A_{\mathcal{I}, \mathcal{J}})_{s,t} = A_{i_s, j_t}$$

Un tale minore è quadrato se e solose $p = q$. Un tale minore è un minore principale se e solo se $\mathcal{I} = \mathcal{J}$. Un tale minore è un minore principale di testa se $\mathcal{I} = \mathcal{J} = \{1, \dots, p\}$.

Osserviamo che, da Schur, il fatto che A sia definita positiva ed è Hermitiana implica che tutti gli autovalori siano reali positivi. Dunque, $\det A > 0$. L'idea della dimostrazione è quella di utilizzare questa affermazione su ogni minore principale di testa. Abbiamo che ogni minore principale di A (in particolare pure quelli di testa) sono a loro volta definiti positivi. Sia $A_{\mathcal{I}} \triangleq A_{\mathcal{I}, \mathcal{I}}$. Osserviamo che

$$(A_{\mathcal{I}}^*)_{s,t} = \overline{A_{i_t, i_s}} = A_{i_s, i_t} = (A_{\mathcal{I}})_{s,t}$$

Per studiare la definita positività, studiamo se $x^* A_{\mathcal{I}} x > 0$ per $x \in \mathbb{C}^p$ con $x \neq 0$. Definiamo $y_x \in \mathbb{C}^n$ come vettore estero, cioè

$$(y_x)_l = \begin{cases} 0 & l \notin \{1, \dots, p\} \\ x_s & l = i_s \end{cases}$$

Con questa notazione troviamo

$$x^* A_{\mathcal{I}} x = y_x^* A y_x$$

Abbiamo che $x \neq 0 \implies y_x \neq 0$. Abbiamo quindi la definita positività sui minori principali, e riutilizzando l'argomento precedente su ognuno, ognuno dei minori principali di testa sono invertibili. Quindi, la matrice è fortemente non singolare.

Dal procedimento risultato si evince che sulle definite positive e Hermitiane si può applicare sia l'eliminazione gaussiana senza pivot, sia l'algoritmo per la fattorizzazione di Cholesky.

Durante l'algoritmo di Gauss su una matrice Hermitiana, partendo normalizzando i pivot dal primo all'ultimo, il blocco non ancora normalizzato è una sottomatrice che rimane Hermitiana (induzione). Se A è la nuova matrice ad un passo e B è quella vecchia, allora $\overline{A}_{k,j} = B_{j,k}$, quindi il costo dell'algoritmo di dimostra ed è quindi equivalente a Cholesky. L'algoritmo di Gauss è ottimale fra gli algoritmi con scambi di righe e colonne, ma può essere battuto usando algoritmi ricorsivi.

Teorema Lo spettro commuta con la moltiplicazione di matrici

Siano $A, B \in \text{Mat}_n(\mathbb{C})$. Allora, $\sigma(AB) = \sigma(BA)$.

Proof Lo spettro commuta con la moltiplicazione di matrici

Se A è invertibile, $BA = A^{-1}ABA$ ovvero sono simili e hanno il medesimo polinomio caratteristico

$$p_{AB}(\lambda) = p_{BA}(\lambda)$$

In particolare, gli autovalori coincidono. Analogamente con B . Ci manca il caso dove sia A che B sono singolari. In tal caso, sia $A = QTQ^*$ con Q unitaria e T triangolare superiore. Sia $\varepsilon > 0$ e sia

$$A_\varepsilon \triangleq QT_\varepsilon Q^*$$

che è invertibile, dove $(T_\varepsilon)_{j,j} = \varepsilon$ se $(T)_{j,j} = 0$ e il resto uguale a T . Cioè sulla diagonale ci sono gli autovalori, e sostituiamo gli zeri con degli ε , visto che è triangolare inferiore rimane invertibile perché il prodotto è non nullo. Riconducendoci al caso invertibile, vale

$$p_{A_\varepsilon B}(\lambda) = p_{BA_\varepsilon}(\lambda)$$

Se $A_\varepsilon \rightarrow 0$ per $\varepsilon \rightarrow 0$, allora per un argomento di continuità pure i polinomi caratteristici tendono a quelli di AB e BA

$$p_{AB}(\lambda) = p_{BA}(\lambda)$$

Teorema

Siano $A \in \mathbb{C}^{n \times m}$ e $B \in \mathbb{C}^{m \times n}$. Allora, $\sigma(AB) = \sigma(BA)$ a meno di $n - m$ (se $n - m > 0$) o $m - n$ (se $m - n > 0$) zeri laddove servono.

Proof

Supponiamo senza perdita di generalità che $m \geq n$. Vogliamo ricondurci al caso quadrato, e quindi consideriamo

$$A_{\text{ext}} = \left(A \left| \begin{array}{c} 0 \\ \vdots \\ 0 \end{array} \right. \right) \in \text{Mat}_n(\mathbb{C}), \quad B_{\text{ext}} = \left(\begin{array}{c|c} B & 0 \\ \hline 0 & \dots 0 \end{array} \right) \in \text{Mat}_n(\mathbb{C})$$

con un numero appropriato di zeri per completarla. Visto che le matrici sono quadrate,

$$\sigma(A_{\text{ext}}B_{\text{ext}}) = \sigma(B_{\text{ext}}A_{\text{ext}})$$

Ma notiamo che nel prodotto $A_{\text{ext}}B_{\text{ext}}$ riga per colonna, ritroviamo AB , e quindi lo spettro è precisamente quello di AB . Invece, il prodotto inverso $B_{\text{ext}}A_{\text{ext}}$ notiamo che otteniamo un blocco quadrato

$$B_{\text{ext}}A_{\text{ext}} = \left(\begin{array}{c|c} BA & 0 \\ \hline 0 & 0 \end{array} \right) = \text{diag}(BA, 0_{n-m})$$

quindi lo spettro coincide.

Questo teorema vale nel caso particolare (già visto) $m = 1$. Infatti, $\sigma(xy^*) = \{y^*x, 0, 0, \dots, 0\}$ con $x, y \in \mathbb{C}^n$, cioè il caso della diade, che ha rango uno.

4.4 Matrici semi-elementari (generalizzazione)

Abbiamo visto che dato $I + xy^*$ con $x, y \in \mathbb{C}^n$ possiamo caratterizzarne lo spettro e la condizione di invertibilità: $g^*x \neq -1$ e in tal caso

$$(I + xy^*)^{-1} = I - \frac{xy^*}{1 + y^*x}$$

Quindi in generale sappiamo tutto delle diadi xy^* . Tuttavia, nell'esercizio avevamo una matrice di rango 2. In generale, al posto di sommare una matrice di rango 1, sommiamo una matrice di rango k , vale lo stesso ragionamento.

Consideriamo quindi $I + R$ con $\text{rank } R = r$ (generalmente molto più piccolo di n). Scrivendo R come righe, sappiamo che esistono r vettori $v_1, \dots, v_r$ linearmente indipendenti tali che

$$R = \begin{bmatrix} \text{riga}_1 \\ \text{riga}_2 \\ \vdots \\ \text{riga}_n \end{bmatrix} = \begin{bmatrix} \sum_{s=1}^r \alpha_{1,s} v_s \\ \sum_{s=1}^r \alpha_{2,s} v_s \\ \vdots \\ \sum_{s=1}^r \alpha_{n,s} v_s \end{bmatrix} = \underbrace{\begin{pmatrix} \alpha_{1,1} & \alpha_{1,2} & \cdots & \alpha_{1,r} \\ \alpha_{2,1} & \alpha_{2,2} & \cdots & \alpha_{2,r} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{n,1} & \alpha_{n,2} & \cdots & \alpha_{n,r} \end{pmatrix}}_r \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix}$$

Quindi la nuova condizione non è più che $g^*x \neq -1$, ma che XY^* non abbia l'autovalore -1 , in quanto se avesse un tale autovalore, la matrice originale avrebbe autovalore $1 - 1 = 0$.

Abbiamo quindi che lo spettro è dato da 1 con molteplicità $n - r$ e gli altri autovalori sono

$$1 + \sigma(YX^*)$$

con molteplicità 1. Quindi se YX^* non ha l'autovalore -1 , $I + R$ è invertibile. In tal caso,

$$(I + XY^*)^{-1} = I - X(I_r + Y^*X)^{-1}Y^*$$

che è una generalizzazione della forma scalare.

Verifichiamo che sia l'inversa:

$$\begin{aligned}
(I - X(I_r + Y^*X)^{-1}Y^*)(I + XY^*) &= I + XY^* - X(I_r + Y^*X)^{-1}Y^* - X(I_r + Y^*X)^{-1}Y^*XY^* \\
&= I + X(I - (I_r + Y^*X)^{-1} - (I_r + Y^*X)^{-1}Y^*X)Y^* \\
&= I + X(I_r + Y^*X)^{-1}(I_r + Y^*X - I_r - Y^*X)Y^* = I
\end{aligned}$$

Proposition

Sia $E = I_n + UV^*$ con $U, V \in \mathbb{C}^{n \times k}$. Allora

1. Gli autovalori di E sono 1 con molteplicità algebrica (almeno) $n - k$ e $1 + \sigma_i(V^*U)$ con $i \in \{1, \dots, k\}$. Nel caso in cui $\text{rank } U = \text{rank } V = k$ allora $\sigma_i(V^*U) \neq 0$.
2. Dagli autovalori dati ricaviamo che E è invertibile se e solo se -1 non è un autovalore di V^*U .
3. Se E è invertibile allora la sua inversa è

$$E^{-1} = I_n - U(I_k + V^*U)V^*$$

Il costo della rappresentazione dell'inversa è

$$k^2(2n - 1) + \mathcal{O}(k^3)$$

4.5 Sherman-Morrison-Woodbury

La formula di *Sherman-Morrison-Woodbury* non è altro che la formula dell'inversa appena data ma reinterpretata nel caso di correzione di rango (al più k) di una matrice invertibile A .

Sia $B = A + UV^*$ con $\det A \neq 0$ e ci riconduciamo al caso di matrici semi-elementari scrivendo $B = A(I + A^{-1}UV^*)$. Allora a questo punto, dalla condizione classica sugli autovalori, ricaviamo che B è invertibile se e solo se UV^* è invertibile, cioè se e solo se $V^*A^{-1}U$. Stiamo quindi usando $A^{-1}U$ come termine. Quindi la matrice è invertibile se e solo se $V^*A^{-1}U$ non possiede l'autovalore -1 . In tal caso, rappresentiamo la matrice come

$$B^{-1} = (I_n - A^{-1}U(I_k + V^*A^{-1}U)^{-1}V^*)^{-1}A^{-1}$$

Quindi se siamo bravi a risolvere sistemi con A possiamo correggere il sistema per la matrice B . Se $\det A = 0$ ha senso comunque procedere ma rispetto al problema ai quadrati minimi, che è un senso più debole di risoluzione del sistema associato. Dato un sistema $By = c$, come preprocesso dobbiamo per forza calcolare

$$W = A^{-1}U$$

cioè $A^{-1}v_1, \dots, A^{-1}v_k$, che sono k sistemi lineari in A . Chiaramente A^{-1} la calcoliamo solo una volta. Sostituendo

$$B^{-1}c = (I_n - W(I_k + V^*A^{-1}U)^{-1}V^*)A^{-1}c$$

In termini computazionali abbiamo $k+1$ risoluzioni con matrice A . Nel caso volessimo risolvere molteplici sistemi lineari con B allora mettiamo pure V^*A^{-1} nel preprocessing.

Esiste un criterio di vicinanza fra matrici dove due matrici sono vicine se il rango della differenza diviso la dimensione è piccolo, oltre che la distanza in norma. Esiste una topologia che tiene conto sia della distanza in norma che secondo questo criterio.

Teorema Teorema di Lusin (Extra)

Data $f \in L^\infty([0, 1])$ e $\varepsilon > 0$, cioè limitata quasi ovunque. Allora $\exists f_\varepsilon$ continua in $[0, 1]$ ed un dominio che copre quasi tutto $\Omega_\varepsilon \subseteq [0, 1]$ tale che $\mu(\Omega_\varepsilon) \geq 1 - \varepsilon$ tale che

$$f|_{\Omega_\varepsilon} = f_\varepsilon$$

Questo è un corrispettivo di considerare

$$\text{rank}(B_n - B) = d_n = o(n)$$

dove n è la dimensione. Quindi relativamente a tutto lo spazio il rango è piccolo.

5 Norme matriciali

Abbiamo la norma infinito

$$\|x\|_\infty = \max_j |x_j|$$

per $x \in \mathbb{C}^n$. Allora abbiamo

$$\begin{aligned} \|A\|_\infty &= \sup_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} \\ &= \sup_{x \neq 0} \left\| A \frac{x}{\|x\|_\infty} \right\| \\ &= \sup_{\|x\|_\infty=1} \|Ax\|_\infty \\ &= \max_{\|x\|_\infty=1} \|Ax\|_\infty \quad \left. \begin{array}{l} \text{Compattezza} \\ \downarrow \end{array} \right\} \\ &= \max_{\|x\|_\infty=1} \max_j \left| \sum_{k=1}^n A_{j,k} x_k \right| \\ &\leq \max_j \sum_{k=1}^n |A_{j,k}| \\ &= \left\| \begin{pmatrix} \|\text{row}_1\|_\infty \\ \|\text{row}_2\|_\infty \\ \vdots \\ \|\text{row}_n\|_\infty \end{pmatrix} \right\| \\ &= \|\text{row}_p\|_1 = \sum_{i=1}^n |A_{p_i} x_i| \quad \left. \begin{array}{l} \text{per qualche } p \\ \downarrow \end{array} \right\} \\ &\quad \begin{cases} x_1 = e^{-i\varphi_1} \\ x_2 = e^{-i\varphi_2} \\ \dots \\ x_n = e^{-i\varphi_n} \end{cases} \quad \left. \begin{array}{l} A_{p_k} = |A_{p_k}| e^{i\varphi_k} \\ \downarrow \end{array} \right\} \end{aligned}$$

Esercizio

Con la stessa dimostrazione, considerare

$$A(f)(x) = \int_X K(x, t) f(t) dt, \quad A: \mathcal{C}[D] \rightarrow \mathcal{C}[D]$$

calcolare

$$\sup_{\|f\|_\infty \leq 1} \|A(f)(x)\|_\infty = \sup_{x \in D} \int_D |K(x, t)| dt$$

Come costruire norme nuove in generale? Sia $\|\cdot\|_*$ su $\mathbb{C}^n$ e $S \in \text{Mat}_n(\mathbb{C})$ invertibile. Allora possiamo definire $\|\cdot\|_{*,S} \triangleq \|S \cdot\|_*$, e quindi per ogni vettore $y \in \mathbb{C}^n$ definire

$$\|y\|_{*,S} = \|Sy\|_* \geq 0$$

Abbiamo

1. $\|y\|_{*,S} = 0$ se e solo se, per definizione $\|Sy\|_* = 0$ se e solo se $Sy = 0$, in quanto pure $\|\cdot\|_*$ è una norma, se e solo se $y = 0$.
2. Sia $\alpha \in \mathbb{C}, y \in \mathbb{C}^n$. Abbiamo che

$$\|\alpha y\|_{*,S} = \|S(\alpha y)\|_* = |\alpha| \cdot \|Sy\|_* = |\alpha| \cdot \|y\|_{*,S}$$

3. Siano $x, y \in \mathbb{C}^n$. Abbiamo che

$$\|x + y\|_{*,S} = \|S(x + y)\|_* = \|Sx + Sy\|_* \leq \|Sx\|_* + \|Sy\|_* = \|x\|_{*,S} + \|y\|_{*,S}$$

L'invertibilità di S serve solo per la prima.

Un altro modo di costruire una norma è quello di fare una combinazione lineare non negativa di altre norme.

$$\sum a_j \|\cdot\|_{*,x_j}, \quad \|\cdot\|_{x_1}, \dots, \|\cdot\|_{x_k} \text{ norme su } \mathbb{C}^n$$

In particolare le combinazioni convesse sono ancora norme. Questo potrebbe essere usato nella creazione di un esame.

Dato $V \in \text{Mat}_n(\mathbb{C})$ studiamo $\|V\|_{*,S}$. Abbiamo

$$\begin{aligned} \|V\|_{*,S} &= \sup_{x \neq 0} \frac{\|Vx\|_{*,S}}{\|x\|_{*,S}} = \sup_{x \neq 0} \frac{\|SVx\|_*}{\|Sx\|_*} \\ &= \sup_{y \neq 0} \frac{\|SV^{-1}Sy\|_*}{\|y\|_*} = \|SV^{-1}\|_* \end{aligned} \quad \left. \begin{array}{l} \\ \\ \end{array} \right\} y = Sx$$

La sostituzione è valida in quanto S è non invertibile e quindi mappa $\mathbb{C}^n$ in $\mathbb{C}^n$ e ovviamente 0 in 0.

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$. Allora,

$$\rho(A) = \inf_{\|\cdot\| \text{ norma matriciale indotta}} \|A\|$$

Proof

Sappiamo che per ogni norma matriciale indotta $\|\cdot\|$

$$\rho(A) \leq \|A\|$$

Sia $\varepsilon > 0$ arbitrariamente piccolo. Cerchiamo una norma matriciale indotta particolare $\|\cdot\|_{*,\varepsilon}$ tale che

$$\|A\|_{*,\varepsilon} \leq \rho(A) + \varepsilon$$

Se troviamo tale norma allora vale la tesi. La norma dipende sia da A che da ε . Scriviamo $A = TJT^{-1}$ con la scomposizione di Jordan. Consideriamo una norma $\|\cdot\|_{*,S}$ con S invertibile. Sappiamo che

$$\|V\|_{*,S} = \|SV^{-1}\|_*$$

Dobbiamo scegliere S appropriatamente. Scegliamo $S = FT^{-1}$ per qualche F (e T dipende dalla A). Visto che T dipende solo da A , F (che deve essere invertibile per il teorema di Binet) dovrà presumibilmente dipendere da ε . Da questa scomposizione otteniamo la semplificazione

$$\|A\|_{*,S} = \|FT^{-1}(TJT^{-1})TF^{-1}\|_* = \|FJF^{-1}\|_*$$

Ricordiamo che J è bidiagonale superiore (autovalori sulla diagonale, valori ± 1 sulla sopradiagonale). Scegliamo $\|\cdot\|_* = \|\cdot\|_\infty$. Dobbiamo scegliere F in maniera tale che il prodotto faccia uscire precisamente gli ε . Cerchiamo una F diagonale in maniera tale che la moltiplicazione scali le righe e le colonne. Vogliamo che gli elementi $(j, j+1)$

$$(FJF)^{-1}_{j,j+1} = \frac{F_{j,j}^*}{F_{j+1,j+1}} = \varepsilon \cdot *$$

Allora scegliamo

$$F^{-1} = \text{diag}(1, \varepsilon, \varepsilon^2, \dots, \varepsilon^{n-1})$$

cioè

$$F = \text{diag}(1, \varepsilon^{-1}, \varepsilon^{-2}, \dots, \varepsilon^{1-n})$$

Se i valori sulla diagonale superiore sono 0, allora tutto funziona, il problema era quando sono 1. Abbiamo quindi in conclusione

$$\|A\|_{\infty, FT^{-1}} = \left\| \begin{pmatrix} \lambda_1 & * & & \\ & \lambda_2 & * & \\ & & \ddots & \ddots \\ & & & \lambda_n & * \end{pmatrix} \right\|_{\infty} \leq \max_j |\lambda_j + * \varepsilon| \leq \rho(A) + \varepsilon$$

Abbiamo quindi un invariante algebrico nel teorema sui spazi di Banach per questo motivo.

5.1 Norme matriciali indotte dalla norma 1 e 2

Abbiamo visto la norma matriciale indotta dalla norma infinito. Studiamo ora i casi con norma 1 e 2. Partiamo dal caso di $\|\cdot\|_1$. Ci chiediamo qual'è la corrispondente norma matriciale indotta. Abbiamo

$$\begin{aligned} \|A\|_1 &= \max_{\|x\|_1=1} \|Ax\|_1 = \max_{\|x\|_1=0} \left\| \sum_{j=1}^n x_j \text{col}_j(A) \right\|_1 \\ &= \max_{\|x\|_1=1} \sum_{j=1}^n |x_j| \cdot \|\text{col}_j(A)\|_1 \\ &= \left(\max_{\|x\|_1=1} \sum_{j=1}^n |x_j| \right) \max_j \|\text{col}_j(A)\|_1 \\ &= \max_j \|\text{col}_j(A)\|_1 \end{aligned} \quad \left. \begin{array}{l} \\ \\ \\ \end{array} \right\} \begin{array}{l} \\ \\ \text{Disuguaglianza} \\ \text{triangolare} \end{array}$$

Per completare e dimostrare l'uguaglianza bisogna esibire un particolare vettore per il quale abbiamo l'uguaglianza. Un tale $\hat{x}$ ha $\|\hat{x}\|_1 = 1$ e

$$\|A\hat{x}\|_1 = \max_j \|\text{col}_j(A)\|_1 = \|\text{col}_p(A)\|_1$$

e scegliamo $\hat{x} = e_p$, così selezioniamo precisamente la colonna p . Per le norme infinite guardavamo la righe mentre qua le colonne.

Passiamo ora alla norma 2. Sia V Hermitiana e definita positiva, quindi ordiamo

$$\lambda_1(V) \leq \dots \leq \lambda_n(V)$$

e vale

$$\lambda_1(V) = \min_{x \neq 0} \frac{x^* V x}{x^* x}, \quad \lambda_n(V) = \max_{x \neq 0} \frac{x^* V x}{x^* x}$$

Possiamo scrivere minimo e massimo al posto di infimum e supremum in quanto possiamo restringerci ad un compatto. Quello che importa è l'angolazione, non andare verso infinito. Per la norma indotta abbiamo

$$\begin{aligned} \|A\|_2 &= \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\sqrt{x^* A^* A x}}{\sqrt{x^* x}} \\ &= \sqrt{\max_{x \neq 0} \frac{x^* V x}{x^* x}} \\ &= \sqrt{\rho(A^* A)} \end{aligned}$$

Essendo definita positiva, raggio spettrale e autovalore massimo sono la stessa cosa (per il modulo).

Proposition

Se A è normale, allora $A = QDQ^*$ con D diagonale complessa. Ma allora

$$A^*A = Q \operatorname{diag}(|\lambda_i|^2)Q^*$$

in quanto

$$\lambda_{\max}(A^*A) = \max_j |\lambda_j(A)|^2 = \rho(A)$$

e la norma indotta è

$$\|A\|_2 = \rho(A)$$

Quindi questo vale non solo per le Hermitiane.

6 Decomposizione ai valori singolari

Notiamo che la parola decomposizione è distinta da una fattorizzazione e non è nemmeno una forma normale.

Teorema Decomposizione ai valori singolari

Sia $A \in \mathbb{C}^{n \times m}$. Allora, $\exists U \in \text{Mat}_n(\mathbb{C}), V \in \text{Mat}_m(\mathbb{C})$ unitarie ed $\exists \Sigma \in \mathbb{R}_{\geq 0}^{n \times m}$ con Σ tale che $\Sigma_{j,k} = 0$ se $j \neq k$ e tale che

$$A = U\Sigma U, \quad \Sigma_{j,j} = b_j, j \in \{1, \dots, \min\{n, m\}\}$$

dove σ_j sono i *valori singolari*. In particolare,

$$\sigma_1 = \|A\|_2 \geq \sigma_2 \geq \dots \geq \sigma_p > 0 = \sigma_{p+1} = \dots = \sigma_{\min\{n, m\}}$$

quindi p è il rango di A .

Nel processing delle immagini viene utilizzata questa decomposizione in quanto la gran parte dell'informazione è contenuta nel rango basso.

Proof Decomposizione ai valori singolari

Distinguiamo due casi.

- $n \geq m$: procediamo per induzione su m . Il caso base è $(n, 1)$. Abbiamo quindi A vettore con elementi a . Consideriamo la matrice di Hausholder

$$Ha = \begin{pmatrix} \alpha \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad H = I - \frac{2vv^*}{\|v\|_2^2}$$

Ma quindi $\alpha = |\alpha|e^{i\theta}$, e sostituendo

$$Ha = \begin{pmatrix} |\alpha| \\ 0 \\ \vdots \\ 0 \end{pmatrix} [e^{i\theta}], \quad a = H \begin{pmatrix} |\alpha| \\ 0 \\ \vdots \\ 0 \end{pmatrix} [e^{i\theta}]$$

Notando che le matrici unitarie mantengono la norma due, per completare osserviamo che

$$|a| = \|A\|_2$$

Sia ora $A \in \mathbb{C}^{n \times m}$ e $m \geq 2$. Notiamo che

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|$$

che oviamo essere il nostro σ_1 . Essendo un massimo, ci deve essere un vettore che lo realizza.

Sia $\hat{x}$ tale che $\|\hat{x}\| = 1$ e $y = A\hat{x}$ con $\|y\|_2 = \|A\|_2$. Definiamo quindi

$$\hat{V} = \begin{bmatrix} \hat{x} & s_2 & \cdots & s_m \end{bmatrix} \in \text{Mat}_m(\mathbb{C})$$

Costruiamo un'altra unitaria

$$\hat{U} = \begin{bmatrix} \frac{1}{\|A\|} y^* \\ t_2^* \\ \vdots \\ t_n^* \end{bmatrix} \in \text{Mat}_n(\mathbb{C})$$

Studiamo quindi

$$\hat{U}A\hat{V} = \hat{U} \left[\begin{array}{c|c|c} y & \hat{s}_2 & \cdots \\ \hline & & \hat{s}_n \end{array} \right]$$

Ma eseguendo il prodotto troviamo

$$\frac{1}{\|A\|} y^* y = \frac{\|y\|^2}{\|A\|^2} = \|A\|$$

quindi il primo elemento in testa è $\|A\|$

$$\hat{U}A\hat{V} = \left[\begin{array}{c|c} \frac{\|A\|}{0} & c^* \\ \hline \vdots & \hat{A} \\ 0 & \end{array} \right]$$

Tuttavia non possiamo ancora applicare l'ipotesi induttiva. Ricordiamo che $\|Pv\|_2 = \|v\|_2$ sempre per ogni P unitaria. Ma allora,

$$\begin{aligned} \|\hat{U}A\hat{V}\|_2 &= \max_{\|x\|=1} \|\hat{U}A\hat{V}x\|_2 \\ &= \max_{\|y\|_2=1} \|\hat{H}Ay\|_2 = \max_{\|y\|_2=1} \|Ay\|_2 = \|A\| \end{aligned} \quad \left. \vphantom{\max_{\|y\|_2=1}} \right\} y = \hat{V}x$$

Vogliamo mostrare che c^* deve essere nullo. Per mostrarlo scegliamo un vettore che lo mostra, denotando $B = \hat{U}A\hat{V}$

$$\begin{aligned} \|B\|_2 &\geq \left\| B \begin{pmatrix} \|A\|_2 \\ c \end{pmatrix} \right\|_2 \cdot \frac{1}{\left\| \begin{pmatrix} \|A\|_2 \\ c \end{pmatrix} \right\|_2} \\ &= \frac{1}{\sqrt{\|A\|_2^2 + \|c\|_2^2}} \left\| \begin{pmatrix} \|A\|_2^2 + \|c\|_2^2 \\ \hat{A}c \end{pmatrix} \right\|_2 \\ &\geq \left\| \begin{pmatrix} \|A\|_2^2 + \|c\|_2^2 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \right\|_2 \quad \left. \vphantom{\left\| \begin{pmatrix} \|A\|_2^2 + \|c\|_2^2 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \right\|_2} \right\} \begin{array}{l} \text{Minoriamo con} \\ \hat{A}c = 0 \end{array} \\ &= \frac{\|A\|_2^2 + \|c\|_2^2}{\sqrt{\|A\|_2^2 + \|c\|_2^2}} \\ &= \sqrt{\|A\|_2^2 + \|c\|^2} \geq \|A\|_2 \end{aligned}$$

Ma se c avesse anche solo una componente non-nulla, allora avremmo il segno maggiore stretto. Ma quindi, deve essere per forza $c = 0$. Siccome $c = 0$, possiamo applicare l'ipotesi induttiva e segue il teorema Allora scriviamo

$$\hat{A} = \tilde{U}\tilde{\Sigma}\tilde{V}$$

con $\tilde{\Sigma}_{1,1} \geq \tilde{\Sigma}_{2,2} \geq \dots$. Troviamo quindi

$$\begin{aligned}
\hat{U}A\hat{V} &= \left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \hat{A} & \\ 0 & & & \end{array} \right] = \left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{U}\tilde{\Sigma}\tilde{V} & \\ 0 & & & \end{array} \right] \\
&= \left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{U} & \\ 0 & & & \end{array} \right] \left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{\Sigma} & \\ 0 & & & \end{array} \right] \left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{V} & \\ 0 & & & \end{array} \right] \\
A = \hat{U}^* &\underbrace{\left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{U} & \\ 0 & & & \end{array} \right]}_U \underbrace{\left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{\Sigma} & \\ 0 & & & \end{array} \right]}_\Sigma \underbrace{\left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{V} & \\ 0 & & & \end{array} \right]}_V \hat{V}^*
\end{aligned}$$

che hanno la forma giusta e soddisfano tutte le proprietà per ipotesi induttiva. Inoltre, quando ricaviamo la norma di $\|A\|_2$ nel caso base, la norma è unica. Per induzione questa rimane unica.

- $n < m$: Sia $B = A^*$. Adesso possiamo utilizzare il primo caso

$$B = A^* = U_B \Sigma_B V_B, \quad \Sigma_B = \text{diag}(\sigma_1(B), \sigma_2(B), \dots, \sigma_p(B), 0, \dots, 0)$$

Con le proprietà che

$$\sigma_1(B) = \|B\|_2 \geq \sigma_2(B) \geq \dots \geq \sigma_p(B) > 0 = \sigma_{p+1}(B) = \dots = \sigma_m(B)$$

Riapplicando la trasposta coniugata otteniamo

$$A = B^* = V_B^* \Sigma_B^T U_B^*$$

dove V_B^* è unitaria in $\text{Mat}_n(\mathbb{C})$ e U_B^* è unitaria in $\text{Mat}_m(\mathbb{C})$. Scegliendo quindi $U = V_B^*$, $\Sigma = \Sigma_B^T$ e $V = U_B^*$, troviamo la tesi se mostriamo anche le proprietà aggiuntive. Sappiamo che $p = \text{rank}(B) = \text{rank}(A)$ e che

$$\sigma_1(B) = \|B\|_2 = \sqrt{\rho(B^*B)} = \sqrt{\rho(AA^*)} = \sqrt{\rho(A^*A)} = \|A\|_2 = \sigma_1(A)$$

usando la commutazione degli autovalori (gli zeri aggiuntivi nello spettro non ci interessano).

Nel caso normale, il modulo degli autovalori sono i valori singolari dopo averli ordinati.

7 Teoria dell'approssimazione

Consideriamo lo spazio $\mathcal{C}([0, 1])$ di funzioni continue a valori reali su $[0, 1]$. Vogliamo esibire una successione $P_n(x)$ di polinomi tale che

$$\|f - P_n\|_{\infty, [0, 1]} \rightarrow 0$$

per $n \rightarrow +\infty$.

Definizione Operatore lineare positivo

Sia

$$\phi: (\mathcal{A}, \leq_{\mathcal{A}}) \rightarrow (\mathcal{B}, \leq_{\mathcal{B}})$$

Diciamo che ϕ è *lineare positivo* (LPO) se $\mathcal{A}, \mathcal{B}$ spazi vettoriali con ordinamenti parziali tale che:

1.

$$\phi(\alpha f + \beta g) = \alpha \phi(f) + \beta \phi(g)$$

per ogni $f, g \in \mathcal{A}$ e per ogni $\alpha, \beta \in \mathbb{K}$ campo.

2. Se $f \geq_{\mathcal{A}} 0_{\mathcal{A}}$ allora

$$\phi(f) \geq_{\mathcal{B}} 0_{\mathcal{B}}$$

Definizione Polinomi di Bernstein

Consideriamo $\mathcal{C}([0, 1])$ e $f \in \mathcal{C}([0, 1])$. Un *polinomio di Bernstein* è definito come

$$B_n(f)(x) = \sum_{k=0}^n f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k}$$

con $B_n: \mathcal{C}([0, 1]) \rightarrow \mathcal{C}([0, 1])$. Equipaggiamo inoltre l'ordinamento $f \geq g$ se e solo se $f(x) \geq g(x)$ per ogni $x \in [0, 1]$.

Se fosse stato uno spazio L^p al posto di un per ogni avremmo un quasi ovunque. L'oggetto B_n è un polinomio di grado al più n , in quanto combinazione lineari di tali.

Proposition

B_n è un endooperatore lineare positivo in $\mathcal{C}([0, 1])$ per ogni n .

Proof

Siano $\alpha, \beta \in \mathbb{R}$ e $f, g \in \mathcal{C}([0, 1])$. Abbiamo

$$\begin{aligned} B_n(\alpha f + \beta g)(x) &= \sum_{k=0}^n (\alpha f + \beta g)\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k} \\ &= \sum_{k=0}^n \left(\alpha f\left(\frac{k}{n}\right) + \beta g\left(\frac{k}{n}\right) \right) x^k (1-x)^{n-k} \\ &= \alpha \sum_{k=0}^n f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k} + \beta \sum_{k=0}^n g\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k} \\ &= \alpha B_n(f) + \beta B_n(g) \end{aligned}$$

quindi è lineare. Per la positività vediamo, se $f \geq 0$ allora $f(k/n) \geq 0$ e quindi dalla definizione una serie di termini positivi su $[0, 1]$.

Proposition

Un operatore lineare positivo $\phi: \mathcal{C}([0, 1]) \rightarrow \mathcal{C}([0, 1])$ è monotono e isotono.

Proof

1. per la monotonia notiamo che $f - g \geq 0$, allora $\phi(f - g) \geq 0$, ma quindi per linearità $\phi(f) - \phi(g) \geq 0$ cioè $\phi(f) \leq \phi(g)$.
2. per l'isotonia notiamo che $-|f| \leq f \leq |f|$. Per la monotonia abbiamo che $-\phi(|f|) \leq \phi(f) \leq \phi(|f|)$ da cui troviamo che $|\phi(f)| \leq \phi(|f|)$.

Gli integrali di funzioni positive sono operatori lineari positivi.

Teorema Teorema di Korovkin in una dimensione

Sia $\{\phi_n\}$ una successione di endooperatori lineari positivi su $\mathcal{C}(K)$, con K compatto di $\mathbb{R}$. Supponiamo che

$$\|\phi_n(y^j)(x) - x^j\|_{\infty, K} \rightarrow 0$$

per $n \rightarrow +\infty$ con $j = 0, 1, 2$, allora $\forall f \in \mathcal{C}(K)$,

$$\|\phi_n(f(y)) - f(x)\|_{\infty, K} \rightarrow 0$$

per $n \rightarrow +\infty$.

Proof

Scriviamo

$$\phi_n(y^j)(x) = x^j + \varepsilon_n^{(j)}(x), \quad \|\varepsilon_n^{(j)}(x)\|_{\infty, K} \rightarrow 0$$

per $n \rightarrow \infty$. Fissiamo $f \in \mathcal{C}(K)$ e fissiamo $\varepsilon > 0$. Dobbiamo trovare n_ε tale che $\forall n \geq n_\varepsilon$

$$\Delta_n(f, x) \triangleq |\phi_n(f(y))(x) - f(x)| \leq \varepsilon, \quad \forall x \in K$$

Quel $\forall x \in K$ ci dà la convergenza uniforme. Scriviamo ora

$$\begin{aligned} \Delta_n(f, x) &= |\phi_n(f(y))(x) - (\phi_n(1)(x) - \varepsilon_n^{(0)}(x))f(x)| \\ &= |\phi_n(f(y))(x) - f(x) \cdot \phi_n(1)(x) + \varepsilon_n^{(0)}(x)f(x)| \\ &\leq |\phi_n(f(y))(x) - f(x)\phi_n(1)(x)| + \|\varepsilon_n^{(0)}\|_{\infty, K} \cdot \|f\|_{\infty, K} \\ &\leq |\phi_n(f(y))(x) - f(x)\phi_n(1)(x)| + \varepsilon/3, \quad \forall n \geq n_\varepsilon \\ &= |\phi_n(f(y) - f(x))(x)| + \varepsilon/3 \\ &\leq \phi_n(|f(y) - f(x)|)(x) + \varepsilon/3 \end{aligned} \quad \begin{array}{l} \left. \begin{array}{l} \text{Disuguaglianza} \\ \text{triangolare} \end{array} \right\} \\ \left. \begin{array}{l} \text{positività} \end{array} \right\} \end{array}$$

Visto che siamo su un compatto, la continuità implica la continuità uniforme, quindi $\forall \tilde{\varepsilon} > 0$ esiste $\tilde{\delta} > 0$ tale che se $|x - y| < \tilde{\delta}$ allora $|f(y) - f(x)| < \tilde{\varepsilon}$ per tutte le $x, y \in K$. Siccome questa ultima condizione vale solo quando $|y - x| < \tilde{\delta}$, possiamo estenderla scrivendo

$$|f(y) - f(x)| \leq \tilde{\varepsilon} + 2\|f\|_{\infty, K} \chi_{\{|y-x| \geq \tilde{\delta}\}}(y)$$

Infatti, quando $|y - x| < \tilde{\delta}$ usiamo la continuità uniforme, mentre nell'altro caso maggioriamo $|f(y) - f(x)|$ con $|f(y)| + |f(x)|$, e a loro volta maggioriamo ognuno di questi con $\|f\|_{\infty, K}$. Per y tale che $|y - x| \geq \tilde{\delta}$, vale che $|y - x|/\tilde{\delta} \geq 1$, ma questo è equivalente a dire che $(y - x)^2/\tilde{\delta}^2 \geq 1$. Quindi possiamo aggiornare la maggiorazione a

$$|f(y) - f(x)| \leq \tilde{\varepsilon} + 2\|f\|_{\infty, K} \frac{(y - x)^2}{\tilde{\delta}^2}$$

Sostituendo questa troviamo che per monotonia

$$\begin{aligned}
\Delta_n(f, x) &\leq \phi_n \left(\frac{y^2 - 2xy + x^2}{\tilde{\delta}^2} \cdot 2\|f\|_{\infty, K} + \tilde{\varepsilon} \right) (x) + \frac{\varepsilon}{3} \\
&= \tilde{\varepsilon} \phi_n(1)(x) + 2 \frac{\|f\|_{\infty, K}}{\tilde{\delta}^2} [\phi_n(y^2)(x) - 2x\phi_n(y)(x) + x^2\phi_n(1)(x)] + \frac{\varepsilon}{3} \\
&= \tilde{\varepsilon}(1 + \varepsilon_n^{(0)}(x)) + 2 \frac{\|f\|_{\infty, K}}{\tilde{\delta}^2} \left[x^2 + \varepsilon_n^{(2)}(x) - 2x \left(x + \varepsilon_n^{(1)}(x) \right) + x^2 \left(1 + \varepsilon_n^{(0)}(x) \right) \right] + \frac{\varepsilon}{3} \\
&\leq \frac{2}{3}\varepsilon + 2 \frac{\|f\|_{\infty, K}}{\tilde{\delta}^2} \left| \varepsilon_n^{(2)}(x) - 2x\varepsilon_n^{(1)}(x) + x^2\varepsilon_n^{(0)}(x) \right|
\end{aligned}$$

$\left. \vphantom{\frac{\varepsilon}{3}} \right\} \text{Scegliendo } \tilde{\varepsilon} = \varepsilon/6$

dove abbiamo anche scelto n_ε abbastanza grande da avere $\|\varepsilon_n^{(0)}\|_{\infty, K} \leq 1$. Poiché K è compatto, poniamo

$$\hat{M} = \sup_{x \in K} |x| < +\infty.$$

Otteniamo quindi la successione numerica che va a zero

$$Q_n \triangleq \frac{2\|f\|_{\infty, K}}{\tilde{\delta}^2} \left(\|\varepsilon_n^{(2)}\|_{\infty, K} + 2\hat{M}\|\varepsilon_n^{(1)}\|_{\infty, K} + \hat{M}^2\|\varepsilon_n^{(0)}\|_{\infty, K} \right) < \frac{\varepsilon}{3}$$

per $n \geq n_\varepsilon$. Quindi, per ogni $x \in K$, abbiamo

$$\Delta_n(f, x) \leq \frac{2}{3}\varepsilon + Q_n < \varepsilon,$$

e dunque

$$\|\phi_n(f(y)) - f(x)\|_{\infty, K} \rightarrow 0.$$

Il teorema può essere esteso, sotto ipotesi opportune, anche alla convergenza in L^p .

Vediamo il test di Korovkin sugli operatori di Bernstein $B_n(\cdot)$ su $[0, 1]$. Abbiamo

1. Vediamo se $B_n(1)(x)$ converge a 1. Abbiamo

$$\sum_{k=0}^n \binom{n}{k} x^k (1-x)^{n-k} = ((1-x) + x)^n = 1$$

e quindi $\varepsilon_n^{(0)} = 0$.

2. Vediamo se $B_n(y)(x)$ converge a x . Abbiamo

$$\begin{aligned}
B_n(y)(x) &= \sum_{k=0}^n \binom{n}{k} \frac{k}{n} x^k (1-x)^{n-k} \\
&= \sum_{k=1}^n \binom{n}{k} \frac{k}{n} x^k (1-x)^{n-k} \\
&= x \sum_{k=1}^n \binom{n-1}{k-1} x^{k-1} (1-x)^{n-k} \\
&= x \cdot \sum_{q=0}^{n-1} \binom{n-1}{q} x^q (1-x)^{n-1-q} \\
&= x
\end{aligned}$$

quindi $\varepsilon_n^{(1)} = 0$.

3. Per definizione,

$$B_n(f)(x) = \sum_{k=0}^n \binom{n}{k} f\left(\frac{k}{n}\right) x^k (1-x)^{n-k}.$$

Dunque

$$\begin{aligned} B_n(X^2)(x) &= \sum_{k=0}^n \binom{n}{k} \left(\frac{k}{n}\right)^2 x^k (1-x)^{n-k} \\ &= \sum_{k=1}^n \frac{k}{n} \binom{n}{k} \frac{k}{n} x^k (1-x)^{n-k} \\ &= \frac{x}{n} \sum_{k=1}^n k \binom{n}{k} x^{k-1} (1-x)^{n-k}. \end{aligned}$$

Usando l'identità

$$k \binom{n}{k} = n \binom{n-1}{k-1},$$

otteniamo

$$\begin{aligned} B_n(X^2)(x) &= \frac{x}{n} \sum_{k=1}^n k \binom{n}{k} x^{k-1} (1-x)^{n-k} \\ &= \frac{x}{n} \sum_{k=1}^n n \binom{n-1}{k-1} \frac{k}{n} x^{k-1} (1-x)^{n-k}. \end{aligned}$$

Scriviamo

$$\frac{k}{n} = \frac{1}{n} + \frac{n-1}{n} \frac{k-1}{n-1}.$$

Allora

$$\begin{aligned} B_n(X^2)(x) &= x \sum_{k=1}^n \binom{n-1}{k-1} \left(\frac{1}{n} + \frac{n-1}{n} \frac{k-1}{n-1} \right) x^{k-1} (1-x)^{n-k} \\ &= \frac{x}{n} \sum_{k=1}^n \binom{n-1}{k-1} x^{k-1} (1-x)^{n-k} \\ &\quad + \frac{x(n-1)}{n} \sum_{k=1}^n \binom{n-1}{k-1} \frac{k-1}{n-1} x^{k-1} (1-x)^{n-k}. \end{aligned}$$

Facendo il cambio di variabile $j = k - 1$, si ha

$$\sum_{k=1}^n \binom{n-1}{k-1} x^{k-1} (1-x)^{n-k} = B_{n-1}(1)(x) = 1,$$

mentre

$$\sum_{k=1}^n \binom{n-1}{k-1} \frac{k-1}{n-1} x^{k-1} (1-x)^{n-k} = B_{n-1}(X)(x) = x.$$

Quindi

$$\begin{aligned} B_n(X^2)(x) &= \frac{x}{n} + \frac{x(n-1)}{n} x \\ &= \frac{x}{n} + \frac{n-1}{n} x^2 \\ &= x^2 + \frac{x(1-x)}{n}. \end{aligned}$$

Pertanto, se poniamo

$$e_n^{(2)}(x) = B_n(X^2)(x) - x^2,$$

allora

$$e_n^{(2)}(x) = \frac{x(1-x)}{n}.$$

Poiché

$$0 \leq x(1-x) \leq \frac{1}{4} \quad \forall x \in [0, 1],$$

si ottiene

$$\|e_n^{(2)}\|_{\infty, [0, 1]} \leq \frac{1}{4n} \xrightarrow{n \rightarrow \infty} 0.$$

Teorema Teorema di Weierstrass in $\mathbb{R}$

Sia $K \subseteq \mathbb{R}$ compatto. Per ogni $f \in C(K)$ esiste una successione di polinomi $\{P_n\}$ tale che

$$\|f - P_n\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Proof

Procediamo per passi.

Passo 1: $K = [0, 1]$.

Consideriamo gli operatori di Bernstein

$$B_n : C([0, 1]) \longrightarrow C([0, 1]).$$

Per costruzione $B_n(f)$ è un polinomio di grado al più n . Inoltre B_n è lineare positivo. Abbiamo verificato che

$$B_n(1) = 1, \quad B_n(X) = X, \quad \|B_n(X^2) - X^2\|_{\infty, [0, 1]} \rightarrow 0.$$

Quindi B_n soddisfa il test di Korovkin su $[0, 1]$. Per il teorema di Korovkin segue che

$$\|B_n(f) - f\|_{\infty, [0, 1]} \xrightarrow{n \rightarrow \infty} 0 \quad \forall f \in C([0, 1]).$$

Passo 2: $K = [a, b]$, con $a < b$.

Sia $f \in C([a, b])$. Definiamo

$$g(t) = f(a + (b - a)t), \quad t \in [0, 1].$$

Allora $g \in C([0, 1])$. Per il passo precedente,

$$\|g - B_n(g)\|_{\infty, [0, 1]} \xrightarrow{n \rightarrow \infty} 0.$$

Per $x \in [a, b]$ poniamo

$$t = \frac{x - a}{b - a}.$$

Allora $t \in [0, 1]$ e

$$f(x) = g\left(\frac{x - a}{b - a}\right).$$

Definiamo quindi

$$P_n(x) = B_n(g)\left(\frac{x - a}{b - a}\right).$$

Essendo composizione di un polinomio con un'affinità, P_n è un polinomio in x . Inoltre

$$\begin{aligned}\|f - P_n\|_{\infty, [a, b]} &= \max_{x \in [a, b]} \left| f(x) - B_n(g) \left(\frac{x - a}{b - a} \right) \right| \\ &= \max_{t \in [0, 1]} |g(t) - B_n(g)(t)| \\ &= \|g - B_n(g)\|_{\infty, [0, 1]} \xrightarrow{n \rightarrow \infty} 0.\end{aligned}$$

Passo 3: $K \subseteq \mathbb{R}$ compatto generico.

Scegliamo un intervallo $[a, b]$ tale che

$$K \subseteq (a, b).$$

Per il teorema di estensione di Tietze, per ogni $f \in C(K)$ esiste $\tilde{f} \in C([a, b])$ tale che

$$\tilde{f}|_K = f.$$

Eventualmente si può scegliere l'estensione in modo che

$$\tilde{f}(a) = \tilde{f}(b) = 0.$$

Per il passo precedente esiste una successione di polinomi $\{P_n\}$ tale che

$$\|\tilde{f} - P_n\|_{\infty, [a, b]} \xrightarrow{n \rightarrow \infty} 0.$$

Restringendo a K , otteniamo

$$\|f - P_n\|_{\infty, K} \leq \|\tilde{f} - P_n\|_{\infty, [a, b]} \xrightarrow{n \rightarrow \infty} 0.$$

Questo conclude la dimostrazione.

Proposition Osservazione sul test di Korovkin in dimensione 1

Sia $K = [a, b]$ e sia

$$\Phi : C(K) \longrightarrow C(K)$$

un operatore lineare positivo. Se Φ riproduce esattamente le funzioni test

$$1, \quad X, \quad X^2,$$

cioè

$$\Phi(1) = 1, \quad \Phi(X) = X, \quad \Phi(X^2) = X^2,$$

allora $\Phi(f) = f$ per ogni $f \in C^2(K)$.

In particolare, per un operatore non banale non ci si aspetta che gli errori del test di Korovkin siano esattamente nulli; è sufficiente che tendano a zero uniformemente.

Proof

Fissiamo $f \in C^2(K)$ e $x \in K$. Scriviamo $Y(t) = t$, per distinguere la variabile della funzione dal punto x in cui si valuta l'operatore.

Per il teorema di Taylor, per ogni $y \in K$ esiste un punto $\xi_{x,y}$ compreso tra x e y tale che

$$f(y) = f(x) + f'(x)(y - x) + \frac{f''(\xi_{x,y})}{2}(y - x)^2.$$

Quindi

$$f(y) - f(x) = f'(x)(y - x) + \frac{f''(\xi_{x,y})}{2}(y - x)^2.$$

Applicando Φ e usando linearità e positività,

$$\begin{aligned} |\Phi(f)(x) - f(x)| &= |\Phi(f(Y) - f(x))(x)| \\ &\leq |f'(x)\Phi(Y - x)(x)| + \frac{1}{2} \|f''\|_{\infty, K} \Phi((Y - x)^2)(x). \end{aligned}$$

Ora

$$\Phi(Y - x)(x) = \Phi(Y)(x) - x\Phi(1)(x) = x - x = 0,$$

e

$$\begin{aligned} \Phi((Y - x)^2)(x) &= \Phi(Y^2 - 2xY + x^2)(x) \\ &= \Phi(Y^2)(x) - 2x\Phi(Y)(x) + x^2\Phi(1)(x) \\ &= x^2 - 2x^2 + x^2 \\ &= 0. \end{aligned}$$

Pertanto

$$|\Phi(f)(x) - f(x)| = 0 \quad \forall x \in K,$$

da cui $\Phi(f) = f$.

Teorema Teorema di Korovkin in $\mathbb{R}^d$

Sia $K \subseteq \mathbb{R}^d$ compatto e siano

$$\Phi_n : C(K) \longrightarrow C(K)$$

operatori lineari positivi.

Supponiamo che

$$\|\Phi_n(g) - g\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0$$

per ogni

$$g \in T, \quad T = \{1, X_1, \dots, X_d, X_1^2 + \dots + X_d^2\}$$

Allora, per ogni $f \in C(K)$,

$$\|\Phi_n(f) - f\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Proof

Indichiamo con

$$\rho(X) = X_1^2 + \dots + X_d^2 = \|X\|^2.$$

L'ipotesi sul test di Korovkin equivale a dire che, per ogni $g \in T$,

$$\Phi_n(g)(x) = g(x) + \varepsilon_n^{(g)}(x), \quad \left\| \varepsilon_n^{(g)} \right\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0$$

Fissiamo $f \in C(K)$ e $\varepsilon > 0$. Poiché K è compatto, f è uniformemente continua. Quindi esiste $\delta > 0$ tale che

$$\|y - x\| < \delta \implies |f(y) - f(x)| < \frac{\varepsilon}{3} \quad \forall x, y \in K$$

Inoltre, se $\|y - x\| \geq \delta$, allora

$$|f(y) - f(x)| \leq 2\|f\|_{\infty, K} \leq \frac{2\|f\|_{\infty, K}}{\delta^2} \|y - x\|^2.$$

Combinando le due stime, otteniamo per ogni $x, y \in K$:

$$|f(y) - f(x)| \leq \frac{\varepsilon}{3} + \frac{2\|f\|_{\infty, K}}{\delta^2} \|y - x\|^2.$$

Fissiamo ora $x \in K$. Scrivendo $Y = (Y_1, \dots, Y_d)$ per la variabile della funzione su cui agisce Φ_n , abbiamo

$$\Phi_n(f)(x) - f(x) = \Phi_n(f(Y) - f(x))(x) + f(x) (\Phi_n(1)(x) - 1).$$

Pertanto

$$\begin{aligned} |\Phi_n(f)(x) - f(x)| &\leq \Phi_n(|f(Y) - f(x)|)(x) + \|f\|_{\infty, K} \left| \varepsilon_n^{(1)}(x) \right| \\ &\leq \frac{\varepsilon}{3} \Phi_n(1)(x) + \frac{2\|f\|_{\infty, K}}{\delta^2} \Phi_n(\|Y - x\|^2)(x) + \|f\|_{\infty, K} \left| \varepsilon_n^{(1)}(x) \right|. \end{aligned}$$

Studiamo il termine quadratico. Poiché

$$\|Y - x\|^2 = \|Y\|^2 - 2 \sum_{i=1}^d x_i Y_i + \|x\|^2,$$

si ha

$$\begin{aligned} \Phi_n(\|Y - x\|^2)(x) &= \Phi_n(\rho)(x) - 2 \sum_{i=1}^d x_i \Phi_n(Y_i)(x) + \|x\|^2 \Phi_n(1)(x) \\ &= \|x\|^2 + \varepsilon_n^{(\rho)}(x) - 2 \sum_{i=1}^d x_i \left(x_i + \varepsilon_n^{(X_i)}(x) \right) \\ &\quad + \|x\|^2 \left(1 + \varepsilon_n^{(1)}(x) \right) \\ &= \varepsilon_n^{(\rho)}(x) - 2 \sum_{i=1}^d x_i \varepsilon_n^{(X_i)}(x) + \|x\|^2 \varepsilon_n^{(1)}(x). \end{aligned}$$

Poiché K è compatto, esiste $M > 0$ tale che

$$\|x\| \leq M \quad \forall x \in K.$$

Dunque

$$\left\| \Phi_n(\|Y - \cdot\|^2)(\cdot) \right\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Inoltre

$$\Phi_n(1)(x) = 1 + \varepsilon_n^{(1)}(x),$$

quindi $\Phi_n(1) \rightarrow 1$ uniformemente. Scegliendo n sufficientemente grande, tutti i termini d'errore precedenti sono minori di quanto serve affinché

$$|\Phi_n(f)(x) - f(x)| < \varepsilon \quad \forall x \in K.$$

Ne segue

$$\|\Phi_n(f) - f\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Vogliamo ora dimostrare una versione multidimensionale del teorema di Weierstrass.

Teorema Teorema di Weierstrass in $\mathbb{R}^d$

Sia $K \subseteq \mathbb{R}^d$ compatto. Per ogni $f \in C(K)$ esiste una famiglia di polinomi $\{P_{\mathbf{n}}\}_{\mathbf{n}}$, con

$$\mathbf{n} = (n_1, \dots, n_d) \in \mathbb{N}^d,$$

tale che

$$\|P_{\mathbf{n}} - f\|_{\infty, K} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Si può scegliere $P_{\mathbf{n}}$ di grado al più n_i nella variabile X_i .

Per dimostrare il risultato, cominciamo definendo i polinomi di Bernstein multidimensionali su $[0, 1]^d$.

Siano

$$\mathbf{n} = (n_1, \dots, n_d), \quad \mathbf{k} = (k_1, \dots, k_d),$$

con

$$0 \leq k_i \leq n_i \quad \forall i = 1, \dots, d.$$

Poniamo

$$\binom{\mathbf{n}}{\mathbf{k}} = \prod_{i=1}^d \binom{n_i}{k_i},$$

$$x^{\mathbf{k}} = \prod_{i=1}^d x_i^{k_i}, \quad (1-x)^{\mathbf{n}-\mathbf{k}} = \prod_{i=1}^d (1-x_i)^{n_i-k_i}.$$

Allora, per $f \in C([0, 1]^d)$, definiamo

$$B_{\mathbf{n}}(f)(x) = \sum_{k_1=0}^{n_1} \cdots \sum_{k_d=0}^{n_d} f\left(\frac{k_1}{n_1}, \dots, \frac{k_d}{n_d}\right) \prod_{i=1}^d \binom{n_i}{k_i} x_i^{k_i} (1-x_i)^{n_i-k_i}.$$

In notazione multi-indice:

$$B_{\mathbf{n}}(f)(x) = \sum_{\mathbf{k}=0}^{\mathbf{n}} \binom{\mathbf{n}}{\mathbf{k}} f\left(\frac{\mathbf{k}}{\mathbf{n}}\right) x^{\mathbf{k}} (1-x)^{\mathbf{n}-\mathbf{k}},$$

dove

$$\frac{\mathbf{k}}{\mathbf{n}} = \left(\frac{k_1}{n_1}, \dots, \frac{k_d}{n_d}\right).$$

Proof Dimostrazione del teorema di Weierstrass in $\mathbb{R}^d$

Consideriamo prima il caso $K = [0, 1]^d$.

Gli operatori $B_{\mathbf{n}}$ sono lineari positivi. Inoltre,

$$B_{\mathbf{n}}(1) = 1.$$

Per ogni $i = 1, \dots, d$, poiché la variabile X_i dipende solo dalla i -esima coordinata,

$$B_{\mathbf{n}}(X_i) = X_i.$$

Analogamente, usando il calcolo unidimensionale già fatto,

$$B_{\mathbf{n}}(X_i^2)(x) = x_i^2 + \frac{x_i(1-x_i)}{n_i}.$$

Quindi

$$\begin{aligned} B_{\mathbf{n}}(X_1^2 + \cdots + X_d^2)(x) &= \sum_{i=1}^d B_{\mathbf{n}}(X_i^2)(x) \\ &= \sum_{i=1}^d x_i^2 + \sum_{i=1}^d \frac{x_i(1-x_i)}{n_i}. \end{aligned}$$

Perciò

$$|B_{\mathbf{n}}(X_1^2 + \cdots + X_d^2)(x) - (X_1^2 + \cdots + X_d^2)(x)| = \sum_{i=1}^d \frac{x_i(1-x_i)}{n_i}.$$

Siccome

$$0 \leq x_i(1-x_i) \leq \frac{1}{4},$$

segue che

$$\|B_{\mathbf{n}}(X_1^2 + \cdots + X_d^2) - (X_1^2 + \cdots + X_d^2)\|_{\infty, [0,1]^d} \leq \frac{d}{4 \min_i n_i} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Dunque $B_{\mathbf{n}}$ soddisfa il test di Korovkin multidimensionale. Pertanto

$$\|B_{\mathbf{n}}(f) - f\|_{\infty, [0,1]^d} \xrightarrow{\min_i n_i \rightarrow \infty} 0 \quad \forall f \in C([0,1]^d).$$

Consideriamo ora un rettangolo

$$Q = [a_1, b_1] \times \cdots \times [a_d, b_d].$$

Per $f \in C(Q)$, definiamo

$$g(t_1, \dots, t_d) = f(a_1 + (b_1 - a_1)t_1, \dots, a_d + (b_d - a_d)t_d),$$

con $t = (t_1, \dots, t_d) \in [0,1]^d$. Allora $g \in C([0,1]^d)$. Definiamo

$$P_{\mathbf{n}}(x) = B_{\mathbf{n}}(g)\left(\frac{x_1 - a_1}{b_1 - a_1}, \dots, \frac{x_d - a_d}{b_d - a_d}\right).$$

Allora $P_{\mathbf{n}}$ è un polinomio in $x_1, \dots, x_d$, di grado al più n_i nella variabile x_i , e

$$\|P_{\mathbf{n}} - f\|_{\infty, Q} = \|B_{\mathbf{n}}(g) - g\|_{\infty, [0,1]^d} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Infine, se $K \subseteq \mathbb{R}^d$ è compatto generico, scegliamo un rettangolo Q tale che

$$K \subseteq \text{int}(Q).$$

Per il teorema di estensione di Tietze, ogni $f \in C(K)$ ammette un'estensione $\tilde{f} \in C(Q)$ con

$$\tilde{f}|_K = f.$$

Per quanto appena dimostrato, esiste una famiglia di polinomi $\{P_{\mathbf{n}}\}_{\mathbf{n}}$ tale che

$$\|\tilde{f} - P_{\mathbf{n}}\|_{\infty, Q} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Restringendo a K , si ottiene

$$\|f - P_{\mathbf{n}}\|_{\infty, K} \leq \|\tilde{f} - P_{\mathbf{n}}\|_{\infty, Q} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

8 Esercizi

Esercizio

Sia $\alpha \geq 1$ reale e consideriamo la matrice

$$A_n(\alpha) = \begin{pmatrix} \alpha & 1 & 1 & \cdots & 1 \\ 1 & \alpha & 1 & \cdots & 1 \\ 1 & 1 & \alpha & \cdots & 1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 & \alpha \end{pmatrix}$$

e

$$B_n(\alpha) = \begin{pmatrix} \alpha & -1 & -1 & \cdots & -1 \\ 1 & \alpha & -1 & \cdots & -1 \\ 1 & 1 & \alpha & \cdots & -1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 & \alpha \end{pmatrix}$$

1. Si consideri nella maniera più precisa possibile lo spettro di A_n e B_n .
2. In particolari, si studi per quale α le matrici risultano invertibili. sono invertibili?
3. Indicato con e_1 il primo vettore della base canonica, è vero che $A_n^{(2)} + e_1 e_1^T$ è definita positiva?
4. È vero che $A_n^{(1)} + e_1 e_1^T$ è semidefinita positiva?

Soluzione

Cominciamo notando che $A_n^*(\alpha) = A_n^T(\alpha) = A_n(\alpha)$ quindi è Hermitiana e il suo spettro è reale. Possiamo notare che $X_n + \alpha I_n = B_n(\alpha)$ dove

$$X_n = \begin{pmatrix} 0 & -1 & \cdots & -1 \\ 1 & 0 & \cdots & -1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 0 \end{pmatrix}$$

Moltiplicando $iX_n = Y_n$ diventa hermitiana $Y_n^* = Y_n$. In generale se moltiplichiamo una matrice per qualcosa, pure i suoi valori vengono moltiplicati per tale quantità. Quindi $Y_n x = \lambda x$ con $\lambda \in \mathbb{R}$ ci porta a dire che X_n può avere solo autovalori immaginari puri. Se $X_n v = \lambda v$, allora

$$(\alpha I + X_n)v = \alpha v + X_n v = (\alpha + \lambda)v$$

quindi gli autovalori di $B_n(\alpha)$ sono della forma $\alpha + i\beta$ con $\beta \in \mathbb{R}$. Per struttura degli autovalori, siccome non toccano mai lo zero, sono tutte invertibili. Consideriamo il caso $\alpha = 1$. In tal caso la matrice A_n è singolare, quindi non è invertibile. Consideriamo $\alpha > 1$. Abbiamo

$$\begin{aligned} A_n(\alpha) &= (\alpha - 1)I_n + \begin{pmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{pmatrix} \\ &= (\alpha - 1)I_n + \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} (1 \quad 1 \quad \cdots \quad 1) = (\alpha - 1)I_n + e_1 e_1^T \end{aligned}$$

Il primo termine è definito positivo, mentre il secondo è la matrice di uni che ha rango 1, quindi la si può scrivere come prodotto di colonna per riga. Vogliamo verificare che la forma quadratica

sia definita positiva, cioè studiamo $x^* A_n(\alpha) x$. Sappiamo che

$$\begin{aligned} x^* A_n(\alpha) x &= \underbrace{x(\alpha - 1)I_n x}_{>0} + x e_1 e_1^T x \\ &= \underbrace{x(\alpha - 1)I_n x}_{>0} + (e_1^T x)^2 \end{aligned}$$

e quindi abbiamo un termine positivo sommato ad una quantità non-negativa. Scomponiamo ora invece l'altra matrice come

$$B_n(\alpha) = \alpha I_n + V_n$$

dove abbiamo già verificato che $(iV_n)^* = iV_n = -iV_n$, quindi otteniamo che V_n è anti-Hermitiana, cioè $V_n^* = -V_n$.

Definizione Matrice di Vandermonde generalizzata

Siano $x_0, x_1, \dots, x_n \in \mathbb{C}$ e siano $p_0, p_1, \dots, p_n \in \mathbb{C}[x]$, $n + 1$ polinomi linearmente indipendenti. La matrice di Vandermonde generalizzata è definita come

$$W_n \triangleq (p_k(x_j))_{j,k=0}^n \in \text{Mat}_{n+1}(\mathbb{C})$$

Esercizio Matrice di Vandermonde generalizzata

Consideriamo una matrice di Vandermonde generalizzata W_n . Sia

$$K_n = \max_{0 \leq k \leq n} \{\deg(p_k)\}$$

1. Si dimostri che $\det W_n \neq 0$ implica che $x_0, x_1, \dots, x_n$ sono a due a due distinti.
2. Se $K_n = n$ e $x_0, x_1, \dots, x_n$ sono a due a due distinti è vero che $\det W_n \neq 0$? (Unisolvenza)
3. Se $K_n > n$ e $x_0, x_1, \dots, x_n$ sono a due a due distinti è ancora vero che si ha unisolvenza, ovvero $\det W_n \neq 0$?

Soluzione Matrice di Vandermonde generalizzata

todo

Esercizio

Sia n grande. Siano dati $2n$ numeri positivi x_j, y_j per $j \in \{1, \dots, n\}$ tali che

$$x_j y_j > \frac{1}{2}, \quad \forall j \in \{1, \dots, n\}$$

Siano $v_1, \dots, v_n \in \mathbb{R}^2$ con $v_j = \begin{pmatrix} x_j \\ y_j \end{pmatrix}$ e $j \in \{1, \dots, n\}$ e si consideri $A \in \text{Mat}_n(\mathbb{R})$ tale che

$$A_{j,k} = 1, \quad j \neq k, k, j \in \{1, \dots, n\}, \quad A_{j,j} = \|v_j\|_2$$

Sia $B \in \text{Mat}_n(\mathbb{R})$ la matrice tridiagonale simmetrica con $B_{j,j} = 2$ per $j \in \{1, \dots, n\}$ e $B_{j,j\pm 1} = 1$ per $j \in \{1, \dots, n-1\}$. Si consideri $C \in \text{Mat}_{2n}(\mathbb{R})$ data da

$$C = \begin{pmatrix} A & A^2 - x_1 A \\ 0 & B \end{pmatrix}$$

1. Si dimostri che A, B, C sono invertibili.

2. Si localizzi lo spettro di C nel modo migliore possibile.
3. Si dimostri che la fattorizzazione LU di C esiste unica ovvero C fortemente non singolare.
4. Si dimostri la convergenza del metodo di Gauss-Seidel applicato ad un sistema $Cx = b$ con $b \in \mathbb{R}^{2n}$.
5. Si dimostri che $f(A), f(B), f(C)$ sono invertibili con $f(x) = 1 - x + x^{31}$. È vero che tutti gli autovalori $f(C)$ sono positivi?

Soluzione

1. TODO
2. TODO
3. TODO
4. La matrice non è Hermitiana ed è difficile definire se è a predominanza diagonale, probabilmente no. Nessuno dei teoremi di condizioni sufficienti ci aiuta. Abbiamo il metodo di Gauss-Seidel $Zu = w$. Scegliamo lo splitting M la parte inferiore di Z e $-N$ la parte superiore stretta. Consideriamo C . Allora la sua parte triangolare inferiore, è composta da due blocchi di 0 (alto a destra e basso a sinistra) e due blocchi con rispettivamente le parti triangolari inferiori di A e B . Invece, la triangolare superiore stretta di C ha diagonale tutta nulla, il blocco in basso a sinistra nullo, il primo e quarto blocco contenenti la parte triangolare superiore stretta di A e B rispettivamente, e il secondo blocco pieno di elementi.

$$M = \begin{pmatrix} \text{tril}(A) & 0 \\ 0 & \text{tril}(B) \end{pmatrix}, \quad N = \begin{pmatrix} -\text{triu}(A, 1) & -(A^2 - x_1 A) \\ 0 & -\text{triu}(B, 1) \end{pmatrix}.$$

Quindi il prodotto è composto come

$$\begin{pmatrix} P_{\text{GS}}(A) & * \\ 0 & P_{\text{GS}}(B) \end{pmatrix}$$

Abbiamo che

$$\sigma(P_{\text{GS}}(C)) = \sigma(P_{\text{GS}}(A)) \cup \sigma(P_{\text{GS}}(B))$$

Questo è dato dal fatto che il determinante della matrice a blocchi è il determinante di A per quello di B , quindi il polinomio caratteristico è il prodotto dei due polinomi caratteristici. Sapendo che sono entrambe definite positive

$$\rho(P_{\text{GS}}(C)) = \max\{\rho(P_{\text{GS}}(A)), \rho(P_{\text{GS}}(B))\} < 1$$

Quindi vale la tesi.

5. Abbiamo la scomposizione di Jordan $X = TJT^{-1}$

$$f(X) = I - X + X^3 = T(i - J + J^{31})T^{-1}$$

Il polinomio sulla matrice diventa il polinomio sui blocchi di Jordan. Quando facciamo le potenze, sulle diagonali rimangono le potenze degli autovalori mentre fuori comincia a salire la triangolare superiore. Quindi gli autovalori di $\sigma(f(X)) = f(\sigma(X))$. Studiamo la funzione notando che su $[0, +\infty)$ è strettamente positiva, e quindi le matrici sono ancora invertibili.

Esercizio

Sia $A \in \text{Mat}_n(\mathbb{R})$ con n pari, $a, b, c > 0$ e $a > b$. Definiamo

$$(A)_{j,k} = \begin{cases} a + c & j = k \\ a & (j+k) \equiv 0 \pmod{2} \wedge j \neq k \\ b & (j+k) \equiv 1 \pmod{2} \end{cases}$$

1. Caratterizzare lo spettro nel modo migliore possibile;

2. Dimostrare che il metodo di Gauss-Seidel è convergente se applicato ad un sistema lineare $Ax = b$.

Soluzione

Abbiamo la forma della matrice

$$A = \begin{pmatrix} a+c & b & a & b & a & \cdots & b \\ b & a+c & b & a & b & \cdots & a \\ a & b & a+c & b & a & \cdots & b \\ b & a & b & a+c & b & \cdots & a \\ a & b & a & b & a+c & \cdots & b \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ b & a & b & a & b & \cdots & a+c \end{pmatrix}$$

$$= cI_n + b \underbrace{\begin{pmatrix} 0 & 1 & 0 & 1 & 0 & \cdots & 1 \\ 1 & 0 & 1 & 0 & 1 & \cdots & 0 \\ 0 & 1 & 0 & 1 & 0 & \cdots & 1 \\ 1 & 0 & 1 & 0 & 1 & \cdots & 0 \\ 0 & 1 & 0 & 1 & 0 & \cdots & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 1 & 0 & 1 & \cdots & 0 \end{pmatrix}}_E + a \underbrace{\begin{pmatrix} 1 & 0 & 1 & 0 & \cdots & 1 & 0 \\ 0 & 1 & 0 & 1 & \cdots & 0 & 1 \\ 1 & 0 & 1 & 0 & \cdots & 1 & 0 \\ 0 & 1 & 0 & 1 & \cdots & 0 & 1 \\ 1 & 0 & 1 & 0 & \cdots & 1 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & 0 & 1 & \cdots & 0 & 1 \end{pmatrix}}_F$$

Sicuramente un generico autovalore

$$\lambda(A) = c + \lambda(bF + aE)$$

(Perché e quando si può fare?). Notiamo che F ed E hanno solamente due righe uguali, quindi il loro rango è ≤ 2 , ma le due righe sono chiaramente indipendenti quindi il rango è precisamente 2. Abbiamo quindi che $\text{rank}(bF) = \text{rank}(aE) = 2$. Quindi la matrice completa ha al massimo rango 4. Quindi, A ha autovalore c con molteplicità almeno $n-4$, mentre gli altri 4 autovalori dobbiamo ancora trovarli. La matrice è reale e simmetrica e Hermitiana quindi diagonalizzabile, quindi le molteplicità algebriche e geometriche coincidono. Siano

$$f = \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 1 \end{pmatrix} \in \{0, 1\}^n, g = \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 1 \end{pmatrix} \in \{0, 1\}^n$$

da cui troviamo $E = gg^T + ff^T$ e $F = gf^T + fg^T$. Allora, la matrice

$$\begin{aligned} bF + aE &= b(gf^T + fg^T) + a(gg^T + ff^T) \\ &= g(bf^T + ag^T) + f(bg^T + af^T) \end{aligned}$$

Ma da questa decomposizione deduciamo che il rango di $bF + aE$ è precisamente ≤ 2 , in quanto possiamo generare tutto come combinazione di due vettori. In realtà è precisamente 2 perché possiamo trovare un minore di testa principale il cui rango è al massimo due (cioè il primo minore di testa principale 2×2) quindi $\text{rank}(bF + aE) = 2$. Quindi, A ha autovalore c con molteplicità almeno $n-2$, e altri 2 autovalori. Adesso scriviamo

$$bF + aE = \left[\begin{array}{c|c} f & g \end{array} \right] \left[\begin{array}{c} bg^T + af^T \\ bf^T + ag^T \end{array} \right]$$

Questa scomposizione funziona più in generale. Applicando il teorema di commutazione dello spettro per moltiplicazione di matrici, invertiamo l'ordine e calcoliamo gli autovalori della matrice risultante, che i sono i due autovalori non banali rimanenti. Abbiamo quindi

$$\begin{aligned} \left[\frac{bg^T + af^T}{bf^T + ag^T} \right] \left[\begin{array}{c|c} f & g \end{array} \right] &= \begin{pmatrix} a\|f\|_2^2 & b\|g\|_2^2 \\ b\|f\|_2^2 & a\|g\|_2^2 \end{pmatrix} \\ &= \frac{n}{2} \begin{pmatrix} a & b \\ b & a \end{pmatrix} \end{aligned} \quad \left. \vphantom{\begin{pmatrix} a\|f\|_2^2 & b\|g\|_2^2 \\ b\|f\|_2^2 & a\|g\|_2^2 \end{pmatrix}} \right\} n \text{ è pari}$$

Quindi gli autovalori di A sono c con molteplicità $n - 2$, e $c + \frac{n}{2}(a \pm b)$ con molteplicità 1. È diagonalizzabile in quanto $a > b$, quindi il metodo di Gauss-Seidel converge.

Formula generale dal complemento di Schur. Se E è invertibile allora

$$\begin{pmatrix} E & F \\ G & H \end{pmatrix} = \begin{pmatrix} I & 0 \\ GE^{-1} & I \end{pmatrix} \begin{pmatrix} E & 0 \\ 0 & H - GE^{-1}F \end{pmatrix} \begin{pmatrix} I & E^{-1}F \\ 0 & I \end{pmatrix}$$

con matrici quadrate.

Esercizio 3/04/2025

Sia

$$A = \begin{pmatrix} B_1 & C \\ 0 & B_2 \end{pmatrix}$$

una matrice a blocchi, con $m_1, m_2 \in \mathbb{N}^+$, $m_1, m_2 \geq 2$, $n = m_1 + m_2$, così da definire $B_1 \in \text{Mat}_{m_1}(\mathbb{R})$ e $B_2 \in \text{Mat}_{m_2}(\mathbb{R})$, e $C \in \text{Mat}_{m_1 \times m_2}(\mathbb{R})$ tale che

$$(C)_{i,j} = 1 + i, \quad 1 \leq i \leq m_1, \quad 1 \leq j \leq m_2$$

Le matrici hanno forma

$$B_1 = \begin{pmatrix} 3 & -1 & & & \\ -1 & 3 & -1 & & \\ & -1 & \ddots & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & 3 \end{pmatrix}, \quad B_2 = \begin{pmatrix} 2 & \alpha_1 & & & \\ \delta_1 & 2 & \alpha_2 & & \\ & \delta_2 & \ddots & \ddots & \\ & & \ddots & \ddots & \alpha_{m_2-1} \\ & & & \delta_{m_2-1} & 12 \end{pmatrix}$$

dove la diagonale di B_2 è tutta costante tranne l'ultimo elemento, e gli elementi sono definiti come

$$\alpha_j = 1 + \frac{1}{9+j}, \quad \frac{1}{10} \leq \delta_j \leq \frac{1}{5}, \quad j = 1, \dots, m_2 - 1.$$

1. Studiare lo spettro di A ;
2. Determinare se $\exists_{=1} \lambda$ autovalore tale che $\lambda = \rho(A)$;
3. Determinare se A è invertibile;
4. Trovare un algoritmo veloce per risolvere $Ax = b$ e calcolarne il costo computazionale;
5. Mostrare la convergenza. Qual è il k minimo?

Soluzione

1. Dalla forma della matrice sappiamo che

$$\sigma(A) = \sigma(B_1) \cup \sigma(B_2)$$

Lo si vede usando la forma triangolare a blocchi. Studiamo quindi separatamente questi spettri. I dischi di Gershgorin di B_1 sono

$$D_1 = D_{m_1} = \{z \in \mathbb{C} \mid |z - 3| \leq 1\} = [2, 4]$$

$$D_i = \{z \in \mathbb{C} \mid |z - 3| \leq 2\} = [1, 5], \quad 1 < i < m_1$$

siccome la matrice è simmetrica, quindi gli autovalori sono reali. Allora abbiamo che $\sigma(B_1) \subseteq [1, 5]$. La matrice B_1 è irriducibile in quanto il suo grafo associato è fortemente connesso (esempio con $m_1 = 6$):



Per il terzo teorema di Gershgorin, se un autovalore fosse 1 o 5 dovrebbe stare sul bordo di tutti i dischi, ma $1, 5 \notin D_1 = D_{m_1}$. Quindi $\sigma(B_1) \subseteq (1, 5)$. In realtà, essendo B_1 tridiagonale

di Toeplitz,

$$\sigma(B_1) = \left\{ 3 - 2 \cos \left(\frac{k\pi}{m_1 + 1} \right) \mid k = 1, \dots, m_1 \right\}.$$

Studiamo ora lo spettro di B_2 . Studiamo lo spettro di $\tilde{B} = DB_2D^{-1}$ con D diagonale invertibile, che tanto non cambia. Costruiamo la matrice D come

$$D = \text{diag}(d_1, \dots, d_{m_2})$$

con

$$d_1 = 1, \quad \frac{d_{j+1}}{d_j} = \sqrt{\frac{\alpha_j}{\delta_j}}$$

Eseguendo il prodotto troviamo

$$\tilde{B} = \begin{pmatrix} 2 & \alpha_1 \frac{d_1}{d_2} & & & \\ \delta_1 \frac{d_2}{d_1} & 2 & \alpha_2 \frac{d_2}{d_3} & & \\ & \delta_2 \frac{d_3}{d_2} & \ddots & \ddots & \\ & & \ddots & 2 & \alpha_{m_2-1} \frac{d_{m_2-1}}{d_{m_2}} \\ & & & \delta_{m_2-1} \frac{d_{m_2}}{d_{m_2-1}} & 12 \end{pmatrix} = \begin{pmatrix} 2 & \gamma_1 & & & \\ \gamma_1 & 2 & \gamma_2 & & \\ & \gamma_2 & \ddots & \ddots & \\ & & \ddots & 2 & \gamma_{m_2-1} \\ & & & \gamma_{m_2-1} & 12 \end{pmatrix}$$

dove $\gamma_j = \sqrt{\alpha_j \delta_j}$. Abbiamo precisamente scelto i valori d_j per forzare una matrice Hermitiana. Calcoliamo ora i dischi di Gershgorin di questa matrice:

$$\begin{aligned} D_1 &= [2 - \gamma_1, 2 + \gamma_1] \\ D_i &= [2 - (\gamma_{i-1} + \gamma_i), 2 + (\gamma_{i-1} + \gamma_i)], \quad 1 < i < m_2 \\ D_{m_2} &= [12 - \gamma_{m_2-1}, 12 + \gamma_{m_2-1}] \end{aligned}$$

I primi $m_2 - 1$ dischi stanno tutti vicino a 2, mentre l'ultimo sta vicino a 12. Diamo un bound

$$\frac{1}{10} \left(1 + \frac{1}{9+j} \right) \leq \alpha_j \delta_j \leq \frac{1}{5} \left(1 + \frac{1}{9+j} \right) \leq \frac{11}{50}$$

Vogliamo anche stimare la somma

$$\sqrt{\alpha_{i-1} \delta_{i-1}} + \sqrt{\alpha_i \delta_i} \leq \sqrt{\frac{i+9}{i+8} \frac{1}{5}} + \sqrt{\frac{i+10}{i+9} \frac{1}{5}} \leq \sqrt{\frac{11}{50}} + \sqrt{\frac{12}{55}}$$

dove il massimo si ottiene per $i = 2$. Quindi,

$$\sigma(B_2) = \sigma(\tilde{B}) \subseteq \left[2 - \left(\sqrt{\frac{11}{50}} + \sqrt{\frac{12}{55}} \right), 2 + \sqrt{\frac{11}{50}} + \sqrt{\frac{12}{55}} \right] \cup \left[12 - \sqrt{\frac{11}{50}}, 12 + \sqrt{\frac{11}{50}} \right].$$

Il raggio più grande del secondo termine avviene per $m_2 = 2$, così otteniamo una stima globale per qualsiasi grandezza, cioè raggio $\sqrt{11/50}$. Questo può essere usato per controllare che l'ultimo cerchio sia isolato rispetto agli altri, cosa che è. Per il secondo teorema di Gershgorin, il primo intervallo contiene $m_2 - 1$ autovalori di B_2 e il secondo intervallo contiene un unico autovalore. Inoltre, per il terzo teorema di Gershgorin, siccome $\tilde{B}$ è irriducibile, questo autovalore non può stare sul bordo del disco isolato.

2. Per il secondo teorema di Gershgorin, c'è un unico autovalore λ_* di B_2 vicino a 12. Inoltre,

$$\lambda_* \geq 12 - \sqrt{\frac{11}{50}} > 5$$

mentre gli autovalori di B_1 stanno in $(1, 5)$ e gli altri autovalori di B_2 stanno nell'intervallo centrato in 2, che è contenuto in $(1, 3)$. Quindi $\rho(A) = \lambda_*$, e questo autovalore è unico.

3. A è invertibile in quanto $0 \notin \sigma(A)$.
4. Siccome la matrice è a blocchi possiamo scrivere

$$\begin{pmatrix} B_1 & C \\ 0 & B_2 \end{pmatrix} \begin{pmatrix} Z \\ Y \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

dove $\begin{pmatrix} Z \\ Y \end{pmatrix}$ è un vettore a blocchi, quindi $B_1 Z + CY = b_1$ e $B_2 Y = b_2$. Dobbiamo quindi risolvere prima $B_2 Y = b_2$, e poi $B_1 Z = b_1 - CY$. Possiamo adoperare l'algoritmo di Thomas, cioè l'eliminazione di Gauss specializzata alle matrici tridiagonali, e poi risolvere con sostituzione all'indietro. Per una matrice tridiagonale $r \times r$, la parte di eliminazione costa $5(r-1)$ operazioni, mentre la sostituzione all'indietro costa $1 + 3(r-1)$, quindi in totale $8r - 7$ operazioni. Per CY non conviene costruire C : siccome $C_{i,j} = 1 + i$,

$$(CY)_i = (1+i) \sum_{j=1}^{m_2} Y_j.$$

Calcoliamo quindi $s = \sum_{j=1}^{m_2} Y_j$ in $m_2 - 1$ somme e poi $b_1 - CY$ in $2m_1$ operazioni. Il costo totale è quindi

$$(8m_2 - 7) + (m_2 - 1 + 2m_1) + (8m_1 - 7) = 10m_1 + 9m_2 - 15$$

cioè $\mathcal{O}(m_1 + m_2)$.

5. Sia $A = M - N$ con

$$M = \begin{pmatrix} B_1 & 0 \\ 0 & B_2 \end{pmatrix}, \quad N = \begin{pmatrix} 0 & -C \\ 0 & 0 \end{pmatrix}$$

Il metodo iterativo converge se

$$\lim_{k \rightarrow +\infty} (M^{-1}N)^k = 0.$$

Abbiamo

$$M^{-1} = \begin{pmatrix} B_1^{-1} & \\ & B_2^{-1} \end{pmatrix}, \quad M^{-1}N = \begin{pmatrix} B_1^{-1} & 0 \\ 0 & B_2^{-1} \end{pmatrix} \begin{pmatrix} 0 & -C \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -B_1^{-1}C \\ 0 & 0 \end{pmatrix} = P$$

Viene calcolato il quadrato della matrice di iterazione P per verificare dopo quanti passi il metodo converge esattamente,

$$P^2 = \begin{pmatrix} 0 & -B_1^{-1}C \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & -B_1^{-1}C \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$$

Quindi P è nilpotente, $\rho(P) = 0$, e il metodo converge. Siccome $P \neq 0$, il k minimo è $k = 2$.