

Appunti di Analisi Numerica

Paolo Bettelini

Contents

1	Fondamenti di algebra lineare numerica	2
1.1	Matrici speciali e forme normali	2
1.2	Norme, matrici normali e teoremi spettrali	5
1.3	Diadi, matrici elementari e aggiornamenti di rango uno	9
1.4	Eliminazione gaussiana e fattorizzazione LU	10
1.5	Riflettori di Householder e fattorizzazione QR	12
2	Metodi iterativi per sistemi lineari	15
2.1	Splitting matriciali e convergenza	15
2.2	Splitting classici e metodi di punto fisso	18
2.3	Metodo di Jacobi	18
2.4	Metodo di Gauss-Seidel	20
2.5	Esempi e confronto qualitativo fra Jacobi e Gauss-Seidel	21
3	Localizzazione spettrale e applicazioni alla convergenza	23
3.1	Teoremi di Gershgorin	23
3.2	Irriducibilità e grafi associati	25
3.3	Applicazioni ai metodi iterativi	28
3.4	Convergenza, consistenza e stabilità	29
4	Analisi dell'errore nei metodi iterativi	30
4.1	Tassi di riduzione dell'errore	30
4.2	Criteri d'arresto	32
4.2.1	Criterio basato sul residuo	32
4.2.2	Criterio basato sulla differenza fra iterati consecutivi	33
4.3	Gauss-Seidel per matrici Hermitiane definite positive	33
4.4	Metodi di rilassamento	35
4.5	Esempi di confronto fra Jacobi e Gauss-Seidel	35
4.6	Matrici consistentemente ordinate e confronto asintotico	36
5	Condizionamento e fattorizzazioni per sistemi lineari	40
5.1	Perturbazioni e condizionamento	40
5.1.1	Norme submoltiplicative e stime generali	40
5.2	Fattorizzazione LU	42
5.3	Fattorizzazione di Cholesky	45
5.4	Matrici semi-elementari e aggiornamenti a basso rango	50
5.5	Formula di Sherman–Morrison–Woodbury	51
6	Norme vettoriali e matriciali	53
6.1	Norma infinito e norma indotta	53
6.2	Norme indotte 1, 2 e infinito	55
7	Decomposizione ai valori singolari	57

8	Approssimazione polinomiale e operatori positivi	60
8.1	Operatori positivi e polinomi di Bernstein	60
8.2	Korovkin multidimensionale e polinomi di Bernstein	69
8.3	Interpolazione polinomiale	71
9	Metodi per autovalori	73
9.1	Metodo delle potenze	73
10	PageRank e modelli matriciali per il Web	75
10.1	Modello di importanza e matrice dei link	75
10.2	Metodo delle potenze per il ranking	76
10.3	Pagine senza link uscenti	76
10.4	Oscillazioni e periodicità	77
10.5	Teletrasporto e convergenza del PageRank	77
11	Esercizi e problemi svolti	79
12	Esami	93

Fondamenti di algebra lineare numerica

1.1 Matrici speciali e forme normali

Teorema Determinante matrice di Vandermonde

Sia V una matrice di Vandermonde. Allora

$$\det V = \prod_{1 \leq i < j \leq n} (z_j - z_i).$$

Quindi V è invertibile se e solo se

$$i \neq j \implies z_i \neq z_j.$$

Proof Determinante matrice di Vandermonde

Procediamo per induzione su n .

1. *Caso base*: se $n = 1$, allora

$$\det V_1 = \det[1] = 1,$$

e la tesi è verificata.

2. *Passo induttivo*: supponiamo che la tesi valga per $n - 1$.

Consideriamo

$$V_n = \left(\begin{array}{cccc|c} 1 & z_1 & \dots & z_1^{n-2} & z_1^{n-1} \\ 1 & z_2 & \dots & z_2^{n-2} & z_2^{n-1} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 1 & z_{n-1} & \dots & z_{n-1}^{n-2} & z_{n-1}^{n-1} \\ \hline 1 & z_n & \dots & z_n^{n-2} & z_n^{n-1} \end{array} \right).$$

Espandendo il determinante lungo l'ultima riga otteniamo

$$\det V_n = \sum_{k=0}^{n-1} (-1)^{n+k+1} z_n^k M_k,$$

dove M_k è il determinante della matrice ottenuta eliminando l'ultima riga e la colonna $k + 1$.

Ponendo

$$A_k = (-1)^{n+k+1} M_k,$$

possiamo vedere $\det V_n$ come un polinomio in z_n :

$$P(z_n) = \det V_n = \sum_{k=0}^{n-1} A_k z_n^k.$$

Il termine di grado massimo corrisponde a $k = n - 1$. In questo caso

$$A_{n-1} = (-1)^{2n} M_{n-1} = M_{n-1} = \det V_{n-1}.$$

Quindi

$$P(z_n) = z_n^{n-1} \det V_{n-1} + \sum_{k=0}^{n-2} A_k z_n^k.$$

Per ipotesi induttiva,

$$\det V_{n-1} = \prod_{1 \leq i < j \leq n-1} (z_j - z_i).$$

Se tra $z_1, \dots, z_{n-1}$ ci sono due valori uguali, allora V_n ha due righe uguali e quindi

$$\det V_n = 0.$$

D'altra parte, anche

$$\prod_{1 \leq i < j \leq n} (z_j - z_i) = 0,$$

per cui la tesi è verificata.

Possiamo dunque supporre che $z_1, \dots, z_{n-1}$ siano distinti.

Se poniamo $z_n = z_i$ per un certo $i < n$, la riga n -esima coincide con la riga i -esima, e quindi

$$P(z_i) = 0.$$

Pertanto P ha le $n - 1$ radici distinte

$$z_1, \dots, z_{n-1}.$$

Poiché P ha grado al più $n - 1$, esiste una costante C tale che

$$P(z) = C \prod_{i=1}^{n-1} (z - z_i).$$

Il coefficiente del termine di grado $n - 1$ è C , ma dall'espansione precedente sappiamo che tale coefficiente è

$$C = \det V_{n-1}.$$

Pertanto

$$\begin{aligned} \det V_n &= \det V_{n-1} \prod_{i=1}^{n-1} (z_n - z_i) \\ &= \left(\prod_{1 \leq i < j \leq n-1} (z_j - z_i) \right) \left(\prod_{i=1}^{n-1} (z_n - z_i) \right) \\ &= \prod_{1 \leq i < j \leq n} (z_j - z_i). \end{aligned}$$

Questo conclude il passo induttivo.

Teorema Forma normale di Schur

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. Esiste una matrice unitaria Q , cioè $Q^*Q = I_n$, tale che

$$Q^*AQ = T$$

dove T è triangolare superiore.

Proof Forma normale di Schur

Procediamo per induzione su n .

1. *Caso base*: abbiamo $A = (a_{11}) = (e^{i\theta})(a_{11})(e^{-i\theta})$ per ogni $\theta \in \mathbb{R}$.
2. *Passo induttivo*: sia λ un autovalore di A e sia x un autovettore associato. Sia $v_1 = x/\|x\|_2$ e quindi $Av_1 = \lambda v_1$ siccome $Ax = \lambda x$. Quindi, v_1 è un autovettore associato a λ con norma 1. Completiamo v_1 ad una base ortonormale di $\mathbb{C}^n$ usando il processo di Gram-Schmidt $\{v_1, \dots, v_n\}$. Costruiamo quindi la matrice unitaria $U_1 = [v_1, \dots, v_n]$. Consideriamo quindi

$$U_1^*AU_1 = \begin{pmatrix} \lambda & * \\ 0 & A_1 \end{pmatrix}$$

dove A_1 è una matrice $(n-1) \times (n-1)$ complessa. Per ipotesi induttiva esiste matrice unitaria U_2 tale che $U_2^*A_1U_2 = T_1$ con T_1 triangolare superiore. Allora costruiamo

$$U = U_1 \begin{pmatrix} 1 & 0 \\ 0 & U_2 \end{pmatrix}$$

Allora

$$U^*AU = \begin{pmatrix} \lambda & * \\ 0 & T_1 \end{pmatrix} = T$$

è triangolare superiore, con diagonale formata dagli autovalori di A .

Proposition

La somma diretta di matrici unitarie A, B è unitaria

Proof

$$\begin{aligned} (A \oplus B)^*(A \oplus B) &= \begin{pmatrix} A^* & 0 \\ 0 & B^* \end{pmatrix} \begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} \\ &= \begin{pmatrix} A^*A & 0 \\ 0 & B^*B \end{pmatrix} = \begin{pmatrix} I_m & 0 \\ 0 & I_n \end{pmatrix} = I_{m+n} \end{aligned}$$

Definizione Forma normale di Jordan

Sia $A \in \text{Mat}_{n \times n}$ una matrice quadrata. Una *matrice di Jordan* J associata ad A è una matrice a blocchi diagonali del tipo

$$J = \begin{pmatrix} J_1 & 0 & \cdots & 0 \\ 0 & J_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & J_k \end{pmatrix}$$

dove ogni blocco ha forma

$$J_i = \begin{pmatrix} \lambda_i & 1 & 0 & \cdots & 0 \\ 0 & \lambda_i & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_i & 1 \\ 0 & 0 & \cdots & 0 & \lambda_i \end{pmatrix}$$

con λ_i autovalori di A .

Teorema Teorema della forma normale di Jordan

Ogni matrice quadrata complessa A è simile a una e una sola matrice di Jordan J , a meno dell'ordine dei blocchi $A = PJP^{-1}$.

1.2 Norme, matrici normali e teoremi spettrali

Siano $x, y \in \mathbb{C}^n$, allora $\|x\|_2^2 = x^*x$ e, per matrici di dimensioni compatibili, $(XY)^* = Y^*X^*$. Inoltre,

$$\|A\|_2 = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \sqrt{\rho(A^*A)}$$

Se A è unitaria $\|A\|_2 = \sqrt{\rho(I)} = 1$. Inoltre, per un autovettore $x \neq 0$, vale $Ax = \lambda x$.

Teorema

Sia λ autovalore di A unitaria, allora $|\lambda| = 1$.

Proof

Abbiamo che $\|Ax\|_2 = \|x\|_2$ ma ciò è uguale a $\|\lambda x\|_2 = |\lambda| \cdot \|x\|_2$, dividiamo per $\|x\|_2$ che non è nullo e troviamo la tesi.

Teorema

Sia $P \in \text{Mat}_{n \times n}(\mathbb{R})$, P matrice di permutazione con $P = P^t$. Allora, gli autovalori λ di P sono in $\{+1, -1\}$.

Teorema

La norma $\|\cdot\|_2$ su $\text{Mat}_{n \times n}(\mathbb{C})$ è unitariamente invariante, cioè $\forall A \in \text{Mat}_{n \times n}(\mathbb{C}), \forall P, Q$ unitarie su $\text{Mat}_{n \times n}(\mathbb{C})$, vale $\|PA\|_2 = \|AQ\|_2 = \|A\|_2$.

Proof

Abbiamo

$$\|PA\|_2 = \sup_{x \neq 0} \frac{\|PAx\|_2}{\|x\|_2} = \sup_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \|A\|_2$$

Inoltre

$$\|AQ\|_2 = \sup_{x \neq 0} \frac{\|AQx\|_2}{\|x\|_2} = \sup_{x \neq 0} \frac{\|Ay\|_2}{\|y\|_2} = \|A\|_2$$

dove $y = Qx$ e poiché Q è unitario $\|y\|_2 = \|x\|_2$.

Teorema

$GL_n(\mathbb{C})$ è denso rispetto a $\text{Mat}_n(\mathbb{C})$.

Proof

Sia $X \in \text{Mat}_{n \times n}(\mathbb{C})$. Mostriamo che $\exists \{X_s\}$ tale che $\{X_s\} \rightarrow X$, con $X_s \in GL_n(\mathbb{C})$. Se X è invertibile allora $\forall s, X_s = X$ e abbiamo finito. Altrimenti consideriamo la forma normale di Schur $X = QTQ^*$, costruiamo $X_s = QT_sQ^*$ con T_s dato da

$$(T_s)_{j,k} = \begin{cases} (T)_{j,k} & j \neq k \\ (T)_{j,k} & k = j \wedge T_{j,j} \neq 0 \\ \frac{1}{s} & k = j \wedge T_{j,j} = 0 \end{cases}$$

Quindi per costruzione T_s è invertibile per tutte le $s > 0$ ed è triangolare superiore. Abbiamo allora

$$\begin{aligned} \|X - X_s\|_2 &= \|QTQ^* - QT_sQ^*\|_2 = \|Q(T - T_s)Q^*\|_2 = \|T - T_s\|_2 \\ &= \left\| \text{diag}(\alpha_{j,s}) \right\|_2 = \frac{1}{s} \rightarrow 0 \end{aligned}$$

Con $\alpha_{j,s} = 0$ se $1 \leq j \leq n$ e $T_{j,j} \neq 0$, e $\alpha_{j,s} = -1/s$ se $1 \leq j \leq n$ e $T_{j,j} = 0$.

Definizione Quoziente di Rayleigh

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$ e $r_A: \mathbb{C}^n \setminus \{0\} \rightarrow \mathbb{C}$ data da

$$r_A(x) \triangleq \frac{x^*Ax}{x^*x}$$

è il *Quoziente di Rayleigh* di A .

Definizione Matrice definita positiva

X è *definita positiva* se e solo se X è Hermitiana e $r_X(v) > 0$ per tutti i $v \neq 0$, e analogamente per le altre definitezze.

Questa è la definizione.

Definizione Matrice normale

Una matrice $X \in \text{Mat}_{n \times n}(\mathbb{C})$ è *normale* se $XX^* = X^*X$.

Proposition

La matrice XX^* è semidefinita positiva

Proof

Sia $B = XX^*$ e allora $B^* = X^{**}X^* = XX^* = B$. Il quoziente di Rayleigh di B è dato da

$$r_B(v) = \frac{v^*XX^*v}{v^*v}$$

chiamando $w = X^*v$, allora $w^* = v^*X$, quindi

$$r_B(v) = \frac{w^*w}{v^*v}$$

che è una quantità non-negativa.

Per analizzare le varie classi di matrici usiamo il teorema di Schur.

Teorema

A è una matrice Hermitiana se e solo se $A = QDQ^*$, Q unitaria, e D diagonale reale.

Cioè il teorema spettrale. Sulla matrice diagonale ci sono gli autovalori e stiamo dicendo che sono reali. Cioè una matrice è Hermitiana se e solo se tutti gli autovalori sono reali e gli autovettori formano una base ortonormale.

Proof

Scomponiamo $A = QTQ^*$ per il teorema di Schur. Vogliamo quindi mostrare che T è diagonale reale. Siccome A è Hermitiana, abbiamo

$$QTQ^* = A^* = (QTQ^*)^* = QT^*Q^*$$

Ma siccome Q è unitaria, moltiplicando a sinistra per Q^* e a destra per Q otteniamo che pure T è Hermitiana. L'unico modo per una matrice triangolare di essere Hermitiana è se i valori sopra la diagonale sono nulli. Inoltre, i valori sulla diagonale devono essere reali in quanto corrispondono al loro coniugato.

Teorema

A è una matrice normale se e solo se $A = QDQ^*$, con Q unitaria e D diagonale.

Questa è un'estensione del teorema spettrale: tutte e sole le matrici normali ammettono una base ortonormale di autovettori.

Proof

Scomponiamo $A = QTQ^*$ per il teorema di Schur. Siccome A è normale, $AA^* = A^*A$. Inoltre,

$$\begin{aligned} AA^* &= QTQ^*QT^*Q^* = QTT^*Q^*, \\ A^*A &= QT^*Q^*QTQ^* = QT^*TQ^*. \end{aligned}$$

Moltiplicando a sinistra per Q^* e a destra per Q otteniamo che pure T è normale. Siccome $TT^* = T^*T$ abbiamo un pattern della matrice

$$\begin{pmatrix} * & * \\ 0 & * \end{pmatrix} \begin{pmatrix} * & 0 \\ * & * \end{pmatrix} = \begin{pmatrix} * & 0 \\ * & * \end{pmatrix} \begin{pmatrix} * & * \\ 0 & * \end{pmatrix}$$

Se consideriamo la prima riga e la prima colonna, abbiamo da una parte un numero solo e dall'altro un prodotto "intero"

$$\sum_{k=1}^n |T_{1,k}|^2 = (T^*T)_{1,1} = |T_{1,1}|^2$$

Ciò succede se e solo se $T_{1,k} = 0$, per k che va da 2 a n . Analogamente guardiamo la seconda riga: sappiamo che uno dei termini è nullo dal passo precedente, quindi $(T^*T)_{2,2} = (TT^*)_{2,2} = |T_{2,2}|^2$. Quindi $T_{2,k} = 0$ per ogni k da 3 a n . Proseguendo il procedimento troviamo quindi che la matrice è diagonale.

Teorema

A è una matrice unitaria se e solo se $A = QDQ^*$, D diagonale unitaria con $|D_{i,i}| = 1$, e Q unitaria.

Proof

Scomponiamo $A = QTQ^*$ per il teorema di Schur. Siccome A è unitaria, $A^*A = I = AA^*$ e quindi è anche normale, allora $A = QDQ^*$ con D diagonale. Abbiamo quindi

$$QD^*DQ^* = I$$

moltiplicando a sinistra per Q^* e a destra per Q otteniamo che $D^*D = I$ quindi è unitaria.

La Q sarà pure unitaria e consiste negli autovettori.

Teorema

A è definita positiva se e solo se $A = QDQ^*$ con D diagonale, $D_{j,j} > 0$ e Q unitaria. E analoghi gli altri.

Proof

A è definita positiva mediante quoziente di Rayleigh se $v^*Av > 0$ per ogni $v \neq 0$, e chiaramente deve essere Hermitiana. Abbiamo quindi la scomposizione $A = QDQ^*$ con D diagonale. Siccome Q ha come colonne una base ortonormale $\{q_1, \dots, q_n\}$, e allora il prodotto scalare con la matrice diagonale è il trasposto coniugato del vettore della base $q_j^*Q = e_j^t$. Abbiamo quindi $0 < q_j^*Aq_j = e_j^tDe_j = D_{j,j}$. Quindi al variare di j , i valori sulla diagonale sono strettamente positivi.

Teorema

Se A è una matrice Hermitiana, l'immagine di r_A è il segmento fra il minimo autovalore e quello più grande.

Proof

Abbiamo

$$\begin{aligned} r_A(v) &= \frac{v^*Av}{v^*v} = \frac{v^*QDQ^*v}{v^*v} \\ &= \frac{w^*Dw}{\|w\|_2^2} \end{aligned}$$

usando $w = Q^*v$, quindi $\|w\|_2^2 = v^*v = \|v\|_2^2$. Definiamo

$$\hat{w} = \frac{w}{\|w\|_2}$$

e abbiamo quindi

$$r_A(v) = \hat{w}^*D\hat{w} = \sum_{j=1}^n |\hat{w}_j|^2 \lambda_j(A)$$

dove $\lambda_j(A)$ sono gli autovalori di A . I coefficienti $|\hat{w}_j|^2$ sono non-negativi e sommano uno, quindi abbiamo una combinazione convessa. Tutte queste combinazioni disegnano l'involucro convesso (minimo oggetto convesso che contiene il tutto), cioè un poliedro complesso in cui i vertici sono autovalori. Siccome A è Hermitiana, tutti gli autovalori sono reali, quindi il poliedro è in realtà il segmento fra l'autovalore minimo e quello massimo.

Definizione

Sia $X \in \text{Mat}_{n \times n}(\mathbb{C})$, diciamo che X è ω -Hermitiana se $X^* = \omega X$.

Una matrice è Hermitiana se e solo se è 1-Hermitiana, e i suoi autovalori sono reali. Una matrice è anti-Hermitiana se e solo se è -1 -Hermitiana. Moltiplicare per i trasforma una matrice anti-Hermitiana in una matrice Hermitiana. Le matrici ω -Hermitiane formano uno spazio vettoriale reale; se lo spazio contiene matrici non nulle, non è uno spazio vettoriale complesso.

In generale, siccome $X^{**} = X$ è un'involuzione sulle matrici ω -Hermitiane otteniamo

$$(\omega X)^* = \bar{\omega} X^* = |\omega|^2 X$$

Quindi ci serve per forza che ω sia un versore, altrimenti lo spazio vettoriale è degenere e contiene solo il vettore nullo (matrice nulla). Vogliamo quindi $\omega = e^{i\theta}$. Notiamo che per $\theta = 0$, gli autovalori sono reali. Per $\theta = \pi$, gli autovalori sono puramente immaginari, e più in generale gli autovalori stanno sulla retta di angolo $-\theta/2$ modulo π . Partendo da $Ax = \lambda x$ abbiamo

$$\begin{aligned} x^* Ax &= \lambda \|x\|_2^2 \\ (x^* Ax)^* &= (\lambda \|x\|_2^2)^* \\ x^* A^* x &= \bar{\lambda} \|x\|_2^2 \\ x^* \omega A x &= \bar{\lambda} \|x\|_2^2 \\ e^{i\theta} x^* Ax &= e^{i\theta} \lambda \|x\|_2^2 \\ &= \bar{\lambda} \|x\|_2^2 \\ e^{i\theta} \lambda &= \bar{\lambda} \end{aligned}$$

1.3 Diadi, matrici elementari e aggiornamenti di rango uno

Definizione Diadi

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. A si dice *diade* se $\exists x, y \in \mathbb{C}^n$ tale che $A = xy^*$.

Definizione Matrice elementare

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. A si dice *elementare* se $A = I_n + F$ con F diade.

Matrici elementari nel senso dell'eliminazione gaussiana.

Proposition

Sia A diade non banale. Allora, i suoi autovalori sono

1. 0 con molteplicità geometrica $n - 1$ (se $n > 1$), e y^*x come autovalore non banale.
2. se $y^*x = 0$ allora 0 ha molteplicità algebrica n e geometrica $n - 1$, e tutti gli autovettori sono gli z tali che $y^*z = 0$, che è un sottospazio di dimensione $n - 1$, cioè quelli ortogonali a y . Se $y^*x \neq 0$ le molteplicità coincidono ed è diagonalizzabile, l'autovettore rimanente è precisamente x , cioè l'autospazio relativo a $\lambda = y^*x$ è generato da x .

Proof

Siano x, y vettori complessi non banali, quindi xy^* ha rango 1 in quanto ogni riga è un multiplo di y^* . Quindi $n - 1$ autovalori sono nulli. Dunque per tutti gli z ortogonali a y ovvero $y^*z = 0$, vale che $Az = xy^*z = x \cdot 0 = 0$. Studiamo ora i vari casi. Se $y^*x = 0$ la traccia è nulla, quindi l'autovalore rimanente è zero. La molteplicità algebrica sale a n mentre quella geometrica rimane $n - 1$. Se invece $y^*x \neq 0$, cioè non è ortogonale, allora $Ax = (y^*x) \cdot x$.

Teorema

Sia $A = I_n + xy^*$ con $x, y \neq 0$. Allora, A è invertibile se e solo se $y^*x \neq -1$. In tal caso,

$$A^{-1} = I - \frac{1}{1 + y^*x} xy^*$$

Proof

Lo spettro di A è della forma $1 + \lambda(xy^*)$. Dalla caratterizzazione degli autovalori di una tale matrice, abbiamo

$$1 + \lambda(xy^*) = \begin{cases} 1 & \mu_g = n - 1 \\ 1 + y^*x & \end{cases}$$

quindi nel secondo caso vogliamo assicurarci che $y^*x \neq -1$. Se la matrice è invertibile,

$$A^{-1} = I + \alpha xy^*$$

Per trovare α abbiamo

$$\begin{aligned} (I + \alpha xy^*)(I + xy^*) &= I + \alpha xy^* + xy^* + (\alpha y^*x)xy^* \\ &= I + [\alpha(1 + y^*x) + 1]xy^* \\ \alpha &= -\frac{1}{1 + y^*x} \end{aligned}$$

Dato un sistema lineare $Bv = c$ con $B = A + xy^*$, dove A è invertibile, $x, y \neq 0$ e $1 + y^*A^{-1}x \neq 0$, supponiamo di voler ricondurre alla soluzione del sistema $Av = c$ (cioè abbiamo perturbato il sistema con una matrice di rango 1) perché supponiamo di avere un algoritmo ottimale per risolvere un sistema associato ad A . Abbiamo che

$$B = A(I + A^{-1}xy^*)$$

e quindi il sistema si risolve come

$$\begin{aligned} Bv &= c \\ v &= B^{-1}c = (I + r_1 y^*)^{-1} A^{-1}c \end{aligned}$$

dove r_1 lo sappiamo risolvere da $Ar_1 = x$. Pure il vettore $A^{-1}c$ può essere calcolato risolvendo $A\hat{c} = c$. Quindi alla fine dobbiamo applicare l'algoritmo iniziale due volte. Quindi otteniamo

$$B^{-1} = \left(I - \frac{A^{-1}xy^*}{1 + y^*A^{-1}x} \right) A^{-1} = A^{-1} - \frac{A^{-1}xy^*A^{-1}}{1 + y^*A^{-1}x}$$

In generale se perturbo una matrice grande con, per esempio, una matrice di norma 5, in generale è grande ma se il rango è 1 allora si risolve semplicemente il problema. Quindi in astratto la distanza fra matrici in un certo senso non è solo la norma ma anche il rango.

1.4 Eliminazione gaussiana e fattorizzazione LU

Per una matrice elementare abbiamo

$$E_{x,y}^{-1} = I - \frac{1}{1 + y^*x} xy^*$$

purché $y^*x \neq -1$. Sia $a \in \mathbb{C}^n$, $a_1 \neq 0$. Allora

$$E = I - \begin{pmatrix} 0 \\ a_2/a_1 \\ \vdots \\ a_n/a_1 \end{pmatrix} e_1^t$$

e quindi

$$Ea = a_1 \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

Nel nostro caso il termine

$$y^* x = e_1^t \begin{pmatrix} 0 \\ -\frac{a_2}{a_1} \\ \vdots \\ -\frac{a_n}{a_1} \end{pmatrix}$$

e

$$E^{-1} = I + \begin{pmatrix} 0 \\ \frac{a_2}{a_1} \\ \vdots \\ \frac{a_n}{a_1} \end{pmatrix} e_1^t$$

Quando una matrice è fortemente non-singolare allora l'algoritmo di eliminazione di Gauss senza pivoting non ha breakdown (se e solo se). Sia $\hat{A}_1 = A_1 = A$ la matrice di partenza. Vogliamo trasformare questa matrice in U triangolare superiore, mantenendo l'equivalenza del sistema lineare. Sia $\hat{a}_j$ la prima colonna della matrice quadrata di ordine $n+1-j$, cioè al primo passo annullo tutto sotto al pivot, quindi vado avanti con matrici di quell'ordine. Allora

$$E_1 = I - \begin{pmatrix} 0 \\ v_1 \end{pmatrix} e_1^t, E_2 = I - \begin{pmatrix} 0 \\ 0 \\ v_2 \end{pmatrix} e_2^t$$

E in generale

$$E_{n-1} = I - \begin{pmatrix} 0 \\ 0 \\ \vdots \\ v_{n-1} \end{pmatrix} e_{n-1}^t$$

e la matrice diventa

$$A_j = \left(\begin{array}{cc|ccc} * & * & * & \cdots & * \\ 0 & * & * & \cdots & * \\ \hline 0 & 0 & & & \\ \vdots & \vdots & & \hat{A}_j & \\ 0 & 0 & & & \end{array} \right)$$

e $A_{j+1} = E_j A_j$. Infine troviamo

$$A_n = U$$

Quindi abbiamo $U = A_n = E_{n-1} \cdots E_2 E_1 A$. Per trovare A bisogna moltiplicare a sinistra per l'inversa, quindi

$$A = E_1^{-1} E_2^{-1} \cdots E_{n-1}^{-1} U = \left(I + \begin{pmatrix} 0 \\ v_1 \end{pmatrix} e_1^t \right) \left(I + \begin{pmatrix} 0 \\ 0 \\ v_2 \end{pmatrix} e_2^t \right) \cdots \left(I + \begin{pmatrix} 0 \\ 0 \\ \vdots \\ v_{n-1} \end{pmatrix} e_{n-1}^t \right) U$$

Dalla struttura sappiamo che questo termine che moltiplica U è triangolare inferiore. Consideriamo i primi due termini del prodotto,

$$\left(I + \begin{pmatrix} 0 \\ v_1 \end{pmatrix} e_1^t \right) \left(I + \begin{pmatrix} 0 \\ 0 \\ v_2 \end{pmatrix} e_2^t \right) = I + \begin{pmatrix} 0 \\ v_1 \end{pmatrix} e_1^t + \begin{pmatrix} 0 \\ 0 \\ v_2 \end{pmatrix} e_2^t + 0$$

quindi i prodotti misti delle diadi si annullano. Questo per induzione si estende a tutti i prodotti e quindi abbiamo una bella semplificazione. Notiamo che nella struttura della moltiplicazione $A = LU$, per come si svolge il prodotto, possiamo considerare la matrice a blocchi mettendo in evidenza il minore A_k , e da questa osservazione sul prodotto di matrici a blocchi, notiamo il se e solo se con la forte non-singularità. Vale $A_k = L_k U_k$ e l'ipotesi di invertibilità è equivalente a dire che i pivot non sono nulli.

1.5 Riflettori di Householder e fattorizzazione QR

Definiamo una generalizzazione per considerare anche la fattorizzazione QR , cioè unitaria per triangolare superiore.

Definizione Matrice elementare di Householder

Sia $v \in \mathbb{C}^n$ con $v \neq 0$. La *matrice elementare di Householder* è definita come

$$H_v = I - \frac{2}{\|v\|_2^2} vv^*$$

e definiamo $H_0 = I_n$.

È una correzione di rango 1 dell'identità.

Proposition

Per ogni $v \in \mathbb{C}^n$, la matrice H_v

1. è Hermitiana;
2. è unitaria;
3. $H_{\alpha v} = H_v$ per ogni $\alpha \neq 0$;

Proof

1. L'identità è Hermitiana, quindi H_0 è Hermitiana. Negli altri casi abbiamo

$$\begin{aligned} H_v^* &= \left(I - \frac{2}{\|v\|_2^2} vv^* \right)^* \\ &= I^* - \frac{2}{\|v\|_2^2} (vv^*)^* \\ &= I - \frac{2}{\|v\|_2^2} vv^* \end{aligned}$$

2. L'identità è unitaria, quindi H_0 è unitaria. Negli altri casi abbiamo

$$H_v^* H_v = H_v^2 = I - \frac{4}{\|v\|_2^2} vv^* + \frac{4}{\|v\|_2^4} vv^* vv^* = I$$

siccome $v^* v = \|v\|_2^2$.

3. Se $v = 0$ allora la proposizione è banale. Sia $v \neq 0$. Abbiamo

$$\begin{aligned} H_{\alpha v} &= I - \frac{2}{\|\alpha v\|_2^2} (\alpha v)(\alpha v)^* \\ &= I - \frac{2\alpha\bar{\alpha}}{|\alpha|^2 \|v\|_2^2} vv^* = H_v \end{aligned}$$

Siccome è una matrice Hermitiana e unitaria, quindi ha autovalori reali di modulo 1. Inoltre, per $v \neq 0$, è elementare quindi ha 1 con molteplicità $n - 1$ e -1 con molteplicità 1. È diagonalizzabile quindi non

distinguo il tipo di molteplicità. D'altro canto,

$$(H_v)v = v - \frac{2}{\|v\|_2^2}vv^*v = -v$$

quindi $H_v w = w$ per $w \in v^\perp$. Consideriamo $x \in \mathbb{C}^n$, possiamo decomporre lo spazio nella direzione dello v e nella sua componente ortogonale. Abbiamo quindi

$$\text{span}(v) \oplus v^\perp = \mathbb{C}^n$$

e quindi scriviamo $x = \alpha v + w$. Quindi l'applicazione è

$$H_v x = H_v(\alpha v + w) = \alpha H_v v + H_v w = w - \alpha v$$

Quindi applicare H_v ad x è come riflettere x rispetto all'iperpiano $v^\perp$.

Teorema

Per ogni $x \in \mathbb{C}^n$, esistono $v \in \mathbb{C}^n$ e $\alpha \in \mathbb{C}$ tale che $H_v x = \alpha e_1$.

Proof

Se $x = \beta e_1$ allora $H_v = I$ e $\alpha = \beta$ con $v = 0$, che è il caso banale. Altrimenti (in particolare $x \neq 0$), osserviamo che $\|x\|_2 = |\alpha|$ in quanto le matrici unitarie conservano la norma (se la dimostrazione va a buon fine). Allora possiamo scrivere $\alpha = |\alpha|e^{i\psi} = \|x\|_2 e^{i\psi}$. Dobbiamo trovare l'angolo. Siccome $H_v x = \alpha e_1$, dobbiamo usare proprio quella x . Siccome H_v è Hermitiana e $y^* H y \in \mathbb{R}$ per tutte le $y \in \mathbb{C}^n$, allora $x^* H_v x = x^* \alpha e_1 = \alpha \bar{x}_1$. Quindi, se scriviamo $x_1 = |x_1|e^{i\theta}$ (scegliendo $\theta = 0$ se $x_1 = 0$), allora

$$\alpha \bar{x}_1 = \|x\|_2 |x_1| e^{i(\psi - \theta)}$$

Dunque, se $x_1 \neq 0$, $\psi = \theta$ oppure $\psi = \theta + \pi$, modulo 2π . Abbiamo quindi due possibili soluzioni $\alpha = \pm \|x\|_2 e^{i\theta}$. Avendo informazioni su α , imponiamo $H_v x = \alpha e_1$. Usando la definizione

$$\begin{aligned} H_v x &= \alpha e_1 \\ \left(I - \frac{2}{\|v\|_2^2} v v^* \right) x &= \alpha e_1 \\ x - \frac{2v^* x}{\|v\|_2^2} v &= \alpha e_1 \\ \frac{2v^* x}{\|v\|_2^2} v &= x - \alpha e_1 \\ v &= x - \alpha e_1 \end{aligned}$$

dove abbiamo usato il fatto che $H_{\beta v} = H_v$ per $\beta \neq 0$, che funziona a patto che $v^* x \neq 0$. La condizione ci impone che

$$\begin{aligned} x^* v &= x^* (x - \alpha e_1) \\ &= \|x\|_2^2 - \alpha \bar{x}_1 \\ &= \|x\|_2^2 - (\pm \|x\|_2 |x_1| e^{i\theta} e^{-i\theta}) \\ &= \|x\|_2^2 \mp \|x\|_2 |x_1| \end{aligned}$$

abbiamo scritto $x^* v$ al posto di $v^* x$: sono coniugati e, in questo caso, reali. Inoltre $\|v\|_2^2 = 2v^* x$, quindi la scelta verifica effettivamente $H_v x = \alpha e_1$. Scegliendo $\alpha = -\|x\|_2 e^{i\theta}$ siamo sicuri che non si annulli e otteniamo la scelta numericamente più stabile.

Esercizio

Costruire base ortonormale partendo da k vettori linearmente indipendenti. Che serve per la forma normale di Schur. Cioè che contenga lo span di quei primi k vettori e che sia ortonormale.

Teorema Fattorizzazione QR

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. Allora $\exists Q$ matrice unitaria e $\exists R$ matrice triangolare superiore tale che

$$A = QR$$

Proof Fattorizzazione QR

Partiamo dal primo passo considerando H_v tale che $H_v a^{(1)} = \alpha^{(1)} e_1$ dove $a^{(1)}$ è la prima colonna di A . Data quindi $A^{(1)} = A$ possiamo costruire

$$A^{(2)} = H_v^{(1)} A^{(1)} = \left(\begin{array}{c|ccc} \alpha^{(1)} & * & \dots & * \\ 0 & & & \\ \vdots & & \hat{A}^{(2)} & \\ 0 & & & \end{array} \right)$$

Il secondo passo è quindi quello di definire

$$A^{(3)} = \left(\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ 0 & & & \\ \vdots & & H_v^{(2)} & \\ 0 & & & \end{array} \right) A^{(2)}$$

e continuando in generale otteniamo

$$A^{(k)} = \underbrace{\left(\begin{array}{c|ccc} I_{k-2} & & 0 & \\ 0 & & H_v^{(k-1)} & \end{array} \right)}_{\hat{H}^{(k-1)}} A^{(k-1)}$$

Continuiamo fino all'iterazione $k = n$, ottenendo quindi $A^{(n)} = R$ che è nella forma triangolare superiore

$$R = A^{(n)} = \hat{H}^{(n-1)} \hat{H}^{(n-2)} \dots \hat{H}^{(1)} A$$

In generale

$$\hat{H}^{(j)} = I_{j-1} \oplus H^{(j)}$$

Il primo blocco è quindi la matrice unitaria e il secondo una matrice di Householder. Essendo l'insieme delle matrici unitarie un gruppo moltiplicativo, P è unitaria. Quindi $R = PA$ con

$$P = \hat{H}^{(n-1)} \hat{H}^{(n-2)} \dots \hat{H}^{(1)}$$

che è unitaria in quanto prodotto di unitarie. Infine, possiamo scrivere $A = QR$ con $Q = P^*$, che è unitaria.

Proposition

La complessità dell'algoritmo di fattorizzazione QR è $\frac{4}{3}n^3 + \mathcal{O}(n^2)$ operazioni aritmetiche, quindi $\mathcal{O}(n^3)$.

Proof

La matrice $H_v = I + xy^*$ viene scritta come diade dove

$$x = -\frac{2}{\|v\|_2^2}v, \quad y = v$$

Al primo passaggio abbiamo $\hat{H}^{(1)} = H^{(1)}$ e per passare da $A^{(1)}$ ad $A^{(2)}$ abbiamo una matrice la cui prima colonna ha in cima $\alpha^{(1)}$ e sotto zeri, il resto delle colonne sono i vettori s_j

$$\left(\begin{array}{c|c|c|c} \alpha^{(1)} & & & \\ 0 & s_2 & \cdots & s_n \\ \vdots & & & \\ 0 & & & \end{array} \right)$$

quindi la colonna è data da

$$s_j = H^{(1)} \text{col}_j(A^{(1)})$$

per $j \in \{2, \dots, n\}$. Il costo da iterare è quindi quello di una moltiplicazione di un vettore per una matrice di Householder, cioè il costo di $(I + xy^*)c$ per $c \in \mathbb{C}^n$. Sia $\gamma = y^*c$, che è un prodotto scalare, quindi n moltiplicazioni ed $n - 1$ somme (parallelizzabile). Dopodiché $\hat{x} = \gamma x$ costa n moltiplicazioni. Infine $c + \hat{x}$ sono n somme. Abbiamo quindi un costo complessivo di $(n-1)(4n-1)$ operazioni. Considerando tutti i passaggi abbiamo una somma

$$\begin{aligned} \sum_{\tau=2}^n (\tau-1)(4\tau-1) &= \sum_{\tau=2}^n (\tau-1)(4\tau-1) = \sum_{\tau=2}^n (4\tau^2 - 5\tau + 1) \\ &= \sum_{\tau=2}^n 4\tau^2 + \mathcal{O}(n^2) = \frac{4}{3}n^3 + \mathcal{O}(n^2) \end{aligned}$$

2 Metodi iterativi per sistemi lineari

2.1 Splitting matriciali e convergenza

Consideriamo $A \in \text{Mat}_{n \times n}(\mathbb{C})$ invertibile. Abbiamo lo *splitting regolare* (M, N) se $A = M - N$ tale che M è invertibile. Consideriamo quindi il sistema lineare $Ax = b$ con $b \in \mathbb{C}^n$ con un suo splitting regolare. Il sistema è quindi equivalente a $(M - N)x = b$, oppure $Mx = b + Nx$. Siccome M è invertibile, $x = Px + c$ dove $P = M^{-1}N$ e $c = M^{-1}b$. Siccome $x = Px + c$, allora la soluzione è punto fisso di una trasformazione affine $T: \mathbb{C}^n \rightarrow \mathbb{C}^n$ tale che $T(y) = Py + c$. Vogliamo quindi trovare il punto fisso di T . Il metodo iterativo collegato è $x^{(k+1)} = Px^{(k)} + c$ dato un punto iniziale $x^{(0)}$. Quindi, definito $e^{(j)} = x - x^{(j)}$, abbiamo che $e^{(k+1)} = Pe^{(k)}$, e quindi $e^{(k)} = P^k e^{(0)}$. Abbiamo quindi convergenza per ogni punto iniziale se e solo se

$$\lim_{k \rightarrow \infty} P^k = 0$$

Ci serve che il raggio spettrale sia minore di 1.

Definizione Modulo di una matrice

Sia $X \in \text{Mat}_{n \times n}(\mathbb{C})$. Definiamo

$$|X| = (|X_{j,k}|)_{j,k=1}^n$$

Teorema Matrix power convergence

Sia $P \in \text{Mat}_{n \times n}(\mathbb{C})$ e $k \in \mathbb{N}$. Allora,

$$\lim_k P^k = 0$$

se e solo se $\rho(P) < 1$.

Proof

($\Rightarrow$) Sappiamo che

$$\lim_k P^k = 0$$

e consideriamo λ autovalore di P con autovettore associato $x \neq 0$.

1. Da un lato sappiamo che $P^k x = \lambda^k x$;
2. Dall'altro sappiamo che

$$\lim_k (P^k y) = \left(\lim_k P^k \right) y = 0, \quad \forall y \in \mathbb{C}^n$$

Ciò implica che

$$\lim_k \lambda^k x = 0$$

che necessita $|\lambda| < 1$.

($\Leftarrow$) Distinguiamo i due casi:

1. *Caso diagonalizzabile*: Abbiamo $P = TDT^{-1}$ dove D è la matrice diagonale degli autovalori λ_i . Elevando alla k abbiamo quindi

$$P^k = (TDT^{-1})^k = TD^k T^{-1}$$

Quindi, per continuità del prodotto matriciale, abbiamo

$$\lim_k P^k = T \left(\lim_k D^k \right) T^{-1}$$

Ma dalla forma di D , il limite tende a 0 se e solo se $|\lambda_i| < 1$. Ma siccome il raggio spettrale è minore di 1 allora vale.

2. *Caso non diagonalizzabile*: Utilizzando la scomposizione di Schur otteniamo $P = QTQ^*$ con Q unitaria e T triangolare superiore. Abbiamo

$$\lim_k P^k = 0$$

se e soltanto se

$$\lim_k T^k = 0$$

in quanto $P^k = QT^k Q^*$. Notiamo che

$$0_{\text{Mat}_{n \times n}(\mathbb{C})} \leq |T| = \begin{pmatrix} |\lambda_1| & & & * \\ & |\lambda_2| & & \\ & & \ddots & \\ 0 & & & |\lambda_n| \end{pmatrix} \leq \begin{pmatrix} \gamma_1 & & & * \\ & \gamma_2 & & \\ & & \ddots & \\ 0 & & & \gamma_n \end{pmatrix} = \hat{T}$$

Stiamo usando l'ordinamento parziale indotto sulle matrici. Nella forma di Schur, possiamo permutare gli elementi della diagonale come vogliamo, quindi scegliamo di ordinarli in modo crescente:

$$|\lambda_1| \leq |\lambda_2| \leq \dots \leq |\lambda_n|$$

L'idea è la seguente: affinché $\hat{T}$ sia sicuramente diagonalizzabile, vogliamo che i suoi elementi diagonali γ_i siano a due a due distinti. Ogni qualvolta troviamo dei termini in $|T|$ che coincidono, aggiungiamo un valore ad uno tale da non fargli superare il successivo nella catena. Ad esempio, se abbiamo un blocco di autovalori con lo stesso modulo:

$$|\lambda_j| = |\lambda_{j+1}| = \dots = |\lambda_q| < |\lambda_{q+1}|$$

poniamo $\varepsilon = |\lambda_{q+1}| - |\lambda_j|$ e definiamo i nuovi valori aggiungendo incrementi successivi di $\frac{\varepsilon}{N}$ (con N opportunamente grande):

$$\gamma_j = |\lambda_j|, \quad \gamma_{j+1} = |\lambda_j| + \frac{\varepsilon}{N}, \quad \gamma_{j+2} = |\lambda_j| + \frac{2\varepsilon}{N}, \dots$$

facendo attenzione a restare strettamente minori del valore distinto successivo. Imponiamo infine che l'ultimo termine $\gamma_n < 1$ (il che è possibile poiché $\rho(P) < 1$), in maniera tale da avere tutti numeri non negativi, a due a due distinti, e tutti minori di 1.

Notiamo che $|T^k| \leq |T|^k$ per espansione del prodotto e applicando la disuguaglianza triangolare. Passando all'esponente per k , abbiamo la seguente catena:

$$0_{\text{Mat}_{n \times n}(\mathbb{C})} \leq |T^k| \leq |T|^k \leq \hat{T}^k$$

Ma siccome $\hat{T}$ ha autovalori tutti distinti è diagonalizzabile, e avendo $\rho(\hat{T}) < 1$, per il caso precedente il suo limite tende a zero. Per il teorema del confronto, il limite della catena collassa a 0, implicando $\lim_k |T^k| = 0$, e dunque $\lim_k P^k = 0$.

Negli spazi finiti dimensionali, tutte le norme sono equivalenti e quindi il risultato non dipende dalla norma. Invece, in uno spazio infinito dimensionale va specificato, in quanto qualcosa può contrarsi rispetto ad una metrica ma non rispetto ad un'altra.

Teorema Teorema di equivalenza delle norme in $\mathbb{C}^n$

todo

Il raggio spettrale è un invariante che ha a che fare con le norme.

Teorema

Sia $\mathcal{N}$ l'insieme delle norme su $\text{Mat}_{n \times n}(\mathbb{C})$ indotte. Allora, $\forall P \in \text{Mat}_{n \times n}(\mathbb{C})$, vale

$$\rho(P) = \inf_{\|\cdot\| \in \mathcal{N}} \|P\|$$

Utilizziamo quindi questo per il teorema delle contrazioni di Banach.

Definizione Metodo iterativo stabile

Metodo iterativo matriciale si dice *stabile* se $\rho(P) < 1$.

Definizione Metodo iterativo consistente

Metodo iterativo matriciale si dice *consistente* se la soluzione esatta è un punto fisso della mappa $\mathbb{C}^n \rightarrow \mathbb{C}^n$ data da $y \rightarrow Py + q$.

Questo ci dà in parte l'arbitrarietà del punto iniziale.

Teorema

Un metodo iterativo è convergente se e solo se è stabile e consistente.

2.2 Splitting classici e metodi di punto fisso

Dato un sistema $Ax = b$, possiamo scrivere $A = M - N$ dove M è non singolare. Allora,

$$\begin{aligned}(M - N)x &= b \\ Mx - Nx &= b \\ Mx &= Nx + b \\ x &= \underbrace{M^{-1}N}_p x + \underbrace{M^{-1}b}_q\end{aligned}$$

L'altra decomposizione classica è $A = D - B - C$ dove $D = \text{diag}(A)$, B è triangolare inferiore con diagonale nulla e C è triangolare superiore con diagonale nulla.

2.3 Metodo di Jacobi

Definizione Metodo di Jacobi

Sia $M = D$ e $N = B + C$ nella composizione a tre fattori. La matrice di iterazione è definita come

$$J = D^{-1}(B + C)$$

quindi

$$x^{(k+1)} = Jx^{(k)} + \underbrace{D^{-1}b}_q$$

Nel metodo di Jacobi $\det M \neq 0$ se e solo se tutti gli elementi principali di A sono non-nulli.

Il metodo di Jacobi è consistente per costruzione. È stabile se e solo se la matrice di iterazione ha raggio spettrale minore di 1. In forma

$$x_i^{(k+1)} = \frac{1}{a_{i,i}} \left[b_i - \sum_{\substack{j=1 \\ i \neq j}}^n a_{i,j} x_j^{(k)} \right]$$

Teorema

Sia $A = D - B - C$ la decomposizione a tre fattori di A . Se vale almeno una delle seguenti ipotesi:

1. A è a predominanza diagonale forte per righe;
2. A è a predominanza diagonale debole per righe, con almeno una riga stretta, e A è irriducibile;
3. A è a predominanza diagonale forte per colonne;
4. A è a predominanza diagonale debole per colonne, con almeno una colonna stretta, e A è irriducibile;

Allora, $\rho(P) < 1$ e quindi il metodo di Jacobi è convergente.

Proof

Dimostriamo la (3). A è invertibile per i teoremi di Gershgorin e gli elementi diagonali sono non-nulli, altrimenti non sarebbe né invertibile né a predominanza diagonale. La consistenza è data dalla definizione. Dobbiamo solamente mostrare che $\rho(J) < 1$. Mostriamo infatti che per ogni autovalore $\lambda \in \sigma(J)$ abbiamo $|\lambda| < 1$. Supponiamo per assurdo che esista $\exists \nu$ tale che $|\nu| \geq 1$. Allora deve soddisfare il polinomio caratteristico

$$\begin{aligned}
 0 &= \det(J - \nu I_n) \\
 &= \det(D^{-1}(B + C) - \nu I_n) \\
 &= \det(D^{-1}(B + C) - \nu D^{-1}D) \\
 &= \underbrace{\det(D^{-1})}_{\neq 0} \cdot \det(B + C - \nu D) \quad \left. \vphantom{\det(D^{-1})} \right\} \text{Teorema di Binet} \\
 \implies 0 &= \det(\underbrace{B + C - \nu D}_H)
 \end{aligned}$$

Di questa matrice H possiamo dire che

$$|h_{i,j}| = \begin{cases} |\nu a_{i,i}| & i = j \\ |a_{i,j}| & i \neq j \end{cases}$$

Poiché $|\nu| \geq 1$ e H è a predominanza diagonale forte per colonne, quindi è anche invertibile. Ma questo è assurdo.

Proof Alternativa

Partiamo da

$$J = D^{-1}(B + C) = - \begin{bmatrix} \frac{1}{a_{11}} & 0 & \cdots & 0 \\ 0 & \frac{1}{a_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{a_{nn}} \end{bmatrix} \cdot \begin{bmatrix} 0 & * & \cdots & * \\ * & 0 & \cdots & * \\ \vdots & \vdots & \ddots & \vdots \\ * & * & \cdots & 0 \end{bmatrix} = - \begin{bmatrix} 0 & \frac{*}{a_{11}} & \cdots & \frac{*}{a_{11}} \\ \frac{*}{a_{22}} & 0 & \cdots & \frac{*}{a_{22}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{*}{a_{nn}} & \frac{*}{a_{nn}} & \cdots & 0 \end{bmatrix}$$

I cerchi di Gershgorin sono centrati nell'origine e sono concentrici con raggi

$$r_i = \frac{\sum_{j=1, j \neq i}^n |a_{i,j}|}{|a_{i,i}|} \leq 1$$

con disuguaglianze tutte strette nel caso di predominanza diagonale forte. Nel caso debole, il terzo teorema di Gershgorin esclude autovalori di modulo uno, siccome A è a predominanza diagonale stretta oppure A è a predominanza diagonale debole ed è irriducibile.

È un metodo altamente parallelizzabile.

2.4 Metodo di Gauss-Seidel

Definizione Metodo di Gauss-Seidel

Sia $M = D - B$ e $N = C$ nella composizione a tre fattori. La matrice di iterazione è definita come

$$G = (D - B)^{-1}C$$

quindi

$$x^{(k+1)} = Gx^{(k)} + (D - B)^{-1}b$$

L'iterazione ha forma

$$\begin{aligned} x^{(k+1)} &= Gx^{(k)} + (D - B)^{-1}b \\ Dx^{(k+1)} - Bx^{(k+1)} &= Cx^{(k)} + b \\ x^{(k+1)} &= D^{-1}Bx^{(k+1)} + D^{-1}Cx^{(k)} + D^{-1}b \\ x_i^{(k+1)} &= \frac{1}{a_{i,i}} \left[b_i - \sum_{j=1}^{i-1} a_{i,j}x_j^{(k+1)} - \sum_{j=i+1}^n a_{i,j}x_j^{(k)} \right] \end{aligned}$$

Jacobi è chiamato il metodo degli elementi simultanei, mentre Gauss-Seidel il metodo degli elementi successivi.

Teorema

Sia $A = D - B - C$ la decomposizione di A per tre fattori. Se vale una delle seguenti ipotesi:

1. A è a predominanza diagonale forte per righe;
2. A è a predominanza diagonale debole per righe, con almeno una riga stretta, e A è irriducibile;
3. A è a predominanza diagonale forte per colonne;
4. A è a predominanza diagonale debole per colonne, con almeno una colonna stretta, e A è irriducibile;

Allora, $\rho(P) < 1$ e quindi il metodo di Gauss-Seidel è convergente.

Proof

A è invertibile per i teoremi di Gershgorin e gli elementi diagonali sono non-nulli, altrimenti non sarebbe né invertibile né a predominanza diagonale. La consistenza è data dalla definizione. Dobbiamo solamente mostrare che $\rho(G) < 1$. Supponiamo per assurdo che esista $\exists \nu$ tale che $|\nu| \geq 1$. Allora deve soddisfare il polinomio caratteristico

$$\begin{aligned} 0 &= \det(G - \nu I_n) \\ &= \det((D - B)^{-1}C - \nu I_n) \\ &= \det((D - B)^{-1}C - \nu(D - B)^{-1}(D - B)) \\ &= \underbrace{\det((D - B)^{-1})}_{\neq 0} \cdot \det(C - \nu(D - B)) \quad \left. \vphantom{\det((D - B)^{-1})} \right\} \text{Teorema di Binet} \\ \implies 0 &= \det(\underbrace{C - \nu(D - B)}_H) \\ |h_{i,j}| &= \begin{cases} |\nu a_{i,j}| & i \geq j \\ |a_{i,j}| & i < j \end{cases} \end{aligned}$$

Poiché $|\nu| \geq 1$, per ogni colonna j abbiamo

$$\begin{aligned} |h_{j,j}| &= |\nu| |a_{j,j}| \geq |\nu| \sum_{i \neq j} |a_{i,j}| \\ &\geq \sum_{i < j} |a_{i,j}| + |\nu| \sum_{i > j} |a_{i,j}| = \sum_{i \neq j} |h_{i,j}|. \end{aligned}$$

Quindi H è a predominanza diagonale per colonne. Nel caso forte tutte le disuguaglianze sono strette; nel caso debole H è irriducibile (come A). Sempre per il fatto che A è a predominanza diagonale per colonne, $\exists i_0 \in \{1, \dots, n\}$ tale che

$$|a_{i_0, i_0}| > \sum_{\substack{j=1 \\ j \neq i_0}}^n |a_{j, i_0}|$$

e per questo indice la maggiorazione precedente vale in senso stretto. Ma quindi la matrice H è invertibile, che è assurdo.

2.5 Esempi e confronto qualitativo fra Jacobi e Gauss-Seidel

Esempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} 3 & 0 & 4 \\ 7 & 4 & 2 \\ -1 & -1 & -2 \end{pmatrix}, \quad b = (7 \quad 13 \quad -4)^T$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & 0 & -\frac{4}{3} \\ -\frac{7}{3} & 0 & -\frac{1}{2} \\ -\frac{1}{2} & -\frac{1}{2} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & 0 & -\frac{4}{3} \\ 0 & 0 & \frac{11}{6} \\ 0 & 0 & -\frac{1}{4} \end{pmatrix}$$

Il raggio spettrale di J è circa $1,337 > 1$ quindi il metodo non converge, mentre $\rho(G) = \frac{1}{4} < 1$ quindi è convergente.

Esempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} -3 & 3 & -6 \\ -4 & 7 & -8 \\ 5 & 7 & -9 \end{pmatrix}, \quad b = (-6 \quad -5 \quad 3)^T$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & 1 & -2 \\ \frac{4}{3} & 0 & \frac{8}{7} \\ \frac{5}{9} & \frac{7}{9} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & 1 & -2 \\ 0 & \frac{4}{7} & 0 \\ 0 & 1 & -\frac{10}{9} \end{pmatrix}$$

Abbiamo i raggi spettrali $\rho(J) = 0.81 < 1$ e $\rho(G) = 1.11 > 1$, quindi quello di Jacobi converge mentre quello di Gauss-Seidel no.

Esempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} 4 & 1 & 1 \\ 2 & -9 & 0 \\ 0 & -8 & -6 \end{pmatrix}, \quad b = (6 \quad -7 \quad -14)^T$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & -\frac{1}{4} & -\frac{1}{4} \\ \frac{2}{9} & 0 & 0 \\ 0 & -\frac{4}{3} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & -\frac{1}{4} & -\frac{1}{4} \\ 0 & -\frac{1}{18} & -\frac{1}{18} \\ 0 & \frac{2}{27} & \frac{2}{27} \end{pmatrix}$$

Abbiamo i raggi spettrali $\rho(J) = 0.44 < 1$ e $\rho(G) = 0.018 < 1$, quindi entrambi convergono ma quello di Gauss-Seidel è più veloce.

Per le matrici a predominanza diagonale stretta, vale in generale che sulla matrice di Gauss-Seidel e Jacobi

$$\|G\|_\infty \leq \|J\|_\infty < 1$$

Tuttavia, anche se $\rho(G) \leq \|G\|_\infty$ e $\rho(J) \leq \|J\|_\infty$, non sempre ne consegue che $\rho(G) \leq \rho(J)$, cioè non sempre il metodo di Gauss-Seidel è asintoticamente più veloce rispetto a quello di Jacobi.

Esempio Controesempio

Consideriamo il sistema lineare

$$A = \begin{pmatrix} 11 & -5 & -5 \\ 5 & 12 & 6 \\ 6 & -4 & 11 \end{pmatrix}, \quad b = (1 \quad 23 \quad 13)^T$$

Abbiamo quindi la matrice di iterazione di Jacobi e Gauss-Seidel

$$J = \begin{pmatrix} 0 & \frac{5}{11} & \frac{5}{11} \\ -\frac{5}{12} & 0 & -\frac{1}{2} \\ -\frac{6}{11} & \frac{4}{11} & 0 \end{pmatrix}, \quad G = \begin{pmatrix} 0 & \frac{5}{11} & \frac{5}{11} \\ 0 & -\frac{25}{132} & -\frac{91}{132} \\ 0 & -\frac{115}{363} & -\frac{181}{363} \end{pmatrix}$$

Abbiamo i raggi spettrali $\rho(J) = 0.79$ e $\rho(G) = 0.83$, e norme $\|J\|_\infty = 0.916$ e $\|G\|_\infty = 0.909$.

3 Localizzazione spettrale e applicazioni alla convergenza

3.1 Teoremi di Gershgorin

Definizione Cerchi di Gershgorin

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$, allora i cerchi di Gershgorin sono i cerchi complessi

$$C_j = \{z \in \mathbb{C} \mid |z - A_{j,j}| \leq r_j\}, \quad r_j = \sum_{\substack{k=1 \\ k \neq j}}^n |A_{j,k}|$$

Teorema Teorema di Gershgorin I

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$, λ autovalore di A . Allora,

$$\lambda \in \bigcup_{j=1}^n C_j$$

Teorema Teorema di Gershgorin II

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$ e siano $s_1, \dots, s_t$, I_i insiemi di indici dove

$$s_i \triangleq \bigcup_{u \in I_i} C_u$$

tali che

1. $s_l \cap s_m = \emptyset$ per $l, m \in \{1, \dots, t\}$ con $l \neq m$;
2. $\bigcup_i I_i = \{1, \dots, n\}$ e $I_l \cap I_m = \emptyset$ per $l \neq m$.

Chiamiamo $k_l = |I_l|$. Allora, s_i contiene esattamente k_i autovalori, contati con molteplicità algebrica.

Proof Teorema di Gershgorin I

Consideriamo la relazione

$$\sum_{k=1}^n A_{j,k} x_k = \lambda x_j$$

dove scegliamo j come indice p tale che $|x_p| = \|x\|_\infty > 0$, cioè vogliamo massimizzare la parte destra. Riscriviamo questa relazione per l'indice p ma isolando questo termine,

$$\begin{aligned} |\lambda x_p - A_{p,p} x_p| &= \sum_{\substack{k=1 \\ k \neq p}}^n A_{p,k} x_k \\ |(\lambda - A_{p,p}) x_p| &= \left| \sum_{\substack{k=1 \\ k \neq p}}^n A_{p,k} x_k \right| \\ |\lambda - A_{p,p}| \cdot |x_p| &\leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| \\ |\lambda - A_{p,p}| &\leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \frac{|x_k|}{|x_p|} \leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \end{aligned}$$

$|x_k| \leq |x_p|$

Quindi, l'autovalore sta nell'unione di tutti i cerchi, in quanto non so in quale cerchio sta

$$\lambda \in \bigcup_{j=1}^n C_j$$

Proof Teorema di Gershgorin II

Scriviamo $A_n = D + R$ dove D è la diagonale di A e R il resto. Sia $t \in [0, 1]$ e $A_n(t) : [0, 1] \rightarrow M_n(\mathbb{C})$ definita da

$$A_n(t) = D + tR$$

Abbiamo quindi che $A_n(0) = D$ e $A_n(1) = A_n$. Definiamo i cerchi

$$C_j(t) = \{z \in \mathbb{C} \mid |A_{j,j} - z| \leq tr_j\}$$

Per il polinomio caratteristico, ogni coefficiente del polinomio è una funzione continua in t siccome le entrate lo sono. Quindi gli autovalori dipendono continuamente dai coefficienti. Quindi siccome $A_{j,k}(t)$ è una funzione lineare affine in t , allora

$$\det(A_n(t) - \lambda I) = (-1)^n \lambda^n + \alpha_{n-1}(t) \lambda^{n-1} + \dots + \alpha_1(t) \lambda + \alpha_0(t)$$

Per Gershgorin I, gli autovalori restano in $\bigcup_j C_j(t) \subseteq \bigcup_j C_j(1)$. Poiché i gruppi s_i sono disgiunti e compatti, un autovalore non può passare da un gruppo all'altro lungo una traiettoria continua. Per $t = 0$, in s_i ci sono precisamente $|I_i|$ elementi diagonali, contati con molteplicità. Il loro numero rimane quindi lo stesso per $t = 1$.

Se tutti i cerchi di Gershgorin sono a due a due disgiunti, ciascuno contiene un solo autovalore, che è quindi semplice. Ma se per esempio la matrice evolve in maniera continua, e due cerchi si toccano, allora entrambi gli autovalori di quei due cerchi possono spostarsi entrambi in uno dei due cerchi; resta vincolato il loro numero totale nella componente isolata.



Esempio Teorema di Gershgorin I

Consideriamo la matrice

$$\begin{pmatrix} 10 & 1 & 3 & 3 \\ -1 & 4 & 0 & 1 \\ i & i & 4 & i \\ i+1 & 0 & 0 & 3i \end{pmatrix}$$

Abbiamo i seguenti cerchi di Gershgorin


$$C_1 = \{z \in \mathbb{C} \mid |z - 10| \leq 7\}$$

$$C_2 = \{z \in \mathbb{C} \mid |z - 4| \leq 2\}$$

$$C_3 = \{z \in \mathbb{C} \mid |z - 4| \leq 3\}$$

$$C_4 = \{z \in \mathbb{C} \mid |z - 3i| \leq \sqrt{2}\}$$

Possiamo notare che sicuramente il determinante della matrice non è nullo.



Definizione Grafo fortemente connesso

todo

3.2 Irriducibilità e grafi associati

Definizione Matrice irriducibile

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$. Si dice che A è *irriducibile* se G_A è fortemente connesso dove G_A è il grafo (N, E) con $N = \{1, \dots, n\}$ dove $(j, k) \in E$ se e solo se $A_{j,k} \neq 0$.




Esempio Teorema di Gershgorin II e III

Consideriamo la matrice

$$A = \begin{pmatrix} -10 & 1 & & & & \\ 1 & -10 & 1 & & & 0 \\ & 1 & -10 & 1 & & \\ & & 1 & -10 & 1 & \\ 0 & & & 1 & -10 & 1 \\ & & & & -1 & 77 \end{pmatrix}$$


Mostrare che esiste un autovalore λ di questa matrice tale che $\lambda = \rho(A)$.

Abbiamo i cerchi



$$\begin{aligned} C_1 &= \{z \in \mathbb{C} \mid |z + 10| \leq 1\} \\ C_2 = C_3 = C_4 = C_5 &= \{z \in \mathbb{C} \mid |z + 10| \leq 2\} \\ C_6 &= \{z \in \mathbb{C} \mid |z - 77| \leq 1\} \end{aligned}$$

C'è quindi un singolo autovalore in C_6 , ma quest'ultimo non può essere propriamente complesso in quanto ci sarebbe un altro autovalore coniugato nello stesso cerchio. Quindi quell'autovalore è reale e coincide con il raggio spettrale, data la sua distanza dall'origine. Il suo grafo associato è fortemente connesso:



Teorema Teorema di Gershgorin III

Sia $A \in \text{Mat}_{n \times n}(\mathbb{C})$, A irriducibile e tale che l'autovalore λ sta sul bordo dell'unione dei cerchi

$$\lambda \in \partial \left(\bigcup_{j=1}^n C_j \right)$$

Allora λ sta sul bordo di tutti i cerchi $\lambda \in \partial C_j, \forall j \in \{1, \dots, n\}$.

Non si verifica quasi mai l'ipotesi, quindi conviene usare la contronominale.

Proof Teorema di Gershgorin III

Sia λ un autovalore e sia x un suo autovettore. Consideriamo la relazione

$$\sum_{k=1}^n A_{j,k} x_k = \lambda x_j$$

dove scegliamo j come indice p tale che $|x_p| = \|x\|_\infty > 0$, cioè vogliamo massimizzare la parte destra.

$$|\lambda x_p - A_{p,p} x_p| \leq \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| \leq |x_p| \cdot r_p$$

$$|\lambda x_p - A_{p,p} x_p| = \sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| = |x_p| \cdot r_p$$

Ma per l'ipotesi l'autovalore sta sul bordo, quindi r_p è precisamente il raggio del cerchio. Scelgo $u = p$ e guardiamo con attenzione alla relazione

$$\sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \cdot |x_k| = \left(\sum_{\substack{k=1 \\ k \neq p}}^n |A_{p,k}| \right) |x_p|$$

Visto che è irriducibile, almeno un termine $i_2 \neq p$ esiste tale che $A_{p,i_2} \neq 0$. Abbiamo quindi necessariamente che $|x_{i_2}| = |x_p|$. Ma allora, tornando a Gershgorin I, avremmo potuto seguire la medesima dimostrazione su $i_2 \neq p$ al posto di p . Quindi, $\lambda \in C_{i_2}$, e per ipotesi λ sta quindi in ∂C_{i_2} . Propagando questo argomento lungo i cammini del grafo, la forte connessione permette di raggiungere tutti i nodi e ottenere la tesi.

Esempio Teorema di Gershgorin III

Consideriamo la matrice

$$A = \begin{pmatrix} 0 & 1 & & & 0 \\ & 0 & 1 & & 0 \\ & & \ddots & \ddots & \\ & & & \ddots & \ddots \\ 0 & & & & 0 & 1 \\ 1 & & & & 0 & 0 \end{pmatrix}$$


Ha autovalori pari a

$$\lambda_j = e^{i \frac{2\pi j}{n}}$$

e autovettori relativi

$$v^{(j)} = \left(\frac{1}{\sqrt{n}} e^{i \frac{2\pi j}{n} k} \right)_{k=1}^n$$

Il suo grafo associato è fortemente connesso:



Esempio Teorema di Gershgorin III

Consideriamo la matrice

$$A = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & \ddots & \ddots & \ddots \\ 0 & & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix}$$

che discretizza l'equazione differenziale

$$\begin{cases} -u''(x) = f(x), & x \in (0, 1) \\ u(0) = \alpha \\ u(1) = \beta \end{cases}$$


con $A_n u = v$. Cominciamo notando che A_n è simmetrica, reale quindi Hermitiana, allora i suoi autovalori sono reali. Abbiamo i cerchi

$$C_1 = C_n = \{z \in \mathbb{C} \mid |z - 2| \leq 1\}$$

$$C_2 = C_3 = \dots = C_{n-1} = \{z \in \mathbb{C} \mid |z - 2| \leq 2\}$$

Dai teoremi di Gershgorin, siccome gli autovalori sono reali, sappiamo quindi che $\lambda \in [0, 4]$. La matrice associata è irriducibile in quanto tridiagonale con sottodiagonale e sopradiagonale non nulle. Tuttavia, $0, 4 \notin \partial C_1$, mentre

$$0, 4 \in \partial \left(\bigcup_{j=2}^n C_j \right)$$



dunque $\lambda \in (0, 4)$. Sappiamo che se $B = B^*$, allora

$$\lambda_{\min}(B) = \min_{\substack{x \in \mathbb{C}^n \\ x \neq 0}} \frac{x^* B x}{x^* x}$$

Ci aspettiamo che r_n sia piccolo con e il vettore di 1

$$A_n e = (1 \quad 0 \quad \dots \quad 0 \quad 1)^T$$

e il quoziente di Rayleigh $r_n = 2/n \rightarrow 0$ per $n \rightarrow \infty$. Se scegliessimo il vettore con elementi che si alternano 1, -1, abbiamo la massima oscillazione fra componenti adiacenti. I coefficienti oscillano, il vettore oscilla e quindi amplifica l'effetto delle differenze fra componenti adiacenti. In tal caso otteniamo un valore appena inferiore al 4.

Supponiamo che $A \in \text{Mat}_n(\mathbb{C})$ con n grande. Come facciamo a verificare in maniera algoritmica se la matrice è fortemente connessa? Sia G_A il suo grafo associato. Consideriamo X la matrice di adiacenza di G_A . Consideriamo $Y = X^2$, cioè

$$(Y)_{j,k} = \sum_{l=1}^n x_{j,l} x_{l,k}$$

Cioè visto che i termini sono booleani, allora è positivo se esiste un nodo l tale che posso muovermi da j a l e da l a k , quindi muoversi fra j a k in due passi. Quindi il termine $(Y)_{j,k}$ è il numero di modi di

attraversare i due nodi in 2 passi. Possiamo semplificare usando una or iterata

$$(Y)_{j,k} = \bigvee_{l=1}^n x_{j,l} \cdot x_{l,k}$$

In generale, $(X^n)_{j,k}$ ci mostra il numero di cammini di lunghezza n per connettere i nodi j, k . Sia

$$\tilde{X} = I_n \vee \bigvee_{k=1}^{n-1} X^k$$

Qui le potenze sono calcolate con il prodotto booleano. Se tale matrice è tutta piena di 1, significa che X è fortemente connessa. L'identità serve per assicurarci che abbiamo uno sulla diagonale, cioè ogni elemento ha un percorso verso sé stesso, cioè il percorso nullo.

Tuttavia, l'algoritmo più ottimale è quello di fare un attraversamento DFS sul grafo, controllare, e poi un attraversamento DFS sul grafo invertito (che è associato alla matrice trasposta).

3.3 Applicazioni ai metodi iterativi

Esempio Jacobi e Gauss-Seidel su una matrice non a predominanza diagonale

Sia $N > 100$. Per $j = 1, \dots, N-2$ poniamo

$$b_j = 1 - \frac{1}{j+1}, \quad a_j = \frac{1}{2} \left(b_j + \frac{1}{b_j} \right).$$

Allora $b_j > 0$, $b_j \rightarrow 1$, $a_j > 0$ e $a_j \rightarrow 1$. Consideriamo la matrice

$$Q = \begin{pmatrix} a_1 & 1 & \cdots & 1 \\ 1 & a_2 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & a_{N-2} \end{pmatrix}.$$

La matrice Q non è a predominanza diagonale. Vogliamo risolvere il sistema

$$Qx = b, \quad x^* = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}, \quad b = Qx^*.$$

Per il metodo di Jacobi si considera lo splitting

$$M = D = \text{diag}(a_j), \quad N = B + C, \quad N_{ij} = \begin{cases} -1 & \text{se } i \neq j, \\ 0 & \text{se } i = j. \end{cases}$$

Quindi l'iterazione è

$$x_i^{(k+1)} = \frac{1}{a_i} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^{N-2} x_j^{(k)} \right).$$

La matrice di iterazione di Jacobi è

$$J = D^{-1}(B + C), \quad \rho(J) > 10.$$

Dunque Jacobi non converge.

Per Gauss-Seidel si considera invece

$$M = D - B = \text{tril}(Q),$$

e in questo caso la matrice di iterazione G soddisfa

$$\rho(G) < 1.$$

Quindi Gauss-Seidel converge.

3.4 Convergenza, consistenza e stabilità

Teorema Convergenza, consistenza e stabilità

Sia $\mathcal{A}$ un metodo iterativo della forma

$$x^{(k+1)} = Px^{(k)} + q.$$

Allora $\mathcal{A}$ è convergente se e solo se $\mathcal{A}$ è consistente e stabile, cioè se e solo se

$$x^* = Px^* + q \quad \text{e} \quad \rho(P) < 1.$$

Proof

Dimostriamo le due implicazioni separatamente.

($\Rightarrow$) Supponiamo che il metodo sia convergente. Per ipotesi, per ogni dato iniziale $x^{(0)} \in \mathbb{C}^n$, la successione $\{x^{(k)}\}_{k \geq 0}$ converge alla soluzione x^* . Passando al limite nell'iterazione otteniamo

$$x^* = \lim_{k \rightarrow +\infty} x^{(k+1)} = \lim_{k \rightarrow +\infty} (Px^{(k)} + q) = Px^* + q.$$

Dunque il metodo è consistente.

Mostriamo ora che è stabile. Supponiamo per assurdo che non lo sia. Allora

$$\rho(P) \geq 1.$$

Quindi esiste un autovalore $\hat{\lambda} \in \sigma(P)$ tale che

$$|\hat{\lambda}| \geq 1.$$

Sia $\hat{u} \neq 0$ un autovettore relativo a $\hat{\lambda}$, cioè

$$P\hat{u} = \hat{\lambda}\hat{u}.$$

Prendiamo come dato iniziale

$$\hat{x}^{(0)} = x^* - \hat{u}$$

e consideriamo la successione $\{\hat{x}^{(k)}\}_{k \geq 0}$ generata dal metodo. Definiamo

$$\hat{e}^{(k)} = x^* - \hat{x}^{(k)}.$$

Poiché il metodo è consistente,

$$x^* = Px^* + q, \quad \hat{x}^{(k+1)} = P\hat{x}^{(k)} + q.$$

Sottraendo le due identità si ottiene l'equazione dell'errore

$$\hat{e}^{(k+1)} = P\hat{e}^{(k)}.$$

Quindi

$$\hat{e}^{(k)} = P^k \hat{e}^{(0)}.$$

Ma

$$\hat{e}^{(0)} = x^* - \hat{x}^{(0)} = \hat{u}.$$

Essendo $\hat{u}$ autovettore di P , segue che

$$\hat{e}^{(k)} = P^k \hat{u} = \hat{\lambda}^k \hat{u}.$$

In particolare,

$$\|\hat{e}^{(k)}\|_{\infty} = |\hat{\lambda}|^k \|\hat{u}\|_{\infty} \geq \|\hat{u}\|_{\infty} \neq 0.$$

Quindi $\hat{x}^{(k)}$ non converge a x^* , contro l'ipotesi di convergenza del metodo. Ne segue che necessariamente $\rho(P) < 1$.

($\Leftarrow$) Supponiamo ora che il metodo sia consistente e stabile. Vogliamo mostrare che per ogni $x^{(0)} \in \mathbb{C}^n$ la successione $\{x^{(k)}\}_{k \geq 0}$, definita da

$$x^{(k+1)} = Px^{(k)} + q,$$

converge a x^* , soluzione del sistema $Ax = b$.

Per consistenza vale

$$x^* = Px^* + q.$$

Sottraendo questa identità dall'iterazione,

$$x^{(k+1)} - x^* = P(x^{(k)} - x^*).$$

Definendo

$$e^{(k)} = x^* - x^{(k)},$$

otteniamo

$$e^{(k+1)} = Pe^{(k)}.$$

Per induzione,

$$e^{(k)} = P^k e^{(0)}.$$

Poiché il metodo è stabile, $\rho(P) < 1$. Quindi

$$P^k \rightarrow 0 \quad \text{in } \mathbb{C}^{n \times n}.$$

Di conseguenza

$$e^{(k)} = P^k e^{(0)} \rightarrow 0,$$

e dunque

$$x^{(k)} \rightarrow x^*.$$

4 Analisi dell'errore nei metodi iterativi

4.1 Tassi di riduzione dell'errore

Il raggio spettrale $\rho(P)$ fornisce asintoticamente il tasso di riduzione dell'errore. Se

$$\|e^{(k)}\| = \gamma_k \|e^{(k-1)}\|,$$

allora

$$\gamma_k = \frac{\|e^{(k)}\|}{\|e^{(k-1)}\|}.$$

Definizione Tasso di riduzione medio dell'errore

Il *tasso di riduzione medio dell'errore* al passo $k \geq 1$ è (il prodotto telescopico è interpretato tramite il rapporto finale se un errore intermedio è nullo)

$$t_k = \sup_{e^{(0)} \in \mathbb{C}^n \setminus \{0\}} \sqrt[k]{\prod_{j=1}^k \frac{\|e^{(j)}\|}{\|e^{(j-1)}\|}} = \sup_{e^{(0)} \in \mathbb{C}^n \setminus \{0\}} \sqrt[k]{\frac{\|e^{(k)}\|}{\|e^{(0)}\|}}.$$

Teorema

Si ha

$$\lim_{k \rightarrow +\infty} t_k = \rho(P).$$

Proof

Osserviamo innanzitutto che

$$e^{(k)} = P^k e^{(0)}.$$

Quindi

$$t_k^k = \sup_{e^{(0)} \in \mathbb{C}^n \setminus \{0\}} \frac{\|P^k e^{(0)}\|}{\|e^{(0)}\|} = \|P^k\|.$$

Perciò

$$t_k = \sqrt[k]{\|P^k\|}.$$

La conclusione segue dalla formula di Gelfand:

$$\lim_{k \rightarrow +\infty} \sqrt[k]{\|P^k\|} = \rho(P).$$

Per completezza, ricordiamo anche l'idea della stima. Sia $\lambda \in \sigma(P)$ tale che

$$|\lambda| = \rho(P),$$

e sia $u \neq 0$ un autovettore relativo a λ , con $\|u\| = 1$. Prendendo $e^{(0)} = u$, si ha

$$\|e^{(k)}\| = \|P^k u\| = \|\lambda^k u\| = |\lambda|^k.$$

Quindi

$$t_k \geq \sqrt[k]{\frac{\|e^{(k)}\|}{\|u\|}} = |\lambda| = \rho(P).$$

D'altra parte, per ogni $\varepsilon > 0$ esiste una norma matriciale indotta $\|\cdot\|_\varepsilon$ tale che

$$\|P\|_\varepsilon \leq \rho(P) + \varepsilon.$$

Per equivalenza delle norme esiste $C_\varepsilon > 0$, indipendente da k , tale che

$$t_k^k = \|P^k\| \leq C_\varepsilon \|P^k\|_\varepsilon \leq C_\varepsilon (\rho(P) + \varepsilon)^k.$$

Quindi $\limsup_k t_k \leq \rho(P) + \varepsilon$. Facendo tendere ε a zero e usando la minorazione precedente, otteniamo la tesi.

Teorema

Se P è diagonalizzabile, ha un unico autovalore dominante in modulo e l'errore iniziale ha componente non nulla lungo il relativo autovettore, allora

$$\gamma_k = \frac{\|e^{(k)}\|}{\|e^{(k-1)}\|} \rightarrow \rho(P) \quad \text{per } k \rightarrow +\infty.$$

Proposition Osservazione

Se $\rho(P) = \frac{1}{2}$, asintoticamente ci aspettiamo

$$\|e^{(k)}\| \approx \frac{1}{2} \|e^{(k-1)}\|.$$

Proposition Osservazione

Il raggio spettrale $\rho(P)$ determina la velocità di convergenza del metodo iterativo. Se vogliamo q cifre di precisione nella soluzione, dobbiamo imporre

$$\frac{\|e^{(k)}\|}{\|e^{(0)}\|} < 10^{-q}.$$

Usando l'approssimazione asintotica

$$\frac{\|e^{(k)}\|}{\|e^{(0)}\|} \approx \rho(P)^k,$$

richiediamo

$$10^{-q} > \rho(P)^k.$$

Passando al logaritmo in base 10, siccome $0 < \rho(P) < 1$, otteniamo

$$-q > k \log_{10} \rho(P),$$

e quindi

$$k > -\frac{q}{\log_{10} \rho(P)} > 0.$$

Ad esempio, confrontare i casi $\rho(P) = 0.79$ e $\rho(P) = 0.83$: anche una piccola variazione del raggio spettrale può aumentare sensibilmente il numero di iterazioni necessarie.

Il valore t_k è una stima asintotica a priori, ma per usarla bisogna conoscere $\rho(P)$, oppure almeno una sua stima. Un'alternativa è definire criteri d'arresto differenti.

I due criteri più comuni sono:

$$\frac{\|r^{(k)}\|}{\|b\|} < \varepsilon, \quad r^{(k)} = b - Ax^{(k)},$$

dove $r^{(k)}$ è il *residuo* del metodo iterativo al passo k , oppure

$$\frac{\|x^{(k)} - x^{(k-1)}\|}{\|x^{(k)}\|} < \varepsilon.$$

Il secondo criterio è sconsigliato quando il raggio spettrale è troppo vicino a 1.

4.2 Criteri d'arresto

Supponiamo $b \neq 0$. Vogliamo capire cosa succede quando fermiamo il metodo con i criteri precedenti. Definiamo l'*errore relativo* come

$$\frac{\|e^{(k)}\|}{\|x^*\|} = \frac{\|x^* - x^{(k)}\|}{\|x^*\|}.$$

4.2.1 Criterio basato sul residuo

Poiché $Ax^* = b$, si ha

$$\begin{aligned} r^{(k)} &= b - Ax^{(k)} \\ &= Ax^* - Ax^{(k)} \\ &= A(x^* - x^{(k)}) \\ &= Ae^{(k)}. \end{aligned}$$

Quindi

$$e^{(k)} = A^{-1}r^{(k)}.$$

Pertanto

$$\|e^{(k)}\| \leq \|A^{-1}\| \|r^{(k)}\|.$$

Inoltre

$$b = Ax^* \implies \|b\| = \|Ax^*\| \leq \|A\| \|x^*\|.$$

Da cui

$$\frac{1}{\|x^*\|} \leq \frac{\|A\|}{\|b\|}.$$

Allora

$$\begin{aligned} \frac{\|e^{(k)}\|}{\|x^*\|} &\leq \|A^{-1}\| \|r^{(k)}\| \frac{\|A\|}{\|b\|} \\ &= \|A^{-1}\| \|A\| \frac{\|r^{(k)}\|}{\|b\|}. \end{aligned}$$

Se il criterio d'arresto impone

$$\frac{\|r^{(k)}\|}{\|b\|} < \varepsilon,$$

allora

$$\frac{\|e^{(k)}\|}{\|x^*\|} < \text{cond}(A)\varepsilon.$$

Quindi il criterio basato sul residuo controlla bene l'errore relativo quando $\text{cond}(A)$ non è troppo grande.

4.2.2 Criterio basato sulla differenza fra iterati consecutivi

Osserviamo che

$$\begin{aligned} x^{(k)} - x^{(k-1)} &= x^{(k)} - x^* + x^* - x^{(k-1)} \\ &= -e^{(k)} + e^{(k-1)} \\ &= -Pe^{(k-1)} + e^{(k-1)} \\ &= (I - P)e^{(k-1)}. \end{aligned}$$

Poiché $\rho(P) < 1$, la matrice $I - P$ è invertibile. Quindi

$$e^{(k-1)} = (I - P)^{-1} (x^{(k)} - x^{(k-1)}).$$

Di conseguenza,

$$\frac{\|e^{(k-1)}\|}{\|x^{(k)}\|} \leq \|(I - P)^{-1}\| \frac{\|x^{(k)} - x^{(k-1)}\|}{\|x^{(k)}\|}.$$

Se il criterio d'arresto impone

$$\frac{\|x^{(k)} - x^{(k-1)}\|}{\|x^{(k)}\|} < \varepsilon,$$

allora

$$\frac{\|e^{(k-1)}\|}{\|x^{(k)}\|} \leq \|(I - P)^{-1}\| \varepsilon.$$

Questo criterio può essere poco affidabile quando $\rho(P) \approx 1$: se esiste un autovalore di P vicino a 1, la matrice $I - P$ è vicina a essere singolare e quindi $\|(I - P)^{-1}\|$ può essere molto grande. In altre parole, gli iterati consecutivi possono essere molto vicini anche se l'errore rispetto alla soluzione è ancora grande.

4.3 Gauss-Seidel per matrici Hermitiane definite positive

Teorema

Sia A Hermitiana con elementi principali reali positivi, cioè $a_{i,i} > 0$. Allora, l'iterazione di Gauss-Seidel è convergente se e solo se A è definita positiva.

Proof

Decomponiamo la matrice come $A = D - B - C = D - B - B^H$ siccome è Hermitiana. Allora la matrice di iterazione è

$$\begin{aligned} G &= (D - B)^{-1}C = (D - B)^{-1}B^H \\ &= (D - B)^{-1}(D - B - A) = I - (D - B)^{-1}A \end{aligned}$$

La formula $G = I - (D - B)^{-1}A$ mostra che, se A è singolare, 1 è autovalore di G : il metodo non converge e A non è definita positiva. Possiamo dunque supporre A non singolare. Prima di concludere, mostriamo che la matrice $Z \triangleq A - G^H A G$ è definita positiva. Poniamo $F \triangleq (D - B)^{-1}A$. Data l'uguaglianza precedente $G = I - F$. In particolare,

$$\begin{aligned} Z &= A - G^H A G = A - (I - F)^H A (I - F) \\ &= \cancel{A} - \cancel{A} + F^H A + A F - F^H A F = F^H (A + F^{-H} A F - A F) \\ &= F^H (A F^{-1} + F^{-H} A - A) F \\ &= F^H (\cancel{A A^{-1}} (D - B) + (D - B)^H \cancel{A^{-H} A} - A) F \\ &= F^H (D - B + D - B^H - A) F = F^H (D + A - A) F = F^H D F \end{aligned}$$

F è non singolare perché $(D - B)^{-1}$ e A non lo sono nemmeno. Inoltre, siccome A ha elementi principali positivi, D a sua volta ha elementi reali positivi, quindi $\forall x \in \mathbb{C}^n \setminus \{0\}$

$$\begin{aligned} x^H Z x &= x^H (A - G^H A G) x = x^H F^H D F x \\ &= y^H D y = \sum_{i=1}^n A_{i,i} \underbrace{|y_i|^2}_{\geq 0} > 0 \end{aligned} \quad \left. \vphantom{\sum_{i=1}^n} \right\} y = Fx$$

Concludiamo ora il teorema:

($\Leftarrow$) Supponiamo che A sia definita positiva. Consideriamo un autovalore $\lambda \in \sigma(G)$ e x autovettore corrispondente, quindi $Gx = \lambda x$. Siccome A è definita positiva,

$$\begin{aligned} x^H Z x &= x^H (A - G^H A G) x = x^H A x - x^H G^H A G x \\ &= x^H A x - \bar{\lambda} x^H A \lambda x = x^H A x - |\lambda|^2 x^H A x \\ &= (1 - |\lambda|^2) x^H A x \end{aligned}$$

Siccome Z è definito positivo, questo termine è positivo se e solo se $1 - |\lambda|^2 > 0$, cioè $1 > |\lambda|$. In altre parole se e solo se $\rho(G) < 1$.

($\Rightarrow$) Supponiamo che il metodo sia convergente e mostriamo che A è definita positiva. Consideriamo l'errore

$$e^{(k)} = x^* - x^{(k)}$$

dove x^* è la soluzione del sistema. Questa successione tende a zero per ipotesi. Poiché $e^{(k)} = P e^{(k-1)}$, $\forall k \geq 1$, abbiamo $e^{(k)} = G e^{(k-1)}$. Allora, considerando la matrice Z dello scorso punto,

$$\begin{aligned} (e^{(0)})^H Z e^{(0)} &= (e^{(0)})^H A e^{(0)} - (e^{(0)})^H G^H A G e^{(0)} \\ &= (e^{(0)})^H A e^{(0)} - (e^{(1)})^H A e^{(1)}. \end{aligned}$$

O più in generale

$$0 < (e^{(k)})^H Z e^{(k)} \quad (e^{(k)} \neq 0) = \underbrace{(e^{(k)})^H A e^{(k)}}_{\alpha_k} - \underbrace{(e^{(k+1)})^H A e^{(k+1)}}_{\alpha_{k+1}} \iff \alpha_k > \alpha_{k+1}$$

cioè la successione è strettamente decrescente finché l'errore è non nullo. Poiché tende a zero, deve partire da un valore strettamente positivo. Supponiamo per assurdo che A non sia definita positiva, allora esisterebbe un certo vettore $e^{(0)} \neq 0$ (cioè un errore iniziale particolare) per cui

$$(e^{(0)})^H A e^{(0)} \leq 0$$

e quindi la successione non tende a zero dall'alto, il che è assurdo perché per ipotesi il metodo converge.

4.4 Metodi di rilassamento

Metodo di rilassamento: se il raggio spettrale della matrice di iterazione è troppo vicino a uno, si può cercare un parametro che lo riduca per accelerare la convergenza; il miglioramento dipende dalla matrice e dalla scelta del parametro. Al posto di risolvere $Ax = b$ risolviamo $\omega Ax = \omega b$, con $\omega \in \mathbb{R} \setminus \{0\}$. Una volta effettuata la decomposizione $\omega A = M - N$ vale $M = D - \omega B$ e $N = (1 - \omega)D + \omega C$. Se $\det D \neq 0$, allora $M = D - \omega B$ è invertibile e

$$x^{(k)} = \underbrace{(D - \omega B)^{-1} [(1 - \omega)D + \omega C]}_{P_\omega} x^{(k-1)} + \omega(D - \omega B)^{-1} b$$

A questo punto abbiamo due classi di rilassamento, quelli $\omega > 1$ (sovrarilassamenti) e $0 < \omega < 1$ (sottorilassamenti). Abbiamo $\rho(P_\omega) \geq |\omega - 1|$, quindi se $|\omega - 1| \geq 1$ non convergerà.

4.5 Esempi di confronto fra Jacobi e Gauss-Seidel

Esempio

Consideriamo la matrice

$$A = \begin{pmatrix} -4 & -1 & 1 & 1 \\ 0 & -4 & -1 & 1 \\ -1 & -1 & 4 & 1 \\ 1 & -1 & 0 & 4 \end{pmatrix}$$

ha predominanza diagonale forte. Abbiamo le matrici di Jacobi e Gauss-Seidel

$$J = \frac{1}{4} \begin{pmatrix} 0 & -1 & 1 & 1 \\ 0 & 0 & -1 & 1 \\ 1 & 1 & 0 & -1 \\ -1 & 1 & 0 & 0 \end{pmatrix}, \quad G = \frac{1}{16} \begin{pmatrix} 0 & -4 & 4 & 4 \\ 0 & 0 & -4 & 4 \\ 0 & -1 & 0 & -2 \\ 0 & 1 & -2 & 0 \end{pmatrix}$$

Il polinomio caratteristico della matrice di Gauss-Seidel è

$$\rho_G(\lambda) = \lambda^4 - \frac{3}{64}\lambda^2 - \frac{\lambda}{256} = \lambda \left(\lambda - \frac{1}{4} \right) \left(\lambda + \frac{1}{8} \right)^2$$

Abbiamo quindi autovalore $\lambda = 0, \frac{1}{4}, -\frac{1}{8}, -\frac{1}{8}$ e il raggio spettrale è minore di 1, quindi converge. Lo spettro della matrice di Jacobi è

$$\lambda_1 = \lambda_2 = \frac{1}{4}, \quad \lambda_3 = \frac{-1 + i\sqrt{2}}{4}, \quad \lambda_4 = \frac{-1 - i\sqrt{2}}{4}$$

il raggio spettrale è $\sqrt{3}/4 < 1$, quindi il metodo è convergente.

Esempio

Consideriamo la matrice

$$A = \begin{pmatrix} -4 & -1 & 1 & 1 \\ 0 & -4 & -1 & -3 \\ -1 & -1 & 4 & 1 \\ 1 & 3 & 0 & 4 \end{pmatrix}$$

ha predominanza diagonale debole ed è irriducibile. Abbiamo le matrici di Jacobi e Gauss-Seidel

$$J = \frac{1}{4} \begin{pmatrix} 0 & -1 & 1 & 1 \\ 0 & 0 & -1 & -3 \\ 1 & 1 & 0 & -1 \\ -1 & -3 & 0 & 0 \end{pmatrix}, \quad G = \frac{1}{16} \begin{pmatrix} 0 & -4 & 4 & 4 \\ 0 & 0 & -4 & -12 \\ 0 & -1 & 0 & -6 \\ 0 & 1 & 2 & 8 \end{pmatrix}$$

Gli spettri sono

$$\sigma_J = \left\{ \frac{1}{4}, -\frac{3}{4}, \frac{1+\sqrt{2}}{4}, \frac{1-\sqrt{2}}{4} \right\}, \quad \sigma_G = \left\{ 0, \frac{1}{4}, \frac{1}{8} \right\}$$

Abbiamo ancora quindi la convergenza in ambo i metodi.

Esempio

Consideriamo la matrice

$$A = \begin{pmatrix} -4 & -1 & 1 & 1 \\ 0 & -4 & 0 & -4 \\ 1 & 1 & 4 & 1 \\ 0 & -4 & 0 & 4 \end{pmatrix}$$

ha predominanza diagonale debole ma non è irriducibile. Abbiamo le matrici di Jacobi e Gauss-Seidel

$$J = \frac{1}{4} \begin{pmatrix} 0 & -1 & 1 & 1 \\ 0 & 0 & 0 & -4 \\ -1 & -1 & 0 & -1 \\ 0 & 4 & 0 & 0 \end{pmatrix}, \quad G = \frac{1}{16} \begin{pmatrix} 0 & -4 & 4 & 4 \\ 0 & 0 & 0 & -16 \\ 0 & 1 & -1 & -1 \\ 0 & 0 & 0 & -16 \end{pmatrix}$$

Il polinomio caratteristico della matrice J è

$$\rho_J(\lambda) = \lambda^4 + \frac{17}{16}\lambda^2 + \frac{1}{16} = (\lambda^2 + 1) \left(\lambda^2 + \frac{1}{16} \right)$$

quindi abbiamo autovalori $\lambda_1 = i, \lambda_2 = -i, \lambda_3 = \frac{i}{4}, \lambda_4 = -\frac{i}{4}$. Abbiamo quindi un raggio spettrale di esattamente 1, e quindi nessuna convergenza. Il polinomio caratteristico per Gauss-Seidel abbiamo

$$\rho_G(\lambda) = \lambda^4 + \frac{17}{16}\lambda^3 + \frac{\lambda^2}{16} = \lambda^2(\lambda + 1) \left(\lambda + \frac{1}{16} \right)$$

abbiamo quindi autovalori $\lambda_1 = \lambda_2 = 0, \lambda_3 = -1, \lambda_4 = -\frac{1}{16}$, quindi ancora una volta abbiamo il raggio spettrale pari a 1.

4.6 Matrici consistentemente ordinate e confronto asintotico

Definizione Consistentemente ordinata

Siano $A \in \text{Mat}_n(\mathbb{C})$ e $\det A \neq 0$ con $A = D - B - C$ e $\det D \neq 0$. Scriviamo $P_J = D^{-1}(B + C)$ e $P_{GS} = (D - B)^{-1}C$. Per semplicità indichiamo $P_J = L + U$ con $L = D^{-1}B$ e $U = D^{-1}C$, e analogamente

$$P_{GS} = (D(I - D^{-1}B))^{-1}C = (I - D^{-1}B)^{-1}D^{-1}C = (I - L)^{-1}U$$

Si dice che A è *consistentemente ordinata* se per ogni $\alpha \in \mathbb{C} \setminus \{0\}$ la matrice P_J è simile a

$$P_J(\alpha) \triangleq \alpha L + \frac{1}{\alpha} U$$

Le matrici tridiagonali che soddisfano le ipotesi della definizione sono consistentemente ordinate. Sia infatti $A \in \text{Mat}_n(\mathbb{C})$ tridiagonale, allora B è nulla tranne la sottodiagonale, e C è nulla tranne la sopradiagonale. Siccome la riscalatura non cambia il pattern della matrice, pure L e U hanno queste forme rispettivamente.

$$L = \begin{pmatrix} 0 & & & & \\ l_{2,1} & \ddots & & & \\ & l_{3,2} & \ddots & & \\ & & \ddots & \ddots & \\ & & & l_{n,n-1} & 0 \end{pmatrix}, \quad U = \begin{pmatrix} 0 & u_{1,2} & & & \\ & \ddots & u_{2,3} & & \\ & & \ddots & \ddots & \\ & & & 0 & u_{n-1,n} \\ & & & & 0 \end{pmatrix}$$

Consideriamo la matrice $\Delta = \text{diag}(1, \alpha, \alpha^2, \dots, \alpha^{n-1})$ da cui $\Delta P_J \Delta^{-1} = P_J(\alpha)$. Questa matrice applicata ad ogni matrice della forma $X = L + U$ produce la forma $\alpha L + \frac{1}{\alpha} U$. Quindi, questa classe include le tridiagonali ed è abbastanza ampia da chiedersi cosa fanno i metodi iterativi.

Teorema

Siano $A \in \text{Mat}_n(\mathbb{C})$ e $\det A \neq 0$ con $A = D - B - C$ e $\det D \neq 0$. Scriviamo $P_J = D^{-1}(B + C)$ e $P_{GS} = (D - B)^{-1}C$. Per semplicità indichiamo $P_J = L + U$ con $L = D^{-1}B$ e $U = D^{-1}C$, e analogamente

$$P_{GS} = (D(I - D^{-1}B))^{-1}C = (I - D^{-1}B)^{-1}D^{-1}C = (I - L)^{-1}U$$

Sia A consistentemente ordinata. Allora,

$$\rho(P_{GS}) = \rho^2(P_J)$$

Quindi, o divergono assieme o convergono assieme, e quando convergono Gauss-Seidel richiede asintoticamente circa la metà delle iterazioni di Jacobi per la stessa riduzione dell'errore (quando $0 < \rho(P_J) < 1$).

Proof

Valutiamo il polinomio caratteristico

$$\begin{aligned} \det(P_{GS} - \lambda I) &= \det((I - L)^{-1}U - \lambda I) = \det(\cancel{(I - L)^{-1}}^1 \det(U - \lambda(I - L))) \\ &= \det(U + \lambda L - \lambda I) \\ &= \det\left(\sqrt{\lambda}\left(\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U - \sqrt{\lambda}I\right)\right) \\ &= (\sqrt{\lambda})^n \det\left(\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U - \sqrt{\lambda}I\right) = g(\lambda) \end{aligned} \quad \lambda \neq 0$$

Possiamo escludere il caso $\lambda = 0$ in quanto la radice nulla non contribuisce verso il raggio spettrale.

Facciamo diventare questa funzione a due variabili, cioè $g(\lambda) = f(\lambda, \sqrt{\lambda})$

$$\begin{aligned} f(\lambda, \mu) &= (\sqrt{\lambda})^n \det \left(\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U - \mu I \right) \\ &= (\sqrt{\lambda})^n \det \left(\underbrace{\sqrt{\lambda}L + \frac{1}{\sqrt{\lambda}}U}_{P_J(\sqrt{\lambda}) \sim P_J} - \mu I \right) = (\sqrt{\lambda})^n \det (P_J - \mu I) \end{aligned}$$

Quindi, per $\lambda \neq 0$, per λ che annulla il polinomio caratteristico di Gauss-Seidel, quello che annulla il polinomio caratteristico di Jacobi è $\sqrt{\lambda}$. Viceversa, ogni autovalore non nullo μ di Jacobi dà $\lambda = \mu^2$ autovalore di Gauss-Seidel tramite la stessa identità. Quindi vale l'uguaglianza dei raggi spettrali, anche quando entrambi sono nulli. Quindi abbiamo inoltre dimostrato che per ogni autovalore non-nullo di Gauss-Seidel ne corrisponde uno, la radice, per la matrice di Jacobi.

Questa condizione/problematica dell'autovalore nullo è in realtà inevitabile. Consideriamo

$$A = \begin{pmatrix} 1 & \alpha \\ \alpha & 1 \end{pmatrix} \in \text{Mat}_2(\mathbb{C})$$

con $|\alpha| < 1$. I metodi convergono e la matrice è tridiagonale (come tutte le matrici 2×2). Abbiamo quindi

$$P_J = D^{-1}(B + C) = \begin{pmatrix} 0 & -\alpha \\ -\alpha & 0 \end{pmatrix}$$

Se consideriamo il vettore di tutti 1, troviamo che un autovalore è $-\alpha$. Siccome la traccia è nulla l'altro autovalore è α . D'altra parte abbiamo

$$P_{GS} = (D - B)^{-1}C = \begin{pmatrix} 1 & 0 \\ \alpha & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 & -\alpha \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ -\alpha & 1 \end{pmatrix} \begin{pmatrix} 0 & -\alpha \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -\alpha \\ 0 & \alpha^2 \end{pmatrix}$$

Quindi l'autovalore zero di Gauss-Seidel non implica che zero sia autovalore di Jacobi (per $\alpha \neq 0$). La matrice di Gauss-Seidel ha sempre un autovalore nullo, mentre quella di Jacobi non necessariamente. Esistono matrici per cui J e GS sono ben definite tali che $\rho(P_J) < 1$ e $\rho(P_{GS}) > 1$. Esistono matrici per cui J e GS sono ben definite tale che $\rho(P_{GS}) < 1$ e $\rho(P_J) > 1$.

Esercizio Per $M > 1$ esistono matrici per cui J e GS sono ben definite tali che $\rho(P_{GS}) < 1$ e $\rho(P_J) > M$.

In questo modo, abbiamo sempre la convergenza di Gauss-Seidel in quanto la matrice è definita positiva, ma sufficientemente poco a predominanza diagonale da non fare convergere Jacobi.

Vogliamo costruire un caso limite di una matrice definita positiva ma non troppo a predominanza diagonale. Consideriamo la matrice con tutti elementi uguali a 1 e aggiungiamo εI , con $\varepsilon > 0$:

$$A_{n,\varepsilon} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{pmatrix} + \varepsilon I.$$

Indichiamo con E la matrice con tutti elementi uguali a 1. Allora

$$A_{n,\varepsilon} = E + \varepsilon I.$$

Questa matrice è definita positiva, infatti gli autovalori di E sono

$$\lambda(E) = \begin{cases} 0 & \text{con molteplicità } n-1, \\ n & \text{con molteplicità } 1, \end{cases}$$

quindi gli autovalori di $A_{n,\varepsilon}$ sono

$$\lambda(A_{n,\varepsilon}) = \begin{cases} \varepsilon & \text{con molteplicità } n-1, \\ n+\varepsilon & \text{con molteplicità } 1. \end{cases}$$

Dunque $A_{n,\varepsilon}$ è definita positiva per ogni $\varepsilon > 0$. Per il teorema di convergenza di Gauss-Seidel per matrici Hermitiane definite positive, abbiamo quindi

$$\rho(P_{GS}) < 1.$$

Calcoliamo ora il raggio spettrale della matrice di iterazione di Jacobi. Poiché

$$D = (1 + \varepsilon)I,$$

si ha

$$P_J = -D^{-1}(L + U).$$

Siccome $L + U = E - I$, otteniamo

$$P_J = -\frac{1}{1+\varepsilon}(E - I) = \frac{1}{1+\varepsilon}(I - E).$$

Quindi

$$\rho(P_J) = \frac{1}{1+\varepsilon}\rho(I - E).$$

Gli autovalori di $I - E$ sono

$$\lambda(I - E) = \begin{cases} 1 & \text{con molteplicità } n-1, \\ 1-n & \text{con molteplicità } 1. \end{cases}$$

Pertanto, per $n \geq 2$,

$$\rho(I - E) = n-1,$$

e quindi

$$\rho(P_J) = \frac{n-1}{1+\varepsilon}.$$

Fissato $M > 1$, scegliamo ad esempio $\varepsilon > 0$ e poi n tale che

$$\frac{n-1}{1+\varepsilon} > M,$$

cioè

$$n > M(1+\varepsilon) + 1.$$

Allora

$$\rho(P_{GS}) < 1 \quad \text{e} \quad \rho(P_J) > M,$$

come volevamo.

Esercizio Altro caso
todo

5 Condizionamento e fattorizzazioni per sistemi lineari

5.1 Perturbazioni e condizionamento

Definizione Errori perturbazione

Dato un sistema $Ax = b$, consideriamo spesso dei sistemi perturbati $(A + \delta A)(x + \delta x) = (b + \delta b)$. I termini $\delta A, \delta b$ sono detti perturbazioni autogenerate (dai dati iniziali), mentre δx è la perturbazione indotta. Gli errori sono definiti come

$$\varepsilon_A = \frac{\|\delta A\|}{\|A\|}, \quad \varepsilon_b = \frac{\|\delta b\|}{\|b\|}, \quad \varepsilon_x = \frac{\|\delta x\|}{\|x\|}$$

Vogliamo che gli errori tendano a zero. Possiamo eseguire il prodotto e usando il fatto che $Ax = b$

$$\begin{aligned} \delta b &= A\delta x + \delta A(x + \delta x) \\ \delta x &= (A + \delta A)^{-1}(\delta b - \delta Ax) \\ &= [A(I + A^{-1}\delta A)]^{-1}[\delta b - \delta Ax] \\ &= (I + A^{-1}\delta A)^{-1}A^{-1}(\delta b - \delta Ax) \end{aligned}$$

Passando alle norme troviamo

$$\begin{aligned} \|\delta x\| &\leq \|(I + A^{-1}\delta A)^{-1}A^{-1}\| \cdot \|\delta b - \delta Ax\| \\ &\leq \|(I + A^{-1}\delta A)^{-1}\| \cdot \|A^{-1}\| \cdot \|\delta b - \delta Ax\| \\ &\leq \|(I + A^{-1}\delta A)^{-1}\| \cdot \|A^{-1}\| \left(\|\delta b\| + \|A\| \cdot \frac{\|\delta A\|}{\|A\|} \cdot \|x\| \right) \\ &= \|(I + A^{-1}\delta A)^{-1}\| \left(\|A^{-1}\| \cdot \|\delta b\| + \underbrace{\|A^{-1}\| \cdot \|A\|}_{\mu(A)} \varepsilon_A \cdot \|x\| \right) \\ \frac{\|\delta x\|}{\|x\|} &\leq \|(I + A^{-1}\delta A)^{-1}\| [\mu(A)\varepsilon_b + \mu(A)\varepsilon_A]. \end{aligned}$$

Abbiamo usato il fatto che $\|b\| = \|Ax\| \leq \|A\| \cdot \|x\|$. Il termine $\mu(A)$ è detto numero di condizionamento. Inoltre notiamo che il numero di condizionamento è sempre maggiore o uguale a 1 in quanto

$$1 = \|I\| = \|A^{-1}A\| \leq \|A\| \cdot \|A^{-1}\| = \mu(A)$$

Per le matrici normali invertibili, il numero di condizionamento in norma 2 è il rapporto fra il massimo e il minimo modulo degli autovalori (esercizio).

5.1.1 Norme submoltiplicative e stime generali

Mettiamo il tutto in un contesto un pochetto più ampio.

Abbiamo una norma $\|\cdot\|_a$ su $\text{Mat}_{n \times n}(\mathbb{C})$ e $\|\cdot\|_b$ su $\mathbb{C}^n$.

Definizione Norma submoltiplicativa

Si dice norma submoltiplicativa se $\forall A, B \in \text{Mat}_{n \times n}(\mathbb{C})$ vale

$$\|AB\| \leq \|A\| \cdot \|B\|$$

Definizione Norme compatibili

Due norme sono compatibili se $\forall A \in \text{Mat}_{n \times n}(\mathbb{C}), \forall y \in \mathbb{C}^n$ vale

$$\|Ay\|_b \leq \|A\|_a \cdot \|y\|_b$$

Proposition

Sia data

$$\|A\|_a = \sup_{x \neq 0} \frac{\|Ax\|_b}{\|x\|_b}$$

allora le due norme sono compatibili e la norma $\|\cdot\|_a$ è submoltiplicativa.

Proof

Cominciamo con la compatibilità. Sia $y = 0$. Si ha

$$\|Ay\|_b = 0 = \|A\|_a \cdot \|y\|_b = 0$$

Se invece $y \neq 0$ abbiamo

$$\begin{aligned} \|Ay\|_b &= \frac{\|Ay\|_b}{\|y\|_b} \cdot \|y\|_b \\ &\leq \left(\sup_{x \neq 0} \frac{\|Ax\|_b}{\|x\|_b} \right) \cdot \|y\|_b = \|A\|_a \cdot \|y\|_b \end{aligned}$$

Successivamente studiamo la submoltiplicatività

$$\begin{aligned} \|AB\|_a &= \sup_{y \neq 0} \frac{\|AB y\|_b}{\|y\|_b} \leq \sup_{y \neq 0} \|A\|_a \cdot \frac{\|B y\|_b}{\|y\|_b} \\ &= \|A\|_a \cdot \|B\|_a \end{aligned}$$

Supponiamo di avere $A \in \text{Mat}_{n \times n}(\mathbb{C})$ invertibile e consideriamo il sistema $Ax = b$. Consideriamo il sistema perturbato $(A + \delta A)(x + \delta x) = b + \delta b$. Quantomeno la matrice $A + \delta A$ deve rimanere invertibile. Scegliamo una $\|\cdot\|$ norma vettoriale data con $\|\cdot\|$ su $\text{Mat}_{n \times n}(\mathbb{C})$ matriciale indotta, quindi compatibilità e submoltiplicatività valgono.

Teorema

Con le notazioni e le ipotesi precedenti e supponendo inoltre che $\varepsilon_A \cdot \mu(A) < 1$ e che $b \neq 0$, vale che

$$\varepsilon_x = \frac{\|\delta x\|}{\|x\|} \leq \frac{\mu(A)(\varepsilon_A + \varepsilon_b)}{1 - \varepsilon_A \cdot \mu(A)}$$

Proof

Abbiamo

$$\begin{aligned} Ax &= b \\ (A + \delta A)(x + \delta x) &= b + \delta b \\ Ax + A\delta x + \delta A(x + \delta x) &= b + \delta b \\ (A + \delta A)\delta x + \delta Ax &= \delta b && \left. \begin{array}{l} \text{Sottrazione} \\ \text{della (1) dalla (2)} \end{array} \right\} \\ (A + \delta A)\delta x &= \delta b - \delta Ax \\ A(I + A^{-1}\delta A)\delta x &= \delta b - \delta Ax \\ (I + A^{-1}\delta A)^{-1}A^{-1}(\delta b - \delta Ax) &= \delta x \end{aligned}$$

Passando alle norme e usando la compatibilità e la submoltiplicatività,

$$\|\delta x\| \leq \|(I + A^{-1}\delta A)^{-1}\| \cdot \|A^{-1}\|(\|\delta b\| + \|\delta A\| \cdot \|x\|)$$

Estraiamo il numero di condizionamento

$$\|A^{-1}\delta A\| \leq \|A^{-1}\| \cdot \|\delta A\| = \underbrace{\|A^{-1}\| \cdot \|A\|}_{\mu(A)} \cdot \underbrace{\frac{\|\delta A\|}{\|A\|}}_{<1}$$

Chiamando $V = A^{-1}\delta A$ abbiamo $V^j \rightarrow 0$ per $j \rightarrow \infty$. Quindi l'inversa di una tale perturbazione è

$$(I + V)^{-1} = \sum_{j=0}^{\infty} (-1)^j V^j$$

Quindi, usando la disuguaglianza triangolare e le submoltiplicatività iterata

$$\|(I + V)^{-1}\| \leq \sum_{j=0}^{\infty} \|V^j\| \leq \sum_{j=0}^{\infty} \|V\|^j$$

in quanto $\|V^j\| \leq \|V^{j-1}\| \cdot \|V\| \leq \|V\|^j$. Abbiamo quindi una serie geometrica e

$$\|(I + V)^{-1}\| \leq \frac{1}{1 - \|V\|}$$

Mettendo tutti assieme

$$\begin{aligned} \|\delta x\| &\leq \frac{\|A\| \cdot \|A^{-1}\|}{1 - \varepsilon_A \mu(A)} \left(\frac{\|\delta b\|}{\|A\|} + \frac{\|\delta A\|}{\|A\|} \cdot \|x\| \right) \\ &\leq \frac{\mu(A) \|x\|}{1 - \varepsilon_A \mu(A)} \left(\frac{\|\delta b\|}{\|b\|} + \varepsilon_A \right) \\ \frac{\|\delta x\|}{\|x\|} = \varepsilon_x &\leq \frac{\mu(A)}{1 - \varepsilon_A \mu(A)} (\varepsilon_b + \varepsilon_A) \end{aligned}$$

Vale sempre $\rho(A) \leq \|A\|$ per tutte le norme matriciali indotte e inoltre il raggio spettrale è l'inf di tutte le norme matriciali indotte.

Proposition Il raggio spettrale non è una norma

1. *assoluta omogeneità*:

$$\rho(\alpha A) = |\alpha| \rho(A)$$

vale.

2. *Disuguaglianza triangolare*: Consideriamo $A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ e $B = A^t$, allora

$$\rho(A + B) > \rho(A) = \rho(B) = \rho(A) + \rho(B) = 0$$

quindi non è valida.

Allora il raggio spettrale non è una norma.

5.2 Fattorizzazione LU

Esistono principalmente tre tipi di fattorizzazione: la fattorizzazione LU , la fattorizzazione QR e la fattorizzazione LL^H dove L è triangolare inferiore con elementi principali > 0 .

Per la fattorizzazione LL^H abbiamo il metodo di Cholesky, mentre per la QR il metodo di Householder.

Teorema Esistenza e unicità della fattorizzazione LU

Sia $A \in \text{Mat}_n(\mathbb{C})$ fortemente non singolare. Allora, esistono e sono uniche $L \in \text{Mat}_n(\mathbb{C})$ triangolare inferiore con $L_{i,i} = 1$ per $i \in \{1, \dots, n\}$ e $U \in \text{Mat}_n(\mathbb{C})$ triangolare superiore tale che $A = LU$.

Proof Esistenza e unicità della fattorizzazione LU

Procediamo per induzione. Il caso di base è $n = 1$ dove $A = (a_{1,1})$ e quindi abbiamo $L = (1)$ e $U = (a_{1,1})$. Sia $n = k > 1$ e supponiamo che la tesi sia vera per $k = n - 1$. Scriviamo

$$A = \left[\begin{array}{c|c} A_{n-1} & b \\ \hline c^H & \alpha \end{array} \right]$$

con $b, c \in \mathbb{C}^{n-1}$ e $\alpha \in \mathbb{C}$ dove A_{n-1} è il minore principale di testa di A di ordine $n - 1$, quindi $A_{n-1} = L_{n-1}U_{n-1}$. Abbiamo quindi il prodotto

$$A = \left[\begin{array}{c|c} L_{n-1}U_{n-1} & b \\ \hline c^H & \alpha \end{array} \right] = \left[\begin{array}{c|c} L_{n-1} & 0 \\ \hline M^H & 1 \end{array} \right] \left[\begin{array}{c|c} U_{n-1} & V \\ \hline 0^H & B \end{array} \right]$$

Analizziamo i blocchi:

1. $L_{n-1}U_{n-1} + 0 \cdot 0^H = A_{n-1}$;
2. $L_{n-1}V + 0 \cdot B = b$ poiché L_{n-1} è invertibile esiste un'unica V tale che $L_{n-1}V = b$;
3. $M^H U_{n-1} + 1 \cdot 0^H = c^H$ e quindi $U_{n-1}^H M = c$, quindi esiste un'unica M tale che $U_{n-1}^H M = c$;
4. $M^H V + 1 \cdot B = \alpha$ e quindi $B = \alpha - M^H V$.

Tutti i blocchi sono così determinati univocamente, e il loro prodotto è A .

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$ invertibile. Allora, esistono L triangolare inferiore con $L_{i,i} = 1$ per $i \in \{1, \dots, n\}$, U triangolare superiore e Π matrice di permutazione $\Pi A = LU$.

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$. Allora, esiste L triangolare inferiore e U triangolare superiore e due matrici di permutazione Π_1, Π_2 tali che $\Pi_1 A \Pi_2 = LU$.

Proof

Procediamo per induzione. Il caso di base è $n = 1$ dove $A = (a_{1,1})$ e quindi abbiamo $L = (1)$, $U = (a_{1,1})$ e $\Pi = (1) = I_1$. Sia $n = k > 1$ e supponiamo che la tesi sia vera per $k = n - 1$. Scriviamo

$$A = \left[\begin{array}{c|c} c_1^H & S_1 \\ \vdots & \vdots \\ \hline c_n^H & S_n \end{array} \right]$$

Vogliamo che tra i vettori $C_i \in \mathbb{C}^{n-1}$ ci siano i generatori di $\mathbb{C}^{n-1}$. Siccome A è invertibile, il determinante è non nullo e applicando l'espansione di Laplace dall'ultimo termine

$$0 \neq \det A = \sum_{i=1}^n (-1)^{n-i} S_i \det(A \setminus \{C_i^H, \vec{S}\})$$

Troviamo che $\exists \vec{j}$ tale che $A \setminus \{C_{\vec{j}}^H, \vec{S}\}$ è una matrice invertibile in $\text{Mat}_{n-1}(\mathbb{C})$. Definiamo Π come la matrice di permutazione che scambia n con $\vec{j}$,

$$\Pi A = \left[\begin{array}{c|c} \hat{A}_{n-1} & b \\ \hline c^H & \alpha \end{array} \right], \quad \det(\hat{A}_{n-1}) \neq 0$$

Per ipotesi induttiva esistono Π_{n-1}, L_{n-1} tali che $\Pi_{n-1}\hat{A}_{n-1} = L_{n-1}U_{n-1}$

$$\left[\begin{array}{c|c} \Pi_{n-1} & 0 \\ \hline 0 & 1 \end{array} \right] \Pi A = \left[\begin{array}{c|c} L_{n-1}U_{n-1} & \hat{b} \\ \hline c^H & \alpha \end{array} \right]$$

dove $\hat{b} = \Pi_{n-1}b$.

Esempio

$$A = \begin{pmatrix} 1 & 2 & 1 \\ -1 & -1 & 2 \\ 1 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 4 \end{pmatrix}$$

Studiamo ora l'algoritmo LU . Osserviamo che la forte non singolarità di A implica l'eliminazione di Gauss per ottenere LU senza usare permutazioni.

Passo 1: siccome A è fortemente non singolare, $a_{1,1} \neq 0$ quindi la prima matrice elementare di Gauss è ben definita

$$E_j = \begin{bmatrix} 1 & & 0 \\ & \ddots & \\ * & & 1 \end{bmatrix}$$

dove $*$ sono elementi della forma $-a_{i,j}/a_{j,j}$ e quindi

$$E_1 = \begin{bmatrix} 1 & & & & \\ -\frac{a_{2,1}}{a_{1,1}} & 1 & & & 0 \\ \vdots & & \ddots & & \\ & & & 1 & \\ -\frac{a_{n,1}}{a_{1,1}} & & & & 1 \end{bmatrix}, \quad \vec{a} = \left(-\frac{a_{2,1}}{a_{1,1}}, -\frac{a_{3,1}}{a_{1,1}}, \dots, -\frac{a_{n,1}}{a_{1,1}} \right)^T$$

Possiamo quindi eseguire il prodotto

$$E_1 A = \left(\begin{array}{c|ccc} a_{1,1} & * & \cdots & * \\ \hline 0 & a_{2,2}^{(2)} & & * \\ \vdots & & \ddots & \\ 0 & * & & * \end{array} \right)$$

dove $a_{2,2}^{(2)}$ è il nuovo elemento diagonale.

Passo 2: supponiamo la tesi sia vera per $k-1$, mostriamo che possiamo applicare il passo k . La tesi è che $a_{k,k}^{(k)} \neq 0$. Abbiamo applicato l'eliminazione gaussiana $k-1$ volte

$$E_{k-1}E_{k-2} \cdots E_2 E_1 A = A^{(k)} = \left(\begin{array}{ccc|cc} a_{11} & & & & \\ & \ddots & & & * \\ & & a_{k-1,k-1}^{(k-1)} & & \\ \hline & & & a_{kk}^{(k)} & * \\ 0 & & & & \end{array} \right)$$

Mostriamo $a_{k,k}^{(k)} \neq 0$. Ribaltando abbiamo

$$A = \underbrace{E_1^{-1}E_2^{-1} \cdots E_{k-1}^{-1}}_{\text{triangolare inferiore}} A^{(k)}$$

Osserviamo che il prodotto di matrici triangolare inferiore è a sua volta triangolare inferiore. Inoltre, siccome tutte le E_i hanno 1 come diagonale, allora pure il prodotto $E_{k-1} \cdots E_1$ ha 1 come diagonale. Ora se $E_j = I + m_j e_j^T$ dove $m_j \in \text{span}\{e_{j+1}, \dots, e_n\}$, calcoliamo $E_j^{-1} = I - m_j e_j^T$ e pertanto $E_1^{-1} E_2^{-1} \cdots E_{k-1}^{-1}$ è triangolare inferiore con 1 sulla diagonale. Abbiamo quindi

$$A = \underbrace{E_1^{-1} \cdots E_{k-1}^{-1}}_{\xi^{(k)}} A^{(k)} = \begin{bmatrix} 1 & & & 0 \\ & \ddots & & \\ * & & 1 & \\ * & \cdots & * & 1 \end{bmatrix} \begin{bmatrix} a_{1,1} & * & \cdots & * & \cdots & * \\ 0 & a_{2,2}^{(2)} & \ddots & \vdots & & \vdots \\ \vdots & \ddots & \ddots & * & & \vdots \\ 0 & \cdots & 0 & a_{k,k}^{(k)} & \cdots & * \\ \hline 0 & \cdots & 0 & 0 & & \\ \vdots & & \vdots & \vdots & \Theta & \\ 0 & \cdots & 0 & 0 & & \end{bmatrix}$$

Quindi Θ va moltiplicato con la parte nulla della sopradiagonale di $E_1^{-1} \cdots E_{k-1}^{-1}$. Prendiamo una generica matrice $B \in \text{Mat}_n(\mathbb{C})$, B_{k-1} è il suo minore principale di testa di ordine $k-1$. Dunque,

$$A_k = \left(\xi^{(k)} A^{(k)} \right)_k = \xi_k^{(k)} A_k^{(k)}$$

Poiché A è fortemente non singolare, $\det(A_k) \neq 0$ allora

$$0 \neq \det(A_k) = \det(A_k^{(k)}) = a_{1,1} \cdot a_{2,2}^{(2)} \cdots a_{k,k}^{(k)}$$

e per il teorema di Binet $a_{k,k}^{(k)} \neq 0$. Quindi possiamo trovare esattamente chi sono l'unica L e l'unica U di LU . Abbiamo $L = E_1^{-1} \cdots E_{n-1}^{-1}$ e $U = A^{(n)}$. Per quanto detto prima, $E_j^{-1} = I - m_j e_j^T$ e quindi

$$\begin{aligned} L &= E_1^{-1} \cdots E_{n-1}^{-1} \\ &= (I - m_1 e_1^T) \cdots (I - m_{n-1} e_{n-1}^T) \\ &= (I - m_1 e_1^T - m_2 e_2^T) \cdots (I - m_{n-1} e_{n-1}^T) \quad \left. \begin{array}{l} (m_j e_j^T)(m_k e_k^T) = 0 \\ \text{per } j < k \end{array} \right\} \\ &= \cdots = I - \sum_{j=1}^{n-1} m_j e_j^T \end{aligned}$$

e quindi

$$L = \begin{pmatrix} 1 & & & & \\ -m_1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & & \ddots & \\ & & & & 1 \end{pmatrix}$$

5.3 Fattorizzazione di Cholesky

Teorema Fattorizzazione di Cholesky

$A = A^*$ definita positiva se e solo se esiste unica V triangolare inferiore con $V_{j,j} > 0$ tale che $A = VV^*$.

Proof Fattorizzazione di Cholesky

($\Rightarrow$) $A = A^*$ definita positiva se e solo se ogni minore principale è definita positiva. In particolare, lo sono i minori principali di testa, che quindi sono invertibili ovvero A è fortemente non singolare. Esiste un'unica L triangolare inferiore con $L_{j,j} = 1$ ed un'unica U triangolare superiore tale che $A = LU$. Scriviamo

$$A = LU = L \operatorname{diag}_j(U_{j,j}) \tilde{U}$$

dove $\tilde{U}$ è U ma con tutti gli elementi sopra la diagonale divisi per $U_{j,j}$, così possiede 1 sulla diagonale. Allora $A = A^* = \tilde{U}^* \operatorname{diag}_j(\overline{U_{j,j}}) L^*$. Ma quindi $\tilde{U}^*$ è una triangolare inferiore con 1 sulla diagonale. L'altro termine prodotto è una triangolare superiore. La forte non singolarità implica pure l'unicità della fattorizzazione, quindi deve essere

$$L = \tilde{U}^*, \quad U = \operatorname{diag}_j(\overline{U_{j,j}}) L^*$$

Abbiamo quindi trovato che

$$A = L \cdot \operatorname{diag}_j(U_{j,j}) L^*$$

Gli $U_{j,j}$ sono reali perché coniugano, ma sono anche in $\mathbb{R}^{>0}$ in quanto A è definita positiva. Siccome L ha uno sulla diagonale ed è triangolare inferiore è invertibile. Scegliamo quindi $v^{(j)} = (L^*)^{-1} e_j$. Con questa scelta,

$$0 < (v^{(j)})^* A v^{(j)} = e_j^T \operatorname{diag}_j(U_{j,j}) e_j$$

Abbiamo quindi che

$$A = L \operatorname{diag}_j(U_{j,j}) L^* = \underbrace{L \operatorname{diag}_j(\sqrt{U_{j,j}})}_V \underbrace{\operatorname{diag}_j(\sqrt{U_{j,j}}) L^*}_{V^*}$$

($\Leftarrow$) Sappiamo che $A = VV^*$ con $V_{j,j} > 0$ e V triangolare inferiore, quindi è sicuramente invertibile. Abbiamo che $A^* = (VV^*)^* = V^{**} V^* = VV^* = A$, quindi è Hermitiana. Inoltre, $\forall x \neq 0$ abbiamo

$$\begin{aligned} x^* A x &= x^* V V^* x \\ &= y^* y = \|y\|_2^2 > 0 \end{aligned} \quad \left. \vphantom{\begin{aligned} x^* A x &= x^* V V^* x \\ &= y^* y = \|y\|_2^2 > 0 \end{aligned}} \right\} y = V^* x$$

siccome V è invertibile $y \neq 0$.

Per l'unicità, se $VV^* = WW^*$, allora $W^{-1}V$ è triangolare inferiore e unitaria, dunque diagonale; la diagonale positiva impone $W^{-1}V = I$, quindi $V = W$.

L'algoritmo è anche un criterio per testare la definita positività di una matrice. Data una Hermitiana, proviamo l'algoritmo: se funziona è definita positiva, altrimenti non lo è. L'algoritmo è un algoritmo compatto. Prendiamo $A \in \text{Mat}_n(\mathbb{C})$ come input ed imponiamo che $VV^* = A$, e si risolve l'equazione rispetto alle incognite, cioè alle entrate di V . Abbiamo quindi una matrice

$$\left(\begin{array}{c|c|c|c} \mathbf{V}_{1,1} & \mathbf{V}_{2,2} & & 0 \\ & & & \\ V_1 & V_2 & \ddots & \\ & & & \mathbf{V}_{n,n} \end{array} \right) \left(\begin{array}{c|c|c|c} \mathbf{V}_{1,1} & V_1^* & & \\ \hline & \mathbf{V}_{2,2} & V_2^* & \\ \hline & & \ddots & \\ \hline 0 & & & \mathbf{V}_{n,n} \end{array} \right) = \left(\begin{array}{c|c|c|c} \mathbf{A}_{1,1} & \mathbf{A}_{2,2} & & * \\ & & & \\ A_1 & A_2 & \ddots & \\ & & & \mathbf{A}_{n,n} \end{array} \right)$$

dove A_i, V_i sono le sotto-colonne relativamente all'elemento della diagonale delle rispettive matrici. L'idea è di isolare iterativamente ogni $A_{i,i}$ e risolvere per $V_{i,i}$, e le sottocolonne rispettive.

Passo 1: per la prima colonna, imponiamo $V_{1,1}^2 = A_{1,1}$ e quindi $V_{1,1} = \sqrt{A_{1,1}}$. Otteniamo quindi $V_{1,1} \cdot V_1$ da cui $V_1 = \frac{A_1}{V_{1,1}}$. Abbiamo eseguito $n - 1$ operazioni (1 operazione per ogni elemento).

Passo 2: per la colonna due, abbiamo

$$|V_{2,1}|^2 + V_{2,2}^2 = A_{2,2} \implies V_{2,2} = \sqrt{A_{2,2} - |V_{2,1}|^2}$$

Abbiamo eseguito 3 operazioni. Denotiamo con $\tilde{V}_i$ la coda di V_i . Abbiamo ora la colonna di dimensione $n - 2$ data da $\bar{V}_{2,1}\tilde{V}_1 + V_{2,2}V_2 = A_2$. Precedentemente non abbiamo usato il coniugato su $V_{1,1}$ in quanto sapevamo che fosse positivo. Otteniamo quindi che

$$V_2 = \frac{A_2 - \bar{V}_{2,1}\tilde{V}_1}{V_{2,2}}$$

Abbiamo ora eseguito $3(n - 2)$ operazioni (3 operazioni per ogni elemento).

Passo 3: continuando otteniamo

$$|V_{3,1}|^2 + |V_{3,2}|^2 + V_{3,3}^2 = A_{3,3}$$

e qua abbiamo $5(n - 3)$ operazioni (5 operazioni per ogni elemento). In generale la dimensione dei vettori scende mentre il numero di operazioni sale.

In totale abbiamo (senza contare quello diagonale che è di ordine inferiore)

$$\sum_{k=1}^{n-1} (2k - 1)(n - k) = (2n + 1) \sum_{k=1}^{n-1} k - 2 \sum_{k=1}^{n-1} k^2 - n(n - 1) = \frac{1}{3}n^3 + \mathcal{O}(n^2)$$

che è esattamente la metà della complessità dell'algoritmo di Gauss. Tuttavia, l'algoritmo di Gauss applicato ad una matrice Hermitiana ha la stessa complessità.

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$ una matrice definita positiva ed Hermitiana. Allora, A è fortemente non singolare.

Proof

Consideriamo $\mathcal{I}, \mathcal{J} \subseteq \{1, \dots, n\}$, ossia $\mathcal{I} = \{i_1, \dots, i_p\}$ e $\mathcal{J} = \{j_1, \dots, j_q\}$ con

$$\begin{aligned} 1 \leq i_1 < i_2 < \dots < i_p \leq n \\ 1 \leq j_1 < j_2 < \dots < j_q \leq n \end{aligned}$$

Denotiamo con $A_{\mathcal{I}, \mathcal{J}} \in \mathbb{C}^{p \times q}$ un generico minore di dimensione $p \times q$ che contiene gli elementi di indici $\mathcal{I}$ incrociati con $\mathcal{J}$. Abbiamo allora l'elemento

$$(A_{\mathcal{I}, \mathcal{J}})_{s,t} = A_{i_s, j_t}$$

Un tale minore è quadrato se e solo se $p = q$. Un tale minore è un minore principale se e solo se $\mathcal{I} = \mathcal{J}$. Un tale minore è un minore principale di testa se $\mathcal{I} = \mathcal{J} = \{1, \dots, p\}$.

Osserviamo che, da Schur, il fatto che A sia definita positiva ed Hermitiana implica che tutti gli autovalori siano reali positivi. Dunque, $\det A > 0$. L'idea della dimostrazione è quella di utilizzare questa affermazione su ogni minore principale di testa. Abbiamo che ogni minore principale di A (in particolare pure quelli di testa) sono a loro volta definiti positivi. Sia $A_{\mathcal{I}} \triangleq A_{\mathcal{I}, \mathcal{I}}$. Osserviamo che

$$(A_{\mathcal{I}}^*)_{s,t} = \overline{A_{i_t, i_s}} = A_{i_s, i_t} = (A_{\mathcal{I}})_{s,t}$$

Per studiare la definita positività, studiamo se $x^* A_{\mathcal{I}} x > 0$ per $x \in \mathbb{C}^p$ con $x \neq 0$. Definiamo $y_x \in \mathbb{C}^n$ come vettore esteso, cioè

$$(y_x)_l = \begin{cases} 0 & l \notin \mathcal{I} \\ x_s & l = i_s \end{cases}$$

Con questa notazione troviamo

$$x^* A_{\mathcal{I}} x = y_x^* A y_x$$

Abbiamo che $x \neq 0 \implies y_x \neq 0$. Abbiamo quindi la definita positività sui minori principali, e riutilizzando l'argomento precedente ciascun minore principale di testa è invertibile. Quindi, la matrice è fortemente non singolare.

Dal procedimento precedente si evince che sulle definite positive e Hermitiane si può applicare sia l'eliminazione gaussiana senza pivot, sia l'algoritmo per la fattorizzazione di Cholesky.

Durante l'algoritmo di Gauss su una matrice Hermitiana, normalizzando i pivot dal primo all'ultimo, il blocco non ancora normalizzato è una sottomatrice che rimane Hermitiana (induzione). Se A è la nuova matrice ad un passo e B è quella vecchia, allora $\overline{A}_{k,j} = B_{j,k}$, quindi il costo dell'algoritmo si dimostra ed è quindi equivalente a Cholesky. L'algoritmo di Gauss è ottimale fra gli algoritmi con scambi di righe e colonne, ma può essere battuto usando algoritmi ricorsivi.

Teorema Lo spettro commuta con la moltiplicazione di matrici

Siano $A, B \in \text{Mat}_n(\mathbb{C})$. Allora, $\sigma(AB) = \sigma(BA)$.

Proof Lo spettro commuta con la moltiplicazione di matrici

Se A è invertibile, $BA = A^{-1}ABA$ ovvero sono simili e hanno il medesimo polinomio caratteristico

$$p_{AB}(\lambda) = p_{BA}(\lambda)$$

In particolare, gli autovalori coincidono. Analogamente con B . Ci manca il caso dove sia A che B sono singolari. In tal caso, sia $A = QTQ^*$ con Q unitaria e T triangolare superiore. Sia $\varepsilon > 0$ e sia

$$A_\varepsilon \triangleq QT_\varepsilon Q^*$$

che è invertibile, dove $(T_\varepsilon)_{j,j} = \varepsilon$ se $T_{j,j} = 0$ e il resto uguale a T . Cioè sulla diagonale ci sono gli autovalori, e sostituiamo gli zeri con degli ε , visto che è triangolare superiore rimane invertibile perché il prodotto è non nullo. Riconducendoci al caso invertibile, vale

$$p_{A_\varepsilon B}(\lambda) = p_{BA_\varepsilon}(\lambda)$$

Se $A_\varepsilon \rightarrow A$ per $\varepsilon \rightarrow 0$, allora per un argomento di continuità pure i polinomi caratteristici tendono a quelli di AB e BA

$$p_{AB}(\lambda) = p_{BA}(\lambda)$$

Teorema

Siano $A \in \mathbb{C}^{n \times m}$ e $B \in \mathbb{C}^{m \times n}$. Allora, $\sigma(AB) = \sigma(BA)$ a meno di $n - m$ (se $n - m > 0$) o $m - n$ (se $m - n > 0$) zeri laddove servono.

Proof

Supponiamo senza perdita di generalità che $n \geq m$. Vogliamo ricondurci al caso quadrato, e quindi consideriamo

$$A_{\text{ext}} = \left(A \left| \begin{array}{c} 0 \\ \vdots \\ 0 \end{array} \right. \right) \in \text{Mat}_n(\mathbb{C}), \quad B_{\text{ext}} = \left(\begin{array}{c|c} B & 0 \\ \hline 0 & \dots & 0 \end{array} \right) \in \text{Mat}_n(\mathbb{C})$$

con un numero appropriato di zeri per completarla. Visto che le matrici sono quadrate,

$$\sigma(A_{\text{ext}}B_{\text{ext}}) = \sigma(B_{\text{ext}}A_{\text{ext}})$$

Ma notiamo che nel prodotto $A_{\text{ext}}B_{\text{ext}}$ riga per colonna, ritroviamo AB , e quindi lo spettro è precisamente quello di AB . Invece, il prodotto inverso $B_{\text{ext}}A_{\text{ext}}$ notiamo che otteniamo un blocco quadrato

$$B_{\text{ext}}A_{\text{ext}} = \left(\begin{array}{c|c} BA & 0 \\ \hline 0 & 0 \end{array} \right) = \text{diag}(BA, 0_{n-m})$$

quindi lo spettro coincide.

Questo teorema vale nel caso particolare (già visto) $m = 1$. Infatti, $\sigma(xy^*) = \{y^*x, 0, 0, \dots, 0\}$ con $x, y \in \mathbb{C}^n$, cioè il caso della diade, che ha rango uno.

5.4 Matrici semi-elementari e aggiornamenti a basso rango

Abbiamo visto che dato $I + xy^*$ con $x, y \in \mathbb{C}^n$ possiamo caratterizzarne lo spettro e la condizione di invertibilità: $y^*x \neq -1$ e in tal caso

$$(I + xy^*)^{-1} = I - \frac{xy^*}{1 + y^*x}$$

Quindi in generale sappiamo tutto delle diadi xy^* . Tuttavia, nell'esercizio avevamo una matrice di rango 2. In generale, al posto di sommare una matrice di rango 1, sommiamo una matrice di rango k , vale lo stesso ragionamento.

Consideriamo quindi $I + R$ con $\text{rank } R = r$ (generalmente molto più piccolo di n). Scrivendo R come righe, sappiamo che esistono r vettori $v_1, \dots, v_r$ linearmente indipendenti tali che

$$R = \begin{bmatrix} \text{riga}_1 \\ \text{riga}_2 \\ \vdots \\ \text{riga}_n \end{bmatrix} = \begin{bmatrix} \sum_{s=1}^r \alpha_{1,s} v_s \\ \sum_{s=1}^r \alpha_{2,s} v_s \\ \vdots \\ \sum_{s=1}^r \alpha_{n,s} v_s \end{bmatrix} = \underbrace{\begin{pmatrix} \alpha_{1,1} & \alpha_{1,2} & \cdots & \alpha_{1,r} \\ \alpha_{2,1} & \alpha_{2,2} & \cdots & \alpha_{2,r} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{n,1} & \alpha_{n,2} & \cdots & \alpha_{n,r} \end{pmatrix}}_r \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_r \end{bmatrix}$$

Quindi la nuova condizione non è più che $y^*x \neq -1$, ma che XY^* non abbia l'autovalore -1 , in quanto se avesse un tale autovalore, la matrice originale avrebbe autovalore $1 - 1 = 0$.

Abbiamo quindi che lo spettro è dato da 1 con molteplicità $n - r$ e gli altri autovalori sono

$$1 + \sigma(Y^*X)$$

contati con le loro molteplicità algebriche. Quindi se Y^*X non ha l'autovalore -1 , $I + R$ è invertibile. In tal caso,

$$(I + XY^*)^{-1} = I - X(I_r + Y^*X)^{-1}Y^*$$

che è una generalizzazione della forma scalare.

Verifichiamo che sia l'inversa:

$$\begin{aligned}
(I - X(I_r + Y^*X)^{-1}Y^*)(I + XY^*) &= I + XY^* - X(I_r + Y^*X)^{-1}Y^* - X(I_r + Y^*X)^{-1}Y^*XY^* \\
&= I + X(I - (I_r + Y^*X)^{-1} - (I_r + Y^*X)^{-1}Y^*X)Y^* \\
&= I + X(I_r + Y^*X)^{-1}(I_r + Y^*X - I_r - Y^*X)Y^* = I
\end{aligned}$$

Proposition

Sia $E = I_n + UV^*$ con $U, V \in \mathbb{C}^{n \times k}$, con $k \leq n$. Allora

1. Gli autovalori di E sono 1 con molteplicità algebrica (almeno) $n - k$ e $1 + \sigma_i(V^*U)$ con $i \in \{1, \dots, k\}$. Nel caso in cui $\text{rank } U = \text{rank } V = k$ gli autovalori non nulli di UV^* sono quelli non nulli di V^*U .
2. Dagli autovalori dati ricaviamo che E è invertibile se e solo se -1 non è un autovalore di V^*U .
3. Se E è invertibile allora la sua inversa è

$$E^{-1} = I_n - U(I_k + V^*U)^{-1}V^*$$

Il costo della rappresentazione dell'inversa è

$$k^2(2n - 1) + \mathcal{O}(k^3)$$

5.5 Formula di Sherman–Morrison–Woodbury

La formula di *Sherman–Morrison–Woodbury* non è altro che la formula dell'inversa appena data ma reinterpretata nel caso di correzione di rango (al più k) di una matrice invertibile A .

Sia $B = A + UV^*$ con $\det A \neq 0$ e ci riconduciamo al caso di matrici semi-elementari scrivendo $B = A(I + A^{-1}UV^*)$. Allora a questo punto, dalla condizione classica sugli autovalori, ricaviamo che B è invertibile se e solo se $I_k + V^*A^{-1}U$ è invertibile, cioè se e solo se -1 non è un autovalore di $V^*A^{-1}U$. Stiamo quindi usando $A^{-1}U$ come termine. Quindi la matrice è invertibile se e solo se $V^*A^{-1}U$ non possiede l'autovalore -1 . In tal caso, rappresentiamo la matrice come

$$B^{-1} = (I_n - A^{-1}U(I_k + V^*A^{-1}U)^{-1}V^*)A^{-1}$$

Quindi se siamo bravi a risolvere sistemi con A possiamo correggere il sistema per la matrice B . Se $\det A = 0$, la formula precedente non è applicabile; si può studiare il problema ai minimi quadrati, ma servono formule e ipotesi diverse. Dato un sistema $By = c$, come preprocessing dobbiamo per forza calcolare

$$W = A^{-1}U$$

cioè $A^{-1}u_1, \dots, A^{-1}u_k$, che si ottengono risolvendo k sistemi lineari con matrice A . Chiaramente la fattorizzazione di A si calcola solo una volta; non è necessario formare esplicitamente A^{-1} . Sostituendo

$$B^{-1}c = (I_n - W(I_k + V^*A^{-1}U)^{-1}V^*)A^{-1}c$$

In termini computazionali abbiamo $k+1$ risoluzioni con matrice A . Nel caso volessimo risolvere molteplici sistemi lineari con B allora mettiamo pure V^*A^{-1} nel preprocessing.

Esiste un criterio di vicinanza fra matrici dove due matrici sono vicine se il rango della differenza diviso la dimensione è piccolo, oltre che la distanza in norma. Esiste una topologia che tiene conto sia della distanza in norma che secondo questo criterio.

Teorema Teorema di Lusin (Extra)

Data $f \in L^\infty([0, 1])$ e $\varepsilon > 0$, cioè limitata quasi ovunque. Allora $\exists f_\varepsilon$ continua in $[0, 1]$ ed un

dominio che copre quasi tutto $\Omega_\varepsilon \subseteq [0, 1]$ tale che $\mu(\Omega_\varepsilon) \geq 1 - \varepsilon$ tale che

$$f|_{\Omega_\varepsilon} = f_\varepsilon|_{\Omega_\varepsilon}$$

Questo è un corrispettivo di considerare

$$\text{rank}(B_n - B) = d_n = o(n)$$

dove n è la dimensione. Quindi relativamente a tutto lo spazio il rango è piccolo.

6 Norme vettoriali e matriciali

6.1 Norma infinito e norma indotta

Abbiamo la norma infinito

$$\|x\|_\infty = \max_j |x_j|$$

per $x \in \mathbb{C}^n$. Allora abbiamo

$$\begin{aligned} \|A\|_\infty &= \sup_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} \\ &= \sup_{x \neq 0} \left\| A \frac{x}{\|x\|_\infty} \right\|_\infty \\ &= \sup_{\|x\|_\infty=1} \|Ax\|_\infty \\ &= \max_{\|x\|_\infty=1} \|Ax\|_\infty \quad \left. \begin{array}{l} \downarrow \\ \text{Compattezza} \end{array} \right\} \\ &= \max_{\|x\|_\infty=1} \max_j \left| \sum_{k=1}^n A_{j,k} x_k \right| \\ &\leq \max_j \sum_{k=1}^n |A_{j,k}| \\ &= \left\| \begin{pmatrix} \|\text{row}_1\|_1 \\ \|\text{row}_2\|_1 \\ \vdots \\ \|\text{row}_n\|_1 \end{pmatrix} \right\|_\infty \\ &= \|\text{row}_p\|_1 = \sum_{i=1}^n |A_{p,i}| \quad \left. \begin{array}{l} \downarrow \\ \text{per qualche } p \end{array} \right\} \\ &\quad \left\{ \begin{array}{l} x_1 = e^{-i\varphi_1} \\ x_2 = e^{-i\varphi_2} \\ \dots \\ x_n = e^{-i\varphi_n} \end{array} \right. \quad \left. \begin{array}{l} \downarrow \\ A_{p,i} = |A_{p,i}| e^{i\varphi_i} \end{array} \right\} \end{aligned}$$

Con questa scelta di x , $\|x\|_\infty = 1$ e $|(Ax)_p| = \sum_i |A_{p,i}|$, quindi la maggiorazione è raggiunta e $\|A\|_\infty = \max_j \sum_k |A_{j,k}|$.

Esercizio

Con un argomento analogo, per un dominio compatto $D \subseteq \mathbb{R}$ e un nucleo continuo K , considerare

$$A(f)(x) = \int_D K(x,t) f(t) dt, \quad A: \mathcal{C}[D] \rightarrow \mathcal{C}[D]$$

calcolare

$$\sup_{\|f\|_\infty \leq 1} \|A(f)\|_\infty = \sup_{x \in D} \int_D |K(x,t)| dt$$

Come costruire norme nuove in generale? Sia $\|\cdot\|_*$ su $\mathbb{C}^n$ e $S \in \text{Mat}_n(\mathbb{C})$ invertibile. Allora possiamo definire $\|\cdot\|_{*,S} \triangleq \|S \cdot\|_*$, e quindi per ogni vettore $y \in \mathbb{C}^n$ definire

$$\|y\|_{*,S} = \|Sy\|_* \geq 0$$

Abbiamo

1. $\|y\|_{*,S} = 0$ se e solo se, per definizione $\|Sy\|_* = 0$ se e solo se $Sy = 0$, in quanto pure $\|\cdot\|_*$ è una norma, se e solo se $y = 0$.

2. Sia $\alpha \in \mathbb{C}, y \in \mathbb{C}^n$. Abbiamo che

$$\|\alpha y\|_{*,S} = \|S(\alpha y)\|_* = |\alpha| \cdot \|Sy\|_* = |\alpha| \cdot \|y\|_{*,S}$$

3. Siano $x, y \in \mathbb{C}^n$. Abbiamo che

$$\|x + y\|_{*,S} = \|S(x + y)\|_* = \|Sx + Sy\|_* \leq \|Sx\|_* + \|Sy\|_* = \|x\|_{*,S} + \|y\|_{*,S}$$

L'invertibilità di S serve solo per la prima.

Un altro modo di costruire una norma è quello di fare una combinazione lineare non negativa di altre norme, con almeno un coefficiente strettamente positivo.

$$\sum a_j \|\cdot\|_{*,x_j}, \quad \|\cdot\|_{x_1}, \dots, \|\cdot\|_{x_k} \text{ norme su } \mathbb{C}^n$$

In particolare le combinazioni convesse sono ancora norme. Questo potrebbe essere usato nella creazione di un esame.

Dato $V \in \text{Mat}_n(\mathbb{C})$ studiamo $\|V\|_{*,S}$. Abbiamo

$$\begin{aligned} \|V\|_{*,S} &= \sup_{x \neq 0} \frac{\|Vx\|_{*,S}}{\|x\|_{*,S}} = \sup_{x \neq 0} \frac{\|SVx\|_*}{\|Sx\|_*} \\ &= \sup_{y \neq 0} \frac{\|SVS^{-1}y\|_*}{\|y\|_*} = \|SVS^{-1}\|_* \end{aligned} \quad \left. \vphantom{\sup_{x \neq 0}} \right\} y = Sx$$

La sostituzione è valida in quanto S è invertibile e quindi mappa $\mathbb{C}^n$ in $\mathbb{C}^n$ e ovviamente 0 in 0.

Teorema

Sia $A \in \text{Mat}_n(\mathbb{C})$. Allora,

$$\rho(A) = \inf_{\substack{\|\cdot\| \text{ norma} \\ \text{matriciale indotta}}} \|A\|$$

Proof

Sappiamo che per ogni norma matriciale indotta $\|\cdot\|$

$$\rho(A) \leq \|A\|$$

Sia $\varepsilon > 0$ arbitrariamente piccolo. Cerchiamo una norma matriciale indotta particolare $\|\cdot\|_{*,\varepsilon}$ tale che

$$\|A\|_{*,\varepsilon} \leq \rho(A) + \varepsilon$$

Se troviamo tale norma allora vale la tesi. La norma dipende sia da A che da ε . Scriviamo $A = TJT^{-1}$ con la scomposizione di Jordan. Consideriamo una norma $\|\cdot\|_{*,S}$ con S invertibile. Sappiamo che

$$\|V\|_{*,S} = \|SVS^{-1}\|_*$$

Dobbiamo scegliere S appropriatamente. Scegliamo $S = FT^{-1}$ per qualche F (e T dipende dalla A). Visto che T dipende solo da A , F (che deve essere invertibile per il teorema di Binet) dovrà presumibilmente dipendere da ε . Da questa scomposizione otteniamo la semplificazione

$$\|A\|_{*,S} = \|FT^{-1}(TJT^{-1})TF^{-1}\|_* = \|FJF^{-1}\|_*$$

Ricordiamo che J è bidiagonale superiore (autovalori sulla diagonale, valori 0 o 1 sulla sopradiagonale). Scegliamo $\|\cdot\|_* = \|\cdot\|_\infty$. Dobbiamo scegliere F in maniera tale che il prodotto faccia uscire precisamente gli ε . Cerchiamo una F diagonale in maniera tale che la moltiplicazione scali le righe e le colonne. Vogliamo che gli elementi $(j, j+1)$

$$(FJF^{-1})_{j,j+1} = \frac{F_{j,j}^*}{F_{j+1,j+1}} = \varepsilon \cdot *$$

Allora scegliamo

$$F^{-1} = \text{diag}(1, \varepsilon, \varepsilon^2, \dots, \varepsilon^{n-1})$$

cioè

$$F = \text{diag}(1, \varepsilon^{-1}, \varepsilon^{-2}, \dots, \varepsilon^{1-n})$$

Se i valori sulla diagonale superiore sono 0, allora tutto funziona, il problema era quando sono 1. Abbiamo quindi in conclusione

$$\|A\|_{\infty, FT^{-1}} = \left\| \begin{pmatrix} \lambda_1 & * & & & \\ & \lambda_2 & * & & \\ & & \ddots & \ddots & \\ & & & \lambda_{n-1} & * \\ & & & & \lambda_n \end{pmatrix} \right\|_{\infty} \leq \max_j (|\lambda_j| + |\cdot| \varepsilon) \leq \rho(A) + \varepsilon$$

Abbiamo quindi un invariante algebrico nel teorema sugli spazi di Banach per questo motivo.

6.2 Norme indotte 1, 2 e infinito

Abbiamo visto la norma matriciale indotta dalla norma infinito. Studiamo ora i casi con norma 1 e 2. Partiamo dal caso di $\|\cdot\|_1$. Ci chiediamo qual è la corrispondente norma matriciale indotta. Abbiamo

$$\begin{aligned} \|A\|_1 &= \max_{\|x\|_1=1} \|Ax\|_1 = \max_{\|x\|_1=1} \left\| \sum_{j=1}^n x_j \text{col}_j(A) \right\|_1 \\ &\leq \max_{\|x\|_1=1} \sum_{j=1}^n |x_j| \cdot \|\text{col}_j(A)\|_1 \\ &\leq \left(\underbrace{\max_{\|x\|_1=1} \sum_{j=1}^n |x_j|}_1 \right) \max_j \|\text{col}_j(A)\|_1 \\ &= \max_j \|\text{col}_j(A)\|_1 \end{aligned} \quad \left. \begin{array}{l} \\ \\ \end{array} \right\} \begin{array}{l} \text{Disuguaglianza} \\ \text{triangolare} \end{array}$$

Per completare e dimostrare l'uguaglianza bisogna esibire un particolare vettore per il quale abbiamo l'uguaglianza. Un tale $\hat{x}$ ha $\|\hat{x}\|_1 = 1$ e

$$\|A\hat{x}\|_1 = \max_j \|\text{col}_j(A)\|_1 = \|\text{col}_p(A)\|_1$$

e scegliamo $\hat{x} = e_p$, così selezioniamo precisamente la colonna p . Per le norme infinite guardavamo la righe mentre qua le colonne.

Passiamo ora alla norma 2. Sia V Hermitiana e definita positiva, quindi ordiniamo

$$\lambda_1(V) \leq \dots \leq \lambda_n(V)$$

e vale

$$\lambda_1(V) = \min_{x \neq 0} \frac{x^* V x}{x^* x}, \quad \lambda_n(V) = \max_{x \neq 0} \frac{x^* V x}{x^* x}$$

Possiamo scrivere minimo e massimo al posto di infimum e supremum in quanto possiamo restringerci ad un compatto. Quello che importa è l'angolazione, non andare verso infinito. Per la norma indotta

abbiamo

$$\begin{aligned}\|A\|_2 &= \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\sqrt{x^* A^* A x}}{\sqrt{x^* x}} \\ &= \sqrt{\max_{x \neq 0} \frac{x^* V x}{x^* x}} \\ &= \sqrt{\rho(A^* A)}\end{aligned}$$

Essendo $A^* A$ semidefinita positiva, raggio spettrale e autovalore massimo sono la stessa cosa (per il modulo).

Proposition

Se A è normale, allora $A = QDQ^*$ con D diagonale complessa. Ma allora

$$A^* A = Q \operatorname{diag}(|\lambda_i|^2) Q^*$$

in quanto

$$\lambda_{\max}(A^* A) = \max_j |\lambda_j(A)|^2 = \rho(A)^2$$

e la norma indotta è

$$\|A\|_2 = \rho(A)$$

Quindi questo vale non solo per le Hermitiane.

7 Decomposizione ai valori singolari

Notiamo che la parola decomposizione è distinta da una fattorizzazione e non è nemmeno una forma normale.

Teorema Decomposizione ai valori singolari

Sia $A \in \mathbb{C}^{n \times m}$. Allora, $\exists U \in \text{Mat}_n(\mathbb{C}), V \in \text{Mat}_m(\mathbb{C})$ unitarie ed $\exists \Sigma \in \mathbb{R}_{\geq 0}^{n \times m}$ con Σ tale che $\Sigma_{j,k} = 0$ se $j \neq k$ e tale che

$$A = U \Sigma V^*, \quad \Sigma_{j,j} = \sigma_j, j \in \{1, \dots, \min\{n, m\}\}$$

dove σ_j sono i *valori singolari*. In particolare,

$$\sigma_1 = \|A\|_2 \geq \sigma_2 \geq \dots \geq \sigma_p > 0, \quad 0 = \sigma_{p+1} = \dots = \sigma_{\min\{n, m\}}$$

quindi p è il rango di A ; se $p = 0$ tutti i valori singolari sono nulli, e se $p = \min\{n, m\}$ la coda nulla è assente.

Nel processing delle immagini viene utilizzata questa decomposizione in quanto la gran parte dell'informazione è contenuta nel rango basso.

Proof Decomposizione ai valori singolari

Distinguiamo due casi.

- $n \geq m$: procediamo per induzione su m . Il caso base è $(n, 1)$. Abbiamo quindi A vettore con elementi a . Consideriamo la matrice di Householder

$$Ha = \begin{pmatrix} \alpha \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad H = I - \frac{2vv^*}{\|v\|_2^2} \quad (v \neq 0)$$

Ma quindi $\alpha = |\alpha|e^{i\theta}$, e sostituendo

$$Ha = \begin{pmatrix} |\alpha| \\ 0 \\ \vdots \\ 0 \end{pmatrix} [e^{i\theta}], \quad a = H \begin{pmatrix} |\alpha| \\ 0 \\ \vdots \\ 0 \end{pmatrix} [e^{i\theta}]$$

Notando che le matrici unitarie mantengono la norma due, per completare osserviamo che

$$|\alpha| = \|a\|_2 = \|A\|_2$$

Sia ora $A \in \mathbb{C}^{n \times m}$ e $m \geq 2$. Se $A = 0$, la tesi è immediata con $\Sigma = 0$; supponiamo quindi $A \neq 0$. Notiamo che

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|$$

che vogliamo essere il nostro σ_1 . Essendo un massimo, ci deve essere un vettore che lo realizza. Sia $\hat{x}$ tale che $\|\hat{x}\| = 1$ e $y = A\hat{x}$ con $\|y\|_2 = \|A\|_2$. Definiamo quindi

$$\hat{V} = \left[\begin{array}{c|c|c|c} \hat{x} & s_2 & \cdots & s_m \end{array} \right] \in \text{Mat}_m(\mathbb{C})$$

Costruiamo un'altra unitaria

$$\hat{U} = \left[\begin{array}{c} \frac{1}{\|A\|} y^* \\ t_2^* \\ \vdots \\ t_n^* \end{array} \right] \in \text{Mat}_n(\mathbb{C})$$

Studiamo quindi

$$\hat{U}A\hat{V} = \hat{U} \left[\begin{array}{c|c|c|c} y & \hat{s}_2 & \cdots & \hat{s}_m \end{array} \right]$$

Ma eseguendo il prodotto troviamo

$$\frac{1}{\|A\|} y^* y = \frac{\|y\|_2^2}{\|A\|_2} = \|A\|_2$$

quindi il primo elemento in testa è $\|A\|$

$$\hat{U}A\hat{V} = \left[\begin{array}{c|c} \frac{\|A\|}{0} & c^* \\ \vdots & \hat{A} \\ 0 & \end{array} \right]$$

Tuttavia non possiamo ancora applicare l'ipotesi induttiva. Ricordiamo che $\|Pv\|_2 = \|v\|_2$ sempre per ogni P unitaria. Ma allora,

$$\begin{aligned} \|\hat{U}A\hat{V}\|_2 &= \max_{\|x\|=1} \|\hat{U}A\hat{V}x\|_2 \\ &= \max_{\|y\|_2=1} \|\hat{U}Ay\|_2 = \max_{\|y\|_2=1} \|Ay\|_2 = \|A\| \end{aligned} \quad \left. \vphantom{\max_{\|y\|_2=1}} \right\} y = \hat{V}x$$

Vogliamo mostrare che c^* deve essere nullo. Per mostrarlo scegliamo un vettore che lo mostra, denotando $B = \hat{U}A\hat{V}$

$$\begin{aligned} \|B\|_2 &\geq \left\| \begin{pmatrix} \|A\|_2 \\ c \end{pmatrix} \right\|_2 \cdot \frac{1}{\left\| \begin{pmatrix} \|A\|_2 \\ c \end{pmatrix} \right\|_2} \\ &= \frac{1}{\sqrt{\|A\|_2^2 + \|c\|_2^2}} \left\| \begin{pmatrix} \|A\|_2^2 + \|c\|_2^2 \\ \hat{A}c \end{pmatrix} \right\|_2 \\ &\geq \frac{1}{\sqrt{\|A\|_2^2 + \|c\|_2^2}} \left\| \begin{pmatrix} \|A\|_2^2 + \|c\|_2^2 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \right\|_2 \quad \left. \vphantom{\left\| \begin{pmatrix} \|A\|_2^2 + \|c\|_2^2 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \right\|_2} \right\} \text{Minoriando ignorando} \\ &\quad \text{la componente } \hat{A}c \\ &= \frac{\|A\|_2^2 + \|c\|_2^2}{\sqrt{\|A\|_2^2 + \|c\|_2^2}} \\ &= \sqrt{\|A\|_2^2 + \|c\|_2^2} \geq \|A\|_2 \end{aligned}$$

Ma se c avesse anche solo una componente non-nulla, allora avremmo il segno maggiore stretto. Ma quindi, deve essere per forza $c = 0$. Siccome $c = 0$, possiamo applicare l'ipotesi induttiva e segue il teorema Allora scriviamo

$$\hat{A} = \tilde{U}\tilde{\Sigma}\tilde{V}^*$$

con $\tilde{\Sigma}_{1,1} \geq \tilde{\Sigma}_{2,2} \geq \dots$. Troviamo quindi

$$\begin{aligned}
\hat{U}A\hat{V} &= \left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \hat{A} & \\ 0 & & & \end{array} \right] = \left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{U}\tilde{\Sigma}\tilde{V}^* & \\ 0 & & & \end{array} \right] \\
&= \left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{U} & \\ 0 & & & \end{array} \right] \left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{\Sigma} & \\ 0 & & & \end{array} \right] \left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{V}^* & \\ 0 & & & \end{array} \right] \\
A = \hat{U}^* &\underbrace{\left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{U} & \\ 0 & & & \end{array} \right]}_U \underbrace{\left[\begin{array}{c|ccc} \|A\|_2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{\Sigma} & \\ 0 & & & \end{array} \right]}_\Sigma \underbrace{\left[\begin{array}{c|ccc} 1 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & \tilde{V}^* & \\ 0 & & & \end{array} \right]}_{V^*} \hat{V}^*
\end{aligned}$$

che hanno la forma giusta e soddisfano tutte le proprietà per ipotesi induttiva. Inoltre, quando ricaviamo la norma di $\|A\|_2$ nel caso base, la norma è unica. L'unicità di tutti i valori singolari segue da $\sigma_j^2 \in \sigma(A^*A)$, contati con molteplicità e ordinati in senso decrescente.

- $n < m$: Sia $B = A^*$. Adesso possiamo utilizzare il primo caso

$$B = A^* = U_B \Sigma_B V_B^*, \quad \Sigma_B = \text{diag}(\sigma_1(B), \sigma_2(B), \dots, \sigma_p(B), 0, \dots, 0)$$

Con le proprietà che

$$\sigma_1(B) = \|B\|_2 \geq \sigma_2(B) \geq \dots \geq \sigma_p(B) > 0, \quad 0 = \sigma_{p+1}(B) = \dots = \sigma_n(B)$$

Riapplicando la trasposta coniugata otteniamo

$$A = B^* = V_B \Sigma_B^T U_B^*$$

dove V_B è unitaria in $\text{Mat}_n(\mathbb{C})$ e U_B^* è unitaria in $\text{Mat}_m(\mathbb{C})$. Scegliendo quindi $U = V_B$, $\Sigma = \Sigma_B^T$ e $V = U_B$, troviamo la tesi se mostriamo anche le proprietà aggiuntive. Sappiamo che $p = \text{rank}(B) = \text{rank}(A)$ e che

$$\sigma_1(B) = \|B\|_2 = \sqrt{\rho(B^*B)} = \sqrt{\rho(AA^*)} = \sqrt{\rho(A^*A)} = \|A\|_2 = \sigma_1(A)$$

usando la commutazione degli autovalori (gli zeri aggiuntivi nello spettro non ci interessano).

Nel caso normale, i moduli degli autovalori sono i valori singolari dopo averli ordinati.

8 Approssimazione polinomiale e operatori positivi

8.1 Operatori positivi e polinomi di Bernstein

Consideriamo lo spazio $\mathcal{C}([0, 1])$ di funzioni continue a valori reali su $[0, 1]$. Vogliamo esibire una successione $P_n(x)$ di polinomi tale che

$$\|f - P_n\|_{\infty, [0, 1]} \rightarrow 0$$

per $n \rightarrow +\infty$.

Definizione Operatore lineare positivo

Sia

$$\phi: (\mathcal{A}, \leq_{\mathcal{A}}) \rightarrow (\mathcal{B}, \leq_{\mathcal{B}})$$

Diciamo che ϕ è *lineare positivo* (LPO) se $\mathcal{A}, \mathcal{B}$ spazi vettoriali con ordinamenti parziali tale che:

1.

$$\phi(\alpha f + \beta g) = \alpha \phi(f) + \beta \phi(g)$$

per ogni $f, g \in \mathcal{A}$ e per ogni $\alpha, \beta \in \mathbb{R}$. Gli ordinamenti sono compatibili con le operazioni degli spazi vettoriali reali.

2. Se $f \geq_{\mathcal{A}} 0_{\mathcal{A}}$ allora

$$\phi(f) \geq_{\mathcal{B}} 0_{\mathcal{B}}$$

Definizione Polinomi di Bernstein

Consideriamo $\mathcal{C}([0, 1])$ e $f \in \mathcal{C}([0, 1])$. Per $n \geq 1$, un *polinomio di Bernstein* è definito come

$$B_n(f)(x) = \sum_{k=0}^n f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k}$$

con $B_n: \mathcal{C}([0, 1]) \rightarrow \mathcal{C}([0, 1])$. Equipaggiamo inoltre l'ordinamento $f \geq g$ se e solo se $f(x) \geq g(x)$ per ogni $x \in [0, 1]$.

Se fosse stato uno spazio L^p al posto di un per ogni avremmo un quasi ovunque. L'oggetto $B_n(f)$ è un polinomio di grado al più n , in quanto combinazione lineare di tali.

Proposition

B_n è un endooperatore lineare positivo in $\mathcal{C}([0, 1])$ per ogni $n \geq 1$.

Proof

Siano $\alpha, \beta \in \mathbb{R}$ e $f, g \in \mathcal{C}([0, 1])$. Abbiamo

$$\begin{aligned} B_n(\alpha f + \beta g)(x) &= \sum_{k=0}^n (\alpha f + \beta g)\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k} \\ &= \sum_{k=0}^n \left(\alpha f\left(\frac{k}{n}\right) + \beta g\left(\frac{k}{n}\right) \right) \binom{n}{k} x^k (1-x)^{n-k} \\ &= \alpha \sum_{k=0}^n f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k} + \beta \sum_{k=0}^n g\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k} \\ &= \alpha B_n(f) + \beta B_n(g) \end{aligned}$$

quindi è lineare. Per la positività vediamo, se $f \geq 0$ allora $f(k/n) \geq 0$ e quindi dalla definizione otteniamo una somma di termini non negativi su $[0, 1]$.

Proposition

Un operatore lineare positivo $\phi: \mathcal{C}([0, 1]) \rightarrow \mathcal{C}([0, 1])$ è monotono (isotono) e soddisfa $|\phi(f)| \leq \phi(|f|)$.

Proof

1. per la monotonia notiamo che $f - g \geq 0$, allora $\phi(f - g) \geq 0$, ma quindi per linearità $\phi(f) - \phi(g) \geq 0$ cioè $\phi(f) \geq \phi(g)$.
2. per la disuguaglianza con il modulo notiamo che $-|f| \leq f \leq |f|$. Per la monotonia abbiamo che $-\phi(|f|) \leq \phi(f) \leq \phi(|f|)$ da cui troviamo che $|\phi(f)| \leq \phi(|f|)$.

Gli integrali di funzioni positive sono operatori lineari positivi.

Teorema Teorema di Korovkin in una dimensione

Sia $\{\phi_n\}$ una successione di endooperatori lineari positivi su $\mathcal{C}(K)$, con K compatto di $\mathbb{R}$. Supponiamo che

$$\|\phi_n(y^j)(x) - x^j\|_{\infty, K} \rightarrow 0$$

per $n \rightarrow +\infty$ con $j = 0, 1, 2$, allora $\forall f \in \mathcal{C}(K)$,

$$\|\phi_n(f(y)) - f(x)\|_{\infty, K} \rightarrow 0$$

per $n \rightarrow +\infty$.

Proof

Scriviamo

$$\phi_n(y^j)(x) = x^j + \varepsilon_n^{(j)}(x), \quad \|\varepsilon_n^{(j)}(x)\|_{\infty, K} \rightarrow 0$$

per $n \rightarrow \infty$. Fissiamo $f \in \mathcal{C}(K)$ e fissiamo $\varepsilon > 0$. Dobbiamo trovare n_ε tale che $\forall n \geq n_\varepsilon$

$$\Delta_n(f, x) \triangleq |\phi_n(f(y))(x) - f(x)| \leq \varepsilon, \quad \forall x \in K$$

Quel $\forall x \in K$ ci dà la convergenza uniforme. Scriviamo ora

$$\begin{aligned} \Delta_n(f, x) &= |\phi_n(f(y))(x) - (\phi_n(1)(x) - \varepsilon_n^{(0)}(x))f(x)| \\ &= |\phi_n(f(y))(x) - f(x) \cdot \phi_n(1)(x) + \varepsilon_n^{(0)}(x)f(x)| \\ &\leq |\phi_n(f(y))(x) - f(x)\phi_n(1)(x)| + \|\varepsilon_n^{(0)}\|_{\infty, K} \cdot \|f\|_{\infty, K} \\ &\leq |\phi_n(f(y))(x) - f(x)\phi_n(1)(x)| + \varepsilon/3, \quad \forall n \geq n_\varepsilon \\ &= |\phi_n(f(y) - f(x))(x)| + \varepsilon/3 \\ &\leq \phi_n(|f(y) - f(x)|)(x) + \varepsilon/3 \end{aligned} \quad \begin{array}{l} \left. \begin{array}{l} \text{Disuguaglianza} \\ \text{triangolare} \end{array} \right\} \\ \left. \begin{array}{l} \text{positività} \end{array} \right\} \end{array}$$

Visto che siamo su un compatto, la continuità implica la continuità uniforme, quindi $\forall \tilde{\varepsilon} > 0$ esiste $\tilde{\delta} > 0$ tale che se $|x - y| < \tilde{\delta}$ allora $|f(y) - f(x)| < \tilde{\varepsilon}$ per tutte le $x, y \in K$. Siccome questa ultima condizione vale solo quando $|y - x| < \tilde{\delta}$, possiamo estenderla scrivendo

$$|f(y) - f(x)| \leq \tilde{\varepsilon} + 2\|f\|_{\infty, K} \chi_{\{y \mid \tilde{\delta} \leq |y-x|\}}(y)$$

Infatti, quando $|y - x| < \tilde{\delta}$ usiamo la continuità uniforme, mentre nell'altro caso maggioriamo $|f(y) - f(x)|$ con $|f(y)| + |f(x)|$, e a loro volta maggioriamo ognuno di questi con $\|f\|_{\infty, K}$. Per y tale che $|y - x| \geq \tilde{\delta}$, vale che $|y - x|/\tilde{\delta} \geq 1$, ma questo è equivalente a dire che $(y - x)^2/\tilde{\delta}^2 \geq 1$. Quindi possiamo aggiornare la maggiorazione a

$$|f(y) - f(x)| \leq \tilde{\varepsilon} + 2\|f\|_{\infty, K} \frac{(y - x)^2}{\tilde{\delta}^2}$$

Sostituendo questa troviamo che per monotonia

$$\begin{aligned}
\Delta_n(f, x) &\leq \phi_n \left(\frac{y^2 - 2xy + x^2}{\tilde{\delta}^2} \cdot 2\|f\|_{\infty, K} + \tilde{\varepsilon} \right) (x) + \frac{\varepsilon}{3} \\
&= \tilde{\varepsilon} \phi_n(1)(x) + 2 \frac{\|f\|_{\infty, K}}{\tilde{\delta}^2} [\phi_n(y^2)(x) - 2x\phi_n(y)(x) + x^2\phi_n(1)(x)] + \frac{\varepsilon}{3} \\
&= \tilde{\varepsilon}(1 + \varepsilon_n^{(0)}(x)) + 2 \frac{\|f\|_{\infty, K}}{\tilde{\delta}^2} \left[x^2 + \varepsilon_n^{(2)}(x) - 2x \left(x + \varepsilon_n^{(1)}(x) \right) + x^2 \left(1 + \varepsilon_n^{(0)}(x) \right) \right] + \frac{\varepsilon}{3} \\
&\leq \frac{2}{3}\varepsilon + 2 \frac{\|f\|_{\infty, K}}{\tilde{\delta}^2} \left| \varepsilon_n^{(2)}(x) - 2x\varepsilon_n^{(1)}(x) + x^2\varepsilon_n^{(0)}(x) \right|
\end{aligned}$$

$\left. \vphantom{\frac{\varepsilon}{3}} \right\} \text{Scegliendo } \tilde{\varepsilon} = \varepsilon/6$

dove abbiamo anche scelto n_ε abbastanza grande da avere $\|\varepsilon_n^{(0)}\|_{\infty, K} \leq 1$. Poiché K è compatto, poniamo

$$\hat{M} = \sup_{x \in K} |x| < +\infty.$$

Otteniamo quindi la successione numerica che va a zero

$$Q_n \triangleq \frac{2\|f\|_{\infty, K}}{\tilde{\delta}^2} \left(\|\varepsilon_n^{(2)}\|_{\infty, K} + 2\hat{M}\|\varepsilon_n^{(1)}\|_{\infty, K} + \hat{M}^2\|\varepsilon_n^{(0)}\|_{\infty, K} \right) < \frac{\varepsilon}{3}$$

per $n \geq n_\varepsilon$. Quindi, per ogni $x \in K$, abbiamo

$$\Delta_n(f, x) \leq \frac{2}{3}\varepsilon + Q_n < \varepsilon,$$

e dunque

$$\|\phi_n(f(y)) - f(x)\|_{\infty, K} \rightarrow 0.$$

Il teorema può essere esteso, sotto ipotesi opportune, anche alla convergenza in L^p .

Vediamo il test di Korovkin sugli operatori di Bernstein $B_n(\cdot)$ su $[0, 1]$. Abbiamo

1. Vediamo se $B_n(1)(x)$ converge a 1. Abbiamo

$$\sum_{k=0}^n \binom{n}{k} x^k (1-x)^{n-k} = ((1-x) + x)^n = 1$$

e quindi $\varepsilon_n^{(0)} = 0$.

2. Vediamo se $B_n(y)(x)$ converge a x . Abbiamo

$$\begin{aligned}
B_n(y)(x) &= \sum_{k=0}^n \binom{n}{k} \frac{k}{n} x^k (1-x)^{n-k} \\
&= \sum_{k=1}^n \binom{n}{k} \frac{k}{n} x^k (1-x)^{n-k} \\
&= x \sum_{k=1}^n \binom{n-1}{k-1} x^{k-1} (1-x)^{n-k} \\
&= x \cdot \sum_{q=0}^{n-1} \binom{n-1}{q} x^q (1-x)^{n-1-q} \\
&= x
\end{aligned}$$

quindi $\varepsilon_n^{(1)} = 0$.

3. Vediamo se $B_n(y^2)(x)$ converge a x^2 . Per definizione,

$$B_n(f)(x) = \sum_{k=0}^n \binom{n}{k} f\left(\frac{k}{n}\right) x^k (1-x)^{n-k}.$$

Dunque, per $n \geq 2$,

$$\begin{aligned} B_n(y^2)(x) &= \sum_{k=0}^n \binom{n}{k} \left(\frac{k}{n}\right)^2 x^k (1-x)^{n-k} \\ &= \sum_{k=1}^n \binom{n}{k} \left(\frac{k}{n}\right)^2 x^k (1-x)^{n-k} \\ &= \frac{x}{n} \sum_{k=1}^n k \binom{n}{k} \frac{k}{n} x^{k-1} (1-x)^{n-k}. \end{aligned}$$

Usando l'identità

$$k \binom{n}{k} = n \binom{n-1}{k-1},$$

otteniamo

$$B_n(y^2)(x) = x \sum_{k=1}^n \binom{n-1}{k-1} \frac{k}{n} x^{k-1} (1-x)^{n-k}.$$

Scriviamo

$$\frac{k}{n} = \frac{1}{n} + \frac{n-1}{n} \frac{k-1}{n-1}.$$

Allora

$$\begin{aligned} B_n(y^2)(x) &= x \sum_{k=1}^n \binom{n-1}{k-1} \left(\frac{1}{n} + \frac{n-1}{n} \frac{k-1}{n-1} \right) x^{k-1} (1-x)^{n-k} \\ &= \frac{x}{n} \sum_{k=1}^n \binom{n-1}{k-1} x^{k-1} (1-x)^{n-k} \\ &\quad + \frac{x(n-1)}{n} \sum_{k=1}^n \binom{n-1}{k-1} \frac{k-1}{n-1} x^{k-1} (1-x)^{n-k}. \end{aligned}$$

Facendo il cambio di variabile $j = k - 1$, si ha

$$\sum_{k=1}^n \binom{n-1}{k-1} x^{k-1} (1-x)^{n-k} = B_{n-1}(1)(x) = 1,$$

mentre

$$\sum_{k=1}^n \binom{n-1}{k-1} \frac{k-1}{n-1} x^{k-1} (1-x)^{n-k} = B_{n-1}(y)(x) = x.$$

Quindi

$$\begin{aligned} B_n(y^2)(x) &= \frac{x}{n} + \frac{x(n-1)}{n} x \\ &= \frac{x}{n} + \frac{n-1}{n} x^2 \\ &= x^2 + \frac{x(1-x)}{n}. \end{aligned}$$

Pertanto, se poniamo

$$\varepsilon_n^{(2)}(x) = B_n(y^2)(x) - x^2,$$

allora

$$\varepsilon_n^{(2)}(x) = \frac{x(1-x)}{n}.$$

Poiché

$$0 \leq x(1-x) \leq \frac{1}{4} \quad \forall x \in [0, 1],$$

si ottiene

$$\|\varepsilon_n^{(2)}\|_{\infty, [0, 1]} \leq \frac{1}{4n} \xrightarrow{n \rightarrow \infty} 0.$$

Teorema Teorema di Weierstrass in $\mathbb{R}$

Sia $K \subseteq \mathbb{R}$ compatto. Per ogni $f \in C(K)$ esiste una successione di polinomi $\{P_n\}$ tale che

$$\|f - P_n\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Proof

Procediamo per passi.

Passo 1: $K = [0, 1]$.

Consideriamo gli operatori di Bernstein

$$B_n : C([0, 1]) \longrightarrow C([0, 1]).$$

Per costruzione $B_n(f)$ è un polinomio di grado al più n . Inoltre B_n è lineare positivo. Abbiamo verificato che

$$B_n(1) = 1, \quad B_n(X) = X, \quad \|B_n(X^2) - X^2\|_{\infty, [0, 1]} \rightarrow 0.$$

Quindi B_n soddisfa il test di Korovkin su $[0, 1]$. Per il teorema di Korovkin segue che

$$\|B_n(f) - f\|_{\infty, [0, 1]} \xrightarrow{n \rightarrow \infty} 0 \quad \forall f \in C([0, 1]).$$

Passo 2: $K = [a, b]$, con $a < b$.

Sia $f \in C([a, b])$. Definiamo

$$g(t) = f(a + (b-a)t), \quad t \in [0, 1].$$

Allora $g \in C([0, 1])$. Per il passo precedente,

$$\|g - B_n(g)\|_{\infty, [0, 1]} \xrightarrow{n \rightarrow \infty} 0.$$

Per $x \in [a, b]$ poniamo

$$t = \frac{x-a}{b-a}.$$

Allora $t \in [0, 1]$ e

$$f(x) = g\left(\frac{x-a}{b-a}\right).$$

Definiamo quindi

$$P_n(x) = B_n(g)\left(\frac{x-a}{b-a}\right).$$

Essendo composizione di un polinomio con un'affinità, P_n è un polinomio in x . Inoltre

$$\begin{aligned} \|f - P_n\|_{\infty, [a, b]} &= \max_{x \in [a, b]} \left| f(x) - B_n(g)\left(\frac{x-a}{b-a}\right) \right| \\ &= \max_{t \in [0, 1]} |g(t) - B_n(g)(t)| \\ &= \|g - B_n(g)\|_{\infty, [0, 1]} \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

Passo 3: $K \subseteq \mathbb{R}$ compatto generico.

Scegliamo un intervallo $[a, b]$ tale che

$$K \subseteq (a, b).$$

Per il teorema di estensione di Tietze, per ogni $f \in C(K)$ esiste $\tilde{f} \in C([a, b])$ tale che

$$\tilde{f}|_K = f.$$

Eventualmente si può scegliere l'estensione in modo che

$$\tilde{f}(a) = \tilde{f}(b) = 0.$$

Per il passo precedente esiste una successione di polinomi $\{P_n\}$ tale che

$$\|\tilde{f} - P_n\|_{\infty, [a, b]} \xrightarrow{n \rightarrow \infty} 0.$$

Restringendo a K , otteniamo

$$\|f - P_n\|_{\infty, K} \leq \|\tilde{f} - P_n\|_{\infty, [a, b]} \xrightarrow{n \rightarrow \infty} 0.$$

Questo conclude la dimostrazione.

Proposition Osservazione sul test di Korovkin in dimensione 1

Sia $K = [a, b]$ e sia

$$\Phi : C(K) \longrightarrow C(K)$$

un operatore lineare positivo. Se Φ riproduce esattamente le funzioni test

$$1, \quad X, \quad X^2,$$

cioè

$$\Phi(1) = 1, \quad \Phi(X) = X, \quad \Phi(X^2) = X^2,$$

allora $\Phi(f) = f$ per ogni $f \in C^2(K)$.

In particolare, per un operatore non banale non ci si aspetta che gli errori del test di Korovkin siano esattamente nulli; è sufficiente che tendano a zero uniformemente.

Proof

Fissiamo $f \in C^2(K)$ e $x \in K$. Scriviamo $Y(t) = t$, per distinguere la variabile della funzione dal punto x in cui si valuta l'operatore.

Per il teorema di Taylor, per ogni $y \in K$ esiste un punto $\xi_{x,y}$ compreso tra x e y tale che

$$f(y) = f(x) + f'(x)(y - x) + \frac{f''(\xi_{x,y})}{2}(y - x)^2.$$

Quindi

$$f(y) - f(x) = f'(x)(y - x) + \frac{f''(\xi_{x,y})}{2}(y - x)^2.$$

Applicando Φ e usando linearità e positività,

$$\begin{aligned} |\Phi(f)(x) - f(x)| &= |\Phi(f(Y) - f(x))(x)| \\ &\leq |f'(x)\Phi(Y - x)(x)| + \frac{1}{2} \|f''\|_{\infty, K} \Phi((Y - x)^2)(x). \end{aligned}$$

Ora

$$\Phi(Y - x)(x) = \Phi(Y)(x) - x\Phi(1)(x) = x - x = 0,$$

e

$$\begin{aligned}\Phi((Y-x)^2)(x) &= \Phi(Y^2 - 2xY + x^2)(x) \\ &= \Phi(Y^2)(x) - 2x\Phi(Y)(x) + x^2\Phi(1)(x) \\ &= x^2 - 2x^2 + x^2 \\ &= 0.\end{aligned}$$

Pertanto

$$|\Phi(f)(x) - f(x)| = 0 \quad \forall x \in K,$$

da cui $\Phi(f) = f$.

Teorema Teorema di Korovkin in $\mathbb{R}^d$

Sia $K \subseteq \mathbb{R}^d$ compatto e siano

$$\Phi_n : C(K) \longrightarrow C(K)$$

operatori lineari positivi.

Supponiamo che

$$\|\Phi_n(g) - g\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0$$

per ogni

$$g \in T, \quad T = \{1, X_1, \dots, X_d, X_1^2 + \dots + X_d^2\}$$

Allora, per ogni $f \in C(K)$,

$$\|\Phi_n(f) - f\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Proof

Indichiamo con

$$\rho(X) = X_1^2 + \dots + X_d^2 = \|X\|^2.$$

L'ipotesi sul test di Korovkin equivale a dire che, per ogni $g \in T$,

$$\Phi_n(g)(x) = g(x) + \varepsilon_n^{(g)}(x), \quad \left\| \varepsilon_n^{(g)} \right\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0$$

Fissiamo $f \in C(K)$ e $\varepsilon > 0$. Poiché K è compatto, f è uniformemente continua. Quindi esiste $\delta > 0$ tale che

$$\|y - x\| < \delta \implies |f(y) - f(x)| < \frac{\varepsilon}{3} \quad \forall x, y \in K$$

Inoltre, se $\|y - x\| \geq \delta$, allora

$$|f(y) - f(x)| \leq 2\|f\|_{\infty, K} \leq \frac{2\|f\|_{\infty, K}}{\delta^2} \|y - x\|^2.$$

Combinando le due stime, otteniamo per ogni $x, y \in K$:

$$|f(y) - f(x)| \leq \frac{\varepsilon}{3} + \frac{2\|f\|_{\infty, K}}{\delta^2} \|y - x\|^2.$$

Fissiamo ora $x \in K$. Scrivendo $Y = (Y_1, \dots, Y_d)$ per la variabile della funzione su cui agisce Φ_n , abbiamo

$$\Phi_n(f)(x) - f(x) = \Phi_n(f(Y) - f(x))(x) + f(x)(\Phi_n(1)(x) - 1).$$

Pertanto

$$\begin{aligned}|\Phi_n(f)(x) - f(x)| &\leq \Phi_n(|f(Y) - f(x)|)(x) + \|f\|_{\infty, K} \left| \varepsilon_n^{(1)}(x) \right| \\ &\leq \frac{\varepsilon}{3} \Phi_n(1)(x) + \frac{2\|f\|_{\infty, K}}{\delta^2} \Phi_n(\|Y - x\|^2)(x) + \|f\|_{\infty, K} \left| \varepsilon_n^{(1)}(x) \right|.\end{aligned}$$

Studiamo il termine quadratico. Poiché

$$\|Y - x\|^2 = \|Y\|^2 - 2 \sum_{i=1}^d x_i Y_i + \|x\|^2,$$

si ha

$$\begin{aligned} \Phi_n(\|Y - x\|^2)(x) &= \Phi_n(\rho)(x) - 2 \sum_{i=1}^d x_i \Phi_n(Y_i)(x) + \|x\|^2 \Phi_n(1)(x) \\ &= \|x\|^2 + \varepsilon_n^{(\rho)}(x) - 2 \sum_{i=1}^d x_i \left(x_i + \varepsilon_n^{(X_i)}(x) \right) \\ &\quad + \|x\|^2 \left(1 + \varepsilon_n^{(1)}(x) \right) \\ &= \varepsilon_n^{(\rho)}(x) - 2 \sum_{i=1}^d x_i \varepsilon_n^{(X_i)}(x) + \|x\|^2 \varepsilon_n^{(1)}(x). \end{aligned}$$

Poiché K è compatto, esiste $M > 0$ tale che

$$\|x\| \leq M \quad \forall x \in K.$$

Dunque

$$\left\| \Phi_n(\|Y - \cdot\|^2)(\cdot) \right\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Inoltre

$$\Phi_n(1)(x) = 1 + \varepsilon_n^{(1)}(x),$$

quindi $\Phi_n(1) \rightarrow 1$ uniformemente. Scegliendo n sufficientemente grande, tutti i termini d'errore precedenti sono minori di quanto serve affinché

$$|\Phi_n(f)(x) - f(x)| < \varepsilon \quad \forall x \in K.$$

Ne segue

$$\|\Phi_n(f) - f\|_{\infty, K} \xrightarrow{n \rightarrow \infty} 0.$$

Vogliamo ora dimostrare una versione multidimensionale del teorema di Weierstrass.

Teorema Teorema di Weierstrass in $\mathbb{R}^d$

Sia $K \subseteq \mathbb{R}^d$ compatto. Per ogni $f \in C(K)$ esiste una famiglia di polinomi $\{P_{\mathbf{n}}\}_{\mathbf{n}}$, con

$$\mathbf{n} = (n_1, \dots, n_d) \in (\mathbb{N}^+)^d,$$

tale che

$$\|P_{\mathbf{n}} - f\|_{\infty, K} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Si può scegliere $P_{\mathbf{n}}$ di grado al più n_i nella variabile X_i .

Per dimostrare il risultato, cominciamo definendo i polinomi di Bernstein multidimensionali su $[0, 1]^d$.

Siano

$$\mathbf{n} = (n_1, \dots, n_d), \quad \mathbf{k} = (k_1, \dots, k_d),$$

con

$$0 \leq k_i \leq n_i \quad \forall i = 1, \dots, d.$$

Poniamo

$$\binom{\mathbf{n}}{\mathbf{k}} = \prod_{i=1}^d \binom{n_i}{k_i},$$

$$x^{\mathbf{k}} = \prod_{i=1}^d x_i^{k_i}, \quad (1-x)^{\mathbf{n}-\mathbf{k}} = \prod_{i=1}^d (1-x_i)^{n_i-k_i}.$$

Allora, per $f \in C([0,1]^d)$, definiamo

$$B_{\mathbf{n}}(f)(x) = \sum_{k_1=0}^{n_1} \cdots \sum_{k_d=0}^{n_d} f\left(\frac{k_1}{n_1}, \dots, \frac{k_d}{n_d}\right) \prod_{i=1}^d \binom{n_i}{k_i} x_i^{k_i} (1-x_i)^{n_i-k_i}.$$

In notazione multi-indice:

$$B_{\mathbf{n}}(f)(x) = \sum_{\mathbf{k}=0}^{\mathbf{n}} \binom{\mathbf{n}}{\mathbf{k}} f\left(\frac{\mathbf{k}}{\mathbf{n}}\right) x^{\mathbf{k}} (1-x)^{\mathbf{n}-\mathbf{k}},$$

dove

$$\frac{\mathbf{k}}{\mathbf{n}} = \left(\frac{k_1}{n_1}, \dots, \frac{k_d}{n_d}\right).$$

Proof Dimostrazione del teorema di Weierstrass in $\mathbb{R}^d$

Consideriamo prima il caso $K = [0,1]^d$.

Gli operatori $B_{\mathbf{n}}$ sono lineari positivi. Inoltre,

$$B_{\mathbf{n}}(1) = 1.$$

Per ogni $i = 1, \dots, d$, poiché la variabile X_i dipende solo dalla i -esima coordinata,

$$B_{\mathbf{n}}(X_i) = X_i.$$

Analogamente, usando il calcolo unidimensionale già fatto,

$$B_{\mathbf{n}}(X_i^2)(x) = x_i^2 + \frac{x_i(1-x_i)}{n_i}.$$

Quindi

$$\begin{aligned} B_{\mathbf{n}}(X_1^2 + \cdots + X_d^2)(x) &= \sum_{i=1}^d B_{\mathbf{n}}(X_i^2)(x) \\ &= \sum_{i=1}^d x_i^2 + \sum_{i=1}^d \frac{x_i(1-x_i)}{n_i}. \end{aligned}$$

Perciò

$$|B_{\mathbf{n}}(X_1^2 + \cdots + X_d^2)(x) - (X_1^2 + \cdots + X_d^2)(x)| = \sum_{i=1}^d \frac{x_i(1-x_i)}{n_i}.$$

Siccome

$$0 \leq x_i(1-x_i) \leq \frac{1}{4},$$

segue che

$$\|B_{\mathbf{n}}(X_1^2 + \cdots + X_d^2) - (X_1^2 + \cdots + X_d^2)\|_{\infty, [0,1]^d} \leq \frac{d}{4 \min_i n_i} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Dunque $B_{\mathbf{n}}$ soddisfa il test di Korovkin multidimensionale. Pertanto

$$\|B_{\mathbf{n}}(f) - f\|_{\infty, [0,1]^d} \xrightarrow{\min_i n_i \rightarrow \infty} 0 \quad \forall f \in C([0,1]^d).$$

Consideriamo ora un rettangolo

$$Q = [a_1, b_1] \times \cdots \times [a_d, b_d].$$

Per $f \in C(Q)$, definiamo

$$g(t_1, \dots, t_d) = f(a_1 + (b_1 - a_1)t_1, \dots, a_d + (b_d - a_d)t_d),$$

con $t = (t_1, \dots, t_d) \in [0, 1]^d$. Allora $g \in C([0, 1]^d)$. Definiamo

$$P_{\mathbf{n}}(x) = B_{\mathbf{n}}(g) \left(\frac{x_1 - a_1}{b_1 - a_1}, \dots, \frac{x_d - a_d}{b_d - a_d} \right).$$

Allora $P_{\mathbf{n}}$ è un polinomio in $x_1, \dots, x_d$, di grado al più n_i nella variabile x_i , e

$$\|P_{\mathbf{n}} - f\|_{\infty, Q} = \|B_{\mathbf{n}}(g) - g\|_{\infty, [0, 1]^d} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Infine, se $K \subseteq \mathbb{R}^d$ è compatto generico, scegliamo un rettangolo Q tale che

$$K \subseteq \text{int}(Q).$$

Per il teorema di estensione di Tietze, ogni $f \in C(K)$ ammette un'estensione $\tilde{f} \in C(Q)$ con

$$\tilde{f}|_K = f.$$

Per quanto appena dimostrato, esiste una famiglia di polinomi $\{P_{\mathbf{n}}\}_{\mathbf{n}}$ tale che

$$\|\tilde{f} - P_{\mathbf{n}}\|_{\infty, Q} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

Restringendo a K , si ottiene

$$\|f - P_{\mathbf{n}}\|_{\infty, K} \leq \|\tilde{f} - P_{\mathbf{n}}\|_{\infty, Q} \xrightarrow{\min_i n_i \rightarrow \infty} 0.$$

8.2 Korovkin multidimensionale e polinomi di Bernstein

L'obiettivo è verificare le ipotesi del teorema di Korovkin per gli operatori di Bernstein su $[0, 1]^d$. In questo modo si ottiene una dimostrazione del teorema di Weierstrass in più variabili: ogni funzione continua su un compatto rettangolare può essere approssimata uniformemente da polinomi.

Definizione Operatore di Bernstein in d variabili

Sia $D = [0, 1]^d$ e sia $\mathbf{n} = (n_1, \dots, n_d)$, con $n_i \in \mathbb{N}^+$. Per $f \in C(D)$ definiamo

$$B_{\mathbf{n}}(f)(x) = \sum_{k_1=0}^{n_1} \cdots \sum_{k_d=0}^{n_d} f\left(\frac{k_1}{n_1}, \dots, \frac{k_d}{n_d}\right) \prod_{i=1}^d \binom{n_i}{k_i} x_i^{k_i} (1 - x_i)^{n_i - k_i},$$

per ogni $x = (x_1, \dots, x_d) \in D$.

La notazione $\mathbf{n} \rightarrow \infty$ significa che $\min_i n_i \rightarrow \infty$.

L'immagine $B_{\mathbf{n}}(f)$ è un polinomio in $x_1, \dots, x_d$, di grado al più n_i nella variabile x_i . Per applicare Korovkin dobbiamo controllare le funzioni test

$$1, \quad y_1, \dots, y_d, \quad \|y\|_2^2 = y_1^2 + \cdots + y_d^2.$$

Proposition Linearità e positività

Per ogni $\mathbf{n}$, l'operatore $B_{\mathbf{n}} : C(D) \rightarrow C(D)$ è lineare e positivo.

Proof

La linearità segue direttamente dalla definizione. Infatti, per $\alpha, \beta \in \mathbb{R}$,

$$\begin{aligned} B_{\mathbf{n}}(\alpha f + \beta g)(x) &= \sum_{k_1=0}^{n_1} \cdots \sum_{k_d=0}^{n_d} (\alpha f + \beta g) \left(\frac{k_1}{n_1}, \dots, \frac{k_d}{n_d} \right) \prod_{i=1}^d \binom{n_i}{k_i} x_i^{k_i} (1-x_i)^{n_i-k_i} \\ &= \alpha B_{\mathbf{n}}(f)(x) + \beta B_{\mathbf{n}}(g)(x). \end{aligned}$$

Inoltre, se $f \geq 0$ su D , allora ogni valore

$$f \left(\frac{k_1}{n_1}, \dots, \frac{k_d}{n_d} \right)$$

è non negativo e tutti i pesi

$$\prod_{i=1}^d \binom{n_i}{k_i} x_i^{k_i} (1-x_i)^{n_i-k_i}$$

sono non negativi su $[0, 1]^d$. Quindi $B_{\mathbf{n}}(f)(x) \geq 0$ per ogni $x \in D$.

Proposition Verifica delle funzioni test di Korovkin

Per $\mathbf{n} \rightarrow \infty$ valgono le convergenze uniformi

$$B_{\mathbf{n}}(1) \rightarrow 1, \quad B_{\mathbf{n}}(y_j) \rightarrow y_j \quad j = 1, \dots, d, \quad B_{\mathbf{n}}(\|y\|_2^2) \rightarrow \|y\|_2^2.$$

Proof

Per la funzione costante 1, usando la formula binomiale in ogni variabile,

$$\begin{aligned} B_{\mathbf{n}}(1)(x) &= \sum_{k_1=0}^{n_1} \cdots \sum_{k_d=0}^{n_d} \prod_{i=1}^d \binom{n_i}{k_i} x_i^{k_i} (1-x_i)^{n_i-k_i} \\ &= \prod_{i=1}^d \sum_{k_i=0}^{n_i} \binom{n_i}{k_i} x_i^{k_i} (1-x_i)^{n_i-k_i} \\ &= \prod_{i=1}^d (x_i + 1 - x_i)^{n_i} = 1. \end{aligned}$$

Dunque $B_{\mathbf{n}}(1) = 1$ esattamente.

Sia ora $y_j(x) = x_j$. Nella variabile j -esima compare il momento primo della distribuzione binomiale, mentre nelle altre variabili compare la somma dei pesi, uguale a 1:

$$\begin{aligned} B_{\mathbf{n}}(y_j)(x) &= \left(\prod_{i \neq j} B_{n_i}(1)(x_i) \right) B_{n_j}(y)(x_j) \\ &= x_j. \end{aligned}$$

Quindi anche in questo caso la convergenza è esatta.

Infine calcoliamo il momento secondo. In una variabile si ha

$$B_n(y^2)(x) = x^2 + \frac{x(1-x)}{n}.$$

Perciò, in d variabili,

$$\begin{aligned} B_{\mathbf{n}}(y_j^2)(x) &= x_j^2 + \frac{x_j(1-x_j)}{n_j}, \\ B_{\mathbf{n}}(\|y\|_2^2)(x) &= \sum_{j=1}^d B_{\mathbf{n}}(y_j^2)(x) \\ &= \sum_{j=1}^d x_j^2 + \sum_{j=1}^d \frac{x_j(1-x_j)}{n_j} \\ &= \|x\|_2^2 + \sum_{j=1}^d \frac{x_j(1-x_j)}{n_j}. \end{aligned}$$

Poiché $0 \leq x_j(1-x_j) \leq 1/4$, otteniamo

$$\|B_{\mathbf{n}}(\|y\|_2^2) - \|y\|_2^2\|_{\infty, D} \leq \frac{1}{4} \sum_{j=1}^d \frac{1}{n_j} \xrightarrow{\mathbf{n} \rightarrow \infty} 0.$$

Teorema Teorema di Weierstrass su $[0, 1]^d$

Per ogni $f \in C([0, 1]^d)$ si ha

$$\|B_{\mathbf{n}}(f) - f\|_{\infty, [0, 1]^d} \xrightarrow{\mathbf{n} \rightarrow \infty} 0.$$

In particolare, ogni funzione continua su $[0, 1]^d$ è limite uniforme di polinomi.

Proof

Gli operatori $B_{\mathbf{n}}$ sono lineari e positivi. Inoltre abbiamo appena verificato la convergenza uniforme sulle funzioni test

$$1, \quad y_1, \dots, y_d, \quad \|y\|_2^2.$$

Per il teorema di Korovkin in dimensione d , segue che

$$\|B_{\mathbf{n}}(f) - f\|_{\infty, [0, 1]^d} \rightarrow 0$$

per ogni $f \in C([0, 1]^d)$. Siccome $B_{\mathbf{n}}(f)$ è un polinomio, otteniamo l'approssimazione uniforme tramite polinomi.

Se l'errore di approssimazione fosse identicamente nullo per ogni funzione continua, allora ogni funzione continua sarebbe un polinomio. Il fatto importante è invece che l'errore tende a zero in norma uniforme: si tratta di approssimazione, non di rappresentazione esatta.

8.3 Interpolazione polinomiale

Siano $x_0, \dots, x_n \in [a, b]$ punti a due a due distinti e siano $f_0, \dots, f_n \in \mathbb{R}$. Esiste un unico polinomio $p \in \mathbb{P}_n$ tale che

$$p(x_j) = f_j, \quad j = 0, \dots, n.$$

Se $f \in C([a, b])$, indicando con $P_n(f)$ il polinomio interpolante di f sui nodi scelti, la domanda naturale è:

$$P_n(f) \xrightarrow{n \rightarrow \infty} f \quad \text{in } C([a, b])?$$

In generale la risposta è negativa: l'interpolazione polinomiale non è un metodo universalmente convergente per ogni funzione continua e per ogni scelta dei nodi.

Teorema Formula dell'errore di interpolazione

Sia $f \in C^{n+1}([a, b])$ e siano $x_0, \dots, x_n \in [a, b]$ nodi a due a due distinti. Se $P_n(f)$ è il polinomio interpolante di f in tali nodi, allora per ogni $x \in [a, b]$ esiste $\xi_x \in (a, b)$ tale che

$$f(x) - P_n(f)(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{j=0}^n (x - x_j).$$

Proof

Se x coincide con uno dei nodi, allora entrambi i membri sono nulli. Supponiamo quindi che $x \notin \{x_0, \dots, x_n\}$. Poniamo

$$W(t) = \prod_{j=0}^n (t - x_j)$$

e fissiamo x . Consideriamo la funzione ausiliaria

$$\varphi(t) = f(t) - P_n(f)(t) - \frac{f(x) - P_n(f)(x)}{W(x)} W(t).$$

Per costruzione $\varphi(x) = 0$. Inoltre, per ogni nodo x_j , si ha $f(x_j) - P_n(f)(x_j) = 0$ e $W(x_j) = 0$, quindi $\varphi(x_j) = 0$. La funzione φ ha dunque almeno $n+2$ zeri distinti.

Applicando ripetutamente il teorema di Rolle, φ' ha almeno $n+1$ zeri distinti, φ'' ne ha almeno n , e così via. Alla fine $\varphi^{(n+1)}$ ha almeno uno zero $\xi_x \in (a, b)$. Poiché $P_n^{(n+1)} = 0$ e $W^{(n+1)} = (n+1)!$, otteniamo

$$0 = \varphi^{(n+1)}(\xi_x) = f^{(n+1)}(\xi_x) - \frac{f(x) - P_n(f)(x)}{W(x)} (n+1)!.$$

Da cui

$$f(x) - P_n(f)(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} W(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{j=0}^n (x - x_j).$$

Esempio Interpolazione di e^x su $[0, 1]$

Sia $f(x) = e^x$ e siano $x_0, \dots, x_n \in [0, 1]$ nodi a due a due distinti. Poiché $f^{(n+1)}(x) = e^x$, si ha

$$\left| f^{(n+1)}(\xi_x) \right| \leq e \quad \text{per ogni } \xi_x \in [0, 1].$$

Inoltre $|x - x_j| \leq 1$ per ogni $x, x_j \in [0, 1]$. Dalla formula dell'errore segue

$$\|e^x - P_n(e^x)\|_{\infty, [0, 1]} \leq \frac{e}{(n+1)!}.$$

Quindi, per questa funzione, l'interpolazione converge uniformemente a e^x , indipendentemente dalla scelta dei nodi in $[0, 1]$.

Teorema Non universalità dell'interpolazione: teorema di Faber

Per ogni scelta di nodi triangolare

$$x_0^{(n)}, \dots, x_n^{(n)} \in [a, b], \quad n = 0, 1, 2, \dots,$$

a due a due distinti per ogni n , esiste una funzione $f \in C([a, b])$ tale che la successione dei polinomi interpolanti non è uniformemente convergente a f . Più precisamente, si può avere

$$\limsup_{n \rightarrow \infty} \|P_n(f)\|_{\infty, [a, b]} = +\infty.$$

Questo risultato mostra che l'interpolazione polinomiale, a differenza dell'approssimazione di Bernstein, non dà automaticamente un procedimento convergente per tutte le funzioni continue.

9 Metodi per autovalori

9.1 Metodo delle potenze

Definizione Ipotesi spettrale dominante

Sia $A \in M_n(\mathbb{C})$ con autovalori $\lambda_1, \dots, \lambda_n$ ordinati in modo che

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|.$$

L'autovalore λ_1 è detto autovalore dominante. Il metodo delle potenze serve ad approssimare λ_1 e un suo autovettore.

L'ipotesi $|\lambda_1| > |\lambda_2|$ è molto comune nelle applicazioni: dice che, iterando la matrice, la componente lungo l'autospazio dominante prevale sulle altre.

Definizione Algoritmo del metodo delle potenze

Si scelga $q^{(0)} \neq 0$ con componente dominante non nulla e si ponga

$$x^{(0)} = \frac{q^{(0)}}{\|q^{(0)}\|_\infty}.$$

Per $k = 0, 1, 2, \dots$ si ripete:

$$\begin{aligned} q^{(k+1)} &= Ax^{(k)}, \\ p_{k+1} &\in \operatorname{argmax}_{1 \leq i \leq n} |q_i^{(k+1)}|, \\ \mu^{(k+1)} &= \begin{cases} \frac{q_{p_{k+1}}^{(k+1)}}{x_{p_{k+1}}^{(k)}}, & x_{p_{k+1}}^{(k)} \neq 0, \\ \frac{(x^{(k)})^* q^{(k+1)}}{(x^{(k)})^* x^{(k)}}, & x_{p_{k+1}}^{(k)} = 0, \end{cases} \\ x^{(k+1)} &= \frac{q^{(k+1)}}{\|q^{(k+1)}\|_\infty}. \end{aligned}$$

Per $k \geq 1$, ci si ferma quando $\mu^{(k+1)} \neq 0$ e, fissata una tolleranza $\varepsilon > 0$, vale

$$\frac{|\mu^{(k+1)} - \mu^{(k)}|}{|\mu^{(k+1)}|} \leq \varepsilon,$$

oppure quando si raggiunge un numero massimo di iterazioni.

La prima condizione segnala la stabilizzazione della stima, ma da sola non garantisce l'accuratezza: conviene controllare anche il residuo $Ax^{(k+1)} - \mu^{(k+1)}x^{(k+1)}$. Sotto le ipotesi di convergenza, $\mu^{(k+1)}$ approssima λ_1 e $x^{(k+1)}$ approssima un autovettore associato, normalizzato in norma ∞ .

Proposition Analisi nel caso diagonalizzabile

Supponiamo che A sia diagonalizzabile e che $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$. Se il vettore iniziale ha componente non nulla lungo l'autovettore dominante, allora il metodo delle potenze converge all'autodirezione dominante.

Proof

Sia $\{v_1, \dots, v_n\}$ una base di autovettori di A , con

$$Av_j = \lambda_j v_j.$$

Scriviamo

$$x^{(0)} = \alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n,$$

con $\alpha_1 \neq 0$. Allora

$$\begin{aligned} A^k x^{(0)} &= \alpha_1 \lambda_1^k v_1 + \alpha_2 \lambda_2^k v_2 + \dots + \alpha_n \lambda_n^k v_n \\ &= \lambda_1^k \left(\alpha_1 v_1 + \sum_{j=2}^n \alpha_j \left(\frac{\lambda_j}{\lambda_1} \right)^k v_j \right). \end{aligned}$$

Poiché

$$\left| \frac{\lambda_j}{\lambda_1} \right| < 1 \quad j = 2, \dots, n,$$

la sommatoria tende a zero. Dunque la direzione di $A^k x^{(0)}$ tende alla direzione di v_1 .

Più precisamente, per una opportuna costante di normalizzazione γ_k ,

$$x^{(k)} = \gamma_k \lambda_1^k \left(\alpha_1 v_1 + O \left(\left| \frac{\lambda_2}{\lambda_1} \right|^k \right) \right).$$

Analogamente,

$$q^{(k+1)} = Ax^{(k)} = \gamma_k \lambda_1^{k+1} \left(\alpha_1 v_1 + O \left(\left| \frac{\lambda_2}{\lambda_1} \right|^k \right) \right).$$

Prendendo il quoziente componente per componente, su una componente non nulla di v_1 (come avviene per l'indice massimo per k sufficientemente grande), si ottiene

$$\mu^{(k+1)} = \lambda_1 \left(1 + O \left(\left| \frac{\lambda_2}{\lambda_1} \right|^k \right) \right).$$

Quindi $\mu^{(k)} \rightarrow \lambda_1$.

Proposition Caso non diagonalizzabile

Supponiamo che $|\lambda_1| > |\lambda_j|$ per $j = 2, \dots, n$ e che λ_1 abbia molteplicità algebrica e geometrica uguale a 1. Allora il metodo delle potenze converge ancora all'autodirezione dominante, purché il vettore iniziale abbia proiezione spettrale non nulla sul blocco dominante.

Proof

Si usa la forma di Jordan. Esiste una matrice invertibile X tale che

$$A = XJX^{-1},$$

dove J ha il blocco (λ_1) associato all'autovalore dominante e gli altri blocchi hanno autovalori di modulo strettamente minore di $|\lambda_1|$. Quindi

$$A^k = XJ^kX^{-1}.$$

Nei blocchi non dominanti compaiono termini del tipo

$$k^m \left(\frac{\lambda_j}{\lambda_1} \right)^k,$$

che tendono a zero perché $|\lambda_j/\lambda_1| < 1$. Rimane quindi solo il contributo del blocco dominante, e si ottiene la stessa conclusione del caso diagonalizzabile.

In pratica bisogna prestare attenzione alla stabilità numerica: la normalizzazione a ogni passo evita overflow o underflow e rende possibile confrontare le iterate.

10 PageRank e modelli matriciali per il Web

10.1 Modello di importanza e matrice dei link

Molte tecnologie moderne dipendono da strumenti matematici profondi. La matematica, però, è neutra: il suo impatto dipende dall'utilizzo. Gli stessi metodi possono comparire in applicazioni mediche, modelli cardiaci, motori di ricerca, droni o sistemi d'arma.


Il problema affrontato da Google è: come assegnare un'importanza alle pagine del Web?

Definizione Regole qualitative dell'importanza

Indichiamo con $I(\alpha)$ l'importanza della pagina α . L'idea è:


$I(\alpha)$ cresce	se esiste un link da una pagina β verso α ,
$I(\alpha)$ cresce di più	se $I(\beta)$ è alta,
$I(\alpha)$ cresce di meno	se β ha molti link uscenti.

Un link $\beta \rightarrow \alpha$ viene rappresentato così:



Una pagina è importante se molti parlano di lei; è ancora più importante se chi parla di lei è a sua volta importante; l'importanza ricevuta da una pagina viene però distribuita tra tutti i suoi link uscenti.

Per esempio, nel grafo seguente, la pagina a riceve link da più pagine; la pagina b è importante perché riceve un link da a , e a ha pochi link uscenti.



Numeriamo tutte le pagine del Web da 1 a N , con N molto grande. Se L_β è il numero di link uscenti dalla pagina β , la regola diventa

$$I(\alpha) = \sum_{\beta \rightarrow \alpha} \frac{I(\beta)}{L_\beta}.$$

Questa formula dice che non si può calcolare una singola importanza isolatamente: tutte le importanze sono accoppiate e vanno calcolate simultaneamente.

Definizione Matrice dei link

Definiamo la matrice $A = (a_{\alpha\beta})$ ponendo

$$a_{\alpha\beta} = \begin{cases} 0, & \text{se } \beta \text{ non ha un link verso } \alpha, \\ \frac{1}{L_\beta}, & \text{se } \beta \text{ ha un link verso } \alpha. \end{cases}$$

Allora il vettore delle importanze $I = (I(1), \dots, I(N))^T$ deve soddisfare

$$I = AI.$$

Inoltre vogliamo

$$I(\alpha) \geq 0, \quad \sum_{\alpha=1}^N I(\alpha) = 1.$$

La matrice A è enorme, perché N è dell'ordine delle pagine del Web, ma è anche estremamente sparsa: ogni pagina contiene solo pochi link rispetto a N .

10.2 Metodo delle potenze per il ranking

Il primo algoritmo naturale è il metodo delle potenze applicato ad A :

$$I^{(0)} = \frac{1}{N} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}, \quad I^{(k+1)} = AI^{(k)}.$$

Se esiste

$$\lim_{k \rightarrow \infty} I^{(k)} = I^*,$$

allora il vettore I^* soddisfa

$$I^* = AI^*.$$

Quindi I^* è un autovettore associato all'autovalore 1. In questo contesto non serve una precisione altissima: l'obiettivo è soprattutto ordinare le pagine per importanza.

10.3 Pagine senza link uscenti

Esempio Pagina senza link uscenti

Consideriamo due pagine, con un solo link $1 \rightarrow 2$ e nessun link uscente da 2:



La matrice dei link è

$$A = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix}.$$

Questa matrice non è stocastica per colonne: la seconda colonna è nulla. Inoltre 1 non è autovalore di A , quindi il metodo delle potenze non può convergere a un autovettore di importanza normalizzato.

Il rimedio è aggiungere teletrasporto sulle colonne nulle. Sia

$$u = \frac{1}{N} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$$

e sia $z \in \mathbb{R}^N$ definito da

$$z_j = \begin{cases} 1, & \text{se la colonna } j \text{ di } A \text{ è nulla,} \\ 0, & \text{altrimenti.} \end{cases}$$

Definiamo

$$A' = A + uz^T.$$

In questo modo ogni colonna nulla viene sostituita con la distribuzione uniforme u .

Teorema Autovalore principale per matrici stocastiche per colonne

La matrice A' è stocastica per colonne. Di conseguenza 1 è autovalore di A' e

$$\rho(A') = 1.$$

Proof

Per costruzione ogni colonna di A' ha elementi non negativi e somma pari a 1. Dunque

$$\|A'\|_1 = 1.$$

Ne segue che

$$\rho(A') \leq \|A'\|_1 = 1.$$

D'altra parte, se $\mathbf{1} = (1, \dots, 1)^T$, la condizione di stocasticità per colonne equivale a

$$\mathbf{1}^T A' = \mathbf{1}^T.$$

Quindi 1 è autovalore di $(A')^T$, e dunque anche di A' . Pertanto $\rho(A') \geq 1$, e concludiamo che $\rho(A') = 1$.

10.4 Oscillazioni e periodicità

Anche se la matrice è stocastica per colonne, il metodo delle potenze può non convergere. Per esempio, con due pagine che si puntano a vicenda,



si ottiene

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$

Gli autovalori sono 1 e -1 . La presenza dell'autovalore -1 , di modulo 1, può produrre oscillazioni e impedire la convergenza del metodo delle potenze.

10.5 Teletrasporto e convergenza del PageRank

Brin e Page introdussero un parametro di teletrasporto. Sia $c \in [0, 1)$, tipicamente

$$c \simeq 0.85.$$

Definiamo

$$A_c = cA' + (1 - c) \frac{1}{N} \mathbf{1}\mathbf{1}^T.$$

La matrice

$$\frac{1}{N} \mathbf{1}\mathbf{1}^T$$

è la matrice le cui colonne sono tutte uguali alla distribuzione uniforme. Quindi A_c è combinazione convessa di matrici stocastiche per colonne e, a sua volta, è stocastica per colonne.

Teorema Spettro della matrice con teletrasporto

La matrice A_c ha autovalore 1. Inoltre, se $\lambda \neq 1$ è un autovalore di A_c , allora

$$|\lambda| \leq c < 1.$$

Di conseguenza il metodo delle potenze applicato ad A_c converge a un vettore stocastico I^* .

Proof

Poiché A_c è stocastica per colonne, $\mathbf{1}$ è autovalore. Studiamo gli altri autovalori. Poniamo

$$E = \frac{1}{N} \mathbf{1} \mathbf{1}^T.$$

Per $\lambda \notin \sigma(cA')$, usando la formula del determinante di una perturbazione di rango uno,

$$\begin{aligned} p_{A_c}(\lambda) &= \det(A_c - \lambda I) \\ &= \det(cA' - \lambda I + (1-c)E) \\ &= \det(cA' - \lambda I) \left(1 + \frac{1-c}{N} \mathbf{1}^T (cA' - \lambda I)^{-1} \mathbf{1} \right). \end{aligned}$$

Siccome A' è stocastica per colonne,

$$\mathbf{1}^T A' = \mathbf{1}^T.$$

Quindi

$$\mathbf{1}^T (cA' - \lambda I) = (c - \lambda) \mathbf{1}^T.$$

Da cui

$$\mathbf{1}^T (cA' - \lambda I)^{-1} = \frac{1}{c - \lambda} \mathbf{1}^T.$$

Pertanto

$$\begin{aligned} p_{A_c}(\lambda) &= p_{cA'}(\lambda) \left(1 + \frac{1-c}{c - \lambda} \right) \\ &= p_{cA'}(\lambda) \frac{1 - \lambda}{c - \lambda}. \end{aligned}$$

Equivalentemente,

$$(c - \lambda) p_{A_c}(\lambda) = (1 - \lambda) p_{cA'}(\lambda).$$

L'identità, ottenuta inizialmente fuori da un insieme finito, vale come identità polinomiale per continuità.

Se gli autovalori di A' sono

$$1, \mu_2, \dots, \mu_N,$$

con $|\mu_j| \leq 1$, allora gli autovalori di A_c sono

$$1, c\mu_2, \dots, c\mu_N.$$

Dunque ogni autovalore diverso da 1 ha modulo minore o uguale a c . Poiché $c < 1$, il metodo delle potenze converge al vettore di PageRank I^* , cioè al vettore stocastico che soddisfa

$$A_c I^* = I^*.$$

11 Esercizi e problemi svolti

Esercizio

Sia $n \geq 2$, sia $\alpha \geq 1$ reale e consideriamo la matrice

$$A_n(\alpha) = \begin{pmatrix} \alpha & 1 & 1 & \cdots & 1 \\ 1 & \alpha & 1 & \cdots & 1 \\ 1 & 1 & \alpha & \cdots & 1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 & \alpha \end{pmatrix}$$

e

$$B_n(\alpha) = \begin{pmatrix} \alpha & -1 & -1 & \cdots & -1 \\ 1 & \alpha & -1 & \cdots & -1 \\ 1 & 1 & \alpha & \cdots & -1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 & \alpha \end{pmatrix}.$$

1. Si determini nella maniera più precisa possibile lo spettro di $A_n(\alpha)$ e di $B_n(\alpha)$.
2. In particolare, si studi per quali valori di α le matrici risultano invertibili.
3. Indicando con e_1 il primo vettore della base canonica, è vero che $A_n(2) + e_1 e_1^T$ è definita positiva?
4. È vero che $A_n(1) + e_1 e_1^T$ è semidefinita positiva?

Soluzione

Cominciamo notando che $A_n^*(\alpha) = A_n^T(\alpha) = A_n(\alpha)$, quindi $A_n(\alpha)$ è Hermitiana e il suo spettro è reale.

Scriviamo

$$A_n(\alpha) = (\alpha - 1)I_n + J_n,$$

dove

$$J_n = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} (1 \quad 1 \quad \cdots \quad 1).$$

La matrice J_n ha rango 1. Inoltre,

$$J_n \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = n \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix},$$

mentre $J_n x = 0$ per ogni vettore x tale che la somma delle sue componenti sia nulla. Quindi

$$\sigma(A_n(\alpha)) = \{\alpha + n - 1, \alpha - 1\},$$

dove $\alpha + n - 1$ ha molteplicità 1, mentre $\alpha - 1$ ha molteplicità $n - 1$.

In particolare, $A_n(\alpha)$ è invertibile se e solo se

$$\alpha > 1.$$

Per $\alpha = 1$, infatti, la matrice $A_n(1)$ è singolare.

Consideriamo ora $B_n(\alpha)$. Possiamo notare che

$$B_n(\alpha) = \alpha I_n + X_n,$$

dove

$$X_n = \begin{pmatrix} 0 & -1 & \cdots & -1 \\ 1 & 0 & \cdots & -1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 0 \end{pmatrix}.$$

La matrice X_n è antisimmetrica reale, cioè

$$X_n^T = -X_n.$$

Definiamo

$$Y_n = iX_n.$$

Allora

$$Y_n^* = (iX_n)^* = -iX_n^T = -i(-X_n) = iX_n = Y_n.$$

Quindi Y_n è Hermitiana e i suoi autovalori sono reali.

Se $Y_n x = \lambda x$, con $\lambda \in \mathbb{R}$, allora

$$iX_n x = \lambda x,$$

cioè

$$X_n x = -i\lambda x.$$

Quindi gli autovalori di X_n sono immaginari puri.

Se $X_n v = \mu v$, allora

$$B_n(\alpha)v = (\alpha I_n + X_n)v = \alpha v + \mu v = (\alpha + \mu)v.$$

Dunque

$$\sigma(B_n(\alpha)) = \alpha + \sigma(X_n).$$

Poiché gli autovalori di X_n sono immaginari puri, gli autovalori di $B_n(\alpha)$ sono della forma

$$\alpha + i\beta, \quad \beta \in \mathbb{R}.$$

Siccome $\alpha \geq 1$, questi autovalori non possono mai essere nulli. Quindi $B_n(\alpha)$ è invertibile per ogni $\alpha \geq 1$.

Consideriamo ora $A_n(2) + e_1 e_1^T$. Poiché

$$A_n(2) = I_n + J_n,$$

abbiamo, per ogni $x \neq 0$,

$$x^* A_n(2)x = x^* x + x^* J_n x > 0.$$

Inoltre

$$x^* e_1 e_1^T x = |e_1^T x|^2 \geq 0.$$

Quindi

$$x^* (A_n(2) + e_1 e_1^T) x > 0$$

per ogni $x \neq 0$, e dunque $A_n(2) + e_1 e_1^T$ è definita positiva.

Infine, $A_n(1) = J_n$. Per ogni x ,

$$x^* J_n x \geq 0$$

e

$$x^* e_1 e_1^T x = |e_1^T x|^2 \geq 0.$$

Quindi

$$x^* (A_n(1) + e_1 e_1^T) x \geq 0$$

per ogni x , e dunque $A_n(1) + e_1 e_1^T$ è semidefinita positiva.

Definizione Matrice di Vandermonde generalizzata

Siano $x_0, x_1, \dots, x_n \in \mathbb{C}$ e siano $p_0, p_1, \dots, p_n \in \mathbb{C}[x]$, $n+1$ polinomi linearmente indipendenti. La matrice di Vandermonde generalizzata è definita come

$$W_n \triangleq (p_k(x_j))_{j,k=0}^n \in \text{Mat}_{n+1}(\mathbb{C})$$

Esercizio Matrice di Vandermonde generalizzata

Consideriamo una matrice di Vandermonde generalizzata W_n . Sia

$$K_n = \max_{0 \leq k \leq n} \{\deg(p_k)\}$$

1. Si dimostri che $\det W_n \neq 0$ implica che $x_0, x_1, \dots, x_n$ sono a due a due distinti.
2. Se $K_n = n$ e $x_0, x_1, \dots, x_n$ sono a due a due distinti è vero che $\det W_n \neq 0$? (Unisolvenza)
3. Se $K_n > n$ e $x_0, x_1, \dots, x_n$ sono a due a due distinti è ancora vero che si ha unisolvenza, ovvero $\det W_n \neq 0$?

Soluzione Matrice di Vandermonde generalizzata

todo

Esercizio

Sia $n \geq 2$. Siano dati $2n$ numeri positivi x_j, y_j per $j \in \{1, \dots, n\}$ tali che

$$x_j y_j > \frac{1}{2}, \quad \forall j \in \{1, \dots, n\}.$$

Siano $v_1, \dots, v_n \in \mathbb{R}^2$ con

$$v_j = \begin{pmatrix} x_j \\ y_j \end{pmatrix}, \quad j \in \{1, \dots, n\},$$

e si consideri $A \in \text{Mat}_n(\mathbb{R})$ tale che

$$A_{j,k} = 1, \quad j \neq k, \quad A_{j,j} = \|v_j\|_2.$$

Sia $B \in \text{Mat}_n(\mathbb{R})$ la matrice tridiagonale simmetrica con

$$B_{j,j} = 2, \quad B_{j,j+1} = B_{j+1,j} = 1, \quad j \in \{1, \dots, n-1\}.$$

Si consideri $C \in \text{Mat}_{2n}(\mathbb{R})$ data da

$$C = \begin{pmatrix} A & A^2 - x_1 A \\ 0 & B \end{pmatrix}.$$

1. Si dimostri che A, B, C sono invertibili.
2. Si localizzi lo spettro di C nel modo migliore possibile.
3. Si dimostri che la fattorizzazione LU di C esiste unica, ovvero che C è fortemente non singolare.
4. Si dimostri la convergenza del metodo di Gauss-Seidel applicato ad un sistema $Cx = b$ con $b \in \mathbb{R}^{2n}$.
5. Si dimostri che $f(A), f(B), f(C)$ sono invertibili con $f(x) = 1 - x + x^{31}$. È vero che tutti gli autovalori di $f(C)$ sono positivi?

Soluzione

1. Per ogni j , usando $x_j, y_j > 0$ e $x_j y_j > 1/2$, abbiamo

$$\|v_j\|_2 = \sqrt{x_j^2 + y_j^2} \geq \sqrt{2x_j y_j} > 1.$$

Quindi possiamo scrivere

$$A = D + J,$$

dove

$$D = \text{diag}(\|v_1\|_2 - 1, \dots, \|v_n\|_2 - 1)$$

è diagonale definita positiva, mentre

$$J = \begin{pmatrix} 1 & \cdots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 1 \end{pmatrix}.$$

Per ogni $z \in \mathbb{R}^n$, $z \neq 0$, si ha

$$z^T A z = z^T D z + z^T J z = \sum_{j=1}^n (\|v_j\|_2 - 1) z_j^2 + \left(\sum_{j=1}^n z_j \right)^2 > 0.$$

Quindi A è definita positiva, e in particolare è invertibile.

Studiamo ora B . Per ogni $z \in \mathbb{R}^n$ si ha

$$z^T B z = 2 \sum_{j=1}^n z_j^2 + 2 \sum_{j=1}^{n-1} z_j z_{j+1}.$$

Riscriviamo questa quantità come

$$z^T B z = z_1^2 + z_n^2 + \sum_{j=1}^{n-1} (z_j + z_{j+1})^2.$$

Questa quantità è sempre non negativa. Inoltre, se è nulla, allora $z_1 = z_n = 0$ e $z_j + z_{j+1} = 0$ per ogni j , da cui segue $z = 0$. Quindi B è definita positiva, e in particolare è invertibile.

Infine, C è triangolare a blocchi:

$$C = \begin{pmatrix} A & A^2 - x_1 A \\ 0 & B \end{pmatrix}.$$

Dunque

$$\det(C) = \det(A) \det(B).$$

Siccome A e B sono invertibili, anche C è invertibile.

2. Siccome C è triangolare a blocchi, il suo spettro è l'unione degli spettri dei blocchi diagonali:

$$\sigma(C) = \sigma(A) \cup \sigma(B).$$

Localizziamo quindi separatamente $\sigma(A)$ e $\sigma(B)$.

Per A , usando il teorema di Gershgorin, ogni autovalore appartiene ad almeno uno degli intervalli

$$[\|v_j\|_2 - (n-1), \|v_j\|_2 + (n-1)], \quad j = 1, \dots, n.$$

Inoltre A è definita positiva, quindi tutti i suoi autovalori sono positivi. Dunque

$$\sigma(A) \subset (0, +\infty) \cap \bigcup_{j=1}^n [\|v_j\|_2 - (n-1), \|v_j\|_2 + (n-1)].$$

Per B , sempre per Gershgorin, la prima e l'ultima riga danno l'intervallo $[1, 3]$, mentre le righe interne danno l'intervallo $[0, 4]$. Quindi $\sigma(B) \subset [0, 4]$. Siccome B è definita positiva, possiamo escludere lo zero; inoltre, per irriducibilità e Gershgorin III, possiamo escludere anche 4. Quindi $\sigma(B) \subset (0, 4)$.

In conclusione,

$$\sigma(C) \subset \left((0, +\infty) \cap \bigcup_{j=1}^n [\|v_j\|_2 - (n-1), \|v_j\|_2 + (n-1)] \right) \cup (0, 4).$$

3. Per mostrare che la fattorizzazione LU di C esiste ed è unica, basta mostrare che C è fortemente non singolare, cioè che tutti i suoi minori principali iniziali sono non nulli.

Consideriamo prima i minori principali iniziali di ordine $k \leq n$. Questi sono esattamente i minori principali iniziali di A . Ma ogni sottomatrice principale iniziale di A ha ancora la forma

$$D_k + J_k,$$

dove D_k è diagonale definita positiva e J_k è semidefinita positiva. Quindi ogni sottomatrice principale iniziale di A è definita positiva, e dunque ha determinante non nullo.

Consideriamo ora i minori principali iniziali di ordine $n+k$, con $k \in \{1, \dots, n\}$. La corrispondente sottomatrice principale iniziale di C ha la forma

$$\begin{pmatrix} A & * \\ 0 & B_k \end{pmatrix},$$

dove B_k è la sottomatrice principale iniziale di ordine k di B . Anche B_k è definita positiva, con lo stesso ragionamento usato per B . Pertanto

$$\det \begin{pmatrix} A & * \\ 0 & B_k \end{pmatrix} = \det(A) \det(B_k) \neq 0.$$

Quindi tutti i minori principali iniziali di C sono non nulli. Di conseguenza C è fortemente non singolare e la fattorizzazione LU esiste ed è unica.

4. La matrice C non è simmetrica, quindi non possiamo concludere direttamente usando i teoremi per matrici definite positive. Tuttavia, C ha una struttura triangolare a blocchi. Consideriamo lo splitting del metodo di Gauss-Seidel

$$C = M - N,$$

dove M è la parte triangolare inferiore di C , diagonale inclusa, e $-N$ è la parte triangolare superiore stretta. Abbiamo quindi

$$M = \begin{pmatrix} \text{tril}(A) & 0 \\ 0 & \text{tril}(B) \end{pmatrix}, \quad N = \begin{pmatrix} -\text{triu}(A, 1) & -(A^2 - x_1 A) \\ 0 & -\text{triu}(B, 1) \end{pmatrix}.$$

La matrice di iterazione di Gauss-Seidel è

$$P_{\text{GS}}(C) = M^{-1}N.$$

Per la struttura a blocchi, si ottiene una matrice del tipo

$$P_{\text{GS}}(C) = \begin{pmatrix} P_{\text{GS}}(A) & * \\ 0 & P_{\text{GS}}(B) \end{pmatrix}.$$

Quindi

$$\sigma(P_{\text{GS}}(C)) = \sigma(P_{\text{GS}}(A)) \cup \sigma(P_{\text{GS}}(B)).$$

Infatti il polinomio caratteristico di una matrice triangolare a blocchi è il prodotto dei polinomi caratteristici dei blocchi diagonali.

Siccome A e B sono simmetriche definite positive, il metodo di Gauss-Seidel converge per entrambe. Dunque

$$\rho(P_{\text{GS}}(A)) < 1, \quad \rho(P_{\text{GS}}(B)) < 1.$$

Ne segue che

$$\rho(P_{\text{GS}}(C)) = \max\{\rho(P_{\text{GS}}(A)), \rho(P_{\text{GS}}(B))\} < 1.$$

Quindi il metodo di Gauss-Seidel applicato a $Cx = b$ converge.

5. Sia $f(x) = 1 - x + x^{31}$. Se X è una matrice e $X = TJT^{-1}$ è una sua forma di Jordan, allora

$$f(X) = Tf(J)T^{-1}.$$

In particolare gli autovalori di $f(X)$ sono gli elementi $f(\lambda)$, con $\lambda \in \sigma(X)$.

Studiamo quindi f su $[0, +\infty)$. Se $0 \leq x \leq 1$, allora $f(x) = 1 - x + x^{31} > 0$. Se invece $x \geq 1$, allora $x^{31} \geq x$, quindi $f(x) = 1 - x + x^{31} \geq 1 > 0$. Dunque

$$f(x) > 0 \quad \forall x \geq 0.$$

Abbiamo visto che tutti gli autovalori di A , B e C sono reali positivi. Quindi, per ogni autovalore λ di A , B o C , abbiamo $f(\lambda) > 0$. In particolare 0 non è autovalore di $f(A)$, $f(B)$ o $f(C)$. Quindi $f(A)$, $f(B)$ e $f(C)$ sono invertibili.

Inoltre, tutti gli autovalori di $f(C)$ sono positivi.

Esercizio

Sia $A \in \text{Mat}_n(\mathbb{R})$ con n pari, $a, b, c > 0$ e $a > b$. Definiamo

$$(A)_{j,k} = \begin{cases} a+c & j=k \\ a & (j+k) \equiv 0 \pmod{2} \wedge j \neq k \\ b & (j+k) \equiv 1 \pmod{2} \end{cases}$$

1. Caratterizzare lo spettro nel modo migliore possibile;
2. Dimostrare che il metodo di Gauss-Seidel è convergente se applicato ad un sistema lineare $Ax = d$, con $d \in \mathbb{R}^n$.

Soluzione

Abbiamo la forma della matrice

$$A = \begin{pmatrix} a+c & b & a & b & a & \cdots & b \\ b & a+c & b & a & b & \cdots & a \\ a & b & a+c & b & a & \cdots & b \\ b & a & b & a+c & b & \cdots & a \\ a & b & a & b & a+c & \cdots & b \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ b & a & b & a & b & \cdots & a+c \end{pmatrix}$$

$$= cI_n + b \underbrace{\begin{pmatrix} 0 & 1 & 0 & 1 & 0 & \cdots & 1 \\ 1 & 0 & 1 & 0 & 1 & \cdots & 0 \\ 0 & 1 & 0 & 1 & 0 & \cdots & 1 \\ 1 & 0 & 1 & 0 & 1 & \cdots & 0 \\ 0 & 1 & 0 & 1 & 0 & \cdots & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 1 & 0 & 1 & \cdots & 0 \end{pmatrix}}_E + a \underbrace{\begin{pmatrix} 1 & 0 & 1 & 0 & \cdots & 1 & 0 \\ 0 & 1 & 0 & 1 & \cdots & 0 & 1 \\ 1 & 0 & 1 & 0 & \cdots & 1 & 0 \\ 0 & 1 & 0 & 1 & \cdots & 0 & 1 \\ 1 & 0 & 1 & 0 & \cdots & 1 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & 0 & 1 & \cdots & 0 & 1 \end{pmatrix}}_F.$$

Siccome $A = cI_n + bE + aF$, gli autovalori di A sono della forma

$$\lambda(A) = c + \lambda(bE + aF).$$

Questo vale perché stiamo sommando un multiplo dell'identità, che commuta con ogni matrice e trasla lo spettro.

Notiamo che F ed E hanno solamente due righe distinte, quindi il loro rango è al più 2. Siano

$$f = \begin{pmatrix} 1 \\ 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix} \in \{0, 1\}^n, \quad g = \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 1 \end{pmatrix} \in \{0, 1\}^n.$$

Allora f è il vettore che seleziona gli indici dispari, mentre g seleziona gli indici pari. Da questo troviamo

$$E = fg^T + gf^T, \quad F = ff^T + gg^T.$$

Allora

$$\begin{aligned} bE + aF &= b(fg^T + gf^T) + a(ff^T + gg^T) \\ &= f(af^T + bg^T) + g(bf^T + ag^T). \end{aligned}$$

Più semplicemente,

$$bE + aF = f(af^T + bg^T) + g(bf^T + ag^T).$$

Da questa decomposizione deduciamo che il rango di $bE + aF$ è al più 2, in quanto possiamo generare tutto come combinazione di due vettori.

In realtà il rango è precisamente 2, perché $a > b > 0$. Infatti i due autovalori non nulli che troveremo sono positivi. Quindi A ha autovalore c con molteplicità almeno $n - 2$, e restano da trovare altri 2 autovalori.

Adesso scriviamo

$$bE + aF = \begin{bmatrix} f & g \end{bmatrix} \begin{bmatrix} af^T + bg^T \\ bf^T + ag^T \end{bmatrix}.$$

Questa scomposizione funziona più in generale. Applicando il teorema di commutazione dello spettro per moltiplicazione di matrici, invertiamo l'ordine e calcoliamo gli autovalori della matrice risultante, che sono i due autovalori non banali rimanenti. Abbiamo quindi

$$\begin{aligned} \begin{bmatrix} af^T + bg^T \\ bf^T + ag^T \end{bmatrix} \begin{bmatrix} f & g \end{bmatrix} &= \begin{pmatrix} a\|f\|_2^2 & b\|g\|_2^2 \\ b\|f\|_2^2 & a\|g\|_2^2 \end{pmatrix} \\ &= \frac{n}{2} \begin{pmatrix} a & b \\ b & a \end{pmatrix}. \end{aligned} \quad \left. \vphantom{\begin{aligned} \begin{bmatrix} af^T + bg^T \\ bf^T + ag^T \end{bmatrix} \begin{bmatrix} f & g \end{bmatrix} = \begin{pmatrix} a\|f\|_2^2 & b\|g\|_2^2 \\ b\|f\|_2^2 & a\|g\|_2^2 \end{pmatrix} } \right\} n \text{ è pari}$$

Gli autovalori di questa matrice sono

$$\frac{n}{2}(a + b), \quad \frac{n}{2}(a - b).$$

Quindi gli autovalori di A sono c , con molteplicità $n - 2$, e

$$c + \frac{n}{2}(a + b), \quad c + \frac{n}{2}(a - b),$$

entrambi con molteplicità 1.

Poiché $c > 0$ e $a > b$, tutti gli autovalori di A sono positivi. Inoltre A è reale simmetrica, quindi è definita positiva. Di conseguenza, il metodo di Gauss-Seidel applicato al sistema $Ax = d$ converge.

Formula generale del complemento di Schur. Se E è invertibile, allora

$$\begin{pmatrix} E & F \\ G & H \end{pmatrix} = \begin{pmatrix} I & 0 \\ GE^{-1} & I \end{pmatrix} \begin{pmatrix} E & 0 \\ 0 & H - GE^{-1}F \end{pmatrix} \begin{pmatrix} I & E^{-1}F \\ 0 & I \end{pmatrix}$$

con matrici quadrate di dimensioni compatibili.

Esercizio Spettro, soluzione veloce e convergenza per una matrice a blocchi

Sia

$$A = \begin{pmatrix} B_1 & C \\ 0 & B_2 \end{pmatrix}$$

una matrice a blocchi, con $m_1, m_2 \in \mathbb{N}^+$, $m_1, m_2 \geq 2$, $n = m_1 + m_2$, così da definire $B_1 \in \text{Mat}_{m_1}(\mathbb{R})$, $B_2 \in \text{Mat}_{m_2}(\mathbb{R})$, e $C \in \text{Mat}_{m_1 \times m_2}(\mathbb{R})$ tale che

$$(C)_{i,j} = 1 + i, \quad 1 \leq i \leq m_1, \quad 1 \leq j \leq m_2.$$

Le matrici hanno forma

$$B_1 = \begin{pmatrix} 3 & -1 & & & \\ -1 & 3 & -1 & & \\ & -1 & \ddots & \ddots & \\ & & \ddots & \ddots & -1 \\ & & & -1 & 3 \end{pmatrix}, \quad B_2 = \begin{pmatrix} 2 & \alpha_1 & & & \\ \delta_1 & 2 & \alpha_2 & & \\ & \delta_2 & \ddots & \ddots & \\ & & \ddots & \ddots & \alpha_{m_2-1} \\ & & & \delta_{m_2-1} & 12 \end{pmatrix}$$

dove la diagonale di B_2 è tutta costante tranne l'ultimo elemento, e gli elementi sono definiti come

$$\alpha_j = 1 + \frac{1}{9+j}, \quad \frac{1}{10} \leq \delta_j \leq \frac{1}{5}, \quad j = 1, \dots, m_2 - 1.$$

1. Studiare lo spettro di A ;
2. Determinare se $\exists_{=1} \lambda$ autovalore tale che $\lambda = \rho(A)$;
3. Determinare se A è invertibile;
4. Trovare un algoritmo veloce per risolvere $Ax = b$ e calcolarne il costo computazionale;
5. Mostrare la convergenza. Qual è il k minimo?

Soluzione

1. Dalla forma della matrice sappiamo che

$$\sigma(A) = \sigma(B_1) \cup \sigma(B_2).$$

Lo si vede usando la forma triangolare a blocchi. Studiamo quindi separatamente questi spettri. I dischi di Gershgorin di B_1 sono

$$D_1 = D_{m_1} = \{z \in \mathbb{C} \mid |z - 3| \leq 1\}, \\ D_i = \{z \in \mathbb{C} \mid |z - 3| \leq 2\}, \quad 1 < i < m_1.$$

Siccome la matrice è simmetrica, gli autovalori sono reali. Quindi possiamo leggere i dischi come intervalli reali, e otteniamo $\sigma(B_1) \subseteq [1, 5]$.

La matrice B_1 è irriducibile, in quanto il suo grafo associato è fortemente connesso (esempio con $m_1 = 6$):



Per il terzo teorema di Gershgorin, se un autovalore fosse 1 o 5, dovrebbe stare sul bordo di tutti i dischi, ma $1, 5 \notin D_1 = D_{m_1}$. Quindi $\sigma(B_1) \subseteq (1, 5)$. In realtà, essendo B_1 tridiagonale

di Toeplitz,

$$\sigma(B_1) = \left\{ 3 - 2 \cos \left(\frac{k\pi}{m_1 + 1} \right) \mid k = 1, \dots, m_1 \right\}.$$

Studiamo ora lo spettro di B_2 . Studiamo lo spettro di $\tilde{B} = DB_2D^{-1}$, con D diagonale invertibile, dato che matrici simili hanno lo stesso spettro. Costruiamo la matrice D come

$$D = \text{diag}(d_1, \dots, d_{m_2})$$

con

$$d_1 = 1, \quad \frac{d_{j+1}}{d_j} = \sqrt{\frac{\alpha_j}{\delta_j}}.$$

Eseguendo il prodotto troviamo

$$\tilde{B} = \begin{pmatrix} 2 & \alpha_1 \frac{d_1}{d_2} & & & \\ \delta_1 \frac{d_2}{d_1} & 2 & \alpha_2 \frac{d_2}{d_3} & & \\ & \delta_2 \frac{d_3}{d_2} & \ddots & \ddots & \\ & & \ddots & 2 & \alpha_{m_2-1} \frac{d_{m_2-1}}{d_{m_2}} \\ & & & \delta_{m_2-1} \frac{d_{m_2}}{d_{m_2-1}} & 12 \end{pmatrix} = \begin{pmatrix} 2 & \gamma_1 & & & \\ \gamma_1 & 2 & \gamma_2 & & \\ & \gamma_2 & \ddots & \ddots & \\ & & \ddots & 2 & \gamma_{m_2-1} \\ & & & \gamma_{m_2-1} & 12 \end{pmatrix},$$

dove $\gamma_j = \sqrt{\alpha_j \delta_j}$. Abbiamo precisamente scelto i valori d_j per ottenere una matrice simmetrica.

Calcoliamo ora i dischi di Gershgorin di questa matrice:

$$\begin{aligned} D_1 &= [2 - \gamma_1, 2 + \gamma_1], \\ D_i &= [2 - (\gamma_{i-1} + \gamma_i), 2 + (\gamma_{i-1} + \gamma_i)], \quad 1 < i < m_2, \\ D_{m_2} &= [12 - \gamma_{m_2-1}, 12 + \gamma_{m_2-1}]. \end{aligned}$$

I primi $m_2 - 1$ dischi stanno tutti vicino a 2, mentre l'ultimo sta vicino a 12.

Diamo un bound:

$$\frac{1}{10} \left(1 + \frac{1}{9+j} \right) \leq \alpha_j \delta_j \leq \frac{1}{5} \left(1 + \frac{1}{9+j} \right) \leq \frac{11}{50}.$$

Vogliamo anche stimare la somma:

$$\sqrt{\alpha_{i-1} \delta_{i-1}} + \sqrt{\alpha_i \delta_i} \leq \sqrt{\frac{i+9}{i+8} \frac{1}{5}} + \sqrt{\frac{i+10}{i+9} \frac{1}{5}} \leq \sqrt{\frac{11}{50}} + \sqrt{\frac{12}{55}},$$

dove il massimo si ottiene per $i = 2$. Quindi

$$\sigma(B_2) = \sigma(\tilde{B}) \subseteq \left[2 - \left(\sqrt{\frac{11}{50}} + \sqrt{\frac{12}{55}} \right), 2 + \sqrt{\frac{11}{50}} + \sqrt{\frac{12}{55}} \right] \cup \left[12 - \sqrt{\frac{11}{50}}, 12 + \sqrt{\frac{11}{50}} \right].$$

Il primo intervallo è contenuto in $(1, 3)$, mentre il secondo è isolato rispetto al primo. Per il secondo teorema di Gershgorin, il primo intervallo contiene $m_2 - 1$ autovalori di B_2 , mentre il secondo intervallo contiene un unico autovalore. Inoltre, per il terzo teorema di Gershgorin, siccome $\tilde{B}$ è irriducibile, questo autovalore non può stare sul bordo del disco isolato.

2. Per il secondo teorema di Gershgorin, c'è un unico autovalore λ_* di B_2 vicino a 12. Inoltre

$$\lambda_* \geq 12 - \sqrt{\frac{11}{50}} > 5,$$

mentre gli autovalori di B_1 stanno in $(1, 5)$ e gli altri autovalori di B_2 stanno nell'intervallo centrato in 2, che è contenuto in $(1, 3)$. Quindi

$$\rho(A) = \lambda_*,$$

e questo autovalore è unico.

3. A è invertibile in quanto $0 \notin \sigma(A)$.
 4. Siccome la matrice è a blocchi, possiamo scrivere

$$\begin{pmatrix} B_1 & C \\ 0 & B_2 \end{pmatrix} \begin{pmatrix} Z \\ Y \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}.$$

Quindi

$$B_1 Z + CY = b_1, \quad B_2 Y = b_2.$$

Dobbiamo quindi risolvere prima $B_2 Y = b_2$, e poi

$$B_1 Z = b_1 - CY.$$

Possiamo adoperare l'algoritmo di Thomas, cioè l'eliminazione di Gauss specializzata alle matrici tridiagonali, e poi risolvere con sostituzione all'indietro.

Per una matrice tridiagonale $r \times r$, la parte di eliminazione costa $5(r-1)$ operazioni, mentre la sostituzione all'indietro costa $1 + 3(r-1)$, quindi in totale $8r - 7$ operazioni.

Per CY non conviene costruire C : siccome $C_{i,j} = 1 + i$, si ha

$$(CY)_i = (1 + i) \sum_{j=1}^{m_2} Y_j.$$

Calcoliamo quindi $s = \sum_{j=1}^{m_2} Y_j$ in $m_2 - 1$ somme e poi $b_1 - CY$ in $2m_1$ operazioni. Il costo totale è quindi

$$(8m_2 - 7) + (m_2 - 1 + 2m_1) + (8m_1 - 7) = 10m_1 + 9m_2 - 15,$$

cioè $\mathcal{O}(m_1 + m_2)$.

5. Sia $A = M - N$ con

$$M = \begin{pmatrix} B_1 & 0 \\ 0 & B_2 \end{pmatrix}, \quad N = \begin{pmatrix} 0 & -C \\ 0 & 0 \end{pmatrix}.$$

Il metodo iterativo converge se

$$\lim_{k \rightarrow +\infty} (M^{-1}N)^k = 0.$$

Abbiamo

$$M^{-1} = \begin{pmatrix} B_1^{-1} & 0 \\ 0 & B_2^{-1} \end{pmatrix}, \quad M^{-1}N = \begin{pmatrix} B_1^{-1} & 0 \\ 0 & B_2^{-1} \end{pmatrix} \begin{pmatrix} 0 & -C \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & -B_1^{-1}C \\ 0 & 0 \end{pmatrix} = P.$$

Calcoliamo il quadrato della matrice di iterazione P per verificare dopo quanti passi il metodo converge esattamente:

$$P^2 = \begin{pmatrix} 0 & -B_1^{-1}C \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & -B_1^{-1}C \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

Quindi P è nilpotente, $\rho(P) = 0$, e il metodo converge. Siccome $P \neq 0$, il k minimo è $k = 2$.

Esercizio

Siano $n > 3$ e

$$B = \begin{pmatrix} 2 & -1 & \cdots & -1 \\ -\delta & 2 & & 0 \\ \vdots & & \ddots & \\ -\delta & 0 & & 2 \end{pmatrix} \in \text{Mat}_n(\mathbb{R}), \quad \frac{2}{n-1} < \delta < \frac{4}{n-1}.$$

Studiare lo spettro di B , risolvere il sistema $Bx = b$, con $b \in \mathbb{R}^n$, e stabilire la convergenza dei metodi di Jacobi e Gauss-Seidel.

Soluzione

Osserviamo anzitutto che i dischi di Gershgorin applicati direttamente alle righe non sono molto informativi: la prima riga ha raggio $n - 1$, quindi, per n grande, il disco corrispondente è molto ampio.

Per migliorare la stima usiamo una similitudine diagonale. Sia

$$D_r = \text{diag}(1, r, \dots, r), \quad r > 0.$$

Allora B è simile a

$$D_r^{-1} B D_r = \begin{pmatrix} 2 & -r & \cdots & -r \\ -\frac{\delta}{r} & 2 & & 0 \\ \vdots & & \ddots & \\ -\frac{\delta}{r} & 0 & & 2 \end{pmatrix}.$$

I raggi dei dischi di Gershgorin per righe sono

$$R_1 = (n-1)r, \quad R_i = \frac{\delta}{r}, \quad i = 2, \dots, n.$$

Bilanciamo i due raggi imponendo

$$(n-1)r = \frac{\delta}{r}, \quad \text{cioè} \quad r = \sqrt{\frac{\delta}{n-1}}.$$

Con questa scelta,

$$R_1 = R_i = \sqrt{(n-1)\delta}.$$

Poiché $\delta < \frac{4}{n-1}$, si ha

$$\sqrt{(n-1)\delta} < 2.$$

Quindi tutti gli autovalori stanno nel disco

$$\left\{ z \in \mathbb{C} : |z - 2| \leq \sqrt{(n-1)\delta} \right\},$$

che non contiene 0. In particolare B è non singolare.

Calcoliamo ora esattamente lo spettro. Scriviamo B come perturbazione di rango al più 2:

$$B = 2I_n + EF,$$

dove

$$E = \begin{pmatrix} 0 & 1 \\ 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \end{pmatrix} \in \text{Mat}_{n \times 2}(\mathbb{R}), \quad F = \begin{pmatrix} -\delta & 0 & \cdots & 0 \\ 0 & -1 & \cdots & -1 \end{pmatrix} \in \text{Mat}_{2 \times n}(\mathbb{R}).$$

Infatti EF è la matrice con prima riga

$$(0, -1, \dots, -1),$$

prima colonna, dalla seconda riga in poi,

$$(-\delta, \dots, -\delta)^T,$$

e tutti gli altri elementi nulli.

Gli autovalori non nulli di EF coincidono con quelli di FE . Ora

$$FE = \begin{pmatrix} 0 & -\delta \\ -(n-1) & 0 \end{pmatrix}.$$

Dunque

$$\det(\lambda I_2 - FE) = \lambda^2 - (n-1)\delta,$$

e quindi

$$\sigma(FE) = \left\{ -\sqrt{(n-1)\delta}, \sqrt{(n-1)\delta} \right\}.$$

Poiché EF ha rango al più 2, gli altri $n-2$ autovalori sono nulli. Pertanto

$$\sigma(EF) = \left\{ -\sqrt{(n-1)\delta}, \sqrt{(n-1)\delta}, \underbrace{0, \dots, 0}_{n-2 \text{ volte}} \right\}.$$

Siccome $B = 2I_n + EF$, otteniamo

$$\sigma(B) = \left\{ 2 - \sqrt{(n-1)\delta}, 2 + \sqrt{(n-1)\delta}, \underbrace{2, \dots, 2}_{n-2 \text{ volte}} \right\}.$$

In particolare, usando ancora $\delta < \frac{4}{n-1}$,

$$2 - \sqrt{(n-1)\delta} > 0,$$

quindi B è non singolare.

Un modo equivalente per vedere l'autovalore 2 è considerare il sottospazio

$$W = \left\{ v \in \mathbb{R}^n : v_1 = 0, \sum_{j=2}^n v_j = 0 \right\}.$$

Se $v \in W$, allora $EFv = 0$, quindi

$$Bv = 2v.$$

Poiché $\dim W = n-2$, l'autovalore 2 ha molteplicità almeno $n-2$, e dalla decomposizione precedente sappiamo che la molteplicità è esattamente $n-2$.

Passiamo ora alla risoluzione del sistema $Bx = b$. Le equazioni sono

$$\begin{aligned} 2x_1 - \sum_{j=2}^n x_j &= b_1, \\ -\delta x_1 + 2x_j &= b_j, \quad j = 2, \dots, n. \end{aligned}$$

Dalla seconda famiglia di equazioni ricaviamo

$$x_j = \frac{b_j + \delta x_1}{2}, \quad j = 2, \dots, n.$$

Poniamo

$$s_b = \sum_{j=2}^n b_j.$$

Allora

$$\sum_{j=2}^n x_j = \sum_{j=2}^n \frac{b_j + \delta x_1}{2} = \frac{s_b + (n-1)\delta x_1}{2}.$$

Sostituendo nella prima equazione,

$$\begin{array}{l} 2x_1 - \frac{s_b + (n-1)\delta x_1}{2} = b_1 \\ 4x_1 - s_b - (n-1)\delta x_1 = 2b_1 \\ (4 - (n-1)\delta)x_1 = 2b_1 + s_b. \end{array} \quad \left. \begin{array}{l} \\ \\ \end{array} \right\} \begin{array}{l} \text{moltiplichiamo per 2} \\ \text{raccoliamo } x_1 \end{array}$$

Poiché $4 - (n-1)\delta > 0$, otteniamo

$$x_1 = \frac{2b_1 + \sum_{j=2}^n b_j}{4 - (n-1)\delta}.$$

Poi, per $j = 2, \dots, n$,

$$x_j = \frac{b_j + \delta x_1}{2}.$$

Questa formula richiede soltanto il calcolo di una somma e poi il calcolo indipendente delle componenti x_j , $j = 2, \dots, n$. Bisogna però prestare attenzione alla stabilità numerica quando δ è molto vicino a $\frac{4}{n-1}$, perché il denominatore

$$4 - (n-1)\delta$$

diventa piccolo.

Studiamo infine Jacobi. La matrice diagonale di B è $D = 2I_n$, quindi la matrice di iterazione di Jacobi è

$$P_J = \frac{1}{2} \begin{pmatrix} 0 & 1 & \cdots & 1 \\ \delta & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \delta & 0 & \cdots & 0 \end{pmatrix}.$$

Sul sottospazio

$$W = \left\{ v \in \mathbb{R}^n : v_1 = 0, \sum_{j=2}^n v_j = 0 \right\}$$

la matrice P_J è nulla. Rimane quindi da studiare l'azione sul sottospazio generato da e_1 e dal vettore

$$w = (0, 1, \dots, 1)^T.$$

Rispetto alla base $\{e_1, w\}$, l'azione è descritta dalla matrice

$$\begin{pmatrix} 0 & \frac{n-1}{2} \\ \frac{\delta}{2} & 0 \end{pmatrix}.$$

Quindi

$$\sigma(P_J) = \left\{ -\frac{1}{2}\sqrt{(n-1)\delta}, \frac{1}{2}\sqrt{(n-1)\delta}, \underbrace{0, \dots, 0}_{n-2 \text{ volte}} \right\}.$$

Il raggio spettrale è

$$\rho(P_J) = \frac{1}{2}\sqrt{(n-1)\delta}.$$

Poiché $\delta < \frac{4}{n-1}$, segue che $\rho(P_J) < 1$. Dunque il metodo di Jacobi converge. Per Gauss-Seidel, dalla forma delle equazioni, l'errore soddisfa

$$\begin{aligned} e_1^{(k+1)} &= \frac{1}{2} \sum_{j=2}^n e_j^{(k)}, \\ e_i^{(k+1)} &= \frac{\delta}{2} e_1^{(k+1)} = \frac{\delta}{4} \sum_{j=2}^n e_j^{(k)}, \quad i = 2, \dots, n. \end{aligned}$$

Quindi, dopo un passo, l'errore appartiene al sottospazio generato da e_1 e da $w = (0, 1, \dots, 1)^T$. Su tale sottospazio, la matrice di iterazione di Gauss-Seidel ha autovalori 0 e

$$\frac{(n-1)\delta}{4}.$$

Di conseguenza

$$\rho(P_{GS}) = \frac{(n-1)\delta}{4} = \rho(P_J)^2.$$

Ancora una volta, poiché $\delta < \frac{4}{n-1}$, si ha

$$\rho(P_{GS}) < 1.$$

Dunque anche il metodo di Gauss-Seidel converge.

12 Esami

Esercizio Matrici a blocchi, localizzazione spettrale e metodi iterativi

Siano date le seguenti matrici:

$$\Delta_1 = \begin{pmatrix} 2 & i & 0 & 0 \\ -i & 2 & i & 0 \\ 0 & -i & 2 & i \\ 0 & 0 & -i & 4 \end{pmatrix}, \quad \Delta_2 = \begin{pmatrix} 25 & 1 \\ 1 & -25 \end{pmatrix}, \quad \Delta_3 = \begin{pmatrix} 2 & 1 & 1 & 1 \\ 1 & 2 & 1 & 1 \\ 1 & 1 & 2 & 1 \\ 1 & 1 & 1 & 2 \end{pmatrix},$$
$$F_{12} = \begin{pmatrix} 1 & -1 \\ -1 & 1 \\ 1 & -1 \\ 5 & 5 \end{pmatrix}, \quad F_{13} = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 1 & 2 & 3 & 4 \\ 1 & 2 & 3 & 4 \\ i & i & i & i \end{pmatrix}, \quad F_{23} = F_{12}^T, \quad i^2 = -1.$$

Si consideri la matrice a blocchi

$$A = \begin{pmatrix} \Delta_1 & F_{12} & F_{13} \\ 0 & \Delta_2 & F_{23} \\ 0 & 0 & \Delta_3 \end{pmatrix}.$$

Si richiede di:

1. localizzare lo spettro della matrice A nel modo migliore possibile;
2. studiare l'invertibilità, la forte non singolarità e le predominanze diagonali forti e deboli della matrice A ;
3. studiare la convergenza del metodo di Gauss-Seidel per la matrice A ;
4. studiare la convergenza del metodo di Jacobi per la matrice A .

Soluzione Soluzione

La matrice A è triangolare superiore a blocchi. Pertanto il suo spettro è dato dall'unione degli spettri dei blocchi diagonali:

$$\sigma(A) = \sigma(\Delta_1) \cup \sigma(\Delta_2) \cup \sigma(\Delta_3).$$

Per localizzare lo spettro è quindi conveniente applicare il teorema di Gershgorin ai singoli blocchi diagonali, evitando di introdurre i blocchi fuori diagonale F_{12}, F_{13}, F_{23} , che allargherebbero inutilmente i dischi.

Localizzazione dello spettro

Consideriamo innanzitutto

$$\Delta_1 = \begin{pmatrix} 2 & i & 0 & 0 \\ -i & 2 & i & 0 \\ 0 & -i & 2 & i \\ 0 & 0 & -i & 4 \end{pmatrix}.$$

I dischi di Gershgorin per righe sono

$$G(2, 1), \quad G(2, 2), \quad G(2, 2), \quad G(4, 1).$$

Poiché Δ_1 è hermitiana, i suoi autovalori sono reali. Intersecando quindi i dischi con l'asse reale si ottiene

$$[1, 3], \quad [0, 4], \quad [0, 4], \quad [3, 5].$$

Tali intervalli sono collegati, quindi Gershgorin non permette una separazione più fine. Otteniamo

$$\sigma(\Delta_1) \subset [0, 5].$$

Per il blocco

$$\Delta_2 = \begin{pmatrix} 25 & 1 \\ 1 & -25 \end{pmatrix}$$

i dischi di Gershgorin sono

$$G(25, 1), \quad G(-25, 1).$$

Essendo Δ_2 simmetrica reale, i suoi autovalori sono reali, quindi

$$\sigma(\Delta_2) \subset [24, 26] \cup [-26, -24].$$

I due intervalli sono disgiunti; dunque, per il secondo teorema di Gershgorin, c'è esattamente un autovalore in ciascuno di essi.

Infine, per

$$\Delta_3 = \begin{pmatrix} 2 & 1 & 1 & 1 \\ 1 & 2 & 1 & 1 \\ 1 & 1 & 2 & 1 \\ 1 & 1 & 1 & 2 \end{pmatrix},$$

ogni riga fornisce il disco

$$G(2, 3).$$

Poiché anche Δ_3 è simmetrica reale, si ottiene

$$\sigma(\Delta_3) \subset [-1, 5].$$

Combinando le tre localizzazioni:

$$\sigma(A) \subset [-26, -24] \cup [-1, 5] \cup [24, 26].$$

Più precisamente, un autovalore appartiene a $[-26, -24]$, un autovalore appartiene a $[24, 26]$, mentre gli altri otto appartengono a $[-1, 5]$.

Invertibilità e forte non singolarità

Essendo A triangolare superiore a blocchi, si ha

$$\det(A) = \det(\Delta_1) \det(\Delta_2) \det(\Delta_3).$$

Calcoliamo i determinanti dei blocchi diagonali.

Per Δ_1 , essendo tridiagonale, usiamo la ricorrenza sui determinanti principali di testa. Si ottiene

$$d_1 = 2, \quad d_2 = 3, \quad d_3 = 4, \quad d_4 = 13.$$

Dunque

$$\det(\Delta_1) = 13.$$

Per Δ_2 ,

$$\det(\Delta_2) = 25(-25) - 1 = -626.$$

Infine, osserviamo che

$$\Delta_3 = I_4 + \mathbf{1}\mathbf{1}^T,$$

dove $\mathbf{1} = (1, 1, 1, 1)^T$. Quindi

$$\det(\Delta_3) = 5.$$

Pertanto

$$\det(A) = 13 \cdot (-626) \cdot 5 = -40690 \neq 0.$$

Quindi

$$A \text{ è invertibile.}$$

Studiamo ora la forte non singolarità, intesa come non annullamento di tutti i minori principali di testa. I determinanti principali di testa dei blocchi diagonali sono:

$$\Delta_1 : \quad 2, 3, 4, 13,$$

$$\Delta_2 : \quad 25, -626,$$

$$\Delta_3 : \quad 2, 3, 4, 5.$$

Poiché A è triangolare superiore a blocchi, ogni minore principale di testa di A è prodotto dei corrispondenti minori principali di testa dei blocchi diagonali. Sono quindi tutti non nulli. Ne segue che

A è fortemente non singolare.

Predominanza diagonale

I moduli degli elementi diagonali di A sono

$$2, 2, 2, 4, 25, 25, 2, 2, 2, 2.$$

Le somme dei moduli degli elementi fuori diagonale per righe sono

$$13, 14, 14, 15, 9, 9, 3, 3, 3, 3.$$

Già la prima riga viola la condizione di predominanza diagonale debole per righe, infatti

$$2 < 13.$$

Quindi A non è diagonalmente dominante, nemmeno debolmente, per righe.

Le somme dei moduli degli elementi fuori diagonale per colonne sono

$$1, 2, 2, 1, 9, 9, 9, 12, 15, 26.$$

Anche per colonne la condizione di predominanza diagonale debole non è soddisfatta. Ad esempio, nella settima colonna si ha

$$2 < 9.$$

Pertanto A non è diagonalmente dominante, nemmeno debolmente, per colonne.

In conclusione,

A non è diagonalmente dominante né fortemente né debolmente, né per righe né per colonne.

Convergenza del metodo di Gauss-Seidel

Scriviamo

$$A = D + L + U,$$

dove D è la diagonale, L la parte strettamente inferiore e U la parte strettamente superiore. La matrice di iterazione di Gauss-Seidel è

$$T_{GS} = -(D + L)^{-1}U.$$

Poiché A è triangolare superiore a blocchi, anche T_{GS} è triangolare superiore a blocchi:

$$T_{GS}(A) = \begin{pmatrix} T_{GS}(\Delta_1) & * & * \\ 0 & T_{GS}(\Delta_2) & * \\ 0 & 0 & T_{GS}(\Delta_3) \end{pmatrix}.$$

Di conseguenza

$$\rho(T_{GS}(A)) = \max \{ \rho(T_{GS}(\Delta_1)), \rho(T_{GS}(\Delta_2)), \rho(T_{GS}(\Delta_3)) \}.$$

Per Δ_1 , abbiamo già calcolato i minori principali di testa:

$$2, 3, 4, 13.$$

Sono tutti positivi e Δ_1 è hermitiana; quindi Δ_1 è definita positiva. Il metodo di Gauss-Seidel converge per matrici hermitiane definite positive, dunque converge per Δ_1 .

Per Δ_2 , calcoliamo direttamente la matrice di iterazione. Si ha

$$T_{GS}(\Delta_2) = \begin{pmatrix} 0 & -\frac{1}{25} \\ 0 & -\frac{1}{625} \end{pmatrix}.$$

Quindi

$$\rho(T_{GS}(\Delta_2)) = \frac{1}{625} < 1.$$

Infine,

$$\Delta_3 = I_4 + \mathbf{1}\mathbf{1}^T.$$

Per ogni $x \neq 0$,

$$x^T \Delta_3 x = \|x\|^2 + (\mathbf{1}^T x)^2 > 0.$$

Quindi Δ_3 è definita positiva, e anche per Δ_3 il metodo di Gauss-Seidel converge.

Pertanto

$$\rho(T_{GS}(A)) < 1.$$

Concludiamo che

il metodo di Gauss-Seidel converge per la matrice A .

Convergenza del metodo di Jacobi

La matrice di iterazione di Jacobi è

$$T_J = -D^{-1}(L + U).$$

Anche in questo caso, poiché A è triangolare superiore a blocchi,

$$T_J(A) = \begin{pmatrix} T_J(\Delta_1) & * & * \\ 0 & T_J(\Delta_2) & * \\ 0 & 0 & T_J(\Delta_3) \end{pmatrix}.$$

Quindi è sufficiente studiare i blocchi diagonali.

Per il blocco Δ_3 , la diagonale è $D = 2I$. Pertanto

$$T_J(\Delta_3) = -\frac{1}{2} \begin{pmatrix} 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 0 \end{pmatrix}.$$

Prendendo il vettore

$$\mathbf{1} = (1, 1, 1, 1)^T,$$

si ha

$$T_J(\Delta_3)\mathbf{1} = -\frac{1}{2} \begin{pmatrix} 3 \\ 3 \\ 3 \\ 3 \end{pmatrix} = -\frac{3}{2}\mathbf{1}.$$

Dunque $-\frac{3}{2}$ è autovalore di $T_J(\Delta_3)$, e quindi anche di $T_J(A)$. Ne segue che

$$\rho(T_J(A)) \geq \frac{3}{2} > 1.$$

Pertanto

il metodo di Jacobi non converge per la matrice A .

Esercizio Perturbazioni immaginarie di una matrice a blocchi

Fissato $\alpha \in \mathbb{R}$ e data A come nell'esercizio precedente, siano $B(\alpha)$ e $C(\alpha)$ le matrici definite da

$$B(\alpha) = \alpha i I_{10} + A, \quad C(\alpha) = \alpha i D + A,$$

dove I_{10} è la matrice identità di dimensione 10 e

$$D = \text{diag}(d_j)_{1 \leq j \leq 10}, \quad d_1, d_2, \dots, d_{10} > 0.$$

Si richiede di:

1. dimostrare che, per ogni $\alpha \in \mathbb{R}$, le matrici $B(\alpha)$ e $C(\alpha)$ sono sempre invertibili;
2. stabilire se $C(\alpha)$ è sempre invertibile anche nel caso in cui $d_1, \dots, d_{10} \in \mathbb{R}$.

Soluzione Soluzione

Poiché A è triangolare superiore a blocchi, anche $B(\alpha)$ e $C(\alpha)$ sono triangolari superiori a blocchi. Poniamo

$$D_1 = \text{diag}(d_1, d_2, d_3, d_4), \quad D_2 = \text{diag}(d_5, d_6), \quad D_3 = \text{diag}(d_7, d_8, d_9, d_{10}).$$

Allora

$$B(\alpha) = \begin{pmatrix} \Delta_1 + i\alpha I_4 & F_{12} & F_{13} \\ 0 & \Delta_2 + i\alpha I_2 & F_{23} \\ 0 & 0 & \Delta_3 + i\alpha I_4 \end{pmatrix},$$

mentre

$$C(\alpha) = \begin{pmatrix} \Delta_1 + i\alpha D_1 & F_{12} & F_{13} \\ 0 & \Delta_2 + i\alpha D_2 & F_{23} \\ 0 & 0 & \Delta_3 + i\alpha D_3 \end{pmatrix}.$$

Di conseguenza, per studiare l'invertibilità, è sufficiente studiare l'invertibilità dei blocchi diagonali.

Invertibilità di $B(\alpha)$

Consideriamo un generico blocco diagonale

$$\Delta_k + i\alpha I.$$

Dall'esercizio precedente sappiamo che $\Delta_1, \Delta_2, \Delta_3$ sono hermitiane e invertibili.

Se $\alpha = 0$, allora

$$\Delta_k + i\alpha I = \Delta_k,$$

che è invertibile.

Sia ora $\alpha \neq 0$. Supponiamo per assurdo che esista $x \neq 0$ tale che

$$(\Delta_k + i\alpha I)x = 0.$$

Moltiplicando a sinistra per x^* , otteniamo

$$x^* \Delta_k x + i\alpha x^* x = 0.$$

Poiché Δ_k è hermitiana,

$$x^* \Delta_k x \in \mathbb{R}.$$

Inoltre

$$x^* x = \|x\|^2 > 0.$$

Prendendo la parte immaginaria si ottiene

$$\alpha \|x\|^2 = 0,$$

che è impossibile, perché $\alpha \neq 0$ e $x \neq 0$.

Quindi ogni blocco $\Delta_k + i\alpha I$ è invertibile. Poiché $B(\alpha)$ è triangolare superiore a blocchi con blocchi diagonali invertibili, segue che

$$B(\alpha) \text{ è invertibile per ogni } \alpha \in \mathbb{R}.$$

Invertibilità di $C(\alpha)$ con $d_j > 0$

Consideriamo ora un generico blocco

$$\Delta_k + i\alpha D_k.$$

Se $\alpha = 0$, il blocco coincide con Δ_k , quindi è invertibile.

Sia dunque $\alpha \neq 0$. Poiché $d_j > 0$ per ogni j , ogni matrice D_k è diagonale definita positiva.

Supponiamo per assurdo che esista $x \neq 0$ tale che

$$(\Delta_k + i\alpha D_k)x = 0.$$

Moltiplicando a sinistra per x^* , otteniamo

$$x^* \Delta_k x + i\alpha x^* D_k x = 0.$$

Il termine $x^* \Delta_k x$ è reale, perché Δ_k è hermitiana. Inoltre

$$x^* D_k x > 0$$

per ogni $x \neq 0$, perché D_k è definita positiva.

Prendendo la parte immaginaria si ottiene

$$\alpha x^* D_k x = 0,$$

che è impossibile, perché $\alpha \neq 0$ e $x^* D_k x > 0$.

Quindi ogni blocco diagonale di $C(\alpha)$ è invertibile. Essendo $C(\alpha)$ triangolare superiore a blocchi, segue che

$$C(\alpha) \text{ è invertibile per ogni } \alpha \in \mathbb{R}.$$

Caso $d_1, \dots, d_{10} \in \mathbb{R}$

Supponiamo ora che i coefficienti d_j siano reali, ma non necessariamente positivi.

I blocchi diagonali di $C(\alpha)$ sono ancora

$$\Delta_1 + i\alpha D_1, \quad \Delta_2 + i\alpha D_2, \quad \Delta_3 + i\alpha D_3.$$

Dall'esercizio precedente sappiamo che Δ_1 e Δ_3 sono hermitiane definite positive.

Infatti, per Δ_1 , i minori principali di testa sono

$$2, 3, 4, 13 > 0,$$

quindi, per il criterio di Sylvester, Δ_1 è definita positiva.

Inoltre

$$\Delta_3 = I_4 + \mathbf{1}\mathbf{1}^T,$$

dove $\mathbf{1} = (1, 1, 1, 1)^T$. Pertanto, per ogni $x \neq 0$,

$$x^* \Delta_3 x = \|x\|^2 + |\mathbf{1}^T x|^2 > 0.$$

Quindi anche Δ_3 è definita positiva.

Consideriamo $k = 1$ oppure $k = 3$. Se

$$(\Delta_k + i\alpha D_k)x = 0,$$

moltiplicando a sinistra per x^* otteniamo

$$x^* \Delta_k x + i\alpha x^* D_k x = 0.$$

Poiché D_k è diagonale reale,

$$x^* D_k x \in \mathbb{R}.$$

Prendendo la parte reale si ottiene

$$x^* \Delta_k x = 0.$$

Ma Δ_k è definita positiva, dunque necessariamente

$$x = 0.$$

Quindi i blocchi

$$\Delta_1 + i\alpha D_1 \quad \text{e} \quad \Delta_3 + i\alpha D_3$$

sono sempre invertibili anche se i d_j sono soltanto reali.

Resta da studiare il blocco centrale:

$$\Delta_2 + i\alpha D_2 = \begin{pmatrix} 25 + i\alpha d_5 & 1 \\ 1 & -25 + i\alpha d_6 \end{pmatrix}.$$

Calcoliamo il determinante:

$$\det(\Delta_2 + i\alpha D_2) = (25 + i\alpha d_5)(-25 + i\alpha d_6) - 1.$$

Sviluppando:

$$\det(\Delta_2 + i\alpha D_2) = -626 - \alpha^2 d_5 d_6 + 25i\alpha(d_6 - d_5).$$

Supponiamo che tale determinante sia nullo. Allora devono annullarsi sia la parte reale sia la parte immaginaria.

Dalla parte immaginaria otteniamo

$$25\alpha(d_6 - d_5) = 0.$$

Se $\alpha = 0$, allora

$$\det(\Delta_2) = -626 \neq 0.$$

Quindi deve essere $\alpha \neq 0$, e perciò

$$d_6 = d_5.$$

Ponendo

$$d_5 = d_6 = d,$$

la parte reale diventa

$$-626 - \alpha^2 d^2,$$

che è sempre strettamente negativa. Quindi non può annullarsi.

Pertanto

$$\det(\Delta_2 + i\alpha D_2) \neq 0$$

per ogni $\alpha \in \mathbb{R}$ e per ogni $d_5, d_6 \in \mathbb{R}$.

Concludiamo che anche nel caso $d_1, \dots, d_{10} \in \mathbb{R}$ tutti i blocchi diagonali sono invertibili. Dunque

$$C(\alpha) \text{ è sempre invertibile per ogni } \alpha \in \mathbb{R}.$$

Esercizio Matrice tridiagonale complessa ed eliminazione gaussiana

Sia $X \in M_n(\mathbb{C})$ tridiagonale con

$$X_{jj} = 2i^j, \quad i^2 = -1,$$

e

$$X_{jk} = X_{kj} = 1 \quad \text{se } |j - k| = 1,$$

per $j, k = 1, \dots, n$.

Si richiede di:

1. dimostrare che X è fortemente nonsingolare;
2. discutere, nel modo più preciso possibile, il costo computazionale del metodo di eliminazione gaussiana senza pivoting applicato al sistema lineare

$$Xy = b, \quad b \in \mathbb{C}^n.$$

Soluzione Soluzione

La matrice X è tridiagonale, con elementi diagonali

$$X_{jj} = 2i^j$$

e con elementi sopradiagonali e sottodiagonali uguali a 1.

Osserviamo innanzitutto che

$$|X_{jj}| = |2i^j| = 2$$

per ogni $j = 1, \dots, n$.

Forte nonsingularità

Studiamo una generica sottomatrice principale di X . Poiché X è tridiagonale, scegliendo un sottoinsieme di indici non necessariamente consecutivi, la corrispondente sottomatrice principale si decompone, a meno di una permutazione simultanea di righe e colonne, in somma diretta di blocchi tridiagonali associati a insiemi di indici consecutivi.

È quindi sufficiente studiare un generico blocco principale T relativo a indici consecutivi.

Per ogni riga di T , l'elemento diagonale ha modulo

$$|t_{jj}| = 2.$$

La somma dei moduli degli elementi fuori diagonale è invece

$$\sum_{k \neq j} |t_{jk}| = \begin{cases} 1, & \text{se } j \text{ è un estremo del blocco,} \\ 2, & \text{se } j \text{ è interno al blocco.} \end{cases}$$

Dunque T è diagonalmente dominante per righe.

Se il blocco ha dimensione 1, allora

$$T = (2i^j),$$

che è certamente nonsingolare.

Se invece il blocco ha dimensione almeno 2, allora T è irriducibile, perché è tridiagonale con sottodiagonale e sopradiagonale non nulle. Inoltre le righe estreme sono strettamente diagonalmente dominanti, poiché

$$2 > 1.$$

Quindi T è irriducibilmente diagonalmente dominante.

Per il teorema di Levy-Desplanques nella forma irriducibile, T è nonsingolare.

Pertanto ogni blocco principale è nonsingolare e quindi ogni sottomatrice principale di X è nonsingolare. In particolare tutti i minori principali di testa sono non nulli. Concludiamo che

X è fortemente nonsingolare.

Eliminazione gaussiana senza pivoting

Poiché X è fortemente nonsingolare, l'eliminazione gaussiana senza pivoting è ben definita: tutti i pivot sono non nulli.

Inoltre X è tridiagonale. L'eliminazione gaussiana senza pivoting non produce fill-in, quindi si ottiene una fattorizzazione

$$X = LU,$$

dove L è bidiagonale inferiore con diagonale unitaria e U è bidiagonale superiore.

Indichiamo con p_j i pivot. Il primo pivot è

$$p_1 = 2i.$$

Poiché gli elementi sottodiagonali e sopradiagonali sono tutti uguali a 1, per $j = 1, \dots, n-1$ si ha

$$m_j = \frac{1}{p_j},$$

e

$$p_{j+1} = 2i^{j+1} - m_j.$$

Qui m_j è il moltiplicatore dell'eliminazione gaussiana.

Applicando l'eliminazione anche al termine noto, poniamo

$$\beta_1 = b_1.$$

Per $j = 1, \dots, n-1$, si ottiene

$$\beta_{j+1} = b_{j+1} - m_j \beta_j.$$

Una volta completata la fase di eliminazione, si risolve il sistema triangolare superiore mediante sostituzione all'indietro. Si ha

$$y_n = \frac{\beta_n}{p_n},$$

e, per $j = n-1, \dots, 1$,

$$y_j = \frac{\beta_j - y_{j+1}}{p_j}.$$

Quindi l'algoritmo ha costo lineare in n . Più precisamente, sfruttando la struttura tridiagonale e il fatto che gli elementi fuori diagonale valgono 1, abbiamo:

$$n-1$$

divisioni complesse per calcolare i moltiplicatori m_j ;

$$n-1$$

sottrazioni complesse per aggiornare i pivot p_j ;

$$n-1$$

moltiplicazioni complesse e

$$n-1$$

sottrazioni complesse per aggiornare il termine noto;

$$n$$

divisioni complesse e

$$n-1$$

sottrazioni complesse per la sostituzione all'indietro.

In totale, per risolvere il sistema $Xy = b$, servono

$$2n - 1$$

divisioni complesse,

$$n - 1$$

moltiplicazioni complesse, e

$$3n - 3$$

somme o sottrazioni complesse.

Pertanto il costo computazionale complessivo è

$$O(n).$$

Anche la memoria richiesta è lineare:

$$O(n),$$

oppure $O(1)$ memoria aggiuntiva se gli aggiornamenti vengono effettuati in-place.

Esercizio Matrice a blocchi dipendente da un parametro

Dati $\alpha \in \mathbb{R}$, $m, n \in \mathbb{N}$, con $\alpha > 0$, $m \geq 2$, $n \geq 100$, si consideri

$$A(\alpha) \in M_{n+m}(\mathbb{R})$$

definita da

$$A(\alpha) := \begin{pmatrix} B & O \\ D(\alpha) & C(\alpha) \end{pmatrix},$$

dove

$$B \in M_n(\mathbb{R}), \quad D(\alpha) \in \mathbb{R}^{m \times n}, \quad C(\alpha) \in M_m(\mathbb{R}),$$

con

$$B_{j,k} := \begin{cases} 1 + \frac{j}{n^2}, & \text{se } j = k, \\ \frac{\sqrt{jk}}{n^2}, & \text{se } j \neq k, \end{cases}$$

$$C_{j,k}(\alpha) := \begin{cases} 2, & \text{se } j = k, \\ \frac{1}{\alpha}, & \text{se } j - k = 1, \\ \alpha, & \text{se } j - k = -1, \\ 0, & \text{altrimenti,} \end{cases}$$

e

$$D_{j,k}(\alpha) := \alpha j + \alpha^2 k.$$

Si richiede di:

1. localizzare lo spettro di B e di $C(\alpha)$, e localizzare lo spettro di $A(\alpha)$;
2. dimostrare la forte nonsingularità di $A(\alpha)$ per ogni $\alpha > 0$, $m \geq 2$, $n \geq 100$;
3. per $m = 2$, calcolare esplicitamente

$$f(\alpha) = \det(A(\alpha))$$

e studiare la funzione $f(\alpha)$.

Soluzione Soluzione

La matrice $A(\alpha)$ è triangolare inferiore a blocchi, infatti

$$A(\alpha) = \begin{pmatrix} B & O \\ D(\alpha) & C(\alpha) \end{pmatrix}.$$

Pertanto lo spettro di $A(\alpha)$ è dato dall'unione degli spettri dei blocchi diagonali:

$$\sigma(A(\alpha)) = \sigma(B) \cup \sigma(C(\alpha)).$$

Il blocco $D(\alpha)$ non influenza né lo spettro né il determinante.

Localizzazione dello spettro di B

La matrice B è simmetrica reale, quindi i suoi autovalori sono reali.

Applichiamo il teorema di Gershgorin per righe. Per la riga j -esima il centro è

$$c_j = 1 + \frac{j}{n^2},$$

mentre il raggio è

$$r_j = \sum_{\substack{k=1 \\ k \neq j}}^n \frac{\sqrt{jk}}{n^2}.$$

Ponendo

$$S_n = \sum_{k=1}^n \sqrt{k},$$

si ottiene

$$r_j = \frac{\sqrt{j}}{n^2} (S_n - \sqrt{j}).$$

Dunque gli intervalli di Gershgorin sono

$$I_j = \left[1 + \frac{j}{n^2} - \frac{\sqrt{j}}{n^2} (S_n - \sqrt{j}), 1 + \frac{j}{n^2} + \frac{\sqrt{j}}{n^2} (S_n - \sqrt{j}) \right].$$

Equivalentemente,

$$I_j = \left[1 + \frac{2j - \sqrt{j}S_n}{n^2}, 1 + \frac{\sqrt{j}S_n}{n^2} \right].$$

Quindi

$$\sigma(B) \subset \bigcup_{j=1}^n I_j.$$

Poiché

$$S_n < n\sqrt{n},$$

si ha, per ogni $j = 1, \dots, n$,

$$1 + \frac{2j - \sqrt{j}S_n}{n^2} > 0,$$

e inoltre

$$1 + \frac{\sqrt{j}S_n}{n^2} < 2.$$

Pertanto

$$\sigma(B) \subset (0, 2).$$

Quindi una localizzazione tramite Gershgorin è

$$\sigma(B) \subset \bigcup_{j=1}^n \left[1 + \frac{2j - \sqrt{j}S_n}{n^2}, 1 + \frac{\sqrt{j}S_n}{n^2} \right] \subset (0, 2).$$

Localizzazione dello spettro di $C(\alpha)$

La matrice $C(\alpha)$ è tridiagonale, con diagonale principale uguale a 2, sopradiagonale uguale ad α e sottodiagonale uguale a $\frac{1}{\alpha}$.

Osserviamo che $C(\alpha)$ è simile alla matrice simmetrica tridiagonale

$$T_m = \begin{pmatrix} 2 & 1 & 0 & \cdots & 0 \\ 1 & 2 & 1 & \ddots & \vdots \\ 0 & 1 & 2 & \ddots & 0 \\ \vdots & \ddots & \ddots & \ddots & 1 \\ 0 & \cdots & 0 & 1 & 2 \end{pmatrix}.$$

Infatti, prendendo

$$P = \text{diag}(1, \alpha^{-1}, \alpha^{-2}, \dots, \alpha^{-(m-1)}),$$

si ha

$$C(\alpha) = PT_m P^{-1}.$$

Quindi

$$\sigma(C(\alpha)) = \sigma(T_m).$$

Applichiamo Gershgorin a T_m . Le righe estreme hanno centro 2 e raggio 1, mentre le righe interne hanno centro 2 e raggio 2. Dunque

$$\sigma(C(\alpha)) \subset [0, 4].$$

Più precisamente, se $m = 2$, ci sono solo le righe estreme e quindi

$$\sigma(C(\alpha)) \subset [1, 3].$$

Se invece $m \geq 3$, otteniamo

$$\sigma(C(\alpha)) \subset [0, 4].$$

In conclusione,

$$\sigma(C(\alpha)) \subset \begin{cases} [1, 3], & \text{se } m = 2, \\ [0, 4], & \text{se } m \geq 3. \end{cases}$$

Localizzazione dello spettro di $A(\alpha)$

Poiché

$$\sigma(A(\alpha)) = \sigma(B) \cup \sigma(C(\alpha)),$$

dalle localizzazioni precedenti segue

$$\sigma(A(\alpha)) \subset (0, 2) \cup [0, 4].$$

Quindi

$$\sigma(A(\alpha)) \subset [0, 4].$$

Più precisamente,

$$\sigma(A(\alpha)) \subset \left(\bigcup_{j=1}^n \left[1 + \frac{2j - \sqrt{j}S_n}{n^2}, 1 + \frac{\sqrt{j}S_n}{n^2} \right] \right) \cup \begin{cases} [1, 3], & \text{se } m = 2, \\ [0, 4], & \text{se } m \geq 3. \end{cases}$$

Forte nonsingularità di $A(\alpha)$

Studiamo i minori principali di testa.

Per $q \leq n$, il minore principale di testa di ordine q coincide con il blocco principale di testa B_q di B . Osserviamo che

$$B_q = I_q + \frac{1}{n^2} v_q v_q^T,$$

dove

$$v_q = (1, \sqrt{2}, \dots, \sqrt{q})^T.$$

Per ogni $x \neq 0$,

$$x^T B_q x = \|x\|^2 + \frac{1}{n^2} (v_q^T x)^2 > 0.$$

Quindi B_q è definita positiva, e in particolare

$$\det(B_q) \neq 0.$$

Ora consideriamo un minore principale di testa di ordine $n + r$, con $1 \leq r \leq m$. Esso ha forma

$$\begin{pmatrix} B & O \\ D_r(\alpha) & C_r(\alpha) \end{pmatrix},$$

dove $C_r(\alpha)$ è il blocco principale di testa di ordine r di $C(\alpha)$. Essendo questa matrice triangolare a blocchi,

$$\det \begin{pmatrix} B & O \\ D_r(\alpha) & C_r(\alpha) \end{pmatrix} = \det(B) \det(C_r(\alpha)).$$

Abbiamo già visto che B è definita positiva, quindi

$$\det(B) \neq 0.$$

Resta da studiare $\det(C_r(\alpha))$. Poniamo

$$\delta_r = \det(C_r(\alpha)).$$

Poiché $C_r(\alpha)$ è tridiagonale, si ha

$$\delta_0 = 1, \quad \delta_1 = 2.$$

Per $r \geq 2$,

$$\delta_r = 2\delta_{r-1} - \alpha \frac{1}{\alpha} \delta_{r-2}.$$

Quindi

$$\delta_r = 2\delta_{r-1} - \delta_{r-2}.$$

Da questa ricorrenza segue per induzione che

$$\delta_r = r + 1.$$

Infatti

$$\delta_1 = 2, \quad \delta_2 = 3, \quad \delta_3 = 4,$$

e il passo induttivo dà

$$\delta_r = 2r - (r - 1) = r + 1.$$

Pertanto

$$\det(C_r(\alpha)) = r + 1 \neq 0.$$

Tutti i minori principali di testa di $A(\alpha)$ sono dunque non nulli. Concludiamo che

$A(\alpha)$ è fortemente nonsingolare per ogni $\alpha > 0$, $m \geq 2$, $n \geq 100$.

Caso $m = 2$: calcolo e studio di $f(\alpha)$

Per $m = 2$,

$$C(\alpha) = \begin{pmatrix} 2 & \alpha \\ \frac{1}{\alpha} & 2 \end{pmatrix}.$$

Poiché $A(\alpha)$ è triangolare a blocchi,

$$\det(A(\alpha)) = \det(B) \det(C(\alpha)).$$

Calcoliamo $\det(B)$. Si ha

$$B = I_n + \frac{1}{n^2} v v^T,$$

dove

$$v = (1, \sqrt{2}, \dots, \sqrt{n})^T.$$

Per il lemma del determinante,

$$\det(B) = 1 + \frac{1}{n^2} v^T v.$$

Ora

$$v^T v = \sum_{j=1}^n j = \frac{n(n+1)}{2}.$$

Quindi

$$\det(B) = 1 + \frac{1}{n^2} \frac{n(n+1)}{2} = 1 + \frac{n+1}{2n} = \frac{3n+1}{2n}.$$

Inoltre

$$\det(C(\alpha)) = 4 - \alpha \frac{1}{\alpha} = 3.$$

Pertanto

$$f(\alpha) = \det(A(\alpha)) = \frac{3n+1}{2n} \cdot 3.$$

Cioè

$$f(\alpha) = \frac{3(3n+1)}{2n}.$$

La funzione f è costante rispetto ad α . In particolare,

$$f'(\alpha) = 0$$

per ogni $\alpha > 0$, e

$$f(\alpha) > 0.$$

Quindi f non ha zeri, non cambia segno ed è costante su tutto l'intervallo

$$(0, +\infty).$$

Esercizio Matrice diagonale più rango uno e matrice a blocchi

Siano $\alpha \in \mathbb{R}$, $n > 100$, e siano

$$b_j = 1 - \frac{1}{(j+1)^2}, \quad a_j = \frac{1}{2} \left(b_j + \frac{1}{b_j} \right), \quad j = 1, \dots, n-2.$$

Si consideri la matrice $Q \in M_{n-2}(\mathbb{R})$ definita da

$$Q = \begin{pmatrix} a_1 & 1 & \cdots & 1 \\ 1 & a_2 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & a_{n-2} \end{pmatrix}.$$

Si consideri inoltre la matrice $P_\alpha \in M_n(\mathbb{R})$ definita da

$$P_\alpha = \begin{pmatrix} 1 & 0 & \cdots & 0 & 1 \\ 0 & & & & 0 \\ \vdots & & Q & & \vdots \\ 0 & & & & 0 \\ 1 & 0 & \cdots & 0 & \alpha \end{pmatrix}.$$

Si richiede di:

1. dimostrare che Q è definita positiva;
2. dare condizioni necessarie e sufficienti su $\alpha \in \mathbb{R}$ affinché P_α sia definita positiva;
3. descrivere due algoritmi di costo computazionale lineare in n per il calcolo di $x \in \mathbb{C}^{n-2}$, soluzione di

$$Qx = b,$$

e di $y \in \mathbb{C}^n$, soluzione di

$$P_\alpha y = c,$$

con $b \in \mathbb{C}^{n-2}$ e $c \in \mathbb{C}^n$.

Soluzione Soluzione

Poniamo

$$N = n - 2.$$

Allora $Q \in M_N(\mathbb{R})$. Per $j = 1, \dots, N$, si ha

$$b_j = 1 - \frac{1}{(j+1)^2} = \frac{j(j+2)}{(j+1)^2} > 0.$$

Inoltre

$$a_j = \frac{1}{2} \left(b_j + \frac{1}{b_j} \right).$$

Definita positività di Q

Poiché Q ha tutti gli elementi fuori diagonale uguali a 1, possiamo scriverla come

$$Q = \mathbf{1}\mathbf{1}^T + D,$$

dove

$$\mathbf{1} = (1, \dots, 1)^T \in \mathbb{R}^N$$

e

$$D = \text{diag}(d_1, \dots, d_N), \quad d_j = a_j - 1.$$

Calcoliamo d_j . Si ha

$$d_j = \frac{1}{2} \left(b_j + \frac{1}{b_j} \right) - 1 = \frac{b_j^2 + 1 - 2b_j}{2b_j} = \frac{(b_j - 1)^2}{2b_j}.$$

Poiché

$$b_j = 1 - \frac{1}{(j+1)^2},$$

segue che

$$b_j - 1 = -\frac{1}{(j+1)^2}.$$

Quindi

$$d_j = \frac{1}{2b_j(j+1)^4}.$$

Usando

$$b_j = \frac{j(j+2)}{(j+1)^2},$$

otteniamo

$$d_j = \frac{1}{2j(j+1)^2(j+2)}.$$

In particolare

$$d_j > 0 \quad \forall j = 1, \dots, N.$$

Dunque D è diagonale definita positiva.

Per ogni $x \in \mathbb{C}^N$, $x \neq 0$, si ha

$$x^* Q x = x^* \mathbf{1} \mathbf{1}^T x + x^* D x.$$

Poiché Q è reale simmetrica, possiamo scrivere

$$x^* Q x = \left| \sum_{j=1}^N x_j \right|^2 + \sum_{j=1}^N d_j |x_j|^2.$$

Il primo termine è non negativo, mentre il secondo è strettamente positivo per $x \neq 0$, perché $d_j > 0$ per ogni j . Quindi

$$x^* Q x > 0 \quad \forall x \neq 0.$$

Pertanto

Q è definita positiva.

Definita positività di P_α

La matrice P_α ha la forma

$$P_\alpha = \begin{pmatrix} 1 & 0 & \cdots & 0 & 1 \\ 0 & & & & 0 \\ \vdots & & Q & & \vdots \\ 0 & & & & 0 \\ 1 & 0 & \cdots & 0 & \alpha \end{pmatrix}.$$

Mediante una permutazione simultanea di righe e colonne, possiamo portare la prima e l'ultima coordinata vicine. La definita positività è preservata da permutazioni ortogonali, quindi P_α è congruente a

$$\begin{pmatrix} 1 & 1 & 0 \\ 1 & \alpha & 0 \\ 0 & 0 & Q \end{pmatrix}.$$

Poiché Q è definita positiva, P_α è definita positiva se e solo se è definita positiva la matrice

$$S_\alpha = \begin{pmatrix} 1 & 1 \\ 1 & \alpha \end{pmatrix}.$$

Per il criterio di Sylvester,

$$S_\alpha > 0 \iff 1 > 0 \quad \text{e} \quad \det(S_\alpha) > 0.$$

Ora

$$\det(S_\alpha) = \alpha - 1.$$

Pertanto

$$S_\alpha > 0 \iff \alpha > 1.$$

Concludiamo che

$$P_\alpha \text{ è definita positiva se e solo se } \alpha > 1.$$

Se $\alpha = 1$, il blocco S_α è semidefinito positivo ma singolare. Se $\alpha < 1$, il blocco S_α è indefinito.

Algoritmo lineare per risolvere $Qx = b$

Usiamo la struttura

$$Q = D + \mathbf{1}\mathbf{1}^T,$$

dove

$$D = \text{diag}(d_1, \dots, d_N), \quad d_j = \frac{1}{2j(j+1)^2(j+2)}.$$

Indichiamo il termine noto con $\beta \in \mathbb{C}^N$, per non confonderlo con i coefficienti b_j . Vogliamo risolvere

$$Qx = \beta.$$

L'equazione diventa

$$Dx + \mathbf{1}(\mathbf{1}^T x) = \beta.$$

Poniamo

$$\sigma = \mathbf{1}^T x = \sum_{j=1}^N x_j.$$

Allora, componente per componente,

$$d_j x_j + \sigma = \beta_j.$$

Quindi

$$x_j = \frac{\beta_j - \sigma}{d_j}.$$

Sommando rispetto a j , otteniamo

$$\sigma = \sum_{j=1}^N \frac{\beta_j - \sigma}{d_j} = \sum_{j=1}^N \frac{\beta_j}{d_j} - \sigma \sum_{j=1}^N \frac{1}{d_j}.$$

Pertanto

$$\sigma = \frac{\sum_{j=1}^N \frac{\beta_j}{d_j}}{1 + \sum_{j=1}^N \frac{1}{d_j}}.$$

Equivalentemente, ponendo

$$w_j = \frac{1}{d_j} = 2j(j+1)^2(j+2),$$

si calcolano

$$T = \sum_{j=1}^N w_j, \quad S = \sum_{j=1}^N w_j \beta_j.$$

Poi

$$\sigma = \frac{S}{1+T}.$$

Infine

$$x_j = w_j(\beta_j - \sigma), \quad j = 1, \dots, N.$$

L'algoritmo richiede solamente un numero costante di operazioni per ogni indice j . Dunque il costo computazionale è

$$\boxed{O(n)}.$$

Algoritmo lineare per risolvere $P_\alpha y = c$

Scriviamo

$$y = (y_1, z, y_n), \quad z \in \mathbb{C}^{n-2},$$

e

$$c = (c_1, \gamma, c_n), \quad \gamma \in \mathbb{C}^{n-2}.$$

Il sistema

$$P_\alpha y = c$$

è equivalente a

$$\begin{cases} y_1 + y_n = c_1, \\ Qz = \gamma, \\ y_1 + \alpha y_n = c_n. \end{cases}$$

Il sistema centrale

$$Qz = \gamma$$

si risolve in costo $O(n)$ con l'algoritmo precedente.

Resta il sistema 2×2

$$\begin{pmatrix} 1 & 1 \\ 1 & \alpha \end{pmatrix} \begin{pmatrix} y_1 \\ y_n \end{pmatrix} = \begin{pmatrix} c_1 \\ c_n \end{pmatrix}.$$

Se

$$\alpha \neq 1,$$

la soluzione è

$$y_n = \frac{c_n - c_1}{\alpha - 1},$$

e quindi

$$y_1 = c_1 - y_n = \frac{\alpha c_1 - c_n}{\alpha - 1}.$$

Dunque, per $\alpha \neq 1$, l'algoritmo è:

$$z = Q^{-1}\gamma,$$

calcolato con l'algoritmo lineare precedente, e poi

$$y_1 = \frac{\alpha c_1 - c_n}{\alpha - 1}, \quad y_n = \frac{c_n - c_1}{\alpha - 1}.$$

Il costo totale resta

$$\boxed{O(n)}.$$

Nel caso $\alpha = 1$, il sistema 2×2 diventa

$$y_1 + y_n = c_1, \quad y_1 + y_n = c_n.$$

Quindi:

$$\alpha = 1 : \begin{cases} \text{nessuna soluzione se } c_1 \neq c_n, \\ \text{infinita soluzioni se } c_1 = c_n. \end{cases}$$

In particolare,

$$P_\alpha \text{ è invertibile se e solo se } \alpha \neq 1.$$

Esercizio Matrice costruita per blocchi di righe

Sia $n > 100$ divisibile per 3 e siano

$$X, Y, Z \in \mathbb{C}^{\frac{n}{3} \times n}.$$

Si supponga che

$$X_{j,k} = 0 \quad \text{per } k > j, \quad k = 2, \dots, \frac{n}{3},$$

$$Y_{j,k} = 0 \quad \text{per } j, k = 1, \dots, \frac{n}{3},$$

e

$$Y_{j,k} = 0 \quad \text{per } k > j + \frac{n}{3}, \quad k = \frac{n}{3} + 2, \dots, \frac{2n}{3},$$

$$Z_{j,k} = 0 \quad \text{per } j = 1, \dots, \frac{n}{3}, \quad k = 1, \dots, \frac{2n}{3},$$

e

$$Z_{j,k} = 0 \quad \text{per } k < j + \frac{2n}{3}, \quad k = \frac{2n}{3} + 1, \dots, n-1.$$

Sia

$$A = \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \in M_n(\mathbb{C}).$$

Si richiede di:

1. dare condizioni necessarie e sufficienti per l'invertibilità di A ;
2. sotto le condizioni precedenti, esibire un algoritmo per la soluzione di un sistema lineare

$$Ax = b$$

di costo $O(n^2)$ operazioni aritmetiche.

Soluzione Soluzione

Poniamo

$$m = \frac{n}{3}.$$

Allora

$$X, Y, Z \in \mathbb{C}^{m \times n}.$$

Partizioniamo le colonne in tre blocchi di ampiezza m . Scriviamo

$$X = (X_1 \ X_2 \ X_3), \quad Y = (Y_1 \ Y_2 \ Y_3), \quad Z = (Z_1 \ Z_2 \ Z_3),$$

dove

$$X_i, Y_i, Z_i \in M_m(\mathbb{C}).$$

Dalle ipotesi della traccia segue che:

X_1 è triangolare inferiore,

$Y_1 = 0, \quad Y_2$ è triangolare inferiore,

$$Z_1 = 0, \quad Z_2 = 0, \quad Z_3 \text{ è triangolare superiore.}$$

Quindi A ha la forma a blocchi

$$A = \begin{pmatrix} X_1 & X_2 & X_3 \\ 0 & Y_2 & Y_3 \\ 0 & 0 & Z_3 \end{pmatrix}.$$

Condizioni necessarie e sufficienti per l'invertibilità

La matrice A è triangolare superiore a blocchi. Pertanto

$$\det(A) = \det(X_1) \det(Y_2) \det(Z_3).$$

Ne segue che

A è invertibile

se e solo se i tre blocchi diagonali

$$X_1, \quad Y_2, \quad Z_3$$

sono invertibili.

Ora, X_1 e Y_2 sono triangolari inferiori, mentre Z_3 è triangolare superiore. Ciascuno di questi blocchi è quindi invertibile se e solo se tutti i suoi elementi diagonali sono non nulli.

Pertanto

A è invertibile

se e solo se

$$\begin{aligned} X_{j,j} &\neq 0, & j &= 1, \dots, m, \\ Y_{j,m+j} &\neq 0, & j &= 1, \dots, m, \end{aligned}$$

e

$$Z_{j,2m+j} \neq 0, \quad j = 1, \dots, m.$$

In conclusione,

$$A \text{ è invertibile} \iff \begin{cases} X_{j,j} \neq 0, \\ Y_{j,m+j} \neq 0, \\ Z_{j,2m+j} \neq 0, \end{cases} \quad j = 1, \dots, m.$$

Algoritmo di costo $O(n^2)$ per risolvere $Ax = b$

Supponiamo ora verificate le condizioni precedenti, quindi A è invertibile.

Scriviamo

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}, \quad b = \begin{pmatrix} b_1 \\ b_2 \\ b_3 \end{pmatrix},$$

con

$$x_1, x_2, x_3 \in \mathbb{C}^m, \quad b_1, b_2, b_3 \in \mathbb{C}^m.$$

Il sistema

$$Ax = b$$

diventa

$$\begin{cases} X_1 x_1 + X_2 x_2 + X_3 x_3 = b_1, \\ Y_2 x_2 + Y_3 x_3 = b_2, \\ Z_3 x_3 = b_3. \end{cases}$$

Poiché A è triangolare superiore a blocchi, il sistema si risolve per sostituzione all'indietro a blocchi.

Primo passo

Si risolve

$$Z_3 x_3 = b_3.$$

Il blocco Z_3 è triangolare superiore e invertibile, quindi si usa sostituzione all'indietro.

Il costo è

$$O(m^2).$$

Secondo passo

Si calcola

$$\tilde{b}_2 = b_2 - Y_3 x_3.$$

Il prodotto $Y_3 x_3$ costa

$$O(m^2).$$

Poi si risolve

$$Y_2 x_2 = \tilde{b}_2.$$

Il blocco Y_2 è triangolare inferiore e invertibile, quindi si usa sostituzione in avanti.

Il costo complessivo del secondo passo è

$$O(m^2).$$

Terzo passo

Si calcola

$$\tilde{b}_1 = b_1 - X_2 x_2 - X_3 x_3.$$

I due prodotti matrice-vettore costano complessivamente

$$O(m^2).$$

Poi si risolve

$$X_1 x_1 = \tilde{b}_1.$$

Il blocco X_1 è triangolare inferiore e invertibile, quindi si usa sostituzione in avanti.

Il costo complessivo del terzo passo è

$$O(m^2).$$

Poiché

$$m = \frac{n}{3},$$

si ha

$$O(m^2) = O(n^2).$$

Quindi l'algoritmo totale ha costo

$$\boxed{O(n^2)}$$

operazioni aritmetiche.

Riassumendo, l'algoritmo è:

1. Risolvi $Z_3 x_3 = b_3$;
2. Risolvi $Y_2 x_2 = b_2 - Y_3 x_3$;
3. Risolvi $X_1 x_1 = b_1 - X_2 x_2 - X_3 x_3$.

Questo algoritmo sfrutta la struttura triangolare a blocchi di A e le strutture triangolari dei blocchi diagonali.

Esercizio Matrice bandata dipendente da un parametro

Sia $t > 2$ e sia $m \geq 100$. Si consideri la matrice

$$A_m(t) \in \mathbb{C}^{m \times m}$$

definita da

$$A_m(t) = \begin{pmatrix} 3 & t & t^2 & & 0 \\ t^{-1} & 3 & t & t^2 & \\ & t^{-1} & 3 & \ddots & \ddots \\ & & \ddots & \ddots & t & t^2 \\ 0 & & & t^{-1} & 3 & t \\ & & & & t^{-1} & 3 \end{pmatrix},$$

dove gli elementi omissi si intendono nulli.

Si richiede di:

1. dimostrare che $A_m(t)$ è invertibile per ogni $t > 2$ e per ogni $m \geq 100$;
2. trovare un valore $\gamma > 0$ tale che

$$|\lambda| > \gamma$$

per ogni autovalore λ di $A_m(t)$;

3. per $t = 11$, motivare l'applicabilità dell'algoritmo di eliminazione gaussiana senza pivoting e determinarne il costo computazionale.

Soluzione Soluzione

Poniamo

$$A = A_m(t).$$

La matrice A è bandata, con diagonale principale uguale a 3, sottodiagonale uguale a t^{-1} , prima sopradiagonale uguale a t e seconda sopradiagonale uguale a t^2 .

Invertibilità di $A_m(t)$

L'idea è usare una similitudine diagonale per trasformare A in una matrice strettamente diagonalmente dominante.

Poniamo

$$\rho = \frac{1}{2t}$$

e consideriamo la matrice diagonale

$$S = \text{diag}(1, \rho, \rho^2, \dots, \rho^{m-1}).$$

Definiamo

$$\tilde{A} = S^{-1}AS.$$

Poiché $\tilde{A}$ è simile ad A , le due matrici hanno lo stesso spettro. In particolare, A è invertibile se e solo se $\tilde{A}$ è invertibile.

Calcoliamo gli elementi non nulli di $\tilde{A}$. Per la diagonale principale si ha

$$\tilde{a}_{j,j} = 3.$$

Per la sottodiagonale:

$$\tilde{a}_{j,j-1} = t^{-1} \frac{\rho^{j-2}}{\rho^{j-1}} = t^{-1} \rho^{-1}.$$

Poiché

$$\rho^{-1} = 2t,$$

segue che

$$\tilde{a}_{j,j-1} = 2.$$

Per la prima sopradiagonale:

$$\tilde{a}_{j,j+1} = t \frac{\rho^j}{\rho^{j-1}} = t\rho = \frac{1}{2}.$$

Per la seconda sopradiagonale:

$$\tilde{a}_{j,j+2} = t^2 \frac{\rho^{j+1}}{\rho^{j-1}} = t^2 \rho^2 = \frac{1}{4}.$$

Quindi ogni riga interna di $\tilde{A}$ ha somma dei moduli degli elementi fuori diagonale al più

$$2 + \frac{1}{2} + \frac{1}{4} = \frac{11}{4}.$$

Le righe di bordo hanno somma ancora minore.

Poiché

$$|\tilde{a}_{j,j}| = 3$$

e

$$3 > \frac{11}{4},$$

la matrice $\tilde{A}$ è strettamente diagonalmente dominante per righe.

Per il teorema di Levy-Desplanques, $\tilde{A}$ è invertibile. Essendo A simile a $\tilde{A}$, anche A è invertibile.

Pertanto

$A_m(t)$ è invertibile per ogni $t > 2$ e per ogni $m \geq 100$.

Stima dal basso degli autovalori

Poiché A e $\tilde{A}$ sono simili, hanno gli stessi autovalori.

Applichiamo il teorema di Gershgorin a $\tilde{A}$. Tutti i dischi hanno centro 3 e raggio al più

$$\frac{11}{4}.$$

Quindi, per ogni autovalore λ , si ha

$$|\lambda - 3| \leq \frac{11}{4}.$$

Da questa inclusione segue

$$|\lambda| \geq 3 - \frac{11}{4} = \frac{1}{4}.$$

Mostriamo ora che la disuguaglianza è stretta. Supponiamo per assurdo che esista un autovalore λ tale che

$$|\lambda| \leq \frac{1}{4}.$$

Allora la matrice

$$\tilde{A} - \lambda I$$

ha diagonale

$$3 - \lambda.$$

Inoltre

$$|3 - \lambda| \geq 3 - |\lambda| \geq \frac{11}{4}.$$

La somma dei moduli degli elementi fuori diagonale è al più $\frac{11}{4}$, quindi $\tilde{A} - \lambda I$ è diagonalmente dominante per righe.

Inoltre $\tilde{A} - \lambda I$ è irriducibile, perché la sottodiagonale e la sopradiagonale sono non nulle. Almeno una riga è strettamente diagonalmente dominante, ad esempio una riga di bordo. Quindi $\tilde{A} - \lambda I$ è irriducibilmente diagonalmente dominante.

Per il teorema di Levy-Desplanques nella forma irriducibile, $\tilde{A} - \lambda I$ è invertibile. Questo è assurdo, perché λ è un autovalore di $\tilde{A}$.

Pertanto

$$|\lambda| > \frac{1}{4}$$

per ogni autovalore λ di $A_m(t)$. Possiamo quindi prendere

$$\gamma = \frac{1}{4}.$$

Caso $t = 11$: eliminazione gaussiana senza pivoting

Consideriamo ora

$$A_m(11).$$

L'eliminazione gaussiana senza pivoting è applicabile se e solo se tutti i pivot sono non nulli, cioè se tutti i minori principali di testa sono non nulli.

Ogni minore principale di testa di $A_m(11)$ è ancora una matrice dello stesso tipo, con dimensione più piccola. Applicando la stessa similitudine diagonale usata prima, con

$$\rho = \frac{1}{22},$$

si ottiene una matrice strettamente diagonalmente dominante per righe. Quindi ogni minore principale di testa è invertibile.

Pertanto tutti i pivot sono non nulli e l'eliminazione gaussiana senza pivoting è applicabile.

Inoltre $A_m(11)$ è una matrice bandata con ampiezza inferiore 1 e ampiezza superiore 2. Durante l'eliminazione senza pivoting non si genera fill-in fuori banda. Infatti si ottiene una fattorizzazione

$$A_m(11) = LU,$$

dove L è bidiagonale inferiore con diagonale unitaria e U ha diagonale principale, prima sopradiagonale e seconda sopradiagonale eventualmente non nulle.

A ogni passo dell'eliminazione si calcola un solo moltiplicatore e si aggiornano al più due elementi della riga successiva. Quindi il costo della fattorizzazione è lineare in m .

Più precisamente, la fattorizzazione richiede:

$$m - 1$$

divisioni per i moltiplicatori, e al più

$$2m - 3$$

moltiplicazioni e

$$2m - 3$$

sottrazioni per gli aggiornamenti.

Dunque il costo della fattorizzazione è

$$O(m).$$

Se si vuole anche risolvere un sistema lineare

$$A_m(11)x = b,$$

le sostituzioni in avanti e all'indietro hanno anch'esse costo lineare. Quindi il costo complessivo resta

$$O(m).$$

Esercizio Cerchi di Gershgorin e definita positività

Sia $t \in (0, 1]$ e sia $m \geq 100$. Si consideri la matrice

$$B_m(t) = D_m + tR_m,$$

dove D_m è diagonale e R_m è tale che

$$(R_m)_{ii} = 0 \quad \forall i = 1, \dots, m.$$

Si richiede di:

1. stabilire se è possibile trovare D_m e R_m tali che $B_m(1)$ abbia cerchi di Gershgorin la cui unione contiene $0_{\mathbb{C}}$ nella parte interna, e, al variare di t , $B_m(t)$ abbia cerchi di Gershgorin la cui unione non contiene $0_{\mathbb{C}}$;
2. discutere l'invertibilità di $B_m(1)$ assumendo la proprietà individuata al punto precedente;
3. stabilire se $B_m(t)$ non può essere definita positiva per nessun $t \in (0, 1]$, assumendo soltanto la proprietà individuata al punto 1.

Soluzione Soluzione

Indichiamo con J_m la matrice $m \times m$ con tutti gli elementi uguali a 1. Consideriamo la scelta

$$D_m = -I_m, \quad R_m = J_m - I_m.$$

Allora D_m è diagonale e R_m ha diagonale nulla, infatti

$$(R_m)_{ii} = 0 \quad \forall i = 1, \dots, m.$$

Con questa scelta si ha

$$B_m(t) = D_m + tR_m = -I_m + t(J_m - I_m).$$

Cerchi di Gershgorin

Per ogni riga di $B_m(t)$, l'elemento diagonale è

$$(B_m(t))_{ii} = -1.$$

Quindi il centro del disco di Gershgorin è

$$c_i = -1.$$

Gli elementi fuori diagonale sono tutti uguali a t , dunque il raggio è

$$r_i(t) = \sum_{j \neq i} |(B_m(t))_{ij}| = t(m-1).$$

Pertanto tutti i cerchi di Gershgorin coincidono:

$$G_t = \{z \in \mathbb{C} : |z + 1| \leq t(m-1)\}.$$

Per $t = 1$ si ha

$$G_1 = \{z \in \mathbb{C} : |z + 1| \leq m-1\}.$$

Poiché $m \geq 100$, si ha

$$m-1 > 1.$$

Dunque

$$0 \in \text{int}(G_1).$$

D'altra parte, se

$$0 < t < \frac{1}{m-1},$$

allora

$$t(m-1) < 1.$$

Quindi

$$0 \notin G_t.$$

Pertanto è possibile trovare D_m e R_m tali che $B_m(1)$ abbia unione dei cerchi di Gershgorin contenente $0_{\mathbb{C}}$ nella parte interna, mentre per opportuni valori di $t \in (0, 1)$ l'unione dei cerchi di Gershgorin di $B_m(t)$ non contiene $0_{\mathbb{C}}$.

Più precisamente, con la scelta precedente:

$$0 \notin \bigcup_i G_i(B_m(t)) \iff 0 < t < \frac{1}{m-1}.$$

Se invece la richiesta fosse interpretata come

$$0 \notin \bigcup_i G_i(B_m(t)) \quad \forall t \in (0, 1),$$

allora ciò sarebbe impossibile. Infatti, se per $t = 1$ si ha 0 nella parte interna dell'unione dei cerchi, allora per continuità dei raggi rispetto a t , 0 resta contenuto nell'unione dei cerchi anche per $t < 1$ sufficientemente vicino a 1.

Invertibilità di $B_m(1)$

Con la scelta fatta,

$$B_m(1) = -I_m + (J_m - I_m) = J_m - 2I_m.$$

Ricordiamo che gli autovalori di J_m sono:

$$m$$

con autovettore

$$\mathbf{1} = (1, \dots, 1)^T,$$

e

$$0$$

con molteplicità $m-1$, sul sottospazio ortogonale a $\mathbf{1}$.

Di conseguenza, gli autovalori di

$$B_m(1) = J_m - 2I_m$$

sono

$$m-2$$

e

$$-2$$

con molteplicità $m-1$.

Poiché

$$m \geq 100,$$

si ha

$$m-2 \neq 0,$$

e chiaramente

$$-2 \neq 0.$$

Pertanto

$$\boxed{B_m(1) \text{ è invertibile.}}$$

Questo mostra che il fatto che $0_{\mathbb{C}}$ appartenga alla parte interna dell'unione dei cerchi di Gershgorin non implica la singolarità della matrice. Il teorema di Gershgorin fornisce una localizzazione dello spettro, non una caratterizzazione esatta dello spettro.

Non definita positività di $B_m(t)$

Con la scelta precedente,

$$B_m(t) = -I_m + t(J_m - I_m).$$

Gli elementi diagonali sono

$$(B_m(t))_{ii} = -1 \quad \forall i = 1, \dots, m.$$

Se una matrice hermitiana fosse definita positiva, allora dovrebbe valere

$$e_i^* B_m(t) e_i > 0$$

per ogni vettore della base canonica e_i . Tuttavia

$$e_i^* B_m(t) e_i = (B_m(t))_{ii} = -1 < 0.$$

Quindi $B_m(t)$ non può essere definita positiva.

Pertanto

$$B_m(t) \text{ non è definita positiva per nessun } t \in (0, 1].$$

In particolare,

$$B_m(t) \text{ non è definita positiva per nessun } t \in (0, 1).$$

La proprietà dei cerchi del punto 1, da sola, non determina l'invertibilità di $B_m(1)$ né esclude la definita positività di $B_m(t)$. Infatti, scegliendo invece $D_m = I_m$ e $R_m = J_m - I_m$, i dischi hanno centro 1 e raggio $t(m-1)$: contengono 0 nell'interno per $t = 1$ e lo escludono per $0 < t < 1/(m-1)$. Tuttavia $B_m(1) = J_m$ è singolare e $B_m(t) = (1-t)I_m + tJ_m$ è definita positiva per ogni $0 < t < 1$, avendo autovalori $1-t$ e $1+t(m-1)$. Le conclusioni precedenti valgono quindi per la scelta $D_m = -I_m$, ma non seguono dalla sola proprietà richiesta.

Esercizio Localizzazione spettrale e metodo delle potenze

Sia data la matrice

$$A \in M_4(\mathbb{C})$$

definita da

$$A = \begin{pmatrix} 7 & 2 & 2 & 2 \\ 0 & -1 & 0 & \frac{1}{2} \\ 0 & 0 & 1 & \frac{i}{2} \\ 1 & 0 & -1 & -i \end{pmatrix}, \quad i^2 = -1.$$

Si richiede di:

1. localizzare lo spettro di A nel modo più preciso possibile;
2. in base alle informazioni spettrali ottenute, concludere se il metodo delle potenze converge.

Soluzione Soluzione

Vogliamo localizzare lo spettro di A usando il teorema di Gershgorin.

Localizzazione dello spettro

Applicando Gershgorin per righe, otteniamo i dischi

$$G_1 = \{z \in \mathbb{C} : |z - 7| \leq 6\},$$

$$G_2 = \left\{z \in \mathbb{C} : |z + 1| \leq \frac{1}{2}\right\},$$

$$G_3 = \left\{ z \in \mathbb{C} : |z - 1| \leq \frac{1}{2} \right\},$$

$$G_4 = \{ z \in \mathbb{C} : |z + i| \leq 2 \}.$$

Questi dischi non separano bene lo spettro, perché formano un'unica componente connessa. Conviene quindi applicare Gershgorin per colonne.

I dischi di Gershgorin per colonne sono:

$$\Gamma_1 = \{ z \in \mathbb{C} : |z - 7| \leq 1 \},$$

$$\Gamma_2 = \{ z \in \mathbb{C} : |z + 1| \leq 2 \},$$

$$\Gamma_3 = \{ z \in \mathbb{C} : |z - 1| \leq 3 \},$$

$$\Gamma_4 = \{ z \in \mathbb{C} : |z + i| \leq 3 \}.$$

Osserviamo che il disco

$$\Gamma_1 = \{ z \in \mathbb{C} : |z - 7| \leq 1 \}$$

è disgiunto dagli altri tre. Infatti:

$$|7 - (-1)| = 8 > 1 + 2,$$

$$|7 - 1| = 6 > 1 + 3,$$

e

$$|7 - (-i)| = |7 + i| = \sqrt{50} > 1 + 3.$$

Quindi Γ_1 è una componente connessa separata dell'unione dei dischi di Gershgorin. Per il secondo teorema di Gershgorin, in Γ_1 cade esattamente un autovalore, contato con molteplicità algebrica. Dunque esiste un autovalore λ_1 tale che

$$\lambda_1 \in \Gamma_1,$$

cioè

$$|\lambda_1 - 7| \leq 1.$$

In particolare,

$$|\lambda_1| \geq 7 - 1 = 6.$$

Gli altri tre autovalori appartengono a

$$\Gamma_2 \cup \Gamma_3 \cup \Gamma_4.$$

Inoltre

$$\Gamma_2 \subset \{ z \in \mathbb{C} : |z| \leq 3 \},$$

$$\Gamma_3 \subset \{ z \in \mathbb{C} : |z| \leq 4 \},$$

e

$$\Gamma_4 \subset \{ z \in \mathbb{C} : |z| \leq 4 \}.$$

Pertanto, se $\lambda \neq \lambda_1$ è un altro autovalore di A , allora

$$|\lambda| \leq 4.$$

Abbiamo quindi ottenuto la localizzazione

$$\sigma(A) \subset \{ z \in \mathbb{C} : |z - 7| \leq 1 \} \cup \{ z \in \mathbb{C} : |z + 1| \leq 2 \} \cup \{ z \in \mathbb{C} : |z - 1| \leq 3 \} \cup \{ z \in \mathbb{C} : |z + i| \leq 3 \}.$$

Più precisamente:

$$\text{un autovalore appartiene a } \{ z \in \mathbb{C} : |z - 7| \leq 1 \},$$

mentre

$$\text{gli altri tre appartengono a } \{z \in \mathbb{C} : |z + 1| \leq 2\} \cup \{z \in \mathbb{C} : |z - 1| \leq 3\} \cup \{z \in \mathbb{C} : |z + i| \leq 3\}.$$

In particolare,

$$|\lambda_1| \geq 6,$$

mentre, per ogni altro autovalore λ ,

$$|\lambda| \leq 4.$$

Dunque λ_1 è un autovalore dominante.

Convergenza del metodo delle potenze

Dal punto precedente sappiamo che esiste un autovalore λ_1 tale che

$$|\lambda_1| \geq 6,$$

mentre tutti gli altri autovalori soddisfano

$$|\lambda| \leq 4.$$

Quindi

$$|\lambda_1| > |\lambda|$$

per ogni altro autovalore λ .

Inoltre, poiché il disco Γ_1 contiene esattamente un autovalore contato con molteplicità algebrica, λ_1 è semplice.

Pertanto la matrice A ha un unico autovalore dominante, semplice e separato dagli altri in modulo. Ne segue che il metodo delle potenze converge alla direzione dell'autovettore associato a λ_1 , per ogni vettore iniziale con componente non nulla lungo tale autovettore dominante.

Quindi

$$\text{il metodo delle potenze converge, salvo scelte iniziali eccezionali.}$$

Più precisamente, il fattore asintotico di convergenza è al più

$$\frac{4}{6} = \frac{2}{3}.$$

Eventuali blocchi di Jordan non dominanti possono introdurre fattori polinomiali in k ; se A è diagonalizzabile, l'errore è dell'ordine

$$\left(\frac{2}{3}\right)^k.$$

Esercizio Raggio spettrale e norme matriciali

Si denoti con $\rho(A)$ il raggio spettrale di una matrice quadrata A , e con $\|A\|_1$ la norma matriciale indotta dalla norma vettoriale $\|\cdot\|_1$.

Dire se le seguenti affermazioni sono vere o false, giustificando le risposte:

1. $\rho(A) < 1$ e $\rho(B) < 1$ implica che $\rho(AB) < 1$;
2. $\rho(A) \geq 1$ e $\rho(B) \geq 1$ implica che $\rho(AB) \geq 1$;
3. $\|A\|_1 < 1$ e $\|B\|_1 < 1$ implica che $\rho(AB) < 1$;
4. $\|A\|_2 \geq 1$ e $\|B\|_2 \geq 1$ implica che $\rho(AB) \geq 1$.

Soluzione Soluzione

Prima affermazione

L'affermazione

$$\rho(A) < 1, \quad \rho(B) < 1 \implies \rho(AB) < 1$$

è falsa.

Infatti, consideriamo

$$A = \begin{pmatrix} 0 & 2 \\ 0 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 0 \\ 2 & 0 \end{pmatrix}.$$

Le matrici A e B sono nilpotenti, quindi

$$\rho(A) = 0, \quad \rho(B) = 0.$$

In particolare,

$$\rho(A) < 1, \quad \rho(B) < 1.$$

Tuttavia

$$AB = \begin{pmatrix} 4 & 0 \\ 0 & 0 \end{pmatrix}.$$

Dunque

$$\rho(AB) = 4 > 1.$$

Quindi la prima affermazione è

falsa.

Seconda affermazione

L'affermazione

$$\rho(A) \geq 1, \quad \rho(B) \geq 1 \implies \rho(AB) \geq 1$$

è falsa.

Consideriamo

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}.$$

Allora

$$\rho(A) = 1, \quad \rho(B) = 1.$$

Però

$$AB = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

Quindi

$$\rho(AB) = 0 < 1.$$

Pertanto la seconda affermazione è

falsa.

Terza affermazione

L'affermazione

$$\|A\|_1 < 1, \quad \|B\|_1 < 1 \implies \rho(AB) < 1$$

è vera.

Infatti, per ogni norma matriciale indotta vale

$$\rho(M) \leq \|M\|$$

per ogni matrice quadrata M . Inoltre la norma indotta è submoltiplicativa, quindi

$$\|AB\|_1 \leq \|A\|_1 \|B\|_1.$$

Pertanto

$$\rho(AB) \leq \|AB\|_1 \leq \|A\|_1 \|B\|_1.$$

Poiché

$$\|A\|_1 < 1 \quad \text{e} \quad \|B\|_1 < 1,$$

si ha

$$\|A\|_1 \|B\|_1 < 1.$$

Quindi

$$\rho(AB) < 1.$$

La terza affermazione è dunque

vera.

Quarta affermazione

L'affermazione

$$\|A\|_2 \geq 1, \quad \|B\|_2 \geq 1 \implies \rho(AB) \geq 1$$

è falsa.

Usiamo lo stesso controesempio del secondo punto:

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}.$$

Entrambe sono matrici diagonali, quindi

$$\|A\|_2 = 1, \quad \|B\|_2 = 1.$$

In particolare,

$$\|A\|_2 \geq 1, \quad \|B\|_2 \geq 1.$$

Tuttavia

$$AB = 0,$$

quindi

$$\rho(AB) = 0 < 1.$$

Pertanto la quarta affermazione è

falsa.

Riassumendo:

Affermazione	Risposta
1	Falsa
2	Falsa
3	Vera
4	Falsa