

Probability

Paolo Bettelini

Contents

1	Probabilità	2
1.1	Costruzione intuitiva	2
1.2	Formalizzazione	3
2	Indipendenza e condizionamento	8
2.1	Indipendenza	10
2.2	Applicazioni a sistemi di particelle	15
2.3	Urne varie	16
2.4	Variabili aleatorie	28
2.5	Vettori aleatori discreti	32
2.6	Indipendenza di variabili aleatorie discrete	36
3	Valore atteso o media di variabili aleatorie discrete	42
3.1	Varianza e covarianza	45
3.2	Correlazione	50
3.3	Medie e varianza di distribuzioni note	52
3.4	Somme di variabili aleatorie	58
4	Spazi di probabilità generali	59
4.1	Funzione di ripartizione o distribuzione	63
4.2	Eventi impossibili e densità continue	66
5	Variabili aleatorie in spazi continui	71
5.1	Variabili aleatorie assolutamente continue	73
5.2	Valore atteso di variabili aleatorie generiche	73
5.3	Variabili aleatorie assolutamente continue	75
5.4	Vettori aleatori assolutamente continui	78
5.5	Distribuzione uniforme	80
5.6	Distribuzione esponenziale	80
5.7	Indipendenza e vettori assolutamente continui	81
5.8	Covarianza tra due variabili aleatorie assolutamente continue	83
6	Vettori gaussiani	85
7	Probabilità condizionate e variabili aleatorie	92
7.1	Caso discreto	92
7.2	Caso continuo	94
8	Convergenza	96
8.1	Risultati asintotici	103
9	Esercizi	109

1 Probabilità

1.1 Costruzione intuitiva



Esempio Approccio classico alla probabilità

Consideriamo un'urna contenente 6 palline numerate da 1 a 6 e per il resto indistinguibili. Vogliamo studiare l'esperimento estrazione di una pallina dall'urna. Vogliamo studiare quale pallina sia più probabile che venga estratta. Vogliamo quindi mettere un ordinamento sull'insieme degli eventi di questo esperimento. Sia Ω l'insieme di tutti i possibili risultati dell'esperimento. Sia P_i la probabilità di estrarre il numero $i \in \{1, 2, 3, 4, 5, 6\}$. In questo caso la scelta naturale è $P_i = \frac{1}{6}$ per tutte le $i \in \{1, 2, 3, 4, 5, 6\}$. Notiamo che $\sum P_i = 1$, cioè la probabilità di estrarre un numero da 1 a 6, cioè in questo caso l'evento certo. Questa viene detta additività della probabilità di eventi disgiunti. Inoltre, la probabilità $P_j = 0$ con $j \notin \{1, 2, 3, 4, 5, 6\}$. Possiamo anche notare che

$$P_i = \frac{\text{Casi favorevoli}}{\text{Casi possibili}} = \frac{|\{i\}|}{|N|}$$

In questo caso i casi elementari $\{i\}$ sono equiprobabili.



Esempio Approccio frequentista alla probabilità

Consideriamo l'esperimento lancio di un dado a 6 facce numerate da 1 a 6. Abbiamo $\Omega = \{1, 2, 3, 4, 5, 6\}$. In questo caso non è detto che gli eventi o i casi elementari siano equiprobabili. Quindi, per assegnare i P_i potremmo lanciare il dado sperimentalmente.

$$P_i^{(k)} = \frac{N_i^{(k)}}{k}$$

con $N_i^{(k)}$ è il numero di volte che esce l'evento i su k lanci. Chiaramente questi valori sono variabili, quindi prendiamo

$$P_i = \lim_{k \rightarrow +\infty} P_i^{(k)}$$

per $i \in \{1, 2, 3, 4, 5, 6\}$ se il limite esiste. Notiamo che $P_i^{(k)} \in [0, 1]$ e

$$\sum_{i=1}^6 P_i^{(k)} = 1, \quad k \in \mathbb{N}$$

e prendendo il limite $k \rightarrow +\infty$

$$\sum_{i=1}^6 P_i = 1$$



In entrambi i casi abbiamo quindi le medesime proprietà ma nella seconda le probabilità non coincidono necessariamente.



Esempio Probabilità soggettiva

Consideriamo un torneo di calcio dove tutti giocano contro tutti, in cui partecipano 6 squadre: (1) R. Madrid, (2) M. City, (3) Bayer Monaco, (4) Atalanta, (5) Porto, (6) Nantes. L'esperimento che consideriamo è quello che studia il vincitore del torneo. Abbiamo $\Omega = \{1, 2, 3, 4, 5, 6\}$. L'approccio classico richiede casi elementari equiprobabili, e in questo caso non lo sono. L'approccio frequentista richiede di richiedere un torneo molte volte sotto le stesse condizioni, il che è praticamente impossibile. L'idea alternativa è quindi quella di chiedere a due esperti del settore di assegnare le probabilità in maniera coerente alle osservazioni che abbiamo fatto negli altri due approcci. Il primo esperto sceglie per esempio

$$P_1 = \frac{1}{4}, P_2 = \frac{1}{4}, P_3 = \frac{1}{5}, P_4 = \frac{1}{5}, P_5 = \frac{1}{10}, P_6 = 0$$

mentre il secondo

$$P_1 = \frac{11}{27}, P_2 = \frac{1}{3}, P_3 = \frac{1}{9}, P_4 = \frac{2}{27}, P_5 = \frac{1}{27}, P_6 = \frac{1}{27}$$

Chiaramente c'è natura soggettiva.



Definizione Probabilità soggettiva

Si definisce probabilità di un evento la misura del grado di fiducia, cioè un numero reale in $[0, 1]$, che in individuo coerente assegna al verificarsi dell'evento considerato, in base alle sue conoscenze. In altro modo, la probabilità di un evento è quanto un individuo coerente ritiene equo pagare per ricevere 1 se l'evento si verifica e 0 se non si verifica.



Ognuno degli approcci ricopre l'approccio precedente. Quello soggettivo è quello più generale.

1.2 Formalizzazione



Definizione Esito

Un *esito* è una qualsiasi asserzione della quale ne si può stabilire la veridicità osservando il risultato dell'esperimento.



Se abbiamo un'urna possiamo rappresentare gli eventi come punti su un segmento di punti, cioè tutte le possibili estrazioni. Con due urne posso fare lo stesso con una griglia discreta, e così via.



Definizione Evento

Un *evento* è un insieme di esiti.

Possiamo fare un ponte fra gli operatori della teoria degli insiemi e la logica degli eventi.

Siano A, B due eventi, indicati con i rispettivi insiemi di esiti A e B .

1. La *negazione* di un evento $\neg A$ corrisponde all'evento associato all'insieme complementare $\Omega \setminus A$.
2. La *somma* logica di due eventi $A + B$, cioè se almeno uno dei due eventi si verificano, corrisponde all'evento associato all'unione insiemistica $A \cup B$.

3. Il *prodotto* logico di due eventi $A \cdot B$, cioè se ambo gli avvenimenti si verificano, corrisponde all'evento associato all'intersezione insiemistica $A \cap B$.
4. La *differenza* logica di due eventi $A - B$ corrisponde all'evento associato alla differenza insiemistica $A \setminus B$.
5. La *differenza simmetrica* di due eventi $A \Delta B$ corrisponde all'evento associato alla differenza simmetrica insiemistica $(A \cap B^c) \cup (A^c \cap B)$.
6. L'*implicazione* logica di due eventi $A \implies B$ corrisponde all'evento associato alla relazione di sottoinsieme $A \subseteq B$.
7. L'*equivalenza* fra due eventi $A = B$, cioè $A \implies B$ e $B \implies A$, corrisponde all'uguaglianza insiemistica $A = B$.
8. Due eventi si dicono *incompatibili*, cioè se non possono verificarsi in contemporanea, corrisponde alla condizione che l'intersezione insiemistica sia vuota $A \cap B = \emptyset$.

La teoria degli insiemi non è esattamente la stessa cosa della teoria degli eventi. Per esempio la probabilità condizionata non corrisponde a nessun insieme.

Definizione

Nel caso della probabilità classica con Ω finito, possiamo scegliere l'insieme degli eventi come $\mathcal{P}(\Omega)$ e definire la misura come $\mathbb{P}: \mathcal{P}(\Omega) \rightarrow [0, 1]$ dato da

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}$$

per uno spazio equiprobabile.

Vogliamo espanderci al caso della probabilità soggettiva

Definizione

Sia $\Omega \neq \emptyset$ di cardinalità finita. Chiamiamo *misura di probabilità* su $\mathcal{P}(\Omega)$ una funzione $\mathbb{P}: \mathcal{P}(\Omega) \rightarrow [0, 1]$ tale che

1. $\mathbb{P}(\Omega) = 1$
2. $\forall A, B \in \mathcal{P}(\Omega)$ disgiunti,

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$$

Chiamiamo *spazio di probabilità con spazio campionato Ω di cardinalità finita* la terna $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$.

Proposition

Sia $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno spazio di probabilità con spazio campionato Ω di cardinalità finita. Allora,

1. per ogni $A \in \mathcal{P}(\Omega)$, $\mathbb{P}(\Omega \setminus A) = 1 - \mathbb{P}(A)$;
2. per ogni $A, B \in \mathcal{P}(\Omega)$ tale che $B \subseteq A$, $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(B)$
3. per ogni $A, B \in \mathcal{P}(\Omega)$, $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$
4. *Additività*: $\forall n \in \mathbb{N}$ e $A_1, \dots, A_n \in \mathcal{P}(\Omega)$ tale che $A_i \cap A_j = \emptyset$ per tutti gli $i \neq j$,

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \sum_{k=1}^n \mathbb{P}(A_k)$$

5. *Subadditività*: $\forall n \in \mathbb{N}$ e $A_1, \dots, A_n \in \mathcal{P}(\Omega)$

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) \leq \sum_{k=1}^n \mathbb{P}(A_k)$$

Proof

1.

$$\begin{aligned}\mathbb{P}(\Omega) &= \mathbb{P}(A \cup (\Omega \setminus A)) \\ &= \mathbb{P}(A) + \mathbb{P}(\Omega \setminus A)\end{aligned}$$

e quindi $\mathbb{P}(A) = 1 - \mathbb{P}(\Omega \setminus A)$.

2.

$$\mathbb{P}(A \setminus B) = \mathbb{P}(A \cap (\Omega \setminus B)) = 1 - \mathbb{P}(\Omega \setminus (A \cap (\Omega \setminus B)))$$

dal disegno degli insiemi

$$\begin{aligned}\mathbb{P}(A \setminus B) &= 1 - \mathbb{P}((\Omega \setminus A) \cup B) \\ &= 1 - \mathbb{P}(\Omega \setminus A) - \mathbb{P}(B) \\ &= \mathbb{P}(A) - \mathbb{P}(B)\end{aligned}$$

3.

$$\begin{aligned}\mathbb{P}(A \cup B) &= \mathbb{P}((A \setminus A \cap B) \cup (B \setminus A \cap B) \cup (A \cap B)) \\ &= \mathbb{P}(A \setminus A \cap B) + \mathbb{P}((B \setminus A \cap B) \cup (A \cap B)) \\ &= \mathbb{P}(A \setminus A \cap B) + \mathbb{P}(B \setminus A \cap B) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) - \mathbb{P}(A \cap B) + \mathbb{P}(B) - \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)\end{aligned}$$

4. Dimostriamo per induzione. Per $n = 2$ vale per la definizione. Assumiamo che la proposizione sia vera per n e mostriamo il passo successivo

$$\begin{aligned}\mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) &= \mathbb{P}\left(\bigcup_{i=1}^{n+1} A_i\right) \\ &= \mathbb{P}\left(\bigcup_{i=1}^n A_i\right) + \mathbb{P}(A_{n+1}) \\ &= \sum_{i=1}^{n+1} \mathbb{P}(A_i)\end{aligned}$$

5. Vale lo stesso passo $n = 2$ dello scorso punto

$$\begin{aligned}\mathbb{P}(A_1 \cup A_2) &= \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2) \\ &\leq \mathbb{P}(A_1) + \mathbb{P}(A_2)\end{aligned}$$

poi segue per induzione come il punto scorso.

Proposition Formula di inclusione-esclusione

Sia $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno spazio di probabilità con spazio campionato Ω di cardinalità finita. Prendiamo $A_1, \dots, A_n \in \mathcal{P}(\Omega)$ con $n \in \mathbb{N}$. Allora,

$$\mathbb{P}\left(\bigcup_{j=1}^n A_j\right) = \sum_{k=1}^n \sum_{\substack{i_1, \dots, i_k \\ \in \{1, \dots, n\} \\ i_1 \neq i_2 \neq \dots \neq i_k}} (-1)^{k+1} \mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right)$$

Tutte le possibili intersezione di k elementi pesati da $A_1, \dots, A_n$.

Proof

Mostriamolo per induzione Il caso $n = 2$ segue dal caso banale dimostrato in precedenza, cioè

$$\begin{aligned} \mathbb{P}(A_1 \cup A_2) &= \sum_{k=1}^2 \sum_{\substack{i_1, \dots, i_k \\ \in \{1, 2\} \\ i_1 \neq \dots \neq i_k}} (-1)^{k+1} \mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right) \\ &= \sum_{i_1 \in \{1, 2\}} \mathbb{P}(A_{i_1}) - \sum_{\substack{i_1, i_2 \in \{1, 2\} \\ i_1 \neq i_2}} \mathbb{P}(A_1 \cap A_2) \\ &= \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2) \end{aligned}$$

Supponiamo che la formula funzioni per $n - 1$ e dimostriamolo per n . Abbiamo

$$\begin{aligned} \overline{A}_{n-1} &= \bigcup_{j=1}^{n-1} A_j \\ \mathbb{P}\left(\bigcup_{j=1}^n A_j\right) &= \mathbb{P}(\overline{A}_{n-1} \cup A_n) \\ &\stackrel{(n=2)}{=} \mathbb{P}(\overline{A}_{n-1}) + \mathbb{P}(A_n) - \mathbb{P}(\overline{A}_{n-1} \cap A_n) \end{aligned}$$

Studiamo separatamente il primo termine e l'ultimo termine. Nel primo abbiamo

$$\mathbb{P}(\overline{A}_{n-1}) = \mathbb{P}\left(\sum_{k=1}^{n-1} \sum_{\substack{i_1, \dots, i_k \\ \in \{1, \dots, n-1\} \\ i_1 \neq \dots \neq i_k}} (-1)^{k+1} \mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right)\right)$$

Per l'ultimo termine usiamo il passo $n - 1$

$$\begin{aligned}
\mathbb{P}(\overline{A}_{n-1} \cap A_n) &= \mathbb{P}\left(\left[\bigcup_{j=1}^{n-1} A_j\right] \cap A_n\right) \\
&= \mathbb{P}\left(\bigcup_{j=1}^{n-1} (A_j \cap A_n)\right) \\
&= \sum_{k=2}^{n-1} \sum_{\substack{i_1, \dots, i_k \\ \in \{1, \dots, n-1\} \\ i_1 \neq \dots \neq i_k}} \mathbb{P}\left(\bigcap_{r=1}^k (A_{i_r} \cap A_n)\right) \\
&= - \sum_{k=2}^n \sum_{\substack{i_2, \dots, i_k \\ \in \{1, \dots, n\} \\ i_1 \neq \dots \neq i_k \\ \exists j \in \{1, \dots, k\} \\ | i_j = n}} \mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right)
\end{aligned}$$

Combinando tutto

$$\begin{aligned}
\mathbb{P}\left(\bigcup_{j=1}^n A_j\right) &= \mathbb{P}(\overline{A}_{n-1}) + \mathbb{P}(A_n) - \mathbb{P}(\overline{A}_{n-1} \cap A_n) \\
&= \mathbb{P}(A_n) + \sum_{k=2}^n \sum_{\substack{i_2, \dots, i_k \\ \in \{1, \dots, n\} \\ i_1 \neq \dots \neq i_k \\ \exists j \in \{1, \dots, k\} \\ | i_j = n}} \mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right) \\
&\quad + \sum_{k=1}^{n-1} \sum_{\substack{i_1, \dots, i_k \\ \in \{1, \dots, n-1\} \\ i_1 \neq \dots \neq i_k}} (-1)^{k+1} \mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right) \\
&= \sum_{k=1}^n \sum_{\substack{i_1, \dots, i_k \\ \in \{1, \dots, n\} \\ i_1 \neq \dots \neq i_k}} (-1)^{k+1} \mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right)
\end{aligned}$$

Andiamo a rappresentare il nostro spazio M. D. P con un vettore. Sia $N \in \mathbb{N}$ e $\Omega = \{\omega_1, \dots, \omega_N\}$. Notiamo che dato $A \in \mathcal{P}(\Omega)$ possiamo sempre rappresentarlo come

$$A = \{\omega_{i_1}, \dots, \omega_{i_k}\}$$

con $k \in \{1, \dots, N\}$ e $i_1, \dots, i_k \in \{1, \dots, N\}$ con $i_1 \neq \dots \neq i_k$. Da questo segue che

$$A = \bigsqcup_{r=1}^k \{\omega_{i_r}\}$$

Quindi per l'additività di una generica M.D.P $\mathbb{P}: \mathcal{P}(\Omega) \rightarrow [0, 1]$ vale

$$\mathbb{P}(A) = \sum_{r=1}^k \mathbb{P}(\{\omega_{i_r}\})$$

Abbiamo quindi scritto la misura di un insieme $A \in \mathcal{P}(\Omega)$ come la somma delle misure dei singoletti che

lo compongono. Ricordiamo che

$$\mathbb{P}(\Omega) = \sum_{i=1}^N \mathbb{P}(\omega_i) = 1$$

Proposition

Sia $\Omega \neq \emptyset$ con $|\Omega| = N$ finito. I seguenti 3 insiemi sono in corrispondenza biunivoca

1.

$$S_N \triangleq \left\{ (P_1, \dots, P_N) \in [0, 1]^N \mid \sum_{i=1}^N P_i = 1 \right\}$$

$$K_{N-1} \triangleq \left\{ (P_1, \dots, P_{N-1}) \in [0, 1]^{N-1} \mid \sum_{i=1}^{N-1} P_i \leq 1 \right\}$$

2.

$$M(\Omega) \triangleq \{ \mathbb{P} \text{ M. D. P su } (\Omega, \mathcal{P}(\Omega)) \}$$

Proof

Per la corrispondenza fra S_N a K_{N-1} prendo la funzione $f: K_{N-1} \rightarrow S_N$ data da

$$f(P_1, \dots, P_{N-1}) \triangleq \left(P_1, \dots, P_{N-1}, 1 - \sum_{i=1}^{N-1} P_i \right)$$

Dimostrazione per esercizio. Dimostriamo che $M(\Omega)$ e S_N sono in corrispondenza biunivoca. Prendiamo $g: M(\Omega) \rightarrow S_N$ come

$$g(\mathbb{P}) \triangleq (\mathbb{P}(\{\omega_1\}), \dots, \mathbb{P}(\{\omega_N\}))$$

Notiamo che per definizione di misura di probabilità, tutti i termini $\mathbb{P}(\{\omega_i\}) \in [0, 1]$ per tutte le $i \in \{1, \dots, N\}$, e

$$\sum_{i=1}^N \mathbb{P}(\{\omega_i\}) = \mathbb{P}(\Omega) = 1$$

quindi $g(\mathbb{P}) \in S_N$ ed è ben definita. La suriettività è data dal fatto che dato $(P_1, \dots, P_N) \in S_N$ basta prendere $\mathbb{P} \in M(\Omega)$ tale che $\mathbb{P}(\{\omega_i\}) \triangleq P_i$. Per l'injectività prendiamo $\mathbb{P}_1, \mathbb{P}_2 \in M(\Omega)$ tali che $g(\mathbb{P}_1) = g(\mathbb{P}_2)$, cioè $\mathbb{P}_1(\{\omega_i\}) = \mathbb{P}_2(\{\omega_i\})$. Ma sono uguali in quanto dato $A = \{\omega_{i_1}, \dots, \omega_{i_k}\} \in \mathcal{P}(\Omega)$

$$\mathbb{P}_1(A) = \sum_{r=1}^k \mathbb{P}_1(\{\omega_{i_r}\}) = \sum_{r=1}^k \mathbb{P}_2(\{\omega_{i_r}\}) = \mathbb{P}_2(A)$$

Per questa corrispondenza biunivoca sono essenziali il possesso di un sottoinsieme di elementi di $\mathcal{P}(\Omega)$ che genera (tramite unioni ed intersezioni) tutto $\mathcal{P}(\Omega)$, e pure l'additività (o caso generale sigma additività per il caso infinito). È importante notare che una funzione generica $\mathcal{P}(\Omega) \rightarrow [0, 1]$ non è univocamente determinata dal valore che assume sui singoletti.

2 Indipendenza e condizionamento

Definizione Probabilità condizionata

Sia $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno S.D.P con Ω finito. Siano $A, B \in \mathcal{P}(\Omega)$ tale che $\mathbb{P}(B) > 0$. Allora la *probabilità*

condizionata di A dato B è definita come

$$\mathbb{P}(A|B) \triangleq \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

Se $\mathbb{P}(A) > \mathbb{P}(A|B)$ allora diciamo che B condiziona negativamente A , e viceversa positivamente, se coincidono non condiziona.

Possiamo evitare la condizione $\mathbb{P}(B) > 0$ possiamo definire la possibilità condizionata come la soluzione per $x \in [0, 1]$ di

$$\mathbb{P}(A \cap B) = x\mathbb{P}(B)$$

Quindi se $\mathbb{P}(B) = 0$ allora l'equazione ha infinite soluzioni.

Se B condiziona negativamente A allora condiziona positivamente $\Omega \setminus A$.

Proposition

La funzione $\mathbb{P}(-|B)$ definisce una misura di probabilità su $(\Omega, \mathcal{P}(\Omega))$.

Proof

1.

$$\mathbb{P}(\Omega|B) = \frac{\mathbb{P}(\Omega \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B)}{\mathbb{P}(B)} = 1$$

2. $\forall A, C \in \mathcal{P}(\Omega)$ tale che $A \cap C = \emptyset$ vale

$$\mathbb{P}(A \cup C|B) = \mathbb{P}(A|B) + \mathbb{P}(C|B)$$

Lo mostriamo

$$\begin{aligned}\mathbb{P}(A \cup C|B) &= \frac{\mathbb{P}((A \cup C) \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}((A \cap B) \cup (C \cap B))}{\mathbb{P}(B)} \\ &= \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} + \frac{\mathbb{P}(C \cap B)}{\mathbb{P}(B)} \\ &= \mathbb{P}(A|B) + \mathbb{P}(C|B)\end{aligned}$$

Teorema Probabilità totale

Siano $\Omega_1, \dots, \Omega_n \in \mathcal{P}(\Omega)$ e $n \in \mathbb{N}$ partizione disgiunta di Ω . Allora $\forall A \in \mathcal{P}(\Omega)$ vale

$$\mathbb{P}(A) = \sum_{k=1}^n \mathbb{P}(A \cap \Omega_k)$$

Proof Probabilità totale

$$\begin{aligned}
\mathbb{P}(A) &= \mathbb{P}(A \cap \Omega) = \mathbb{P}\left(A \cap \left(\bigcup_{k=1}^n \Omega_k\right)\right) \\
&= \mathbb{P}\left(\bigcup_{k=1}^n (A \cap \Omega_k)\right) \\
&= \sum_{k=1}^n \mathbb{P}(A \cap \Omega_k) \\
&= \sum_{k=1}^n \mathbb{P}(A|\Omega_k)\mathbb{P}(\Omega_k) \\
&= \sum_{k=1}^n \mathbb{P}(A \cap \Omega_k)
\end{aligned}$$

Teorema Formula di Bayes

Siano $A_1, \dots, A_n \in \mathcal{P}(\Omega)$ partizione di Ω e $B \in \mathcal{P}(\Omega)$ tale che $\mathbb{P}(B) > 0$ allora

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{k=1}^n \mathbb{P}(B|A_k)\mathbb{P}(A_k)}, \quad \forall i \in \{1, \dots, n\}$$

Proof Formula di Bayes

Applichiamo due volte la definizione di probabilità condizionata

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{k=1}^n \mathbb{P}(B|A_k)\mathbb{P}(A_k)}$$

2.1 Indipendenza

Definizione Eventi stocasticamente indipendenti

$\forall A, B \in \mathcal{P}(\Omega)$ diciamo che A, B sono stocasticamente indipendenti se

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

Assumiamo che siano ambo non-nulle. Allora

$$\mathbb{P}(A|B) = \mathbb{P}(A) \implies \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

E inoltre

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) \implies \mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A)$$

Quindi A non condiziona B se e solo se B non condiziona A se e solo se $\mathbb{P}(A)\mathbb{P}(B) = \mathbb{P}(A \cap B)$.

Importante: disgiunzione e indipendenza non sono la stessa cosa. La disgiunzione è una caratteristica insiemistica, mentre l'indipendenza può variare fra modelli. Se due eventi sono disgiunti, allora $\mathbb{P}(A \cap B) = 0$. Se A, B sono indipendenti allora $0 = \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$, e quindi o $\mathbb{P}(A) = 0$ oppure $\mathbb{P}(B) = 0$. Viceversa, se $\mathbb{P}(A) = 0$ o $\mathbb{P}(B) = 0$, allora $0 = \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$. Quindi, due eventi disgiunti sono indipendenti se e solo se uno dei due è l'evento impossibile.

Proposition

Se $A \cap B = \emptyset$, allora sono indipendenti se e solo se $\mathbb{P}(A) = 0$ oppure $\mathbb{P}(B) = 0$.

Quindi nei casi significativi, se due eventi sono disgiunti sono quasi sempre non indipendenti.

Definizione Indipendenza di famiglia di eventi

Siano $A_1, \dots, A_n \in \mathcal{P}(\Omega)$ diciamo che $A_1, \dots, A_n$ sono *eventi indipendenti* se $\forall k \leq n$ e $\forall i_1, \dots, i_k \in \{1, \dots, n\}$ vale che

$$\mathbb{P}\left(\bigcap_{r=1}^k A_{i_r}\right) = \prod_{r=1}^k \mathbb{P}(A_{i_r})$$

Esempio Eventi indipendenti a due a due non sono indipendenti

Lanciamo 3 monete equilibrate e distinguibili $\Omega = \{T, C\}^3$. Tutti i casi sono equiprobabili. Consideriamo gli eventi:

- $A_1 \equiv$ il risultato della prima moneta è uguale a quello della seconda.
- $A_2 \equiv$ il risultato della prima moneta è uguale a quello della terza.
- $A_3 \equiv$ il risultato della terza moneta è uguale a quello della seconda.

Mostriamo che sono a due a due indipendenti ma non indipendenti. Abbiamo

$$\Omega = \{(T, T, T)(T, T, C)(T, C, T)(T, C, C)(C, T, T)(C, T, C)(C, C, T)(C, C, C)\}$$

Le probabilità sono

$$\mathbb{P}(A_1) = \mathbb{P}(A_2) = \mathbb{P}(A_3) = \frac{1}{2}$$

$$\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_2 \cap A_3) = \mathbb{P}(A_1 \cap A_3) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2}$$

Tuttavia,

$$\begin{aligned} \mathbb{P}(A_1 \cap A_2 \cap A_3) &= \mathbb{P}(\{(T, T, T), (C, C, C)\}) = \mathbb{P}(A_1 \cap A_2) \\ &= \mathbb{P}(A_1 \cap A_3) = \mathbb{P}(A_2 \cap A_3) = \frac{1}{4} \neq \frac{1}{8} = \mathbb{P}(A_1)\mathbb{P}(A_2)\mathbb{P}(A_3) \end{aligned}$$

Esempio Eventi indipendenti non sono indipendenti a due a due

Lanciamo un dado equilibrato a 8 facce numerate da 1 a 8, quindi $\Omega = \{1, \dots, 8\}$ e possiamo prendere la probabilità classica visto che il dato è equilibrato. Consideriamo gli eventi:

- $A = \{1, 2, 3, 4\};$
- $B = \{1, 5, 6, 7\};$
- $C = \{1, 2, 3, 8\}.$

Chiaramente $\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}$. Inoltre

$$\mathbb{P}(A \cap B \cap C) = \frac{1}{8} = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C)$$

e

$$\mathbb{P}(A \cap B) = \frac{1}{8} \neq \mathbb{P}(A)\mathbb{P}(B) = \frac{1}{4}$$

Quindi sono a 3 a 3 indipendenti ma non a 2 a 2 indipendenti.

Cerchiamo quindi una condizione necessaria e sufficiente che ci garantisca che gli eventi siano indipendenti

nel senso della nostra definizione. Partiamo dal caso di 3 eventi

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C)$$

e cerchiamo una condizione aggiuntiva per garantire che siano a due a due indipendenti

$$\begin{aligned}\mathbb{P}(A \cap B) &= \mathbb{P}(A \cap B \cap \Omega) \\ &= \mathbb{P}((A \cap B \cap C) \cup (A \cap B) \cap (\Omega \setminus C)) = \mathbb{P}(A \cap B \cap C) + \mathbb{P}(A \cap B \cap (\Omega \setminus C)) \\ &= \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) + \mathbb{P}(A \cap B \cap (\Omega \setminus C))\end{aligned}$$

Ci serve che anche $A, B, \Omega \setminus C$ verifichino

$$\mathbb{P}(A \cap B \cap (\Omega \setminus C)) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(\Omega \setminus C)$$

E continuando da prima

$$\begin{aligned}\mathbb{P}(A \cap B) &= \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) + \mathbb{P}(A \cap B \cap (\Omega \setminus C)) \\ &= \mathbb{P}(A)\mathbb{P}(B) (\mathbb{P}(C) + \mathbb{P}(\Omega \setminus C)) = \mathbb{P}(A)\mathbb{P}(B)\end{aligned}$$

Quindi A e B sono indipendenti. Sopra abbiamo dimostrato l'uguaglianza

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) + \mathbb{P}(A \cap B \cap (\Omega \setminus C))$$

se da qua assumiamo A, B indipendenti otteniamo

$$\mathbb{P}(A)\mathbb{P}(B) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) + \mathbb{P}(A \cap B \cap (\Omega \setminus C))$$

cioè

$$\begin{aligned}\mathbb{P}(A \cap B \cap (\Omega \setminus C)) &= \mathbb{P}(A)\mathbb{P}(B) - \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) \\ &= \mathbb{P}(A)\mathbb{P}(B)(1 - \mathbb{P}(C)) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(\Omega \setminus C)\end{aligned}$$

Abbiamo quindi trovato che

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B) \iff \mathbb{P}(A \cap B \cap (\Omega \setminus C)) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(\Omega \setminus C)$$

assunto che siano indipendenti.

Proposition

Siano $A_1, \dots, A_n \in \mathcal{P}(\Omega)$ allora sono equivalenti:

1. $A_1, \dots, A_n$ sono indipendenti;
- 2.

$$\mathbb{P}\left(\bigcap_{k=1}^n B_k\right) = \prod_{k=1}^n \mathbb{P}(B_k)$$

dove $B_k = A_k$ o $B_k = \Omega \setminus A_k$ per ogni combinazione possibile di A_k e i suoi complementi.

Proof

($\Leftarrow$) Procediamo per induzione su n . Il caso base $n = 2$ segue assumendo vera l'ipotesi 2: prendendo $B_1 = A_1$ e $B_2 = A_2$ otteniamo $\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2)$, che è la definizione di indipendenza per due eventi. Assumiamo per ipotesi induttiva che l'implicazione (2) $\Rightarrow$ (1) sia vera per $n - 1$ eventi e dimostriamola per n . Affinché gli $A_1, \dots, A_n$ siano indipendenti (1), la regola del prodotto deve valere per l'intersezione di tutti gli n eventi e per qualsiasi loro sottofamiglia. La validità per tutti gli n eventi è garantita direttamente dall'ipotesi (2) scegliendo $B_k = A_k$ per ogni k :

$$\mathbb{P}\left(\bigcap_{k=1}^n A_k\right) = \prod_{k=1}^n \mathbb{P}(A_k)$$

Ora dimostriamo che la proprietà vale per le sottofamiglie. Consideriamo senza perdita di generalità i primi $n - 1$ eventi. Sfruttiamo la legge delle probabilità totali per marginalizzare l'evento n -esimo:

$$\begin{aligned}\mathbb{P}\left(\bigcap_{k=1}^{n-1} B_k\right) &= \mathbb{P}\left(\left(\bigcap_{k=1}^{n-1} B_k\right) \cap A_n\right) + \mathbb{P}\left(\left(\bigcap_{k=1}^{n-1} B_k\right) \cap (\Omega \setminus A_n)\right) \\ &= \left(\prod_{k=1}^{n-1} \mathbb{P}(B_k)\right) \mathbb{P}(A_n) + \left(\prod_{k=1}^{n-1} \mathbb{P}(B_k)\right) \mathbb{P}(\Omega \setminus A_n) \\ &= \left(\prod_{k=1}^{n-1} \mathbb{P}(B_k)\right) [\mathbb{P}(A_n) + \mathbb{P}(\Omega \setminus A_n)] \\ &= \prod_{k=1}^{n-1} \mathbb{P}(B_k) \cdot 1 = \prod_{k=1}^{n-1} \mathbb{P}(B_k)\end{aligned}$$

Abbiamo così dimostrato che la (2) vale anche per i primi $n - 1$ eventi. Per l'ipotesi induttiva, ciò implica che tale sottofamiglia di eventi è indipendente. Lo stesso ragionamento si applica a qualsiasi altra sottofamiglia. Unendo questo risultato alla validità per gli n eventi congiunti, concludiamo che $A_1, \dots, A_n$ sono reciprocamente indipendenti.

($\Rightarrow$) Lunedì TODO

TODO 9 marzo.

- 1.
- 2.
3. Facciamo ora le non ordinate senza reimmissione. La nostra urna è $U = \{u_1, \dots, u_n\}$ e facciamo $k \in \mathbb{N}$ estrazioni con $k \leq n$. Rispetto al caso precedente, i vari casi diminuiscono e possiamo rappresentare quest'ultimi come classi di equivalenza rispetto alla relazione di essere uguali a meno di una permutazione. Quindi consideriamo il quoziente delle disposizioni semplici D_n^k rispetto alla seguente relazione di equivalenza: dati $v, w \in D_n^k$ con $v = (v_1, \dots, v_k)$ e $w = (w_1, \dots, w_k)$ abbiamo

$v \sim w$ se e solo se $\exists \sigma \in \text{Sym}(k)$ tale che

$$w = (v_{\sigma(1)}, v_{\sigma(2)}, \dots, v_{\sigma(k)})$$

Indichiamo come C_k^n l'insieme delle combinazioni di k elementi estratti da n elementi

$$C_k^n = D_k^n / \sim$$

E siccome l'ordine del gruppo simmetrico è $k!$, l'ordine è dato da

$$C_n^k = \frac{n!}{(n-k)!k!} = \binom{n}{k}$$

4. Ora studiamo le non ordinate con reimmissione. Quindi, rispetto a prima dobbiamo aggiungere anche i casi dove gli elementi si ripetono, Tuttavia, visto che abbiamo vettori co componente che possono essere uguali, la relazione di equivalenza con le permutazioni non è significativa come prima, perché scambiare due elementi uguali non cambia il vettore di $\hat{D}_k^n$. Quindi dobbiamo trovare una relazione di equivalenza alternativa. Dobbiamo creare una relazione di equivalenza che conti il numero di ogni elemento compaia in und eterminato vettore. Prendiamo $v = (v_1, \dots, v_k) \in \hat{D}_k^n$ e definiamo

$$\#_i \triangleq |\{j \in \{1, \dots, k\} \mid v_j = u_i\}|, \quad u_i \in U \wedge i \in \{1, \dots, n\}$$

cioè quante volte l'elemento u_i appare nel vettore v . Prendiamo ora il vettore $\bar{v} \in \{0, 1\}^{k+m-1}$ con

$$\bar{v} = \left(\underbrace{1, 1, 1, \dots, 1}_{\#_1 \text{ times}}, \underbrace{0, 1, 1, 1, \dots, 1}_{\#_2 \text{ times}}, \dots, 0, \underbrace{1, 1, 1, \dots, 1}_{\#_n \text{ times}} \right)$$

Dati v_1 e v_2 appartenenti a $\hat{D}_k^n$ definiamo la relazione di equivalenza $v_1 \sim v_2$ se e solo se $\bar{v}_1 = \bar{v}_2$. Abbiamo quindi l'insieme delle combinazioni con ripetizione dato da

$$\hat{C}_k^n \triangleq \hat{D}_k^n / \sim$$

che è in equivalenza con

$$V \triangleq \left\{ \bar{v} \in \{0, 1\}^{n+k-1} \mid \sum_{j=1}^{n+k-1} \bar{v}_j = k \right\}$$

Abbiamo che $|V| = |\hat{C}_k^n|$, cioè dobbiamo contare il numero di configurazioni con k 1s in $n+k-1$ slot (o contiamo gli zeri), cioè

$$|\hat{C}_k^n| = |\hat{D}_k^n / \sim| = \binom{n+k-1}{k} = \binom{n+k-1}{n-1} = \frac{(n+k-1)!}{k!(n-1)!}$$

Esercizio

Prendiamo r cassetti distinti, dove in ognuno di essi devo mettere esattamente k_i elementi di U urna di palline che vengono estratte, con il vincolo che le devo mettere tutte, cioè $\sum k_i = r$. Non conta l'ordine delle palline nei cassetti. Quante configurazioni abbiamo? Nel caso $r = 1$ abbiamo solo la possibilità $k_1 = n$ e quindi una sola combinazione. Nel caso $r = 2$ abbiamo $k_2 = n - k_1$, quindi abbiamo $n!$ configurazioni delle nostre palline, ma nel primo cassetto $k_1!$ combinazioni ridondanti, mentre nel secondo $(n - k_1)!$. Nel caso generale abbiamo r cassetti e quindi

$$\frac{n!}{\prod_{i=1}^r k_i!}$$

configurazioni, che è il coefficiente multinomiale cioè

$$\frac{n!}{\prod_{i=1}^r k_i!} = \binom{n}{k_1} \binom{n-k_1}{k_2} \binom{n-k_1-k_2}{k_3} \dots$$

2.2 Applicazioni a sistemi di particelle

Prendiamo un sistema di n particelle che può assumere $r \in \mathbb{N}$ stati diversi. Supponiamo che l'energia totale sia sempre costante. Quindi, se siamo all'equilibrio termico, tutte le configurazioni (di possibili stati per le particelle) hanno la stessa probabilità di realizzarsi.

1. *Le particelle sono distinguibili:* sia $\Omega_{n,r}$ l'insieme di tutte le possibili configurazioni

$$\Omega_{n,r} \triangleq \{1, \dots, r\}^n$$

Sia $w \in \Omega$ con $w = (w_1, \dots, w_n)$. Dalla nostra assunzione usiamo la probabilità classica

$$\mathbb{P}(\{w\}) = \frac{1}{|\Omega_{n,r}|} = \frac{1}{r^n}$$

Fissati $k_1, \dots, k_r \in \mathbb{N}$ tali che $\sum k_i = n$, calcolare la probabilità dell'evento $O_{k_1, \dots, k_r}$, cioè “avere esattamente k_i particelle nello stato i ”. Usiamo dunque la distribuzione multinomiale

$$|O_{k_1, \dots, k_r}| = \binom{n}{k_1, \dots, k_r}$$

di conseguenza,

$$\mathbb{P}(O_{k_1, \dots, k_r}) = \frac{|O_{k_1, \dots, k_r}|}{|\Omega|} = \frac{n!}{r^n k_1! \dots k_r!}$$

Notiamo che (per esercizio usando l'espansione del multinomio)

$$\sum_{\substack{k_1, \dots, k_r \in \mathbb{N} \\ k_1 + k_2 + \dots + k_r = n}} \frac{1}{r^n} \frac{n!}{k_1! k_2! \dots k_r!} = 1$$

cioè

$$\sum_{\substack{k_1, \dots, k_r \in \mathbb{N} \\ k_1 + k_2 + \dots + k_r = n}} \mathbb{P}(O_{k_1, \dots, k_r}) = 1$$

Tuttavia in fisica non siamo generalmente interessati in quali particelle sono in un certo stato, bensì quante sono in un certo stato. Di conseguenza, possiamo definire uno spazio campionario che si basa su questo

$$\hat{\Omega}_{n,r} \triangleq \left\{ (k_1, \dots, k_r) \in \mathbb{N}^r \mid \sum k_i = n \right\}$$

Per quanto detto precedentemente, se le particelle sono distinguibili, una misura di probabilità da mettere su questo spazio è $\mathbb{P}_{\text{BE}}: \mathcal{P}(\hat{\Omega}_{n,r}) \rightarrow [0, 1]$ tale che

$$\mathbb{P}_{\text{BE}}(\{\bar{k}\}) = \frac{1}{r^n} \cdot \frac{n!}{k_1! k_2! \dots k_r!}$$

con $\bar{k} = (k_1, \dots, k_r) \in \hat{\Omega}_{n,r}$. Quest'ultima viene chiamata statistica di Maxwell-Boltzmann. Se le particelle non sono distinguibili, usiamo invece un'altra statistica. Non possiamo più usare Ω , ma dobbiamo usare $\hat{\Omega}$ dove le particelle sono indistinguibili. La cardinalità di quest'ultimo è

$$|\hat{\Omega}_{n,r}| = \binom{n+r-1}{n}$$

e nel mondo microscopico questa statistica è sperimentalmente quella corretta e non l'altra. Questo significa che non possiamo fare nessun esperimento che ci permetta di distinguere una configurazione di particelle dall'altra. Quindi, non ha senso lavorare sullo spazio Ω . Di conseguenza, visto che possiamo solo distinguere le configurazioni di $\hat{\Omega}$, dobbiamo tradurre la nostra assunzione su di cui di conseguenza la misura di probabilità da mettere è $\mathbb{P}_{\text{BE}}$ (Bose-Einstein) tale che

$$\mathbb{P}_{\text{BE}}(\{\bar{k}\}) = \frac{1}{|\hat{\Omega}_{n,r}|}$$

Altre varianti includono la statistica di Dirac-Fermi per i fermioni.

2.3 Urne varie

Abbiamo k monete e n scatole distinte e vogliamo contare in quanti modi possiamo mettere le monete nelle scatole. Dobbiamo decidere:

1. se le monete sono distinguibili o meno;
2. se posso mettere più monete in una scatola, quindi serve $k \leq n$, o meno.

Il parallelo con le urne è:

- reimmissione $\iff$ mettere più di una moneta per scatola;
- non reimmissione $\iff$ una moneta per scatola;
- ordine $\iff$ monete distinguibili;
- non ordine $\iff$ monete non distinguibili.

Esercizio

Consideriamo un'urna contenente $N \in \mathbb{N}$ palline di cui $R \leq N$ rosse e le altre blu. Estraiamo n palline e vogliamo calcolare la probabilità di avere $k \leq n$ rosse, in questi due casi:

1. estrazione con reimmissione;
2. estrazione senza reimmissione.

Soluzione

Per come presentato l'esperimento, le palline non sono distinguibili, tranne per il colore binario. Possiamo immaginarci che le palline siano numerate da 1 a N . Adesso conta l'ordine.

1. Nel caso con reimmissione, consideriamo le disposizioni con ripetizioni

$$\Omega = \hat{D}_n^N$$

che ha quindi cardinalità N^n . Visto che l'estrazione è casuale, possiamo prendere la misura uniforme $\mathbb{P}: \mathcal{P}(\Omega) \rightarrow [0, 1]$ tale che $\mathbb{P}(C) = |C|/|\Omega|$. Vogliamo calcolare la probabilità di A_k che è equivalente a dire "vogliamo estrarre esattamente k palline rosse". La cardinalità dell'evento è dato da

$$|A_k| = \binom{n}{k} R^k (N - R)^{n-k}$$

cioè stiamo moltiplicando ogni possibile combinazione di posizione per le disposizioni con ripetizioni di k palline rosse con le disposizioni con ripetizioni di $N - K$ palline blu. Quindi abbiamo

$$\mathbb{P}(A_k) = \frac{|A_k|}{|\Omega|} = \binom{n}{k} \left(\frac{R}{N}\right)^k \left(1 - \frac{R}{N}\right)^{n-k}$$

2. Nel caso senza reimmissione, consideriamo le disposizioni semplici

$$\Omega = D_n^N$$

che ha quindi cardinalità $N!/(N-n)!$. Manteniamo la probabilità uniforme. Calcoliamo la probabilità dell'evento A_k cioè “estraggo k palline rosse”. Possiamo usare lo stesso ragionamento di prima,

$$|A_k| = \frac{R!}{(R-k)!} \frac{(N-R)!}{(N-R-(n-k))!}$$

cioè stiamo moltiplicando le disposizioni senza ripetizioni di k palline da R palline rosse con le disposizioni senza ripetizioni di $m-n$ palline da $N-R$ palline blu. Da questo deduciamo che

$$\begin{aligned} \mathbb{P}(A_k) &= \frac{\cancel{\binom{n}{k}} \frac{R!}{(R-k)!} \frac{(N-R)!}{(N-R-(n-k))!}}{\frac{N!}{(N-n)!}} = \frac{\binom{n}{k} \binom{R}{k} \binom{N-R}{n-k} \cancel{k!(n-k)!}}{\binom{N}{n} \cancel{n!}} \\ &= \frac{\binom{R}{k} \binom{N-R}{n-k}}{\binom{N}{n}} \end{aligned}$$

Il primo termine sono le combinazioni non ordinate di k elementi da R slot, il secondo di $n-k$ elementi estratti da $N-R$ slot rimanenti, e il termine a denominatore è la cardinalità di C_n^N cioè le combinazioni non ordinate di n elementi estratti da N . Quindi, avremmo potuto scegliere $\Omega = C_n^N$, con cardinalità $\binom{N}{n}$. In questo caso avremmo

$$|A_k| = \binom{R}{k} \binom{N-R}{n-k}$$

Abbiamo moltiplicando per $k!/k!$ il primo termine, per $(n-k)!/(n-k)!$ il secondo e per $n!/n!$ il terzo per ottenere i coefficienti binomiali.

Notiamo che

Definizione Legge binomiale

Sullo spazio $\Omega = \{0, \dots, n\}$ possiamo definire la probabilità

$$\mathbb{P}(\{k\}) = \binom{n}{k} p^k (1-p)^{n-k}$$

Che è la probabilità di avere k successi di probabilità p in n tentativi.

Definizione Legge ipergeometrica

todo

La differenza con la binomiale sta nel fatto che nel caso con ripetizione abbiamo l'indipendenza di una estrazione con l'altra.

Notiamo che se il numero delle palline tendesse ad infinito, l'idea di reimmissione perde di senso perché abbiamo infinite palline. Quindi la seconda probabilità deve tendere alla prima, cioè l'ipergeometrica deve tendere a quella binomiale.

Esercizio

Dimostrare che la seconda probabilità tende alla prima se il numero delle palline tende ad infinito.

Soluzione

Abbiamo

$$\begin{aligned} \mathbb{P}(A_k) &= \frac{\frac{R!}{k!(R-k)!} \cdot \frac{(N-R)!}{(n-k)!(N-R-(n-k))!}}{\frac{N!}{n!(N-n)!}} \\ &= \binom{n}{k} \frac{\left(\prod_{i=0}^{k-1} (R-i)\right) \left(\prod_{j=0}^{n-k-1} (N-R-j)\right)}{\prod_{h=0}^{n-1} (N-h)} \\ &= \binom{n}{k} \left[\prod_{i=0}^{k-1} \left(\frac{R-i}{N-i} \right) \right] \left[\prod_{j=0}^{n-k-1} \left(\frac{N-R-j}{N-k-j} \right) \right] \\ &= \binom{n}{k} \left[\prod_{i=0}^{k-1} \frac{R}{N} \left(\frac{1 - \frac{i}{R}}{1 - \frac{i}{N}} \right) \right] \left[\prod_{j=0}^{n-k-1} \frac{N-R}{N} \left(\frac{1 - \frac{j}{N-R}}{1 - \frac{k+j}{N}} \right) \right] \\ &= \binom{n}{k} \left(\frac{R}{N} \right)^k \left(1 - \frac{R}{N} \right)^{n-k} \left[\prod_{i=0}^{k-1} \left(\frac{1 - \frac{i}{R}}{1 - \frac{i}{N}} \right) \prod_{j=0}^{n-k-1} \left(\frac{1 - \frac{j}{N-R}}{1 - \frac{k+j}{N}} \right) \right] \end{aligned}$$

Distinguiamo ora alcuni casi:

1. se

$$\lim_{N \rightarrow \infty} \frac{R}{N} = 1$$

allora $\mathbb{P}(A_k) = 0$ per tutte le $k \neq n$, mentre $\mathbb{P}(A_n) = 1$;

2. se

$$\lim_{N \rightarrow \infty} \frac{R}{N} = 0$$

allora $\mathbb{P}(A_k) = 1$ per tutti i $k \neq 0$, mentre $\mathbb{P}(A_0) = 1$.

3. se

$$\lim_{N \rightarrow \infty} \frac{R}{N} = p \in (0, 1)$$

allora $R \rightarrow \infty$ e $N - R \rightarrow \infty$, quindi

$$\mathbb{P}(A_k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad \forall k \in \{0, \dots, n\}$$

Esercizio

Calcolare la probabilità dell'evento R_i “la i -esima pallina estratta è rossa” in entrambi i casi.

Soluzione

1. *Con reimmissione*: abbiamo semplicemente

$$\mathbb{P}(R_i) = \frac{R}{N}, \quad \forall i \in \{1, \dots, n\}$$

2. *Senza reimmissione*: chiaramente,

$$\mathbb{P}(R_1) = \frac{R}{N}$$

Ricordiamo che $\Omega = D_n^N$. Per ogni $i \in \{1, \dots, n\}$, consideriamo la funzione $\varphi_i: \Omega \rightarrow \Omega$ tale che

$$\varphi_i(\omega) = (\omega_1, \omega_2, \dots, \omega_{i-1}, \omega_1, \omega_{i+1}, \dots, \omega_n)$$

con $\omega = (\omega_1, \dots, \omega_n) \in \Omega$. Ovviamente φ_i è biiettiva $\forall i \in \{1, \dots, n\}$. Inoltre,

$$R_1 \triangleq \{(\omega_1, \dots, \omega_n) \in \Omega \mid \omega_1 \in \{1, \dots, R\}\}$$

$$R_i \triangleq \{(\omega_1, \dots, \omega_n) \in \Omega \mid \omega_i \in \{1, \dots, R\}\}, \quad i \in \{1, \dots, n\}$$

Per R_1 stiamo usando il fatto che le prime R palline numerate sono rosse. Quindi, $\varphi_i(R_1) = R_i$. Visto che φ_i è biiettiva,

$$|R_1| = |\varphi_i(R_1)| = |R_i|$$

E possiamo concludere che

$$\mathbb{P}(R_i) = \frac{|R_i|}{|\Omega|} = \frac{|R_1|}{|\Omega|} = \frac{R}{N}$$

Consideriamo l'esperimento di N lanci di una moneta con probabilità $p \in [0, 1]$ che esca testa e $1 - p$ che esca croce. Vogliamo probabilizzare l'esperimento, abbiamo quindi

$$\Omega = \{0, 1\}^N$$

Un evento è

$$\omega = (\omega_1, \omega_2, \dots, \omega_N) \in \Omega$$

Solo nel caso $p = \frac{1}{2}$ possiamo usare la probabilità uniforme. Se per esempio fosse $p = 1$ avremmo

$$\mathbb{P}(\{1, \dots, 1\}) = 1, \quad \mathbb{P}(\{0, \dots, 0\}) = 0$$

quindi non sono equiprobabili. A questo punto per identificare la misura dobbiamo dedurre delle assunzioni su di essa derivanti dal nostro esperimento. Ci servono assicurazioni che permettano di determinare unicamente la misura. L'assunzione è la seguente: il risultato dell' i -esimo lancio di moneta è indipendente (o non condizionato) dai risultati degli lanci $\forall i$. Consideriamo gli eventi T_i equivalente a “all' i -esimo lancio esce testa” e C_i “all' i -esimo lancio esce croce”, cioè

$$T_i = \{\omega = (\omega_1, \dots, \omega_N) \in \Omega \mid \omega_i = 1\}, \quad C_i = \{\omega = (\omega_1, \dots, \omega_N) \in \Omega \mid \omega_i = 0\}$$

cioè uno è complementare dell'altro. Abbiamo visto che questi eventi $T_1, \dots, T_N$ o $C_1, \dots, C_N$ sono indipendenti se e solo se

$$\mathbb{P}(L_1 \cap \dots \cap L_n) = \prod \mathbb{P}(L_i)$$

con $L_i = T_i$ oppure $L_i = C_i = \Omega \setminus T_i$. Quindi una misura adeguata che modella l'esperimento deve verificare le seguenti condizioni

1. Per ogni i

$$\mathbb{P}(T_i) = p = 1 - \mathbb{P}(C_i)$$

- 2.

$$\mathbb{P}\left(\bigcap_{i=1}^N L_i\right) = \prod_{i=1}^N \mathbb{P}(L_i)$$

con $L_i = T_i$ oppure $L_i = C_i = \Omega \setminus T_i$.

3. $\mathbb{P}$ sia una misura di probabilità.

Siccome riusciamo a calcolare la probabilità dei singoletti, possiamo calcolare la probabilità di tutti gli eventi, quindi è univoca. Possiamo infatti rappresentare

$$\{w\} = \bigcap_{i=1}^N L_i$$

con $L_i = T_i$ se $w_i = 1$ e $L_i = C_i$ se $w_i = 0$. Di conseguenza,

$$\begin{aligned} \mathbb{P}(\{w\}) &= \mathbb{P}\left(\bigcap_{i=1}^N L_i\right) = \prod_{i=1}^N \mathbb{P}(L_i) \\ &= \prod_{i=1}^N p^{\omega_i} (1-p)^{1-\omega_i} = p^{\sum_{i=1}^M \omega_i} (1-p)^{N-\sum_{i=1}^M \omega_i} \end{aligned}$$

Esercizio

Vediamo alcuni eventi significativi

1. S_k equivalente a dire “ottengo esattamente k teste”.
2. B_n equivalente a dire “ottengo la prima testa all' n esimo lancio”.
3. D_n equivalente a dire “ottengo almeno una testa nei primi n lanci”.

Soluzione

1. Abbiamo

$$\begin{aligned} \mathbb{P}(\{w\}) &= \sum_{\omega \in S_k} \mathbb{P}(\{w\}) = \sum_{\omega \in S_k} p^{\sum_{i=1}^M \omega_i} (1-p)^{N-\sum_{i=1}^M \omega_i} \\ &= \sum_{\omega \in S_k} p^k (1-p)^{N-k} = |S_k| p^k (1-p)^{N-k} \\ &= \binom{N}{k} p^k (1-p)^{N-k} \end{aligned}$$

che è la binomiale. Notiamo che $S_i \cap S_j = \emptyset$ per $i \neq j$, quindi $\bigcup_{k=0}^N S_k = \Omega$ Quindi

$$\mathbb{P}\left(\bigcup_{k=0}^N S_k\right) = \sum_{k=0}^N \binom{N}{k} p^k (1-p)^{N-k} = 1$$

2. Notiamo che

$$B_n = \bigcup_{k=0}^N (B_n \cap S_k) = \bigcup_{k=1}^{N-n+1} (B_n \cap S_k)$$

e $B_n \cap S_0$ in quanto dobbiamo avere almeno una testa, mentre $B_n \cap S_k = \emptyset$ con $k > N-n+1$

in quanto le prime $n - 1$ devono essere croci. Visto che $S_i \cap S_j = \emptyset$ per $i \neq j$, otteniamo

$$\mathbb{P}(B_n) = \sum_{k=1}^{N-n+1} \mathbb{P}(B_n \cap S_k) = \sum_{k=1}^{N-n+1} \mathbb{P}(B_n|S_k)\mathbb{P}(S_k)$$

È facile calcolare la probabilità per ambo i termini:

- (a) Calcoliamo $\mathbb{P}(B_n|S_k)$, cioè la probabilità di avere la prima testa all' n -esimo lancio, sapendo che abbiamo ottenuto k teste totali. Sappiamo quindi che i primi $n - 1$ sono 0 e quello alla posizione n è 1, quindi per gli altri termini abbiamo $\binom{N-m}{k-1}$ combinazioni, e quindi

$$(P_n|S_k) = \frac{\binom{N-n}{k-1}}{\binom{N}{k}}$$

ossia il numero di modi in cui posso mettere $k - 1$ uni in $N - n$ posti restanti, diviso per i omni possibili di mettere k uni in N posti. Mettendo tutto assieme otteniamo

$$\begin{aligned} \mathbb{P}(B_n) &= \sum_{k=1}^{N-n+1} \mathbb{P}(B_n|S_k)\mathbb{P}(S_k) \\ &= \sum_{k=1}^{N-n+1} \frac{\binom{N-n}{k-1} p^k (1-p)^{N-k} \binom{N-m}{k-1}}{\binom{N}{k}} \\ &= \sum_{k=1}^{N-n+1} \binom{N-n}{k-1} p^k (1-p)^{N-k} \\ &= \sum_{h=0}^{N-n} \binom{N-n}{h} p^h (1-p)^{N-h-1} \\ &= p(1-p)^{n-1} \sum_{h=0}^{N-n} \binom{N-n}{h} p^h (1-p)^{N-n-h} \\ &= p(1-p)^{n-1} [p + 1 - p]^{N-n} = p(1-p)^{n-1} \end{aligned}$$

- (b) Calcoliamolo anche nell'altra versione: per ogni k in $\{1, \dots, N - n + 1\}$ vale i.

$$B_n \cap S_k = \{\omega \in \Omega \mid (0, \dots, 0, 1, \omega_{n+1}, \dots, \omega_N) \mid \sum_{k=n+1}^N \omega_k = 1\}$$

ii.

$$\mathbb{P}(\{\omega\}) = p^k (1-p)^{N-k}$$

Abbiamo quindi che la cardinalità è

$$|B_n \cap S_k| = \binom{N-m}{k-1}$$

e allora

$$\mathbb{P}(B_n) = \sum_{k=1}^{N-n+1} \mathbb{P}(B_n \cap S_k) = \sum_{k=1}^{N-n+1} \binom{N-m}{k-1} p^k (1-p)^{N-k}$$

e il resto segue come prima.

Il risultato è consistente con la nostra intuizione e non dipende da N , in quanto i lanci dopo l' n -esimo sono irrilevanti.

3. Possiamo scrivere la probabilità come la complementare di “ottengo tutte croci nei primi n lanci”. Abbiamo quindi

$$\mathbb{P}(D_n) = 1 - \mathbb{P}(D_n^c) = 1 - (1-p)^n$$

Basandoci su questo esercizio, supponiamo di fare tendere il numero di tentativi N all'infinito. Notiamo che

$$\sum_{n=1}^{\infty} \mathbb{P}(B_n) = \sum_{n=1}^{\infty} p(1-p)^{n-1} = p \sum_{n=1}^{\infty} (1-p)^{n-1} = \sum_{k=0}^{\infty} (1-p)^k$$

Allora intuitivamente questo sempre coerente in quanto

$$\bigcup_{n=1}^{\infty} B_n$$

è equivalente all'evento "ottengo almeno una testa in un numero infinito di tentativi". Se $p > 0$, allora questo è un evento certo. Per rendere rigoroso questo argomento ci serve uno spazio di probabilità tale che

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(B_n)$$

In teoria per modellizzare infiniti lanci di moneta abbiamo bisogno di $\Omega = \{0, 1\}^{\mathbb{N}}$. Ma Ω non è numerabile. Inoltre ci serve una proprietà di additività più forte per ottenere quello che vogliamo. Possiamo anche vedere il problema anche dal punto di vista $\mathbb{P}(D_n) = 1 - (1-p)^n$. Come prima se facciamo andare il numero di tentativi a $+\infty$, ci aspettiamo di ottenere l'evento certo. Notiamo che per tutte le n

$$D_n \leq D_{n+1}$$

e inoltre

$$D_{\infty} = \bigcup_{n=1}^{\infty} D_n$$

che dovrebbe essere un evento certo. Possiamo fare il seguente conto

$$\mathbb{P}(D_{\infty}) = \mathbb{P}\left(\lim_n \bigcup_{k=1}^n D_k\right) = \lim_n \mathbb{P}(D_n) = \lim_n 1 - (1-p)^n = 1$$

Senza ipotesi aggiuntive sulla misura di probabilità non sappiamo se possiamo fare quel passaggio di estrazione dal limite, in quanto serve una continuità dal basso poiché $\{D_n\}_{n \in \mathbb{N}}$ è una successione crescente. Di conseguenza la necessità di modellizzare alcuni esperimenti ci spinge a generalizzare la nozione di spazio di probabilità rispetto a due aspetti:

1. L'insieme Ω può essere infinito, in particolare
 - (a) al più numerabile,
 - (b) arbitrario (qua nascono problemi di misurabilità).
2. Dobbiamo trovare una proprietà da assumere per la misura che garantisca che si comporti bene rispetto a famiglie numerabili di insiemi.

Definizione Spazio di probabilità su insieme al più numerabile

Sia $\Omega \neq \emptyset$ al più numerabile. Chiamiamo misura di probabilità su $(\Omega, \mathcal{P}(\Omega))$ una funzione $\mathbb{P}: \mathcal{P}(\Omega) \rightarrow [0, 1]$ tale che

1. $\mathbb{P}(\Omega) = 1$;
2. σ -additività: $\forall \{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ tali che $A_i \cap A_j = \emptyset$ per $i \neq j$, vale

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

Chiamiamo $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ spazio di probabilità.

Notiamo che la σ -additività implica l'additività. In generale il converso non vale. Studiamo se questa definizione si comporta bene con i limiti.

Definizione Convergenza per insiemi

Sia $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ e $A \in \mathcal{P}(\Omega)$. Indichiamo con

1. $A_n \uparrow A$ se $A_n \subseteq A_{n+1}$ e

$$A = \bigcup_{n=1}^{\infty} A_n$$

2. $A_n \downarrow A$ se $A_n \supseteq A_{n+1}$ e

$$A = \bigcap_{n=1}^{\infty} A_n$$

Teorema

Sia $\mathbb{P}: \mathcal{P}(\Omega) \rightarrow [0, 1]$ funzione tale che

1. $\mathbb{P}(\Omega) = 1$
2. $\forall A, B \in \mathcal{P}(\Omega)$ tale che $A \cap B = \emptyset$ vale $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$.

Allora le seguenti condizioni sono equivalenti:

A σ -additività: $\mathbb{P}$ è una misura di probabilità su $(\Omega, \mathcal{P}(\Omega))$;

B *continuità dal basso*: $\forall \{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ tale che $A_n \uparrow A$ vale

$$\mathbb{P}(A) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \mathbb{P}\left(\lim_n \bigcup_{k=1}^n A_k\right) = \lim_n \mathbb{P}(A_n)$$

C $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ tale che $A_n \uparrow \Omega$ vale

$$\lim_n \mathbb{P}(A_n) = 1$$

D *continuità dall'alto*: $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ tale che $A_n \downarrow \emptyset$ vale


$$\lim_n \mathbb{P}(A_n) = \mathbb{P}(\emptyset) = 0$$

E $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ tale che $A_n \downarrow \emptyset$ vale

$$\lim_n \mathbb{P}(A_n) = 0$$

Proof

Dimostriamo il seguente schema:



Se Ω è finito non c'è nulla da dimostrare. Supponiamo invece che sia infinito numerabile.

1. $(b) \implies (c)$: basta prendere $A = \Omega$ in (b);
2. $(d) \implies (e)$: basta prendere $A = \emptyset$ in (d);
3. $(c) \implies (b)$: prendiamo $A_n \uparrow A$. Usiamo il fatto che $\Omega = A \cup A^c$. Prendiamo $B_n = A_n \cup A$ e notiamo che

$$(a) \quad B_n = A_n \cap A^c \subseteq A_{n+1} \cup A^c = B_{n+1}.$$

(b)

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n \cup A^c \subseteq A_{n+1} \cup A^c = B_{n+1}$$

Quindi $B_n \uparrow \Omega$. Possiamo applicare (c) su $\{B_n\}$ quindi

$$1 = \mathbb{P}(\Omega) = \lim_n \mathbb{P}(B_n) = \lim_n \mathbb{P}(A_n) + \mathbb{P}(A^c)$$

e di conseguenza

$$\lim_n \mathbb{P}(A_n) = 1 - \mathbb{P}(A^c) = \mathbb{P}(A)$$

4. (e) $\implies$ (d): analogo;

5. (b) $\implies$ (d): per prima cosa notiamo che presi $\{C_n\} \subseteq \mathcal{P}(\Omega)$ allora $C_n \uparrow C$ è equivalente a dire che $C_n^c \uparrow C^c$. Prendiamo $\{A_n\} \subseteq \mathcal{P}(\Omega)$ tali che $A_n \downarrow A$. Per quello che abbiamo scritto prima, $A_n \downarrow A$ implica che $A_n^c \uparrow A^c$ e quindi

$$\lim_n \mathbb{P}(A_n^c) = \mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

di conseguenza

$$1 - \mathbb{P}(A) = \lim_n \mathbb{P}(A_n^c) = \lim_n 1 - \mathbb{P}(A_n) = 1 - \lim_n \mathbb{P}(A_n)$$

6. (d) $\implies$ (b): todo.

7. (d) $\implies$ (c): Prendiamo $\{A_n\} \subseteq \mathcal{P}(\Omega)$ tali che $A_n \uparrow A$. Nello stesso modo di prima otteniamo che $A_n \uparrow A$ implica $A_n^c \downarrow A^c$ e quindi per (b) vale

$$\mathbb{P}(A_n^c) = \mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

e come prima

$$1 - \mathbb{P}(A) = \lim_n \mathbb{P}(A_n^c) = 1 - \lim_n \mathbb{P}(A_n)$$

8. (a) $\implies$ (b): Prendiamo $\{A_n\} \subseteq \mathcal{P}(\Omega)$ tali che $A_n \uparrow A$. Definiamo $B_1 = A_1$ e $B_n = A_n/A_{n-1}$ per tutte le $n > 1$. Il diagramma di Wenn forma delle corone annidate. Per definizione di $A_n \uparrow A$, $\{B_n\}$ sono digiunti e

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n = A$$

Quindi concludiamo che

$$\begin{aligned} \mathbb{P}(A) &= \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(B_n) = \lim_n \sum_{k=1}^n \mathbb{P}(B_k) \\ &= \lim_n \sum_{k=1}^n \mathbb{P}(A_k/A_{k-1}) = \lim_n \sum_{k=1}^n \mathbb{P}(A_k) - \mathbb{P}(A_{k-1}) = \lim_n \mathbb{P}(A_n) \end{aligned}$$

Quindi abbiamo dimostrato che vale (b).

9. (b) $\implies$ (a): Prendiamo $\{A_n\} \subseteq \mathcal{P}(\Omega)$ tale che sono disgiunti. Definiamo

$$B_n = \bigcup_{k=1}^n A_k$$

Quindi abbiamo che $B_n \subseteq B_{n+1}$ per tutte le n e

$$\bigcup_{n=1}^{\infty} B_n = \bigcup_{n=1}^{\infty} A_n = A$$

quindi $B_n \uparrow A$, e allora possiamo applicare (b)

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \mathbb{P}(A) = \lim_n \mathbb{P}(B_n) = \lim_n \mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \lim_n \sum_{k=1}^n \mathbb{P}(A_k) = \sum_{k=1}^{\infty} \mathbb{P}(A_k)$$

Quindi abbiamo mostrato che vale (a). È fondamentale l'additività di $\mathbb{P}$, il che è legato ai risultati di estensione. Infatti, per estendere unicamente una funzione da un'algebra ad una σ -algebra ci serve la σ -additività sull'algebra.

la σ -additività sembra più un'assunzione tecnica che ci garantisce di poter usare i risultati classici della teoria della misura, come per esempio la continuità dall'alto o dal basso. Si possono studiare anche modelli senza quest'ultima.

Proposition σ -sub additività

Sia $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$. Allora,

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

Questa è significativa solo se il termine destro è minore di 1.

Proof

Nel caso finito abbiamo visto la formula di inclusione/esclusione che implica che per ogni n

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) \leq \sum_{k=1}^n \mathbb{P}(A_k)$$

Quindi se definiamo

$$B_n = \bigcup_{k=1}^n A_k$$

Allora, per definizione, $B_n \uparrow \bigcup_{n=1}^{\infty} A_n$ quindi

$$\begin{aligned} \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) &= \lim_n \mathbb{P}(B_n) = \lim_n \mathbb{P}\left(\bigcup_{k=1}^n A_k\right) \\ &\leq \lim_n \sum_{k=1}^n \mathbb{P}(A_k) = \sum_{k=1}^{\infty} \mathbb{P}(A_k) \end{aligned}$$

Visto che Ω è al più numerabile, $\mathcal{P}(\Omega)$ non è necessariamente numerabile. Tuttavia, come nel caso finito, tutti gli elementi di $\mathcal{P}(\Omega)$ possono essere scritti come unioni numerabili di insiemi del tipo $\{\omega\}$ con $\omega \in \Omega$. Quindi possiamo provare un teorema di caratterizzazione per le misure di probabilità su $\mathcal{P}(\Omega)$ analogo a quello nel caso finito.

Definizione Densità discreta

Chiamiamo *densità discreta* una qualsiasi funzione $p: \Omega \rightarrow [0, 1]$ tale che

$$\sum_{\omega \in \Omega} p(\omega) = 1$$

Proposition

Sia $\mathbb{P}$ una misura di probabilità su $(\Omega, \mathcal{P}(\Omega))$. Allora, la funzione $p: \Omega \rightarrow [0, 1]$ definita da

$$p(\omega) \triangleq \mathbb{P}(\{\omega\})$$

è una densità discreta.

In questo caso diciamo che p è la densità discreta associata a $\mathbb{P}$.

Proof

Segue immediatamente usando la σ -additività

$$\sum_{\omega \in \Omega} p(\omega) = \sum_{\omega \in \Omega} \mathbb{P}(\{\omega\}) = \mathbb{P}(\Omega) = 1$$

Proposition

Una misura di probabilità $\mathbb{P}$ su $(\Omega, \mathcal{P}(\Omega))$ è univocamente determinata dalla sua densità discreta p , in particolare

$$\mathbb{P}(A) = \sum_{\omega \in A} p(\omega)$$

per tutte le $A \in \mathcal{P}(\Omega)$. In particolare, se due misure di probabilità $\mathbb{P}_1, \mathbb{P}_2$ su $(\Omega, \mathcal{P}(\Omega))$ con densità discrete rispettivi p_1, p_2 , allora $p_1 = p_2$ se e solo se $\mathbb{P}_1 = \mathbb{P}_2$.

Proof

($\Rightarrow$) Mostriamo che se due misure di probabilità hanno la medesima densità, allora coincidono. Siano $\mathbb{P}_1, \mathbb{P}_2$ misure di probabilità su $(\Omega, \mathcal{P}(\Omega))$ tali che abbiamo la medesima densità discreta p . Allora, per ogni $A \in \mathcal{P}(\Omega)$ vale

$$\mathbb{P}_1(A) = \sum_{\omega \in A} \mathbb{P}_1(\{\omega\}) = \sum_{\omega \in A} p(\omega) = \sum_{\omega \in A} \mathbb{P}_2(\{\omega\}) = \mathbb{P}_2(A)$$

($\Leftarrow$) Siano $\mathbb{P}_1$ e $\mathbb{P}_2$ misure di probabilità su $(\Omega, \mathcal{P}(\Omega))$ con densità p_1 e p_2 rispettivamente. Assumiamo che per tutte le $A \in \mathcal{P}(\Omega)$, $\mathbb{P}_1(A) = \mathbb{P}_2(A)$. Allora

$$p_1(\omega) = \mathbb{P}_1(\{\omega\}) = \mathbb{P}_2(\{\omega\}) = p_2(\omega)$$

per tutte le $\omega \in \Omega$.

Come nel caso finito, qua la σ -additività è fondamentale per garantire che p determina univocamente $\mathbb{P}$.
TODO c'è un errore nel corollario.

Corollario

Sia $\mathbb{P}$ misura di probabilità su $(\Omega, \mathcal{P}(\Omega))$ con densità discreta p . Allora sono equivalenti:

1. $\exists S \subseteq \Omega$ tale che $|S| < \infty$ e $\mathbb{P}(S) = 1$;
2. $\exists S \subseteq \Omega$ tale che $|S| < \infty$ e $p(\omega) > 0 \iff \omega \in S$.

Proof

($\Rightarrow$) Dire che $p(S) = 1$ è equivalente a dire che $\mathbb{P}(S^c) = 0$. Se per assurdo esistesse $\omega \in S^c$ tale che $p(\omega) > 0$, allora

$$\mathbb{P}(S^c) > \mathbb{P}(\{\omega\}) = p(\omega) > 0$$

Quindi è assurdo e tale insieme non esiste.

($\Leftarrow$) Notiamo che

$$\mathbb{P}(S^c) = \sum_{\omega \in S^c} \mathbb{P}(\{\omega\}) = \sum_{\omega \in S^c} p(\omega) = 0$$

quindi

$$\mathbb{P}(S) = 1 - \mathbb{P}(S^c) = 1$$

In generale possiamo dire che

$$S = \{\omega \in \Omega \mid p(\omega) > 0\}$$

allora $\mathbb{P}(S) = 1$.

Tutti i risultati precedenti valgono anche nel caso con Ω al più numerabile. Il teorema delle probabilità totali si può estendere al caso di partizioni numerabili.

Teorema

Sia $\{\Omega_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ tale che $\Omega_i \cap \Omega_j = \emptyset$ per $i \neq j$ e

$$\bigcup_{n=1}^{\infty} \Omega_n = \Omega$$

Allora, per tutte le $A \in \mathcal{P}(\Omega)$ vale

$$\mathbb{P}(A) = \sum_{n=1}^{\infty} \mathbb{P}(A \cap \Omega_n) = \sum_{n=1}^{\infty} \mathbb{P}(A|\Omega_n) \mathbb{P}(\Omega_n)$$

Proof

Abbiamo

$$\begin{aligned} \mathbb{P}(A) &= \mathbb{P}(A \cap \Omega) = \mathbb{P}\left(A \cap \bigcup_{n=1}^{\infty} \Omega_n\right) \\ &= \mathbb{P}\left(\bigcup_{n=1}^{\infty} (A \cap \Omega_n)\right) = \sum_{n=1}^{\infty} \mathbb{P}(A \cap \Omega_n) \end{aligned}$$

La distribuzione di probabilità uniforme può ora essere definita mediante la densità

$$p(\omega) = \frac{1}{|\Omega|}$$

Quella di Bernoulli di parametro $p \in [0, 1]$ su $\Omega = \{0, 1\}$ può essere definita mediante la densità

$$p(1) = p, \quad p(0) = 1 - p(1) = 1 - p$$

Quella binomiale di parametro $p \in [0, 1]$ e $n \in \mathbb{N}$ su $\Omega = \{0, \dots, n\}$ è la misura di probabilità con densità

$$p(k) = \binom{n}{k} p^k (1-p)^{n-k}$$

per $k \in \Omega$.

Quella ipergeometrica di parametri $N \in \mathbb{N}$, $R \leq N$ e $n \leq N$ su $\Omega = \{0, \dots, n\}$ può essere definita con densità

$$p(k) = \frac{\binom{R}{k} \binom{N-R}{n-k}}{\binom{N}{n}}$$

Quella geometrica di parametro $p \in [0, 1]$ su $\Omega = \mathbb{N}$ può essere definita con densità

$$p(n) = p(1-p)^{n-1}$$

TODO mettere pure la multinomiale.

Inoltre possiamo definire pure la Poisson di parametro $\lambda > 0$ su $\Omega = \mathbb{N} \cup \{0\}$ definita con densità

$$p(k) = \frac{\lambda^k}{k!} e^{-\lambda}$$

Verifichiamo che sia una densità discreta e che quindi definita una misura di probabilità

$$\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = 1$$

Modellizza il numero di arrivi in una coda in un certo lasso temporale

2.4 Variabili aleatorie

Definizione Variabile aleatorie

Una *variabile aleatoria* è una quantità che dipende dal risultato di un esperimento aleatorio.

Sia $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno spazio di probabilità numerabile.

Definizione Variabile aleatoria discreta

Una *variabile aleatoria discreta* è una funzione $X: \Omega \rightarrow E$ dove $E \subseteq \mathbb{R}^n$ discreto.

Definizione Legge della variabile aleatoria

Chiamiamo *legge della variabile aleatoria* X la funzione $\mu_X: \mathcal{P}(E) \rightarrow [0, 1]$ definita da

$$\mu_X(A) \triangleq \mathbb{P}(X \in A) \triangleq \mathbb{P}(\{\omega\} \in \Omega \mid X(\omega) \in A), \quad A \in \mathcal{P}(E)$$

Cioè vogliamo la probabilità che X appartenga ad un sottoinsieme.

Per esempio, identificare l'insieme testa e croce con $\{0, 1\}$ corrisponde alla definizione di una variabile aleatoria $X: \{T, C\} \rightarrow \{0, 1\}$ tale che $X(T) = 1$ e $X(C) = 0$. In questo caso la legge è

$$\begin{aligned} \mu_X(\{1\}) &= \mathbb{P}(X = 1) = \mathbb{P}(\{T\}) = p \\ \mu_X(\{0\}) &= \mathbb{P}(X = 0) = \mathbb{P}(\{C\}) = 1 - p \end{aligned}$$

In questo caso μ_X è una bernoulliana di parametri p .

Proposition

Sia $X: \Omega \rightarrow E$ con $E \subseteq \mathbb{R}^n$ discreto. Allora, la legge di variabili aleatoria discreta μ_X di X è una misura di probabilità sullo $(E, \mathcal{P}(E))$.

Proof

1.

$$\mu_X(E) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in E\}) = \mathbb{P}(\Omega) = 1$$

2. σ -additività: siano $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{P}(\Omega)$ tali che $A_i \cap A_j = \emptyset$. Allora,

$$\begin{aligned} \mu_X\left(\bigcup_{n=1}^{\infty} A_n\right) &= \mathbb{P}\left(\{\omega \in \Omega \mid X(\omega) \in \bigcup_{n=1}^{\infty} A_n\}\right) \\ &= \mathbb{P}\left(\bigcup_{n=1}^{\infty} \underbrace{\{\omega \in \Omega \mid X(\omega) \in A_n\}}_{C_n \in \mathcal{P}(\Omega)}\right) \end{aligned}$$

Se i C_n sono disgiunti, abbiamo finito perché usiamo la σ -additività di $\mathbb{P}$. Supponiamo per assurdo che esistano i, j naturali tale che $i \neq j$ e $\omega \in \Omega$ tale che

$$\omega \in C_i \cap C_j$$

Per definizione dei C_n vale che

$$X(\omega) \in A_i \cap A_j$$

per il fatto che X è una funzione quindi ogni elemento di Ω associa uno e un solo elemento di E . Tuttavia, A_i e A_j sono disgiunti per ipotesi, quindi è assurdo. Quindi, $C_i \cap C_j = \emptyset$ per ogni $i \neq j$. Di conseguenza, vale la σ -addittività grazie alla σ -addittività di $\mathbb{P}$.

3. chiaramente $\mu_X(A) \in [0, 1]$.

Abbiamo anche quindi una densità associata a questa misura. Quindi, ci basta conoscere la densità discreta alla variabile aleatoria per conoscerne la legge.

Definizione Densità discreta di X

Sia $X: \Omega \rightarrow E$ una variabile aleatoria discreta con $E \subseteq \mathbb{R}^n$ discreto. Chiamiamo *densità discreta* di (o associata) ad X la densità discreta $p_X: E \rightarrow [0, 1]$ associata alla legge μ_X di X . Cioè,

$$p_X(x) \triangleq \mu_X(\{x\}) = \mathbb{P}(X = x) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) = x\}), \quad \forall x \in E$$

Syntax: usiamo la notazione $X \sim \gamma$ per intendere che X ha legge γ , cioè $\mu_X = \gamma$.

Quindi $X \sim \gamma$ se X ha densità discreta uguale alla densità discreta di γ .

Esempio

Consideriamo $X \sim \text{bin}(n, p)$. Ciò significa che $X: \Omega \rightarrow \{0, \dots, n\}$ con densità discreta p_X data da

$$p_X(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad \forall k \in \{0, \dots, n\}$$

Sia $X: \Omega \rightarrow E \subseteq \mathbb{R}^n$ con densità discreta $p_X: E \rightarrow [0, 1]$. Allora, $\forall A \in \mathcal{P}(E)$, vale

$$\begin{aligned} \mu_X(A) &= \mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)) = \sum_{x \in A} \mathbb{P}(X = x) \\ &= \sum_{x \in A} p_X(x) \end{aligned}$$

La serie è ben definita in quanto A è discreto, quindi abbiamo unione al più numerabile di $\{x\}$ (al più una serie, non un integrale). Quindi la probabilità che X prenda valore in A è data dalla somma delle probabilità che X assuma nei singoletti di A . Notiamo che definito

$$S = \{x \in E \mid p_X(x) = \mathbb{P}(X = x) > 0\}$$

Notiamo allora che, per definizione di densità discreta, vale

$$\mu_X(S) = \mathbb{P}(X \in S) = 1$$

In particolare, S è il più piccolo sottoinsieme di E su cui μ_X assume valore 1. Di solito viene chiamato *supporto* della misura μ_X (oppure di X). Visto che siamo nel caso discreto, $\mathbb{P}(X \in A) > 0$ se e solo se $A \cap S \neq \emptyset$. Nel continuo questo non è detto.

Le funzioni indicatrici di $A \in \mathcal{P}(\Omega)$ sono un caso particolare di variabili aleatorie. Abbiamo che

$$\begin{aligned} \mathbb{P}(\chi_A = 0) &= \mathbb{P}(\{\omega \in \Omega \mid \chi_A(\omega) = 0\}) = \mathbb{P}(A^c) \\ \mathbb{P}(\chi_A = 1) &= \mathbb{P}(\{\omega \in \Omega \mid \chi_A(\omega) = 1\}) = \mathbb{P}(A) \end{aligned}$$

Da questo ricaviamo che $\chi_A \sim \text{ber}(\mathbb{P}(A))$.

Proposition Proprietà funzioni indicatrici

Siano $A, B \in \mathcal{P}(\Omega)$. Allora

1. $\chi_A = 1 - \chi_{\Omega \setminus A}$

2.

$$\chi_{A \cup B} = \chi_A + \chi_B - \chi_{A \cap B} = \max\{\chi_A, \chi_B\}$$

3.

$$\chi_{A \cap B} = \chi_A \chi_B = \min\{\chi_A, \chi_B\}$$

4. se $A \subseteq B$, allora

$$\chi_{B \setminus A} = \chi_B - \chi_A$$

Proof

1. Distinguiamo due casi:

(a) se $\omega \in A$, allora

$$0 = \chi_{\Omega \setminus A}(\omega) = 1 - \chi_A(\omega)$$

(b) se $\omega \in \Omega \setminus A$, allora

$$1 = \chi_{\Omega \setminus A}(\omega) = 1 - \chi_A(\omega)$$

2. Distinguiamo quattro casi:

(a) se $\omega \in A \cap B$, allora

$$\begin{aligned} 1 &= \chi_{A \cup B}(\omega) = \max\{\chi_A(\omega), \chi_B(\omega)\} \\ &= \overset{1}{\cancel{\chi_A(\omega)}} + \overset{1}{\cancel{\chi_B(\omega)}} - \overset{1}{\cancel{\chi_{A \cap B}(\omega)}} \end{aligned}$$

(b) se $\omega \in A \cap (\Omega \setminus B)$, allora

$$\begin{aligned} 1 &= \chi_{A \cup B}(\omega) = \max\{\chi_A(\omega), \chi_B(\omega)\} \\ &= \overset{1}{\cancel{\chi_A(\omega)}} + \overset{0}{\cancel{\chi_B(\omega)}} - \overset{0}{\cancel{\chi_{A \cap B}(\omega)}} \end{aligned}$$

(c) se $\omega \in (\Omega \setminus A) \cap B$, il caso è analogo al precedente.

(d) se $\omega \in (\Omega \setminus A) \cap (\Omega \setminus B)$, allora

$$\begin{aligned} 0 &= \chi_{A \cup B}(\omega) = \max\{\chi_A(\omega), \chi_B(\omega)\} \\ &= \overset{0}{\cancel{\chi_A(\omega)}} + \overset{0}{\cancel{\chi_B(\omega)}} - \overset{0}{\cancel{\chi_{A \cap B}(\omega)}} \end{aligned}$$

3. todo

4. todo

Prendiamo $X: \Omega \rightarrow E$ discreta con $E \subseteq \mathbb{R}^n$ discreto. Definiamo

$$\Omega_x \triangleq \{\omega \in \Omega \mid X(\omega) = x\}, \quad \forall x \in E$$

cioè la fibra di x . Notiamo che $\{\Omega_x\}$ è una famiglia numerabile. Inoltre $\Omega_x \cap \Omega_y = \emptyset$ per $x \neq y$, in quanto X è una funzione. Inoltre,

$$\Omega = \bigcup_{x \in E} \Omega_x$$

unione al più numerabile. Definiamo la variabile aleatoria

$$\hat{X} = \sum_{x \in E} x \chi_{\Omega_x}$$

Ma notiamo che $\hat{X}(\omega) = x = X(\omega)$. Possiamo quindi scrivere una variabile aleatoria discreta come sommatoria o serie di funzioni indicatrici.

Data una variabile aleatoria discreta, possiamo sempre associarne la legge, che è una misura di probabilità sullo spazio di arrivo. Possiamo fare il converso, cioè: fissato $E \subseteq \mathbb{R}^n$ discreto e μ misura di probabilità su $(E, \mathcal{P}(E))$, allora esiste uno spazio di probabilità $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ discreto e $X: \Omega \rightarrow E$ tale che $\mu_X = \mu$, cioè X ha legge μ ? La risposta è sì: come spazio di probabilità prendiamo $(E, \mathcal{P}(E), \mu)$ cioè $\Omega = E$, e come variabile aleatoria prendiamo $X: \Omega \rightarrow E$ tale che $X(\omega) = \omega$. Di conseguenza, per definizione delle legge di X , per tutte le A vale

$$\mu_X(A) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in A\}) = \mathbb{P}(\{\omega \in \Omega = E \mid \omega \in A\}) = \mathbb{P}(A) = \mu(A)$$

Questa si chiama costruzione canonica di una variabile aleatoria.

Come facciamo a capire se due variabili aleatorie coincidono?

Definizione

Siano $(\Omega_1, \mathcal{P}(\Omega_1), \mathbb{P}_1), (\Omega_2, \mathcal{P}(\Omega_2), \mathbb{P}_2)$ spazi di probabilità discreti e $X_1: \Omega_1 \rightarrow E, X_2: \Omega_2 \rightarrow E$ variabili aleatorie discrete con $E \subseteq \mathbb{R}^n$. Supponiamo che $X_1 \sim \mu_1$ con densità p_1 e $X_2 \sim \mu_2$ con densità p_2 .

1. Diciamo che X_1 e X_2 sono uguali *in legge* (o in distribuzione o debolmente) se $\mu_1 = \mu_2$, o in modo equivalente $p_1 = p_2$.
2. Diciamo che X_1 e X_2 sono uguali *quasi certamente* se $\Omega_1 = \Omega_2 = \Omega$ e $\mathbb{P}_1 = \mathbb{P}_2 = \mathbb{P}$ e vale che

$$\mathbb{P}(\{\omega \in \Omega \mid X_1(\omega) = X_2(\omega)\}) = 1$$

Cioè per la misura quasi certa, vogliamo che coincidano ove la misura è non nulla. Non è l'uguaglianza insiemistica delle funzioni. È simile ma possiamo escludere dalla variabile aleatoria insiemi di misura nulla rispetto a $\mathbb{P}$. In altri modi

$$\mathbb{P}(\{\omega \in \Omega \mid X_1(\omega) \neq X_2(\omega)\}) = 0$$

Anche nel caso in cui $\Omega_1 = \Omega_2 = \Omega$ e $\mathbb{P}_1 = \mathbb{P}_2 = \mathbb{P}$, in generale l'uguaglianza in distribuzione non implica quella quasi certa.

Esempio Uguaglianza in distribuzione non implica quella quasi certa

Consideriamo $\Omega = \{T, C\}$ e $X: \Omega \rightarrow [0, 1]$ tale che $X(T) = 1$ e $X(C) = 0$ e $\mathbb{P}(X = 1) = \mathbb{P}(X = 0) = \frac{1}{2}$. Quindi, X è una bernoulliana di parametro $\frac{1}{2}$. Possiamo scambiare testa e croce, quindi $Y = 1 - X$, quindi

$$\mathbb{P}(Y = 1) = \mathbb{P}(1 - X = 1) = \mathbb{P}(X = 0) = \frac{1}{2} \mathbb{P}(Y = 0) = \mathbb{P}(1 - X = 0) = \mathbb{P}(X = 1) = \frac{1}{2}$$

Quindi, X e Y sono uguali in legge ma non quasi certamente, in quanto $1 = X(T) \neq Y(T) = 0$ e $0 = X(C) \neq Y(C) = 1$. Quindi le due funzioni sono distinte in ogni punti di Ω , e non è trascurabile.

Tuttavia vale il viceversa. Usiamo la notazione $X =_d Y$ per indicare che X è uguale a Y in legge.

Proposition

Consideriamo $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ spazio di probabilità discreto e $X, Y: \Omega \rightarrow E \subseteq \mathbb{R}$ variabili aleatorie discrete. Allora, se $X = Y$ quasi ovunque, $X =_d Y$.

Proof

Abbiamo che $\mathbb{P}(\Omega_0) = 1$ con

$$\Omega_0 = \{\omega \in \Omega \mid X(\omega) = Y(\omega)\}$$

che non è necessariamente il più piccolo. Notiamo che $\forall A \in \mathcal{P}(\Omega)$ vale

$$\mathbb{P}(A) = \mathbb{P}(A \cap \Omega_0) + \mathbb{P}(A \cap (\Omega \setminus \Omega_0)) - \mathbb{P}(A \cap \Omega_0)$$

sfruttando questa osservazione dimostriamo che le leggi μ_X e μ_Y sono uguali, cioè

$$\mu_X(A) = \mu_Y(A), \quad \forall A \in \mathcal{P}(\Omega)$$

Sia $A \in \mathcal{P}(\Omega)$, allora sfruttando l'osservazione

$$\begin{aligned} \mu_X(A) &= \mathbb{P}(X \in A) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in A\} \cap \Omega_0) \\ &= \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in A\} \cap \{\omega \in \Omega \mid X(\omega) = Y(\omega)\}) \\ &= \mathbb{P}(Y \in A) = \mu_Y(A) \end{aligned}$$

Proposition

Siano $(\Omega_1, \mathcal{P}(\Omega_1), \mathbb{P}_1), (\Omega_2, \mathcal{P}(\Omega_2), \mathbb{P}_2)$ spazi di probabilità discreti e $X: \Omega_1 \rightarrow E, Y: \Omega_2 \rightarrow E$ variabili aleatorie discrete con $E \subseteq \mathbb{R}^n$ discreto. Sia $f: E \rightarrow F$ con $F \subseteq \mathbb{R}^n$ discreto. Allora,

$$X =_d Y \implies f \circ X =_d f \circ Y$$

Proof

Innanzitutto notiamo che preso $A \in \mathcal{P}(F)$, vale che

$$\begin{aligned} \{f(x) \in A\} &= \{\omega \in \Omega_1 \mid f(X(\omega)) \in A\} \\ &= \{\omega \in \Omega_1 \mid X(\omega) \in f^{-1}(A)\} = \{X \in f^{-1}(A)\} \end{aligned}$$

Notiamo che $f(X): \Omega_1 \rightarrow F$ è una variabile aleatoria discreta, e di conseguenza l'uguaglianza appena vista significa che l'evento $f(X)$ assume valore in A è uguale all'evento X assume valore in $f^{-1}(A)$. Analogamente,

$$\{f(Y) \in A\} = \{Y \in f^{-1}(A)\}$$

Dobbiamo mostrare che $\mu_Y = \mu_X$ implica che $\mu_{f(X)} = \mu_{f(Y)}$ dove

$$X \sim \mu_X, \quad Y \sim \mu_Y, \quad f(X) \sim \mu_{f(X)}, \quad f(Y) \sim \mu_{f(Y)}$$

Fissato $A \in \mathcal{P}(F)$, vale che

$$\begin{aligned} \mu_{f(X)}(A) &= \mathbb{P}(f(X) \in A) = \mathbb{P}(X \in f^{-1}(A)) \\ &= \mu_X(f^{-1}(A)) = \mu_Y(f^{-1}(A)) \\ &= \mathbb{P}(Y \in f^{-1}(A)) = \mathbb{P}(f(Y) \in A) = \mu_{f(Y)} \end{aligned}$$

2.5 Vettori aleatori discreti

Sia $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno spazio di probabilità discreto

Definizione Vettore aleatorio discreto

Sia $n \in \mathbb{N}$. Un *vettore aleatorio discreto* una n -upla $(X_1, \dots, X_n)$ tale che $X_i: \Omega \rightarrow E_i$ variabile aleatoria discreta con $E_i \in \mathbb{R}^n$ discreto.

Notiamo subito che per un vettore aleatorio discreto può essere visto come una variabile aleatoria discreta

$$X: \Omega \rightarrow \prod_{i=1}^n E_i, \quad X(\omega) = (X_1(\omega), \dots, X_n(\omega))$$

a cui possiamo associare una legge μ_X su $\mathcal{P}(\prod E_i)$ e una densità discreta

$$p_X: \prod_{i=1}^n E_i \rightarrow [0, 1], \quad p_X(x_1, \dots, x_n) = \mathbb{P}(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

con $(x_1, \dots, x_n) \in \prod E_i$. Ogni elementi di $\mathcal{P}(\prod E_i)$ può essere scritto come unioni o intersezioni di elementi del tipo di $\prod A_i$ con $A_i \in \mathcal{P}(E_i)$, quindi vale

$$\mu_X \left(\prod_{i=1}^n A_i \right) = \mathbb{P}(X_1 \in A_1, X_2 \in A_2, \dots, X_n \in A_n) = \mathbb{P} \left(\bigcup_{i=1}^n \{X_i \in A_i\} \right)$$

Inoltre, preso $k \in \{1, \dots, n\}$ e $i_1 < \dots < i_k \in \{1, \dots, n\}$, possiamo considerare i sotto-vettori aleatori $(X_{i_1}, X_{i_2}, \dots, X_{i_k})$ e possiamo identificarlo con la variabile aleatoria discreta

$$X_I: \Omega \rightarrow \prod_{j=1}^k E_{i_j}$$

dato da

$$X_i(\omega) = (X_{i_1}(\omega), X_{i_2}(\omega), \dots, X_{i_k}(\omega)), \quad \omega \in \Omega$$

dove $I = (i_1, \dots, i_k)$. Ovviamente anche a questa variabile aleatoria discreta si associa una legge

$$\mu_X: \mathcal{P} \left(\prod_{j=1}^k E_{i_j} \right) \rightarrow [0, 1]$$

e anche qua notamo che

$$\begin{aligned} p_I(x_{i_1}, \dots, x_{i_k}) &= \mathbb{P}(X_{i_1} = x_{i_1}, X_{i_2} = x_{i_2}, \dots, X_{i_k} = x_{i_k}) \\ &= (x_{i_1}, \dots, x_{i_k}) \in \prod_{j=1}^k E_{i_j} \end{aligned}$$

Definizione Congiunta e marginali

Siano $(X_1, \dots, X_n)$ vettore aleatorio discreto con $X_i: \Omega \rightarrow E_i$ variabile aleatoria discreta. Chiamiamo *legge congiunta* di $(X_1, \dots, X_n)$ la legge della variabile aleatoria discreta

$$X = (X_1, \dots, X_n): \Omega \rightarrow \prod_{i=1}^n E_i$$

e la indichiamo con $\mu_{X_1, \dots, X_n}$. Analogamente, chiamiamo *densità congiunta* del vettore $(X_1, \dots, X_n)$ la densità di X e la indichiamo con

$$p_{X_1, \dots, X_n}: \prod_{i=1}^n E_i \rightarrow [0, 1]$$

Dato $k \in \{1, \dots, n\}$ e $i_1 < \dots < i_k \in \{1, \dots, n\}$ e $I = (i_1, \dots, i_k)$ chiamiamo *legge marginale* di $(X_1, \dots, X_n)$ rispetto I la legge della variabile aleatoria discreta

$$X_I = (X_{i_1}, X_{i_2}, \dots, X_{i_k}): \Omega \rightarrow \prod_{j=1}^k E_{i_j}$$

e la indichiamo μ_I . Allo stesso modo chiamiamo *densità marginale* di $(X_1, \dots, X_n)$ rispetto ad I la densità della variabile aleatoria discreta X_i e la indichiamo con

$$p_I: \prod_{j=1}^k E_{i_j} \rightarrow [0, 1]$$

In particolare chiamiamo *marginali unidimensionali* le leggi o densità del vettore delle X_i con $i \in \{1, \dots, n\}$, cioè

$$\begin{aligned} p_i(X_i) &= (X_i = x_i), \quad x_i \in E_i, \forall i \in \{1, \dots, n\} \\ \mu_i(A_i) &= \mathbb{P}(X_i \in A_i), \quad A_i \in \mathcal{P}(E_i), \forall i \in \{1, \dots, n\} \end{aligned}$$

che sono la densità massimale e la legge marginale.

Proposition

Sia $(X_1, \dots, X_n)$ vettore aleatorio discreto con $X_i: \Omega \rightarrow E_i \subseteq \mathbb{R}$. discreto $\forall i \in \{1, \dots, n\}$. Allora, la legge o densità congiunta determina univocamente le leggi o densità marginali. In particolare, $\forall k \in \{1, \dots, n\}, i_1 < \dots < i_k \in \{1, \dots, n\}$, e $I = (i_1, \dots, i_k)$, vale che

$$\begin{aligned} p_I(x_{i_1}, \dots, x_{i_k}) &= \mathbb{P}(X_{i_1} = x_{i_1}, \dots, X_{i_k} = x_{i_k}) \\ &= \sum_{\substack{x_j \in E_j \\ j \in \{1, \dots, n\} \setminus I}} p_{x_1, \dots, x_n}(x_1, x_{i_1}, \dots, x_{i_k}, x_n) \end{aligned}$$

Nello sgtesso modo

$$\begin{aligned} \mu_I \left(\prod_{j=1}^k A_{i_j} \right) &= \mathbb{P}(X_{i_1} \in A_{i_1}, \dots, X_{i_k} \in A_{i_k}) \\ &= \mu_{X_1, \dots, X_n}(X_1 \in E_1, \dots, X_{i_1} \in A_{i_1}, \dots, X_{i_k} \in A_{i_k}, \dots, X_n \in E_n) \\ &= \mathbb{P}(X_1 \in E_1, \dots, X_{i_1} \in A_{i_1}, \dots, X_{i_k} \in A_{i_k}, \dots, X_n \in E_n) \end{aligned}$$

Cioè stiamo sommando su tutti gli elementi E_j con $j \in I$. Per $j \notin I$ consideriamo l'evneto $\{x_j \in E_j\} = \Omega$.

Proof

La densità determina univocamente la legge, quindi basta provare il risultato solo per quest'ultima. Fissiamo per comodità $k \in \{1, \dots, n\}$ e $i_1 = 1, \dots, i_k = k$. Quindi,

$$\begin{aligned} P_{1, \dots, k}(x_1, \dots, x_k) &= \mathbb{P}(X_1 = x_1, \dots, X_k = x_k) \\ &= \mathbb{P}(X_1 = x_1, \dots, X_k = x_k, \Omega) \\ &= \mathbb{P}(X_1 = x_1, \dots, X_k = x_k, X_{k+1} \in E_{k+1}, \dots, X_n \in E_n) \quad \Bigg\rangle \Omega = \{X_i \in E_i\} \\ &= \mathbb{P} \left(X_1 = x_1, \dots, X_k = x_k, X_{k+1} \in \bigcup_{x \in E_{k+1}} \{x\}, \dots, X_n \in \bigcup_{x \in E_n} \{x\} \right) \quad \Bigg\rangle (*) \\ &= \sum_{x_{k+1} \in E_{k+1}} \dots \sum_{x_n \in E_n} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) \\ &= \sum_{x_{k+1} \in E_{k+1}} \dots \sum_{x_n \in E_n} p_{X_1, \dots, X_n}(x_1, \dots, x_n) \end{aligned}$$

Dove (*) è il fato che

$$\{(x_1, \dots, x_n)\} \cap \{(y_1, \dots, x_n)\} = \emptyset$$

se $\exists j \in \{1, \dots, n\}$ tale che $x_j \neq y_j$.

L'idea è quella di ignorare le componenti che ci interessano rimpiazzandole con E_i , che è l'evento certo, in quanto la probabilità che un elemento stia nel suo insieme di definizione è 1.

Esempio

Consideriamo il vettore aleatorio (X, Y) con $X: \Omega \rightarrow E_1 \subseteq \mathbb{R}$ e $Y: \Omega \rightarrow E_2 \subseteq \mathbb{R}$ variabili aleatorie discrete. Indichiamo con $\mu_{X,Y}$ la legge congiunta e con $p_{X,Y}$ la densità congiunta. Allora

$$\begin{aligned} p_X(x) &= \sum_{y \in E_2} p_{X,Y}(x, y) \\ p_Y(y) &= \sum_{x \in E_1} p_{X,Y}(x, y) \end{aligned}$$

cioè la densità marginale di X e quella di Y . Inoltre, presi $A_1 \in \mathcal{P}(E_1), A_2 \in \mathcal{P}(E_2)$, vale

$$\mu_{X,Y}(A_1 \times A_2) = \mathbb{P}(X \in A_1, Y \in A_2) = \sum_{x \in A_1} \sum_{y \in A_2} p_{X,Y}(x, y)$$

Da questo deduciamo che

$$\begin{aligned} \mu_X(A_1) &= \mu_{X,Y}(A_1 \times E_2) = \sum_{x \in A_1} \sum_{y \in E_2} p_{X,Y}(x, y) \\ &= \sum_{x \in A_1} p_X(x) \end{aligned}$$

Allo stesso modo

$$\mu_Y(A_2) = \sum_{y \in A_2} \sum_{x \in E_1} p_{X,Y}(x, y) = \sum_{y \in A_2} p_Y(y)$$

che è coerente. Notiamo anche che se per $x \in E_1$ vale $p_X(x) = 0$, allora $p_{X,Y}(x, y) = 0$ per tutte le $y \in E_2$. Analogamente se per $y \in E_2$ vale $p_Y(y) = 0$, allora $p_{X,Y}(x, y) = 0$ per tutte le $x \in E_1$. Infatti,

$$0 = p_X(x) = \sum_{y \in E_2} p_{X,Y}(x, y) \implies p_{X,Y}(x, y) = 0$$

per tutte le $y \in E_2$. Questo vuol dire che se la variabile aleatoria X assume il valore x con probabilità 0, allora il vettore (X, Y) assume valore (x, y) al variare di $y \in E_2$ con probabilità 0, cioè

$$\mathbb{P}((x, y) \in \{x\} \times E_2) = 0$$

In pratica stiamo togliendo un asse, sul quale non prenderà valore. Una sorta di viceversa non vale, cioè se per $(x, y) \in E_1 \times E_2$ vale $p_{X,Y}(x, y) = 0$, allora non è vero che $p_X(x) = 0 \wedge p_Y(y) = 0$.

In generale, le leggi/densità marginali non determinano univocamente la congiunta.

Esempio Controesempio

Consideriamo un'urna con n palline numerate da 1 a n . Facciamo due estrazioni. Indichiamo con una variabile aleatoria $X_1: \Omega \rightarrow \{1, \dots, n\}$ il risultato della prima estrazione e $X_2: \Omega \rightarrow \{1, \dots, n\}$ quello della seconda, dove $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ è uno spazio di probabilità generico. In particolare, il vettore $(X_1, X_2): \Omega \rightarrow \{1, \dots, n\}^2$ rappresenta il risultato dell'esperimento. Dividiamo in due casi:

1. *estrazioni senza reimmissione*: calcoliamo la densità congiunta di (X_1, X_2)

$$p_{X_1, X_2}(i, j) = \mathbb{P}(X_1 = i, X_2 = j) = \begin{cases} 0 & i = j \\ \frac{1}{n(n-1)} & i \neq j \end{cases}$$

calcoliamo le marginali

$$p_1(i) = \sum_{j=1}^n p_{X_1, X_2}(i, j) = \sum_{\substack{j=1 \\ j \neq i}}^n \frac{1}{n(n-1)} = \frac{1}{n(n-1)}(n-1) = \frac{1}{n}$$

$$p_2(j) = \sum_{i=1}^n p_{X_1, X_2}(i, j) = \frac{1}{n}$$

Se $i = j$, allora la congiunta è nulla ma nei marginali sono $\frac{1}{n}$. Inoltre $p_1(i), p_2(i) > 0, \forall i \in \{1, \dots, n\}$. Quindi $\{1, \dots, n\}$ è il supporto delle leggi di X_1 e X_2 ma $\{1, \dots, n\}^2$ non è il supporto del vettore (X_1, X_2) , infatti il suo supporto è

$$S = \{(i, s) \in \{1, \dots, n\}^2 \mid i \neq s\}$$

Quindi non è detto che il supporto del vettore sia il prodotto cartesiano dei singoli supporti.

2. *estrazioni con reimmissione*: calcoliamo la densità congiunta di (X_1, X_2)

$$p_{X_1, X_2}(i, j) = \mathbb{P}(X_1 = i, X_2 = j) = \frac{1}{n^2}$$

calcoliamo le marginali

$$p_1(i) = \sum_{j=1}^n p_{X_1, X_2}(i, j) = \frac{1}{n}$$

$$p_2(j) = \sum_{i=1}^n p_{X_1, X_2}(i, j) = \frac{1}{n}$$

Abbiamo trovato il controesempio: abbiamo le stesse marginali ma congiunta diverse. Notiamo che in questo caso la congiunta è il prodotto delle marginali (anche il supporto è il prodotto cartesiano dei supporti). In particolare,

$$p_{X_1, X_2}(i, j) = \mathbb{P}(\{X_1 = 1\} \cap \{X_2 = 2\}) = p_1(i)p_2(j) = \mathbb{P}(X_1 = i)\mathbb{P}(X_2 = j)$$

Questo ci suggerisce il concetto di indipendenza fra variabili aleatorie discrete.

2.6 Indipendenza di variabili aleatorie discrete

Fissiamo $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ spazio di probabilità discreto.

Definizione Indipendenza di variabili aleatorie discrete

Siano $X_1, \dots, X_n$ con $n \in \mathbb{N}$ variabili aleatorie discrete $X_i: \Omega \rightarrow E_i \subseteq \mathbb{R}$ discreto per $i \in \{1, \dots, n\}$. Diciamo che queste sono indipendenti se

$$\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n \mathbb{P}(X_i \in A_i), \quad \forall A_i \in \mathcal{P}(E_i), i \in \{1, \dots, n\}$$

Negli eventi indipendenti abbiamo considerato tutte le possibili catene, mentre qui no. Quell'idea è nasconsta nel fatto che stiamo dando la definizione per ogni A_i . Posso prendere $A_i = E_i$ per annullare

un evento e quindi averlo sulle singole famiglie.

Preso $k \in \{1, \dots, n\}$ e $i_1 < \dots < i_k \in \{1, \dots, n\}$ allora anche $X_{i_1}, \dots, X_{i_k}$ sono variabili discrete indipendenti. Infatti basta prendere la definizione appena data con $A_j = E_j$ per ogni $j \notin \{i_1, \dots, i_k\}$.

Infatti,

$$\begin{aligned} \mathbb{P}\left(\bigcap_{v=1}^k \{X_{i_v} \in A_{i_v}\}\right) &= \mathbb{P}\left(\bigcap_{v=1}^k \{X_{i_v} \in A_{i_v}\} \cap \Omega\right) \\ &= \mathbb{P}\left(\left(\bigcap_{v=1}^k \{X_{i_v} \in A_{i_v}\}\right) \cap \left(\bigcap_{j \notin \{i_1, \dots, i_k\}} \{X_j \in E_j\}\right)\right) \\ &= \prod_{v=1}^k \mathbb{P}(X_{i_v} \in A_{i_v}) \end{aligned}$$

Questo fatto ci dice che gli eventi $\{X_1 \in A_1\}, \dots, \{X_n \in A_n\}$ soddisfano la definizione di eventi indipendenti per ogni scelta degli $A_i \in \mathcal{P}(E_i)$. Intuitivamente questa definizione di indipendenza ci dice che avere informazioni su una o più variabili alatorie discrete non condiziona la probabilità di assumere un certo valore delle altre variabili.

Vediamolo nel caso $n = 2$, $i \in E_1$ e $j \in E_2$

$$\begin{aligned} \mathbb{P}(X_2 = j | X_1 = i) &= \frac{\mathbb{P}(\{X_2 = j\} \cap \{X_1 = i\})}{\mathbb{P}(X_1 = i)} \\ &= \frac{\mathbb{P}(X_2 = j) \cancel{\mathbb{P}(X_1 = i)}}{\cancel{\mathbb{P}(X_1 = i)}} \end{aligned}$$

Proposition

Siano $(X_1, \dots, X_n)$ variabili aleatorie discrete $X_1: \Omega \rightarrow E_1 \subseteq \mathbb{R}^n$ discreto con $i \in \{1, \dots, n\}$ e $n \in \mathbb{N}$. Siano

$$p_{X_1, \dots, X_n}: \prod_{i=1}^n E_i \rightarrow [0, 1]$$

la densità congiunta del vettore $(X_1, \dots, X_n)$ e p_i densità marginale di X_i con $i \in \{1, \dots, n\}$. Allora, $X_1, \dots, X_n$ indipendenti se e solo se

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = \prod_{i=1}^n p_i(x_i), \quad \forall (x_1, \dots, x_n) \in \prod_{i=1}^n E_i$$

Proof

($\Rightarrow$) Supponiamo che $X_1, \dots, X_n$ siano indipendenti. Sia $(x_1, \dots, x_n) \in \prod E_i$. Allora,

$$\begin{aligned} p_{X_1, \dots, X_n}(x_1, \dots, x_n) &= \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) \\ &= \prod_{i=1}^n \mathbb{P}(X_i = x_i) = \prod_{i=1}^n p_i(x_i) \end{aligned}$$

($\Leftarrow$) Siano $A_i \in \mathcal{P}(E_1), \dots, A_n \in \mathcal{P}(E_n)$. Abbiamo che

$$\begin{aligned}\mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) &= \sum_{x_1 \in A_1} \cdots \sum_{x_n \in A_n} p_{X_1, \dots, X_n}(x_1, \dots, x_n) \\ &= \sum_{x_1 \in A_1} p_1(x_1) \cdots \sum_{x_n \in A_n} p_n(x_n) \\ &= \mathbb{P}(X_1 \in A_1) \cdots \mathbb{P}(X_n \in A_n) = \prod_{i=1}^n \mathbb{P}(X_i \in A_i)\end{aligned}$$

Proposition

Siano $Y, X: \Omega \rightarrow E \subseteq \mathbb{R}$ discrete con densità congiunta $p_{X,Y}: E \times E \rightarrow [0, 1]$. Supponiamo che $\exists \alpha, \beta: E \rightarrow \mathbb{R}^+$ tale che

$$p_{X,Y}(x, y) = \alpha(x)\beta(y), \quad \forall x, y \in E$$

Allora X e Y sono indipendenti.

Proof

Abbiamo

$$p_X(x) = \sum_{y \in E} p_{X,Y}(x, y) = \sum_{y \in E} \alpha(x)\beta(y) = \alpha(x) \sum_{y \in E} \beta(y)$$

Quindi $p_X(x) = C\alpha(x)$ per ogni $x \in E$, dove

$$C = \sum_{y \in E} \beta(y)$$

Analogamente $p_Y(y) = D\beta(y)$ per ogni $y \in E$, dove

$$D = \sum_{x \in E} \alpha(x)$$

Inoltre sappiamo che

$$1 = \sum_{x \in E} \sum_{y \in E} p_{X,Y}(x, y) = \sum_{x \in E} \sum_{y \in E} \alpha(x)\beta(y) = CD$$

e quindi $D = C^{-1}$. Concludiamo quindi che $\forall x, y \in E$

$$p_{X,Y}(x, y) = \alpha(x)\beta(y) \cdot 1 = \alpha(x)\beta(y) \cdot CD = C\alpha(x)D\beta(y) = p_X(x)p_Y(y)$$

Questa proposizione è generalizzabile.

Proposition

Siano $X_1, \dots, X_n$ variabili aleatorie discrete $X_i: \Omega \rightarrow E_i$ con $i \in \{1, \dots, n\}$. Siano $X'_1, \dots, X'_n$ variabili aleatorie discrete $X'_i: \Omega \rightarrow E_i$ con $i \in \{1, \dots, n\}$. Supponiamo che

$$(X_1, \dots, X_n) =_d (X'_1, \dots, X'_n)$$

Allora $X_1, \dots, X_n$ sono indipendenti se e solo se $X'_1, \dots, X'_n$ sono indipendenti.

Proof

La condizione di ipotesi significa che

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) p_{X'_1, \dots, X'_n}(x_1, \dots, x_n)$$

dove

$$p_{X_1, \dots, X_n}, p_{X'_1, \dots, X'_n} : \prod_{i=1}^n E_i \rightarrow [0, 1]$$

sono le densità congiunte di $(X_1, \dots, X_n)$ e $(X'_1, \dots, X'_n)$ rispettivamente. Usando il risultato precedente sulla caratterizzazione di indipendenza con le densità, la densità di $(X_1, \dots, X_n)$ fattorizza nelle marginali se e solo se fattorizza quella di $(X'_1, \dots, X'_n)$.

Proposition

Siano $X: \Omega \rightarrow E$ e $Y: \Omega \rightarrow F$ variabili aleatorie discrete e indipendenti. Siano $f: E \rightarrow K$ e $g: F \rightarrow H$ con K e H insiemi discreti. Allora, anche le variabili aleatorie discrete $f(X): \Omega \rightarrow K$ e $g(Y): \Omega \rightarrow H$ sono indipendenti.

Proof

Siano $A \in \mathcal{P}(K)$ e $B \in \mathcal{P}(H)$, allora

$$\begin{aligned} \mathbb{P}(f(X) \in A, g(Y) \in B) &= \mathbb{P}(X \in f^{-1}(A), Y \in g^{-1}(B)) \\ &= \mathbb{P}(X \in f^{-1}(A)) \mathbb{P}(Y \in g^{-1}(B)) \\ &= \mathbb{P}(f(X) \in A) \mathbb{P}(g(Y) \in B) \end{aligned}$$

Proposition

Siano $X_1, \dots, X_n$ variabili aleatorie discrete $X_i: \Omega \rightarrow E_i$ indipendenti. Allora per ogni sottoinsieme di indici $I = \{i_1, \dots, i_k\} \subseteq \{1, \dots, n\}$ e $J = \{j_1, \dots, j_h\} \subseteq \{1, \dots, n\}$ tali che $I \cap J = \emptyset$, allora le variabili aleatorie discrete

$$X_I = (X_{i_1}, \dots, X_{i_k}), \quad X_J = (X_{j_1}, \dots, X_{j_h})$$

sono indipendenti.

Proof

Visto che $X_1, \dots, X_n$ abbiamo visto $\forall (x_1, \dots, x_n) \in \prod E_i$ vale

$$\begin{aligned} p_I(x_{i_1}, \dots, x_{i_k}) &= \prod_{l=1}^k p_{i_l}(x_{i_l}) \\ p_J(x_{j_1}, \dots, x_{j_h}) &= \prod_{l=1}^h p_{j_l}(x_{j_l}) \end{aligned}$$

dove p_I è la marginale di X_I e p_J è la marginale di X_J . Indichiamo con $p_{I,J}$ la congiunta di (X_I, X_J) . Allora

$$p_{I,J}(x_{i_1}, \dots, x_{i_k}, x_{j_1}, \dots, x_{j_h}) = \left(\prod_{l=1}^k p_{i_l}(x_{i_l}) \right) \left(\prod_{l=1}^h p_{j_l}(x_{j_l}) \right)$$

Proposition

Siano $X_1, \dots, X_{n+m}$ variabili aleatorie discrete $X_i: \Omega \rightarrow E_i \subseteq \Omega$ indipendenti. Allora, anche le variabili aleatorie discrete

$$\sum_{i=1}^n X_i, \quad \sum_{i=n+1}^{n+m} X_i$$

sono indipendenti.

Proof

La proposizione precedente ci dice che le variabili aleatorie discrete

$$(X_1, \dots, X_n): \Omega \rightarrow \prod_{i=1}^n E_i$$

$$(X_{n+1}, \dots, X_{n+m}): \Omega \rightarrow \prod_{i=n+1}^{n+m} E_i$$

sono indipendenti, concludiamo applicando l'altra proposizione prima con

$$f(X_1, \dots, X_n) = \sum_{i=1}^n x_i$$

$$g(X_{n+1}, \dots, X_{n+m}) = \sum_{j=1}^m x_{n+j}$$

quindi $f(X_1, \dots, X_n)$ e $g(X_{n+1}, \dots, X_{n+m})$ sono indipendenti.

Torniamo all'esempio degli n lanci di probabilità di una moneta con probabilità $p \in [0, 1]$ che esca testa e $1 - p$ che esca croce. Interpretiamolo con le variabili aleatorie. Sia $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno spazio di probabilità discreto di appoggio. Definiamo le variabili aleatorie $X_1, \dots, X_n: \Omega \rightarrow \{0, 1\}$ indipendenti e identicamente distribuite con $X_i \sim \text{Ber}(p)$ per tutte le i , che rappresentano i lanci i -esimi. Si dice identicamente distribuite perché lancio sempre la stessa moneta, e indipendenti perché abbiamo l'assunzione delle prove ripetute indipendenti. Abbiamo studiato la probabilità di avere k successi in n lanci. La variabile aleatoria corrispondente è

$$S_n = \sum_{k=1}^n X_k$$

Allora $\{S_n = k\}$ se e solo se abbiamo k successioni in n lanci. Preso $k \in \{0, \dots, n\}$ ci interessa

$$\begin{aligned} \mathbb{P}(S_n = k) &= \sum_{\substack{v \in \{0,1\}^n \\ v=(v_1, \dots, v_n) \\ \sum_{i=1}^n v_i = k}} \mathbb{P}(X_1 = v_1, \dots, X_n = v_n) \\ &= \sum_{\substack{v \in \{0,1\}^n \\ v=(v_1, \dots, v_n) \\ \sum_{i=1}^n v_i = k}} \left(\prod_{i=1}^n \mathbb{P}(X_i = v_i) \right) \\ &= \sum_{\substack{v \in \{0,1\}^n \\ v=(v_1, \dots, v_n) \\ \sum_{i=1}^n v_i = k}} p^k (1-p)^{n-k} = \binom{n}{k} p^k (1-p)^{n-k} \end{aligned}$$

$\swarrow$ Indipendenza
 $\searrow$ Identicamente distribuite

Quindi abbiamo trovato che $S_n \sim \text{Bin}(n, p)$. Possiamo modellizzare con le variabili aleatorie anche l'estrazione senza reimmersione dall'urna con rosse e blu, ma in questo le $X_1, \dots, X_n$ non sono indipendenti

e identicamente distribuite. Poiché $X_i \sim \text{Ber}(p_i)$ ma p_i dipende da cosa ho estratto prima.

Le variabili aleatorie sono in generale più versatili rispetto che una semplice modellizzazione con spazi di probabilità. Se voglio modificare un esperimento, posso aggiungere variabili aleatorie etc. (lo spazio di probabilità è di appoggio e rimane invariato), mentre con lo spazio di probabilità dovrei creare un nuovo spazio. Se per esempio studio i lanci di un dado equilibrato, e voglio aggiungere un secondo lancio all'esperimento, allora basta aggiungere una variabile aleatoria piuttosto che creare un nuovo spazio di probabilità del tutto. Se voglio studiare la somma di due lanci ci basta considerare la somma della variabile aleatoria. Abbiamo una struttura matematica sulle variabili aleatorie.

Consideriamo uno spazio di probabilità discreto $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ e prendiamo $X: \Omega \rightarrow \mathbb{R}^n$ l'immagine di $X(\Omega) \subseteq \mathbb{R}^n$, è un sottoinsieme discreto di $\mathbb{R}^n$.

$$\mathbb{P}(X \in X(\Omega)) = \mathbb{P}(\Omega) = 1$$

Quindi è inutile specificare ogni volta $X: \Omega \rightarrow E \subseteq \mathbb{R}^n$ con E discreto, quindi scriveremo solo $X: \Omega \rightarrow \mathbb{R}^n$. Sia $p_X: \mathbb{R}^n \rightarrow [0, 1]$ densità discreta di X e notiamo subito che

$$x \in \mathbb{R}^n \setminus X(\Omega)$$

implica che $p_X(x) = 0$. Quindi $p_X > 0$ al più in una quantità numerabile di $x \in \mathbb{R}^n$. Sia ora $g: X(\Omega) \rightarrow \mathbb{R}$. Allora, $g(X) = g \circ X: \Omega \rightarrow \mathbb{R}$ variabile aleatorie discreta, ha densità

$$\begin{aligned} p_{g(X)}(y) &= \mathbb{P}(g(X) = y) = \mathbb{P}(\{\omega \in \Omega \mid g(X(\omega)) = y\}) \\ &= \mathbb{P}(\{\omega \in \Omega \mid \exists x \in \mathbb{R}^n \mid X(\omega) = x \wedge g(x) = y\}) \\ &= \sum_{\substack{x \in X(\Omega) \\ g(x)=y}} p_X(x) = \sum_{\substack{x \in \mathbb{R}^n \\ g(x)=y}} p_X(x) \end{aligned}$$

possiamo estendere il dominio a $\mathbb{R}^n$ perché tanto $p_X > 0$ al più in una quantità numerabile di $x \in \mathbb{R}^n$.

3 Valore atteso o media di variabili aleatorie discrete

La media aritmetica è il baricentro di punti di massa equivalente. Se le masse non sono equivalenti consideriamo la media pesata

$$\sum_{i=1}^n x_i \cdot \frac{m_i}{m}, \quad m = \sum_{i=1}^n m_i$$

notiamo che $p_i = m_i/m \in [0, 1]$ e

$$\sum_{i=1}^n p_i = 1$$

Quindi i $p_1, \dots, p_n$ sono una densità discreta. Da questo ci aspettiamo che la media di una variabile aleatoria $X: \Omega \rightarrow \mathbb{R}^n$ sia data da

$$\sum_{n \in X(\Omega)} x p_X(x)$$

Definizione Valore atteso di variabili aleatorie discrete

Sia $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno spazio di probabilità discreto e $X: \Omega \rightarrow \mathbb{R}$ una variabile aleatoria discreta. Diciamo che X ammette *valore atteso* / *media* se la serie

$$\sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\{\omega\})$$

esiste (finita o infinita). In questo caso chiamiamo valore atteso

$$\mathbb{E}[X] \triangleq \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\{\omega\})$$

Esempio

Sia $\Omega = \mathbb{N}$ e $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ uno spazio di probabilità discreto dove

$$\mathbb{P}(\{n\}) = \frac{c}{n^2}, \quad c = \left(\sum_{n=1}^{\infty} \frac{1}{n^2} \right)^{-1}$$

prendiamo $X: \mathbb{N} \rightarrow \mathbb{N}$ tale che $X(n) = n$. Allora,

$$\begin{aligned} \mathbb{E}[x] &= \sum_{n \in \mathbb{N}} X(n) \cdot \mathbb{P}(\{n\}) = c \sum_{n \in \mathbb{N}} n \cdot \frac{1}{n^2} \\ &= c \sum_{n=1}^{\infty} \frac{1}{n} = +\infty \end{aligned}$$

Dai risultati noti sulle serie numeriche sappiamo che se

$$\sum_{\omega \in \Omega} |X(\omega)| \mathbb{P}(\{\omega\}) < +\infty$$

Allora X ammette valore atteso finito.

Sia $A \in \mathcal{P}(\Omega)$ consideriamo $\chi_A: \Omega \rightarrow \{0, 1\}$. In questo caso,

$$\mathbb{E}[\chi_A] = \sum_{\omega \in \Omega} \chi_A(\omega) \mathbb{P}(\{\omega\}) = \sum_{\omega \in \Omega} \mathbb{P}(\{\omega\}) = \mathbb{P}(A)$$

Quindi nell'interpretazione soggettivista di de Finetti, il valore atteso non è altro che il valore equo da pagare per ottenere la quantità aleatoria X .

In generale il valore atteso o la media non sono necessariamente un valore assunto da X .

Proposition

Sia $p_X: \mathbb{R} \rightarrow [0, 1]$ e tutto il resto TODO. Allora il valore atteso esiste se e solo se

$$\sum_{x \in \mathbb{R}} x p_X(x)$$

esiste. In questo caso,

$$\mathbb{E}[x] = \sum_{x \in \mathbb{R}} x p_X(x)$$

Notiamo che la serie è ben definita poiché $p_X > 0$ al più in una quantità numerabile di $x \in \mathbb{R}$.

Proposition

$\forall x \in X(\Omega)$ definiamo

$$\Omega_x = \{\omega \in \Omega \mid X(\omega) = x\}$$

Abbiamo già visto che $\{\Omega_x\}_{x \in X(\Omega)}$ è una partizione numerabile disgiunta di Ω . Abbiamo

$$\begin{aligned} \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\{\omega\}) &= \sum_{x \in X(\Omega)} \sum_{\omega \in \Omega_x} X(\omega) \mathbb{P}(\{\omega\}) \\ &= \sum_{x \in X(\Omega)} x \sum_{\omega \in \Omega_x} \mathbb{P}(\{\omega\}) \\ &= \sum_{x \in X(\Omega)} x \cdot \mathbb{P}(\Omega_x) \\ &= \sum_{x \in X(\Omega)} x \mathbb{P}(\{\omega \in \Omega \mid X(\omega) = x\}) \\ &= \sum_{x \in X(\Omega)} x \cdot p_X(x) \end{aligned}$$

Allora il primo membro esiste se e solo se l'ultimo membro esiste.

Proposition

Sia $X: \Omega \rightarrow \mathbb{R}^n$ variabile aleatoria discreta e $g: X(\Omega) \rightarrow \mathbb{R}$. Allora, la variabile aleatoria discreta $g(X): \Omega \rightarrow \mathbb{R}$ ammette valore atteso se e solo se la serie

$$\sum_{x \in \mathbb{R}} g(x) p_X(x)$$

esiste. In questo caso,

$$\mathbb{E}[g(x)] = \sum_{x \in \mathbb{R}} g(x) p_X(x)$$

Proof

$\forall x \in X(\Omega)$ definiamo

$$\Omega_x = \{\omega \in \Omega \mid X(\omega) = x\}$$

Abbiamo già visto che $\{\Omega_x\}_{x \in X(\Omega)}$ è una partizione numerabile disgiunta di Ω . Abbiamo

$$\begin{aligned} \sum_{\omega \in \Omega} g(X(\omega)) \mathbb{P}(\{\omega\}) &= \sum_{y \in \mathbb{R}} y p_{g(x)}(y) \\ &= \sum_{\omega \in \Omega} g(X(\omega)) \mathbb{P}(\{\omega\}) \\ &= \sum_{x \in X(\Omega)} \sum_{\omega \in \Omega_x} g(X(\omega)) \mathbb{P}(\{\omega\}) \\ &= \sum_{x \in X(\Omega)} g(x) \sum_{\omega \in \Omega_x} \mathbb{P}(\{\omega\}) \\ &= \sum_{x \in X(\Omega)} g(x) \mathbb{P}(\Omega_x) \\ &= \sum_{x \in X(\Omega)} y(x) p_X(x) \end{aligned}$$

dove al primo passaggio abbiamo usato la proposizione precedente per variabile aleatoria $y = g(x)$.

Possiamo usare questa proposizione in modi modi. Per esempio $(X_1, X_2): \Omega \rightarrow \mathbb{R}^2$ discreto e $g: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ tale che $g(x_1, x_2) = x_1 x_2$ quindi

$$\mathbb{E}[X_1, X_2] = \mathbb{E}[g(X_1, X_2)] = \sum_{(x_1, x_2) \in \mathbb{R}^2} x_1 x_2 p_{X_1, X_2}(x_1, x_2)$$

notiamo che anche nel caso $X: \Omega \rightarrow \mathbb{R}$ discreto X può avere valore atteso infinito ma $g(x)$ può avere valore atteso finito e viceversa.

Proposition

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tali che $\mathbb{E}[X], \mathbb{E}[Y] < +\infty$. Allora,

1. se $X \leq Y$ quasi certamente, allora

$$\mathbb{E}[X] \leq \mathbb{E}[Y]$$

- 2.

$$|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$$

3. se $a, b \in \mathbb{R}$, allora

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

4. se $X \geq 0$ quasi certamente, allora $X = 0$ quasi certamente se e solo se $\mathbb{E}[X] = 0$.
5. se $X = c \in \mathbb{R}$ quasi certamente, allora $\mathbb{E}[X] = c$.
- 6.

$$\mathbb{E}[\mathbb{E}[X]] = \mathbb{E}[X]$$

I punti (1), (2), (3) funzionano anche senza la condizione $\mathbb{E}[X], \mathbb{E}[Y] < +\infty$.

Proposition

$$\mathbb{E}[X] < \infty \iff \mathbb{E}[|X|] < \infty$$

Proof

Lezione del 30 fra le cose aggiunte a posteriori al PDF.

Grazie ad una proposizione di ieri dato $(X_1, \dots, X_n)$ vettore aleatorio discreto con $X_i: \Omega \rightarrow \mathbb{R}$ discreta

e $g: \mathbb{R}^n \rightarrow \mathbb{R}$ allora la variabile discreta $g(X)$ ammette valore atteso finito se e solo se

$$\sum_{\substack{\bar{x}=(x_1, \dots, x_n) \\ \in \mathbb{R}^n}} |g(\bar{x})| p_{X_1, \dots, X_n}(\bar{x}) < +\infty$$

dove $p_{X_1, \dots, X_n}$ è la densità congiunta di $(X_1, \dots, X_n)$. In questo caso,

$$\mathbb{E}[g(X)] = \sum_{\bar{x} \in \mathbb{R}^n} g(\bar{x}) p_{X_1, \dots, X_n}(\bar{x})$$

3.1 Varianza e covarianza

Fissiamo $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ spazio di probabilità discreto e $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete.

Definizione Momenti

- Diciamo che X ammette momento k -esimo finito se

$$\mathbb{E}[|X|^k] < +\infty$$

- Diciamo che X, Y ammettono momento misto finito se

$$\mathbb{E}[|XY|] < +\infty$$

In questi casi chiamiamo $\mathbb{E}[X^k]$ *momento k -esimo di X* e $\mathbb{E}[XY]$ *momento misto di X e Y* .

Proposition

Sia $p_{X,Y}: \mathbb{R}^2 \rightarrow \mathbb{R}$ la congiunta del vettore (X, Y) e $p_X: \mathbb{R} \rightarrow \mathbb{R}$ la densità discreta di X .

1. X ammette momento k -esimo finito se e solo se

$$\sum_{x \in \mathbb{R}} |x|^k p_X(x) < \infty$$

e in tal caso

$$\mathbb{E}[X^k] = \sum_{x \in \mathbb{R}} x^k p_X(x)$$

2. X, Y ammettono momento misto finito se e solo se

$$\sum_{(x,y) \in \mathbb{R}^2} |xy| p_{X,Y}(x, y) < +\infty$$

e in tal caso

$$\mathbb{E}[XY] = \sum_{(x,y) \in \mathbb{R}^2} xy p_{X,Y}(x, y)$$

Proof

Basta applicare la proposizione sulla composizione con $g_1: \mathbb{R} \rightarrow \mathbb{R}$ e $g_2: \mathbb{R}^2 \rightarrow \mathbb{R}$ date da $g_1(x) = x^k$ e $g_2(x, y) = xy$ e ricordare che $\forall Z: \Omega \rightarrow \mathbb{R}$ variabile aleatoria discreta

$$\mathbb{E}[Z] < +\infty \iff \mathbb{E}[|Z|] < +\infty$$

Proposition disuguaglianza di Jensen

Sia $f: \mathbb{R} \rightarrow \mathbb{R}$ una funzione convessa e tale che $f(\mathbb{E}[X]) < \infty$. Allora,

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)]$$

Questa vale più in generale. Questa è una generalizzazione del modulo.

Proof

Per ipotesi $\forall x_0 \in \mathbb{R}, \exists \lambda_0 \in \mathbb{R}$ tale che

$$f(x) \geq g(x_0) + \lambda_0(x - x_0), \quad \forall x \in \mathbb{R}$$

Prendiamo $x_0 = \mathbb{E}[X]$ e x diventa X allora

$$f(X) \geq f(\mathbb{E}[X]) - \lambda_0(X - \mathbb{E}[X])$$

quasi certamente. Facciamo ora il valore atteso di ambo i membri

$$\begin{aligned} \mathbb{E}[f(X)] &\geq \mathbb{E}[f(\mathbb{E}[X]) - \lambda_0(X - \mathbb{E}[X])] \\ \mathbb{E}[f(X)] &\geq \mathbb{E}[f(\mathbb{E}[X])] - \lambda_0 \mathbb{E}[X - \mathbb{E}[X]] \\ \mathbb{E}[f(X)] &\geq \mathbb{E}[f(X)] \end{aligned}$$

Al contrario se la funzione è concava vale il $\leq$.

Proposition Cauchy-Schwarz

Supponiamo che $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$. Allora il vettore aleatorio (X, Y) ammette momento misto finito. In particolare,

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}$$

Proof

Se uno dei due è nullo, per esempio $\mathbb{E}[X^2] = 0$, allora la proposizione è banale in quanto $\mathbb{E}[X^2] = 0$ se e solo se $X^2 = 0$ quasi certamente se e solo se $X = 0$ quasi certamente. Supponiamo quindi che ambo non siano nulli. Partiamo dal caso $\mathbb{E}[XY] > 0$. Definiamo

$$X^* = \frac{X}{\sqrt{\mathbb{E}[X^2]}}, \quad Y^* = \frac{Y}{\sqrt{\mathbb{E}[Y^2]}}$$

Notiamo immediatamente che

$$\begin{aligned} 0 &\leq \mathbb{E}[(X^* - Y^*)^2] = \mathbb{E}[(X^*)^2] + \mathbb{E}[(Y^*)^2] - 2\mathbb{E}[X^*Y^*] \\ &= \frac{\mathbb{E}[X^2]}{\mathbb{E}[X^2]} + \frac{\mathbb{E}[Y^2]}{\mathbb{E}[Y^2]} - 2 \frac{\mathbb{E}[XY]}{\sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}} \\ &= 2 - 2 \frac{\mathbb{E}[XY]}{\sqrt{\mathbb{E}[X^2]\mathbb{E}[Y^2]}} \end{aligned}$$

e quindi segue la tesi. L'altro caso è analogo facendo attenzione al segno. Per la disuguaglianza di Jensen anche $\mathbb{E}[X], \mathbb{E}[Y] < +\infty$, e dunque $\mathbb{E}[X^*], \mathbb{E}[Y^*] < +\infty$.

Grazie alla disuguaglianza di Jensen notiamo che se $\mathbb{E}[|X|^k] < +\infty$ allora $\mathbb{E}[|X|^h] < +\infty$ per $h \in \{1, \dots, k\}$, usando la funzione $X^{k/h}$.

La disuguaglianza di Cauchy-Schwarz che abbiamo visto non è altro che una disuguaglianza per il prodotto scalare di uno spazio L^p

$$L^p(E, \gamma) = \left\{ f: E \rightarrow \mathbb{R} \mid \int_E f^p(x) d\gamma(x) < \infty \right\}$$

che è uno spazio di Banach rispetto alla norma (quozientato rispetto alla relazione di equivalenza

dell'uguaglianza quasi ovunque)

$$\|f\|_p = \left(\int_a^b |f(x)|^p d\gamma(x) \right)^{\frac{1}{p}}, \quad 1 \leq p < \infty$$

nel caso $p = 2$ ha anche un prodotto scalare che induce la norma

$$\langle f, g \rangle_2 = \int_E f(x)g(x) d\gamma(x)$$

(rispetto a qualsiasi misura sigma finita)

Definizione Covarianza e varianza

Siano $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$. Abbiamo

1. *varianza*:

$$\text{Var}(X) \triangleq \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

2. *covarianza*

$$\text{Cov}(X, Y) \triangleq \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Proposition

Siano $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$. Abbiamo

$$\text{Var}(X) = \sum_{x \in \mathbb{R}} (x - \mathbb{E}[X])^2 p_X(x)$$

e

$$\begin{aligned} \text{Cov}(X, Y) &= \sum_{(x,y) \in \mathbb{R}^2} (x - \mathbb{E}[X])(y - \mathbb{E}[Y]) p_{X,Y}(x, y) \\ &= \sum_{(x,y) \in \mathbb{R}^2} xy p_{X,Y}(x, y) - \mathbb{E}[X]\mathbb{E}[Y] \end{aligned}$$

Entrambe sono ben definite poiché per la disuguaglianza di Jensen $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$.

Nella varianza stiamo facendo la media pesata degli scarti quadratici, cioè stiamo misurando la dispersione dalla media. Il motivo per cui mettiamo il quadrato è

1. evitiamo che spostamenti positive e negativi si compensino,
2. amplifichiamo l'effetto di scostamenti molto grossi > 1 , e minimizziamo quelli più vicini,
3. motivo legato alla regolarità della funzione

$$f(c) = \sum_{x \in \mathbb{R}} (x - c)^2 p_X(x)$$

In generale una distanza $f(y) = |c_0 - y|$ non è differenziabile vicino a c_0 , invece $f(y) = |c_0 - y|^2$ lo è.

Proposition Varianza nulla

Sia $X: \Omega \rightarrow \mathbb{R}$ variabile aleatoria discreta tale che $\mathbb{E}[X^2] < \infty$. Se il momento secondo è finito, pure il momento primo lo è. Allora,

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = 0 \iff \exists c \in \mathbb{R} \mid X = c \text{ almost everywhere}$$

In particolare $\mathbb{E}[X] = c$.

Cioè se abbiamo varianza nulla, la variabile coincide con la media quasi ovunque.

Proof Varianza nulla

($\Leftarrow$) Sia $p_X: \mathbb{R} \rightarrow \mathbb{R}$ densità discreta di X , quindi visto che $X = c$ quasi ovunque, allora

$$p_X(c) = 1, \quad p_X(x \neq c) = 0$$

Di conseguenza,

$$\text{Var}(X) = \sum_{x \in \mathbb{R}} (x - \mathbb{E}[X])^2 p_X(x) = (c - \mathbb{E}[X])^2 = 0$$

in quanto $X = c$ quasi certamente.

($\Rightarrow$) Abbiamo

$$0 = \text{Var}(X) = \sum_{x \in \mathbb{R}} (\underbrace{x - \mathbb{E}[X]}_{Z = (X - \mathbb{E}[X])^2})^2 p_X(x)$$

dove Z è una variabile aleatoria non negativa quasi certamente. Di conseguenza, Z è nulla quasi certamente.

Potremmo scegliere la varianza come lo scarto quadratico della distanza da qualsiasi valore. Tuttavia, scegliamo il punto medio in quanto il valore atteso minimizza lo scarto quadratico medio (pesato rispetto alla densità). Questo ce lo mostra la seguente proposizione.

Proposition

Sia $X: \Omega \rightarrow \mathbb{R}$ variabile aleatoria discreta tale che $\mathbb{E}[X^2] < \infty$. Allora,

$$\text{Var}(X) \leq \mathbb{E}[(X - c)^2], \quad \forall c \in \mathbb{R}$$

vale l'uguaglianza se e solo se $c = \mathbb{E}[X]$.

Proof

Abbiamo

$$\begin{aligned} \mathbb{E}[(X - c)^2] &= \mathbb{E}[(X - \mathbb{E}[X] + \mathbb{E}[X] - c)^2] \\ &= \mathbb{E}[(X - \mathbb{E}[X])^2] + 2\mathbb{E}[(X - \mathbb{E}[X])(\mathbb{E}[X] - c)] + \mathbb{E}[(\mathbb{E}[X] - c)^2] \\ &= \text{Var}(X) + 2(\mathbb{E}[X] - c)(\mathbb{E}[X] - \mathbb{E}[X]) + (\mathbb{E}[X] - c)^2 \\ &= \text{Var}(X) + (\mathbb{E}[X] - c)^2 \end{aligned}$$

Otteniamo quindi

$$\mathbb{E}[(X - c)^2] = \text{Var}(X) + (\mathbb{E}[X] - c)^2 \geq \text{Var}(X)$$

Vale l'uguaglianza se e solo se $c = \mathbb{E}[X]$.

Vediamo le proprietà della varianza e della covarianza che discendono dalle proprietà di $\mathbb{E}$.

Proposition Proprietà varianza e covarianza

Siano $n \in \mathbb{N}$ e $X_1, \dots, X_n: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tale che $\mathbb{E}[X_1^2], \dots, \mathbb{E}[X_n^2] < +\infty$. Abbiamo che

1. $\text{Var}(\alpha X + \beta) = \alpha^2 \text{Var}(X)$;
2. $\text{Var}(X) = \text{Cov}(X, X)$;
3. $\text{Cov}(X_1, X_2) = \text{Cov}(X_2, X_1)$;
4. $\forall a, b \in \mathbb{R}$ vale

$$\text{Cov}(\alpha X_1 + \beta X_2, X_3) = \alpha \text{Cov}(X_1, X_3) + \beta \text{Cov}(X_2, X_3)$$

5.

$$\text{Var}\left(\sum_{k=1}^n X_k\right) = \sum_{k=1}^n \text{Var}(X_k) + \sum_{i \neq j} \text{Cov}(X_i, X_j)$$

Al posto di $i \neq j$ possiamo mettere $i < j$ e moltiplicare per 2 il termine in quanto la covarianza è simmetrica.

Proposition

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tale che $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$. Se X o Y quasi certamente costanti, allora

$$\text{Cov}(X, Y) = 0$$

Proof

Supponiamo senza perdita di generalità che $X = c$ quasi certamente. Allora $\mathbb{E}[X] = c$ e quindi $\mathbb{E}[X] - X = 0$ quasi certamente. Abbiamo

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = 0$$

Il viceversa non vale necessariamente, basta ricordare che la covarianza è legata a un prodotto scalare che può essere nullo anche se uno dei vettori non è nullo (usando l'ortogonalità).

Proposition Indipendenza e covarianza

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tali che $\mathbb{E}[|X|], \mathbb{E}[|Y|] < +\infty$. Se X, Y sono indipendenti, allora $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. In particolare, $\text{Cov}(X, Y) = 0$.

Proof

Sappiamo che X, Y sono indipendenti se e solo se la congiunta fattorizza mediante il prodotto delle marginali

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

Quindi

$$\begin{aligned} \mathbb{E}[|XY|] &= \sum_{(x,y) \in \mathbb{R}^2} p_{X,Y}(x, y)|xy| = \sum_{(x,y) \in \mathbb{R}^2} p_X(x)p_Y(y)|xy| \\ &= \sum_{x \in \mathbb{R}} |x|p_X(x) \sum_{y \in \mathbb{R}} |y|p_Y(y) \\ &= \mathbb{E}[|X|]\mathbb{E}[|Y|] < +\infty \end{aligned}$$

Notiamo che usando la disuguaglianza di Cauchy-Schwarz sappiamo che $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$ implica

$\mathbb{E}[|XY|] < +\infty$. Nel caso indipendente, questa proposizione ci dice che basta meno cioè $\mathbb{E}[|X|], \mathbb{E}[|Y|] < +\infty$.

Non è vero che se la covarianza è nulla allora le variabili aleatorie siano indipendenti. La covarianza misura bene la relazione lineare fra variabili aleatorie. Per esempio una relazione quadratica non è letta bene.

Esempio Covarianza nulla ma variabili dipendenti

Sia $X: \Omega \rightarrow \{-1, 0, 1\}$ tale che

$$p_X(-1) = p_X(0) = p_X(1) = \frac{1}{3}$$

cioè $X \sim \text{Unif}(\{-1, 0, 1\})$. Chiaramente $\mathbb{E}[X] = 0$.

Sia ora $Y: \Omega \rightarrow \{0, 1\}$ tale che $Y = X^2$. Chiaramente X e Y sono dipendenti. Abbiamo

$$\begin{aligned} \mathbb{E}[Y] &= \mathbb{E}[X^2] = \sum_{x \in \mathbb{R}} x^2 p_X(x) \\ &= \sum_{x \in \{-1, 0, 1\}} x^2 p_X(x) = \frac{2}{3} \end{aligned}$$

Tuttavia

$$\mathbb{E}[XY] = \sum_{x \in \{-1, 0, 1\}} x^3 p_X(x) = -\frac{1}{3} + 0 + \frac{1}{3}$$

Quindi

$$\mathbb{E}[XY] = 0 = \frac{2}{3} \cdot 0 = \mathbb{E}[Y]\mathbb{E}[X]$$

Equivalentemente $\text{Cov}(X, Y) = 0$ ma X, Y non sono indipendenti.

Corollario

Siano $X_1, \dots, X_n: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tali che $\mathbb{E}[X_1^2], \dots, \mathbb{E}[X_n^2] < +\infty$ e $X_1, \dots, X_n$ indipendenti. Allora,

$$\text{Var}\left(\sum_{k=1}^n X_k\right) = \sum_{k=1}^n \text{Var}(X_k)$$

3.2 Correlazione

Come abbiamo visto, la covarianza misura dipendenze lineari fra variabili aleatorie, ma non ci dà necessariamente informazioni circa dipendenze di altro tipo che potrebbero intercorrere fra variabili aleatorie.

Proposition

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tali che $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$. Allora,

$$|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}$$

Inoltre, se $\text{Var}(X), \text{Var}(Y)$ positive (escludendo quindi il caso di varianza nulla), vale l'uguaglianza se e solo se $\exists a, b \in \mathbb{R}$ tale che $Y = aX + b$ quasi certamente.

Cioè se e solo se esiste una relazione perfettamente lineare fra le due variabili.

Proof

Basta applicare la disuguaglianza di Cauchy-Schwarz alle variabili aleatorie

$$\bar{X} = X - \mathbb{E}[X], \quad \bar{Y} = Y - \mathbb{E}[Y]$$

Per la seconda parte dell'enunciato

($\Leftarrow$) Supponiamo che esistano a, b tali che $Y = aX + b$ quasi certamente. Abbiamo

$$\begin{aligned} \text{Cov}(X, Y) &= \text{Cov}(X, aX + b) = a \text{Cov}(X, X) \\ &= a \text{Var}(X) = \sqrt{a^2 \text{Var}(X)^2} \\ &= \sqrt{\text{Var}(X) a^2 \text{Var}(X)} = \sqrt{\text{Var}(X) \text{Var}(Y)} \end{aligned}$$

($\Rightarrow$) Abbiamo

$$\begin{aligned} \mathbb{E} \left[\left(\frac{\bar{X}}{\sqrt{\mathbb{E}[X^2]}} - \frac{\bar{Y}}{\sqrt{\mathbb{E}[Y^2]}} \right)^2 \right] &= 2 - \frac{2\mathbb{E}[\bar{X}\bar{Y}]}{\sqrt{\mathbb{E}[\bar{X}^2]}\sqrt{\mathbb{E}[\bar{Y}^2]}} \\ &= 2 - \frac{2\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} \quad \left. \vphantom{\mathbb{E} \left[\left(\frac{\bar{X}}{\sqrt{\mathbb{E}[X^2]}} - \frac{\bar{Y}}{\sqrt{\mathbb{E}[Y^2]}} \right)^2 \right]} \right\} \mathbb{E}[\bar{X}^2] = \text{Var}(X) \\ &= 0 \end{aligned}$$

Quindi

$$\left(\frac{\bar{X}}{\sqrt{\mathbb{E}[X^2]}} - \frac{\bar{Y}}{\sqrt{\mathbb{E}[Y^2]}} \right)^2 = 0 \text{ quasi certamente}$$

e quindi

$$\frac{\bar{X}}{\sqrt{\mathbb{E}[X^2]}} = \frac{\bar{Y}}{\sqrt{\mathbb{E}[Y^2]}}$$

e sostituendo otteniamo

$$Y = \frac{\text{Var}(Y)}{\text{Var}(X)}(X - \mathbb{E}[X]) + \mathbb{E}[Y]$$

Quindi vale la tesi con

$$a = \frac{\text{Var}(Y)}{\text{Var}(X)}, \quad b = \mathbb{E}[Y] - \frac{\text{Var}(Y)}{\text{Var}(X)}\mathbb{E}[X]$$

Quindi, covarianza nulla non implica che le variabili non siano indipendenti. Tuttavia, se la covarianza non è nulla, allora sicuramente sono dipendenti.

Definizione Coefficiente di correlazione

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tali che $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$. Definiamo coefficiente di correlazione tra X e Y la quantità

$$\Gamma(X, Y) \triangleq \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

se $\text{Var}(X), \text{Var}(Y) \neq 0$.

Notiamo che $\Gamma \in [-1, 1]$ e $\Gamma(X, Y) = \pm 1$ se e solo se $Y = aX + b$ con $\text{sign}(a) = \pm 1$ e $|a| > 0$.

Proposition

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tale che $p_X = p_Y$ cioè $p_X(z) = p_Y(z)$ per ogni $z \in \mathbb{R}$. Allora X ammette valore atteso finito se e solo se Y ammette valore atteso finito e

$$\mathbb{E}[X] = \mathbb{E}[Y]$$

Proof

Abbiamo

$$\mathbb{E}[X] = \sum_{z \in \mathbb{R}} zp_X(z) = \sum_{z \in \mathbb{R}} zp_Y(z) = \mathbb{E}[Y]$$

3.3 Medie e varianza di distribuzioni note**Proposition** Media della distribuzione geometrica

Sia $X: \Omega \rightarrow \mathbb{N} \subseteq \mathbb{R}$ tale che

$$p_X(n) = p(1-p)^{n-1}$$

Allora il valor medio è

$$\mathbb{E}[X] = \frac{1}{p}$$

Proof Media della distribuzione geometrica

Calcoliamo la media

$$\begin{aligned} \mathbb{E}[X] &= \sum_{x \in \mathbb{R}} xp_X(x) = \sum_{n=1}^{\infty} np(1-p)^{n-1} \\ &= p \sum_{n=1}^{\infty} n(1-p)^{n-1} = p \sum_{n=1}^{\infty} \frac{d}{dp} (-(1-p)^n) \\ &= p \frac{d}{dp} \left(- \sum_{n=1}^{\infty} (1-p)^n \right) = -p \frac{d}{dp} \left(\sum_{n=0}^{\infty} (1-p)^n - 1 \right) \\ &= -p \frac{d}{dp} \left[\frac{1}{p} - 1 \right] = -p \left(\frac{1}{p^2} \right) = \frac{1}{p} \end{aligned}$$

Proposition Varianza della distribuzione geometrica

Sia $X: \Omega \rightarrow \mathbb{N} \subseteq \mathbb{R}$ tale che

$$p_X(n) = p(1-p)^{n-1}$$

Allora la varianza è

$$\text{Var}(X) = \frac{1-p}{p^2}$$

Proof Varianza della distribuzione geometrica

Abbiamo

$$\text{Var}(X) = \mathbb{E}[X]^2 - \mathbb{E}[X^2] = \mathbb{E}[X]^2 - \frac{1}{p^2}$$

Dobbiamo quindi calcolare

$$\begin{aligned}
\mathbb{E}[X]^2 &= \sum_{x \in \mathbb{R}} x^2 p_X(x) = \sum_{n=1}^{\infty} n^2 p(1-p)^{n-1} \\
&= p \sum_{n=1}^{\infty} n^2 (1-p)^{n-1} = p \sum_{n=1}^{\infty} n(n-1+1)(1-p)^{n-1} \\
&= p \sum_{n=1}^{\infty} n(1-p)^{n-1} + p \sum_{n=2}^{\infty} n(n-1)(1-p)^{n-1} \\
&= \frac{1}{p} + p(1-p) \sum_{n=2}^{\infty} n(n-1)(1-p)^{n-2} \\
&= \frac{1}{p} + p(1-p) \sum_{n=2}^{\infty} \frac{d^2}{dp^2} [(1-p)^n] \\
&= \frac{1}{p} + p(1-p) \left[\frac{d^2}{dp^2} \sum_{n=2}^{\infty} (1-p)^n \right] \\
&= \frac{1}{p} + p(1-p) \left\{ \frac{d^2}{dp^2} \left[\left(\sum_{n=0}^{\infty} (1-p)^n \right) - 1 - (1-p) \right] \right\} \\
&= \frac{1}{p} + p(1-p) \frac{d^2}{dp^2} \left(\frac{1}{p} - 1 - (1-p) \right) \\
&= \frac{1}{p} + p(1-p) \frac{2}{p^3} = \frac{2-p}{p^2}
\end{aligned}$$

In conclusione la varianza è

$$\frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}$$

Ricordiamo che $p \in (0, 1]$. Se fosse $p = 0$ non avrebbe senso (non ha senso calcolare la probabilità del primo successo se questo è impossibile). Se $p \rightarrow 1$, allora la varianza tende a zero. Anche questo è coerente in quanto più la probabilità è alta, più il primo successo si concentra sui primi tentativi, e quindi la varianza è vicina a 0. In particolare, se $p = 1$ abbiamo il successo sempre e solo al primo lancio, quindi la varianza è esattamente nulla.

Vediamo ora una proprietà caratterizzante della distribuzione geometrica.

Proposition Assenza di memoria della distribuzione geometrica

Sia $X \sim \text{Geo}(p)$ con $p \in (0, 1]$. Allora $\forall n, m \in \mathbb{N}$

$$\mathbb{P}(X > n + m | X > n) = \mathbb{P}(X > m)$$

Proof Assenza di memoria della distribuzione geometrica

Vediamo una considerazione generale per $h \in \mathbb{N}$

$$\begin{aligned}
\mathbb{P}(X > h) &= 1 - \mathbb{P}(X \leq h) = 1 - \sum_{k=1}^h p(1-p)^{k-1} \\
&= 1 - p \sum_{k=1}^h (1-p)^{k-1} = 1 - p \sum_{k=0}^{h-1} (1-p)^k \\
&= 1 - \cancel{p} \frac{1 - (1-p)^h}{\cancel{p}} = (1-p)^h
\end{aligned}$$

Cioè la probabilità di ottenere il primo successo dopo h lanci è uguale alla probabilità di ottenere h fallimenti nei primi h tentativi. Ma quindi, $\forall n, m \in \mathbb{N}$ vale che

$$\begin{aligned}\mathbb{P}(X > m + n | X > n) &= \frac{\mathbb{P}(\{X < m + n\} \cap \{X > n\})}{\mathbb{P}(X > n)} \\ &= \frac{\mathbb{P}(X > n + m)}{\mathbb{P}(X > n)} \\ &= \frac{(1-p)^{n+m}}{(1-p)^n} = (1-p)^m = \mathbb{P}(X > m)\end{aligned}$$

$\left. \begin{array}{l} \\ \\ \end{array} \right\} \{X > n\} \subseteq \{X > n + m\}$

Vale anche il viceversa

Proposition

Sia $X: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete tale che

1. $\mathbb{P}(X \in \mathbb{N}) = 1$
2. $\forall m, n \in \mathbb{N}, \mathbb{P}(X > n + m | X > n) = \mathbb{P}(X > m)$
3. $\mathbb{P}(X = 1) = p \in (0, 1]$

Allora $X \sim \text{Geo}(p)$.

Proof

Consideriamo per esempio

$$\begin{aligned}\mathbb{P}(X > 2) &= \mathbb{P}(\{X > 2\} \cap \{X > 1\}) = \mathbb{P}(X > 2 | X > 1) \mathbb{P}(X > 1) \\ &= \mathbb{P}(X > 1) \mathbb{P}(X > 1)^2\end{aligned}$$

$\left. \begin{array}{l} \\ \\ \end{array} \right\} \text{Ipotesi (2)}$

Per induzione troviamo che

$$\mathbb{P}(X > n + 1) = \mathbb{P}(X > 1)^{n+1}$$

Supponiamo infatti che valga per n e dimostriamolo per $n + 1$. Abbiamo

$$\begin{aligned}\mathbb{P}(X > n + 1) &= \mathbb{P}(X > n + 1, X > 1) \\ &= \mathbb{P}(X > n + 1 | X > 1) \mathbb{P}(X > 1) \\ &= \mathbb{P}(X > n) \mathbb{P}(X > 1) \\ &= \mathbb{P}(X > 1)^{n+1}\end{aligned}$$

$\left. \begin{array}{l} \\ \\ \end{array} \right\} \begin{array}{l} \text{Ipotesi (2)} \\ \text{Ipotesi induttiva} \end{array}$

Ricordando che per (1) e (3) $\mathbb{P}(X \in \mathbb{N}) = 1$ e $\mathbb{P}(X = 1) = p$. Allora,

$$\mathbb{P}(X > 1) = 1 - \mathbb{P}(X = 1) = 1 - p$$

Abbiamo quindi che

$$\mathbb{P}(X > n) = (1 - p)^n$$

e allora notando che $\{X = n\} = \{X > n - 1\} \setminus \{X > n\}$ abbiamo

$$\begin{aligned}\mathbb{P}(X = n) &= \mathbb{P}(X > n - 1) - \mathbb{P}(X > n) \\ &= (1 - p)^{n-1} - (1 - p)^n = (1 - p)^{n-1}(1 - 1 - p) = p(1 - p)^{n-1}\end{aligned}$$

Quindi, X ha densità discreta

$$p_X(n) = p(1 - p)^{n-1}$$

per tutte le n . Questa determina univocamente la variabile aleatoria e quindi la distribuzione.

Proposition Media della distribuzione geometrica

Sia $X \sim \text{Poiss}(\lambda)$ con $\lambda > 0$ Allora la media è

$$\mathbb{E}[X] = \lambda$$

Proof Media della distribuzione geometrica

Abbiamo la media

$$\begin{aligned}\mathbb{E}[X] &= \sum_{x \in \mathbb{R}} x p_X(x) = \sum_{k=0}^{\infty} k \frac{\lambda^k e^{-\lambda}}{k!} \\ &= e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} \\ &= e^{-\lambda} \lambda \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} \\ &= e^{-\lambda} e^{\lambda} \lambda = \lambda\end{aligned} \quad \left. \begin{array}{l} \downarrow \\ h = k - 1 \end{array} \right\}$$

Proposition Varianza della distribuzione geometrica

Sia $X \sim \text{Poiss}(\lambda)$ con $\lambda > 0$ Allora la media è

$$\text{Var}(X) = \lambda$$

Proof Varianza della distribuzione geometrica

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \lambda^2$$

Quindi ci resta da calcolare

$$\begin{aligned}\mathbb{E}[X^2] &= \sum_{k=0}^{\infty} k^2 e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} (k+1-1) \frac{\lambda^k}{(k-1)!} \\ &= e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!} + e^{-\lambda} \sum_{k=2}^{\infty} (k-1) \frac{\lambda^k}{(k-1)!} \\ &= \lambda + e^{-\lambda} \lambda^2 \sum_{h=0}^{\infty} \frac{\lambda^h}{h!} = \lambda + \lambda^2\end{aligned} \quad \left. \begin{array}{l} \downarrow \\ h = k - 2 \end{array} \right\}$$

E quindi finalmente

$$\text{Var}(X) = \lambda^2 - \lambda - \lambda^2 = \lambda$$

Proposition Media della distribuzione binomiale

Sia $X \sim \text{Bin}(n, p)$ con $n \in \mathbb{N}, p \in [0, 1]$ Allora la media è

$$\mathbb{E}[X] = np$$

Proof Media della distribuzione binomiale

Noi sappiamo che

$$X \sim \sum_{k=1}^n X_k$$

dove $X_1, \dots, X_n$ I. I. D dove

$$X_i \sim \text{Ber}(p), \quad p \in [0, 1]$$

cioè

$$p_{X_i}(0) = 1 - p, \quad p_{X_i}(1) = p$$

Inoltre sappiamo che

$$\mathbb{E}[X_i] = 0 \cdot (1 - p) + 1 \cdot p = p$$

Abbiamo quindi che

$$\begin{aligned} \mathbb{E}[X] &= \mathbb{E}\left[\sum_{k=1}^n X_k\right] = \sum_{k=1}^n \mathbb{E}[X_k] \\ &= \sum_{k=1}^n p = np \end{aligned} \quad \left. \vphantom{\sum_{k=1}^n} \right\} X_k \sim \text{Ber}(p)$$

Proposition Varianza della distribuzione binomiale

Sia $X \sim \text{Bin}(n, p)$ con $n \in \mathbb{N}, p \in [0, 1]$ Allora la varianza è

$$\text{Var}(X) = np(1 - p)$$

Proof Varianza della distribuzione binomiale

Noi sappiamo che

$$X \sim \sum_{k=1}^n X_k$$

dove $X_1, \dots, X_n$ I. I. D dove

$$X_i \sim \text{Ber}(p), \quad p \in [0, 1]$$

cioè

$$p_{X_i}(0) = 1 - p, \quad p_{X_i}(1) = p$$

Inoltre sappiamo che

$$\text{Var}(X_i) = \mathbb{E}[X_i^2] - \mathbb{E}[X_i]^2 = p(1 - p)$$

Abbiamo quindi che

$$\text{Var}(X) = \text{Var}\left(\sum_{k=1}^n X_k\right)$$

La varianza delle somme, dalla definizione con il quadrato, contiene i prodotti misti, ossia le covarianze. Ma le $X_1, \dots, X_n$ sono indipendenti, quindi le covarianze sono nulle, e rimangono solamente la somma delle varianze

$$\text{Var}(X) = \sum_{k=1}^n \text{Var}(X_k) = \sum_{k=1}^n p(1 - p) = np(1 - p)$$

Facciamo una osservazione circa la somma di binomiali.

Proposition

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ tale che $X \sim \text{Bin}(n, p)$ e $Y \sim \text{Bin}(m, p)$ con $n, m \in \mathbb{N}$. Inoltre siano X, Y indipendenti. Allora,

$$X + Y \sim \text{Bin}(n + m, p)$$

Proof

Consideriamo $Z_1, \dots, Z_n, \dots, Z_{n+1}, \dots, Z_{n+m}$ I.I.D tale che $Z_i \sim \text{Ber}(p)$ per $i \in \{1, \dots, n+m\}$. Siano

$$X' = \sum_{k=1}^n Z_k, \quad Y' = \sum_{k=1}^m Z_{n+k}$$

da questo deduciamo che

$$X' + Y' = \sum_{k=1}^{n+m} Z_k \sim \text{Bin}(n + m, p)$$

Ovviamente per definizione X', Y' sono indipendenti e $X' \sim \text{Bin}(n, p) \sim X$ mentre $Y' \sim \text{Bin}(m, p) \sim Y$. Visto che anche X e Y sono indipendenti per ipotesi allora i vettori $(X', Y') \sim (X, Y)$. Infatti,

$$p_{X', Y'}(x, y) = p_{X'}(x)p_{Y'}(y) = p_X(x)p_Y(y) = p_{X, Y}(x, y)$$

Per un teorema fatto in precedenza $\forall f: \mathbb{R}^2 \rightarrow \mathbb{R}$ vale che

$$f(X, Y) \sim f(X', Y')$$

Se prendiamo $f(x, y) = x + y$ otteniamo

$$X + Y \sim X' + Y' \sim \text{Bin}(n + m, p)$$

3.4 Somme di variabili aleatorie

Proposition

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie discrete e sia $p_{X,Y}$ la densità discreta del vettore (X, Y) . Allora definita $Z = X + Y$ anche Z è una variabile aleatorie discreta con densità con densità

$$p_Z(z) = \sum_{x \in \mathbb{R}} p_{X,Y}(x, z - x) = \sum_{y \in \mathbb{R}} p_{X,Y}(z - y, y)$$

In particolare, se X e Y sono indipendenti

$$p_Z(z) = \sum_{x \in \mathbb{R}} p_X(x) p_Y(z - x)$$

con $z \in \mathbb{R}$.

Centra con le convoluzioni.

Proof

Notiamo che $X(\Omega), Z(\Omega)$ e $Y(\Omega)$ sono sottoinsiemi discreti di $\mathbb{R}$. Quindi, $\forall z \in Z(\Omega)$ vale che

$$\begin{aligned} \mathbb{P}(Z = z) &= \mathbb{P}(X + Y = z) = \mathbb{P}\left(\bigcup_{x \in X(\Omega)} \{X + Y = z, X = x\}\right) \\ &= \sum_{x \in X(\Omega)} \mathbb{P}(Y + x = z | X = x) \mathbb{P}(X = x) \\ &= \sum_{x \in X(\Omega)} p_{X,Y}(x, z - x) \end{aligned} \quad \left. \begin{array}{l} \\ \\ \end{array} \right\} \text{Disgiunti al variare di } x$$

L'altra uguaglianza si trova in modo analogo, scomponendo $Y(\Omega)$ anziché $X(\Omega)$.

Corollario

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ indipendenti tale che $X \sim \text{Poiss}(\lambda)$ e $Y \sim \text{Poiss}(\mu)$ con $\lambda, \mu > 0$. Allora,

$$Z = X + Y \sim \text{Poiss}(\lambda + \mu)$$

Proof

Notiamo che il supporto di X, Y e Z è $\mathbb{N} \cup \{0\}$. Quindi anche Z è una variabile aleatoria discreta e per il teorema precedente $\forall z \in \mathbb{N} \cup \{0\}$

$$\begin{aligned} p_Z(z) &= \sum_{x=0}^{\infty} p_X(x) p_Y(z - x) = \sum_{n=0}^z \frac{\lambda^n e^{-\lambda}}{n!} \cdot \frac{\mu^{z-n} e^{-\mu}}{(z-n)!} \\ &= e^{-(\lambda+\mu)} \sum_{n=0}^z \frac{\lambda^n \mu^{z-n}}{n! (z-n)!} \cdot \frac{z!}{z!} \\ &= \frac{e^{-(\lambda+\mu)}}{z!} \sum_{n=0}^z \binom{z}{n} \lambda^n \mu^{z-n} \\ &= \frac{e^{-(\lambda+\mu)}}{z!} (\lambda + \mu)^z \end{aligned} \quad \left. \begin{array}{l} \\ \\ \end{array} \right\} \text{Binomio Newton}$$

Notando che $p_Y(z - x) = 0$ se $x > z$ facciamo andare la serie fino a z al posto che ∞ . Quindi p_Z è la densità di una Poisson di parametro $\mu + \lambda$. Visto che la densità determina univocamente la

legge otteniamo la tesi.

4 Spazi di probabilità generali

Vogliamo generalizzare la nostra nozione di spazio di probabilità al caso Ω non discreto, e in seguito la nozione di variabili aleatorie. Consideriamo la misura di Lebesgue sull'intervallo $[0, 1]$, cioè $\mu((a, b)) = b - a$ con $0 < a < b < 1$. Visto che abbiamo il problema degli insiemi non misurabili, piuttosto che cambiare la misura andiamo a cambiare la σ -algebra, e non consideriamo più quella delle parti.

Definizione σ -algebra

Sia $\Phi \subseteq \mathcal{P}(X)$. Diciamo che Φ è una σ -algebra se

1. *chiusura rispetto ai complementi*: se $A \in \Phi$, allora $X \setminus A \in \Phi$;
2. *chiusura rispetto alle unioni numerabili*: se $\{A_n\}_{n \in \mathbb{N}} \subseteq \Phi$, allora

$$\bigcup_{n=1}^{\infty} A_n \in \Phi$$

3. $\emptyset \in \Phi$.

Se Φ' è un'altra σ -algebra allora $\Phi' \subseteq \mathcal{P}(\Omega)$. Se Φ è una σ -algebra, allora è un'algebra (cioè solo unione finita). Le due nozioni coincidono per forza di cose se $|\Omega| < +\infty$. Abbiamo anche la chiusura rispetto alle intersezioni numerabili.

Proposition

Sia $\Omega \neq \emptyset$ se I insieme di indici non necessariamente numerabile. Sia

$$\{\Phi_t\}_{t \in I}$$

una famiglia di σ -algebra di Ω . Allora, la famiglia

$$\bigcap_{t \in I} \Phi_t$$

è una σ -algebra su Ω .

Proof

Per esercizio.

Proposition

Non vale lo stesso per l'unione.

Esercizio

Per esercizio trovare un controesempio, anche in uno spazio finito.

Proposition

Sia $\Omega \neq \emptyset$ e sia $\Phi \subseteq \mathcal{P}(\Omega)$ una famiglia di sottoinsiemi. Allora esiste sempre la più piccola σ -algebra Φ' di Ω che contiene Φ . Cioè se E è un'altra tale σ -algebra, $\Phi' \subseteq E$.

Indichiamo la σ -algebra generata da I come $\mathcal{F} = \sigma(I)$.

Proof

Consideriamo l'insieme di tutte le tali σ -algebre

$$\tilde{\Lambda} \triangleq \{\mathcal{F} \text{ } \sigma\text{-algebra su } \Omega \mid I \subseteq \mathcal{F}\}$$

Chiaramente $\mathcal{P}(\Omega) \in \tilde{\Lambda}$, non è vuota. Di conseguenza possiamo definire

$$\sigma(I) = \bigcap_{\mathcal{F} \in \tilde{\Lambda}} \mathcal{F}$$

Se Ω è discreto, allora preso

$$I = \{\{\omega\} \mid \omega \in \Omega\}$$

abbiamo che $\sigma(I) = \mathcal{P}(\Omega)$.

La σ -algebra di Borel è generata dalla topologia. In generale questa è più grande della topologia perché non contiene soltanto gli aperti, bensì pure i chiusi e altri ancora.

Proposition σ -algebra di Borel di $\mathbb{R}^n$

Sia $n \in \mathbb{N}$ e consideriamo le famiglie

$$\begin{aligned} J_1 &= \{I = (a_1, b_1) \times \cdots \times (a_n, b_n) \mid a_1 \leq b_1, \dots, a_n \leq b_n\} \\ J_2 &= \{(-\infty, \bar{x}] = (-\infty, x_1] \times \cdots \times (-\infty, x_n] \mid \bar{x} = (x_1, \dots, x_n)\} \\ J_3 &= \{I = (a_1, b_1] \times \cdots \times (a_n, b_n] \mid a_1 \leq b_1, \dots, a_n \leq b_n\} \\ J_4 &= \{I = [a_1, b_1) \times \cdots \times [a_n, b_n) \mid a_1 \leq b_1, \dots, a_n \leq b_n\} \end{aligned}$$

Allora,

$$\sigma(J_1) = \sigma(J_2) = \sigma(J_3) = \sigma(J_4)$$

Famiglia	Topologia generata	σ -algebra generata	Interpretazione
J_1	topologia euclidea classica di $\mathbb{R}^n$	$\sigma(J_1) = \mathbb{B}(\mathbb{R}^n)$	rettangoli aperti; nozione standard di continuità
J_2	topologia generata dagli ortanti inferiori $(-\infty, \bar{x}]$	$\sigma(J_2) = \mathbb{B}(\mathbb{R}^n)$	semirette/ortanti inferiori; naturale per la semicontinuità superiore (coordinata per coordinata)
J_3	topologia dei rettangoli semiaperti $(a_1, b_1] \times \cdots \times (a_n, b_n]$	$\sigma(J_3) = \mathbb{B}(\mathbb{R}^n)$	versione “destra-chiusa” dei rettangoli elementari; analoga alla topologia limite superiore
J_4	topologia dei rettangoli semiaperti $[a_1, b_1) \times \cdots \times [a_n, b_n)$	$\sigma(J_4) = \mathbb{B}(\mathbb{R}^n)$	versione “sinistra-chiusa” dei rettangoli elementari; analoga alla topologia di Sorgenfrey

$$\sigma(J_1) = \sigma(J_2) = \sigma(J_3) = \sigma(J_4) = \mathbb{B}(\mathbb{R}^n)$$

Definizione Spazio di probabilità generale

Sia $\Omega \neq \emptyset$ e $\mathcal{F}$ una σ -algebra su Ω . Sia $\mathbb{P}: \mathcal{F} \rightarrow [0, 1]$ una misura. Chiamiamo *spazio di probabilità* la terna $(\Omega, \mathcal{F}, \mathbb{P})$.

Definizione Misura di probabilità discreta

Dato uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ diciamo che $\mathbb{P}$ è una *misura di probabilità discreta* se $\exists \Omega_0 \subseteq \Omega$ tale che $\mathbb{P}(\Omega_0) = 1$.

Vediamo che questa sia effettivamente una generalizzazione, e che questa definizione è coerente nel caso $\Omega = \mathbb{R}^n$ e $\mathcal{F} = \mathcal{B}(\mathbb{R}^n)$.

Se $\mathbb{P}$ è misura di probabilità discreta su $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ allora esiste $S \subseteq \mathbb{R}^n$ discreto tale che $\mathbb{P}(S) = 1$. Prima di tutto notiamo che $\mathcal{P}(S) \supseteq \mathcal{B}(\mathbb{R}^n)$. Infatti, preso $\bar{s} \in S$ vale che

$$\{\bar{s}\} = (-\infty, \bar{s}] \cap [\bar{s}, +\infty) \in \mathcal{B}(\mathbb{R}^n)$$

Quindi $\forall \bar{s} \in S, \{\bar{s}\} \subseteq \mathcal{B}(\mathbb{R}^n)$. Quindi $\mathcal{P}(S)$ è generata dalle unioni numerabili di $\{\bar{s}\}$. Allora, per la definizione di σ -algebra, $\mathcal{P}(S) \supseteq \mathcal{B}(\mathbb{R}^n)$. Da questo deduciamo che possiamo immergere lo spazio di probabilità discreto $(S, \mathcal{P}(S), \mathbb{P}_S)$ nello spazio generale $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \mathbb{P})$ dove

$$\mathbb{P}_S: \mathcal{P}(S) \rightarrow [0, 1]$$

data dalla restrizione $\mathbb{P}_S = \mathbb{P}|_{\mathcal{P}(S)}$. Ovviamente da questo deduciamo anche che possiamo definire una densità discreta $p: \mathbb{R}^n \rightarrow [0, 1]$ tale che

$$p(\bar{s}) = \mathbb{P}(\{\bar{s}\}), \quad \forall \bar{s} \in S$$

e

$$p(\bar{x}) = 0, \quad \forall \bar{x} \in \mathbb{R}^n \setminus S$$

Vale ancora la corrispondenza biunivoca fra quest'ultime. Quindi una misura di probabilità discreta rimane univocamente determinata dal valore che assume sui singoletti. Nel caso generale, vale una proprietà analoga?

Lemma

Sia $(\Omega, \mathcal{F})$ uno spazio misurabile. Sia J famiglia di sottoinsiemi di Ω tale che $J \subseteq \mathcal{F}$ è chiusa per intersezioni finite e $\sigma(J) = \mathcal{F}$. Se $\mathbb{P}_1$ e $\mathbb{P}_2$ sono misure di probabilità su $(\Omega, \mathcal{F})$ tale che

$$\mathbb{P}_1(A) = \mathbb{P}_2(A), \quad \forall A \in J$$

Allora, $\mathbb{P}_1 = \mathbb{P}_2$.

Quindi se due misure coincidono su un insieme che genera la σ -algebra e sono chiuse per intersezione, allora coincidono.

Notiamo che nel caso Ω discreto l'abbiamo dimostrato direttamente con $J = \{\{\omega\} | \omega \in \Omega\}$, questo lemma è una versione più generale.

Teorema Teorema di Caratheodory

Sia $\Omega \neq \emptyset$ e $\mathcal{F}$ una σ -algebra su Ω , $J \subseteq \mathcal{F}$ algera di Ω tale che $\sigma(J) = \mathcal{F}$. Sia $\mathbb{P}: J \rightarrow [0, 1]$ una funzione tale che

1. $\mathbb{P}(\Omega) = 1$;

2. $\forall \{A_n\}_{n \in \mathbb{N}} \subseteq J$ tale che $A_i \cap A_j = \emptyset$ per $i \neq j$ e

$$\bigcap_{n=1}^{\infty} A_n \in J$$

vale

$$\mathbb{P}\left(\bigcap_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

Allora, $\exists! \bar{\mathbb{P}}: \mathcal{F} \rightarrow [0, 1]$ misura di probabilità su $(\Omega, \mathcal{F})$ che estende $\mathbb{P}$.

Questo è esattamente come quando abbiamo detto che la densità discreta sui singoletti definisce la probabilità.

Notiamo che le semirette $(-\infty, \bar{x}]$ con $\bar{x} \in \mathbb{R}^n$ sono chiuse per intersezione, quindi se $\mathbb{P}_1 = \mathbb{P}_2$ sono misure di probabilità su $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ che coincidono su ogni $(-\infty, \bar{x}]$ allora $\mathbb{P}_1 = \mathbb{P}_2$. Tuttavia, le semirette non sono una algebra (in quanto il complemento non è della stessa forma), quindi se ho una funzione definita solo sulle semirette, non è detto che possa venire estesa ad una misura di probabilità su $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$.

Rivediamo alcuni nostri esempi in questo contesto più generale.

Consideriamo la misura di Lebesgue su $[0, 1]$. Prendiamo quindi $\Omega = [0, 1]$ e $\mathcal{F} = \mathcal{B}([0, 1])$ e consideriamo la funzione $\mathbb{P}$ definita da

$$\mathbb{P}((a, b]) = b - a, \forall 0 \leq a < b \leq 1$$

Vogliamo usare il teorema di Caratheodory per definire una misura di probabilità su $\mathcal{B}([0, 1])$ estendendo $\mathbb{P}$. Per fare ciò ci serve un'altra J , quale prendiamo? Prendiamo J come la famiglia degli insiemi dati dall'unione finita di intervalli disgiunti $(a, b]$

$$J = \left\{ A \subseteq [0, 1] \mid A = \bigcup_{i=1}^n (a_i, b_i], a_1 \leq b_1 \leq a_2 \leq \dots \leq b_n \right\}$$

Chiaramente anche gli intervalli aperti generano $\mathcal{B}([0, 1])$ quindi pure questi lo generano. Per dimostrare che questa è una algebra basta ricordare che un'unione finita di intervalli si può sempre riscrivere come unione finita di intervalli disgiunti. Consideriamo $\mathbb{P}: J \rightarrow [0, 1]$ tale che

$$\mathbb{P}(A) = \sum_{i=1}^n b_i - a_i, \quad A = \bigcup_{i=1}^n (a_i, b_i], a_1 \leq b_1 \leq a_2 \leq \dots \leq b_n$$

Possiamo applicare il teorema di Caratheodory e quindi esiste una unica misura di probabilità su $\mathcal{B}([0, 1])$ che estende. Nota: per ottenere proprio la misura di Lebesgue su $[0, 1]$ bisogna considerare la misura sulla σ -algebra di Borel completata con gli insiemi di misura nulla.

Per l'esempio dei lanci di moneta con peso p avevamo considerato $\Omega = \{0, 1\}^N$, gli eventi $E = \mathcal{P}(E)$ e

$$\mathbb{P}(\{\omega\}) = p^{\sum \omega_i \omega_i} (1 - p)^{N - \sum \omega_i}$$

con $\omega = (\omega_1, \dots, \omega_n) \in \{0, 1\}^N$. Vogliamo ora modellizzare il caso degli infiniti lanci di monete. Vorremmo che troncando la probabilità ad un certo N , ritroviamo la probabilità classica. Consideriamo quindi $\Omega = \{0, 1\}^{\mathbb{N}}$ che non è numerabile. Dopo vediamo che σ -algebra mettere. Vogliamo una misura di probabilità che ristretta ad N lanci si comporti come il caso discreto. Fissato $n \in \mathbb{N}$ e $\bar{x}(x_1, \dots, x_n) \in \{0, 1\}^n$ (risultati dei lanci)

$$C_{n, \bar{x}} \triangleq \{\omega = \{\omega_n\}_{n \in \mathbb{N}} \in \{0, 1\}^{\mathbb{N}} \mid \omega_1 = x_1, \dots, \omega_n = x_n\}$$

Vogliamo quindi che

$$\mathbb{P}(C_{n, \bar{x}}) = p^{\sum \omega_i \omega_i} (1 - p)^{N - \sum \omega_i}$$

Stiamo quindi prendendo la famiglia di tutte le successioni vincolando i primi n elementi, che non è numerabile. In generale quando abbiamo una ipersuperficie e vincoliamo delle variabili lanciando variare le altre, otteniamo un cilindro. I $C_{n,\bar{x}}$ definiscono una famiglia $\bar{\mathcal{J}}$ chiusa per intersezioni, quindi per il lemma che abbiamo visto se esiste una misura di probabilità $\mathbb{P}$ su $\sigma(\bar{\mathcal{J}})$ che verifica la condizione, allora è unica. In verità, usando Caratheodory e lavorando sull'algebra generata da $\bar{\mathcal{J}}$ si dimostrasse esiste questa misura di probabilità.

La famiglia $\sigma(\bar{\mathcal{J}})$ è chiamata la σ -algebra dei cilindri. Su spazi buoni (separabili) è equivalente alla σ -algebra di Borel.

4.1 Funzione di ripartizione o distribuzione

Definizione Funzione di ripartizione

Sia μ misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Chiamiamo *funzione di ripartizione di μ o associata a μ* la funzione

$$F_\mu: \mathbb{R} \rightarrow [0, 1]$$

definita da

$$F_\mu(x) \triangleq \mu((-\infty, x]), \quad \forall x \in \mathbb{R}$$

Per un lemma precedente, la funzione di ripartizione determina univocamente la misura. Quindi, se γ è un'altra misura sullo stesso spazio con la stessa funzione di ripartizione, allora $\gamma = \mu$. Questo è dato dal fatto che le semirette generano $\mathcal{B}(\mathbb{R})$ e sono chiusi per intersezione finita.

Proposition Proprietà della funzioni di ripartizione

Sia μ misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e F_μ la sua funzione di ripartizione. Allora:

1. F_μ è monotona non decrescente;
2. F_μ è continua da destra;
- 3.

$$\lim_{x \rightarrow \infty} F_\mu(x) = 1, \quad \lim_{x \rightarrow -\infty} F_\mu(x) = 0$$

Proof Proprietà della funzioni di ripartizione

1. Siano $x, y \in \mathbb{R} \mid x \leq y$. Allora,

$$F_\mu(x) = \mu((-\infty, x]) \leq \mu((-\infty, y]) = F_\mu(y)$$

per la monotonia della misura (inclusione).

2. Fissato $x_0 \in \mathbb{R}$, per ogni $\varepsilon > 0$ troviamo $\delta(x_0, \varepsilon)$ tale che

$$x - x_0 < \delta \implies F(x) - F(x_0) \leq \varepsilon$$

Abbiamo quindi

$$\begin{aligned} F_\mu(x) - F_\mu(x_0) &= \mu((-\infty, x]) - \mu((-\infty, x_0]) \\ &= \mu((x_0, x]) \leq \mu((x_0, x_0 + \delta]) \end{aligned}$$

in quanto $x < x_0 + \delta$. Consideriamo la successione di insiemi

$$\left(x_0, x_0 + \frac{1}{n}\right] \downarrow \emptyset$$

Quindi per la continuità dall'alto di μ , vale che

$$\lim_n \mu \left(\left(x_0, x_0 + \frac{1}{n}\right] \right) = 0$$

Quindi, fissato $\varepsilon > 0$ esiste $n_0 \in \mathbb{N}$ tale che

$$\mu\left(\left(x_0, x_0 + \frac{1}{n}\right]\right) < \varepsilon, \quad \forall n > n_0$$

Prendendo quindi $\delta = 1/n_0$ da destra otteniamo che

$$F(x) - F(x_0) \leq \mu((x_0, x_0 + \delta]) \leq \varepsilon, \quad \forall x \in \mathbb{R} \mid x - x_0 < \delta$$

3. Mostriamo che il limite tende a 1. Consideriamo la famiglia di eventi

$$\{(-\infty, n]\}_{n \in \mathbb{N}} \uparrow \mathbb{R}$$

Quindi, per la continuità dal basso della misura,

$$\lim_n \mu((-\infty, n]) = 1$$

Da questo, fissato $\varepsilon > 0$, $\exists n_0 \in \mathbb{N}$ tale che

$$1 - \mu((-\infty, n]) \leq \varepsilon, \quad \forall n > n_0$$

Allora preso $\delta = n_0 + 1$ vale che

$$1 - F(x) = 1 - \mu((-\infty, x]) \leq 1 - \mu((-\infty, \delta]) \leq \varepsilon, \quad \forall x > \delta$$

L'altro limite è analogo (compito).

Se μ è misura discreta su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, allora esiste $D \subseteq \mathbb{R}$ discreto, prendendo quello minimale per comodità, tale che $\mu(D) = 1$. Visto che abbiamo preso quello minimale

$$\mu(\{x\}) =: p(x) > 0 \iff x \in D$$

Quindi

$$F_\mu(x) = \sum_{\substack{y \in D \\ y \leq x}} p(y) = \sum_{\substack{y \in D \\ y \leq x}} \mu(\{y\})$$

Nel caso discreto la funzione di ripartizione sarà della forma a scala. Tale funzione può tendere asintoticamente a 1 oppure direttamente assumere il valore 1 dopo un certo punto, come per esempio la bernoulli o la poisson. Abbiamo un risultato generale.

Proposition

Sia μ misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e F_μ la sua funzione di ripartizione. Allora, $\forall x, y \in \mathbb{R}$ con $x \leq y$ vale:

$$1. \mu((x, y]) = F(y) - F(x);$$

$$2. \mu(x, y) = F(y^-) - F(x) \text{ dove}$$

$$F(y^-) = \lim_{z \rightarrow y^-} F(z)$$

$$3. \mu[x, y) = F(y^-) - F(x^-) \text{ dove}$$

$$F(y^-) = \lim_{z \rightarrow y^-} F(z), \quad F(x^-) = \lim_{z \rightarrow x^-} F(z)$$

$$4. \mu[x, y] = F(x) - F(x^-) \text{ dove}$$

$$F(x^-) = \lim_{z \rightarrow x^-} F(z)$$

$$5. \mu(\{x\}) = F(x) - F(x^-) \text{ dove}$$

$$F(x^-) = \lim_{z \rightarrow x^-} F(z)$$

Proof

Dimostriamo solo la (2) e il (5).

1. Abbiamo

$$\begin{aligned}
\mu((x, y)) &= \mu((-\infty, y)) - \mu((-\infty, x]) \\
&= \lim_n \mu((-\infty, y - 1/n]) - \mu((-\infty, x]) \\
&= \lim_n F\left(y - \frac{1}{n}\right) - F(x) = F(y^-) - F(x)
\end{aligned}$$

2. Abbiamo

$$\begin{aligned}
\mu(\{x\}) &= \mu((-\infty, x]) - \mu((-\infty, x)) \\
&= F(x) - \lim_n \mu((-\infty, x - 1/n]) \\
&= F(x) - F(x^-)
\end{aligned}$$

Si dice funzione di Càdlàg se il limite da sinistra esiste e la funzione è continua a destra.

Corollario

Dalla (5) notiamo che $\mu(\{x\}) > 0$ se e solo se F_μ è discontinua in x e ed è uguale a zero se e solo se F_μ è continua.

In quanto, quando μ è discreta allora F_μ è una funzione a scala, e quindi discontinua. Se F_μ è continua allora μ non è discreta, cioè non esiste D discreto tale che $\mu(D) = 1$.

Nota

F_μ discontinua non implica μ discreta. Controesempio: sia μ su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e prendiamo $\mu((a, b)) = b - a$ per $0 \leq a < b < 1/2$ e $\mu(\{1/2\}) = 1/2$ e

$$\mu(I) = \mu(I \cap [0, 1/2])$$


Quindi

$$\mu([0, 1/2]) = \mu([0, 1/2]) + \mu(\{1/2\}) = \frac{1}{2} - 0 + \frac{1}{2} = 1$$

che va bene. La funzione di ripartizione è definita da

$$F_\mu(x) = \mu((-\infty, x]) = \begin{cases} \mu((-\infty, x] \cap [0, 1/2]) = \mu(\emptyset) = 0 & x \leq 0 \\ \mu((-\infty, x] \cap [0, 1/2]) = \mu([0, x]) = x & 0 \leq x < \frac{1}{2} \\ \mu((-\infty, x] \cap [0, 1/2]) = \mu([0, 1/2]) = 1 & x \geq \frac{1}{2} \end{cases}$$

F_μ è discontinua ma $\forall a, b \in (0, 1/2)$ tale che $a < b$ vale $\mu((a, b)) > 0$ quindi il supporto di μ è tutto $[0, 1/2]$ che non è discreto.



4.2 Eventi impossibili e densità continue

Abbiamo visto che data una misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e F_μ la sua funzione di ripartizione se $F_\mu: \mathbb{R} \rightarrow [0, 1]$ è continua allora

$$\mu(\{x\}) = 0, \quad \forall x \in \mathbb{R}$$

A differenza del caso discreto, la nozione di evento impossibile è più delicata. Per esempio, se vogliamo studiare la durata della vita di un macchinario, non siamo interessati a calcolare la probabilità che smetta di funzionare esattamente ad un certo istante. Siamo piuttosto interessati a misurare la probabilità che il macchinario funzioni per un certo intervallo temporale.

Definizione Misure assolutamente continue

Sia μ misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e F_μ la sua funzione di ripartizione. Diciamo che μ è *assolutamente continua rispetto a Lebesgue* se $\exists f: \mathbb{R} \rightarrow [0, +\infty]$ tale che valgono una delle seguenti due condizioni equivalenti:

1.

$$\mu((a, b)) = \int_a^b f(x) dx, \quad \forall a, b \in \mathbb{R} \mid a < b$$

$$F_\mu(x) = \int_{-\infty}^x f(y) dy, \quad \forall x \in \mathbb{R}$$

Le due condizioni sono equivalenti in quanto $\mathcal{B}(\mathbb{R})$ è generata sia dalle semirette che dagli intervalli. Queste sono anche equivalenti a

$$\mu(A) = \int_A f(x) dx, \quad \forall A \in \mathcal{B}(\mathbb{R})$$

Inoltre, f è unica a meno di insiemi di misura nulla rispetto a Lebesgue. Dal punto di vista della teoria della misura stiamo dicendo che

$$\int_A \mu(x) = \mu(A) = \int_A f(x) dx$$

con abuso di notazioni

$$f(x) = \frac{d\mu(x)}{dx}$$

$f(x)$ è chiamata derivata di Radon-Nikodym di μ rispetto alla misura di Lebesgue. Chiaramente questo è solo un senso che non ha senso puntualmente, è solo un simbolo poiché la relazione è rigorosa solo nel senso integrale.

Definizione

Nelle notazioni del teorema precedente chiamiamo f *densità di μ* e la indichiamo con f_μ .

Visto che la funzione di ripartizione determina univocamente la misura di probabilità, allora anche la densità la determina univocamente. Cioè, se μ e γ sono misure di probabilità assolutamente continue con densità f_μ e f_γ , allora $f_\mu = f_\gamma$ quasi ovunque se e solo se $\mu = \gamma$.

Proposition Proprietà delle densità

Sia μ una misura di probabilità assolutamente continua con funzione di ripartizione F_μ e densità f_μ . Allora,

1. $f_\mu \geq 0$ quasi ovunque;
2. f_μ è integrabile rispetto a Lebesgue;

3.

$$\int -\infty d + \infty f_n(x) d\mu = 1$$

4. F_μ è continua.

Proof

Le proposizioni (1) e (2) seguono dal fatto che

$$\int_a^b f(x) dx = \mu((a, b)) \in [0, 1]$$

Per la (3), per definizione

$$\int_{-\infty}^{+\infty} f_\mu(y) dy = \lim_{x \rightarrow \infty} \int_{-\infty}^x f_\mu(y) dy = \lim_{x \rightarrow \infty} F_\mu(x) = 1$$

La (4) segue dal teorema fondamentale del calcolo: visto che f è integrabile su tutto $\mathbb{R}$ e

$$F(x) = \int_{-\infty}^x f(y) dy$$

Per le proprietà base dell'integrazione F_μ è continua.

Teorema

Sia $f: \mathbb{R} \rightarrow [0, +\infty)$ una densità, cioè è integrabile e

$$\int_{\mathbb{R}} f(x) dx = 1$$

Allora, $\exists! \mu$ misura di probabilità assolutamente continua su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tale che $f_\mu = f$.

Proof

Consideriamo la funzione

$$F(x) = \int_{-\infty}^x f(y) dy$$

Notiamo che:

1. $F: \mathbb{R} \rightarrow [0, 1]$ continua e quindi continua da destra
2. visto che $f \geq 0$ quasi ovunque, allora F è monotona non decrescente.
- 3.

$$\lim_{x \rightarrow \infty} F(x) = \int_{-\infty}^{\infty} f(x) dx = 1$$

4.

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{x \rightarrow -\infty} \int_{-\infty}^x f(y) dy = 0$$

Quindi, per uno degli ultimi teoremi, esiste unica μ misura di probabilità tale che $F_\mu = F$. Ma

quindi,

$$F_\mu(x) = F(x) = \int_{-\infty}^x f(y) dy, \quad \forall x \in \mathbb{R}$$

quindi per definizione di misura di probabilità assolutamente continua μ è assolutamente continua e $f_\mu = f$.

Dalla definizione di assoluta continuità di una misura di probabilità μ , abbiamo che

$$\mu((a, b)) = \int_a^b f_\mu(x) dx$$

è l'area sottesa da f_μ . Ciò è analogo a quando nel caso discreto facevamo la somma discreta. Cioè per esempio, la probabilità che qualcosa sia fra 2 e 5 è la somma delle probabilità che sia 2, 3, 4, 5 come se fossero degli istogrammi.

Se γ e μ sono discrete con densità ρ_γ, ρ_μ allora

$$\mu = \gamma \iff \rho_\gamma = \rho_\mu$$

Se invece γ e μ sono assolutamente continue con densità f_γ e f_μ allora

$$\mu = \gamma \iff f_\gamma = f_\mu$$

quasi ovunque. Dunque, per definire una misura di probabilità su $\mathbb{R}$ ci basta definire una funzione di ripartizione, oppure una densità o una densità discreta.

Esempio Distribuzione esponenziale

Consideriamo la funzione

$$f(x) = \lambda e^{-\lambda x} \chi_{[0, +\infty)}(x)$$

Mostriamo che è una densità. Abbiamo che

$$\int_{\mathbb{R}} f(x) dx = [-e^{-\lambda x} \chi_{[0, +\infty)}(x)]_{-\infty}^{\infty} = [-e^{-\lambda x}]_0^{\infty} = 1$$

Quindi, f è una densità.

La misura di probabilità che ha come densità μ si chiama esponenziale di parametro λ , e la indichiamo con

$$\mu = \exp(\lambda), \quad \lambda > 0$$

Questa distribuzione è spesso usata per modellizzare il tempo di vita di un macchinario.

In questo caso la coda della misura di probabilità è data da

$$\begin{aligned} \mu((x, +\infty)) &= 1 - \mu((-\infty, x]) = 1 - F(x) \\ &= 1 - \int_0^x \lambda e^{-\lambda y} dy = e^{-\lambda x} \end{aligned}$$

con $x > 0$, ossia la velocità di decadimento della coda. Questo valore rappresenta la probabilità che il macchinario viva oltre l'istante x . Giustamente, più x è grande più questa probabilità è piccola.

Sia μ misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e F_μ funzione di ripartizione abbiamo già visto che se μ è assolutamente continua, allora F_μ è continua. Inoltre, se la densità f_μ è anch'essa continua, F_μ sarà $\mathcal{C}^1$ per il teorema fondamentale del calcolo. Vale anche un viceversa.

Proposition

Sia μ misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ e F_μ funzione di ripartizione di μ . Se F_μ è continua su tutto $\mathbb{R}$ e $\mathcal{C}^1$ a meno di un numero finito di punti (basterebbe $\mathcal{C}^1$ a tratti), allora μ è assolutamente continua con densità

$$f_\mu = F'_\mu$$

quasi ovunque. Si tolgono i punti in cui F_μ non è derivabile.

Proof

Abbiamo

$$f(x) = \begin{cases} F'(x) & F \text{ is } \mathcal{C}^1 \text{ in } x \\ 0 & \text{otherwise} \end{cases}$$

Sappiamo che F_μ è continua non decrescente, quindi A è non negativa. Dal teorema fondamentale del calcolo

$$\int_{-\infty}^{\infty} f(x) dx = \lim_{a \rightarrow -\infty} \lim_{b \rightarrow +\infty} \int_a^b f(x) dx = \lim_{a \rightarrow -\infty} \lim_{b \rightarrow +\infty} F(b) - F(a) = 1 - 0 = 1$$

per le proprietà delle funzioni di ripartizione. Quindi, f è una densità, e per il teorema precedente $\exists! \tilde{\mu}$ tale che $f_{\tilde{\mu}} = f$ ma per definizione

$$F_{\tilde{\mu}} = F_\mu$$

e quindi $\tilde{\mu} = \mu$. Quindi, μ è assolutamente continua con densità $f_\mu = f$.

Come recap abbiamo visto che se μ è una misura di probabilità su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ con funzione di ripartizione F_μ , allora,

1. F_μ discontinua e costante a tratti se e solo se μ discreta;
2. F_μ continua implica μ non discreta;
3. μ assolutamente continua allora F_μ continua;
4. F_μ continua e $\mathcal{C}^1$ a tratti implica μ assolutamente continua.

Esempio F_μ continua non implica assolutamente continua

Il controesempio è una funzione cantoriana normalizzata.

Teorema Decomposizione di Lebesgue

C'è un risultato generale che dice che μ può essere sempre decomposta come

$$\mu = \alpha\mu_1 + \beta\mu_2 + \sigma\mu_3$$

dove

1. $\alpha + \beta + \sigma = 1$;
2. μ_1 misura di probabilità discreta;
3. μ_2 misura di probabilità assolutamente continua;
4. μ_3 misura di probabilità continua singolare (o cantoriana), cioè F_μ è continua.

Esempio

Consideriamo l'esempio del tempo di vita di un macchinario. A volte si può tenere conto anche di eventuali difetti di fabbrica: supponiamo che con probabilità $p \in [0, 1]$ il macchinario sia difettoso

e si rompa immediatamente, mentre con probabilità $1 - p$ abbia tempo di vita esponenziale di parametro $\lambda > 0$. La misura di probabilità che descrive questo modello è

$$\mu = p\delta_0 + (1 - p)\exp(\lambda)$$

dove δ_0 è la misura di Dirac concentrata in 0. La funzione di ripartizione è

$$F_\mu(x) = \begin{cases} 0 & x < 0 \\ p + (1 - p)(1 - e^{-\lambda x}) & x \geq 0 \end{cases}$$

ossia

$$F_\mu(x) = \begin{cases} 0 & x < 0 \\ 1 - (1 - p)e^{-\lambda x} & x \geq 0 \end{cases}$$

La misura μ non è assolutamente continua, perché

$$\mu(\{0\}) = p$$

mentre la misura di Lebesgue di $\{0\}$ è nulla. Tuttavia, per $x > 0$, la parte assolutamente continua ha densità

$$f(x) = (1 - p)\lambda e^{-\lambda x} \chi_{[0, +\infty)}(x).$$

Quindi questo è un esempio di misura mista: una parte discreta, data da $p\delta_0$, e una parte assolutamente continua, data da $(1 - p)\exp(\lambda)$.

5 Variabili aleatorie in spazi continui

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità generico.

Definizione Variabile aleatorie

Chiamiamo *variabile aleatorie* una funzione $X: \Omega \rightarrow \mathbb{R}^n$ (borel) misurabile, cioè

$$\forall A \in \mathcal{B}(\mathbb{R}^n), X^{-1}(A) \in \mathcal{F}$$

Nel caso Ω discreto stavamo usando la σ -algebra delle parti, e quindi la misurabilità era automatica. Se prendiamo $\Omega = \mathbb{R}^n$ e $\mathcal{F} = \mathcal{B}(\mathbb{R}^n)$, allora X continua implica X (borel) misurabile.

Proposition

Sia $X: \Omega \rightarrow \mathbb{R}^n$ variabile aleatorie. La funzione $\mu_X: \mathcal{B}(\mathbb{R}^n) \rightarrow [0, 1]$ definita da

$$\mu_X(A) \triangleq \mathbb{P}(X^{-1}(A)) = \mathbb{P}(X \in A), \quad A \in \mathcal{B}(\mathbb{R}^n)$$

è una misurabile di probabilità su $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$. La chiameremo *legge* o *distribuzione* di X .

Proof

Identica a quella discreta sostituendo $\mathcal{P}(\Omega)$ con $\mathcal{F}$.

La misurabilità di X ci serve per garantire che μ_X sia ben definita.

Proposition

Data μ misura di probabilità su $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ esiste sempre X variabile aleatorie tale che μ è la sua legge, cioè $\mu_X = \mu$.

Proof

Basta prendere $\Omega = \mathbb{R}^n$, $\mathcal{F} = \mathcal{B}(\mathbb{R}^n)$ e $\mathbb{P} = \mu$. Allora, presa $X = \text{Id}_{\mathbb{R}^n}$, che è ovviamente misurabile, e

$$\mu_X(A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(A) = \mu(A), \quad \forall A \in \mathcal{B}(\mathbb{R}^n)$$

Proposition

Sia $X: \Omega \rightarrow \mathbb{R}^n$ variabile aleatorie e $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ funzione misurabile. Allora, $f \circ X = f(X): \Omega \rightarrow \mathbb{R}^m$ è pure variabile aleatorie-

Proof

Basta mostrare che $f \circ X$ è misurabile. In generale non è vero per funzioni misurabili. Sia $A \in \mathcal{B}(\mathbb{R}^m)$. Allora,

$$(f \circ X)^{-1}(A) = \{\omega \in \Omega \mid f(X(\omega)) \in A\} = \{\omega \in \Omega \mid X(\omega) \in f^{-1}(A)\} = X^{-1}(f^{-1}(A)) \in \mathcal{F}$$

in quanto X è misurabile e f misurabile e quindi $f^{-1}(A) \in \mathcal{B}(\mathbb{R}^n)$.

Definizione

Sia $X: \Omega \rightarrow \mathbb{R}^n$ variabile aleatoria. Chiamiamo σ -algebra generata da X la più piccola σ -algebra

che contiene la famiglia di insiemi

$$\mathcal{J} \triangleq \{X^{-1}(A) \mid A \in \mathcal{B}(\mathbb{R}^n)\}$$

Syntax: scriviamo $\sigma(X)$.

Cioè stiamo intersecando tutte le famiglie che rendono la funzione continua. Se anziché fissare lo spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$ fissiamo solo Ω e prendiamo una funzione $X: \Omega \rightarrow \mathbb{R}^n$, $\sigma(X)$ non è altro che la più piccola σ -algebra che rende X misurabile. Da questo deduciamo subito che se $X: \Omega \rightarrow \mathbb{R}^n$ è misurabile rispetto ad una σ -algebra $\mathcal{F}$ su Ω , allora $\sigma(X) \subseteq \mathcal{F}$.

Nota Problema del quasi certamente

Nel caso discreto, abbiamo detto che una proposizione è vera quasi certamente se l'insieme degli $\omega \in \Omega$ tale per cui quella proposizione è vera ha probabilità piena. Nel caso di Ω generico, non possiamo sempre prendere $\mathcal{F} = \mathcal{P}(\Omega)$, e quindi di conseguenza non è detto che un insieme arbitrario sia misurabile, in particolare non è detto che l'insieme di tutti gli ω che rendono vera una certa proposizione sia misurabile. Ci sono due modi per ovviare a ciò:

- Diciamo che una proposizione è vera quasi certamente se $\exists A \in \mathcal{F}$ tale che $\forall \omega \in A$ la proposizione è vera e $\mathbb{P}(A) = 1$. Quindi si richiede che ne esista almeno uno. Per esempio diciamo che $X \geq 0$ quasi certamente rispetto a $\mathbb{P}$. Se $\exists A \in \mathcal{F}$ tale che $\mathbb{P}(A) = 1$ e

$$A \subseteq \{\omega \in \Omega \mid X(\omega) \geq 0\}$$

Nel caso discreto richiederemmo che l'insieme totale abbia misura 1. In questo caso richiediamo che ne esista uno più piccolo misurabile, che per monotonia ha pure lui misura piena. Chiaramente se $\{\omega \in \Omega \mid X(\omega) \geq 0\} \in \mathcal{F}$, possiamo prendere direttamente questo come A , come nel caso discreto.

- Possiamo completare la σ -algebra $\mathcal{F}$ con gli insiemi di misura nulla, cioè definiamo

$$\mathcal{N} = \{A \subseteq \Omega \mid \exists A_0 \in \mathcal{F}, A \subseteq A_0 \wedge \mathbb{P}(A_0) = 0\}$$

Cioè stiamo considerando tutti gli insiemi contenuti in insiemi di misura nulla. Chiamiamo *complemento* di $\mathcal{F}$ la σ -algebra generata $\mathcal{F} \cup \mathcal{N}$. In questo modo contiene anche quelli di misura 1 in quanto complementari.

Definizione

Siano $(\Omega_1, \mathcal{F}_1, \mathbb{P}_1), (\Omega_2, \mathcal{F}_2, \mathbb{P}_2)$ spazi di probabilità generici e $X: \Omega_1 \rightarrow \mathbb{R}^n, Y: \Omega_2 \rightarrow \mathbb{R}^n$ variabili aleatorie.

1. $X =_d Y$ (uguali in distribuzione) se $\mu_X = \mu_Y$
2. $X = Y$ quasi certamente se $\Omega_1 = \Omega_2$ e $\mathcal{F}_1 = \mathcal{F}_2$ e $\mathcal{P}_1 = \mathcal{P}_2$ e $\exists A \in \mathcal{F}$ tale che

$$A \subseteq \{\omega \in \Omega \mid X(\omega) = Y(\omega)\}$$

e $\mathbb{P}(A) = 1$.

Ricordiamo che se $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ misurabile allora

$$f(X) =_d f(Y) \iff X = Y$$

e $X = Y$ quasi certamente implica $X =_d Y$ ma non il viceversa. Valgono tutti i risultati visti nel caso discreto, per le dimostrazioni è sufficiente sostituire $\mathcal{P}(\Omega) = \mathcal{F}$.

5.1 Variabili aleatorie assolutamente continue

Definizione Funzione di ripartizione

Sia $X: \Omega \rightarrow \mathbb{R}$ variabile aleatorie con legge μ_X . Chiamiamo *funzione di ripartizione* di X la funzione di ripartizione F_x associata alla misura di probabilità μ_X , cioè

$$F_X(x) = \mathbb{P}(X \leq x) = \mu_X((-\infty, x]), \quad \forall x \in \mathbb{R}$$

Abbiamo già visto che il caso discreto si “immerge in questo caso” più generale. Analogamente a quanto fatto prima, data $X: \Omega \rightarrow \mathbb{R}^n$ con legge μ_X diciamo che X è discreta se μ_X è discreta, cioè $\exists S \subseteq \mathbb{R}^n$ discreto tale che

$$P(X \in S) = \mu_X(S) = 1$$

Come già visto nella prima parte del corso, possiamo definire $p_X: \mathbb{R}^n \rightarrow [0, 1]$ data da

$$p_X(x) = \mathbb{P}(X = x) = \mu_X(\{x\}), \quad \forall x \in \mathbb{R}^n$$

Notiamo sempre che $p_X(x) = 0$ per ogni $x \notin S$ che è il nostro insieme discreto.

Definizione Variabile aleatoria assolutamente continua

Sia $X: \Omega \rightarrow \mathbb{R}$ variabile aleatorie con legge μ_X . Diciamo che X è assolutamente continua se μ_X è assolutamente continua e chiamiamo *densità di X* la densità f_X associata a μ_X , cioè

$$\mathbb{P}(X \in A) = \mu_X(A) = \int_A f_X(x) d\mu$$

Ricordiamo sempre la condizione sufficiente per l'assoluta continuità. In generale vale che

$$F_x(x) = \int_{-\infty}^x f(y) dy$$

Abbiamo visto che X assolutamente continua se la sua funzione di ripartizione $F_X: \mathbb{R} \rightarrow \mathbb{R}$ è continua e $\mathcal{C}^1$ a tratti. In questo caso, $f_X = F'_X$ quasi ovunque.

Mettendo insieme tutto quello che abbiamo fatto, possiamo concludere che data una funzione $F: \mathbb{R} \rightarrow [0, 1]$, monotona non decrescente, continua da destra e $\lim_{x \rightarrow \infty} F(x) = 1$ e $\lim_{x \rightarrow -\infty} F(x) = 0$ allora esiste spazio di probabilità con $F_X = F$.

Importante: abbiamo visto che μ misura di probabilità su $\mathbb{R}$ tale che F è la sua funzione di distribuzione ma fissata μ possono esistere infinite variabili aleatorie con legge μ e quindi funzione di ripartizione F , uguali in distribuzione (hanno la stessa legge), ma non uguali quasi certamente.

Nello stesso modo, data $p: \mathbb{R} \rightarrow [0, 1]$ densità discreta o $f: \mathbb{R} \rightarrow [0, +\infty]$ densità rispetto a Lebesgue, allora $\exists (\Omega, \mathcal{F}, \mathbb{P})$ spazio di probabilità e $X: \Omega \rightarrow \mathbb{R}$ discreta o assolutamente continua con densità p o f .

Importante: data una funzione di ripartizione o densità, esiste sempre una variabile aleatoria ad esse associata, ma loro determinano univocamente solo la legge della variabile aleatoria, non la variabile aleatoria stessa.

5.2 Valore atteso di variabili aleatorie generiche

L'idea è quella di considerare $(\Omega, \mathcal{F}, \mathbb{P})$ spazio di probabilità e $X: \Omega \rightarrow \mathbb{R}$ variabile aleatoria con legge μ_X . Vorremmo definire

$$\mathbb{E}[X] \triangleq \int_{\Omega} X(\omega) d\mathbb{P}(\omega)$$

Sostituendo la variabile $x = X(\omega)$ otteniamo

$$\mathbb{E}[X] = \int_{\mathbb{R}} x (\mathbb{P} \circ X^{-1}) dx = \int_{\mathbb{R}} x \mu_X dx$$

Se $\mathbb{P}$ è discreta, la definizione coincide con quella vecchia

$$\mathbb{E}[X] = \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\{\omega\})$$

Sempre nel caso discreto, abbiamo visto il cambio variabile $x = X(\omega)$

$$\mathbb{E}[X] = \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\{\omega\}) = \sum_{x \in \mathbb{R}} x \mu(\{x\}) = \sum_{x \in \mathbb{R}} x p_X(x)$$

dove $\mu(\{x\}) > 0$ su al più una quantità numerabile. Quindi, nel caso assolutamente continuo troviamo

$$\mathbb{E}[X] = \int_{\mathbb{R}} x \mu_X dx = \int_{\mathbb{R}} x f_X(x) dx$$

La prendiamo come data in quanto non abbiamo visto la teoria per il cambio di variabile. Prendiamo quindi quest'ultima come la definizione di valore atteso.

Definizione Valore atteso

Sia $X: \Omega \rightarrow \mathbb{R}$ variabile aleatoria assolutamente continua con densità f_X . Allora definiamo il valore atteso come

$$\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x) dx$$

se esiste.

Dalle proprietà dell'integrale di Lebesgue sappiamo che $\mathbb{E}[X]$ esiste finite se e solo se

$$\int_{\mathbb{R}} |x| f_X(x) d\mu < +\infty$$

Valgono tutte le proprietà del valore atteso viste nel caso discreto, in particolare ricordiamo che se X e Y sono variabili aleatorie assolutamente continue con densità f_X e f_Y allora se $f_X = f_Y$ quasi ovunque, allora i valori attesi coincidono.

Teorema

Sia $X: \Omega \rightarrow \mathbb{R}$ variabile aleatoria assolutamente continua e $g: \mathbb{R} \rightarrow \mathbb{R}$ funzione misurabile. Allora $g \circ X = g(X): \Omega \rightarrow \mathbb{R}$ ammette valore atteso finito se e solo se

$$\int_{\mathbb{R}} |g(x)| f_X(x) dx < +\infty$$

In tal caso,

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) f_X(x) dx$$

Questo teorema ci permette di definire la varianza.

Definizione

Sia $X: \Omega \rightarrow \mathbb{R}$ variabile aleatorie assolutamente continua con densità $f_X: \mathbb{R} \rightarrow [0, +\infty]$ e tale che

$$\int_{\mathbb{R}} |x|^2 f_X(x) dx < +\infty$$

Definiamo *varianza* di X la quantità

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \int_{\mathbb{R}} (x - \mathbb{E}[X])^2 f_X(x) dx$$

Possiamo anche scrivere

$$\mathbb{E}[X^2] - \mathbb{E}[X]^2 = \int_{\mathbb{R}} x^2 f_X(x) dx - \mathbb{E}[X]^2$$

Come nel caso discreto, se il momento secondo è finito allora pure il momento primo è finito

$$\begin{aligned} \int_{\mathbb{R}} x f_X(x) dx &= \int_{\mathbb{R}} 1 \cdot f_X^{1/2}(x) \cdot x \cdot f_X^{1/2}(x) dx \\ &\leq \left(\int_{\mathbb{R}} 1 f_X(x) dx \right)^{1/2} \cdot \left(\int_{\mathbb{R}} x^2 f_X(x) dx \right)^{1/2} \\ &= 1^{1/2} \cdot \left(\int_{\mathbb{R}} x^2 f_X(x) dx \right)^{1/2} < +\infty \end{aligned}$$

con disuguaglianza per Hölder, e l'integrale fa 1 in quanto f_X è densità.

In generale,

$$\mathbb{E}[x^p] < +\infty \implies \mathbb{E}[x^q] < +\infty, \quad \forall p \leq q$$

5.3 Variabili aleatorie assolutamente continue

Definizione

Chiamiamo *vettore aleatorio di $\mathbb{R}^n$* una n -tupla $(X_1, \dots, X_n)$ dove

$$X_i: \Omega \rightarrow \mathbb{R}$$

variabile aleatorie per ogni $i \in \{1, \dots, n\}$.

Abbiamo già visto quelli discreti e ora ci concentreremo su quelli assolutamente continui. Anche in questo caso possiamo vedere il vettore aleatorio come una variabile aleatoria a valori in $\mathbb{R}^n$, $X = (X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$. Notiamo che X è Borel-misurabile se e solo se $X_1, \dots, X_n$ sono Borel misurabili. Questo segue dal fatto che $\mathcal{B}(\mathbb{R}^n)$ è generata da insiemi del tipo $A_1 \times \dots \times A_n$ con $A_1, \dots, A_n \in \mathcal{B}(\mathbb{R})$. Questo ci dà la direzione da destra a sinistra. Il converso è dato dal fatto che, dato X se voglio trovare un X_i usiamo la proiezione canonica, che è una funzione continua anzi un operatore lineare, quindi misurabile. È un operatore lineare in quanto $X_i = \pi(X)$ con $\pi(X): \mathbb{R}^n \rightarrow \mathbb{R}$ data dal prodotto scalare

$$\pi(\bar{x}) = \langle e_i, \bar{x} \rangle$$

con $\bar{x} \in \mathbb{R}^n$ e e_i vettori della base canonica. Quindi, $X_i = \pi \circ X$ dove la prima è continua e la seconda misurabile, quindi X_i misurabile. Abbiamo quindi una corrispondenza biunivoca fra le variabili aleatorie di $\mathbb{R}^n$ e vettori aleatori di $\mathbb{R}^n$.

Definizione Leggi congiunte e marginali

Sia $X = (X_1, \dots, X_n)$ vettore aleatorio di $\mathbb{R}^n$. Chiamiamo *legge congiunta* la legge

$$\mu_{X_1, \dots, X_n}$$

di X visto come variabile aleatoria di $\mathbb{R}^n$, cioè $\forall A_1, \dots, A_n \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}(X \in A_1 \times \dots \times A_n) = \mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \mu_{X_1, \dots, X_n}(A_1 \times \dots \times A_n)$$

Allo stesso modo, con $\forall k \in \{1, \dots, n\}$ con $i_1 < \dots < i_k \in \{1, \dots, n\}$ chiamiamo *legge marginale* del vettore $(X_1, \dots, X_n)$ rispetto ad $I = (i_1, \dots, i_k)$ la legge della variabile aleatoria $X_I = (X_{i_1}, \dots, X_{i_k}): \Omega \rightarrow \mathbb{R}^k$ e la indichiamo con $\mu_{X_{i_1}, \dots, X_{i_k}}$ oppure μ_I , cioè $\forall A_1, \dots, A_k \in \mathcal{B}(\mathbb{R})$

$$\mathbb{P}(X_I \in A_1 \times \dots \times A_k) = \mathbb{P}(X_{i_1} \in A_1, \dots, X_{i_k} \in A_k)$$

Anche in questo caso chiamiamo *marginali unidimensionali* le leggi delle variabili aleatorie reali X_i e le indichiamo con μ_{X_i} oppure μ_i . Anche in questo caso generico la congiunta determina univocamente le marginali.

Proposition

$\forall A_{i_1}, \dots, A_{i_k} \in \mathcal{B}(\mathbb{R})$ vale che

$$\mu_{X_{i_1}, \dots, X_{i_k}}(A_{i_1} \times \dots \times A_{i_k}) = \mu(X_1, \dots, X_n)(C_1 \times \dots \times C_n)$$

dove

$$C_j = \begin{cases} \mathbb{R} & j \notin \{i_1, \dots, i_k\} \\ A_j & j \in \{i_1, \dots, i_k\} \end{cases}$$

In particolare nel caso $k = 1$ vale

$$\begin{aligned} \mu_{X_1}(A_1) &= \mathbb{P}(X_1 \in A_1) = \mathbb{P}(X_1 \in \mathbb{R}, \dots, X_i \in A_i, \dots, X_n \in \mathbb{R}) \\ &= \mu_{X_1, \dots, X_n}(\mathbb{R} \times \dots \times A_i \times \dots \mathbb{R}) \end{aligned}$$

La dimostrazione è analoga al caso discreto.

Definizione Funzione di ripartizione

Sia $X = (X_1, \dots, X_n)$ vettore aleatorio di $\mathbb{R}^n$ con legge congiunta $\mu_{X_1, \dots, X_n}$. Diciamo che la *funzione di ripartizione congiunta del vettore* è la funzione

$$F_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow \mathbb{R}$$

tale che $\forall \bar{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$

$$F_{X_1, \dots, X_n}(\bar{x}) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \mu_{X_1, \dots, X_n}((-\infty, \bar{x}])$$

Preso $k \in \{1, \dots, n\}$ e $i_1 < \dots < i_k \in \{1, \dots, n\}$ chiamiamo *funzione di ripartizione marginale* rispetto ad $I = (i_1, \dots, i_k)$ la funzione

$$F_{X_{i_1}, \dots, X_{i_k}} : \mathbb{R}^k \rightarrow \mathbb{R}$$

tale che $\forall \bar{x} = (x_1, \dots, x_n) \in \mathbb{R}^k$

$$F_{X_{i_1}, \dots, X_{i_k}}(\bar{x}) = \mathbb{P}(X_{i_1} \leq x_1, \dots, X_{i_k} \leq x_k)$$

Anche in questo caso possiamo ritrovare le marginali dalla funzione di ripartizione congiunta. In questo caso prendiamo il limite

$$F_{X_{i_1}, \dots, X_{i_k}}(X_{i_1}, \dots, X_{i_k}) = \lim_{\substack{x_j \rightarrow \infty \\ j \notin \{i_1, \dots, i_k\}}} F_{X_1, \dots, X_n}(X_1, \dots, X_n)$$

In particolare per le funzioni di ripartizione unidimensionali vale

$$F_{X_1}(x_i) = \lim_{x_j \rightarrow \infty, j \neq i} F_{X_1, \dots, X_n}(x_1, \dots, x_n)$$

cioè li facciamo andare tutti ad infinito tranne una.

Proof

Per comodità prendiamo $i_1 = 1, \dots, i_k = k$. Abbiamo

$$\begin{aligned}
 F_{X_1, \dots, X_k}(x_1, \dots, x_k) &= \mathbb{P}(X_1 \leq x_1, \dots, X_k \leq x_k) \\
 &= \mathbb{P}(X_1 \leq x_1, \dots, X_k \leq x_k, X_{k+1} \in \mathbb{R}, X_n \in \mathbb{R}) \\
 &= \lim_{\substack{x_{k+1} \rightarrow +\infty \\ \dots \\ x_n \rightarrow +\infty}} \mathbb{P}(X_1 \leq x_1, \dots, X_k \leq x_k, X_{k+1} \leq x_{k+1}, \dots, X_n \leq x_n) \quad \left. \begin{array}{l} \text{Continuità} \\ \text{dal basso} \end{array} \right\} \\
 &= \lim_{\substack{x_{k+1} \rightarrow +\infty \\ \dots \\ x_n \rightarrow +\infty}} F_{X_1, \dots, X_n}(x_1, \dots, x_n)
 \end{aligned}$$

Come nel caso discreto, non vale il viceversa. Le stessi leggi o funzioni di ripartizione non determinano univocamente la congiunta o legge di ripartizione.

Anche nel caso di $\mathbb{R}^n$ la funzione di ripartizione determina univocamente la legge. Di conseguenza possiamo lavorare con la funzione di ripartizione per dedurre risultati sulla legge. Inoltre, la funzione di ripartizione può essere sempre definita indipendentemente dalla forma delle $X_1, \dots, X_n$ (non necessariamente discrete o assolutamente continue).

Definizione Indipendenza

Siano $X_1, \dots, X_n$ variabili aleatorie reali $X_i: \Omega \rightarrow \mathbb{R}$. Diciamo che $X_1, \dots, X_n$ sono *indipendenti* se le σ -algebre da loro generate $\sigma(X_1), \dots, \sigma(X_n)$ sono indipendenti, cioè

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i)$$

per tutte le $A_1 \in \sigma(X_1), \dots, A_n \in \sigma(X_n)$.

Questa è una definizione che generalizza tutte le indipendenze.

Proposition

Siano $\mathcal{F}_1, \dots, \mathcal{F}_n$ delle σ -algebre su Ω e $\mathcal{I}_1, \dots, \mathcal{I}_n$ famiglie di sottoinsiemi di Ω chiuse rispetto all'intersezione finita tali che $\mathcal{F}_i = \sigma(\mathcal{I}_i)$. Allora, $\mathcal{F}_1, \dots, \mathcal{F}_n$ indipendenti se e solo se

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n \mathbb{P}(A_i)$$

per tutte le $A_1 \in \mathcal{I}_1, \dots, A_n \in \mathcal{I}_n$.

Quindi, mi basta verificare l'indipendenza dei generatori delle σ -algebre e la ottengo per le σ -algebre.

Nel caso discreto questa proposizione si concretizza dati $X: \Omega \rightarrow \mathbb{R}$ e $Y: \Omega \rightarrow \mathbb{R}$ discreti. In generale sappiamo che $\sigma(X)$ è la σ -algebra generata dagli insiemi del tipo $\{X \in A\}$ con insieme della σ -algebra in arrivo che nel caso discreto è $A \in \mathcal{P}(X(\Omega))$. In questo caso $\mathcal{P}(X(\Omega))$ è generato dagli insiemi $\{x\}$ con $x \in X(\Omega)$. Di conseguenza, $\sigma(X)$ è generata da dagli insiemi del tipo $\{X = x\}$ con $x \in X(\Omega)$ oppure $\mathbb{R}$. Nel caso generico in arrivo abbiamo tutta la σ -algebra di Borel, che può essere generata dalle semirette $(-\infty, x]$ con $x \in \mathbb{R}$. Di conseguenza, $\sigma(X)$ è generata dagli insiemi del tipo:

- $\{X \in A\}$ con $A \in \mathcal{B}(\mathbb{R})$;
- $\{X \leq x\}$ con $x \in \mathbb{R}$.

Quindi otteniamo il seguente risultato.

Teorema

Siano $X_1, \dots, X_n$ variabili reali $X_i: \Omega \rightarrow \mathbb{R}$. Le seguenti affermazioni sono equivalenti:

1. $X_1, \dots, X_n$ indipendenti;
2. $\forall A_1, \dots, A_n \in \mathcal{B}(\mathbb{R})$ vale

$$\begin{aligned}\mu_{X_1, \dots, X_n}(A_1 \times \dots \times A_n) &= \mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) \\ &= \prod_{i=1}^n \mathbb{P}(X_i \in A_i) = \prod_{i=1}^n \mu_{X_i}(A_i)\end{aligned}$$

3. $\forall x_1, \dots, x_n \in \mathbb{R}$ vale

$$\begin{aligned}F_{X_1, \dots, X_n}(x_1, \dots, x_n) &= \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) \\ &= \prod_{i=1}^n \mathbb{P}(X_i \leq x_i) = \prod_{i=1}^n F_{X_i}(x_i)\end{aligned}$$

4. Se $X_1, \dots, X_n$ discrete (già visto) allora $\forall x_1, \dots, x_n \in \mathbb{R}$

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n \mathbb{P}(X_i = x_i)$$

5.4 Vettori aleatori assolutamente continui

Definizione Vettore aleatorio assolutamente continuo

Sia $(X_1, \dots, X_n)$ vettori aleatori con congiunta $\mu_{X_1, \dots, X_n}$ e funzione di ripartizione $F_{X_1, \dots, X_n}$. Diciamo che il vettore è *assolutamente continuo* se $\exists f_{X_1, \dots, X_n}: \mathbb{R}^n \rightarrow [0, +\infty]$ tale che una delle seguenti affermazioni è vera:

1. $\forall a_1 < b_1, \dots, a_n < b_n$ vale

$$\mu_{X_1, \dots, X_n} \left(\prod_{i=1}^n (a_i, b_i) \right) = \int_{\prod_{i=1}^n (a_i, b_i)} f_{X_1, \dots, X_n} d\mu_n$$

2. $\forall x_1, \dots, x_n \in \mathbb{R}$ vale

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f_{X_1, \dots, X_n}(y_1, \dots, y_n) d(y_1, \dots, y_n)$$

In questo caso chiamiamo $f_{X_1, \dots, X_n}$ densità congiunta di X .

Se $(X_1, \dots, X_n)$ vettore aleatorio assolutamente continuo con densità f allora

$$\int_{\mathbb{R}^n} f(x_1, \dots, x_n) d(x_1, \dots, x_n) = \mathbb{P}(x_1 \in \mathbb{R}, \dots, x_n \in \mathbb{R}) = 1$$

Di conseguenza f è integrabile rispetto a Lebesgue e quindi posso applicare Fubini-Tonelli a piacere.

Anche in questo caso $f_{X_1, \dots, X_n}$ è unica quasi ovunque e determina univocamente la legge di $(X_1, \dots, X_n)$.

Anche in questo la congiunta determina la natura delle marginali.

Proposition

$\forall k \in \{1, \dots, n\}$ e $i_1 < \dots < i_k \in \{1, \dots, n\}$ il vettore aleatorio $(X_{i_1}, \dots, X_{i_k})$ è assolutamente

continuo con densità $f_{X_{i_1}, \dots, X_{i_k}} : \mathbb{R}^k \rightarrow [0, +\infty]$ data da

$$f_{X_1, \dots, X_n}(x_{i_1-1}, \dots, x_{i_k}) = \underbrace{\int_{\mathbb{R}} \dots \int_{\mathbb{R}}}_{n-k \text{ volte}} f_{X_1, \dots, X_n}(x_1, \dots, x_n) d(x_{j_1}, \dots, x_{n-k})$$

con $j_1 < \dots < j_{n-k} \notin \{i_1, \dots, i_k\}$. In particolare $\forall i \in \{1, \dots, n\}$, X_i è assolutamente continua con densità $f_{X_i} : \mathbb{R} \rightarrow [0, +\infty)$ data da

$$f_{X_i}(x_i) = \underbrace{\int_{\mathbb{R}} \dots \int_{\mathbb{R}}}_{n-1 \text{ volte}} f_{X_1, \dots, X_n}(x_1, \dots, x_n) d(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$$

Proof

Dimostriamolo nel caso $i_1 = 1, \dots, i_k = k$. Verifichiamo che il vettore $(X_1, \dots, X_k)$ verifichi la seconda condizione della definizione. Usando i risultati precedenti sulla funzione di ripartizione deduciamo che

$$\begin{aligned} F_{X_1, \dots, X_n}(x_1, \dots, x_k) &= \lim_{\substack{x_{k+1} \rightarrow +\infty \\ \dots \\ x_n \rightarrow +\infty}} F_{X_1, \dots, X_n}(x_1, \dots, x_n) \\ &= \lim_{\substack{x_{k+1} \rightarrow +\infty \\ \dots \\ x_n \rightarrow +\infty}} \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f_{X_1, \dots, X_n}(x_1, \dots, x_n) d(x_1, \dots, x_n) \\ &= \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_k} g(x_1, \dots, x_k) d(x_1, \dots, x_k) \end{aligned}$$

$\left. \begin{array}{l} \text{Continuità} \\ \text{assoluta} \end{array} \right\}$
 $\left. \begin{array}{l} \text{Fubini-Tonelli} \\ \text{e limite} \end{array} \right\}$

dove

$$g(x_1, \dots, x_k) = \underbrace{\int_{\mathbb{R}} \dots \int_{\mathbb{R}}}_{n-k \text{ volte}} f(x_1, \dots, x_n) d(x_{k+1}, \dots, x_n)$$

Quindi il vettore $(X_1, \dots, X_k)$ verifica la (2) con densità g .

Come già visto nel caso discreto, le marginali non determinano la congiunta, ma qua è ancora peggio. In questo caso se le X_i sono assolutamente continue per tutte le $i \in \{1, \dots, n\}$ non è detto che $(X_1, \dots, X_n)$ sia assolutamente continuo.

Esempio Controesempio

Prendiamo $Y : \Omega \rightarrow \mathbb{R}$ assolutamente continua e consideriamo il vettore (Y, Y) . Notiamo subito che

$$\mathbb{P}((Y, Y) \in D) = 1$$

dove $D = \{(x, y) \in \mathbb{R}^2 \mid x = y\}$, cioè la diagonale del piano bidimensionale. Se per assurdo (Y, Y) fosse assolutamente continua, allora esisterebbe $f : \mathbb{R}^2 \rightarrow [0, +\infty)$ tale che

$$1 = \mathbb{P}((Y, Y) \in D) = \int_D f(x, y) d(x, y) = 0$$

in quanto D ha misura nulla di Lebesgue, e quindi è assurdo.

5.5 Distribuzione uniforme

Consideriamo $X \sim \text{Unif}((a, b))$ con $a < b$, X è una variabile aleatoria reale assolutamente continua con densità

$$f_X(x) = \frac{\chi_{[a,b]}}{b-a}$$

Notiamo subito che

$$\int_{\mathbb{R}} f_X(x) dx = 1$$

quindi è una distribuzione. Questa si chiama uniforme sull'insieme (a, b) , poiché analogamente al caso discreto, a segmenti di lunghezza uguale (cardinalità nel caso discreto) viene assegnata la medesima probabilità. Calcoliamo ora valore atteso e varianza

$$\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x) dx = \int_a^b \frac{x}{b-a} dx = \frac{b^2 - a^2}{2(b-a)} = \frac{b+a}{2}$$

che è la coordinata del punto medio. Per la varianza

$$\mathbb{E}[X^2] - \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \frac{(b+a)^2}{4}$$

con

$$\begin{aligned} \mathbb{E}[X^2] &= \int_{\mathbb{R}} x^2 f_X(x) dx = \int_a^b \frac{x^2}{b-a} dx \\ &= \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3} \end{aligned}$$

Quindi la varianza non è altro che

$$\text{Var}(X) = \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4}$$

5.6 Distribuzione esponenziale

Sia $X \sim \text{Exp}(\lambda)$ con $\lambda > 0$. Allora X è una variabile aleatoria assolutamente continua con densità

$$f_X(x) = \lambda e^{-\lambda x} \chi_{[0, +\infty]}(x)$$

Avevamo già visto che f_x integra a 1 su tutto $\mathbb{R}$. Anche la distribuzione esponenziale ha la proprietà di perdita della memoria della geometrica, cioè

$$\mathbb{P}(X = y + h | X > y) = \mathbb{P}(X > h), \quad \forall y, h > 0$$

Dimostriamolo, calcoliamo la funzione di ripartizione

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x f_X(y) dy \\ &= \begin{cases} 0 & x \leq 0 \\ \int_0^x \lambda e^{-\lambda y} dy & x > 0 \end{cases} = \begin{cases} 0 & x \leq 0 \\ 1 - e^{-\lambda x} & x > 0 \end{cases} \end{aligned}$$

Notiamo che $\forall x > 0$

$$\mathbb{P}(X > h) = 1 - \mathbb{P}(X \leq x) = 1 - F_X(x) = e^{-\lambda x}$$

Quindi, concludiamo che

$$\begin{aligned}\mathbb{P}(X > y + h | X > y) &= \frac{\mathbb{P}(X > y + h, X > y)}{\mathbb{P}(X > y)} \\ &= \frac{\mathbb{P}(X > y + h)}{\mathbb{P}(X > y)} = \frac{e^{-\lambda(y+h)}}{e^{-\lambda y}} = e^{-\lambda h} = e^{-\lambda h}\end{aligned}$$

Calcoliamo media e varianza. Abbiamo

$$\begin{aligned}\mathbb{E}[X] &= \int_{\mathbb{R}} x f_X(x) dx = \int_0^{\infty} \lambda x e^{-\lambda x} dx \\ &= [-e^{-\lambda x} x]_0^{+\infty} + \int_0^{+\infty} e^{-\lambda x} dx = \frac{1}{\lambda}\end{aligned}$$

Per la varianza abbiamo

$$\text{Var}(X) = \mathbb{E}[X^2] - \frac{1}{\lambda^2}$$

con

$$\begin{aligned}\mathbb{E}[X^2] &= \int_{\mathbb{R}} x^2 f_X(x) dx = \int_0^{+\infty} \lambda x^2 e^{-\lambda x} dx \\ &= [-e^{-\lambda x} x^2]_0^{\infty} + \frac{2}{\lambda} \int_0^{\infty} \lambda x e^{-\lambda x} dx \\ &= \frac{2}{\lambda^2}\end{aligned}$$

Quindi la varianza è

$$\text{Var}(X) = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

I valori di media e varianza tornano da un punto di vista modellistico, infatti più è grande λ , più la coda dell'esponenziale si appiattisce sull'asse delle ascisse, di conseguenza la probabilità di concentra sempre di più su di un intorno destro di zero, e quindi la media si avvicina a zero e la varianza diminuisce.

5.7 Indipendenza e vettori assolutamente continui

Proposition

Sia $(X_1, \dots, X_n)$ vettore aleatorio di $\mathbb{R}^n$ assolutamente continuo con densità congiunta

$$f_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow [0, +\infty)$$

$X_1, \dots, X_n$ indipendenti se e solo se

$$f_{X_1, \dots, X_n}(\bar{x}) = \prod_{i=1}^n f_{X_i}(x_i)$$

quasi ovunque con $\bar{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ e dove

$$f_{X_i} : \mathbb{R} \rightarrow [0, +\infty)$$

sono le densità marginali di X_i per ogni $i \in \{1, \dots, n\}$.

Proof

Entrambi le direzioni si dimostrano con il teorema di Fubini (in ambo i sensi).

($\Rightarrow$) Sfruttiamo la caratterizzazione di indipendenza con le funzioni di ripartizioni. Sia $F_{X_1, \dots, X_n}$ funzione di ripartizione congiunta e F_{X_i} la funzione di ripartizione marginale di X_i per ogni $i \in \{1, \dots, n\}$. Visto che $X_1, \dots, X_n$ sono indipendenti, allora per ogni $\bar{x} = (x_1, \dots, x_n)$ vale

$$\begin{aligned} F_{X_1, \dots, X_n}(\bar{x}) &= \prod_{i=1}^n F_{X_i}(x_i) = \prod_{i=1}^n \int_{-\infty}^{x_i} f_{X_i}(y_i) dy_i \\ &= \int_{[-\infty, \bar{x}]} \prod_{i=1}^n f_{X_i}(y_i) d(y_1, \dots, y_n) \end{aligned}$$

Visto che abbiamo un prodotto di cose integrabili abbiamo applicato il teorema di Fubini. Ma quindi la funzione $\prod_{i=1}^n f_{X_i}$ verifica la definizione di vettore assolutamente continuo per $(X_1, \dots, X_n)$. Di conseguenza, per l'unicità quasi ovunque della densità

$$F_{X_1, \dots, X_n} = \prod_{i=1}^n f_{X_i}$$

quasi ovunque su $\mathbb{R}$.

($\Leftarrow$) Nello stesso modo, $\forall \bar{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$,

$$\begin{aligned} F_{X_1, \dots, X_n}(\bar{x}) &= \int_{[-\infty, \bar{x}]} f_{X_1, \dots, X_n}(\bar{y}) d(\bar{y}) \\ &= \int_{(-\infty, \bar{x})} \prod_{i=1}^n f_{X_i}(y_i) dy_i = \prod_{i=1}^n \int_{-\infty}^{x_i} f_{X_i}(y_i) dy_i \\ &= \prod_{i=1}^n F_{X_i}(x_i) \end{aligned}$$

Quindi per la caratterizzazione di indipendenza con le funzioni di ripartizioni $X_1, \dots, X_n$ sono indipendenti.

Le uguaglianze quasi ovunque per le densità diventano “ovunque” per le funzioni di ripartizioni poiché esse hanno una definizione non locale, in questo caso particolare la funzione di ripartizione dipende dall'integrale su $(-\infty, \bar{x})$, non interessa a nulla cosa succede sul singolo valore.

A differenza del caso discreto, per dimostrare che $X_1, \dots, X_n$ non sono indipendenti, non basta mostrare esiste un punto $\bar{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ tale che

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) \neq \prod_{i=1}^n f_{X_i}(x_i)$$

in quanto il punto ha misura di Lebesgue nulla, e la condizione adotta il quasi ovunque. Tuttavia, se $f_{X_1, \dots, X_n}$ e f_{X_i} sono continue per tutte le $i \in \{1, \dots, n\}$, allora la funzione

$$g := f_{X_1, \dots, X_n} - \prod_{i=1}^n f_{X_i}$$

è pure continua e diversa da zero in $\bar{x}$. Di conseguenza, esiste $r > 0$ tale che $g(\bar{y}) \neq 0$ per tutte le $\bar{y} \in B_r(\bar{x})$, che è una bolla con misura non nulla. Quindi la densità congiunta non fattorizza nelle marginali su un insieme non trascurabile. Quindi nel caso di funzioni continue vale comunque il criterio su un singolo punto.

Come nel caso discreto, dato un vettore (X_1, X_2) assolutamente continuo, X_1 e X_2 sono indipendenti se e solo se $\exists \alpha, \beta: \mathbb{R} \rightarrow [0, +\infty)$ tale che

$$f_{X_1, X_2} \propto \alpha(x_1)\beta(x_2)$$

quasi ovunque in $\mathbb{R}^n$. Se

$$\int_{\mathbb{R}} \alpha(x) dx = \int_{\mathbb{R}} \beta(x) dx = 1$$

α e β sono le marginali di X_1 e X_2 rispettivamente.

Corollario

Sia $(X_1, \dots, X_n)$ vettore aleatorio di $\mathbb{R}^n$. $X_1, \dots, X_n$ indipendenti e assolutamente continui con densità $f_{X_1}, \dots, f_{X_n}$. Allora, il vettore $(X_1, \dots, X_n)$ è assolutamente continuo con densità

$$f_{X_1, \dots, X_n}(\bar{x}) = \prod_{i=1}^n f_{X_i}(x_i)$$

quasi ovunque con $\bar{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$.

Proof

identica al caso $\Leftarrow$ della dimostrazione.

5.8 Covarianza tra due variabili aleatorie assolutamente continue

Teorema di cambio di variabile

Sia $(X_1, \dots, X_n)$ vettore aleatorio assolutamente continuo con densità congiunta $f_{X_1, \dots, X_n}: \mathbb{R}^n \rightarrow \mathbb{R}$. Sia $g: \mathbb{R}^n \rightarrow \mathbb{R}$ continua. Allora, la variabile aleatoria reale $g \circ X = g(X): \Omega \rightarrow \mathbb{R}$ ammette valore atteso finito se e solo se

$$\int_{\mathbb{R}^n} |g(\bar{x})| f_{X_1, \dots, X_n}(\bar{x}) d\bar{x} < +\infty$$

In tal caso,

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}^n} g(\bar{x}) f_{X_1, \dots, X_n}(\bar{x}) d\bar{x}$$

Non ci è dato che $g(X)$ sia assolutamente continuo.

Definizione Covarianza tra due variabili aleatorie assolutamente continue

Siano X, Y variabili aleatorie reali tali che (X, Y) è un vettore aleatorio assolutamente continuo con densità congiunta $f_{X, Y}: \mathbb{R}^2 \rightarrow [0, +\infty)$. Supponiamo che $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$. Definiamo come *covarianza*

$$\begin{aligned} \text{Cov}(X, Y) &\triangleq \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] \\ &= \int_{\mathbb{R}^2} xy f_{X, Y}(x, y) d(x, y) - \int_{\mathbb{R}} x f_X(x) dx \int_{\mathbb{R}} y f_Y(y) dy \\ &= \int_{\mathbb{R}^2} (X - \mathbb{E}[X])(Y - \mathbb{E}[Y]) f_{X, Y}(x, y) d(x, y) \end{aligned}$$

dove f_X e f_Y sono le marginali di X, Y .

Valgono tutte le proprietà del caso discreto. L'unica che ricordiamo è

Proposition

Siano $X, Y: \Omega \rightarrow \mathbb{R}$ variabili aleatorie assolutamente continue con densità f_X e f_Y e tale che $\mathbb{E}[|X|], \mathbb{E}[|Y|] < +\infty$ e indipendenti. Allora,

$$\begin{aligned}\mathbb{E}[|XY|] &= \mathbb{E}[|X|]\mathbb{E}[|Y|] \\ \mathbb{E}[XY] &= \mathbb{E}[X]\mathbb{E}[Y]\end{aligned}$$

In particolare, $\text{Cov}(X, Y) = 0$.

Se X, Y sono assolutamente continue e indipendenti possiamo dedurre che (X, Y) vettore aleatorio assolutamente continuo con densità $f_X \cdot f_Y$.

Teorema

Sia (X, Y) vettore aleatorio assolutamente continuo di $\mathbb{R}^2$ con densità $f_{X,Y}: \mathbb{R}^2 \rightarrow [0, +\infty)$ tale che le funzioni

$$x \rightarrow f_{X,Y}(x, z-x), \quad y \rightarrow f_{X,Y}(z-y, y)$$

siano integrabili $\forall z \in \mathbb{R}$. Allora, la variabile aleatoria $Z = X + Y$ è assolutamente continua con densità

$$f_Z(z) = \int_{\mathbb{R}} f_{X,Y}(x, z-x) dx = \int_{\mathbb{R}} f_{X,Y}(z-y, y) dy$$

quasi ovunque $\forall z \in \mathbb{R}$. In particolare, se X e Y sono indipendenti con marginali f_X e f_Y , allora

$$f_Z(z) = \int_{\mathbb{R}} f_X(x)f_Y(z-x) dx = \int_{\mathbb{R}} f_X(z-y)f_Y(y) dy$$

Proposition

Consideriamo il dominio

$$D_z = \{(x, y) \in \mathbb{R}^2 \mid x + y \leq z\}$$

con $z \in \mathbb{R}$. Calcoliamo la funzione di ripartizione di $Z = X + Y$

$$\begin{aligned}F_Z(z) &= \mathbb{P}(Z \leq z) = \mathbb{P}(X + Y \leq z) = \mathbb{P}((X, Y) \in D_z) \\ &= \int_{D_z} f_{X,Y}(x, y) d(x, y) && \left. \begin{array}{l} (X, Y) \text{ ass.} \\ \text{continuo} \end{array} \right\} \\ &= \int_{\mathbb{R}} \int_{-\infty}^{z-x} f_{X,Y}(x, y) dy dx && \left. \begin{array}{l} \text{Fubini} \end{array} \right\} \\ &= \int_{\mathbb{R}} \int_{-\infty}^z f_{X,Y}(x, t-x) dt dx && \left. \begin{array}{l} t = y + x \\ y = t - x \end{array} \right\} \\ &= \int_{-\infty}^z \underbrace{\left[\int_{\mathbb{R}} f_{X,Y}(x, t-x) dx \right]}_{g(t)} dt && \left. \begin{array}{l} \text{Fubini} \end{array} \right\}\end{aligned}$$

La funzione g verifica la definizione di assoluta continuità per la variabile reale Z , quindi è la sua densità. Per fare l'altra uguaglianza basta usare Fubini con $x \in (-\infty, z-y)$ e $y \in \mathbb{R}$.

Ricordiamo il cambio di variabile con diffeomorfismo Ψ

$$\int_A g(x) dx = \int_{\Psi(A)} g(\Psi(z)) |\det([J\psi](z))| dz$$

Proposition

Sia $(X_1, \dots, X_n)$ vettore aleatorio assolutamente continuo con densità congiunta $f_{X_1, \dots, X_n}$. Sia $A \subseteq \mathbb{R}^n$ tale che

$$\mathbb{P}((X_1, \dots, X_n) \in A) = 1$$

Sia $\varphi: A \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$ diffeomorfismo. Allora, il vettore aleatorio $\Psi = \varphi(X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$ è assolutamente continuo con densità

$$f_{Y_1, \dots, Y_n}(\bar{y}) = \begin{cases} f_{X_1, \dots, X_n}(\varphi^{-1}(\bar{y})) |\det([J\varphi^{-1}J(\bar{y})](\bar{y}))|, & \bar{y} \in \varphi(A) \\ 0 & y \notin \varphi(A) \end{cases}$$

Proposition Trasformazione affine

Consideriamo $(X_1, \dots, X_n)$ vettore aleatorio assolutamente continuo con densità congiunta $f_{X_1, \dots, X_n}: \mathbb{R}^n \rightarrow [0, +\infty)$ e prendiamo $\varphi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ definita da

$$\varphi(\bar{x}) = A\bar{x} + \bar{b}, \quad \bar{x} \in \mathbb{R}^n$$

con A matrice $n \times n$ non singolare e $\bar{b} \in \mathbb{R}^n$. Allora, il vettore aleatorio $Y = \varphi(X)$ è assolutamente continuo con densità

$$f_Y(\bar{y}) = \frac{1}{|\det A|} f(A^{-1}(\bar{y} - \bar{b})), \quad \bar{y} \in \mathbb{R}^n$$

Applicazione del teorema di trasformazione.

Definizione

Dato un vettore $(X_1, \dots, X_n)$ diciamo che ha legge uniforme su $\mathcal{O} \subseteq \mathbb{R}^n$ di misura positiva, vuol dire che è un vettore assolutamente continuo con densità

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = \frac{1}{\mu(\mathcal{O})} \chi_{\mathcal{O}}(x_1, \dots, x_n)$$

dove μ è la misura di Lebesgue.

6 Vettori gaussiani

Definizione Vettore atteso

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia

$$X = (X_1, \dots, X_n)$$

un vettore aleatorio a valori in $\mathbb{R}^n$. Chiamiamo *vettore atteso* di X il vettore dei valori attesi, cioè

$$\mathbb{E}[X] = \begin{pmatrix} \mathbb{E}[X_1] \\ \vdots \\ \mathbb{E}[X_n] \end{pmatrix}.$$

Definizione

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità e sia

$$X = (X_1, \dots, X_n)$$

un vettore aleatorio a valori in $\mathbb{R}^n$. Chiamiamo *matrice di covarianza* di X la matrice Q_X definita da

$$Q_X = (q_{ij})_{i,j=1}^n, \quad q_{ij} = \text{Cov}(X_i, X_j).$$

Notiamo subito che Q_X è simmetrica. Inoltre

$$\text{diag}(Q_X) = (\text{Var}(X_1), \dots, \text{Var}(X_n)).$$

Sia ora A una matrice $m \times n$ e sia $b \in \mathbb{R}^m$. Allora

$$\mathbb{E}[AX + b] = A\mathbb{E}[X] + b.$$

Inoltre, se Q_X è la matrice di covarianza di X , allora

$$Q_{AX+b} = AQ_X A^T.$$

Definizione Vettore gaussiano standard

Sia $X = (X_1, \dots, X_n)$ un vettore aleatorio di $\mathbb{R}^n$. Diciamo che X è un *vettore gaussiano standard* se è assolutamente continuo con densità

$$f_X(x_1, \dots, x_n) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2}(x_1^2 + \dots + x_n^2)}.$$

In questo caso usiamo la notazione

$$X \sim \mathcal{N}(0, I_n).$$

Se $n = 1$, ritroviamo esattamente la densità della gaussiana reale standard $\mathcal{N}(0, 1)$.

Studiamo alcune proprietà immediate di questo vettore. La densità si può scrivere come

$$f_X(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{x_i^2}{2}}.$$

Quindi $X_1, \dots, X_n$ sono variabili aleatorie indipendenti e identicamente distribuite, con

$$X_i \sim \mathcal{N}(0, 1) \quad \forall i \in \{1, \dots, n\}.$$

Da ciò segue che

$$\mathbb{E}[X_i] = 0, \quad \text{Var}(X_i) = 1 \quad \forall i \in \{1, \dots, n\}.$$

Inoltre, per indipendenza,

$$\text{Cov}(X_i, X_j) = 0 \quad \forall i \neq j.$$

Di conseguenza

$$\mathbb{E}[X] = 0, \quad Q_X = I_n.$$

Definizione Vettore gaussiano

Sia $X = (X_1, \dots, X_n)$ un vettore aleatorio di $\mathbb{R}^n$. Diciamo che X è un *vettore gaussiano* se è assolutamente continuo con densità

$$f_X(x) = \frac{1}{(2\pi)^{n/2} \sqrt{\det(Q)}} e^{-\frac{1}{2} \langle Q^{-1}(x-m), x-m \rangle},$$

dove $m \in \mathbb{R}^n$ e Q è una matrice $n \times n$ simmetrica definita positiva, cioè

$$\langle Qx, x \rangle > 0 \quad \forall x \in \mathbb{R}^n \setminus \{0\}.$$

In particolare Q è invertibile e $\det(Q) > 0$. In questo caso usiamo la notazione

$$X \sim \mathcal{N}(m, Q).$$

Vedremo ora che m è effettivamente il vettore medio e Q è effettivamente la matrice di covarianza.

Richiamo. Se T è una matrice simmetrica definita positiva, allora esiste un'unica matrice simmetrica definita positiva V tale che

$$V^2 = T.$$

La matrice V si chiama *radice quadrata* di T e si indica con

$$V = \sqrt{T}.$$

Nel caso diagonale, se

$$T = \text{diag}(\lambda_1, \dots, \lambda_n), \quad \lambda_i > 0,$$

allora

$$\sqrt{T} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n}).$$

Teorema Caratterizzazione tramite gaussiana standard

Sia $X = (X_1, \dots, X_n)$ un vettore aleatorio di $\mathbb{R}^n$, sia Q una matrice $n \times n$ simmetrica definita positiva e sia $m \in \mathbb{R}^n$. Allora

$$X \sim \mathcal{N}(m, Q)$$

se e solo se

$$X \stackrel{d}{=} \sqrt{Q} Z + m, \quad Z \sim \mathcal{N}(0, I_n).$$

Proof

($\Rightarrow$) Supponiamo che

$$X = \sqrt{Q} Z + m, \quad Z \sim \mathcal{N}(0, I_n).$$

Poiché Q è definita positiva, anche $\sqrt{Q}$ è definita positiva, dunque è invertibile. Consideriamo la mappa

$$\varphi : \mathbb{R}^n \rightarrow \mathbb{R}^n, \quad \varphi(z) = \sqrt{Q} z + m.$$

Questa è un diffeomorfismo, con inversa

$$\varphi^{-1}(x) = Q^{-1/2}(x - m).$$

Per il teorema di trasformazione delle densità, X è assolutamente continuo con densità

$$\begin{aligned} f_X(x) &= f_Z(\varphi^{-1}(x)) |\det(D\varphi^{-1}(x))| \\ &= \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \|Q^{-1/2}(x-m)\|^2} \cdot \frac{1}{\det(\sqrt{Q})} \\ &= \frac{1}{(2\pi)^{n/2} \sqrt{\det(Q)}} e^{-\frac{1}{2} \|Q^{-1/2}(x-m)\|^2}. \end{aligned}$$

Ora, siccome $Q^{-1/2}$ è simmetrica,

$$\|Q^{-1/2}(x-m)\|^2 = \langle Q^{-1}(x-m), x-m \rangle.$$

Quindi

$$f_X(x) = \frac{1}{(2\pi)^{n/2} \sqrt{\det(Q)}} e^{-\frac{1}{2} \langle Q^{-1}(x-m), x-m \rangle}.$$

Dunque $X \sim \mathcal{N}(m, Q)$.

($\Leftarrow$) Viceversa, supponiamo che

$$X \sim \mathcal{N}(m, Q).$$

Definiamo

$$Z = Q^{-1/2}(X - m).$$

Applicando di nuovo il teorema di trasformazione delle densità al diffeomorfismo

$$\psi(x) = Q^{-1/2}(x - m),$$

si verifica che Z ha densità

$$f_Z(z) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2}\langle z, z \rangle}.$$

Quindi

$$Z \sim \mathcal{N}(0, I_n).$$

Pertanto

$$X = \sqrt{Q} Z + m,$$

come volevamo.

Dal teorema precedente deduciamo immediatamente che, se $X \sim \mathcal{N}(m, Q)$, allora

$$\mathbb{E}[X] = \mathbb{E}[\sqrt{Q} Z + m] = \sqrt{Q} \mathbb{E}[Z] + m = m.$$

Inoltre

$$Q_X = Q_{\sqrt{Q} Z} = \sqrt{Q} Q_Z (\sqrt{Q})^T = \sqrt{Q} I_n \sqrt{Q} = Q.$$

Proposition Trasformazioni lineari di vettori gaussiani

Sia

$$X \sim \mathcal{N}(m, Q),$$

sia A una matrice $n \times n$ invertibile e sia $b \in \mathbb{R}^n$. Allora il vettore

$$Y = AX + b$$

è gaussiano. Più precisamente,

$$Y \sim \mathcal{N}(Am + b, AQA^T).$$

Proof

Per quanto dimostrato prima, possiamo scrivere

$$X = \sqrt{Q} Z + m, \quad Z \sim \mathcal{N}(0, I_n).$$

Allora

$$\begin{aligned} Y &= AX + b \\ &= A(\sqrt{Q} Z + m) + b \\ &= A\sqrt{Q} Z + Am + b. \end{aligned}$$

Il termine $A\sqrt{Q} Z$ è un vettore gaussiano centrato. La sua matrice di covarianza è

$$Q_{A\sqrt{Q} Z} = A\sqrt{Q} I_n (\sqrt{Q})^T A^T = AQA^T.$$

Quindi

$$Y \sim \mathcal{N}(Am + b, AQA^T).$$

Osservazione. In generale, l'incorrelazione tra due variabili aleatorie, cioè

$$\text{Cov}(X, Y) = 0,$$

non implica l'indipendenza. Nel caso gaussiano, però, questa implicazione diventa vera.

Teorema Indipendenza delle componenti gaussiane

Sia

$$X = (X_1, \dots, X_n) \sim \mathcal{N}(m, Q).$$

Allora

$$Q = \text{diag}(\lambda_1, \dots, \lambda_n), \quad \lambda_i > 0,$$

se e solo se $X_1, \dots, X_n$ sono indipendenti e

$$X_i \sim \mathcal{N}(m_i, \lambda_i) \quad \forall i \in \{1, \dots, n\}.$$

Proof

($\Rightarrow$) Supponiamo che

$$Q = \text{diag}(\lambda_1, \dots, \lambda_n), \quad \lambda_i > 0.$$

Allora

$$\det(Q) = \lambda_1 \cdots \lambda_n$$

e

$$Q^{-1} = \text{diag}\left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_n}\right).$$

La densità di X diventa

$$\begin{aligned} f_X(x_1, \dots, x_n) &= \frac{1}{(2\pi)^{n/2} \sqrt{\lambda_1 \cdots \lambda_n}} e^{-\frac{1}{2} \sum_{i=1}^n \frac{(x_i - m_i)^2}{\lambda_i}} \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\lambda_i}} e^{-\frac{(x_i - m_i)^2}{2\lambda_i}}. \end{aligned}$$

Ogni fattore

$$\frac{1}{\sqrt{2\pi\lambda_i}} e^{-\frac{(x_i - m_i)^2}{2\lambda_i}}$$

è la densità di una gaussiana reale $\mathcal{N}(m_i, \lambda_i)$. Quindi la densità congiunta fattorizza nel prodotto delle densità marginali. Per il criterio di indipendenza dei vettori assolutamente continui, $X_1, \dots, X_n$ sono indipendenti.

($\Leftarrow$) Viceversa, supponiamo che $X_1, \dots, X_n$ siano indipendenti e che

$$X_i \sim \mathcal{N}(m_i, \lambda_i), \quad \lambda_i > 0.$$

Allora, per $i \neq j$,

$$\text{Cov}(X_i, X_j) = 0,$$

mentre

$$\text{Var}(X_i) = \lambda_i.$$

Dunque la matrice di covarianza di X è diagonale:

$$Q = Q_X = \text{diag}(\lambda_1, \dots, \lambda_n).$$

Osservazione. Fino a questo punto ci siamo limitati al caso dei vettori gaussiani assolutamente continui rispetto alla misura di Lebesgue, perché li abbiamo definiti come vettori assolutamente continui aventi una certa densità.

La definizione classica, però, ammette anche il caso in cui il vettore gaussiano non sia assolutamente continuo rispetto alla misura di Lebesgue.

Sia $X = (X_1, \dots, X_n)$ un vettore aleatorio di $\mathbb{R}^n$. Secondo la definizione classica, diciamo che X è un vettore gaussiano se, per ogni $v \in \mathbb{R}^n$, la variabile aleatoria reale

$$\langle X, v \rangle$$

è una gaussiana reale oppure una delta di Dirac. Una delta di Dirac può essere interpretata come una gaussiana con varianza nulla.

In questo caso la matrice di covarianza può essere soltanto semidefinita positiva, quindi non necessariamente invertibile. Quando ciò accade, il vettore gaussiano non è assolutamente continuo rispetto alla misura di Lebesgue su tutto $\mathbb{R}^n$.

Se Q è una matrice di covarianza semidefinita positiva, possiamo decomporre

$$\mathbb{R}^n = \text{Im}(Q) \oplus \ker(Q).$$

Grazie a questa decomposizione, possiamo disintegrare la legge del vettore gaussiano in due parti:

$$\text{parte assolutamente continua su } \text{Im}(Q), \quad \text{parte di Dirac su } \ker(Q).$$

Esempio Vettore gaussiano degenere

Consideriamo

$$X \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}\right).$$

In questo caso la prima componente è una gaussiana reale standard, associata all'autovettore

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

mentre la seconda componente è una delta di Dirac in 0, associata all'autovettore

$$\begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Esercizio

Sia $(X, Y) \sim \mathcal{N}(0, Q)$, con Q definita positiva 2×2 . In particolare,

$$Q = \begin{pmatrix} a & b \\ b & c \end{pmatrix}.$$

Sappiamo che

$$a = \text{Var}(X) > 0, \quad c = \text{Var}(Y) > 0, \quad b = \text{Cov}(X, Y),$$

e, poiché Q è definita positiva,

$$ac - b^2 > 0.$$

Vogliamo calcolare la legge del vettore

$$\begin{pmatrix} V \\ Z \end{pmatrix} = \begin{pmatrix} X \\ X + Y \end{pmatrix}.$$

Scriviamo

$$\begin{pmatrix} V \\ Z \end{pmatrix} = A \begin{pmatrix} X \\ Y \end{pmatrix}, \quad A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}.$$

Poiché A è invertibile, si ha

$$\begin{pmatrix} V \\ Z \end{pmatrix} \sim \mathcal{N}(0, \Sigma), \quad \Sigma = AQA^t.$$

Calcoliamo:

$$\Sigma = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} a & b \\ b & c \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} a & a+b \\ a+b & a+c+2b \end{pmatrix}.$$

Poniamo quindi

$$\Sigma = \begin{pmatrix} \alpha & \gamma \\ \gamma & \beta \end{pmatrix},$$

dove

$$\alpha = a, \quad \gamma = a + b, \quad \beta = a + c + 2b.$$

In particolare,

$$\beta = \text{Var}(Z) = \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y).$$

Vogliamo calcolare la legge di $X + Y$. Poiché $Z = X + Y$, basta calcolare la densità marginale di Z .

La densità congiunta di (V, Z) è

$$f_{V,Z}(v, z) = \frac{1}{2\pi\sqrt{\det \Sigma}} e^{-\frac{1}{2} \left\langle \Sigma^{-1} \begin{pmatrix} v \\ z \end{pmatrix}, \begin{pmatrix} v \\ z \end{pmatrix} \right\rangle}.$$

Poiché

$$\Sigma^{-1} = \frac{1}{\det \Sigma} \begin{pmatrix} \beta & -\gamma \\ -\gamma & \alpha \end{pmatrix},$$

otteniamo

$$\begin{aligned} \left\langle \Sigma^{-1} \begin{pmatrix} v \\ z \end{pmatrix}, \begin{pmatrix} v \\ z \end{pmatrix} \right\rangle &= \frac{1}{\det \Sigma} \left\langle \begin{pmatrix} \beta v - \gamma z \\ -\gamma v + \alpha z \end{pmatrix}, \begin{pmatrix} v \\ z \end{pmatrix} \right\rangle \\ &= \frac{1}{\det \Sigma} [\beta v^2 - 2\gamma v z + \alpha z^2]. \end{aligned}$$

Quindi

$$f_{V,Z}(v, z) = \frac{1}{2\pi\sqrt{\det \Sigma}} e^{-\frac{1}{2\det \Sigma} [\beta v^2 - 2\gamma v z + \alpha z^2]}.$$

Calcoliamo ora la marginale di Z :

$$\begin{aligned} f_Z(z) &= \int_{\mathbb{R}} f_{V,Z}(v, z) dv \\ &= \frac{1}{2\pi\sqrt{\det \Sigma}} \int_{\mathbb{R}} e^{-\frac{1}{2\det \Sigma} [\beta v^2 - 2\gamma v z + \alpha z^2]} dv. \end{aligned}$$

Completiamo il quadrato:

$$\beta v^2 - 2\gamma v z + \alpha z^2 = \beta \left(v - \frac{\gamma}{\beta} z \right)^2 + \left(\alpha - \frac{\gamma^2}{\beta} \right) z^2.$$

Quindi

$$f_Z(z) = \frac{1}{2\pi\sqrt{\det \Sigma}} e^{-\frac{1}{2\det \Sigma} \left(\alpha - \frac{\gamma^2}{\beta} \right) z^2} \int_{\mathbb{R}} e^{-\frac{\beta}{2\det \Sigma} \left(v - \frac{\gamma}{\beta} z \right)^2} dv.$$

Ora

$$\int_{\mathbb{R}} e^{-\frac{\beta}{2 \det \Sigma} (v - \frac{\gamma}{\beta} z)^2} dv = \sqrt{\frac{2\pi \det \Sigma}{\beta}}.$$

Dunque

$$f_Z(z) = \frac{1}{\sqrt{2\pi\beta}} e^{-\frac{1}{2 \det \Sigma} \left(\alpha - \frac{\gamma^2}{\beta}\right) z^2}.$$

Poiché

$$\det \Sigma = \alpha\beta - \gamma^2,$$

si ha

$$\frac{1}{\det \Sigma} \left(\alpha - \frac{\gamma^2}{\beta} \right) = \frac{1}{\beta}.$$

Pertanto

$$f_Z(z) = \frac{1}{\sqrt{2\pi\beta}} e^{-\frac{z^2}{2\beta}}.$$

Quindi

$$Z = X + Y \sim \mathcal{N}(0, \beta),$$

cioè

$$X + Y \sim \mathcal{N}(0, \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)).$$

Se X e Y sono indipendenti, allora

$$\text{Cov}(X, Y) = 0,$$

e quindi

$$X + Y \sim \mathcal{N}(0, \text{Var}(X) + \text{Var}(Y)).$$

Proposition

Sia $(X, Y) \sim \mathcal{N}(\bar{m}, Q)$ con $\bar{m} = (m_1 + m_2)$. Allora,

$$X + Y \sim \mathcal{N}(m_1 + m_2, \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y))$$

Proof

Simile all'esercizio soprastante.

Infatti preso $v = (v_1, v_2) \in \mathbb{R}^2$, allora per quanto fatto $\langle (X, Y), v \rangle$ è una variabile aleatoria gaussiana per ogni $v \in \mathbb{R}^2$.

7 Probabilità condizionate e variabili aleatorie

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ spazio di probabilità e (X, Y) vettore aleatorio di $\mathbb{R}^2$. Vogliamo studiare la distribuzione di X dato $Y = y$.

7.1 Caso discreto

Sia $p_{X,Y}$ la densità discreta congiunta di (X, Y) . Sia $S \subseteq \mathbb{R}^2$ discreto tale che

$$p_{X,Y}(x, y) > 0 \iff (x, y) \in S$$

Dato $(x, y) \in S$, allora

$$\mathbb{P}(X = x | Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)} = \frac{p_{X,Y}(x, y)}{p_Y(y)}$$

Definizione

In questo caso chiamiamo densità di X dato Y la funzione

$$p_{X|Y}: \mathbb{R} \rightarrow [0,1]$$

tale che

$$p_{X|Y}(y) = \frac{p_{X,Y}(x,y)}{p_Y(y)}$$

Notiamo che $p_{X|Y}$ è una densità. Infatti, per ogni $y \in \mathbb{R}$

$$\sum_{x \in \mathbb{R}} p_{X|Y}(x|y) = \sum_{x \in \mathbb{R}} \frac{p_{X,Y}(x,y)}{p_Y(y)} = \frac{1}{p_Y(y)} \sum_{x \in \mathbb{R}} p_{X,Y}(x,y) \overset{p_Y(y)}{=} 1$$

Inoltre, se abbiamo l'indipendenza

$$p_{X|Y}(x|y) = \frac{p_{X,Y}(x,y)}{p_Y(y)} = \frac{p_X(x)p_Y(y)}{p_Y(y)} = p_X(x)$$

Succede esattamente quello che succede nel caso della probabilità condizionata fra due eventi indipendenti.

Possiamo anche definire il valore atteso di X dato $Y = y$ come segue

$$\mathbb{E}[X|Y = y] \triangleq \sum_{x \in \mathbb{R}} x p_{X|Y}(x|y)$$

Se volessimo calcolare il valore atteso senza fissato y ,

$$\mathbb{E}[X|Y] = \sum_{x \in \mathbb{R}} x p_{X|Y}(x|Y)$$

Questa è una variabile aleatoria definita da

$$\mathbb{E}[X|Y](\omega) = \sum_{x \in \mathbb{R}} x p_{X|Y}(x, y), \quad y = Y(\omega)$$

Questa osservazione ci dà l'idea intuitiva che può essere formalizzato (avanzato) che il valore atteso condizionato può essere definito come l'unica variabile aleatoria $\Omega \rightarrow \mathbb{R}$ che verifica una certa proprietà.

Esercizio

Sia $X \sim \text{Poiss}(\lambda)$ e $Y \sim \text{Poiss}(\gamma)$ indipendenti. Vogliamo calcolare la densità discreta condizionata di X dato $X+Y = n \in \mathbb{N} \cup \{0\}$. Ricordiamo che $X+Y \sim \text{Poiss}(\lambda+\gamma)$. Quindi, per ogni $n \in \mathbb{N} \cup \{0\}$ e $k \leq n$ vale

$$\begin{aligned} p_{X|X+Y}(k|n) &= \mathbb{P}(X = k | X + Y = n) = \frac{\mathbb{P}(X = k, X + Y = n)}{\mathbb{P}(X + Y = n)} = \frac{\mathbb{P}(X = k, Y = n - k)}{P(X + Y = n)} \\ &= \frac{\mathbb{P}(X = k) \mathbb{P}(Y = n - k)}{\mathbb{P}(X + Y = n)} = \frac{\frac{e^{-\lambda} \lambda^k}{k!} \frac{e^{-\gamma} \gamma^{n-k}}{(n-k)!}}{\frac{e^{-(\lambda+\gamma)} (\lambda+\gamma)^n}{n!}} \quad \left. \vphantom{\frac{e^{-\lambda} \lambda^k}{k!} \frac{e^{-\gamma} \gamma^{n-k}}{(n-k)!}} \right) \text{Indipendenza} \\ &= \binom{n}{k} \left(\frac{\lambda}{\lambda + \gamma} \right)^k \left(\frac{\gamma}{\lambda + \gamma} \right)^{n-k} \end{aligned}$$

che è una densità di una

$$\text{Bin} \left(n, \frac{\lambda}{\lambda + \gamma} \right)$$

Quindi possiamo dire che per ogni $n \in \mathbb{N}$,

$$X|X+Y=n \sim \text{Bin}\left(n, \frac{\lambda}{\lambda+\gamma}\right)$$

Da questo deduciamo che

$$\mathbb{E}[X|X+Y=n] = n \left(\frac{\lambda}{\lambda+\gamma} \right)$$

7.2 Caso continuo

Sia $f_{X,Y}$ densità congiunta di (X,Y) e f_Y marginali di Y . Analogamente al caso discreto

Definizione

Fissati $y \in \mathbb{R}$ tale che $f_Y(y) > 0$ definiamo densità di X dato Y la funzione

$$f_{X|Y}(\cdot|y): \mathbb{R} \rightarrow \mathbb{R}^+$$

definita da

$$f_{X|Y}(x,y) \triangleq \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

quasi ovunque $x \in \mathbb{R}$.

Fissato $y \in \mathbb{R}$, $f_{X|Y}(\cdot|y)$ è una densità. Infatti,

$$\begin{aligned} \int_{\mathbb{R}} f_{X|Y}(x|y) dx &= \int_{\mathbb{R}} \frac{f_{X,Y}(x,y)}{f_Y(y)} dx \\ &= \frac{1}{f_Y(y)} \int_{\mathbb{R}} f_{X,Y}(x,y) dx = 1 \end{aligned}$$

Anche in questo caso, se X e Y sono indipendenti, allora

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{f_X(x)f_Y(y)}{f_Y(y)} = f_X(x)$$

quasi ovunque $x \in \mathbb{R}$. Nello stesso modo, possiamo definire il valore atteso condizionato come

$$\mathbb{E}[X|Y=y] = \int_{\mathbb{R}} x f_{X|Y}(x|y) dx$$

Esercizio

Consideriamo

$$f_{X,Y}(x,y) = \frac{e^{-x/y} e^{-y}}{y} \chi_{\mathbb{R}^+ \times \mathbb{R}^+}(x,y)$$

Calcoliamo la densità condizionata di X dato Y . Come prima cosa dobbiamo calcolare la marginale di Y . Per ogni $y > 0$ vale che

$$\begin{aligned} f_Y(y) &= \int_{\mathbb{R}} \frac{e^{-x/y} e^{-y}}{y} \chi_{\mathbb{R}^+ \times \mathbb{R}^+}(x,y) dx = e^{-y} \int_0^{+\infty} \frac{e^{-x/y}}{y} dx \\ &= e^{-y} \left[-e^{-x/y} \right]_0^{\infty} = e^{-y} \end{aligned}$$

Da questo

$$f_Y(y) = e^{-y} \chi_{[0, +\infty]}(y)$$

cioè $Y \sim \text{Exp}(1)$. Da qua possiamo calcolare $f_{X|Y}(\cdot|y)$ per ogni $y > 0$, cioè

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{e^{-x/y} \cancel{e^{-y}}}{y \cancel{e^{-y}}} \chi_{[0, +\infty]}(x)$$

Da questo deduciamo che $X|Y = y \sim \text{Exp}(1/y)$. Automaticamente possiamo calcolare il valore atteso condizionato

$$\mathbb{E}[X|Y = y] = \frac{1}{1/y} = y$$

8 Convergenza

Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità. Consideriamo una successione $\{X_n\}_{n \in \mathbb{N}}$ di variabili aleatorie reali e una variabile aleatoria reale X .

Definizione Convergenza in legge o in distribuzione

Diciamo che $\{X_n\}_{n \in \mathbb{N}}$ converge in legge, o in distribuzione, a X se, poste

$$F_n(x) = \mathbb{P}(X_n \leq x), \quad F(x) = \mathbb{P}(X \leq x),$$

vale

$$F_n(x) \longrightarrow F(x)$$

per ogni punto $x \in \mathbb{R}$ di continuità di F .

In questo caso scriviamo

$$X_n \xrightarrow{d} X.$$

Definizione Convergenza in probabilità

Diciamo che $\{X_n\}_{n \in \mathbb{N}}$ converge in probabilità a X se, per ogni $\varepsilon > 0$,

$$\lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0.$$

Equivalentemente, per ogni $\varepsilon > 0$ e per ogni $\eta > 0$, esiste $n_0 \in \mathbb{N}$ tale che

$$\mathbb{P}(|X_n - X| > \varepsilon) < \eta \quad \forall n \geq n_0.$$

In questo caso scriviamo

$$X_n \xrightarrow{\mathbb{P}} X.$$

Definizione Convergenza quasi certa

Diciamo che $\{X_n\}_{n \in \mathbb{N}}$ converge quasi certamente a X se esiste $\Omega_0 \in \mathcal{F}$ tale che

$$\mathbb{P}(\Omega_0) = 1$$

e

$$\lim_{n \rightarrow +\infty} X_n(\omega) = X(\omega) \quad \forall \omega \in \Omega_0.$$

In questo caso scriviamo

$$X_n \xrightarrow{\text{q.c.}} X.$$

Osserviamo subito alcune differenze importanti tra le tre nozioni. Per la convergenza in distribuzione non è necessario che le variabili aleatorie X_n e X siano definite sullo stesso spazio di probabilità: la definizione usa soltanto le funzioni di ripartizione. Per la convergenza quasi certa, invece, $X_n(\omega)$ e $X(\omega)$ devono essere confrontate punto per punto, quindi le variabili devono essere definite sullo stesso spazio di probabilità. Se l'insieme

$$\left\{ \omega \in \Omega : \lim_{n \rightarrow +\infty} X_n(\omega) = X(\omega) \right\}$$

è misurabile, allora nella definizione di convergenza quasi certa possiamo prendere direttamente

$$\Omega_0 = \left\{ \omega \in \Omega : \lim_{n \rightarrow +\infty} X_n(\omega) = X(\omega) \right\}.$$

Un'altra differenza concettuale è la seguente. Se interpretiamo la successione $\{X_n\}_{n \in \mathbb{N}}$ come un vettore aleatorio a infinite componenti, allora per dimostrare la convergenza quasi certa serve, in generale,

conoscere la legge congiunta dell'intero vettore. Per la convergenza in probabilità, invece, basta conoscere le distribuzioni delle differenze $X_n - X$. Le implicazioni fondamentali sono:

$$X_n \xrightarrow{\text{q.c.}} X \xrightarrow{\quad} X_n \xrightarrow{\mathbb{P}} X \xrightarrow{\quad} X_n \xrightarrow{d} X$$

$\nwarrow \quad \neq \quad \swarrow \qquad \nwarrow \quad \neq \quad \swarrow$

Teorema La convergenza in probabilità implica la convergenza in distribuzione

Se

$$X_n \xrightarrow{\mathbb{P}} X,$$

allora

$$X_n \xrightarrow{d} X.$$

Proof

Fissiamo $\varepsilon > 0$. Per ogni $x \in \mathbb{R}$ e per ogni $n \in \mathbb{N}$, usando la formula delle probabilità totali,

$$\begin{aligned} F_n(x) &= \mathbb{P}(X_n \leq x) \\ &= \mathbb{P}(X_n \leq x, X \leq x + \varepsilon) + \mathbb{P}(X_n \leq x, X > x + \varepsilon). \end{aligned}$$

Se $X_n \leq x$ e $X > x + \varepsilon$, allora

$$|X_n - X| > \varepsilon.$$

Quindi

$$\begin{aligned} F_n(x) &\leq \mathbb{P}(X \leq x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon) \\ &= F(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon). \end{aligned}$$

Otteniamo così la prima disuguaglianza:

$$F_n(x) \leq F(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon).$$

Analogamente,

$$\begin{aligned} F(x - \varepsilon) &= \mathbb{P}(X \leq x - \varepsilon) \\ &= \mathbb{P}(X \leq x - \varepsilon, X_n \leq x) + \mathbb{P}(X \leq x - \varepsilon, X_n > x). \end{aligned}$$

Se $X \leq x - \varepsilon$ e $X_n > x$, allora

$$|X_n - X| > \varepsilon.$$

Di conseguenza

$$F(x - \varepsilon) \leq F_n(x) + \mathbb{P}(|X_n - X| > \varepsilon),$$

cioè

$$F_n(x) \geq F(x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon).$$

Combinando le due disuguaglianze otteniamo

$$F(x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \leq F_n(x) \leq F(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon).$$

Poiché $X_n \xrightarrow{\mathbb{P}} X$, vale

$$\mathbb{P}(|X_n - X| > \varepsilon) \longrightarrow 0.$$

Passando al limite inferiore e al limite superiore:

$$F(x - \varepsilon) \leq \liminf_{n \rightarrow +\infty} F_n(x) \leq \limsup_{n \rightarrow +\infty} F_n(x) \leq F(x + \varepsilon).$$

Se x è un punto di continuità di F , facendo tendere $\varepsilon \downarrow 0$ si ottiene

$$\liminf_{n \rightarrow +\infty} F_n(x) = \limsup_{n \rightarrow +\infty} F_n(x) = F(x).$$

Dunque

$$F_n(x) \longrightarrow F(x)$$

in ogni punto di continuità di F , cioè $X_n \xrightarrow{d} X$.

Esempio La convergenza in distribuzione non implica la convergenza in probabilità

Sia

$$X \sim \text{Ber}\left(\frac{1}{2}\right), \quad X_n = X \quad \forall n \in \mathbb{N}.$$

Allora

$$X_n \xrightarrow{\text{q.c.}} X,$$

e quindi anche

$$X_n \xrightarrow{d} X.$$

Definiamo

$$Y = 1 - X.$$

Allora anche

$$Y \sim \text{Ber}\left(\frac{1}{2}\right).$$

Quindi X e Y hanno la stessa distribuzione, e perciò

$$X_n \xrightarrow{d} Y.$$

Tuttavia X_n non converge in probabilità a Y . Infatti, per ogni $\varepsilon \in (0, 1)$,

$$\begin{aligned} \mathbb{P}(|X_n - Y| > \varepsilon) &= \mathbb{P}(|X - (1 - X)| > \varepsilon) \\ &= \mathbb{P}(|2X - 1| > \varepsilon) \\ &= 1. \end{aligned}$$

Dunque

$$\mathbb{P}(|X_n - Y| > \varepsilon) \not\rightarrow 0.$$

Questo mostra che

$$X_n \xrightarrow{d} Y \not\Rightarrow X_n \xrightarrow{\mathbb{P}} Y.$$

L'unicità del limite va quindi intesa rispetto alla specifica nozione di convergenza che si sta usando. Nell'esempio, X e Y sono uguali in distribuzione, ma non sono uguali quasi certamente.

Definizione Limite superiore e limite inferiore di eventi

Sia $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi. Definiamo

$$\limsup_{n \rightarrow +\infty} A_n = \bigcap_{m=1}^{+\infty} \bigcup_{n=m}^{+\infty} A_n.$$

Equivalentemente,

$$\limsup_{n \rightarrow +\infty} A_n = \{\omega \in \Omega : \omega \in A_n \text{ per infiniti } n\}.$$

Definiamo inoltre

$$\liminf_{n \rightarrow +\infty} A_n = \bigcup_{m=1}^{+\infty} \bigcap_{n=m}^{+\infty} A_n.$$

Equivalentemente,

$$\liminf_{n \rightarrow +\infty} A_n = \{\omega \in \Omega : \omega \in A_n \text{ definitivamente}\}.$$

Poniamo

$$S_m = \bigcup_{n=m}^{+\infty} A_n, \quad L_m = \bigcap_{n=m}^{+\infty} A_n.$$

Allora $\{S_m\}_{m \in \mathbb{N}}$ è decrescente e $\{L_m\}_{m \in \mathbb{N}}$ è crescente:

$$S_{m+1} \subseteq S_m, \quad L_m \subseteq L_{m+1}.$$

Inoltre

$$\limsup_{n \rightarrow +\infty} A_n = \bigcap_{m=1}^{+\infty} S_m, \quad \liminf_{n \rightarrow +\infty} A_n = \bigcup_{m=1}^{+\infty} L_m.$$

Per la continuità della probabilità lungo successioni monotone,

$$\mathbb{P}(S_m) \downarrow \mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n\right),$$

e

$$\mathbb{P}(L_m) \uparrow \mathbb{P}\left(\liminf_{n \rightarrow +\infty} A_n\right).$$

Poiché, per ogni $m \in \mathbb{N}$,

$$L_m \subseteq A_m \subseteq S_m,$$

si ottiene la catena di disuguaglianze

$$\mathbb{P}\left(\liminf_{n \rightarrow +\infty} A_n\right) \leq \liminf_{n \rightarrow +\infty} \mathbb{P}(A_n) \leq \limsup_{n \rightarrow +\infty} \mathbb{P}(A_n) \leq \mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n\right).$$

Questa è una forma del lemma di Fatou per successioni di eventi.

In particolare, se

$$\liminf_{n \rightarrow +\infty} A_n = \limsup_{n \rightarrow +\infty} A_n = A,$$

allora diciamo che A_n converge ad A e vale

$$\lim_{n \rightarrow +\infty} \mathbb{P}(A_n) = \mathbb{P}(A).$$

Teorema Lemma di Borel-Cantelli

Sia $\{A_n\}_{n \in \mathbb{N}} \subseteq \mathcal{F}$ una successione di eventi. Se

$$\sum_{n=1}^{+\infty} \mathbb{P}(A_n) < +\infty,$$

allora

$$\mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n\right) = 0.$$

Proof

Poniamo

$$S_m = \bigcup_{n=m}^{+\infty} A_n.$$

Allora

$$\limsup_{n \rightarrow +\infty} A_n = \bigcap_{m=1}^{+\infty} S_m,$$

e $\{S_m\}_{m \in \mathbb{N}}$ è decrescente. Quindi

$$\mathbb{P}(S_m) \downarrow \mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n\right).$$

Per subadditività,

$$\mathbb{P}(S_m) = \mathbb{P}\left(\bigcup_{n=m}^{+\infty} A_n\right) \leq \sum_{n=m}^{+\infty} \mathbb{P}(A_n).$$

Poiché la serie $\sum_{n=1}^{+\infty} \mathbb{P}(A_n)$ converge, il resto della serie tende a 0:

$$\sum_{n=m}^{+\infty} \mathbb{P}(A_n) \longrightarrow 0.$$

Pertanto

$$\mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n\right) = 0.$$

Per studiare la convergenza quasi certa introduciamo, per ogni $\varepsilon > 0$, gli eventi

$$A_n(\varepsilon) = \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}.$$

Proposition Criteri per la convergenza quasi certa

Con la notazione precedente valgono le seguenti affermazioni:

$$\mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n(\varepsilon)\right) = 0 \quad \forall \varepsilon > 0 \quad \Longleftrightarrow \quad X_n \xrightarrow{\text{q.c.}} X.$$

Inoltre,

$$\sum_{n=1}^{+\infty} \mathbb{P}(A_n(\varepsilon)) < +\infty \quad \forall \varepsilon > 0 \quad \implies \quad X_n \xrightarrow{\text{q.c.}} X.$$

Infine,

$$X_n \xrightarrow{\text{q.c.}} X \quad \implies \quad X_n \xrightarrow{\mathbb{P}} X.$$

Proof

Dimostriamo il primo punto.

($\implies$) Supponiamo che $X_n \xrightarrow{\text{q.c.}} X$. Allora esiste $\Omega_0 \in \mathcal{F}$ tale che

$$\mathbb{P}(\Omega_0) = 1$$

e

$$X_n(\omega) \longrightarrow X(\omega) \quad \forall \omega \in \Omega_0.$$

Fissato $\varepsilon > 0$, se $\omega \in \Omega_0$, allora ω appartiene ad $A_n(\varepsilon)$ solo per un numero finito di indici n . Infatti, dalla convergenza puntuale segue che definitivamente

$$|X_n(\omega) - X(\omega)| \leq \varepsilon.$$

Quindi

$$\Omega_0 \cap \limsup_{n \rightarrow +\infty} A_n(\varepsilon) = \emptyset.$$

Pertanto

$$\mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n(\varepsilon)\right) = 0.$$

($\Longleftarrow$) Supponiamo ora che

$$\mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n(\varepsilon)\right) = 0 \quad \forall \varepsilon > 0.$$

È sufficiente considerare $\varepsilon = 1/k$, con $k \in \mathbb{N}$. Definiamo

$$\Omega_0 = \Omega \setminus \bigcup_{k=1}^{+\infty} \limsup_{n \rightarrow +\infty} A_n \left(\frac{1}{k} \right).$$

Per subaddittività numerabile,

$$\mathbb{P}(\Omega_0) = 1.$$

Sia $\omega \in \Omega_0$. Fissiamo $\varepsilon > 0$ e scegliamo $k \in \mathbb{N}$ tale che

$$\frac{1}{k} < \varepsilon.$$

Poiché $\omega \notin \limsup_{n \rightarrow +\infty} A_n(1/k)$, esiste $n_0 \in \mathbb{N}$ tale che

$$\omega \notin A_n \left(\frac{1}{k} \right) \quad \forall n \geq n_0.$$

Cioè

$$|X_n(\omega) - X(\omega)| \leq \frac{1}{k} < \varepsilon \quad \forall n \geq n_0.$$

Dunque $X_n(\omega) \rightarrow X(\omega)$. Poiché $\omega \in \Omega_0$ era arbitrario e $\mathbb{P}(\Omega_0) = 1$, segue che

$$X_n \xrightarrow{\text{q.c.}} X.$$

Il secondo punto segue immediatamente dal lemma di Borel-Cantelli applicato agli eventi $A_n(\varepsilon)$, per ogni $\varepsilon > 0$, e dal primo punto.

Dimostriamo il terzo punto. Se $X_n \xrightarrow{\text{q.c.}} X$, dal primo punto abbiamo

$$\mathbb{P} \left(\limsup_{n \rightarrow +\infty} A_n(\varepsilon) \right) = 0 \quad \forall \varepsilon > 0.$$

Applicando la disuguaglianza di Fatou per eventi,

$$\limsup_{n \rightarrow +\infty} \mathbb{P}(A_n(\varepsilon)) \leq \mathbb{P} \left(\limsup_{n \rightarrow +\infty} A_n(\varepsilon) \right) = 0.$$

Quindi

$$\lim_{n \rightarrow +\infty} \mathbb{P}(A_n(\varepsilon)) = 0 \quad \forall \varepsilon > 0.$$

Per definizione,

$$\mathbb{P}(A_n(\varepsilon)) = \mathbb{P}(|X_n - X| > \varepsilon),$$

perciò

$$X_n \xrightarrow{\mathbb{P}} X.$$

Esempio La convergenza in probabilità non implica la convergenza quasi certa

Ricordiamo prima che una successione $\{X_n\}_{n \in \mathbb{N}}$ di variabili aleatorie si dice indipendente se, per ogni $m \in \mathbb{N}$, le variabili aleatorie

$$X_1, \dots, X_m$$

sono indipendenti.

Sia $\{X_n\}_{n \in \mathbb{N}}$ una successione di variabili aleatorie indipendenti tali che

$$X_n \sim \text{Ber} \left(\frac{1}{n} \right).$$

Quindi

$$\mathbb{P}(X_n = 1) = \frac{1}{n}, \quad \mathbb{P}(X_n = 0) = 1 - \frac{1}{n}.$$

Mostriamo innanzitutto che

$$X_n \xrightarrow{\mathbb{P}} 0.$$

Sia $\varepsilon > 0$. Se $\varepsilon \geq 1$, allora

$$\mathbb{P}(|X_n - 0| > \varepsilon) = 0.$$

Se invece $\varepsilon \in (0, 1)$, allora

$$\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(X_n = 1) = \frac{1}{n} \rightarrow 0.$$

Dunque $X_n \xrightarrow{\mathbb{P}} 0$.

Mostriamo ora che X_n non converge quasi certamente a 0. Fissiamo $\varepsilon \in (0, 1)$ e poniamo

$$A_n(\varepsilon) = \{|X_n - 0| > \varepsilon\}.$$

Poiché $X_n \in \{0, 1\}$, per $\varepsilon \in (0, 1)$ si ha

$$A_n(\varepsilon) = \{X_n = 1\}.$$

Quindi

$$\mathbb{P}(A_n(\varepsilon)) = \frac{1}{n}.$$

Vogliamo calcolare

$$\mathbb{P}\left(\limsup_{n \rightarrow +\infty} A_n(\varepsilon)\right).$$

Per ogni $m \in \mathbb{N}$, poniamo

$$S_m = \bigcup_{n=m}^{+\infty} A_n(\varepsilon).$$

Allora $S_m \downarrow \limsup_{n \rightarrow +\infty} A_n(\varepsilon)$. Inoltre

$$\mathbb{P}(S_m) = 1 - \mathbb{P}\left(\bigcap_{n=m}^{+\infty} A_n(\varepsilon)^c\right).$$

Usiamo l'indipendenza. Per $k \geq m$,

$$\begin{aligned} \mathbb{P}\left(\bigcap_{n=m}^k A_n(\varepsilon)^c\right) &= \prod_{n=m}^k \mathbb{P}(A_n(\varepsilon)^c) \\ &= \prod_{n=m}^k \left(1 - \frac{1}{n}\right). \end{aligned}$$

Se $m \geq 2$, allora

$$\prod_{n=m}^k \left(1 - \frac{1}{n}\right) = \prod_{n=m}^k \frac{n-1}{n} = \frac{m-1}{k}.$$

Facendo $k \rightarrow +\infty$, otteniamo

$$\mathbb{P}\left(\bigcap_{n=m}^{+\infty} A_n(\varepsilon)^c\right) = 0.$$

Quindi

$$\mathbb{P}(S_m) = 1 \quad \forall m \in \mathbb{N}.$$

Passando al limite lungo $S_m \downarrow \limsup A_n(\varepsilon)$,

$$\mathbb{P} \left(\limsup_{n \rightarrow +\infty} A_n(\varepsilon) \right) = 1.$$

In particolare questo valore non è 0. Per il criterio precedente,

$$X_n \not\xrightarrow{q.c.} 0.$$

Abbiamo quindi costruito un esempio in cui

$$X_n \xrightarrow{\mathbb{P}} 0 \quad \text{ma} \quad X_n \not\xrightarrow{q.c.} 0.$$

8.1 Risultati asintotici

Supponiamo di avere una moneta, ma di non sapere se sia equilibrata oppure no. Per modellizzare questa situazione consideriamo una successione $\{X_n\}_{n \in \mathbb{N}}$ di variabili aleatorie reali indipendenti, dove

$$X_n \sim \text{Ber}(p), \quad p \in [0, 1], \quad \forall n \in \mathbb{N}.$$

Il parametro p è incognito e rappresenta la probabilità di ottenere testa. Dunque

$$\mathbb{P}(X_n = 1) = p, \quad \mathbb{P}(X_n = 0) = 1 - p.$$

Vogliamo trovare un modo per stimare p . L'idea più semplice è quella frequentista: lanciamo la moneta n volte e facciamo il rapporto tra il numero di teste ottenute e il numero totale di lanci. Definiamo quindi

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k.$$

Questa quantità è la frequenza relativa del numero di teste. In statistica, $\bar{X}_n$ è uno stimatore di p .

La domanda naturale è: quanto grande deve essere n affinché $\bar{X}_n$ sia abbastanza vicino a p ? Per rispondere useremo le nozioni di convergenza viste nella lezione precedente.

Legge debole dei grandi numeri

Teorema Legge debole dei grandi numeri

Sia $\{X_n\}_{n \in \mathbb{N}}$ una successione di variabili aleatorie reali indipendenti tali che

$$\mathbb{E}[X_n] = \mu, \quad \text{Var}(X_n) = \sigma^2 < +\infty, \quad \forall n \in \mathbb{N}.$$

Posto

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k,$$

vale

$$\bar{X}_n \xrightarrow{\mathbb{P}} \mu.$$

Cioè, per ogni $\eta > 0$,

$$\lim_{n \rightarrow +\infty} \mathbb{P}(|\bar{X}_n - \mu| > \eta) = 0.$$

Per dimostrare questo teorema ci servono due disuguaglianze fondamentali.

Proposition Disuguaglianze di Markov e Chebyshev

Sia X una variabile aleatoria reale.

1. Se $X \geq 0$ quasi certamente, allora per ogni $\varepsilon > 0$

$$\mathbb{P}(X \geq \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}.$$

Questa è la disuguaglianza di Markov.

2. Se $\mathbb{E}[X^2] < +\infty$, allora per ogni $\varepsilon > 0$

$$\mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}.$$

Questa è la disuguaglianza di Chebyshev.

Proof

Dimostriamo prima la disuguaglianza di Markov. Poiché $X \geq 0$ quasi certamente, per ogni $\varepsilon > 0$ vale

$$X \geq \varepsilon \mathbb{1}_{\{X \geq \varepsilon\}} \quad \text{q.c.}$$

Passando al valore atteso,

$$\mathbb{E}[X] \geq \mathbb{E}[\varepsilon \mathbb{1}_{\{X \geq \varepsilon\}}] = \varepsilon \mathbb{E}[\mathbb{1}_{\{X \geq \varepsilon\}}] = \varepsilon \mathbb{P}(X \geq \varepsilon).$$

Quindi

$$\mathbb{P}(X \geq \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}.$$

Per Chebyshev applichiamo Markov alla variabile aleatoria non negativa

$$Y = (X - \mathbb{E}[X])^2.$$

Allora

$$\begin{aligned} \mathbb{P}(|X - \mathbb{E}[X]| \geq \varepsilon) &= \mathbb{P}((X - \mathbb{E}[X])^2 \geq \varepsilon^2) \\ &\leq \frac{\mathbb{E}[(X - \mathbb{E}[X])^2]}{\varepsilon^2} \\ &= \frac{\text{Var}(X)}{\varepsilon^2}. \end{aligned}$$

Proof Dimostrazione della legge debole

Per ogni $n \in \mathbb{N}$,

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}\left[\frac{1}{n} \sum_{k=1}^n X_k\right] = \frac{1}{n} \sum_{k=1}^n \mathbb{E}[X_k] = \frac{1}{n} n\mu = \mu.$$

Inoltre, usando l'indipendenza,

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{k=1}^n X_k\right) = \frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}.$$

Applicando Chebyshev a $\bar{X}_n$, per ogni $\eta > 0$ otteniamo

$$\mathbb{P}(|\bar{X}_n - \mu| > \eta) \leq \mathbb{P}(|\bar{X}_n - \mu| \geq \eta) \leq \frac{\text{Var}(\bar{X}_n)}{\eta^2} = \frac{\sigma^2}{n\eta^2} \rightarrow 0.$$

Dunque

$$\bar{X}_n \xrightarrow{\mathbb{P}} \mu.$$

Esempio Applicazione al lancio di una moneta

Nel caso $X_n \sim \text{Ber}(p)$, abbiamo

$$\mathbb{E}[X_n] = p, \quad \text{Var}(X_n) = p(1-p).$$

Quindi, per ogni $\eta > 0$, la legge debole e la disuguaglianza di Chebyshev danno

$$\mathbb{P}(|\bar{X}_n - p| > \eta) \leq \frac{p(1-p)}{n\eta^2}.$$

Poiché

$$p(1-p) \leq \frac{1}{4} \quad \forall p \in [0, 1],$$

otteniamo anche la stima uniforme

$$\mathbb{P}(|\bar{X}_n - p| > \eta) \leq \frac{1}{4n\eta^2}.$$

Questa disuguaglianza mostra due fatti intuitivi:

- più n è grande, più è piccola la probabilità che $\bar{X}_n$ sia lontana da p ;
- più scegliamo η piccolo, cioè più vogliamo una stima precisa, più aumenta la probabilità di sbagliare di più di η .

La legge debole dice che, per n grande, è improbabile che $\bar{X}_n$ si discosti da μ più di η . Tuttavia non afferma che tale probabilità sia mai esattamente nulla: per ogni n finito può ancora capitare una deviazione grande, anche se con probabilità piccola.

Legge forte dei grandi numeri

Teorema Legge forte dei grandi numeri

Sia $\{X_n\}_{n \in \mathbb{N}}$ una successione di variabili aleatorie reali indipendenti e identicamente distribuite, con

$$\mathbb{E}[X_n] = \mu, \quad \text{Var}(X_n) = \sigma^2 < +\infty.$$

Allora

$$\bar{X}_n \xrightarrow{\text{q.c.}} \mu.$$

Proof

Poniamo

$$S_n = \sum_{k=1}^n X_k, \quad \bar{X}_n = \frac{S_n}{n}.$$

Cominciamo osservando perché la dimostrazione non segue direttamente dalla legge debole. Fissato $\eta > 0$, poniamo

$$A_n(\eta) = \left\{ \left| \frac{S_n}{n} - \mu \right| > \eta \right\}.$$

Per Chebyshev,

$$\mathbb{P}(A_n(\eta)) \leq \frac{\sigma^2}{n\eta^2}.$$

Ma

$$\sum_{n=1}^{+\infty} \frac{\sigma^2}{n\eta^2} = +\infty,$$

quindi non possiamo applicare direttamente Borel-Cantelli agli eventi $A_n(\eta)$.

Il trucco è considerare prima la sottosuccessione degli indici quadrati. Per ogni $k \in \mathbb{N}$, poniamo

$$A_{k^2}(\eta) = \left\{ \left| \frac{S_{k^2}}{k^2} - \mu \right| > \eta \right\}.$$

Allora, sempre per Chebyshev,

$$\mathbb{P}(A_{k^2}(\eta)) \leq \frac{\sigma^2}{k^2 \eta^2}.$$

Quindi

$$\sum_{k=1}^{+\infty} \mathbb{P}(A_{k^2}(\eta)) \leq \frac{\sigma^2}{\eta^2} \sum_{k=1}^{+\infty} \frac{1}{k^2} < +\infty.$$

Per il lemma di Borel-Cantelli segue che

$$\frac{S_{k^2}}{k^2} \xrightarrow{\text{q.c.}} \mu.$$

Supponiamo ora, per il momento, che

$$X_n \geq 0 \quad \text{q.c.} \quad \forall n \in \mathbb{N}.$$

Allora la successione $\{S_n\}_{n \in \mathbb{N}}$ è crescente quasi certamente. Per ogni n scegliamo $k_n \in \mathbb{N}$ tale che

$$k_n^2 \leq n < (k_n + 1)^2.$$

Poiché S_n è crescente,

$$S_{k_n^2} \leq S_n \leq S_{(k_n+1)^2}.$$

Dividendo per n e usando

$$k_n^2 \leq n < (k_n + 1)^2,$$

otteniamo

$$\frac{S_{k_n^2}}{(k_n + 1)^2} \leq \frac{S_n}{n} \leq \frac{S_{(k_n+1)^2}}{k_n^2}.$$

Riscriviamo gli estremi come

$$\frac{k_n^2}{(k_n + 1)^2} \frac{S_{k_n^2}}{k_n^2} \leq \frac{S_n}{n} \leq \frac{(k_n + 1)^2}{k_n^2} \frac{S_{(k_n+1)^2}}{(k_n + 1)^2}.$$

Quando $n \rightarrow +\infty$, anche $k_n \rightarrow +\infty$, e

$$\frac{k_n^2}{(k_n + 1)^2} \rightarrow 1, \quad \frac{(k_n + 1)^2}{k_n^2} \rightarrow 1.$$

Inoltre abbiamo già dimostrato che

$$\frac{S_{k^2}}{k^2} \xrightarrow{\text{q.c.}} \mu.$$

Per il teorema dei carabinieri,

$$\frac{S_n}{n} \xrightarrow{\text{q.c.}} \mu$$

nel caso $X_n \geq 0$ quasi certamente.

Passiamo al caso generale. Scriviamo

$$X_n = X_n^+ - X_n^-,$$

dove

$$X_n^+ = \max\{0, X_n\}, \quad X_n^- = \max\{0, -X_n\}.$$

Poiché le variabili X_n sono identicamente distribuite e hanno momento secondo finito, anche $\{X_n^+\}_{n \in \mathbb{N}}$ e $\{X_n^-\}_{n \in \mathbb{N}}$ sono successioni indipendenti e identicamente distribuite di variabili non negative con momento secondo finito. Applicando il caso non negativo otteniamo

$$\frac{1}{n} \sum_{k=1}^n X_k^+ \xrightarrow{\text{q.c.}} \mathbb{E}[X_1^+],$$

e

$$\frac{1}{n} \sum_{k=1}^n X_k^- \xrightarrow{\text{q.c.}} \mathbb{E}[X_1^-].$$

Sull'intersezione dei due insiemi di probabilità 1, possiamo sottrarre i due limiti:

$$\frac{1}{n} \sum_{k=1}^n X_k = \frac{1}{n} \sum_{k=1}^n X_k^+ - \frac{1}{n} \sum_{k=1}^n X_k^- \xrightarrow{\text{q.c.}} \mathbb{E}[X_1^+] - \mathbb{E}[X_1^-] = \mathbb{E}[X_1] = \mu.$$

Quindi

$$\bar{X}_n \xrightarrow{\text{q.c.}} \mu.$$

Remark Osservazioni sulle due leggi dei grandi numeri

Abbiamo dimostrato la legge debole e la legge forte sotto ipotesi molto simili. Poiché

$$\bar{X}_n \xrightarrow{\text{q.c.}} \mu \implies \bar{X}_n \xrightarrow{\mathbb{P}} \mu,$$

la legge forte implica la legge debole. Tuttavia entrambe le leggi possono essere dimostrate anche sotto ipotesi più deboli di quelle usate qui.

La legge forte dice qualcosa di più della legge debole: $\bar{X}_n$ può discostarsi molto da μ , ma l'insieme degli ω per cui questo accade definitivamente in modo incompatibile con la convergenza ha probabilità nulla. Invece, nella legge debole, il limite riguarda le probabilità

$$\mathbb{P}(|\bar{X}_n - \mu| > \eta),$$

cioè il limite è esterno allo spazio campionario.

Infine, come già visto per le nozioni di convergenza, per risultati quasi certi serve in generale informazione sulla legge congiunta dell'intera successione $\{X_n\}_{n \in \mathbb{N}}$. Per risultati in probabilità spesso bastano informazioni più deboli, come media e varianza di $\bar{X}_n$.

Teorema centrale del limite

Teorema Teorema centrale del limite

Sia $\{X_n\}_{n \in \mathbb{N}}$ una successione di variabili aleatorie reali indipendenti e identicamente distribuite, con

$$\mathbb{E}[X_n] = \mu, \quad \text{Var}(X_n) = \sigma^2 \in (0, +\infty).$$

Allora

$$\frac{\sqrt{n}}{\sigma} (\bar{X}_n - \mu) \xrightarrow{d} Z, \quad Z \sim \mathcal{N}(0, 1).$$

Questo teorema non viene dimostrato qui. La nozione di convergenza usata è la più debole tra quelle considerate, cioè la convergenza in distribuzione. Tuttavia il teorema centrale del limite fornisce un'informazione molto precisa: descrive la legge limite delle fluttuazioni di $\bar{X}_n$ attorno a μ , dopo la normalizzazione corretta.

Remark Normalizzazione

Il fattore σ è essenziale. Infatti la forma equivalente del teorema è

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

Dividendo per σ si ottiene il limite normale standard:

$$\frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, 1).$$

Esempio Caso gaussiano

Supponiamo che

$$X_n \sim \mathcal{N}(\mu, \sigma^2) \quad \forall n \in \mathbb{N},$$

e che le variabili X_n siano indipendenti. Allora la media campionaria è ancora gaussiana e vale

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Infatti la somma di variabili gaussiane indipendenti è gaussiana, e

$$\mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Di conseguenza

$$\bar{X}_n - \mu \sim \mathcal{N}\left(0, \frac{\sigma^2}{n}\right),$$

e quindi

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu) \sim \mathcal{N}(0, 1) \quad \forall n \in \mathbb{N}.$$

Se F_n è la funzione di ripartizione di

$$Z_n = \frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu)$$

e F è la funzione di ripartizione di $Z \sim \mathcal{N}(0, 1)$, allora

$$F_n(x) = F(x) \quad \forall x \in \mathbb{R}, \quad \forall n \in \mathbb{N}.$$

Quindi, in questo caso, la convergenza in distribuzione è immediata.

9 Esercizi

Esercizio

Due variabili aleatorie X, Y sono indipendenti ed hanno distribuzione uniforme rispettivamente sugli insiemi $\{0, 1, 2\}$ e $\{0, 1, 2, 3\}$.

1. Calcolare la distribuzione congiunta di (X, Y) ;
2. Calcolare la distribuzione di $U \triangleq XY$;
3. Calcolare la distribuzione di $V \triangleq X + Y$;
4. Calcolare $\mathbb{E}[UV]$;
5. Calcolare $\text{Var}(UV)$.

Soluzione

1. Visto che X e Y sono indipendenti allora la congiunta del vettore è il prodotto delle densità

$$p_{X,Y}(x, y) = p_X(x)p_Y(y), \quad x \in \{0, 1, 2\}, y \in \{0, 1, 2, 3, 4\}$$

Visto che X e Y hanno legge uniforme

$$p_X(x) = \frac{1}{3}, \quad p_Y(y) = \frac{1}{4}, \quad x \in \{0, 1, 2\}, y \in \{0, 1, 2, 3, 4\}$$

Quindi

$$p_{X,Y}(x, y) = \frac{1}{12}, \quad \forall (x, y) \in \{0, 1, 2\} \times \{0, 1, 2, 4\}$$

2. Notiamo subito che il supporto di U è $\{0, 1, 2, 4, 8\}$. Per esempio

$$\mathbb{P}(U = 8) = \mathbb{P}(X = 2, Y = 4) = p_{X,Y}(2, 4) = \frac{1}{12}$$

Visto che la distribuzione è uniforme, possiamo contare i casi

$X \backslash Y$	0	1	2	4
0	0	0	0	0
1	0	1	2	4
2	0	2	4	8

Abbiamo quindi i seguenti:

$$\mathbb{P}(U = 0) = \frac{6}{12} = \frac{1}{2}$$

$$\mathbb{P}(U = 1) = \frac{1}{12} = \mathbb{P}(U = 8)$$

$$\mathbb{P}(U = 2) = \frac{1}{4} = \mathbb{P}(U = 4)$$

Infatti la somma totale è

$$\frac{1}{2} + 2 \cdot \frac{1}{12} + \frac{1}{6} + \frac{1}{6} = 1$$

3. Notiamo subito che il supporto di U è $\{0, 1, 2, 3, 4, 5, 6\}$. Visto che la distribuzione è uniforme, possiamo contare i casi

$X \backslash Y$	0	1	2	4
0	0	1	2	4
1	1	2	3	5
2	2	3	4	6

$$\begin{aligned}\mathbb{P}(U=0) &= \mathbb{P}(U=6) = \mathbb{P}(U=5) = \frac{6}{12} = \frac{1}{2} \\ \mathbb{P}(U=1) &= \mathbb{P}(U=3) = \mathbb{P}(U=4) = \frac{1}{6} \\ \mathbb{P}(U=2) &= \frac{1}{4}\end{aligned}$$

Infatti la somma è 1.

4. Purtroppo U e V sono possibilmente dipendenti. Quindi scriviamo

$$\begin{aligned}\mathbb{E}[UV] &= \mathbb{E}[XY(X+Y)] = \mathbb{E}[X^2Y + XY^2] \\ &= \mathbb{E}[X^2Y] + \mathbb{E}[Y^2X] \\ &= \mathbb{E}[Y]\mathbb{E}[X^2] + \mathbb{E}[Y^2]\mathbb{E}[X]\end{aligned}\quad \left. \vphantom{\begin{aligned}\mathbb{E}[UV] &= \mathbb{E}[XY(X+Y)] \\ &= \mathbb{E}[X^2Y] + \mathbb{E}[Y^2X] \\ &= \mathbb{E}[Y]\mathbb{E}[X^2] + \mathbb{E}[Y^2]\mathbb{E}[X]\end{aligned}} \right\} \text{Indipendenza}$$

Allora abbiamo

$$\begin{aligned}\mathbb{E}[X] &= \frac{1}{3}(1+2) = 1 \\ \mathbb{E}[Y] &= \frac{1}{4}(1+2+4) = \frac{7}{4} \\ \mathbb{E}[X^2] &= \frac{1}{3}(1+4) = \frac{5}{3} \\ \mathbb{E}[Y^2] &= \frac{1}{4}(1+4+14) = \frac{21}{4}\end{aligned}$$

Quindi complessivamente

$$\mathbb{E}[UV] = \frac{7}{4} \cdot \frac{5}{3} + 1 \cdot \frac{21}{4} = \frac{49}{6}$$

Si poteva calcolare la congiunta di (U, V) partendo dalla congiunta di (X, Y) e poi usando il risultato che dice che

$$\mathbb{E}[UV] = \sum_{u,v \in \mathbb{R}} uv p_{U,V}(u, v)$$

5. TODO

Esercizio

Sia (X, Y) un vettore aleatorio discreto le cui densità marginali sono fissate come segue

$$\begin{aligned}\mathbb{P}(X=1) &= p_X(1) = 0.3 = 1 - p_X(2) = 1 - \mathbb{P}(X=2) \\ \mathbb{P}(Y=1) &= p_Y(1) = 0.6 = 1 - p_Y(2) = 1 - \mathbb{P}(Y=2)\end{aligned}$$

e la densità congiunta è

$$\mathbb{P}(X=k, Y=n) \triangleq p_{X,Y}(k, n) = p_{k,n}$$

1. Si calcoliamo $\mathbb{E}[X]$, $\mathbb{E}[Y]$, $\text{Var}(X)$ e $\text{Var}(Y)$;
2. Determinare le distribuzioni congiunte che, rispettivamente rendono minima e massima la covarianza tra le due variabili aleatorie.
3. Determinare la distribuzione congiunta che rende incorrelate (scorrelate) X e Y , verificare se tale distribuzione le rende anche indipendenti.

Soluzione

1. Possiamo fare una tabella di contingenza, cioè

$Y \backslash X$	1	2	
1	$p_{1,1}$	$p_{2,1}$	$p_Y(1) = 0.6$
2	$p_{1,2}$	$p_{2,2}$	$p_Y(2) = 0.4$
	$p_X(1) = 0.3$	$p_X(2) = 0.7$	

A destra abbiamo i valori marginali di Y e sotto i valori marginali di X . Abbiamo quindi

$$\mathbb{E}[X] = 0.3 + 0.7 \cdot 2 = 1.7$$

$$\mathbb{E}[X^2] = 3.1 - (1.7)^2 = 0.21$$

$$\mathbb{E}[Y] = 0.6 + 0.4 \cdot 2 = 1.4$$

$$\mathbb{E}[Y^2] = 0.6 + 0.4 \cdot 4 = 2.2$$

$$\text{Var}(Y) = 2.2 - (1.4)^2 = 0.24$$

2. Abbiamo che la covarianza

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[XY] - 1.7 \cdot 1.4$$

Quindi dobbiamo massimizzare o minimizzare $\mathbb{E}[XY]$ con

$$\mathbb{E}[XY] = \sum_{x,y \in \mathbb{R}} xyp_{X,Y}(x,y) = p_{1,1} + 2(p_{2,1} + p_{1,2}) + 4 \cdot p_{2,2}$$

L'idea è quella di scrivere i vari $p_{i,j}$ in funzione di una sola incognita x . Scriviamo

$$x \triangleq p_{1,1}$$

$$p_{1,1} + p_{1,2} = 0.3 \rightarrow p_{1,2} = 0.3 - x$$

$$p_{1,1} + p_{2,1} = 0.6 \rightarrow p_{2,1} = 0.6 - x$$

$$p_{1,1} + p_{2,1} + p_{1,2} + p_{2,2} = 1 \rightarrow p_{2,2} = 0.1 + x$$

Quindi abbiamo pure il vincolo che $0 \leq x \leq 0.3$. Allora sostituendo otteniamo

$$\begin{aligned} \mathbb{E}[XY] &= x + 2(0.3 - x + 0.6 - x) + 4(0.1 + x) \\ &= x + 2.2 \end{aligned}$$

Quindi i valori di massimo e minimo avvengono per $x = 0.3$ e $x = 0$ rispettivamente, cioè per il massimo vale

$$p_{1,1} = 0.3, \quad p_{1,2} = 0, \quad p_{2,1} = 0.3, p_{2,2} = 0.4$$

e per il minimo

$$p_{1,1} = 0, \quad p_{1,2} = 0.3, \quad p_{2,1} = 0.6, p_{2,2} = 0.1$$

3. Incorrelate significa che la covarianza fra X e Y è nulla. Da prima sappiamo che $\mathbb{E}[XY] = x + 2.2$. Quindi

$$\text{Cov}(X, Y) = x + 2.2 - 1.7 \cdot 1.4 = x - 0.18$$

Quindi la covarianza è nulla se e solo se $x = 0.18$. Per tale valore abbiamo

$$p_{1,1} = 0.18, \quad p_{1,2} = 0.12, \quad p_{2,1} = 0.42, p_{2,2} = 0.28$$

Verifichiamo l'indipendenza studiando se la congiunta fattorizza in tutti i punti. Vediamole tutte

$$p_X(1)p_Y(1) = 0.3 \cdot 0.6 = 0.18 = p_{1,1}$$

$$p_X(1)p_Y(2) = 0.3 \cdot 0.4 = 0.12 = p_{1,2}$$

$$p_X(2)p_Y(1) = 0.7 \cdot 0.6 = 0.42 = p_{2,1}$$

$$p_X(2)p_Y(2) = 0.7 \cdot 0.4 = 0.28 = p_{2,2}$$

Quindi sono indipendenti.

Esercizio

Ci sono due urne $\mathcal{U}_1, \mathcal{U}_2$ così composte:

1. $\mathcal{U}_1$ contiene 10 palline con il numero 1 e 5 palline con il numero 2;
2. $\mathcal{U}_2$ contiene 8 palline con il numero 8 e 12 con il numero 2.

Si estrae una pallina dalla prima urna e si trasferisce nella seconda, dopo che si estrae una pallina dalla seconda urna.

1. Calcolare la probabilità di estrarre 1 dalla prima urna, sapendo che è stato estratto 2 dalla seconda urna.
2. Siano X_1, X_2 i risultati delle estrazioni dalla prima e dalla seconda urna, verificare se le due variabili aleatorie sono indipendenti.
3. Calcolare la distribuzione di $S \triangleq X_1 + X_2$;
4. Calcolare la probabilità che alla prima estrazione sia stato ottenuto 1 sapendo che $S = 2$.

Soluzione

1. Consideriamo $E_1^{(1)}$ l'evento "estratto 1 dall'urna 1" e $E_2^{(2)}$ l'evento "estratto 2 dall'urna 2". Abbiamo quindi

$$\begin{aligned}\mathbb{P}(E_1^{(1)}|E_2^{(2)}) &= \frac{\mathbb{P}(E_1^{(1)} \cap E_2^{(2)})}{\mathbb{P}(E_2^{(2)})} \\ &= \frac{\mathbb{P}(E_2^{(2)}|E_1^{(1)})\mathbb{P}(E_1^{(1)})}{\mathbb{P}(E_2^{(2)})} = \frac{\frac{12}{21} \cdot \frac{2}{3}}{\mathbb{P}(E_2^{(2)})} \\ \mathbb{P}(E_2^{(2)}) &= \mathbb{P}(E_2^{(2)}|E_1^{(1)})\mathbb{P}(E_1^{(1)}) + \mathbb{P}(E_2^{(2)}|E_1^{(2)})\mathbb{P}(E_1^{(2)}) \quad \left. \begin{array}{l} \text{Teorema probabilità} \\ \text{totali} \end{array} \right\} \\ &= \frac{12}{21} \cdot \frac{2}{3} + \frac{13}{21} \cdot \frac{1}{3} = \frac{37}{21 \cdot 3} \\ \mathbb{P}(E_1^{(1)}|E_2^{(2)}) &= \frac{24}{37}\end{aligned}$$

2. Si capisce subito non sono indipendenti però calcoliamo la congiunta perché ci servirà dopo. Abbiamo

$$\begin{aligned}p_{X_1, X_2}(1, 1) &= \mathbb{P}(X_1 = 1, X_2 = 1) = \mathbb{P}(X_2 = 1|X_1 = 1)\mathbb{P}(X_1 = 1) = \frac{9}{21} \cdot \frac{2}{3} \\ p_{X_1, X_2}(1, 2) &= \mathbb{P}(X_1 = 1, X_2 = 2) = \mathbb{P}(X_2 = 2|X_1 = 1)\mathbb{P}(X_1 = 1) = \frac{12}{21} \cdot \frac{2}{3} \\ p_{X_1, X_2}(2, 1) &= \mathbb{P}(X_1 = 2, X_2 = 1) = \frac{8}{21} \cdot \frac{1}{3} \\ p_{X_1, X_2}(2, 2) &= \mathbb{P}(X_1 = 2, X_2 = 2) = \frac{12}{21} \cdot \frac{1}{3}\end{aligned}$$

Controlliamo

$$p_{X_1, X_2}(1, 1) + p_{X_1, X_2}(1, 2) + p_{X_1, X_2}(2, 1) + p_{X_1, X_2}(2, 2) = \frac{18 + 24 + 8 + 13}{63} = 1$$

Da prima sappiamo che

$$\begin{aligned}p_{X_1}(1) &= \mathbb{P}(X_1 = 1) = \mathbb{P}(E_1^{(1)}) = \frac{2}{3} \\ p_{X_2}(2) &= \mathbb{P}(X_2 = 2) = \mathbb{P}(E_2^{(2)}) = \frac{XXX}{XXX}\end{aligned}$$

Tuttavia,

$$p_{X_1, X_2}(1, 2) = XXXXX \neq XXXXX$$

che differiscono.

3. $X_1 + X_2$ ha supporto $\{2, 3, 4\}$. Qua X_1 e X_2 non sono indipendenti quindi non possiamo contare i casi ma dobbiamo usare la congiunta

$$\mathbb{P}(X_1 + X_2 = 2) = \mathbb{P}(X_1, X_2 = 1) = p_{X_1, X_2}(1, 1) = \frac{6}{21}$$

$$\mathbb{P}(X_1 + X_2 = 3) = p_{X_1, X_2}(1, 2) + p_{X_1, X_2}(2, 1) = \dots$$

$$\mathbb{P}(X_1 + X_2 = 4) = p_{X_1, X_2}(2, 2) = \dots$$

4. TODO XXX

Esercizio

Consideriamo la variabile aleatoria reale X la cui funzione di ripartizione $F: \mathbb{R} \rightarrow \mathbb{R}$ è definita

$$F(t) \triangleq \begin{cases} 0 & t < 0 \\ t & t \in [0, 1/2) \\ at^2 + bt + \frac{1}{2} & t \in [1/2, 1) \\ 1 & t \geq 1 \end{cases}$$

1. Dimostrare che per $a = 1$ e $b = -1/2$ è una variabile aleatoria assolutamente continua. Calcolare la densità di X
2. fissati $a = 1$ e $b = -1/2$. Determinare il più piccolo intervallo chiuso e limitato S di $\mathbb{R}$ tale per cui la probabilità che X prenda valori in S è uguale a 1.
3. Fissati $a = 1$ e $b = -1/2$. Calcolare media e varianza di X .
4. Per quali valori di a, b , X è una variabile aleatoria tale che la probabilità dell'evento $\{X = 1/2\}$ è 0 e la probabilità dell'evento $\{X = 1\}$ è $1/4$? In questo caso X è ancora assolutamente continua?

Soluzione

1. Una condizione sufficiente per garantire che X sia assolutamente continua è che sia continua e $\mathcal{C}^1$ a tratti. Chiaramente è $\mathcal{C}^1$ a tratti per la definizione. Studiamo quindi la continuità nei punti $t = 0, 1/2, 1$. Ricordiamo che la funzione di ripartizione è continua da destra.

- Per $t = 0$ abbiamo $F(0) = 0$

$$\lim_{x \rightarrow 0^+} F(x) = 0$$

e quindi è continua.

- Per $t = 1/2$ abbiamo

$$F\left(\frac{1}{2}\right) = \frac{a}{4} + \frac{b}{2} + \frac{1}{2}$$

mentre il limite

$$\lim_{x \rightarrow \frac{1}{2}^-} F(x) = \frac{1}{2}$$

Serve quindi che

$$\frac{a}{4} + \frac{b}{2} + \frac{1}{2} = \frac{1}{2} \implies a = -2b$$

- Per $t = 1$ abbiamo

$$\lim_{x \rightarrow 1^-} F(x) = -2b + b + \frac{1}{2}$$

e $F(1) = 1$, quindi serve

$$-b + \frac{1}{2} = 1 \implies b = -\frac{1}{2}$$

e di conseguenza $a = 1$.

Abbiamo quindi la funzione

$$F_X(t) = \begin{cases} 0 & t < 0 \\ t & t \in [0, 1/2) \\ t^2 - \frac{t}{2} + \frac{1}{2} & t \in [1/2, 1) \\ 1 & t \geq 1 \end{cases}$$

La densità è data da $f_x = F'_x$ quasi ovunque, quindi

$$f_X(x) = \begin{cases} 0 & x < 0 \\ 1 & x \in [0, 1/2) \\ 2x - \frac{1}{2} & x \in [1/2, 1) \\ 0 & x \geq 1 \end{cases}$$

2. Bisogna trovare il più piccolo compatto S tale che

$$\mathbb{P}(X \in S) = 1$$

Dalla forma della densità troviamo immediatamente che $S = [0, 1]$ in quanto altrove la funzione è nulla. Dobbiamo tuttavia dimostrare che questo è il più piccolo compatto. Notiamo che la funzione di ripartizione è crescente e strettamente crescente in $[0, 1]$. Allora, $\forall a, b \in \mathbb{R}$ con $0 < a < b < 1$ vale che

$$\mathbb{P}(X \in (a, b)) = F(b) - F(a) > 0$$

Se esistesse $S' \subseteq S$ chiuso tale che $\mathbb{P}(X \in S') = 1$, allora

$$\mathbb{P}(X \in S \setminus S') = 0$$

Ma allora, F_x costante in $S \setminus S'$ che è assurdo in quanto F_x è crescente in S .

3. TODO media e varianza.
4. Abbiamo bisogno che

$$\mathbb{P}\left(X = \frac{1}{2}\right) = F_x\left(\frac{1}{2}\right) - \lim_{x \rightarrow \frac{1}{2}^-} F_x(x) = \frac{1}{2}$$

e

$$\mathbb{P}(X = 1) = F_x(1) - \lim_{x \rightarrow 1^-} F_x(x) = \frac{1}{4}$$

Dai conti precedenti abbiamo che $a = -2b$. Abbiamo $1 + 2b - b - 1/2 = \frac{1}{4}$ e quindi $b = -\frac{1}{4}$ e di conseguenza $a = 1/2$. Chiaramente non è più assolutamente continua in quanto la funzione non è più continua in un punto.

Soluzione Esercizio 1 del foglio 3

1. Integrale gaussiano normalizzato
2. Il valore atteso è dato da

$$\mathbb{E}[Z] = \int_{\mathbb{R}} z \varphi(z) dz = \int_{\mathbb{R}} \frac{z}{\sqrt{2\pi}} e^{-z^2/2} dz = 0$$

per simmetria. Quindi la varianza è data da

$$\text{Var}(Z) = \mathbb{E}[Z^2] - \mathbb{E}[Z]^2 = \mathbb{E}[Z^2]$$

con

$$\begin{aligned}\mathbb{E}[Z^2] &= \int_{\mathbb{R}} \frac{z^2}{\sqrt{2\pi}} e^{-z^2/2} dz \\ &= 2 \int_0^{\infty} \frac{z^2}{\sqrt{2\pi}} e^{-z^2/2} dz \\ &= \frac{2}{\sqrt{2\pi}} \left(\left[-ze^{-z^2/2} \right]_0^{\infty} + \int_0^{\infty} e^{-z^2/2} dz \right) \\ &= 2 \int_0^{\infty} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = 1\end{aligned}$$

3. Sia $X = \sigma Z + \mu$ e calcoliamone la funzione di ripartizione associata

$$\begin{aligned}F_X(x) &= \mathbb{P}(X \leq x) = \mathbb{P}(\sigma Z + \mu \leq x) \\ &= \mathbb{P}\left(Z \leq \frac{x - \mu}{\sigma}\right) = \int_{-\infty}^{\frac{x - \mu}{\sigma}} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz \\ &= \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{(t - \mu)^2}{2\sigma^2}} \cdot \frac{1}{\sigma} dt\end{aligned}$$

$t = z\sigma + \mu$

Al posto del cambio di variabile avremmo potuto derivare il tutto rispetto a x . Abbiamo quindi ottenuto

$$F_X(x) = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(t - \mu)^2}{2\sigma^2}} \cdot dx$$

Quindi X verifica la definizione di assoluta continuità con densità

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

4. Abbiamo la media

$$\mathbb{E}[X] = \mathbb{E}[\sigma Z + \mu] = \sigma \mathbb{E}[Z] + \mu = \mu$$

e la varianza

$$\text{Var}(Z) = \text{Var}(\sigma Z + \mu) = \sigma^2 \text{Var}(Z) + 0 = \sigma^2$$

Esercizio Da mettere come proposizione con già il risultato qua

Sia $Z \sim \mathcal{N}(0, 1)$. Z variabile aleatoria reale assolutamente continua con densità

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$$

Vogliamo calcolare i momenti di ordine $k \in \mathbb{N}$, cioè

$$\mathbb{E}[Z^k] = \int_{\mathbb{R}} z^k \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz$$

Soluzione

Sicuramente per $k = 1$ otteniamo il valore atteso $\mathbb{E}[Z] = 0$. Per $k = 2$ otteniamo la varianza $\mathbb{E}[Z^2] = 1$. Per $k = 3$ l'integranda è una funzione dispari per una funzione dispari, quindi pure questo integrale è zero. Quindi,

$$\mathbb{E}[Z^{2k+1}] = 0$$

Ci mancano i momenti pari. Ci sono vari modi: integrale per parti e per induzione trovare la forma chiusa, sfruttare la funzione generatrice dei momenti. Quello che facciamo è invece il seguente: speriamo che Y abbia una legge nella per cui è facile calcolarne i momenti

$$\mathbb{E}[Z^{2k}] = \mathbb{E}[Y^{2k}]$$

Calcoliamo la legge di Y^2 usando la funzione di ripartizione. Notiamo subito che

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(Z^2 \leq y) = 0, \quad \forall y \leq 0$$

Studiamola per $y > 0$. Abbiamo

$$\begin{aligned} F_Y(y) &= \mathbb{P}(Y \leq y) = \mathbb{P}(Z^2 \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) \\ &= 1 - \mathbb{P}(\{Z < -\sqrt{y}\} \cup \{Z > \sqrt{y}\}) \\ &= 1 - \mathbb{P}(\{Z \leq -\sqrt{y}\} \cup \{Z \geq \sqrt{y}\}) \\ &= 1 - 2\mathbb{P}(\{Z \geq \sqrt{y}\}) = 2F_Z(\sqrt{y}) - 1 \end{aligned} \quad \begin{array}{l} \left. \begin{array}{l} Z \text{ ass. continua quindi} \\ \text{aggiunta trascurabile} \\ \text{Medesima area} \end{array} \right\}$$

dove

$$F_Z(z) = \mathbb{P}(Z \leq z) = \int_{-\infty}^z f_Z(y) dy$$

Quindi abbiamo dimostrato che

$$F_Y(y) = \begin{cases} F_Y(y) = 2F_Z(\sqrt{y}) - 1 & y \geq 0 \\ 0 & y < 0 \end{cases}$$

Notiamo che F_Y è sicuramente continua in $\mathbb{R} \setminus \{0\}$ e in 0 vale che

$$F_Y(0) = 2F_Z(0) - 1 = 1 - 1 = 0 = \lim_{y \rightarrow 0^-} F_Y(y)$$

Abbiamo quindi dimostrato che $F_Y(y) = 2F_Z(\sqrt{y}) - 1$. Questo ci dice che F_Y è continua in quanto F_Z è continua. In realtà è pure C^1 a tratti. Quindi, Y è assolutamente continua con densità

$$f_Y(y) = \begin{cases} F'_Y(y) = 2F'_Z(\sqrt{y}) \cdot \frac{1}{\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2} & y \geq 0 \\ 0 & y < 0 \end{cases}$$

In altre parole,

$$f_Y(y) = \frac{1}{2y\pi} e^{-y/2} \chi_{(0,+\infty)}(y)$$

Una variabile aleatoria con tale densità è chiamata legge gamma di parametri $1/2$ e $1/2$ e viene indicata con $\Gamma(1/2, 1/2)$. In generale la gamma è data dalla densità

$$f_Y(x) = \frac{\beta^\alpha x^{\alpha-1} e^{-\beta x}}{\Gamma(\alpha)} \chi_{(0,+\infty)}(x)$$

con $\alpha, \beta > 0$. In questo caso usiamo la notazione $X \sim \Gamma(\alpha, \beta)$. Ricordiamo le proprietà di Γ :

1. $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$. Questa la si mostra per parti.

2.

$$\begin{aligned}\Gamma\left(\frac{1}{2}\right) &= \int_0^{+\infty} \frac{1}{\sqrt{y}} e^{-x} dx \\ &= \int_0^{+\infty} \frac{1}{y} e^{-y^2} \cdot 2y dy = \sqrt{\pi}\end{aligned}$$

$y = \sqrt{x}$

3. se $\alpha \in \mathbb{N}$ allora $\Gamma(\alpha) = (\alpha - 1)! \Gamma(1) = (\alpha - 1)!$.

Dimostriamo quindi che questa effettivamente integra a 1 (da mettere in una proposizione separata)

$$\begin{aligned}\int_{\mathbb{R}} f_X(x) dx &= \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} \beta^\alpha x^{\alpha-1} e^{\beta x} dx \\ &= \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} y^{\alpha-1} e^{-y} dy = \frac{\Gamma(\alpha)}{\Gamma(\alpha)} = 1\end{aligned}$$

$y = \beta x$

Da questo conto abbiamo visto che β non è altro che un fattore di scala, in particolare $X \sim \Gamma(\alpha, \beta)$ equivalente a dire $X \sim \frac{W}{\beta}$ dove $W \sim \Gamma(\alpha, 1)$. Calcoliamo ora i momenti della distribuzione gamma. Partiamo da $W \sim \Gamma(\alpha, 1)$. Abbiamo

$$\begin{aligned}\mathbb{E}[W^k] &= \int_{\mathbb{R}} y^k f_W(y) dy = \frac{1}{\Gamma(\alpha)} \int_0^{\infty} y^k y^{\alpha-1} e^{-y} dy \\ &= \frac{\Gamma(\alpha + k)}{\Gamma(\alpha)} = (\alpha + k - 1)(\alpha + k - 2) \cdots \alpha\end{aligned}$$

Ricordando che $X \sim \Gamma(\alpha, \beta)$ equivalente $X = \frac{W}{\beta}$ troviamo

$$\mathbb{E}[X^k] = \mathbb{E}\left[\frac{1}{\beta^k} W^k\right] = \frac{1}{\beta^k} (\alpha + k - 1) \cdots \alpha$$

Tornando al nostro problema iniziale avevamo $Z \sim \mathcal{N}(0, 1)$ e dobbiamo calcolare

$$\mathbb{E}[Z^{2k}] = \mathbb{E}[(Z^2)^k]$$

Abbiamo trovato che $Y = Z^2 \sim \Gamma(1/2, 1/2)$ e quindi

$$\begin{aligned}\mathbb{E}[Z^{2k}] &= \mathbb{E}[Y^k] = 2^k \left(\frac{1}{2} + k - 1\right) \left(\frac{1}{2}k - 2\right) \cdots \frac{1}{2} \\ &= (2k - 1)(2k - 3)(2k - 5) \cdots 1 = (2k - 1)!!\end{aligned}$$

Esercizio

Sia (X, Y) il vettore aleatorio di $\mathbb{R}^2$ assolutamente continuo con densità

$$f_{X,Y}(x, y) = \frac{x}{4} e^{-\frac{x^2}{4}} y \chi_D(x, y)$$

con

$$D = \{(x, y) \in \mathbb{R}^2 \mid 0 < y < x\} \subseteq \mathbb{R}^+ \times \mathbb{R}^+$$

1. Calcolare le marginali del vettore
2. Determinare se X e Y sono indipendenti.
3. Considera il vettore $(X, X/Y)$, questo ha componenti indipendenti?

Esercizio

1. abbiamo per $x > 0$

$$\begin{aligned} f_X(x) &= \int_{\mathbb{R}} f_{X,Y}(x,y) dy = \int_0^x \frac{x}{4} e^{-\frac{x^2}{4}} y dy \\ &= \frac{x}{4} e^{-\frac{x^2}{4}} \left[\frac{y^2}{2} \right]_0^x = \frac{x^3}{8} e^{-\frac{x^2}{4}} \end{aligned}$$

Quindi

$$f_X(x) = \frac{x^3}{8} e^{-\frac{x^2}{4}} \chi_{(0,+\infty)}(x)$$

Analogamente troviamo per $y > 0$

$$\begin{aligned} f_Y(y) &= \int_{\mathbb{R}} f_{X,Y}(x,y) dx = \int_y^{+\infty} \frac{x}{4} e^{-\frac{x^2}{4}} y dx \\ &= \frac{y}{2} \int_y^{+\infty} \frac{x}{2} e^{-\frac{x^2}{4}} dx \\ &= \frac{y}{2} \left[-e^{-\frac{x^2}{4}} \right]_y^{+\infty} = \frac{y}{2} e^{-\frac{y^2}{4}} \end{aligned}$$

Quindi

$$f_Y(y) = \frac{y}{2} e^{-\frac{y^2}{4}} \chi_{(0,+\infty)}(y)$$

2. Guardiamo se il prodotto delle marginali coincide con la congiunta. Ad occhio, non sembrano indipendenti in quanto non si riesce a fattorizzare la funzione indicatrice χ_D . Una funzione indicatrice di un prodotto cartesiano è il prodotto delle funzioni indicatrici, ma in questo caso la funzione indicatrice è su un dominio non rettangolare. Chiaramente $f_{X,Y}$ è continua in

$$C = \{(x,y) \in \mathbb{R}^2 \mid 0 < x < y\}$$

e pure f_X e f_Y . Evitiamo quindi i punti sulla bisettrice. Se prendiamo un punto $(x,y) \in C$, allora $f_{X,Y}(x,y) = 0$. Tuttavia, $f_X(x) > 0$ e $f_Y(y) > 0$ e quindi X e Y non sono indipendenti.

3. Per prima cosa dobbiamo calcolare la legge del vettore $(U,V) = (X, X/Y)$. Usiamo il teorema di trasformazione con diffeomorfismo. Chiaramente $\mathbb{P}((X,Y) \in D) = 1$ e $(U,V) = \varphi(X,Y)$ con $\varphi(x,y) = (x, x/y)$. Di conseguenza, siccome x è sempre maggiore di y , abbiamo

$$\varphi(D) = \mathbb{R}^+ \times (1, +\infty)$$

Per il teorema

$$f_{U,V}(u,v) = \begin{cases} f_{X,Y}(\varphi^{-1}(u,v)) |\det([J\varphi^{-1}](u,v))| & (u,v) \in \varphi(D) \\ 0 & (u,v) \notin \varphi(D) \end{cases}$$

Dobbiamo calcolare φ^{-1} . Invertendo troviamo $x = u$ e $y = u/v$, cioè

$$\varphi^{-1}(u,v) = (u, u/v)$$

La Jacobiana è data da

$$[J\varphi^{-1}](u,v) = \begin{pmatrix} 1 & 0 \\ \frac{1}{v} & -\frac{u}{v^2} \end{pmatrix}$$

il cui determinante è $-\frac{u}{v^2}$ che è non-nullo per ogni $u, v \in \varphi(D)$. Quindi,

$$\begin{aligned} f_{U,V}(u, v) &= f_{X,Y}(\varphi^{-1}(u, v)) \frac{u}{v^2} \chi_{\varphi(D)}(u, v) \\ &= \frac{v}{4} e^{-v^2/4} \frac{u}{v} \frac{u}{v^2} \chi_{(0,+\infty) \times (1,+\infty)}(u, v) \\ &= \frac{1}{4} \frac{u^3}{v^3} e^{-\frac{v^2}{4}} \chi_{(0,+\infty)}(u) \cdot \chi_{(+,\infty)}(v) \\ &= \alpha(u) \beta(v) \end{aligned}$$

con

$$\alpha(u) = \frac{1}{4} u^3 e^{-\frac{v^2}{4}} \chi_{(0,+\infty)}(u), \quad \beta(v) = \frac{1}{v^3} \chi_{(1,+\infty)}(v)$$

Quindi, $U = X$ e $V = X/Y$ sono indipendenti.

Esercizio

Sia (X, Y) vettore aleatorio assolutamente continuo con legge uniforme sul quadrato $[-1, 1]^2$, cioè ha densità

$$f_{X,Y}(x, y) = \frac{1}{4} \chi_{[-1,1]^2}(x, y)$$

È facile dimostrare che X e Y sono indipendenti con distribuzione uniforme sul segmento $[-1, 1]$ cioè

$$f_X(x) = \frac{1}{2} \chi_{[-1,1]}(x), \quad f_Y(y) = \frac{1}{2} \chi_{[-1,1]}(y)$$

Inoltre, il supporto di (X, Y) è precisamente il quadrato $[-1, 1]^2$. Vogliamo ruotare il quadrato di 45 gradi in senso antiorario e studiare cosa succede alla variabile aleatoria. Ci aspettiamo che dopo la rotazione le componenti del vettore non siano più indipendenti. Dimostrarlo.

Soluzione

Dobbiamo trovare la trasformazione data, cioè

$$A = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} = \frac{\sqrt{2}}{2} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$$

Notiamo subito che $\det A = 1$ in quanto elemento del gruppo ortogonale e

$$A^{-1} = \frac{A^t}{\det(A)} = \frac{\sqrt{2}}{2} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$$

Il nostro vettore è dato da $(U, V) = \varphi(X, Y)$ con $\varphi(x, y) = A \begin{pmatrix} x \\ y \end{pmatrix}$. Applichiamo il teorema circa le trasformazioni affini e otteniamo

$$\begin{aligned} f_{U,V}(u, v) &= \frac{1}{\det A} f_{X,Y}(A^{-1}(u, v)) \\ &= f_{X,Y} \end{aligned}$$

con

$$A^{-1} \begin{pmatrix} u \\ v \end{pmatrix} = \frac{\sqrt{2}}{2} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = \begin{pmatrix} \frac{\sqrt{2}}{2}(u+v), \frac{\sqrt{2}}{2}(v-u) \end{pmatrix}$$


Otteniamo quindi

$$\begin{aligned} f_{X,Y} \left(\frac{\sqrt{2}}{2}(u+v), \frac{\sqrt{2}}{2}(v-u) \right) &= \frac{1}{4} \chi_{[-1,1]^2} \left(\frac{\sqrt{2}}{2}(u+v), \frac{\sqrt{2}}{2}(v-u) \right) \\ &= \frac{1}{4} \chi_{[-1,1]} \left(\frac{\sqrt{2}}{2}(u+v) \right) \chi_{[-1,1]} \left(\frac{\sqrt{2}}{2}(v-u) \right) \end{aligned}$$

Possiamo per esempio mettere a sistema

$$\begin{cases} -1 \leq \frac{\sqrt{2}}{2}(u+v) \leq 1 \\ -1 \leq \frac{\sqrt{2}}{2}(v-u) \leq 1 \end{cases} \rightarrow \begin{cases} \frac{2}{\sqrt{2}} \leq u+v \leq \frac{2}{\sqrt{2}} \\ \frac{2}{\sqrt{2}} \leq v-u \leq \frac{2}{\sqrt{2}} \end{cases} \rightarrow \begin{cases} \frac{2}{\sqrt{2}} - u \leq v \leq \frac{2}{\sqrt{2}} - u \\ \frac{2}{\sqrt{2}} - u \leq v \leq \frac{2}{\sqrt{2}} - u \end{cases}$$

Questo è precisamente il rombo



Mostriamo quindi che sono dipendenti. Abbiamo quindi

$$f_{U,V}(u, v) = \frac{1}{4} \chi_{[-\sqrt{2}, \sqrt{2}]}(u+v) \chi_{[-\sqrt{2}, \sqrt{2}]}(v-u)$$

Calcoliamo le marginali

$$\begin{aligned} f_U(u) &= \int_{\mathbb{R}} f_{U,V}(u, v) dv = \int_{\mathbb{R}} \frac{1}{4} \chi_{[-\sqrt{2}, \sqrt{2}]}(u+v) \chi_{[-\sqrt{2}, \sqrt{2}]}(v-u) du \\ f_V(v) &= \int_{\mathbb{R}} f_{U,V}(u, v) du = \int_{\mathbb{R}} \frac{1}{4} \chi_{[-\sqrt{2}, \sqrt{2}]}(u+v) \chi_{[-\sqrt{2}, \sqrt{2}]}(v-u) dv \end{aligned}$$

Ci serve un punto (v_0, v_0) interno al rombo tale che

$$f_{U,V}(u_0, v_0) \neq f_U(u_0) f_V(v_0)$$

Prendiamo $(u_0, v_0) = (0, 0)$. Abbiamo che $f_{U,V}(0, 0) = \frac{1}{4}$, mentre

$$\begin{aligned} f_U(0) &= \int_{\mathbb{R}} \frac{1}{4} \chi_{[-\sqrt{2}, \sqrt{2}]}(v) \chi_{[-\sqrt{2}, \sqrt{2}]}(v) dv \\ &= \frac{\sqrt{2}}{2} f_V(0) = \int_{\mathbb{R}} \frac{1}{4} \chi_{[-\sqrt{2}, \sqrt{2}]}(u) \chi_{[-\sqrt{2}, \sqrt{2}]}(u) du \\ &= \frac{\sqrt{2}}{2} \end{aligned}$$

e quindi $f_V(0) f_U(0) = \frac{1}{2} \neq \frac{1}{4} = f_{U,V}(0, 0)$.